

빅데이터를 활용한 디지털금융전문가 과정

부실예측모형연구2

(Statistics Analysis. Machine Learning)

Population & Sample

● 모집단(population)

통계분석의 대상이 되는 모든 개체들의 집합

● 표본(sample)

모집단으로부터 임의로 추출된 모집단의 부분집합


→ 현실에서는 시간과 비용상의 제약으로 인해 전수조사보다는 표본을 조사하는 표본조사가 일반적으로 수행

● 모수(parameter)

모집단의 특성(characteristics)을 나타내 주는 수치 : 모평균, 모비율, 모분산, 모표준편차 등

● 표본통계량(sample statistic) 또는 통계량(statistic)

- 표본의 특성을 나타내는 척도
- 표본의 중심경향을 나타내는 표본평균, 표본비율 등
- 표본의 산포도를 나타내는 표본분산, 표본표준편차 등



Descriptive Statistics & Inferential Statistics

구분	내용
기술 통계 (Descriptive Statistics)	▪ 데이터의 간결한 요약 정보를 제공 ▪ 수집한 표본데이터의 주요 특성을 분석 및 기술하는 통계방법 ▪ 수치적으로, 그래프 등으로 시각화를 통해 데이터를 요약 ▪ 평균, 중앙값, 최빈도 ▪ 분산 (표준편차), 범위
추론 통계 (Inferential Statistics)	▪ 모집단에 대한 추론을 하기 위해서, 모집단으로부터 추출한 표본을 사용하여 모집단을 추론 ▪ 추정 (점추정, 구간추정) ▪ 가설검정 ▪ 검정통계량 ▪ P-value

Sampling Method

모집단의 특성을 파악하기 위해 표본을 추출한다면, 표본을 어떻게 추출하는지에 대한 방법도 중요하다.

1. 확률적 표본추출 방법(probability sampling method)

모집단에 속한 모든 단위가 표본으로 선택 받을 수 있는 확률이 동일하게 가지고 있는 경우


→ 무작위(랜덤)로 추출되어야만 한다. !!

2. 비확률적 표본추출 방법(non-probability sampling method)

모집단에 속한 모든 단위가 표본으로 선택 받을 수 있는 확률이 정확하게 결정되지 않은 상황 하에서의 표본추출 기법

→ 표집 편향에 영향을 받을 수 있다. → 모집단을 일반화하기 어렵다는 단점

표본 추출 방법 구분



Sampling Method

1. 확률적 표본추출 방법(probability sampling method)

1) 단순 무작위 표본추출

- 모집단의 모든 부분(표집 틀)이 표본으로 선택될 동일한 확률을 가지고 있는 경우
- 단순 무작위 표본추출을 위해 난수표나 컴퓨터를 활용한 무작위 배정을 통해 표본을 추출한다.
- 임의적인 수나 컴퓨터화된 임의 숫자 생성기를 활용하게 된다.
- 무작위로 표본이 뽑히기 때문에 표본은 편향되지 않으며 표본으로부터의 얻어진 결과를 통해 일반화 시킬 수 있다.

2) 체계적 표본추출

모집단에 번호를 부여하고 일정 간격으로 표본을 추출하는 방법
(사례: 선거 출구조사)

Sampling Method

1. 확률적 표본추출 방법(probability sampling method)

3) 비례층화 표본추출

- 어떠한 기준에 따라 모집단을 층 나누듯 범주화하고 이를 여러 소집단으로 구성하는 방법
- 집단 내에서는 동질적이지만 집단 간에는 이질적인 특성을 지닌다.
- 비례층화는 여러 집단으로 분류한 후 → 각 집단의 구성 개수에 비례하여 추출하는 방법
→ 다단계 층화 표본추출

4) 군집 표본추출법

- 군집표본(cluster sampling)은 모집단에서 집단을 일차적으로 표집한 다음, 선정된 각 집단에서 구성원을 표본으로 추출하는 다단계 표집 방법
- 주로 모집단을 총망라한 목록을 수집하기가 현실적으로 불가능할 때 사용
- 집락 내부는 이질적(heterogeneous)이고 집락 간에는 동질적(homogeneous) 특성을 가지도록 하는 것이 특징이며, 집락추출법의 효율성은 모집단 요소들의 목록화를 최소화하는 데에 달려있다.(집락 표집)
- 모집단의 규모가 커서 모집단을 확정할 수 있는 표본프레임을 찾기 어려울 때 모집단을 단계적으로 군집 또는 집단화

(군집추출방법 절차)

- 1) 소집단 분류 : 모집단을 상호배타적인 소집단으로 분류
- 2) 소집단 선정 : 분류된 소집단 중에서 무작위로 표본선정
 - (1) 1단계 군집표본추출 (one cluster sampling) : 세분된 소집단에 있는 모든 모집단 구성요소를 이용하는 경우
 - (2) 2단계 군집표본추출 (two cluster sampling) : 표본으로 선정된 소집단에서 표본구성요소를 확률적으로 다시 선정하는 방법

Sampling Method

1. 확률적 표본추출 방법(probability sampling method)

군집표본추출법, 층화표본추출법 유사점과 차이점

1) 유사점

소집단 세분

2) 차이점

- 층화표본추출법 : 각 소집단에서 일정한 표본이 선정되어 모든 소집단이 다 이용되어진다.
- 군집표본추출법 :
 - 소집단 전부가 표본으로 선정되거나 그 중 일부를 표본으로 선정되어 한개의 소집단이 표본이 되어 그 소집단 구성원을 모두 다 추출하거나 일정수만큼 추출할 수 있다.

Sampling Method

2. 비확률적 표본추출 방법(non-probability sampling method)

1) 편의 표본추출법

조사자 편의에 따라 모집단으로부터 접근성이 용이하고 편리한 방법을 통해 표본을 추출하는 방식 → 측정도구의 타당성을 확인하려는 목적의 예비조사에서 편리하게 사용

2) 판단 표본추출법(목적 표본추출법)

- 조사자의 주관에 따라 표본의 대상을 선정하는 것을 의미
- 이때 표본은 모집단의 특성을 반영할 수 있는 사람들로 구성이 되어야 하고 이를 위해서 조사자의 주관적 견해가 중요한 기준으로 작용 → 적은 수의 표본만으로도 모집단의 특성을 대표할 수 있는 장점

3) 할당 표본추출법

- 층화 표본추출법과 같이 모집단이 상호 배타적인 하위집단으로 나뉘어져 있는 상태에서 하위집단을 선택한 후 그 안에서 작위적으로 표본을 추출하는 방법
- 얼마나 할당해서 추출할지는 비례할당 추출법과 비비례할당 추출법에 따라 진행하면 된다.
- → 층화 표본추출법은 무작위적으로 표본이 추출되는 한편, 할당 표본추출법은 작위적으로 표본이 추출된다는 점에서 차이

4) 눈덩이 표본추출법

- 초기 연구에서 조사자의 대상을 쉽게 찾기 어려울 때 전문가 집단의 추천이나 권유를 통해 첫 표본만 소개를 받아 조사를 진행하고 그 후 그 표본에서 건너 건너 아는 사람을 통해 눈덩이식으로 불어나 표본을 추출하는 방법
- 접근하기 어려운 모집단을 대상으로 조사를 진행하거나 처음부터 표본 프레임을 선정하기 어려운 경우에서 유용하게 사용

Statistical Analysis

통계분석 한계

통계분석은 대부분 표본조사로 수행 → 모집단의 일부분인 표본에 의해서 전체의 특성을 파악하게 되기 때문에 오차가 발생, 또한 표본을 추출하고 조사를 수행하는 과정에서도 **오차(error)가 발생**

오차 : 표본오차와 비표본오차

1) 표본오차(sampling error)

모집단 전체의 특성을 나타내는 모수와 이와 연관된 표본통계량 사이에서 발생하는 오차

(예 : 표본평균과 모평균의 차이).

2) 비표본오차(non-sampling error)

표본추출 및 조사 수행 과정에서의 발생하는 모든 오류로서 누락, 오기, 모집단의 비합리적 설정 등으로 인하여 발생하는 오차

→ 표본의 크기가 증가되면 표본오차는 감소하게 되지만 표본의 크기를 증가시킬 경우 시간과 비용이 같이 증가하므로 적절한 표본오차 수준과 표본의 크기를 선정하는 것이 중요하다.


→ 일반적으로 표본의 크기가 증가하면 처리해야 하는 자료가 많아지므로 비표본오차는 오히려 증가하는 경향이 있다.
그러나 철저한 관리·감독을 통해 비표본오차는 감소시킬 수 있는 부분이므로 적절한 규모의 표본 크기를 고려해야 한다.

Statistical Analysis

Parameter

- **매개변수**
- 선형 회귀 또는 로지스틱 회귀에서의 **회귀계수**
- 인공신경망의 **가중치(w)**
- SVM(Support Vector Machine)의 서포트 벡터

$$y_i = \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i = \mathbf{x}_i^T \boldsymbol{\beta} + \varepsilon_i, \quad i = 1, \dots, n,$$



Hyperparameter

최적의 훈련 모델을 구현하기 위해 모델에 설정하는 변수 (특징)
 모델의 매개변수를 추정하는 데 도움이 되는 프로세스에서 사용

하이퍼파라미터

: 연구자가 수동으로 임의 설정 가능

: 학습 알고리즘의 샘플에 대한 일반화를 위해 조절 (사례)

- 학습률
 - 손실 함수
 - 미니배치 크기
 - 에포크 수
 - 은닉층 개수
 - k-NN의 k값
- 하이퍼파라미터의 튜닝 기법
- 그리드 탐색
 - 랜덤 탐색
 - 베이지안 최적화
 - 휴리스틱 탐색

Statistical Analysis : Data Type

범주형(categorical) 자료 (질적 척도(qualitative))

- 숫자들의 크기 차이가 계산되지 않는 척도
- 수학적 연산 결과는 의미가 없기 때문에 연산의 개념을 적용할 수 없음

1. 명목척도(Nominal Scale)

- 측정 대상이 어느 집단에 속하는지 분류할 때 사용
- 단순히 측정 대상의 특성을 분류하거나 확인하기 위한 목적으로 숫자를 부여

(사례)

- 성별(남자=1, 여자=2) , 혈액형
- 출생지역 , 자동차 브랜드명
- 종교

2. 순서척도/서열척도(Ordinal Scale)

- 측정 대상의 서열관계를 관측하는 척도
- 대소 또는 높고 낮음 등의 순위만 제공할 뿐 양적 비교 불가능

(사례)

- 만족도(상=1, 중=2, 하=3), 선호도,
- 학년, 신용등급, 내신등급

수치형 (numerical)자료 (양적 자료)

수치형자료. 숫자들의 크기 차이를 계산할 수 있는 척도

1. 구간척도/등간척도(interval scale)

- 측정 대상이 갖고 있는 속성의 양을 측정하는 것으로 구간 사이의 간격이 의미가 있는 자료
- 순위를 부여하되 순위 사이의 간격이 동일하여 양적 비교 가능

(사례)

온도, 지수

2. 비율척도

- 간격에 대한 비율이 의미를 가지는 자료,
- 절대적 기준인 0이 존재하고 사칙연산이 가능
- 제일 많은 정보를 가지는 척도

(사례)

무게, 나이, 시간, 거리

Statistical Analysis : Data Type

구분	내용	사례
비율척도	• 수치가 크기의 차이뿐 아니라, 그 비율까지 나타내 주는 것 • 하나의 측정치가 다른 측정치의 몇 배가 되느냐 하는 비율의 정보를 가르쳐 줄 수 있는 척도 • 분류, 서열, 동간성, 절대영점을 갖추고 있어 가감승제가 가능해 통계적 조작이 가능	원점수를 가공해서 얻은 표준점수인 Z점수, T점수 IQ검사의 원점수를 가공해서 얻은 편차 IQ 등
서열(序列)척도	• 크기나 중요성에 기준하여 측정결과들에 순위를 매기는 것 • 명명척도의 분류기능에다 순위를 나타내는 것을 추가한 것 • 척도가 나타내고 있는 속성이 정확하게 얼마나 되느냐는 정보는 알려 주지 못한다.	성적에 따라 A, B, C, D, F 분류 백분위 점수
명명(命名)척도	어떤 사물을 지칭하거나 분류하기 위해 부여한 임의의 수치나 기호	우편번호, 학생 학번
동간(同間)척도	• 수치의 차가 일정한 간격을 가지고 있는 경우 • 측정치의 순위 뿐 아니라, 측정치들이 얼마나 더 크고 작은 지를 알려준다	시험을 보고 얻은 원점수, IQ검사의 원점수, 나이 등

Central Tendency

중심경향도(central tendency)

1. 평균(Mean)

Mean , Median , Mode, Quantile

- **Average is a value which is typical of representative of a set of data.– Spiegel**
- **An average is an attempt to find one single figure to describe all the figures.– Clark and Sekkade**
- 모든 자료들을 다 합한 후 전체 자료의 수로 나누어 계산
- 평균은 구간척도와 비율척도로 측정된 자료의 대푯값으로 가장 널리 사용되는 수치
- 산술평균, 기하평균, 가중평균, 절사평균, 조화평균, 이동평균...

1. Mathematical Averages


Arithmetic Mean, Geometric Mean(G), Harmonic Mean(H)),

2. Positional Averages

Median(M or Me) and Mode(Z)),

3. Commercial Averages

Moving Average, Progressive Average, and Composite Average




<https://www.geeksforgeeks.org/measures-of-central-tendency-2/?ref=lbp>

Central Tendency

중심경향도(central tendency)


1. 평균(Mean)

Objective and Functions of Averages



Requisites of Measures of Central Tendency

Requisites of a Good Measure of Central Tendency



<https://www.geeksforgeeks.org/measures-of-central-tendency-2/?ref=lbp>

Central Tendency

1. 평균(Mean)

(1) 산술평균(AM : Arithmetic mean)

모든 자료들을 다 합한 후 전체 자료의 수로 나누어서 계산 → 일반적으로 평균(mean)은 산술평균을 의미
→ 항상 유일한(unique) 수치로 계산, → 가장 일반적인 중심경향도를 나타내는 것

1) 모평균(population mean)

: 모집단 전체자료를 합하여 자료의 총 관측수로 나눈 값

$$\mu = \frac{x_1 + x_2 + \dots + x_N}{N} = \frac{\sum_{i=1}^N x_i}{N}$$

2) 표본평균

: 표본집단 전체자료를 합하여 자료의 총 관측수로 나눈 값

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{\sum_{i=1}^n x_i}{n}$$

Central Tendency

* 평균과 기대값 /기대수익/기대수익률

* 평균과 기대수익률

1. 평균

표본평균 : 표본집단 전체자료를 합하여 자료의 총 관측수로 나눈 값

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{\sum_{i=1}^n x_i}{n}$$

2. 기대 값

확률을 고려한 평균

$$E(x) = \sum p_i x_i$$

(예시)

주사위 1, 2, 3, 4, 5, 6

- 평균 = $(1 + \dots + 6) / 6 = 3.5$
- 기대 값 = $1 \times \frac{1}{6} + \dots + 6 \times \frac{1}{6} = 3.5$

2. 기대값 (수익률)

과거 연평균수익률(추세분석법), 시나리오분석법 등

$$\bar{R} = \frac{1}{N} \sum_{i=1}^N R_i$$

$$R_i = \ln\left(\frac{S_t}{S_{t-1}}\right)$$

일별 로그(ln)수익률을 사용한 경우 → 연수익률로 환산하는 경우
연수익률 = $\bar{R}$ (일평균 로그수익률) $\times 252$

Central Tendency

1. 평균(Mean)

평균이라는 데이터의 함정 유의하기 !!!!!!!!!!!

평균값이 대표치로 부적절한 경우

대표치로 가장 많이 사용되는 수치는 모든 자료의 정보가 포함되는 산술평균

But 상황에 따라 산술평균이 대표치로서 부적절 !!!!

(부적절한 경우)

- ✓ 산술평균 : 이상치값이 포함된 경우 → 정규성 여부 검증??
- ✓ 명목자료나 서열자료와 같은 질적 자료의 경우
- ✓ 개방구간을 가진 도수분포 자료
- ✓ 자료의 수가 매우 적은 경우

(부적절한 경우 대응치)

중위수, 최빈수

* Simpson's Paradox

- 심슨(Simpson, E. ; 1910~1961)은 1951년에 여러 개의 그룹을 합쳐 놓았을 때 각 그룹의 우열 관계가 뒤바뀌는 현상에 대하여 주목
- 데이터를 그룹으로 나누었을 때와 전체 데이터를 볼 때 결과가 정반대로 나타날 수 있음을 보여주는 현상
- 데이터의 부분 집합에서 관찰된 경향이 전체 데이터 집합에서는 완전히 다른 경향을 보일 수 있다는 것
- 이 현상은 데이터를 해석할 때 매우 주의해야 하는 이유를 잘 보여준다.

심슨의 역설의 원인

- 데이터 내에 숨겨진 변수(lurking variable) 또는 교란 변수(confounding variable) 때문 존재하는 경우
- 이러한 변수들은 분석에서 고려되지 않았을 때, 잘못된 결론을 이끌어낼 수 있다.

중요성

- 데이터 분석과 해석에 있어서 변수 간의 상호작용과 구조적 요인을 고려하는 것의 중요성을 강조
- 데이터를 세분화하여 분석할 때는 특히 주의해야 하며, 전체적인 맥락과 다른 가능한 설명을 항상 염두에 두어야 한다.
- 데이터 분석에서 심슨의 역설을 인식하는 것은 잘못된 결론을 피하고, 더 정확하고 신뢰할 수 있는 해석을 도출하는데 중요하다.

버클리 대학교 성별 차별 사건

1973년, 캘리포니아 대학교 버클리 캠퍼스(UC Berkeley)에 대해 성별에 기반한 입학 과정에서의 차별이 있다는 주장이 제기

전체	지원자	합격자	합격률
남학생	1150	815	71%
여학생	820	185	23%

공과대	지원자	합격자	합격률
남학생	1000	800	80%
여학생	120	100	83%

문과대	지원자	합격자	합격률
남학생	150	15	10%
여학생	700	82	12%

여성이 더 경쟁이 치열한 학과에 더 많이 지원했기 때문일 수 있다.

Central Tendency

1. 평균(Mean)

(2) 기하평균(GM: Geometric mean)

- n개의 관측치에 대한 기하평균(geometric mean)은 관측치를 곱한 값의 n 제곱근으로 정의
- 인구증가율, 물가상승율, 경제성장률 등과 같이 연속적인 변화율 데이터를 기반으로 어느 구간에서의 평균 변화율을 구할 때 사용하는 것

$$\text{기하평균(GM)} = \sqrt[n]{X_1 \times X_2 \times \dots \times X_N} = (X_1 \times X_2 \times \dots \times X_N)^{\frac{1}{N}}$$

양변에 자연로그(natural logarithm)를 취해 변형해 사용

(예시) 100만원으로 투자 1기간 200만원 다음 2기간 100만원이 되었다면 산술평균과 기하평균수익률?

기하평균 다른 표현

$$G = \sqrt[n]{\prod_{i=1}^n x_i} \\ = (x_1 \times \dots \times x_n)^{1/n}$$



$$\begin{aligned} \ln G &= \frac{1}{n} \ln(x_1 \times \dots \times x_n) \\ &= \frac{1}{n} (\ln x_1 + \dots + \ln x_n) \\ &= \frac{1}{n} \sum_{i=1}^n \ln x_i \\ G &= \exp\left(\frac{1}{n} \sum_{i=1}^n \ln x_i\right) \end{aligned}$$

기하평균을 구할 때 주의할 사항

투자수익률과 같은 자료에서 음수의 값이 나올 때 이를 처리하는 방법은 루트 안의 수치는 음수의 값이 되지 않아야 하므로 %로 표현된 자료의 개별 값에 1을 더해주고 기하평균을 구한 뒤 도출된 결과에서 1을 차감해야 한다.

주가 연평균 수익률 : 산술평균 수익률 ? 기하평균수익률?

Central Tendency

1. 평균(Mean)

(3) 가중평균 (Weighted mean)

- 가중평균(weighted mean)은 각 관측치에 대한 가중치가 다를 때 평균을 구하는 방법
- 산술평균은 관측치마다 가중치를 동일하게 부여하여 평균을 구하는 방법 = 동일가중평균
- Portfolio 기대수익률: 포트폴리오를 구성하는 각 종목의 구성비율을 가중치(w_i)로 두고 개별종목의 수익률과 가중치를 고려하여 평균을 구하면 포트폴리오 전체의 기대수익률이 계산

$$\text{가중평균} (\bar{X}_w) = \sum_{i=1}^n w_i X_i, \sum_{i=1}^n w_i = 1$$

(4) 절사평균(Trimmed mean)

- 산술평균은 전체 자료의 값을 모두 반영한다는 점에서 가장 일반적인 자료의 대표값으로 사용되지만 한계점으로 자료에 극단적인 값(extreme value)이 존재하는 경우 크게 영향을 받아 대표값으로서의 가치가 떨어지는 경우가 있다.
- 극단적인 값, 이상치(outlier)가 있는 경우 자료의 분포 상태에 이외의 수치로 대표값을 선정하게 되는데 그 중 하나의 방법으로 절사평균 사용
- 절사평균(trimmed mean)은 자료 중에서 크거나 작은 일정 %를 버리고 평균을 계산

Central Tendency

1. 평균(Mean)

(5) 조화평균 (H : Harmonic mean)

- '주어진 수의 역수의 산술평균의 역수'
- 역수의 차원에서 평균을 구하고, 다시 역수를 취해 원래 차원의 값으로 돌아오는 것
(사례) 평균 속력을 구할 때 사용, 머신러닝(분류분석) 성과평가 F1 score

$$\text{조화평균(H)} = \frac{1}{\frac{1}{n} \sum \frac{1}{x_i}} = \frac{1}{\frac{1}{n} \left(\frac{1}{x_1} + \frac{1}{x_2} + \dots + \frac{1}{x_n} \right)}$$

(예시)

A지점에서 B 지점까지의 거리는 12 km

'갑'이 자전거를 타고 A에서 B로 이동할 때 평균 속력이 12 km/h이고, 반대로 B에서 A로 이동할 때(자전거 고장)으로 6 km/h로 이동했다고 하자.

A→B→A로 이루어지는 왕복 경로 동안 자전거가 이동하는 동안의 평균 속력은 얼마일까요?

자전거가 왕복하는데 걸리는 시간은 총 3 시간

- 산술평균 $(12+6)/2 = 9$ km, 9 km/h를 적용하여 왕복 24 km를 이동하는데 걸리는 시간 $24/9 = 2.7$ 시간
- 조화평균 8 km/h → 왕복 24 km를 이동하는데 걸리는 시간 $24/8 = 3$ 시간

산술평균, 기하평균 조화평균 크기 비교 ???

(사례) 1기: 10%, 2기: 20%

* Moving Average Line

* 주식시장 : 이동평균선

- N일 이동평균선은 과거 N일 동안의 주식 종가의 평균치를 매일 점으로 표시하고 이를 계속 이어서 선으로 표시한 것
- 5일MA, 20일MA, 60일, 120일 200일 MA

- Simple Moving Average, SMA
- Weighted Moving Average , WMA
- Exponential moving average, EMA

핀테크자료 : 4.증권분석 기술적분석 부분 참조

파이썬 : Pandas를 이용한 주가이동평균선

Central Tendency

2. 중앙치 (Median), 중위수

(정의)

- 관측치에 **극단적인 값이 존재하여 분포가 극도로 비대칭인 경우에는** 평균이 대표치로서 바람직하지 않으므로 중앙치를 많이 사용
중앙치(median)는 자료를 크기 순서로 배열했을 때 중앙에 위치하게 되는 수치로서 중위수라고도 부른다.

(특징)

- 중앙치를 기준으로 하여 전체 자료의 50%는 중앙치 하부에, 나머지 50%는 중앙치 상부에 분포하게 된다.
- → 계산된 중앙치의 값은 항상 유일한(unique) 값을 지닌다.

3. 최빈치(mode)

(정의)

최빈치(mode)는 가장 빈도가 높은 자료

(특징)

- 산술평균과 중앙치와는 달리 유일한 값으로 계산되지 않을 수 있다는 것이다.
- → 자료의 분포에 따라 최빈치는 여러 개가 나올 수도 있고 없을 수도 있다.

Central Tendency

4. 분위수(Quantile)

- 자료를 크기 순서로 배열할 경우 그 자료를 분할하는 역할을 하는 위치의 수치를 계산한 것
- 분위수의 종류 : 사분위수(Quartile), 오분위수(quintile), 십분위수(decile), 백분위수(percentile) 등

분위수 사용 용도

- 자료의 형태가 정규분포를 벗어나는 경우가 많거나,
- 산포가 매우 클 경우, 그 정도를 대략 파악하거나,
- 상하위 부분에서 극단적인 치우침이 있을 때
- 평균 만으로 통계를 대표할 수 없고, 평균,분위값을 함께 고려함이 적당함

사분위수(Quartile)


: 크기 순서에 따라 나열한 자료들을 4등분한 경우에, 분할 경계선 : 25%, 50%, 75% 100%.

n개의 값이 있다면 중앙값이 2사분위수인 Q2

(Q2 + 1)/2 번째가 1사분위수인 Q1,

(Q2 + n)/2 번째가 3사분위수인 Q3

- 제1 사분위수(또는 하위 사분위수) Q1은 f값이 0.25
- 제3 사분위수(또는 상위 사분위수) Q3은 f값이 0.75
- 사분위수 범위 : $Q3 - Q1$ 으로 정의
- 사분위수는 데이터 표본을 4개의 동일한 부분으로 나눈 값(1/4분위수와 3/4분위수를 많이 사용) → 사분위수는 데이터의 관측치가 아닌 계산된 값



Central Tendency

4. 분위수(Quantile)

사분위수(Quartile)

사분위수	내용
제1 사분위수(Q1)	데이터의 25%가 이 값보다 작거나 같음.
제2 사분위수(Q2)	중위수 데이터의 50%가 이 값보다 작거나 같음.
제3 사분위수(Q3)	데이터의 75%가 이 값보다 작거나 같음.
사분위간 범위	제1 사분위수와 제3 사분위수 간의 거리(Q3-Q1)이므로, 데이터의 중간 50%에 대한 범위

(예시)

N= 25 의 경우

(25, 27, 28, 32, 33, 33, 34, 35, 36, 37, 37, 37, 38, 38, 39, 40, 40, 41, 42, 43, 44, 44, 47, 48, 48)

1 사분위 위치 결정

공식을 사용하여 첫 번째 사 분위수의 위치를 결정 $k(N + 1) / 100, \rightarrow [25(25+1)]/100 = 6.5$

첫 번째 사 분위수가 $33+0.5(34-33) = 33.5$

3 분위 위치 결정

첫 번째 사 분위수를 결정했으면 다음 공식을 사용하여 세 번째 사 분위수의 위치를 결정

$k3 * (N + 1) / 100$ 여기서 N은 다시 데이터 세트의 포인트 수입니다.

$75(25+1)/100 = 19.5$

19번째와 20번째 가운데

$42 + 0.5(43-42) = 42.5$

Dispersion

분산도 (산포도. dispersion)

- 자료가 대표치를 중심으로 얼마나 밀집 또는 분산되어 있는가를 나타내는 수치
→ 흩어져 있는가를 나타내는 수치
- 산포도가 큰 자료는 변동이 크다는 것을 의미하며 변동이 크다는 것은 통계적 추론 과정에서 불확실성과 위험이 크다는 것
- 산포도 수치 : 범위, 분산과 표준편차, 사분위편차, 변동계수 등

1. 범위 (Range)

- **자료의 최대값과 최소값의 차이**
- 산포도를 알아보는 방법 중에서 가장 간단하게 값을 구할 수 있는 수치
(문제점)
 - 서로 다른 표본에서 조사한 자료의 범위가 같다고 해서 산포도가 같거나 혹은 유사하다고 분석하기는 힘들다.
 - → 범위는 자료의 수가 비교적 적은 경우 간단하게 대략적인 산포도를 파악하자 할 때 주로 사용

Dispersion

2. 분산(Variance)

평균과 개별 관측치 간의 차이 (이를 '편차'라고 함)를 **제공**한 후 그 **평균값**을 계산

→ (즉, 변동을 표본크기 배제를 위해 n으로 나눈 값)

- 분산이 클수록 개별 자료들이 평균으로부터 멀리 떨어져 있어서 편차가 심하다는 것을 의미

(1) 모분산(population variance)

모집단의 개별 자료와 모평균과의 차이를 제공하여 평균을 구한 값이며 모집단 자료의 산포도를 나타낸다.

(2) 표본분산(sample variance)

- 표본의 개별 자료와 표본평균과의 차이를 제공하여 평균을 구한 값이며 표본 자료의 산포도를 나타낸다.
- 표본분산을 구할 때는 모분산과 달리 분모를 표본의 크기 - 1인 n - 1로 나눠야 한다.
- (이유) n으로 나누어 표본분산을 구할 경우 표본분산은 모분산을 과소 추정되므로 → bias (뒷편 증명)

모분산(population variance)

$$\sigma^2 = \frac{\sum (x_i - \mu)^2}{n} = \frac{\sum x_i^2}{n} - \mu^2$$

표본분산(sample variance)

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n-1}$$

주식수익률의 분산

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (R_i - \bar{R})^2$$

$$R_i = \ln\left(\frac{S_t}{S_{t-1}}\right)$$

일별 로그수익률 사용한 경우 → 연수익률 분산으로 환산

s^2 은 일평균로그수익률의 분산 → $s^2 \times 252$

Dispersion

3. 표준편차(standard deviation)

- 분산을 통해 산포도를 구하는 이유는 개별치와 평균과의 차이를 단순히 합하게 되면 0($\sum \text{편차} = 0$)이 되므로 편차의 제곱을 계산하는 것 !!!
- 분산은 산포도를 직접적으로 해석하는 데에 어려움이 있다. 분산은 제공한 값의 평균이므로 원자료와 측정단위가 달라진다.
- → 따라서 분산에 양의 제곱근을 구하여 원래의 측정단위와 같도록 구한 수치가 필요하게 된다.

(1) 모표준편차(population standard deviation)

모집단의 개별 자료가 모평균과 얼마나 떨어져 있는가를 나타내는 수치이며 모분산의 양의 제곱근

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{\sum (x_i - \mu)^2}{n}}$$

Euclidean distance !!!

(2) 표본표준편차(sample standard deviation)

표본의 개별자료가 표본평균과 얼마나 떨어져 있는가를 나타내는 수치이며 표본분산의 양의 제곱근

$$s = \sqrt{s^2} = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n-1}}$$

- 덧셈 ↔ 뺄셈
- 곱셈 ↔ 나눗셈
- 제곱 ↔ 제곱근

주식수익률의 표준편차

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (R_i - \bar{R})^2}$$

Dispersion

4. 변동계수(CV: coefficient of variation)

- 산포도를 측정하는 수치들은 자료의 중심경향도를 나타내는 수치의 크기를 고려하지 않은 것이다.
→ 이러한 종류의 산포도는 중심경향도가 서로 다른 자료들을 비교할 경우 적합하지 못한 수치가 된다.
- 대표치가 서로 다른 자료간의 산포도를 비교할 수 있는 수치가 필요한데 이것을 변동계수(CV)또는 분산계수
→ 변동계수는 **상대적 표준편차**라고 불리며 산술평균에 대한 표준편차의 비율로 계산

$$CV = \frac{\text{표준편차}}{\text{평균}} \times 100$$

예) 집단 A는 평균 15, 표준편차가 5이며, 집단 B는 평균 20, 표준편차가 10이다. 두 집단 중에서 어떠한 집단의 산포도가 상대적으로 더 크다고 할 수 있는가?

A집단의 CV = $5/15 \times 100 = 33.3\%$

B집단의 CV = $10/20 \times 100 = 50.0\%$

따라서 B집단이 상대적으로 변동성이 더 크다.

Dispersion

5. 왜도(skewness)

왜도(skewness) : 분포의 비대칭 정도를 나타내는 수치
(계산) 개별 자료와 평균과의 편차를 세제곱하여 계산

$$\text{skewness} = \frac{1}{n} \frac{\sum (x_i - \bar{x})^3}{s^3}$$

1) 좌우 대칭인 분포의 경우 : 왜도의 값 = 0 → 정규분포 경우, 평균=중앙치=최빈치라는 식이 성립

2) 왜도 < 0 인 경우 (skewed to the left)

자료의 분포가 오른쪽으로 치우쳐져 있고 자료에 극단적으로 작은 값이 존재해서 왼쪽으로 꼬리가 생기는 분포(negatively skewed, 가 있다.



이 경우에 왜도의 수치는 음수의 값이 나오며 음의 값이 클수록 왼쪽으로 긴 꼬리를 갖는다는 의미이다.

평균은 극단적인 값에 영향을 받게 되므로 가장 적은 값을 갖게 된다. 자료의 대표치 사이에는 평균 < 중앙치 < 최빈치의 식이 성립한다.

3) 왜도 > 0 인 경우 (skewed to the right)

자료의 분포가 왼쪽으로 치우쳐져 있고 자료에 극단적으로 큰 값이 존재해서 오른쪽으로 꼬리가 생기는 분포(positively skewed)가 있다.

skewed to the left



skewed to the right

Dispersion

6. 첨도(kurtosis)

- 자료의 분포가 얼마나 중심에 집중되어 있는가를 나타내는 수치
- 첨도의 수치를 통해 자료의 분포가 얼마나 뾰족한 가를 측정할 수 있다.
- 자료의 뾰족한 정도는 정규분포를 기준으로 하여 상대적으로 나타내는 경우가 일반적이다.

(계산)

- 첨도는 개별자료와 평균과의 편차를 네제곱하여 계산
- 정규분포의 경우는 첨도 값 = 3
- 첨도 값 > 3 : 정규분포보다 더 뾰족함: 긴꼬리 분포가 되고 꼬리가 두텁다
- 첨도 값 < 3 : 정규분포보다 더 평평함 : 짧은꼬리 분포가 되고 꼬리가 얇다


$$\text{kurtosis} = \frac{1}{n} \frac{\sum (x_i - \bar{x})^4}{s^4}$$

$$m_4 = E\left[\left(\frac{X - \mu}{\sigma}\right)^4\right] - 3 = \frac{\mu_4}{\sigma^4} - 3$$

- $m_4 > 0$
· 표준정규분포 보다 더 뾰족함

- $m_4 < 0$
· 표준정규분포 보다 덜 뾰족함

- $m_4 = 0$
· 표준정규분포 정도의 뾰족함



* Python

https://github.com/freejyb/fin_stats

* Moment

적률(Moment)

- 확률 분포의 특성을 나타내는 수치
- 확률 분포의 형태와 특성을 이해하고 설명하는 데 사용
- 적률은 적률생성함수의 미분형태로 표현

구분	내용
1차 적률 (Mean)	▪ 확률 변수의 평균, 분포의 중심 위치 ▪ 표기 : $E[X]$ ▪ 확률 변수의 기대값과 동일
2차 적률 (Variance)	▪ 확률 변수의 분산 ▪ 확률 변수의 값이 평균으로부터 얼마나 퍼져 있는지 정도
3차 적률 (Skewness)	▪ 확률 분포의 왜도(비대칭도, skewness)를 측정 ▪ 0에 가까울수록 대칭 분포, 양수일 경우 왼쪽으로 긴 꼬리를 가진 분포, 음수일 경우 오른쪽으로 긴 꼬리를 가진 분포
4차 적률 (Kurtosis)	▪ 확률 분포의 첨도(뽀족함, kurtosis)를 측정 ▪ 정규분포의 경우 3에 가까운 값을 가지며, 이보다 큰 경우 뽀족한 꼬리를 가진 분포를 나타내며, 작은 경우 더 퍼진 꼬리를 가진 분포를 나타낸다.

Power of 'Mean'

Collective Intelligence

<https://www.youtube.com/watch?v=AgXSBgT7TDo>

<https://www.youtube.com/watch?v=din2UVvRnGU>

평균의 한계를 생각해보자 !!!!

Magic of 'Variance'

* Unbiased Estimator

• 추정량 (추정통계량)

- 표본의 통계량을 가지고 모집단의 통계량(모수)를 추정한다.
- 모집단의 평균을 표본평균들의 평균을 이용하여 추정
- 모집단의 분산은 표본분산들의 평균을 이용하여 추정
- → 이렇게 모수를 추정하는 값들을 '추정량' :
- '표본평균', '표본분산'도 추정량

편의(bias)

- 편의(bias) = 추정량의 기댓값 - 실제 모수
(예시)
- 표본평균의 기댓값 - 모집단의 평균
- 표본분산의 기댓값 - 모집단의 분산

불편추정량이란?

- High bias → Underfitting
- High variance → Overfitting

- 불편추정량 : 편의가 없는 추정량 → 그 기댓값이 모수와 동일한 추정량이라는 뜻
- 표본평균들의 평균(기댓값)은 모집단의 평균과 동일하다. → 이 추정량을 불편추정량이라 한다.
- 표본분산의 기댓값은 모분산과 다르므로 불편추정량이 아니다(n 으로 나누어서 구한다면). 하지만 $(n-1)$ 로 나누어서 구한다면 불편추정량이 맞다.

Bias 와 var trade-off

BLUE : Best Linear Unbiased Estimator , Gauss-Markov theorem

→ 회귀계수에 대한 불편추정량 중에서 가장 분산이 작은 추정량

* degree of freedom

자유도(degree of freedom)

불편추정치와 자유도가 어떤 관계

→ 자유롭게 값을 취할 수 있는 변수의 개수를 의미

- 표본의 평균이 m 으로 정해진 상황에서 분산을 구하게 된다.
- 표본평균이 m 으로 정해지는 순간 $x_1, \dots, x_n$ 중에서 $n-1$ 개 값이 정해지면 나머지 1개는 종속적으로 정해져 버린다.
- 표본분산을 구할 때의 자유도는 $n-1$ 이 된다. → 편차의 합은 ??????
- 표본분산을 불편추정치로 만들기 위해서 $n-1$ 로 나누게 되었다.
- $n-1$ 로 나눠주고 보니 표본분산을 구하는 수식의 자유도와 같았다.
- 단일 모수에 대한 추정에서 자유도는 표본(n)의 크기에서 1을 뺀 값이 된다. → $n-1$
- t 분포는 표준정규분포에 비해 높이가 낮으므로 꼬리 부분이 두꺼워지며 자유도가 증가할수록 표준정규분포에 가까워진다.

* Formulation

*표본분산 증명

- 모분산은 n 으로 나누어 계산하고
- 표본분산을 ($n-1$)로 나누는 이유 → (불편추정치 (Unbiased Estimate)과 자유도(degree of freedom))

모집단에서 표본을 뽑았을 때 집합을 X_1 이라면, 표본의 크기는 n 이고 원소는 아래와 같다.

$$X_1 = \{x_1^1, x_1^2, \dots, x_1^n\}$$

표본의 분산

$$V(X) = E[(X_1 - \mu)^2] = \frac{\sum_{i=1}^n (x_i - \mu)^2}{n-1}$$

표본분산을 구할 때, n 이 아니라 $n-1$ 로 나누는 이유는 표본분산을 '불편추정량'으로 만들기 위하여

불편추정량으로 만들어주는 이유는 표본분산을 더 좋은 추정량으로 만들기 위함이다.

→ n 이 충분히 크다면 n 으로 나누건, $n-1$ 로 나누건 큰 차이 없다.

모집단의 평균 : μ , 표본의 평균 : $\bar{X}_1$

모집단의 표준편차 : σ , 표본의 분산 : S_1

$$E(\bar{X}) = \mu$$

→ 위 식이 성립하면 표본평균은 불편추정치

표본분산의 확률분포 → 카이제곱 분포(chi-squared distribution) χ^2

* Formulation

* 표본평균의 평균

모집단에서 표본을 뽑고 평균을 구한다. 표본을 또 뽑고 평균을 구한다. 표본을 또 뽑고 평균을 구한다.

이를 무한히 반복하면 무한히 많은 표본평균이 생긴다. 이를 대상으로 다시 평균을 구한다.

→ 이때 계산되는 것이 표본평균

표본평균의 평균 $E(\bar{X}) =$ 모평균

$$E(\bar{X}) = \mu$$

표본평균
$$\bar{X} = \frac{\sum_{i=1}^n x_i}{n}$$

표본평균의 평균(기댓값) $E(\bar{X}) = E\left(\frac{\sum_{i=1}^n x_i}{n}\right)$


$$E(\bar{X}) = \frac{1}{n} E(\sum_{i=1}^n x_i)$$

$$E(\bar{X}) = \frac{1}{n} E(x_1 + x_2 + \cdots + x_n)$$

$$E(\bar{X}) = \frac{1}{n} [E(x_1) + E(x_2) + \cdots + E(x_n)]$$

각각은 모집단의 평균과 같다. $E(\bar{X}) = \frac{1}{n} [n\mu]$

그러므로 **표본평균의 평균 = 모평균** → 불편추정치
 $E(\bar{X}) = \mu$



➤ **표본평균이 확률분포는 어떨까??**

➤ **표본평균의 확률분포가 정규분포를 따르는 경우**

: 모집단의 분포가 정규분포를 따르는 것으로 알려져 있고, 모분산(σ^2)을 알고 있는 경우

➤ **표본평균의 확률분포가 t분포를 따르는 경우**

: 모집단이 정규분포일 때 모분산이 알려지지 않은 경우에는 표본이 소표본 ($n < 30$)이라면 표본평균은 자유도 $n - 1$ 의 t분포(t-distribution)를 따르게 된다.

* Formulation

* 표본평균의 평균

- 모집단이 하나 있다고 가정, 모집단의 평균을 μ , 분산을 σ^2 하면
- 이 모집단에서 크기가 n 인 표본을 뽑아서 분산을 구하고, 다시 표본을 또 뽑고 분산을 구하는 것을 반복하면 무수히 많은 표본 분산이 있게 된다. $\rightarrow$ 이 표본분산을 평균한 것이 표본분산의 평균이다.

표본분산의 평균 = 모분산

$$\text{표본분산 } S^2 = \frac{\sum_{i=1}^n (x_i - \bar{X})^2}{n-1}$$

$$\text{표본분산의 기댓값 } E(S^2) = E\left(\frac{\sum_{i=1}^n (x_i - \bar{X})^2}{n-1}\right)$$

$$E(S^2) = \frac{1}{n-1} E(\sum_{i=1}^n (x_i - \bar{X})^2)$$

아래와 같이 모집단의 평균 μ 를 빼고 더하면
0을 더한것과 같기 때문에 등호에 영향을 주지 않는다.

$$E(S^2) = \frac{1}{n-1} E(\sum_{i=1}^n (x_i - \mu + \mu - \bar{X})^2)$$

$$E(S^2) = \frac{1}{n-1} E(\sum_{i=1}^n [(x_i - \mu)^2 + 2(x_i - \mu)(\mu - \bar{X}) + (\mu - \bar{X})^2])$$

$$E(S^2) = \frac{1}{n-1} E(\sum_{i=1}^n [(x_i - \mu)^2] + \sum_{i=1}^n [2(x_i - \mu)(\mu - \bar{X})] + \sum_{i=1}^n [(\mu - \bar{X})^2])$$

둘째항에서 시그마와 무관한 항을 밖으로 꺼내면

$$E(S^2) = \frac{1}{n-1} E\left(\sum_{i=1}^n [(x_i - \mu)^2] + 2(\mu - \bar{X}) \sum_{i=1}^n [(x_i - \mu)] + \sum_{i=1}^n [(\mu - \bar{X})^2]\right)$$

마지막 항은 아래와 같이 바꿀 수 있다.(n 번 더한 것)

$$E(S^2) = \frac{1}{n-1} E(\sum_{i=1}^n [(x_i - \mu)^2] + 2(\mu - \bar{X}) \sum_{i=1}^n [(x_i - \mu)] + n[(\mu - \bar{X})^2])$$

* Formulation

*표본분산의 평균-cont'

두번째 항도 아래와 같이 변형(μ 를 n 번 더하여 시그마를 제거)

$$E(S^2) = \frac{1}{n-1} E \left(\sum_{i=1}^n [(x_i - \mu)^2] + 2(\mu - \bar{X}) \sum_{i=1}^n [(x_i) - n\mu] + n[(\mu - \bar{X})^2] \right)$$

표본평균의 정의를 이용 $\bar{X} = \frac{\sum_{i=1}^n x_i}{n}$ $n\bar{X} = \sum_{i=1}^n x_i$

$$E(S^2) = \frac{1}{n-1} E(\sum_{i=1}^n [(x_i - \mu)^2] + 2(\mu - \bar{X})[n\bar{X} - n\mu] + n[(\mu - \bar{X})^2])$$

둘째항을 n 으로 묶어주면.

$$E(S^2) = \frac{1}{n-1} E(\sum_{i=1}^n [(x_i - \mu)^2] + 2n(\mu - \bar{X})(\bar{X} - \mu) + n[(\mu - \bar{X})^2])$$

-1을 꺼내고 완전제곱식으로 만들어준다

$$E(S^2) = \frac{1}{n-1} E(\sum_{i=1}^n [(x_i - \mu)^2] - 2n(\mu - \bar{X})^2 + n[(\mu - \bar{X})^2])$$

둘째항과 셋째항을 계산 $E(S^2) = \frac{1}{n-1} E(\sum_{i=1}^n [(x_i - \mu)^2] - n(\bar{X} - \mu)^2)$

$E(S^2) = \frac{1}{n-1} E(\sum_{i=1}^n [(x_i - \mu)^2] - n(\bar{X} - \mu)^2)$ 기댓값을 아래와 같이 둘로 분리

$$E(S^2) = \frac{1}{n-1} \left\{ E \left(\sum_{i=1}^n [(x_i - \mu)^2] \right) + E(-n(\bar{X} - \mu)^2) \right\}$$

$$E(S^2) = \frac{1}{n-1} \left\{ E \left(\sum_{i=1}^n [(x_i - \mu)^2] \right) - nE(\bar{X} - \mu)^2 \right\}$$

우변의 두번째 항은 표본평균의 분산

(*표본평균의 분산= 모분산/n) $E(S^2) = \frac{1}{n-1} \left\{ E(\sum_{i=1}^n [(x_i - \mu)^2]) - n \frac{\sigma^2}{n} \right\}$

n 을 약분 $E(S^2) = \frac{1}{n-1} \{ E(\sum_{i=1}^n [(x_i - \mu)^2]) - \sigma^2 \}$

괄호 안의 시그마를 풀어서 쓰면

$$E(S^2) = \frac{1}{n-1} \{ E[(x_1 - \mu)^2] + [(x_2 - \mu)^2] + \cdots + [(x_n - \mu)^2] - \sigma^2 \}$$

$$\begin{aligned} E(S^2) &= \frac{1}{n-1} \{ E[(x_1 - \mu)^2] + E[(x_2 - \mu)^2] \\ &\quad + \cdots + E[(x_n - \mu)^2] - \sigma^2 \} \\ E(S^2) &= \frac{1}{n-1} \{ n\sigma^2 - \sigma^2 \} \\ E(S^2) &= \frac{1}{n-1} \{ n-1 \} \sigma^2 \\ \mathbf{E(S^2) = \sigma^2} \end{aligned}$$

표본분산의 평균(기댓값) = 모분산

* Formulation

* 표본평균의 평균

- 표본평균의 평균 = 모평균 : $E(\bar{X}) = \mu$
- 표본분산의 평균 = 모분산 : $E(S^2) = \sigma^2$

- 표본평균의 분산 = $Var[\bar{X}] = \frac{\text{모분산}}{n}$
- 표본평균의 표준편차(표준오차) = $\frac{s}{\sqrt{n}}$

표본 평균의 분산 : $V(\bar{X}) = E[(\bar{X} - \mu)^2]$

표본평균 : $\bar{X} = \frac{\sum_{i=1}^n x_i}{n}$

표본평균의 분산을 구하는 식에 대입

$$V(\bar{X}) = E\left[\left(\frac{\sum_{i=1}^n x_i}{n} - \mu\right)^2\right], \quad V(\bar{X}) = E\left[\left(\frac{\sum_{i=1}^n (x_i - \mu)}{n}\right)^2\right], \quad V(\bar{X}) = \frac{1}{n^2} E[(\sum_{i=1}^n (x_i - \mu))^2], \quad V(\bar{X}) = \frac{1}{n^2} E[(x_1 - \mu) + (x_2 - \mu) + \dots + (x_n - \mu)^2]$$

$$V(\bar{X}) = \frac{1}{n^2} E[(x_1 - \mu)^2 + (x_2 - \mu)^2 + \dots + (x_n - \mu)^2 + (x_1 - \mu)(x_2 - \mu) + (x_1 - \mu)(x_3 - \mu) + \dots]$$

$$V(\bar{X}) = \frac{1}{n^2} \{E[(x_1 - \mu)^2 + (x_2 - \mu)^2 + \dots + (x_n - \mu)^2] + E[(x_1 - \mu)(x_2 - \mu) + (x_1 - \mu)(x_3 - \mu) + \dots]\}$$

$$V(\bar{X}) = \frac{1}{n^2} \{E[(x_1 - \mu)^2] + E[(x_2 - \mu)^2] + \dots + E[(x_n - \mu)^2] + E[(x_1 - \mu)(x_2 - \mu)] + E[(x_1 - \mu)(x_3 - \mu)] + \dots\}$$

$$E[(x_1 - \mu)(x_2 - \mu)]$$

두 변수가 독립일 경우 아래와 같이 분리 가능

$$E[(x_1 - \mu)(x_2 - \mu)] = E[(x_1 - \mu)] E[(x_2 - \mu)], \quad E[(x_1 - \mu)] = E[x_1] - \mu = \mu - \mu = 0, \quad (\bar{X}) = \frac{1}{n^2} \{E[(x_1 - \mu)^2] + E[(x_2 - \mu)^2] + \dots + E[(x_n - \mu)^2]\}$$

$$V(\bar{X}) = \frac{1}{n^2} \{n\sigma^2\} = \frac{\sigma^2}{n}$$

$$\text{표본평균의 분산} = \frac{\text{모분산}}{n}$$

* Central limit theorem

[중심극한정리 Central limit theorem)]

모집단의 평균이 μ 이고 분산이 σ^2 일 때,

임의로 추출한 n 개의 표본을 선택했을 때,

표본에 대한 표본평균($\bar{X}$)은 모집단의 분포와 상관없이

표본 n 이 충분히 클 때 (통상적으로 30 이상) 근사적으로 (평균 = μ , 분산 = $\frac{\sigma^2}{n}$) 정규분포를 따르게 된다.

표본평균의 평균 = 모평균

$$E(\bar{X}) = \mu$$

$$Z = \frac{\bar{X} - \mu}{\left(\frac{\sigma}{\sqrt{n}}\right)} \sim N(0, 1)$$

* Error , Residual

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$$

✓ 오차(Error)

- 모집단(population)으로부터 추정한 회귀식으로부터 얻은 예측값과 실제 관측값의 차이(모집단회귀식(참회귀식)과 관측값과의 수직거리) → 실제 계산은 어려움.
- 데이터 마이닝

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$$

$$\hat{\varepsilon}_i = Y_i - \hat{Y}_i$$

✓ 잔차 (Residual)

- → 표본(sample)집단에서 회귀식을 얻었다면, 그 회귀식을 통해 얻은 예측값과 실제 관측값의 차이 (추정회귀식과 관측값과의 수직거리) : 오차항의 추정치 (통계분석)
- 잔차를 기준으로 최적의 회귀모형을 찾는 방법 중 가장 대표적인 방법으로 '최소제곱법(method of least square)'
- → 둘의 차이는 모집단에서 얻은 것이냐 표본집단에서 얻은 것이냐 차이
- But!!
- 통계분석에서는 표본집단에서 회귀식을 얻기 때문에, 잔차를 가지고 회귀식의 최적의 파라미터 값들을 추정한다.
- → 즉, 잔차들의 제곱들을 더한 것(잔차제곱합)을 최소로 만들어주는 파라미터를 찾는 것

통계모형에서 잔차는 오차항의 추정치이라고 볼 수 있는데, 잔차항이 임의적이면 데이터를 이용한 통계모형을 이용한 개선이 어렵다고 생각하고 통계모형이 적절하다고 판단한다. → 오차항에 대한 특정 확률분포를 가정하게 된다.

✓ 편차(Deviation)

- : 평균에서 개별값을 뺀 것
- : 편차의 합은 0

(증명)

n개 변수 : $x_1, x_2, \dots, x_n$

평균(a.m) = $\frac{x_1 + x_2 + \dots + x_n}{n}$

편차의 합 = $(x_1 - m) + (x_2 - m) + \dots + (x_n - m)$

= $(x_1 + x_2 + \dots + x_n) - (n \times m)$

= $(n \times m) - (n \times m) = 0$

S.E : Standard Error

* 표준오차(SE : Standard Error)

여러 표본의 표준편차의 평균 값 → 표본분산을 표본수로 나눈값을 제공근 한 값

- 표본들이 실제 모집단과 얼마나 차이가 나는가에 관한 것으로 평균의 정확도를 추정할 때 사용

$$\text{표준오차(SE)} = \frac{S_X}{\sqrt{n}}$$

→ 이때 매번 뽑히는 여러 표본평균들이 얼마만큼의 변동, 즉 편차를 가지겠는가에 대한 답을 주는 것이 표준오차

→ 모평균에 대하여 추론할 때 표본평균의 표준오차를 사용해야 함.

→ 표준오차가 작을수록 표본의 대표성이 높다

표준오차(SE)가 왜 발생?????

표본이 매번 추출될 때 마다 값이 바뀌는 특성때문에 표본 통계량은 매번 그 값에 변동(혹은 오차) 하기 때문에~~~~

→ But 하지만, 일반적으로 표본추출은 단 한번 시행하므로

표본평균도 하나가 나올 것이고, 표준오차를 계산할 수도 없다.

→ 표본평균이 여러 개가 있어야 그들의 편차를 계산할 수 있지만,
그럼에도 불구하고 이론적으로 표준오차를 계산할 수 있다.

$$\text{표준오차(S.E)} = \frac{\text{표본 표준편차}}{\text{관측치의 제공근으로 나눈 값}}$$

$$\text{표본평균의 분산} = \frac{\text{모분산}}{n}$$

σ : 모집단 표준편차(standard deviation), n 은 모집단의 크기

표본오차(Sampling Error)

=모평균 추정구간의 중심으로부터 최대 허용할 최대허용오차

→ 모평균 추정치의 표본오차를 말함.

$$\text{표본오차} = \text{임계값} \times \text{표준오차(SE)}$$

- 표준오차** : 평균의 추정치에 대한 불확실도를 수치화한 것
- 표준 편차** : 모집단의 분포가 얼마나 퍼져 있는가를 서술하는 개념

* Formulation

* 표준오차(SE : Standard Error)

평균의 표준오차는 표본평균 분포의 표준편차

$$S.E = \frac{\sigma}{\sqrt{n}} = \frac{s}{\sqrt{n}}$$

σ 를 모르기 때문에 s 로

* 표본평균의 표준오차(S.E) 증명

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$Var[\bar{X}] = Var\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = Var\left[\frac{1}{n}(X_1 + X_2 + \dots + X_n)\right]$$

$$= \frac{1}{n^2} Var[X_1 + X_2 + \dots + X_n]$$

$$= \frac{1}{n^2} \times n \times Var[X] = \frac{1}{n} Var[X] \rightarrow \frac{\text{모분산}}{n} \text{ (표본평균의 분산)}$$

$$\sqrt{Var[\bar{X}]} = \frac{1}{\sqrt{n}} std[X] = \frac{1}{\sqrt{n}} \sigma = \frac{\sigma}{\sqrt{n}}$$

* Sampling Error

(경향신문 2024.5.31)

한국갤럽이 지난 28일부터 사흘간 전국 성인 1001명을 대상으로 조사해 이날 발표한 여론조사에서 윤 대통령이 '잘하고 있다'는 긍정 평가는 21%로 나타났다. (중략)

이번 조사는 통신3사가 제공한 무선전화 가상번호를 무작위 추출한 전화조사원 인터뷰(CATI) 방식으로 실시됐다. 표본오차는 95% 신뢰수준에서 $\pm 3.1\%$ 포인트다.

95% 신뢰수준에서 표본오차가 $\pm 3.1\%$ 포인트라는 것은, 여러 번 표본을 추출하여 조사를 반복할 경우, 95%의 확률로 조사된 지지율(21%)이 실제 지지율에서 $\pm 3.1\%$ 포인트 범위 내에 있을 것이라는 의미

"조사된 지지율이 21%이며, 이 지지율은 실제 모집단의 지지율에 대해 95% 신뢰수준에서 $\pm 3.1\%$ 포인트의 표본오차를 가진다. 즉, 실제 지지율은 17.9%에서 24.1% 사이에 있을 가능성이 95%이다."

표본오차(Sampling Error)

- 표본 통계량과 모집단 통계량 간의 차이를 의미
- 특정 표본이 모집단을 얼마나 잘 대표하는지를 나타내는 오차
- 표본오차는 실제 모집단의 값을 알 수 없기 때문에 직접적으로 계산하기 어렵지만, 이론적 개념을 이해하는 것이 중요하다.

표본오차 발생 상황

- 모집단에서 하나의 표본을 추출했을 때, 이 표본이 모집단 전체의 특성을 완벽하게 반영하지 못하는 경우.
- 표본 평균($\bar{X}$)이 모집단 평균(μ)과 다를 때 발생한다.

이론적 표본오차의 계산

$$\text{Sampling Error} = \bar{X} - \mu$$

실제 계산

현실에서는 모집단 평균 μ 를 알 수 없기 때문에 직접적인 표본오차 계산은 불가능

* Sampling Error

표본오차(Sampling Error)

- 모집단의 평균을 모르는 경우, 표본오차(Sampling Error)를 직접 계산할 수 없기 때문에 **표본통계량과 표준오차(Standard Error)**를 사용하여 간접적으로 추정하게 된다.

표본오차 추정 방법

1. 표준오차 (SE)계산

표준오차는 표본의 크기와 표본의 표준편차를 사용하여 계산

$$SE = \frac{s}{\sqrt{n}}$$

• s : 표본의 표준편차
• n : 표본 크기

2. 신뢰구간 설정

신뢰구간은 표본 평균 주위에 모집단 평균이 포함될 것으로 예상되는 범위를 제공한다.
예를 들어, 95% 신뢰구간은 다음과 같이 계산

$$\bar{X} \pm Z \times SE$$

• $\bar{X}$: 표본 평균
• Z : 선택한 신뢰수준에 해당하는 z-값 (예: 95% 신뢰수준에서 약 1.96).
• SE : 표준오차

(예시)

1. 표본 데이터

- 표본 크기 (n) = 25
- 표본 평균 ($\bar{X}$) = 168 cm
- 표본 표준편차 (s) = 10 cm

2. 표준오차 계산:

$$SE = \frac{10}{\sqrt{25}} = 2$$

3. 신뢰구간 계산 (95% 신뢰수준)

$$168 \pm (1.96)(2) = 168 \pm 3.92 = 164.08 \sim 171.92$$

모집단 평균이 95%의 확률로 164.08에서 171.92 사이에 있을 것이라고 해석할 수 있다.

다시 말해, 우리가 얻은 표본평균 168은 95% 신뢰수준에서 실제 모집단 평균이 164.08에서 171.92 사이에 존재한다는 것을 의미한다.

Greek letter symbol

가설검정 : 유의수준

제2종 오류

감마분포형태, 각도

미분 derivative

- ✓ Δ 와 d ??
- ✓ ∂ : round
- ✓ ∇ : del, nabla

모수

단위벡터

감바분포의
비율모수
역급수, 파장

모평균

$A \alpha$	Alpha (알파)	$N \nu$	Nu (뉴)
$B \beta$	Beta (베타)	$\Xi \xi$	Xi (크시)
$\Gamma \gamma$	Gamma (감마)	$O o$	Omicron (오미크론)
$\Delta \delta$	Delta (델타)	$\Pi \pi$	Pi (파이)
$E \epsilon$	Epsilon (엡실론)	$P \rho$	Rho (로우)
$Z \zeta$	Zeta (제타)	$\Sigma \sigma$	Sigma (시그마)
$H \eta$	Eta (에타)	$T \tau$	Tau (타우)
$\Theta \theta$	Theta (세타)	$Y \upsilon$	Upsilon (업실론)
$I \iota$	Iota (이오타)	$\Phi \phi$	Phi (파이)
$K \kappa$	Kappa (카파)	$X \chi$	Chi (카이)
$\Lambda \lambda$	Lambda (람다)	$\Psi \psi$	Psi (프사이)
$M \mu$	Mu (뮤)	$\Omega \omega$	Omega (오메가)

자유도 degree of freedom

좌표

누적곱 / 원주율

상관계수, 좌표

합계, 표준편차

시간

누적정규분포함수
평면의 각도

카이제곱분포

좌표, 각도

표본공간
각도, 저항
 $\Sigma, \int, ?$

* SI

국제단위계(Système international d'unités , International System Units 약칭 SI)

- 1960년 국제도량형총회 시작 ,
- **전류, 온도, 시간, 길이, 질량, 광도, 물질량을** 전 세계에서 표준화된 도량형으로, MKS 단위계(Mètre-Kilogramme-Second)이라고도 불린다.
- 1960년 10월 제 11차 국제 도량형 총회(Conférence générale des poids et mesures)에서 SI가 결정

국내 단위는 7개의 기본

- 단위(미터(m), 킬로그램(kg), 초(s), 암페어(A), 켈빈(K), 몰(mol), 칸델라(cd)), 2개의 보조 단위(라디안(rad), 스테라디안(sr))와 이들로부터 유도되는 조합단위(19개)를 요소로 하는 일관성이 있는 단위의 집단이다.

<https://ko.wikipedia.org/wiki/%EA%B5%AD%EC%A0%9C%EB%8B%A8%EC%9C%84%EA%B3%84>

* 쉬어가기



아돌프 케틀레
(Adolphe Quetelet,
1796년 ~ 1874년)

- 벨기에 출생
- 1835년 《*Sur l'homme et le développement de ses facultés, ou Essai de physique sociale*》(인간과 인간의 능력 개발에 관한 논의, 사회물리학 시론)을 통하여 **평균적인 인간의 개념을 제시**
- **사회과학**에 **통계학**을 적용함으로써 근대 통계학의 아버지로 불린다.
- 전수조사 에서 표보조사로 '추론'~~
- 인구통계와 범죄통계를 연구하여 구현상 이외의 도덕현상이나 범죄현상 같은 무질서해 보이는 사회현상에 있어서도 일종의 규칙성이 존재한다는 것을 증명한 연구
- 월별 · 지역별 · 기온별 · 시간별 출생률과 연령 · 직업 · 지역 · 계절과 장소에 따른 사망률을 조사하며 신장과 체중 · 성장률 · 음주와 정신병력 여부, 자살 · 범죄 등도 변수에 넣어 계산한 끝에, 어떤 사회에서의 출생률과 사망률, 자살자의 수 등이 매년 거의 일정하다는 사실을 발견
- 1853년 국제통계기구의 모체가 되는 국제통계회의를 창설
- 'Quetelet Index' : 오늘날에는 '체질량 지수' (BMI: Body Mass Index)로 알려져 있다. → 체중(kg)을 키(m)의 제곱으로 나눈 값으로, 개인의 건강 상태를 평가하는 데 널리 사용
- '평균 인간' 개념을 도입
- 우생학(eugenics)은 인류의 유전적 특성을 개선하고자 하는 과학적이고 사회적인 운동
- → 19세기 말에 영국의 과학자 **프랜시스 골턴** (Francis Galton)의해 처음 소개
- **프랜시스 골턴** (Francis Galton)은 "우생학"이라는 용어를 만들어 인간의 품질을 개선할 수 있는 연구를 지칭
- 나치 독일에서는 이 이론이 인종 청소와 대량 학살의 정당화로 악용

*쉬어가기 : 인물로 보는 통계학의 흐름

시대	인물	주요 기여
고대, 그리스	철학, 수학	
17c	John Graunt	'자연과 정치적 관찰의 통계'(Natural and Political Observations Made upon the Bills of Mortality) 현대 인구통계학의 기초 마련 → 런던의 사망 원인 기록을 분석하여, 사망률, 출생률, 질병의 영향 등을 통계적으로 접근
	William Petty	'정치적 산술학'(Political Arithmetic)을 창시하여 경제적, 사회적 데이터를 정량적으로 분석하는 방법론을 제시
	Blaise Pascal	프랑스의 수학자, 물리학자, 종교 철학자 특히 확률론의 초기 발전에 중요한 기여 파스칼과 피에르 드 페르마(Pierre de Fermat)는 서신을 통해 문제들을 토론하면서 현대 확률론의 기초를 마련 "파스칼의 삼각형"과 관련된 이항 분포의 기초를 다루는 것이었으며, 이것은 조합론과 확률 계산에서 중요한 역할
	Jacob Bernoulli	스위스의 수학자 《확률론의 예술》("Ars Conjectandi")은 그가 사망한 후 1713년에 출판 확률론을 체계적으로 다룬 최초의 시도 중 하나로 평가 조합론, 이항 분포, 그리고 대수의 법칙 마련
18c	Leonhard Paul Euler	- 스위스 수학자 (베루누이 제자) 1734-1735년, x의 함수를 $f(x)$로 표기함 1736년, 약 반세기 전에 이미 발견된 수였으나 표기법이 제각기 따로놀던 자연로그의 밑에 e라는 기호를 씀 1737년, 원주율의 기호로 π를 채택함 1777년, 허수 단위의 기호로 i를 씀 - 합을 나타내는 기호로 Σ를 도입함
	Thomas Bayes	- 영국의 목사와 수학자 - 확률론에 혁신적인 관점을 제공한 것으로, 특히 '베이즈 정리'를 통해 이루어졌다. - 사후 확률을 계산하는 데 중심적인 역할

*쉬어가기 : 인물로 보는 통계학의 흐름

시대	인물	주요 기여
18-19c	Carl Friedrich Gauss	■ 수학에서의 기여 《산술 연구》("Disquisitiones Arithmeticae")는 대수학과 수론에 큰 영향 → 소수의 분포, 합동식, 이차 잉여의 법칙 등을 다룬다.. 기하학: 유클리드 기하학의 발전에 중요한 역할. 대수학: 가우스는 복소수의 기하학적 해석을 발전 ■ 통계학에서의 기여 최소제곱법: 1795년에 최소제곱법을 독립적으로 발견→ 회귀 분석 중요한 도구로 사용 정규 분포: 가우스는 측정 오류가 정규 분포를 따른다는 사실을 발견 → '가우시안 분포' 또는 '벨 커브'로 잘 알려져 있으며, 이는 통계학에서 가장 중요한 확률 분포 중 하나 → 정규 분포는 다양한 자연 현상과 사회 과학의 데이터 분석에 적용
	Pierre-Simon Laplace	프랑스의 수학자, 천문학자, 물리학자, 통계학과 확률론 분야에서 매우 중요한 기여 베이즈 정리의 확장: 토머스 베이즈(Thomas Bayes)의 초기 아이디어를 발전시켜 베이즈 정리를 현대적 형태로 확장→ 이를 천문학적 데이터의 분석에 적용하여 더 정확한 결과를 도출 중심극한정리(Central Limit Theorem, CLT): 독립적이고 동일하게 분포된 확률 변수들의 합이 충분히 많은 경우 정규 분포에 근접한다는 것을 설명 - 추론 통계에서 활용 확률적 불확실성의 철학적 해석: '라플라스의 악마'라는 개념을 통해 우주의 결정론적 이해를 주장→ 모든 과거와 현재의 정보를 알고 있는 지적 존재라면 미래를 예측할 수 있을 것이라는 생각을 포함하고 있다. 이는 확률론의 철학적 해석과 과학적 접근 방식에 대한 근본적인 논의를 촉발 통계적 방법론의 개발: 천문학적 관측에서 발생하는 오차를 처리하기 위해 통계적 방법론을 개발했습니다. 그는 오차의 법칙과 최소제곱법을 사용하여 관측 데이터에서 가장 가능성이 높은 값을 추정
19c~20c	Francis Galton	통계학과 유전학에 대한 기여 상관관계(Correlation): 변수 간의 관계를 수량화하는 상관관계 개념을 소개하고, 이를 분석하는 통계적 방법을 개발 회귀 분석(Regression Analysis): 유전적 특성의 연속성을 연구하면서 회귀라는 용어를 처음 사용 지문 분석: 지문이 개인별로 고유하다는 사실을 과학적으로 증명하고, 법의학에서 지문을 사용하는 시스템을 개발
	Florence Nightingale	통계학적 접근은 간호학 및 공중 보건 분야뿐만 아니라 데이터 분석과 시각화의 발전에도 기여 크림 전쟁 동안 나이팅게일은 군 병원에서 수집한 데이터를 분석하여, 병사들의 사망 원인 대부분이 전투상의 부상이 아니라 비위생적인 환경에서 비롯된 감염병이라는 것을 밝혀냄. 데이터를 효과적으로 사용하여 실질적인 변화를 이끌어내고, 이를 통해 현대 의료 및 공중 보건 시스템의 발전에 기여한 인물로 기억

*쉬어가기 : 인물로 보는 통계학의 흐름

시대	인물	주요 기여
19c~20c 초반	Carl Pearson	- 상관계수 (Pearson Correlation Coefficient) 두 변수 간의 선형 관계를 측정하는 피어슨 상관계수를 개발 - p-값과 가설 검정 : 통계적 가설 검정에서 p-값의 개념을 도입하는 데 기여 - 카이제곱 검정 (Chi-square Test) : 범주형 데이터의 독립성을 검정하는 카이제곱 검정을 개발 두 범주형 변수 간의 연관성이 우연에 의한 것인지 아니면 통계적으로 유의미한 연관성이 있는지를 평가하는 데 사용
	William Sealy Gosset	- 스튜던트의 t-분포 표본 크기가 작을 때 정규분포를 사용하는 것이 부적합할 수 있다. → 극단값을 더 잘 수용 - 스튜던트의 t-검정 : t-분포를 기반으로 한 '스튜던트의 t-검정'을 개발 두 집단 간의 평균 차이가 통계적으로 유의미한지를 판단하는 데 사용 - 산업 통계학의 적용: 품질 관리와 생산 과정의 효율성을 높이기 위해 통계학적 방법을 적극적으로 활용 데이터를 기반으로 한 의사결정 프로세스를 촉진하고, 품질 관리의 과학적 기반을 강화하는 데 기여
	Ronald Aylmer Fisher	- F 분포 : 통계학에서 두 표본의 분산을 비교할 때 사용되는 연속확률분포 - 분산 분석(ANOVA) 개발 : F 분포는 여러 그룹의 평균이 통계적으로 유의미한 차이가 있는지를 검정하는 데 사용 - F 검정: 두 개의 독립적인 표본의 분산이 같은지를 비교하는 데 F 검정이 사용 - 최대우도 추정법 개념 도입: 주어진 데이터가 관측될 가능성(우도)을 최대화하는 파라미터 값을 찾는 기법으로, 다양한 통계적 모델에서 파라미터 추정에 널리 사용
20c 후반	Charles Spearman	Spearman's Rank Correlation Coefficient 두 변수 간의 통계적 의존성을 측정하는 비모수적 방법 → 데이터 값 대신 변수의 순위를 사용하여 계산되며, 두 변수 사이의 연관성이 선형적이지 않거나, 데이터가 서열 척도로 측정된 경우에 유용
	Maurice Kendall	Kendall's tau' 순위 상관계수: 순위 기반의 비모수적 상관계수는 두 변수 간의 연관성을 측정하는 데 사용 , 켄달의 고급 통계 이론(The Advanced Theory of Statistics)
	Frank Wilcoxon	윌콕슨 순위합 검정 (Wilcoxon Rank-Sum Test) 두 독립된 표본 그룹 사이의 중앙값 차이를 검정하는 방법 윌콕슨 부호 순위 검정 (Wilcoxon Signed-Rank Test) 두 관련 표본 또는 한 표본에 대한 반복 측정 사이의 차이를 평가하는 데 사용됩니다. 이 검정은 차이의 절대값을 순위로 매기고, 원래의 부호(양수 또는 음수)를 고려하여 통계적 유의성을 평가

Probability

1. 확률 관련 용어
2. 확률 법칙
3. 총확률정리와 베이지스 이론
4. 확률변수와 확률함수
 - 확률변수와 확률함수 정의
 - 확률변수와 확률함수의 관계
 - 확률변수의 기댓값과 분산

Probability & Decision Making

의사결정 (Decision Making)

1. 정의/목적

- 문제해결 및 목적달성을 위한 여러가지 해결방안(대안, Alternatives) 중에서 최선의 것을 선택하는 활동
- 불확실성이 존재할 경우, 선택 가능한 대안의 결과에 대한 예측과 불확실성은 확률로 표현해야 한다.
(의사결정상황 구분)
- 불확실한 상황하의 의사결정
- 확실한 상황하의 의사결정
- 위험 부담하의 의사결정

2. 의사결정과정

- ① 문제의 정의
- ② 목표 및 평가기준 제시
- ③ 대체안의 개발
- ④ 대체안의 분석 및 평가
- ⑤ 최적대체안의 선택
- ⑥ 선택된 대체안의 실행
- ⑦ 실행결과 검토

(사례)

확률계획법(Probabilistic programming) → 위험 or 불확실성하에서의 의사결정

- 입력 데이터들이 확률분포를 따르는 확률변수로 주어지며 특정 의사결정에 대해서 발생확률만을 알고 있을 경우 위험하에서의 의사결정
- 특정 의사결정에 대한 발생확률조차 전혀 알 수 없는 상태인 경우 불확실성하에서의 의사결정으로 구분한다.
→ 불확실한 상황에서는 의사결정자가 어떤 기준을 정하여 의사결정을 할 수 밖에 없다. 이러한 기준은 의사결정자의 주관이나 가치관에 따라 좌우된다.


Probability Experiment

구분	내용	사례
확률실험 (Random experiment)	확률실험(random experiment)은 사전에 실험의 결과를 사전에 확실하게 예측하지 못하는 실험	<u>동전던지기, 주사위던지기 등</u>
표본공간 (Sample space)	확률실험의 결과(outcome)로 얻을 수 있는 <u>모든 가능한 결과치의 집합, S 또는 Ω (omega)</u>	<u>(앞면, 뒷면), (1,2,3,4,5, 6)</u>
사건 또는 사상 (Event)	실험 또는 관찰로 인해 발생하는 하나 또는 두 개 이상의 결과의 집합체 사상은 표본 공간의 부분집합이며 특정한 조건에 해당하는 원소들로 구성	<u>짝수가 나오는 사건</u> (구분) - 단순사건(simple event) : 실험으로 인한 결과가 하나인 경우 - 복합사건(compound event) : 실험의 결과가 두 개 이상인 경우
상호 배타적 (Mutually exclusive) 사상	동일한 표본공간에 대하여 정의된 두 사상 A와 B 간에 공통된 원소가 하나도 없는 경우	

Probability Experiment

확률실험과 표본공간의 예

확률실험	표본공간: 사건이 일어 날 수 있는 모든 경우
동전 던지기	{앞면, 뒷면}
주사위 던지기	{1, 2, 3, 4, 5, 6}
집에서 회사까지 출근 시간	최소 20 분에서 최대 1시간이 걸린다면 $\{x 20 \leq x \leq 60\}$
주식 투자 수익률	$\{x -\infty \leq x \leq \infty\}$



Probability Experiment

확률의 정의

- 확률(probability)이란 사상이 발생할 가능성을 나타내는 0과 1 사이의 수로 정의
- 확률의 합은 1이 된다.

1. 확률 구분

- 사건(E)의 정보량 $I(E)$ 는 확률 $P(E)$ 의 마이너스 로그함수로 표현 $I(E) = -\log[P(E)]$
 → 확률값이 작아지면 정보량은 커지고, 확률값이 커지면 정보량은 작아진다.
 → 정보량의 기댓값 : Entropy

1) 이론적(사전적) 확률(priori probability), Classical approach

확률실험을 하지 않고도 발생할 모든 경우의 수를 알고 있고 특정 사건에 대한 경우의 수에 대해 상대도수를 계산할 수 있는 확률 (equally likely events)
 (예시) 주사위 1의 눈이 나올 확률은 1/6

$$P(A) = \frac{\text{사상 } A \text{의 원소 개수}}{\text{표본공간이 원소 개수}}$$

2) 실험적 확률(empirical probability), 경험적 확률

- 확률실험을 n 회 반복하였을 때 특정 사상 A 가 m 번 발생하였다면 사상 A 가 발생할 확률은 상대도수의 극한치로 정의
 → 사건 발생 후 계산
- "대수의 법칙(law of Large Numbers)" : 수많은 실험들을 통해 어떤 사건의 경험적 확률은 실제 확률에 근접

$$P(A) = \lim_{n \rightarrow \infty} \frac{m}{n}$$

3) 주관적 확률(subjective probability)

- 주관적 확률은 확률을 개인의 지식, 정보, 경험 등의 주관적 요소에 의하여 측정하는 방법
- (예시) 어떤 경제 전문가에게 하반기 금융시장의 경기가 호전될 확률을 자문하였을 때 30%라고 대답한다면 이것이 주관적 확률인 것

Rules in Probability

2. 확률의 정의에 따른 기본법칙

1) $0 \leq P(A) \leq 1$

확률은 항상 0과 1사이의 값을 갖는다.

2) $P(S) = 1, P(\emptyset) = 0$

$P(S)$ 는 표본공간의 확률이므로 항상 1이며 공집합의 발생확률 $P(\emptyset)$ 는 0이다.

3) $P(A^c) = 1 - P(A)$

- A의 여사건을 의미하며 A가 발생하지 않을 확률을 말한다. 이 확률은 1에서 A가 발생할 확률을 제외하여 도출한다.
- 여사건(Complement of an Event) : 사건 A의 여사건은 사건 A에 포함되지 않은 모든 사건의 합, A^c
- $P(A) + P(A^c) = 1$

4) $A \subset B$ 이면, $P(A) \leq P(B)$

A가 B의 부분집합이면 A가 발생할 확률은 항상 B가 발생할 확률보다 작거나 같다. 같은 경우일 때는 A와 B가 동일한 경우이다.

Rules in Probability

3. 확률의 덧셈법칙 (Addition rule)

확률의 덧셈법칙은 사건 A와 B 중 어느 하나가 발생할 확률을 구하는 법칙

1. 덧셈법칙의 적용

동일한 표본공간에서 정의된 사상 A 또는 B가 발생할 확률은 아래와 같이 정의된다.

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

2. 덧셈법칙의 예외

두 사상 A와 B가 상호 배타적인 경우 교집합은 공집합이 되므로 교집합의 확률은 0
따라서 확률의 덧셈법칙은 다음과 같이 예외적으로 정의된다.

$$P(A \cup B) = P(A) + P(B)$$

(예시) A대학교 경찰정보학과 학생 40명을 대상으로 조사

- 헌법을 수강하는 학생 : 20명
- 범죄통계학을 수강하는 학생 : 25명
- 헌법과 범죄통계학을 동시에 수강하는 학생 : 15명
- 경찰정보학과 학생 40명 중 한 명을 선택했을 때 헌법 또는 통계학을 수강하고 있는 확률은?

$$\rightarrow P(A \cup B) = P(A) + P(B) - P(A \cap B)$$


$$= \left(\frac{20}{40}\right) + \left(\frac{25}{40}\right) - \left(\frac{15}{40}\right) = \left(\frac{30}{40}\right) = 0.75 \rightarrow 75\% \text{ 확률}$$

Rules in Probability

4. 배반사건과 독립사건

1) 배반사건 (Mutually Exclusive)

- 두 사건 A, B가 있을 때 $A \cap B$ 가 의미하는 바는 A사건과 B사건이 동시에 일어난다는 것인데 동시에 일어나는 사건이 없는 경우를 배반적 사건, 또는 배타적 사건이라고 함.
- (예시) 주사위를 던지는데 A는 짝수가 나올 사건이고 B는 홀수가 나올 사건이라고 한다면 두 사건이 동시에 일어날 수 없다 $\rightarrow A \cap B = 0$



2) 독립사상(independent events)

한 사상의 발생이 다른 사상의 발생 확률에 영향을 미치지 않을 경우 두 사상은 상호 독립(mutually independent)

(독립 사상은 성질)

- 독립은 동시에 일어날 수 있지만 서로 영향을 끼치지 않는다. $\rightarrow$ 따라서 조건부확률 $P(A|B)$ 은 B가 A에 영향을 끼치지 않으면 $P(A)$ 와 같기 때문에 $P(A|B) = P(A)$ 로 쓸 수 있다.
- 두 사건 A와 B가 독립일 때 동시에 일어나는 확률은 $P(A), P(B)$ 곱으로 나타낼 수 있다.

$$P(A|B) = P(A) , P(B|A) = P(B) , P(A \cap B) = P(A|B) \cdot P(B) = P(A) \cdot P(B)$$

(예시) 복원추출의 경우

주머니 안에 있는 공을 꺼내는 경우, 복원추출한다면, 이전에 공을 꺼낸 사건이 다음에 뽑는 사건에 영향을 끼치지 않는다.


Rules in Probability

5. 조건부 확률 (Conditional probability)

조건부 확률은 특정한 사상이 이미 발생하였다는 조건하에서 다른 사상이 발생할 확률

- $P(A)$: A가 발생할 확률
- $P(A|B)$: B가 발생한 조건에서 A가 발생할 확률
- Probability of A given B
- $P(B \cap A) = P(A|B) \cdot P(B)$ 이므로
- $\rightarrow P(A|B) = \frac{P(B \cap A)}{P(B)}$

Bayes' theorem 연결!!!



$$P(A|B) = \frac{P(B \cap A)}{P(B)}$$

Rules in Probability

6. 확률의 곱셈법칙 (multiplication rule)

- 동일한 표본공간에서 정의된 두개의 사상에 대한 확률의 곱셈법칙(multiplication rule)은 두 사상이 동시에 발생할 확률을 의미
→ 곱의 확률 혹은 **결합확률(joint probability)**이라고도 한다.
- A와B의 곱사건 : "A and B" 또는 $A \cap B$ 로 표기
- 사건 A와B의 결합확률(joint probability), $P(A \text{ and } B)$ 또는 $P(A \cap B)$ 는 A와B의 곱사건의 확률

$$P(A \cap B) = P(A|B) \times P(B) \\ = P(B|A) \times P(A)$$

$$\text{조건부확률 : } P(A|B) = P(A \cap B)/P(B)$$

곱셈법칙의 예외

- 두 개의 사상 A, B가 **상호독립이라면** 곱셈법칙의 예외적인 경우가 성립한다.

$$P(A \cap B) = P(A) \times P(B)$$

- 독립사상에서
- $P(A|B) = P(A)$, $P(B|A) = P(B)$
- $P(A \cap B) = P(A|B) \times P(B) = P(A) \times P(B)$

- (예시)
- 주사위를 2번 던졌을 경우 ; 표본공간 $S = \{(1,1), (1,2), \dots, (6,6)\}$ (총 36개)
- 첫번째 수가 1일 경우를 사건 A : $A = \{(1,1), (1,2), (1,3), (1,4), (1,5), (1,6)\} \rightarrow \frac{1}{6}$
- 두번째 수가 5일 경우를 B사건이라 하면, $B = \{(1,5), (2,5), (3,5), (4,5), (5,5), (6,5)\} \rightarrow \frac{1}{6}$
- A와 B의 곱사건, $(A \cap B) = \{(1,5)\}$
- 결합확률 $P(A \cap B) = \frac{1}{6} \times \frac{1}{6} = \frac{1}{36}$

Rules in Probability

7. 총확률정리와 베이즈 정리

1) 총확률정리(total probability rule)


→ 표본공간이 k개의 상호 배타적인 사상으로 분할될 경우 임의의 사상 P(B)의 발생 확률로 구해진다.

. 조건부확률로부터 조건이 붙지 않은 확률을 계산할 때 쓸 수 있다.

표본공간이 상호배타적인 사상 $A_1, A_2, \dots, A_k$ 로 분할될 때

$$P(B) = \sum_{i=1}^k P(B | A_i) P(A_i)$$

→ 사건의 원인을 여러가지로 나누어서, 각 원인에 대한 조건부 확률 $P(A|B_i)$ 과 그 **원인**이 되는 확률 $P(B_i)$ 의 곱에 의한 .
가중 합($\sum$)으로 구할 수 있음을 말한다.



$$\begin{aligned} P(B) &= P(B \cap A) \\ &= P(B \cap A_1) + P(B \cap A_2) \\ &= P(B | A_1) P(A_1) + P(B | A_2) P(A_2) \end{aligned}$$

(용도)

→ 한 실험이 연속된 하위실험들로 구성될 때 유용

→ 조건부확률로부터 조건이 붙지 않은 확률을 계산할 때

* Baysian

통계학 : 한 사건이 장기적으로 일어날 때 발생하는 빈도를 확률

- 빈도주의(Frequentist) : 확률을 사건의 빈도로 보는 것 - 고전적 분석 !!!
- 베이지안(Baysian) : 확률을 사건 발생에 대한 믿음 또는 척도로 바라보는 관점



베이지안!!! : 일어나지 않은 일에 대한 확률의 불확실성의 개념 + 사건과 관련이 있는 여러 확률 → 새로운 일어날 사건을 추정하는 것

빈도주의(Frequentist)	베이지안(Baysian)
- 빈번하게 특정한 사건이 반복되어 발생하는가를 관찰하고 가설을 세우고 모델을 만들어서 검증 - 모수(parameter)는 우리가 모르는 고정된 상수	- 확률은 사건 발생에 대한 믿음 또는 척도(주관적) - 모수는 확률적으로 변하는 수 (확률변수) - 베이지안의 확률적 추론 방법 - 사전확률(지식, 부정확한 선입관) → 관측 결과치 → 우도(Likelihood) → 사후확률
- 사건이 독립적이고 반복적이며 정규분포 형태일때 유용 - 대용량 데이터를 처리 할 수 있다면 계산이 비교적 복잡하지 않기 때문에 쉽게 처리가능	확률 모델이 명확히 설정되어 있다면 조건부로 가설을 검증하기 때문에 가설의 타당성이 높아진다
- 사전에 관찰지식이 없는 경우 실험 결과 신뢰가 저하 - 데이터가 불확실하거나 부족하면 결과가 불확실	- 사전지식에 대한 모델링이 어렵다. 사전지식 모델링에 따른 사후 확률결과가 변화 가능성
동전을 던져 앞면이 나오는 사건의 '확률'은 0.5이다.	앞면이 나왔다'는 주장의 신뢰도(degree of belief)가 0.5이다.
이런 검진결과를 가진 환자의 경우 정밀검사를 해보면 10명 중에 7명은 암에 걸려있다.	자신이 암에 걸렸음을 주장하는 의사의 주장이 사실일 신뢰도가 70%이다.

Rules in Probability

7. 총확률정리와 베이즈 정리

2) 베이즈 정리(Bayes' theorem)

- 두 확률 변수의 **사전적 확률 (prior probability, 사전분포)**과 **사후확률 (posterior probability)** 과의 관계에 대한 **설명**
- 토머스 베이즈(- Thomas Bayes, -1701년 7월 1일~ 1761년 4월 7일) : 잉글랜드의 장로교 목사로 확률론의 베이즈 정리를 최초로 서술
- Thomas Bayes는 확률이 상황에 따라 변할 수 있는 것이라고 생각했는데, 이는 기존의 개념과 다른 것으로 **추가되는 새로운 증거에 따라 확률을 새로 계산 및 개선**
- **→ '이전의 경험(사전정보)과 현재의 새로운 증거를 토대로 어떤 사건이 일어날 확률을 추론하는 알고리즘'.**
- 특정사항의 조건부 확률/전체 조건부 확률로 의사결정이론에 기초하여 주어진 주변 확률과 조건부 확률을 이용해서 다른 조건부 확률을 계산하는 것
- **베이즈 정리를 쓰면 데이터(샘플)가 주어지기 전의 사전적 확률값이 데이터가 주어지면서 어떻게 변하는지 계산할 수 있다.** → 따라서 데이터가 주어지기 전에 이미 어느 정도 확률값을 예측하고 있을 때 이를 새로 수집한 데이터와 합쳐서 최종 결과에 반영할 수 있다.

https://ko.wikipedia.org/wiki/%ED%86%A0%EB%A8%B8%EC%8A%A4_%EB%B2%A0%EC%9D%B4%EC%A6%88

1. 확률 기본개념

Bayes' theorem

조건부 확률 (conditional probability)

- $P(A)$: A가 발생할 확률 ,
- $P(A|B)$: B가 발생한 조건에서 A가 발생할 확률
→ 조건부 확률 **Probability of A given B**

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

베이즈 정리(Bayes' theorem)

사후확률 ← 우도 ← 사전확률

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

- $P(A|B)$: **사후확률**(posterior probability). 사건 B가 발생한 후 갱신된 사건 A의 확률
- $P(B|A)$: **우도**(가능도, **likelihood probability**) 사건 A가 발생한 경우 사건 B의 확률
- $P(A)$: **사전적 확률**(**prior probability**) 사건 B가 발생하기 전에 가지고 있던 사건 A의 확률 → 주관적확률에서 객관적확률로 발전 (주가 예측시 주로 0.5)
- $P(B)$: 정규화 상수(normalizing constant) 또는 증거(evidence). 확률의 크기 조정 → 특정 클래스(A)의 분포에 상관없이 전체 클래스에서 특정 특징(B)이 관측될 확률

사전 분포
(prior)



추가 정보
(likelihood)



사후
분포

: 사후확률과 사전확률과의 관계에 대한 설명

→ 사건 B가 발생함으로써 사건 A의 확률이 어떻게 변화하는지를 표현한 정리

→ **사후분포는 사전분포에 우도를 곱함값에 비례한다.**

A가 발생할 확률: $P(A)$, A가 발생한 조건에서 B가 발생할 확률을 $P(B|A)$

$$P(B|A) = P(B \cap A) / P(A)$$

그림에서 $P(B \cap A)$ 는 (우선 전체 C에서 A가 발생해야 하므로) 'A의 발생 확률인 $P(A)$ '에 'A가 발생한 상태에서 B가 발생할 확률인 $P(B|A)$ '를 곱하면 된다.

즉 $P(B \cap A) = P(B|A) * P(A)$ 이항 정리하면

$$P(B|A) = P(B \cap A) / P(A)$$

또한 $P(A|B) = P(A \cap B) / P(B)$ 이므로, $P(A \cap B) = P(A|B) * P(B)$,

그리고 $P(B \cap A) = P(A \cap B)$ 이므로,

$P(B|A) * P(A) = P(A|B) * P(B)$ 이 되어서 결국 **$P(B|A) = P(A|B) * P(B) / P(A)$ 이 된다.**

여기서 $P(A) = P(A|B) * P(B) + P(A|B) * P(B)$ 로 바꾸어 쓸 수 있다.

즉 우리가 알고자 하는 $P(B|A)$ 를 이미 알고 있는 $P(A)$ 와 $P(B)$, 그리고 우도 $P(A|B)$ 를 활용하여 구한다.

$$P(A|B) = \frac{P(A, B)}{P(B)} \rightarrow P(A, B) = P(A|B)P(B)$$

$$P(B|A) = \frac{P(A, B)}{P(A)} \rightarrow P(A, B) = P(B|A)P(A)$$

$$P(A, B) = P(A|B)P(B) = P(B|A)P(A)$$

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Bayes' theorem

베이즈의 정리(Bayes' theorem)를 이용한 분류 메커니즘

- 베이즈 추정(Bayesian Estimation)에 기반한 통계적 기법
- 지도학습(Supervised Learning) 일종
 - Feature와 Label이 필요
- Feature에 따라 Label을 분류하는데 베이즈 정리를 사용하는 것이 특징
- 타겟변수: 범주형(1,0), 수치형이라면 범주형으로 변환
- 표본을 통해 모수를 추정하기보다는 표본 정보와 사전 정보를 함께 사용하여 모수를 추정하는 것
- 추론 대상의 사전 확률과 추가적인 정보를 기반으로 해당 대상의 사후 확률을 추론하는 통계적 방법을 베이즈 추정

likelihood(이미 알고 있는 사건들이 발생했다는 조건 하에, 다른 사건이 발생할 확률)를 구하고, 사전확률과 사후확률을 통해 입력 데이터가 클래스 중 어느 클래스에 속할지에 대한 확률을 구하는 것

Bayes' theorem

베이즈 정리(Bayes' theorem) 사례

- $P(A|B)$: 사건 B를 관측한 후에 그 원인이 되는 A의 확률을 새로 산출한다는 의미 → 사후확률(posterior probability)
- $P(A)$: 사전확률(prior probability) 사건 B가 발생하기 전에 가지고 있던 정보

폐암(A) $P(A)=10\%$	건강(1-A) $P(1-A)=90\%$
0.08 (흡연)	0.32 (흡연)
0.02 (비흡연)	0.58 (비흡연)

- $P(A)=0.1$, 국민 중 폐암 환자 : 비중 → 사전확률(prior probability)
- 주관적 → 객관적 확률로
- $P(B)=0.4$, 국민 중 흡연확률

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

$$= \frac{0.8 \times 0.1}{0.08 + 0.32} = \frac{0.08}{0.4} = 0.2$$

흡연자 중에서 폐암에 걸릴 확률 → $P(A|B) = 20\%$

→ 사전확률 (폐암환자)를 통해 흡연이라는 새로운 사건을 통해 사후 확률 즉, 흡연자 중 폐암의 걸릴 확률이 계산 가능!!!!

$$P(A|B) = \frac{P(B \cap A)}{P(B)} = \frac{\frac{8}{100}}{\frac{40}{100}} = 0.2$$

Bayes' theorem

(예시)

직장 남성의 30%는 지나친 음주로 인해 간에 이상이 있는 것으로 알려져 있다.

만약 간에 이상이 있다면 검사 결과 90%는 이상 반응을 나타나게 되고, 간에 이상이 있지 않은 경우도 이상 반응을 나타낼 수 있는 확률이 10%가 된다고 한다.

임의의 직장 남성에게 대하여 간의 이상 여부를 검사하였을 때 이상이 있는 것으로 나타났지만 실제로는 간에 이상이 없을 확률은 얼마인가?

<해설>

- 간에 이상이 있을 사상 : A_1
- 간에 이상이 없을 사상 : A_2
- 검사결과 이상증상이 나타날 확률 : B

$$P(A_1) = 0.3, P(A_2) = 0.7, P(B | A_1) = 0.9, P(B | A_2) = 0.1$$

총확률 정리에 의해 임의의 직장 남성이 검사에서 이상반응을 보일 확률 $P(B)$ 구하면

$$\rightarrow P(B) = P(B | A_1) P(A_1) + P(B | A_2) P(A_2) = (0.9 \times 0.3) + (0.1 \times 0.7) = 0.34$$

검사결과가 이상이 있는 것으로 나타난 사람에게 대하여 실제로는 간에 이상이 없을 사후적 확률

$$\rightarrow P(A_2 | B) = \frac{P(B | A_2) P(A_2)}{P(B)} = \frac{0.1 \times 0.7}{0.34} = 0.206$$

* Naive Bayes Classifier

나이브 베이즈 모형

- 조건부 확률 기반 생성 모형
- 베이즈 정리를 이용한 확률분류기

Naïve 하다 의미???

천진난만은 순진한(naive, naïve)한 상태

나이브 베이즈 분류기에서는 각각의 특징 간에 서로 아무런 상관관계가 없다는 가정,

→ X변수 (feature) 들이 서로 **조건부 독립(Conditional Independence)**이라는 가정

→ **우도 계산시** 모든 X에 대한 결합확률을 구하는 것이 아니라 y에 따른 각 독립변수들의 확률의 곱으로 쉽게 계산할 수 있기 때문에 !!!!

$$P(A, B) = P(A \cap B) = P(A|B)P(B) = P(A)P(B)$$

나이브 가정하에선 조건부 독립인 확률변수가 가지는 확률들의 곱으로 우도(가능도)가 표현
연관된 확률변수 간에 서로 독립이라는 가정을 함으로써 더 쉽게 베이즈 추론을 할 수 있게 된다.!!!

특징(변수) 1개 경우

$$P(A|B) = \frac{P(A \cap B)P(A)}{P(B)}$$

여러 특징(변수)을
n개로 확대하면!!!

$$P(A|B) = P(A | B_1 \cap B_2 \cap B_3 \cap \dots \cap B_n) = \frac{P(B_1 \cap B_2 \cap B_3 \cap \dots \cap B_n)P(A)}{P(B)}$$

독립성 가정으로 + **가우스분포 Likelihood 모형**

→ X 벡터의 원소가 모두 실수이면, 각 클래스에 값들이 가우스 분포를 따른다고 가정

→ P(A|B)를 최대화 시키는 가우스 함수의 평균을 찾는다.

$$P(A | B_1 \cap B_2 \cap B_3 \cap \dots \cap B_n) = \frac{P(B_1|A)P(B_2|A) \dots \dots P(B_n|A)P(A)}{P(B)}$$

* Naive Bayes Classifier

나이브 베이즈 분류 모형

Likelihood(가능도)를 구하고, → 사전확률과 사후확률을 통해 입력 데이터가 클래스 중 어느 클래스에 속할지에 대한 확률을 구하는 것

분류 과정

1. Feature(Label를 결정요인) 와 Label(1또는 0, 상승 또는 하락)을 파악하는 것
2. Training data set을 통해 classifier 모델 훈련
: 클래스별(상승 또는 하락) 각 속성의 확률분포는 정규분포 라고 가정
: 정규분포 확률밀도함수 (Probability Density Function)로 어느 클래스(상승 또는 하락)에 속할 지의 확률 값 산출
→ 개별종목에 대한 상승확률과 하락확률을 계산하여 높은 확률쪽으로 최종 클래스 결정
3. 테스트 단계에서는 classifier 모델의 성능 (performance) 평가
(accuracy , Precision, Recall 등으로 측정)


금융시장 사례

- 부실기업 예측모형
- 주가 상승/하락 예측

* Naive Bayes Classifier

주가 상승/하락 예측 사례

1. Data set



2. Data set

만약 100종목 12분기 사용시, - 1200개 row

- 클래스별(상대적 상승종목, 하락종목) 특성
- Feature 이상치 제거, Winsorization 후
- 클래스별 feature 기초통계량(평균, 표준편차) 산출
- 정규분포 확률밀도함수 (PDF) : 클래스(상승, 하락)각 속성의 확률분포는 정규분포 가정

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{-(x-\mu)^2}{2\sigma^2}}$$

* Naive Bayes Classifier

주가 상승/하락 예측 사례

3. 상승/하락 분류

■ 나이브 베이즈 분류기 → 투자 고려종목(A)에 대한 상승/하락 분류 판단 → 결과를 통해 매수/매도 여부 의사결정

■ A 종목 : Feature 별 특성

■ A 종목이 상승분류? 하락 분류?



$$P(A|B_1 \cap B_2 \cap B_3 \cap \dots \cap B_n) = \frac{P(B_1|A)P(B_2|A) \dots P(B_n|A)P(A)}{P(B)}$$

$p(\text{상승} | ROE \cap \text{매출액증가율} \cap PER \cap \dots \cap \text{총자산})$ 확률값

$p(\text{하락} | ROE \cap \text{매출액증가율} \cap PER \cap \dots \cap \text{총자산})$ 확률값

→ A종목의 상승확률값과 하락확률값을 비교하여 더 높은 확률값 클래스로 분류

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

상승확률 값

사전확률 : $p(A) \rightarrow p(\text{상승}) = 0.5 \rightarrow$ 앞 자료 1200 row 에서 실제 비율을 계산해도 됨.

$p(\text{매출액증가율} | \text{상승})$, $p(ROE | \text{상승})$,

최종적으로는 확률의 곱을 계산 : 확률의 연속곱이 낮은 값을 보이므로 나이브분류기에서는 확률값($\rightarrow p(\text{매출액증가율} | \text{상승}) \dots$) 을 log 변환 후 계산된다.

상승 확률 = $\log (P(\text{상승} | \text{feature}))$

- 클래스(상승) 매출액증가율 : 평균 8%,
- 표준편차 30%
- A종목 매출액증가율 : 평균 10%, 표준편차 20%
- $P(\text{매출액증가율} | \text{상승})$

$$= \frac{1}{\sqrt{2\pi \times 0.3^2}} e^{-\frac{(0.1-0.08)^2}{2 \times 0.3^2}}$$

이런 방식으로 다른 feature에 대하여도 계산
이후 log값으로 상승확률 계산

상승 확률 = $\log (p(\text{상승} | \text{feature}))$

하락확률 값

사전확률 : $P(B) \rightarrow P(\text{하락}) = 0.5$

$p(\text{매출액증가율} | \text{하락})$, $p(ROE | \text{하락})$,

→ 상승확률 계산과 동일한 방법으로 계산 하락 확률 = $\log (p(\text{하락} | \text{feature}))$

Marginal Probability

주변확률(Marginal Probability)

- 다른 확률변수와 관계없이 발생하는 개별변수의 확률
- 조건부확률과 대비되는 개념으로 비조건부 확률(unconditional probability)라고도 한다.
- 결합확률분포에서는 두 변수간의 교집합 확률을 제시하게 되지만 이를 이용하여 개별변수의 확률인 주변확률을 계산할 수 있다.
- 결합확률분포를 표로 작성할 경우 표의 주변에 개별변수의 확률이 나타난다고 해서 주변확률이라고 부른다.

두 개의 이산변수 X, Y에 대한 주변확률함수

$$f(x) = \sum_{y \in Y} f(x, y), \quad f(y) = \sum_{x \in X} f(x, y)$$

- 결합확률과 주변확률을 이용하여 변수간의 독립성 뿐 아니라 조건부확률을 구할 수 있다.
- 조건부확률은 하나의 변수의 값이 주어졌다는 조건하에서 다른 변수가 특정한 값을 가질 확률로 정의된다. 개별 변수 Y가 특정한 값 y로 값이 주어졌을 때 변수 X가 특정한 값 x를 취할 확률은 다음과 같은 식으로 계산

$$P(X = x | Y = y) = \frac{P(X=x, Y=y)}{P(Y=y)} = \frac{f(x, y)}{f(y)}$$

Probability

결합확률분포(joint probability distribution)

(1) 개념

- 1) 결합확률(joint probability) : 두 개 이상의 사건이 동시에 발생할 확률을 의미 → 사건 A와 B의 교집합의 확률
→ 결합확률은 활용도가 매우 높는데 현실적으로 많은 경우 여러 변수의 행태를 결합적으로 분석할 필요성이 있기 때문이다.
- 2) 결합확률분포(joint probability distribution) : 두 개 이상의 확률변수에 대한 결합적 관계에 대해 확률분포를 구하는 것.

(2) 결합확률함수(joint probability function)

이변량 확률분포에서 결합확률함수(joint probability function)는 임의의 두 확률변수 X, Y 가 동시에 발생할 확률

(3) 결합확률분포를 통한 변수간 독립성 측정

결합확률은 교집합의 확률이므로 확률의 곱셈법칙을 이용하여 변수간의 독립성 여부를 파악할 수 있다.

만약 두 변수가 상호 독립이라면 확률의 곱셈법칙의 예외적인 경우가 되며 결합확률은 각 변수의 주변확률을 곱한 식으로 표현할 수 있다. 두 확률변수가 상호 종속이라면 결합확률은 각 변수간의 주변확률을 곱한 수치와 다르다.

- $f(x, y) = f(x)f(y)$: 변수 X, Y 상호 독립
- $f(x, y) \neq f(x)f(y)$: 변수 X, Y 상호 종속

Probability & Odds

확률(p)과 오즈(Odds)

- 확률(Probability : p) = 비율(proportion), 전체 중에서 어떤 사건(A : event)이 차지하는 크기 $\rightarrow \frac{P(A)}{\text{전체}}$
- 비율(proportion) : 전체 중에서 사건이 차지하는 크기
- 비(ratio) : 사건 A와 B의 **상대적 크기**. 성비, 인구밀도
- Odds : 어떤 사건이 발생할 확률이 발생하지 않을 확률 **대비** 몇배? $\rightarrow \frac{P(y=1|x)}{1-P(y=1|x)}$
- **Odds ratio** : 오즈의 비

- 1) 우리나라 경찰관 중 서울경찰청에 근무하는 비율(proportion)?
- 2) 다른 경찰청 근무 경찰관 대비 서울경찰청 근무 경찰관의 (ratio)는?

- 1) $\frac{\text{서울 경찰관}}{\text{전체 경찰관}} = \frac{27,184}{117,037} = 0.232 \rightarrow 23.2\%$
- 2) $\frac{\text{서울 경찰관}}{\text{다른 경찰관}} = \frac{27,184}{89,853} = 0.3025 \rightarrow 30.25\%$

지방청별(1)	2018				
	합계	경찰청소속			
	소계	소계	지방경찰청	경찰서	지구대파출소
합계	117,037	117,037	19,422	48,356	49,259
서울특별시	27,184	27,184	6,304	10,503	10,377
부산광역시	8,816	8,816	1,296	3,826	3,694
대구광역시	5,531	5,531	840	2,388	2,303
인천광역시	6,153	6,153	1,136	2,556	2,461
광주광역시	3,320	3,320	710	1,343	1,267
대전광역시	3,075	3,075	571	1,301	1,203
울산광역시	2,458	2,458	493	981	984
세종특별자치시	308	308	0	150	158
경기도	22,845	22,845	2,842	9,813	10,190
강원도	4,231	4,231	528	1,809	1,894
충청북도	3,529	3,529	573	1,447	1,509
충청남도	4,563	4,563	741	1,873	1,949
전라북도	4,819	4,819	695	1,901	2,223
전라남도	5,342	5,342	677	2,197	2,468
경상북도	6,390	6,390	769	2,682	2,939
경상남도	6,774	6,774	780	2,977	3,017
제주특별자치도	1,699	1,699	467	609	7623

Probability & Odds

확률(p)과 오즈(Odds)

- 확률(Probability : p) = 비율(proportion), 전체 중에서 어떤 사건(A : event)이 차지하는 크기 $\rightarrow \frac{P(A)}{\text{전체}}$
- 비율(proportion) : 전체 중에서 사건이 차지하는 크기
- 비(ratio) : 사건 A와 B의 **상대적 크기**, 성비, 인구밀도
- Odds : 어떤 사건이 발생할 확률이 발생하지 않을 확률 **대비** 몇배? $\rightarrow \frac{P(y=1|x)}{1-P(y=1|x)}$
- **Odds ratio** : 오즈의 비

오즈(Odds) = $\frac{\text{성공률}}{\text{실패률}} = \frac{p}{1-p} = \frac{\text{사건이 발생할 확률}}{\text{사건이 발생하지 않을 확률}}$
(성공=1, 실패=0, 이항자료에서 성공률을 p)

로지스틱 회귀분석 !!

오즈비(Odds Ratio) : 오즈의 비

$$= \frac{\frac{p_1}{1-p_1}}{\frac{p_0}{1-p_0}} = \frac{e^{(\beta_0 + \beta_1)}}{e^{\beta_0}} = e^{(\beta_1)}$$

- $0 \leq p \leq 1$
- $0 \leq \text{odds} \leq \infty$
- $\text{Logit}(p) = \ln\left(\frac{p}{1-p}\right)$
- $\rightarrow \text{Odds}$ 를 정규분포로 연결하는 고리
- $\rightarrow -\infty < \ln(\text{odds}) < \infty$

1:1 인 경우

$\text{Odds ratio} = \frac{0.5}{1-0.5} = 1 \rightarrow \log(\text{오즈비}) = 0$ 이므로 분포의 중심 위치.

$\rightarrow$ 만약, $\log(\text{오즈비})$ 값이 0과 멀어지면 분포의 양쪽 끝으로 ~~

(예시)

경마게임에서 A 경주마에 대한 승률이 2 : 1이라고 했을 경우에 Odds 와 Odds ratio ?

$$\text{Odds} = \frac{2}{1} = 2 \rightarrow \frac{\frac{2}{3}}{1-\frac{2}{3}} = 2, \quad \text{Odds ratio} = \frac{\frac{\frac{2}{3}}{1-\frac{2}{3}}}{\frac{\frac{1}{3}}{1-\frac{1}{3}}} = 4$$

Logistic Regression

<https://www.youtube.com/watch?v=keR5t8MNi38>

Probability & Likelihood

확률(Probability)

확률분포가 있을 때, 관측값이 분포안에서 어떤 확률을 보여주는지에 대한 값

$$\text{확률} = P(\text{관측값}X \mid \text{확률분포})$$

→ 즉 주어진 확률분포(이산, 연속확률변수)를 고정 시킨 후 관측값이 포함될 수치 (관측값 X에 대한 확률)

- 확률의 합 = 1 → 적분하면 전체 면적은 항상 1 → z분포의 분산값?
- Mutually Exclusive: 어떤 사건이 발생하게 되면 다른 사건은 발생하지 않는다는 것
- Collectively exhaustive : 무수한 sample point들 중에 어느 하나라도 Sample Space를 벗어나는 것은 없다

우도 (Likelihood) , 가능도

▪ 관측값X가 관측되었을 때 관측값이 특정 확률분포로 부터 나왔는지에 대한 가능성

가능도 =

▪ 연속확률밀도함수의 y 값

$$L(\text{확률분포} \mid \text{관측값}X)$$

▪ 주어진 표집 값에 대한 모수의 가능도는 이 모수를 따르는 분포가 주어진 관측 값에 대해 부여하는 확률

→ 우리가 알고있는 데이터들이 그 모수를 따르는 분포로부터 나올 가능성!

우도함수 (가능도함수)

표본 $x_1, x_2, \dots, x_n$ 의 결합확률밀도함수(joint probability density function)

→ 확률변수는 서로 독립

$$L(\Theta \mid x_1, \dots, x_n) = \prod_{i=1}^n f(x_i \mid \Theta)$$

- 가능도 함수는 확률분포가 아니며, 합하여 1이 되지 않을 수 있다.
- Not mutually exclusive , Not exhaustive

"특정한 현상이 일어났다고 할 때, 특정 통계모델 하에서 이 현상이 일어날 확률" 의미 !!!!

Probability & Likelihood


최대우도추정법 (Maximum Likelihood Estimates: MLE)

- 어떤 모수가 주어졌을 때, 원하는 값들이 나올 **가능도**를 최대(Max)로 만드는 모수를 선택하는 방법
- 이론적으로 가장 가능성이 높은 모수를 찾는 방법**

(임의 확률분포 가정)

관찰한 관측치가 서로 *i.i.d(independent identically distributed)*
: 오차가 평균은 0이고, 분산은 σ^2 인 정규분포를 따른다. "


https://ko.wikipedia.org/wiki/%EC%B5%9C%EB%8C%80%EA%B0%80%EB%8A%A5%EB%8F%84_%EB%B0%A9%EB%B2%95



로그 우도(가능도)(log likelihood)

- 우도함수의 로그(log)를 취한 함수
- 최대가능도 추정법을 사용하여 가능도가 최대가 되는 θ 를 계산하기 위하여는 수치적 최적화(numerical optimization)가 필요!
- 로그함수는 단조 증가하기 때문에, 가능도 함수에서 극값을 가지는 위치와 로그 가능도에서 극값을 가지는 위치는 같다.
 - 로그 변환에 의해서는 최대값의 위치가 변치 않는다.
 - 반복시행으로 인한 복수 표본 데이터인 경우 결합 확률밀도함수가 동일한 함수의 곱으로 나타나는 경우가 많은데 이때 로그 변환에 의해 곱셈이 덧셈이 되어 계산이 단순해진다. (로그의 성질 참조)
 - 따라서 가능도 함수를 미분하여 극값을 확률 변수가 독립확률변수로 나누어지는 경우와 같이 확률분포함수가 곱셈 꼴로 나올 때 미분 계산의 편리성을 위해 사용

단조증가(monotone increasing) :: 어떤 수열이나 함수가 정의된 구간에서 감소하지 않는 경우를 단조증가
→ 감소하는 구간이 없는 경우 : 값이 일정하거나 증가하는 구간밖에 없는 경우가 된다.



Probability & Likelihood

최대우도 추정법 (Maximum Likelihood Estimates: MLE) 예시

통 안에 100개 공이 있다. 공은 흰색공과 검은색 공이 섞여 있다.
 10개를 무작위로 추출하였더니, 흰색공 6개, 검은색 공 4개 뽑혔다.
 '최대우도 추정법'에 의하면 통 안에 100개 중 검은색 공은 몇 개 일까?

$$p = \frac{\text{검은 공 수}}{\text{전체 공 수}}$$

$$1 - p = \frac{\text{검은 공이 아닌 수 (=흰색 공 수)}}{\text{전체 공 수}}$$

-통 안에서 검은 공이 나올 확률(p)
 -첫번째 사건은 두번째 사건에 영향을 미치지 않는다.

$$= p \times (1 - p) \times p \times (1 - p) \times p \times (1 - p) \times p \times (1 - p) \times (1 - p) \times (1 - p)$$

$$= p^4 \times (1 - p)^6$$

10개 공을 추출할 때 4개 검은색 공이 나오는 경우의 수

$$\binom{10}{4} = \frac{10!}{4!6!} = 210 = C$$

$$\rightarrow C(10, 4)! = 210$$

← 이항분포의 우도함수(가능도함수)



베르누이 확률변수 Y에 대한 우도함수 $\rightarrow L = \prod p^{y_i}(1 - p)^{1-y_i}$

Probability & Likelihood

최대우도 추정법 (Maximum Likelihood Estimates: MLE) 예시

각 관측값 x 에 대한 총가능도(= 모든 가능도의 곱)가 최대가 되게 하는 확률분포를 찾는 것

통 안에서 공을 10번 추출할 때, 흰 공 6개, 검은 공 4개 뽑힐 확률은?

$$p(\text{사건들} \mid p) = C \times p^4 \times (1-p)^6$$

$$p^* = \operatorname{argmax}_p C \times p^4 \times (1-p)^6$$

(p^* : 우리가 목격한 사건들이 발생한 확률을 가장 높게 만드는 p)

argmax : arguments of the maxima, maxima $f(x)$: $f(x)$ 의 최대값을 만들어주는 입력 x 자체를 의미.

3.1
로지스틱회귀분석 참조

log를 취해 계산을 간단하게 만든다.

$$p^* = \operatorname{argmax}_p C \times p^4 \times (1-p)^6$$

$$= \operatorname{argmax}_p \log(C) + 4\log(p) + 6\log(1-p)$$

$$= \operatorname{argmax}_p f(p)$$

$$f(p) = \log(C) + 4\log(p) + 6\log(1-p)$$

$$f'(p) = \frac{4}{p} - \frac{6}{1-p} = 0, \quad \text{만족하는 } p \text{ 를 구하면 } p = \frac{4}{10}$$

결국 최대우도추정법에 의하면 100개 공에는 검은 공이 $p = \frac{4}{10}$ 감안하면 40개라고 할 수 있다.

베르누이 확률변수

베르누이 실험의 결과에 따라 0 (실패) 또는 1 (성공)의 값을 대응시키는 확률 변수 (Random Variable)

→ 이 확률변수의 확률분포를 베르누이 확률분포

$$P(Y = y_i) = p^{y_i}(1-p)^{1-y_i}$$

($y_i=0,1$)

베르누이 확률변수 Y 에 대한 우도함수 $\rightarrow L = \prod p^{y_i}(1-p)^{1-y_i}$

Probability & Likelihood

최대우도 추정법 (Maximum Likelihood Estimates: MLE) 활용

- **Logistic Regression**
- Decision Trees
- SVM
- Maximum Entropy Model
- Deep Learning

확률표본과 표본공간, 사건

확률표본(probabilistic sample, random sample)

- 풀고자 하는 확률적 문제에서 발생(realize)할 수 있는 하나의 현상
- 선택(sampled)될 수 있는 하나의 경우

표본공간(sample space)

- 가능한 모든 표본의 집합
- 보통 Ω 로 표기

사건(event)

- 표본공간 Ω 의 부분집합
- 전체 표본공간 중에서 우리가 관심을 가지고 있는 일부 표본의 집합

(예시) 동전 1번 던지기 문제

- 확률표본 : 앞면(Head)이 나오는 현상" 또는 "뒷면(Tail)이 나오는 결과
- 표본공간(sample space) $\Omega = \{H, T\}$
- 사건(event)
 - 앞면의 사건 $A = \{H\}$
 - 뒷면의 사건 $B = \{T\}$

Random variable & Random function

1. 확률변수(Random variable)


: 어떠한 실험의 결과를 실수에 대응시켰을 때 그 값(표본공간을 숫자로 바꿔주는 함수)

→ 확률변수(random variables)

→ **확률변수는 미지의 모수를 바탕으로 한 수확함수로 표현되는 확률분포를 따른다.**

: 표본공간의 요소 하나하나에 숫자를 부여하는 변수 X

→ 이산형 확률변수, 연속형 확률변수



→ 하나의 확률실험에 대한 확률변수 전체는 대문자 X, Y, Z 등으로 나타내고 개별값은 소문자 x, y, z 표시

$P(X=x)$: 확률변수 X 가 x 값을 취할 확률

Random variable & Random function

확률변수와 확률함수의 관계

▪ 확률변수(random variable)

→ 사건에 실수값을 대응시키고 그 값에 확률을 부여한 것.

→ 확률로 표현할 사건 및 이벤트를 정의하는 것으로 일어나는 사건의 경우의 수에 대해 숫자화 한 것을 의미

$P(X=x)$: 확률변수 X 가 x 값을 취할 확률

▪ 확률함수

→ 확률을 가진 어떤 사건이 일어날 확률을 통해 파라미터를 만들고, 이를 활용한 수학적 함수를 만드는 것을 뜻한다.
수학적으로 설명하면, 확률 p 를 가진 어떤 사건이 n 회 시행 중에서 x 회 나타날 때, 확률변수 x 와 이에 대응되는 $P(x)$ 의 관계를 나타낸 함수라 말할 수 있다.

[예시 - 동전을 두 번 던질 때, 앞면이 나오는 경우]

• **사건** : 동전을 두 번 던졌을 때 발생하는 사건은 HH, HT, TH, TT

• **확률변수** : HH는 2, HT, TH는 1, TT는 0을 반환 시킨다.

• 확률

1. 확률변수가 2인 경우는 전체 경우의 수 : $1/4$,

2. 확률변수가 1인 경우는 전체 경우의 수 : $2/4 = 1/2$,

3. 확률변수가 0인 경우는 전체 경우의 수 : $1/4$

• **확률함수** : $P(X=2)=1/4$, $P(X=1)=1/2$, $P(X=0)=1/4$

Random variable

1.1 이산확률변수 (discrete random variables) 정의 및 특성

- 변수가 취할 수 있는 값을 하나하나 헤아려 열거할 수 있을 때 그 변수
- 확률실험 결과를 이산확률변수로 나타낼 수 있을 때 개별 확률변수 값에 대한 확률을 구할 수 있다.
- 이산확률변수를 갖는 확률분포가 이산확률분포(discrete probability distribution)

→ 표, 함수로 표시

(사례)

- 동전을 다섯 번 던져서 앞면이 나온 횟수 : $X = 0, 1, 2, 3, 4, 5$
- 1시간 동안 D동 K은행을 방문한 고객 수 : $X = 0, 1, 2, 3 \dots$
- 범죄자를 성별로 분류한 자료 : $X = 1$ (남자), 2 (여자)

Random variable

1.2 연속확률변수 (continuous random variables) 정의 및 특성

- 확률실험의 결과로 나타나는 사상이 주어진 실수구간 내에 속하는 어떠한 값도 취할 수 있는 확률변수
- 연속확률변수를 갖는 확률분포가 연속확률분포(continuous probability distribution)
- 연속확률변수에 대한 확률을 계산할 때 가장 특징적인 것은 개별변수값에 대한 확률을 0이라고 보는 것
- 연속확률변수는 상한값이나 하한값이 주어질 수는 있지만 해당 실수구간의 모든 실수를 취할 수 있기 때문에 정확하게 특정한 한 값이 나올 확률은 0에 가깝다고 보는 것
- → '그래프', 함수 표시 됨

(사례)

- 집에서 회사까지의 출근시간 (최소 30분 최대 1시간) : $30 \leq x \leq 60$
- A사 여자 직원의 신장 (최소 150cm에서 최대 180cm) : $150 \leq x \leq 180$
- 특정 범죄 발생시간 현황 : $0 \leq x \leq 24$

Probability function

2. 확률함수 (Probability Function)

1) 확률함수란?

- (정의) 확률변수 X가 어떤 특정 실수 x를 취할 확률을 함수로 나타낸 것
- (확률함수 역할) 확률실험의 결과를 실수로 바꿔주는 작업을 수행하는 것이 확률변수라면 확률변수에 대응하는 확률을 할당하는 것

2) 구분

(1) 확률질량함수(PMF : Probability Mass Function) : 이산확률분포

- 일반적으로 말하는 확률함수(probability function)
- 이산확률변수 X가 취할 수 있는 각각의 실수값에 확률을 대응시키는 방법 또는 규칙 → 분포표로 표시
 - → $P(X=x)$ 나 $P(x)$ 표기
 - (예시) 주사위를 한번 던졌을 때 나타나는 확률변수가 X 일 때 이 에 대응하는 확률질량함수 $f(x) = 1/6$

(2) 확률밀도함수(PDF: Probability Density Function : pdf) : 연속확률분포

- 연속확률변수 X가 취할 수 있는 실수구간에 대하여 확률을 대응시키는 방법 또는 규칙
- 확률밀도함수는 연속확률변수에 대응하므로, 특정값을 가질 확률은 0이다. 즉, $P(X=x)$ 는 항상 0이다.

→ 그러므로 특정값을 가질 확률이 아닌 특정 구간에 포함된다고 표현

$$P(x_1 \leq X \leq x_2) = \int_{x_1}^{x_2} f(x)dx$$

→ 따라서 $P(A \leq X \leq B)$ 의 확률과 $P(A < X < B)$ 의 확률은 같다. 확률밀도함수는 주로 $f(x)$ 로 표기

- 연속확률변수를 셀 수 없기 때문에 주어진 구간의 적분값이 1이 되도록 한다는 것
- 연속적이며 무한하기 때문에 분포를 표현하는 것이 불가능하다. $f(x)$ 표기

모든 X에 대한 확률의 합은 1이다.

$$\rightarrow \int_{-\infty}^{\infty} f(x)dx = 1$$

* pmf & pdf

- 확률질량함수 : 이산확률변수의 확률분포를 나타내는 것
- 확률밀도함수 : 연속확률변수의 확률을 결정하는 함수

이산확률변수를 확률질량함수라고 하는 이유는?

이산확률변수 X 의 경우 X 의 값에 따라 각각 확률(질량)을 나타낼 수 있으므로, $p(x)$ 를 확률질량함수라고 부르는 것

연속확률변수가 확률밀도함수라고 하는 이유는?

확률밀도함수 $f(x)$ 의 구간 x_1 에서 x_2 의 정적분식으로 표현하면

$$P(x_1 \leq X \leq x_2) = \int_{x_1}^{x_2} f(x)dx$$

좌변 : [확률], 우변 : $d(x)$ 는 [구간길이], $f(x)$ 는 [확률/구간길이]를 의미로 볼 수 있음

→ [확률/구간길이] x [구간길이] = [확률]이기 때문이다.

확률을 일종의 양(질량)으로 보고, 구간길이를 일종의 부피로 보면 [확률/구간길이]는 [질량/부피]가 되므로 '밀도'를 의미하게 된다. → 밀도 = 질량/부피 → 단위 부피당 질량

결국, 연속확률변수는 '확률밀도함수'가 되는 것이다.

- <https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.norm.html>

Random variable

1. 확률변수의 기댓값

- 확률변수의 특성 → 중심경향도와 산포도
- 확률변수의 **중심경향도는 평균의 개념인 기대값으로** 표현된다.
- **확률변수의 산포도는 분산과 표준편차로** 설명할 수 있다.
- 자료가 확률변수인 경우에는 일반 자료에서와 달리 기댓값과 분산을 구할 때 확률을 가중치로 계산하게 된다.

1) 기댓값(Expected Value)의 정의

- 기댓값(Expected Value)은 확률변수의 중심 경향을 나타내 주는 수치적 척도
 - 확률변수가 취할 수 있는 모든 값의 평균을 의미
 - **이산확률변수의 평균은 도수분포표로** 정리된 자료의 평균을 구하는 공식에서 상대도수를 가중치로 계산한 것을 확률로 대체하여 계산하게 되는 개념
- 즉, 각 변수가 발생할 확률은 상대도수의 개념이며 이 확률을 가중치로 하여 가중평균을 계산한 것이 확률변수의 기대값이다.
- 기대값은 확률실험을 장기적으로 실행하여 나타나는 확률변수들의 평균을 계산했을 때 얻어질 것으로 기대되는 수치이며 실험을 무수히 반복했을 때 확률변수 평균의 극한값 또는 장기적 평균의 개념

Random variable

1. 확률변수의 기댓값

1) 이산확률변수 기댓값

X	x_1	x_2		x_n
$P(X=x_i)$	P_1	P_2		P_n

$$X \text{ 이산변수 경우 : } E(X) = \sum_{i=1}^n P_i x_i = x_1 P_1 + x_2 P_2 + \dots + x_n P_n$$

→ 이산확률변수의 기댓값은 확률(P_i)의 가중 합(weighted sum)으로 해석

2) 연속확률변수 기댓값

X 가 연속변수 경우 : $E(X) = \int x_i f(x)dx$ 로 정의

기댓값의 특성

확률변수를 선형적으로 변화시킬 경우 기댓값 또한 선형적으로 변화한다.

- $E(a) = a$
- $E(aX) = aE(X)$
- $E(a+bX) = a+bE(X)$
- $E(X+Y) = E(X) + E(Y)$
- $E(aX + bY) = a E(X) + b E(Y)$

a 와 b 는 상수, X 와 Y 는 확률변수

Random variable

2. 확률변수의 분산 및 표준편차

1) 분산(Variance)의 도출

- 확률변수의 분산(variance)은 확률변수의 산포도를 측정하는 도구
- 확률변수의 기대값이 구해지면 개별 확률변수와 기대값과의 편차를 제공하여 확률 가중치를 부여한 평균값이 분산

- $\text{Var}(X) = E(X - \mu_X)^2 = E(X^2) - [E(X)]^2$
- 이산변수의 경우 $= \sum_{i=1}^n [x - E(X)]^2 \times P(x)$
- 연속변수 경우 $= \int [x - E(X)]^2 \times f(x) d(x)$

$$\begin{aligned}
 & \sum_{i=1}^n [x - E(X)]^2 \times P_i \\
 &= \sum_{i=1}^n x_i^2 P_i - 2m \sum_{i=1}^n x_i P_i + m^2 \sum_{i=1}^n P_i \\
 &= \sum_{i=1}^n x_i^2 P_i - 2m m + m^2 \\
 &= \sum_{i=1}^n x_i^2 P_i - m^2 \\
 &\rightarrow E(X^2) - [E(X)]^2
 \end{aligned}$$

2) 표준편차(Standard Deviation)의 도출

분산은 원래의 단위에서 제공이 되기 때문에 해석상의 어려움이 있으므로 분산의 양의 제곱근으로 표준편차(standard deviation)를 도출한다.

- $\sigma(X) = \sqrt{\text{Var}(x)}$

Random variable

2. 확률변수의 분산 및 표준편차

3) 분산의 특성

- 확률변수의 분산은 편차의 제곱이기 때문에 상수만 추가될 경우는 분산의 변화에 영향을 미치지 못한다.
- 분산은 2차식으로 도출되며 기댓값과의 편차 제곱에 대한 기댓값이므로 기댓값의 변화와는 차이가 발생하는 것.
- 연속확률변수의 분산은 이산확률변수의 분산과 동일

- $\text{Var}(a) = 0$
- $\text{Var}(aX) = a^2 \text{Var}(X)$
- $\text{Var}(aX + b) = a^2 \text{Var}(X)$
- $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$
- $\rightarrow$ 만약 변수 X, Y 가 독립적이면 : $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$
- $\text{Var}(X) = E(X - \mu_X)^2 = E(X^2) - [E(X)]^2 = E(X^2) - \mu^2$

a 와 b 는 상수, X 와 Y 는 확률변수

4) 공분산(Covariance)의 정의

공분산은 두 확률변수 X, Y 사이의 선형관계가 어떤 방향으로 이루어지는지를 표현하는 수치

공분산은 두 확률변수 각각의 기댓값과 편차를 곱한 값에 대한 기댓값으로 정의

$$\begin{aligned} \text{Cov}(X, Y) &= E[(X - E(X)) [Y - E(Y)]] \\ &= E(XY) - E(X)E(Y) \end{aligned}$$

Random variable

(예제)

1. 다음의 확률분포를 갖는 이산확률변수 X 의 기대값과 분산?

X	1	2	3	4	계
$P(X)$	0.2	0.3	0.3	0.2	1

- $E(X) = (1)(0.2) + (2)(0.3) + (3)(0.3) + (4)(0.2) = 0.2 + 0.6 + 0.9 + 0.8 = 2.5$
- $E(X^2) = 1^2(0.2) + 2^2(0.3) + 3^2(0.3) + 4^2(0.2) = 0.2 + 1.2 + 2.7 + 3.2 = 7.3$
- $V(X) = E(X^2) - [E(X)]^2 = 7.3 - 2.5^2 = 7.3 - 6.25 = 1.05$

2. 검은공 3개, 흰공 4개가 들어 있는 주머니에서 2개의 공을 임의로 추출할 때 흰공의 개수를 확률변수 X 라고 할 때 확률변수 X 의 기댓값과 분산을 구하면?

X	0	1	2	합계
$P(X)$	$1/7$	$4/7$	$2/7$	1

- $P(X=0) = \frac{{}^3C_2}{{}^7C_2} = \frac{1}{7}$
- $P(X=2) = \frac{{}^4C_2}{{}^7C_2} = \frac{2}{7}$
- $P(X=1) = \frac{{}^3C_1 \times {}^4C_1}{{}^7C_2} = \frac{4}{7}$
- $E(X) = 0\left(\frac{1}{7}\right) + 1\left(\frac{4}{7}\right) + 2\left(\frac{2}{7}\right) = \left(\frac{4}{7}\right) + \left(\frac{4}{7}\right) = \frac{8}{7}$
- $E(X^2) = 0^2\left(\frac{1}{7}\right) + 1^2\left(\frac{4}{7}\right) + 2^2\left(\frac{2}{7}\right) = \frac{12}{7}$
- $V(X) = E(X^2) - [E(X)]^2 = \frac{12}{7} - \left(\frac{8}{7}\right)^2 = \frac{20}{49} = 0.40816$

Probability distribution

확률분포(Probability distribution) 개념

- 확률변수가 특정한 값을 가질 확률을 나타내는 함수를 의미
- 확률분포는 확률변수와 그에 따른 확률이 어떻게 분포되는 가를 보여주는 것
- 모든 확률변수들은 그 특성에 따라 다양한 확률분포를 따르게 된다.
- 통계분석은 확률변수가 어떤 분포를 따르는가를 파악한 후 → 그 분포의 성질을 이용하여 수행되는 경우가 대부분이다.
- 보편적으로 현실에서 일어나는 사건에 대한 확률분포는 대부분 소수의 특정분포를 따르게 된다.
→ 확률변수가 발생하는 상황에 가장 적합한 확률분포를 찾을 수 있다면 통계분석을 비교적 용이하게 수행할 수 있는 것이다.

확률 변수의 종류에 따라 이산확률분포와 연속확률분포

Probability distribution

확률분포 중요성

1. 확률 계산

: 확률변수가 일어날 확률을 전체 100%인 분포로 표현하여 관측된 통계량이 일어날 확률을 계산할 수 있게 한다.

2. 가설검정 활용

확률변수의 특성(이산 or 연속) 및 분석특성(평균, 분산 차이검정 등)에 따라 이론적으로 성립된 확률분포를 기준으로 모집단의 추론 및 가설검정이 가능하게 한다.

t 분포 → t 검정 (t-test), F 분포 → F 검정 (F-test)

3. 최적의 이론적 모형

: 각 확률분포는 변수와 분석의 특성에 맞는 최적의 이론적 모형을 의미

4. 통계적 의사결정 활용

: 확률분포는 통계량을 파악하여 통계적 의사결정을 내리는 기준 제시

Probability distribution

연속확률분포 (continuous probability distribution)	이산확률분포 (discrete probability distribution)
• 연속확률변수를 갖는 분포 • 확률변수가 <u>특정 구간에 속할 확률을 계산하게</u> 된다. • 확률변수가 연속적이면서 무한개의 경우의 수를 가지는 실수의 값을 가질 때 이루는 확률분포	• 이산확률변수를 갖는 분포 • 개별 변수에 대한 확률을 계산할 수 있다 • 정수와 같이 이산적 값을 가지는 이산확률변수에 대한 확률분포
• 정규분포 Normal distribution, Gaussian distribution • 표준정규분포 (standard normal distribution) • 균일분포 (균등분포) • 감마분포 (gamma distribution) • 베타분포 • 지수분포 (exponential distribution) - 표본분포 : • 표본평균의 분포 : t 분포 • 표본분산의 분포 : 카이제곱분포 (chi-squared distribution) • F분포	• 베르누이분포 (Bernoulli Distribution) • 이항분포 (Binomial distribution) • 기하분포 (Geometric distribution) • 음이항분포 (Negative Binomial Distribution) • 초기화분포 (Hypergeometric distribution) • 포아송분포 (Poisson distribution)
• 그래프로 표시	• 분포표로 표시
• 확률밀도함수 (PDF)	• 확률질량함수 (PMF)
(예시) 사람의 키, 체중, 소득, 주가수익률	(예시) 동전을 두 번 던질 때 앞면이 나올 확률, 찬반투표


Continuous Probability distribution

연속형 확률분포

- 확률변수가 가질 수 있는 값이 셀 수 없을 정도가 많을 때 확률변수
- 연속형 확률분포는 확률변수 각 값의 확률이 아니라 구간의 확률에 의하여 확률분포가 결정
- 정규분포, 표준정규분포, t분포 등
- 연속형 확률변수의 확률분포는 확률밀도함수에 의하여 결정

확률밀도함수 $f(x)$

- 0을 포함한 양의 값을 가지며, X축과 확률밀도함수에 의하여 둘러싸인 부분의 전체 넓이는 1,
- 연속형 확률변수가 구간에 속할 확률을 결정지어 주는 함수
- 연속형 확률변수가 구간 $[a,b]$ 에 속할 확률은 그 구간에서 X축과 확률밀도함수에 의하여 둘러싸인 부분의 넓이
 - 누적분포함수 $F(x)$: 어떤 값 x 보다 작은 구간인 $(-\infty, x]$ 의 속할 확률, $F(x) = P(X \in (-\infty, x]) = P(X \leq x)$



Continuous Probability distribution

1. 정규분포(Normal distribution; Gaussian distribution)

- Johann Carl Friedrich Gauss 도입한 연속확률분포
- 사회·경제적현상이 대체적으로 정규분포를 따르는 것으로 확인되어 정규분포는 통계이론에서 가장 중요하며 현실적으로 가장 많이 적용되는 분포
- 평균(μ , 위치)과 분산(σ^2 , 모양)에 의해 분포 결정

- $X \sim N(\mu, \sigma^2)$
- $E(X) = \mu$
- $Var(X) = \sigma^2$

확률밀도함수(pdf) : 정규분포를 나타내는 곡선

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, -\infty < x < \infty$$

- $f(x)$: 확률밀도함수, π : 원주율
- σ : 집단(클래스, 모집단)의 표준편차
- μ : 집단(클래스)의 평균
- X : 해당 변수

정규분포 성질

(1) 정규분포 특징

- 평균에 대하여 좌우 대칭
- 그래프 곡선 아래 면적 = 1
- 정규분포 그래프는 종 모양

(2) 정규확률변수(normal random variable): 정규분포를 가지는 확률변수

- 평균 주위의 값을 많이 취하며 평균으로부터 좌우로 표준편차의 약3배 이상 떨어진 값은 거의 취하지 않음.

(3) 평균과 표준편차가 같은 두 개의 다른 정규분포는 존재할 수 없다.




(4) 정상부 (평균)에서는 평균(mean)과 중앙값(median), 최빈값(mode) 모두 일치

Continuous Probability distribution

1. 정규분포(Normal distribution; Gaussian distribution)

정규분포가 중요한 이유

- 많은 연속형 데이터가 정규분포를 따르기 때문
- 표본들을 뽑아서 표본들의 평균을 구해보면 그것들이 따르는 분포가 정규분포이기 때문에 더욱 중요: 이를 표본분포(통계량의 확률분포)



표본평균의 확률분포가 정규분포를 따르는 경우


- 모집단의 분포가 정규분포를 따르는 것으로 알려져 있고, 모분산(σ^2)을 알고 있는 경우
- 표본평균의 확률분포는 정규분포를 따르게 된다.
 - 모집단 $X \sim N(\mu, \sigma^2)$ 일 때 표본평균($\bar{X}$)의 분포는 $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$ 이 된다는 것이다.

* Multivariate Normal Distribution

Multivariate normal distribution

다변량 정규 분포(MVN: Multivariate Normal), 결합 정규분포(Joint normal distribution)

- 정규 분포(Normal distribution) : 1개 확률변수 X 에 대한 정규분포(normal distribution)
- 다변량 정규분포(Multivariate Normal distribution) : 복수개의 확률변수가 존재하고 그것을 한번에 모형화 한 것
→ 각각의 정규분포(normal distribution)를 다차원 공간에 확장하여 나타낸 분포



- 확률변수 X 와 Y 각각의 확률밀도함수(PDF): 푸른색(X), 붉은색(Y)
- XY 2차원 평면위에 해당하는 점들을 찍어보면 초록색 원안의 검은 점들로 표현
- 다변량 정규분포(multivariate normal distribution)는 초록색 원안에 분포된 점들의 확률밀도함수(PDF)

https://ko.wikipedia.org/wiki/%EB%8B%A4%EB%B3%80%EB%9F%89_%EC%A0%95%EA%B7%9C%EB%B6%84%ED%8F%AC

판별분석(Discriminant Analysis) 에서 독립변수에 대한 가정 !!!

3. 연속확률분포

* Gauss





1777년 ~1855년
독일 수학자

정규분포 (Normal distribution; Gaussian distribution)

최소제곱법(Gauss Least Squares Method)

1~100까지의 숫자들을 모두 더하면 몇이 나올까?"



<정수론>

1798년 저술하여 1801년 처음 출판한 라틴어 정수론 교과서

2. 표준정규분포(Standard normal distribution)


'단위 문제에서 자유롭다'(scale-free) 표준화(standardization)

- 서로 다른 정규분포를 비교할 수 있도록 여러 개의 분포를 어떤 하나의 기준으로 재배치해서 서로 비교할 수 있도록 한 **표준화된 분포**
(예시) 서로 다른 두 정규분포를 비교해야 하는데, 한쪽은 사람들의 키를 cm 단위로 측정한 반면, 다른 쪽에서는 inch 단위로 측정해 놓은 상황
→ 표준편차를 활용한 거리제기를 적용해도 직접 비교하는게 불가능하므로 표준화가 필요
- 표준정규분포의 Z 값은 어떤 확률변수 X 가 그것의 평균 또는 기댓값으로부터 표준편차를 기준으로 얼마나 떨어져 있는지를 나타내는 지표 →
표준정규분포 = Z분포
- 모든 정규분포는 표준정규분포로 표준화(standardization)할 수 있다. → 정규변수 X를 표준정규변수 Z로 표준화 하는 과정

$$Z = \frac{X - \mu}{\sigma} = \frac{\text{관측값} - \text{평균}}{\text{표준편차}}$$


정규분포

- $X \sim N(\mu, \sigma^2)$



표준정규분포

$$Z \sim N(0, 1)$$



Continuous Probability distribution

2. 표준정규분포(Standard normal distribution)


정규분포

- $N(\mu, \sigma^2)$ 확률변수 X
- $P(a \leq X \leq b)$

표준정규분포

- $N(0, 1)$ 확률변수 Z
- $P\left(\frac{a-\mu}{\sigma} \leq X \leq \frac{b-\mu}{\sigma}\right)$

확률변수 Z 가 평균이 0이고 분산이 1인 정규분포를 따를 때 Z 는 표준정규분포를 따른다고 하며, Z 의 확률밀도함수



$$f(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}z^2}$$

$$-\infty < z < \infty$$

*누적표준정규분포(cumulative standard normal distribution)

Z 분포에서 $Z=-\infty$ 부터 $Z=+\infty$ 까지의 확률을 누적해서 그린 확률분포


- <https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.norm.html>

Continuous Probability distribution

2. 표준정규분포(Standard normal distribution)

평균이 0이고 분산이 1인 정규확률변수는 z 로 나타내며 다음과 같이 표현

z 는 표준정규분포를 따른다고 한다.



표준정규분포의 형태는 위에 그림과 같으며

중심 0에서부터 양의 값 z 까지의 확률은 음영부분의 넓이와 같다.

연속확률분포

그래프의 면적(확률밀도함수)을 통해 확률 z 값의 면적을 구해둔 표

→ 표준정규분포표

$$Z \sim N(0, 1)$$

확률변수 X 가 정규분포 $N(\mu, \sigma^2)$ 를 따르면

확률변수 $Z = \frac{X-\mu}{\sigma}$ 는 표준정규분포 $N(0, 1^2)$ 를 따른다.

$$\blacksquare E(Z) = E\left(\frac{X-\mu}{\sigma}\right) = \frac{E(X)}{\sigma} - \frac{\mu}{\sigma} = \frac{\mu}{\sigma} - \frac{\mu}{\sigma} = 0$$

$$\blacksquare \sigma(Z) = \sqrt{V\left(\frac{X-\mu}{\sigma}\right)} = \sqrt{\frac{V(X)}{\sigma^2}} = \frac{\sigma(X)}{\sigma} = \frac{\sigma}{\sigma} =$$

1

Continuous Probability distribution


2. 표준정규분포(Standard normal distribution)

표준정규분포의 a와 b구간확률

예시1) z값이 1 이하의 값이 나올 확률? (다음면 표1 참조)


1 이하일 확률 : 0.8413 즉, 84.13%

z가 ()보다 작을 확률 : 빗금 친 면적



예시3) z값이 a와 b사이 확률?


: 0과 b 사이 확률과 0과 -a사이 확률을 각각 계산한 후 더하면 됨.



예시2) z 값이 -1 에서 1 일 때의 면적 (확률) 은? (다음면 표2 참조)

: 0에서 1 확률이 '표' 에 의하면 0.3413이므로

-과 1사이 확률은 $0.3413 \times 2 = 0.6826$



Continuous Probability distribution

2. 표준정규분포(Standard normal distribution)

z보다 작은 값을 가질 확률에 대한 누적 표준정규분포표

z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2.0	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.1	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2.2	0.9861	0.9864	0.9868	0.9871	0.9875	0.9878	0.9881	0.9884	0.9887	0.9890
2.3	0.9893	0.9896	0.9898	0.9901	0.9904	0.9906	0.9909	0.9911	0.9913	0.9916
2.4	0.9918	0.9920	0.9922	0.9925	0.9927	0.9929	0.9931	0.9932	0.9934	0.9936
2.5	0.9938	0.9940	0.9941	0.9943	0.9945	0.9946	0.9948	0.9949	0.9951	0.9952
2.6	0.9953	0.9955	0.9956	0.9957	0.9959	0.9960	0.9961	0.9962	0.9963	0.9964
2.7	0.9965	0.9966	0.9967	0.9968	0.9969	0.9970	0.9971	0.9972	0.9973	0.9974
2.8	0.9974	0.9975	0.9976	0.9977	0.9977	0.9978	0.9979	0.9979	0.9980	0.9981
2.9	0.9981	0.9982	0.9982	0.9983	0.9984	0.9984	0.9985	0.9985	0.9986	0.9986


표준정규분포표 1

연속확률분포
그래프의
면적(확률밀도함수)을 통해
확률
z값의 면적을 구해준 표




표준정규분포표 2

	0	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0	0	0.004	0.008	0.012	0.016	0.0199	0.0239	0.0279	0.0319	0.0359
0.1	0.0398	0.0438	0.0478	0.0517	0.0557	0.0596	0.0636	0.0675	0.0714	0.0753
0.2	0.0793	0.0832	0.0871	0.091	0.0948	0.0987	0.1026	0.1064	0.1103	0.1141
0.3	0.1179	0.1217	0.1255	0.1293	0.1331	0.1368	0.1406	0.1443	0.148	0.1517
0.4	0.1554	0.1591	0.1628	0.1664	0.17	0.1736	0.1772	0.1808	0.1844	0.1879
0.5	0.1915	0.195	0.1985	0.2019	0.2054	0.2088	0.2123	0.2157	0.219	0.2224
0.6	0.2257	0.2291	0.2324	0.2357	0.2389	0.2422	0.2454	0.2486	0.2517	0.2549
0.7	0.258	0.2611	0.2642	0.2673	0.2704	0.2734	0.2764	0.2794	0.2823	0.2852
0.8	0.2881	0.291	0.2939	0.2967	0.2995	0.3023	0.3051	0.3078	0.3106	0.3133
0.9	0.3159	0.3186	0.3212	0.3238	0.3264	0.3289	0.3315	0.334	0.3365	0.3389
1	0.3413	0.3438	0.3461	0.3485	0.3508	0.3531	0.3554	0.3577	0.3599	0.3621
1.1	0.3643	0.3665	0.3686	0.3708	0.3729	0.3749	0.377	0.379	0.381	0.383
1.2	0.3849	0.3869	0.3888	0.3907	0.3925	0.3944	0.3962	0.398	0.3997	0.4015
1.3	0.4032	0.4049	0.4066	0.4082	0.4099	0.4115	0.4131	0.4147	0.4162	0.4177
1.4	0.4192	0.4207	0.4222	0.4236	0.4251	0.4265	0.4279	0.4292	0.4306	0.4319
1.5	0.4332	0.4345	0.4357	0.437	0.4382	0.4394	0.4406	0.4418	0.4429	0.4441
1.6	0.4452	0.4463	0.4474	0.4484	0.4495	0.4505	0.4515	0.4525	0.4535	0.4545
1.7	0.4554	0.4564	0.4573	0.4582	0.4591	0.4599	0.4608	0.4616	0.4625	0.4633
1.8	0.4641	0.4649	0.4656	0.4664	0.4671	0.4678	0.4686	0.4693	0.4699	0.4706
1.9	0.4713	0.4719	0.4726	0.4732	0.4738	0.4744	0.475	0.4756	0.4761	0.4767



Continuous Probability distribution

2. 표준정규분포(Standard normal distribution)



(유의수준 α)	Z 값
0.1	1.28
0.05	1.645
0.025	1.96
0.01	2.33

$$P(0 \leq Z \leq 1.645) = 0.45, \quad P(-1.645 \leq Z \leq 1.645) = 0.9$$

$$P(0 \leq Z \leq 1.96) = 0.475, \quad P(-1.96 \leq Z \leq 1.96) = 0.95$$

$$P(0 \leq Z \leq 2.575) = 0.495, \quad P(-2.575 \leq Z \leq 2.575) = 0.99$$

Confidence Interval	Z
80%	1.282
85%	1.440
90%	1.645
95%	1.960
99%	2.576
99.5%	2.807
99.9%	3.291

Continuous Probability distribution

2. 표준정규분포(Standard normal distribution)

(예제1)

00은행에서 근무하는 직원들의 평균 근무기간을 조사하였는데 15년이고, 표준편차는 5년인 정규분포를 따른다고 한다. 00 은행에서 20년 이상 근무한 직원 비율은 얼마나 될까?

$P(X \geq 20)$ 를 구하는 문제이다. 표준화(Z) 하면 $Z = (20-15)/(5) = 1$
 즉, $P(Z \geq 1)$ 를 구하는 문제가 된다.
 표준정규분포표에서 찾아보면 해당 값은 0.8413
 20년 이상 근무한 직원 확률은 $(1-0.8413)=0.1577$, 즉 15.77%가 된다.

$$Z = \frac{X - \mu}{\sigma} = \frac{\text{관측값} - \text{평균}}{\text{표준편차}}$$

(예제2)

최근 휴대폰들의 평균 수명은 900일이고, 표준편차가 50일인 정규분포를 따른다고 한다. 휴대폰 수명이 800일 이하일 확률은?

$P(X \leq 800)$ 를 구하는 문제이다. 표준화(Z) 하면 $Z = (800-900)/(50) = -0.5$
 즉, $P(Z \leq -0.5)$ 를 구하는 문제가 된다.
 표준정규분포표에서 0.5 이상일 확률을 구한 다음 0.6915
 좌우대칭이므로 $(1-0.6915)$
 휴대폰 수명이 800일 이하일 확률 $(1-0.6915)=0.3085$, 즉 30.85%가 된다.

Continuous Probability distribution

2. 표준정규분포(Standard normal distribution)

(예제3)

공무원 시험 응시생 중에서 합격생 평균 점수가 70점이고, 분산이 25점인 정규분포를 따른다.
시험 응시생 중에서 75점 이상 80점 이하일 확률은?

$P(75 \leq X \leq 80)$ 확률 계산문제이다. 표준정규분포(Z)로 전환하면

$$Z = \frac{X - \mu}{\sigma} = \frac{\text{관측값} - \text{평균}}{\text{표준편차}}$$

$= P[(75-70)/5] \leq Z \leq [(80-70)/5]$, 분산 25점이므로 표준편차는 5점

$= P[1 \leq Z \leq 2]$

$= P(Z \leq 2) - P(Z \leq 1)$

$= 0.9772 - 0.8413$

* 표준정규분포표

$= 0.1359$

결국 75점 이상 80점 이하일 확률은 13.59%이다.

iid (independent and identically distribution)

1. independent (독립적)

각 각의 사건이 다른 사건에 영향을 주지 않는다.

하나의 확률 변수의 값이 다른 데이터나 변수에 영향을 미치지 않는다.

$$f(x, y, z) = f(x) \times f(y) \times f(z)$$

2. identically distribution (동일 확률분포)

동일한 확률분포를 가진다.

→ 데이터들이 동일한 모집단에서 추출되었거나 동일한 확률분포를 가지는 형태로 모델링될 수 있다는 가정을 의미
(예시) 주사위 던지기, 동전 던지기

표본분포에 대한 통계량을 계산하고 검증할 때 표본의 확률변수가 iid라는 가정이 있으면 쉽게 수학적으로 계산, 검증이 가능하여 금융데이터 분석에서 가정으로 주로 활용

모집단의 모수를 알아내기 위해

모집단의 일부data를 표본수집한 뒤 → iid 가정 → 표본수집한 값들을 변수변환이나 적률생성함수 등을 이용하여 통계량을 계산

→ 이 통계량은 (모집단을 표현한) 확률변수를 변형한 형태인 또 다른 확률변수로 표본확률분포를 갖게 되고, 이렇게 구한 통계량을 통해 모수를 옳게 추정하면 모집단의 확률분포를 알 수 있어서 모집단의 상태를 기술하고 예측할 수 있다.

Continuous Probability distribution

3. t분포 (Student t분포, Student's t-distribution)

- 프리드리히 로베르트 헬메르트(Friedrich Robert Helmert)가 1875년에 도입
- 통계학자 William Sealy Gosset (1876~1937)이 스튜던트라는 필명으로 재발견 (1907) ~ 스튜던트 t-분포
- 만약 모집단이 정규분포를 따른다고 하면, 표본평균은 t분포를 따른다는 것

→모집단이 정규분포가 아닌 경우에는 표본분석시 t분포를 활용해서 구한 신뢰구간이나 p-value는 정확하지 않을 가능성이 높다.

But 통계연구에서 시뮬레이션 연구를 통해 모집단이 정규분포가 아닌 경우에도 모집단의 왜도가 심각하지 않고 표본의 크기가 매우 작지만 많다면 표본분석시 t분포를 이용하는 것이 괜찮다는 것을 밝혀냈다는 것!!!!!!!

t-분포의 확률변수 정의



$$t\text{-value} = \frac{\bar{X} - \mu_0}{\frac{s}{\sqrt{n}}} \sim t(n-1)$$

$$s = \sqrt{\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}}$$

정규분포를 표준화 시킨 Z와 상당히 유사


다만, 확률변수 t는 자유도가 (n-1)인 t-분포를 따른다. → $t_{(n-1)}$

Continuous Probability distribution

3. t분포 (Student t분포, Student's t-distribution)

모양 특징

- t분포는 정규분포와 같이 중심(=0)을 기준으로 좌우 대칭 → 산모양의 형태를 갖고 중심은 0으로 고정
- 분포의 모양은 자유도(df, degree of freedom)에 따라 달라지므로 자유도가 t분포의 모수
- 자유도가 커질수록 꼬리가 얇아지고 중심부분이 높아져, 자유도가 무한대가 되면 표준정규분포와 동일한 모양
- 표본의 크기가 적을때는 표준 정규분포를 위에서 눌러 놓은 것과 같은 형태를 보이지만 표본이 커져서 **자유도가 증가하면 표준 정규분포와 거의 같은 분포가 됨**
정규분포 $N(\mu, \sigma^2)$ 으로부터의 확률표본이고, 데이터가 연속형일 경우 활용



- 자유도 < 30 : 표준정규분포 보다 분산이 커져 보다 평평한 모양이 되고, .
- 자유도 > 30 : 표준정규분포와 비슷하게 되고, .
- 자유도 > 120 이상이 되면, 표준정규분포와 완전히 같아 짐

표본평균의 확률분포가 t분포를 따르는 경우

표본평균의 확률분포에서 모집단이 정규분포일 때 모분산이 알려지지 않은 경우에는 표본의 크기에 따라 분포가 달라진다.

- 표본에 대표본인 경우 : 모분산을 모르더라도 중심극한정리에 의해 표본평균은 정규분포를 따르게 된다.
- 표본이 소표본 ($n < 30$) 경우 : 표본평균은 자유도 $n - 1$ 의 **t분포(t-distribution)**를 따르게 된다.

Continuous Probability distribution

3. t분포 (Student t분포, Student's t-distribution)

(활용)

- T분포는 모집단이 정규분포를 하더라도 분산 σ^2 이 알려져 있지 않고 표본의 수가 적은 경우에, 평균 μ 에 대한 신뢰구간 추정 및 가설검정에 아주 유용하게 쓰이는 분포
 - →가설검정에서 t검정: t분포를 이용한 검정
- 만약 n 이 매우 크다면 표본평균은 더욱 정확히 정규분포를 따를 것이고, 표본평균의 분산 역시 0으로 점차 수렴하게 됨. 이 경우, 사실상 분산의 영향이 미미하게 되어 무시할 수 있지만, 표본 수가 작을 때는 문제가 됨.
- 이 경우의 검정을 위해, 정규분포와 형태는 비슷하지만 **모분산 값을 포함하고 있지 않고, 대신 표본분산을 이용한 분포를 고안해 내는데, 그것이 t분포!!!!**

Continuous Probability distribution

3. t분포 (Student t분포, Student's t-distribution)

t-분포는

*모집단이 정규분포이고, 모평균을 추정하고 싶은데 모분산을 알 수 없고 표본의 크기가 작은 경우에 활용
→ 모분산 대신에 표본 분산으로 대신해서 보기로~~~*

표준정규분포 (Z분포)

$$\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \Rightarrow \frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}}$$

$$\frac{\frac{\bar{X} - \mu}{\sigma}}{\frac{s}{\sqrt{n}\sigma}} = \frac{\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}}{\sqrt{\frac{s^2}{\sigma^2}}} \Rightarrow \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0, 1), \quad \frac{s^2}{\sigma^2} \sim \frac{\chi_{n-1}^2}{n-1}$$

자유도가 n-1인 t분포를 따른다

$$t\text{-value} = \frac{\bar{X} - \mu_0}{\frac{s}{\sqrt{n}}} \sim t(n-1)$$

Continuous Probability distribution

3. t분포 (Student t분포, Student's t-distribution)

스튜던트 t 분포는 다음 확률변수의 분포로 정의

$$T \equiv \frac{Z}{\sqrt{V/\nu}} = (\bar{X} - \mu) \frac{\sqrt{n}}{S} \quad Z: \text{표준정규분포}, V: \text{자유도}(\nu) \text{인 카이제곱분포} \quad V = \frac{(n-1)s^2}{\sigma^2} \sim \chi_{n-1}^2$$

t 분포는 산모양으로서 t=0에서 좌우대칭을 이룬다.

t 분포의 모양을 결정하는 것은 자유도이며, 자유도가 커질수록 표준정규분포에 가깝게 된다.

$$\begin{aligned} &= \frac{\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}}{\sqrt{\frac{(n-1)s^2}{\sigma^2}/(n-1)}} \\ &= \frac{\bar{X} - \mu}{s/\sqrt{n}} \sim t_{n-1} \end{aligned}$$

$$t\text{-value} = \frac{\bar{X} - \mu_0}{\frac{s}{\sqrt{n}}} \sim t(n-1)$$

확률변수 T가 자유도 ν인 t-분포를 따르는 경우 t-분포 기대값과 분산

1) 기대값

$$E(T) = 0, \nu > 1$$

2) 분산

$$\text{Var}(T) = \frac{\nu}{\nu-2}, \nu > 2$$

$$\infty, 1 < \nu \leq 2$$

Continuous Probability distribution

3. t분포 (Student t분포, Student's t-distribution)


일방향(One-sided)	75% (0.25)	80% (0.2)	85% (0.15)	90% (0.1)	95% (0.05)	97.5% (0.025)	99% (0.01)	99.5% (0.005)	99.75% (0.0025)	99.9% (0.001)	99.95% (0.0005)
양방향(Two-sided)	50%	60%	70%	80%	90%	95%	98%	99%	99.5%	99.8%	99.9%
1	1.000	1.376	1.963	3.078	6.314	12.71	31.82	63.66	127.3	318.3	636.6
2	0.816	1.080	1.386	1.886	2.920	4.303	6.965	9.925	14.09	22.33	31.60
3	0.765	0.978	1.250	1.638	2.353	3.182	4.541	5.841	7.453	10.21	12.92
4	0.741	0.941	1.190	1.533	2.132	2.776	3.747	4.604	5.598	7.173	8.610
5	0.727	0.920	1.156	1.476	2.015	2.571	3.365	4.032	4.773	5.893	6.869
6	0.718	0.906	1.134	1.440	1.943	2.447	3.143	3.707	4.317	5.208	5.959
7	0.711	0.896	1.119	1.415	1.895	2.365	2.998	3.499	4.029	4.785	5.408
8	0.706	0.889	1.108	1.397	1.860	2.306	2.896	3.355	3.833	4.501	5.041
9	0.703	0.883	1.100	1.383	1.833	2.262	2.821	3.250	3.690	4.297	4.781
10	0.700	0.879	1.093	1.372	1.812	2.228	2.764	3.169	3.581	4.144	4.587
11	0.697	0.876	1.088	1.363	1.796	2.201	2.718	3.106	3.497	4.025	4.437
12	0.695	0.873	1.083	1.356	1.782	2.179	2.681	3.055	3.428	3.930	4.318
13	0.694	0.870	1.079	1.350	1.771	2.160	2.650	3.012	3.372	3.852	4.221
14	0.692	0.868	1.076	1.345	1.761	2.145	2.624	2.977	3.326	3.787	4.140
15	0.691	0.866	1.074	1.341	1.753	2.131	2.602	2.947	3.286	3.733	4.073
16	0.690	0.865	1.071	1.337	1.746	2.120	2.583	2.921	3.252	3.686	4.015
17	0.689	0.863	1.069	1.333	1.740	2.110	2.567	2.898	3.222	3.646	3.965
18	0.688	0.862	1.067	1.330	1.734	2.101	2.552	2.878	3.197	3.610	3.922
19	0.688	0.861	1.066	1.328	1.729	2.093	2.539	2.861	3.174	3.579	3.883
20	0.687	0.860	1.064	1.325	1.725	2.086	2.528	2.845	3.153	3.552	3.850
21	0.686	0.859	1.063	1.323	1.721	2.080	2.518	2.831	3.135	3.527	3.819
22	0.686	0.858	1.061	1.321	1.717	2.074	2.508	2.819	3.119	3.505	3.792
23	0.685	0.858	1.060	1.319	1.714	2.069	2.500	2.807	3.104	3.485	3.767
24	0.685	0.857	1.059	1.318	1.711	2.064	2.492	2.797	3.091	3.467	3.745
25	0.684	0.856	1.058	1.316	1.708	2.060	2.485	2.787	3.078	3.450	3.725
26	0.684	0.856	1.058	1.315	1.706	2.056	2.479	2.779	3.067	3.435	3.707
27	0.684	0.855	1.057	1.314	1.703	2.052	2.473	2.771	3.057	3.421	3.690
28	0.683	0.855	1.056	1.313	1.701	2.048	2.467	2.763	3.047	3.408	3.674
29	0.683	0.854	1.055	1.311	1.699	2.045	2.462	2.756	3.038	3.396	3.659
30	0.683	0.854	1.055	1.310	1.697	2.042	2.457	2.750	3.030	3.385	3.646

- α (알파) : 확률(유의수준)
- 양측검정(0.025). 1종 오류를 범할 확률은 α
- 자유도(Degrees of Freedom) : 표본(n)-1

$$t\text{-value} = \frac{\bar{X} - \mu_0}{\frac{s}{\sqrt{n}}} \sim t_{(n-1)}$$

$$s.e = \frac{\sigma}{\sqrt{n}}$$

- 표준오차가 커지면 t가 작아진다
- 회귀계수(b)가 커지면 t가 커진다.
- t값이 얼마일때 통계적 유의성???
- p-value 같이 봐야 함.




Continuous Probability distribution

4. 카이제곱 분포 (χ^2 분포, chi-squared distribution) 표본분산의 확률분포

- 카이제곱 분포(χ^2 분포, chi-squared distribution): **k개의 서로 독립적인 표준정규확률변수를 각각 제곱한 다음 합해서 얻어지는 분포** → 표본분산의 확률분포
- 표준정규분포의 분산의 특징을 확률분포로 만든 것이 카이제곱 분포
- (생각하기) 분포 !!
- 정규분포, 표준정규분포, t분포 : 좌우대칭, 중심 0을 기준으로 가깝거나 멀리 떨어진 정도로 분포 파악
- 분포의 특징 : 변동의 '단위'와 '자료수'를 반영 할 수 있도록 고안된 분포
- 단위가 다른 경우 동일한 변동이라도 제곱합을 구하면 단위가 작은 경우가 더 크게 나오기 때문이고, **자료수가 많을수록 제곱합을 하면 값이 커진다.**

정규분포 $N(\mu, \sigma^2)$ 를 따르는 모집단으로부터 추출된 표본은 $X_1, X_2, \dots, X_n$ 할 때,
자유도는 $(n-1)$ 인 카이제곱(χ^2)의 확률변수 정의



$$f(x; k) = \frac{1}{2^{k/2} \Gamma(k/2)} x^{k/2-1} e^{-x/2} \mathbf{1}_{\{x \geq 0\}}$$


카이제곱분포도 t분포와 마찬가지로 자유도에 따라 분포의 형태가 결정된다.
정규분포 및 t분포와는 다르게 카이제곱 분포는 좌우대칭이 아니다.

Continuous Probability distribution

4. 카이제곱 분포 (χ^2 제곱, chi-squared distribution)

Chi-Square 분포 특성

- χ^2 -확률변수는 연속확률변수인 표준정규변수의 함수이므로 **연속확률분포**
- Z 분포의 제곱에 대한 분포이므로 항상 양(+)의 값을 가지면서 비대칭 형태이다. : χ^2 -분포는 정규분포나 t분포와는 달리, 오른쪽에 긴 꼬리를 가지는 비대칭형 → **자유도(k)가 커질수록 넓게 분포**
- 0의 오른쪽 분포에 분포하지만 0에서 멀어질수록 분포가 감소한다. (치우침이 매우 큰 경우는 많지 않음을 의미한다)
- **표본수 크기가 증가하게 되면 점점 대칭성을 갖추게 되어, 통상 n이 30 이상이면 거의 정규분포에 가까워진다.**



Continuous Probability distribution

4. 카이제곱 분포 (χ^2 제곱, chi-squared distribution)

모평균과 모분산이 알려지지 않은 모집단의 모분산에 대한 가설검정에 사용되는 분포로 정규분포에서 파생된 분포
표본의 평균보다 분산이 더 중요할 경우 사용

(예시)

→ 사례 : 품질, 공정 관리

- 표본분산의 표본분포는 카이제곱 분포에 따른다.

(활용)

- 분산분석(ANOVA)에 활용 → 정규분포를 이루는 여러 집단을 한꺼번에 다룰 수 있으므로
- 변수간의 독립성 검정 및 통계적 분석을 위한 여러 가지 가정에 대한 적합성 검정에 이용
- 표준정규분포로부터 얻는 값을 제공해서 합해주므로 카이제곱분포는 오차나 편차를 분석할 때 유용
- 범주형 자료 검정 및 분석
- (예시 : 성별 (남/여) 의 특성에 따른 선호비율의 차이)

- 동질성 검정: '변인의 분포가 이항분포나 정규분포와 동일하다'라는 가설을 설정한다. 이는 어떤 모집단의 표본이 그 모집단을 대표하고 있는지를 검증하는 데 사용한다.
- 독립성 검정: 변인이 두 개 이상일 때 사용되며, 기대빈도는 '두 변인이 서로 상관이 없고 독립적'이라고 기대하는 것을 의미하며 관찰빈도와와의 차이를 통해 기대빈도의 진위여부를 밝힌다. (위키백과)

Continuous Probability distribution

카이제곱검정 간단한 사례

동전 20번 던지기

동전던지기	관측빈도	기대빈도	편차(D)	편차제곱	편차제곱/ 기대빈도
H	5	10	-5	25	2.5
T	15	10	5	25	2.5
SUM	20	20	0	50	5

$$\chi^2 = \sum \frac{(\text{관측빈도} - \text{기대빈도})^2}{\text{기대빈도}}$$

주사위 60번 던지기


자료수가 많을수록 제곱합을 하면 값이 커진다.

주사위	관측빈도	기대빈도	편차	편차제곱	편차제곱/ 기대빈도
1	5	10	-5	25	2.5
2	14	10	4	16	1.6
3	15	10	5	25	2.5
4	6	10	-4	16	1.6
5	8	10	-2	4	0.4
6	12	10	2	4	0.4
SUM	60	60	0	90	9



Continuous Probability distribution

4. 카이제곱 분포 (χ^2 분포, chi-squared distribution)



		(1- α)					α				
df	α	0.995	0.99	0.975	0.95	0.9	0.1	0.05	0.025	0.01	0.005
1		0.00004	0.0002	0.001	0.004	0.02	2.71	3.84	5.02	6.63	7.88
2		0.01	0.02	0.05	0.10	0.21	4.61	5.99	7.38	9.21	10.60
3		0.07	0.11	0.22	0.35	0.58	6.25	7.81	9.35	11.34	12.84
4		0.21	0.30	0.48	0.71	1.06	7.78	9.49	11.14	13.28	14.86
5		0.41	0.55	0.83	1.15	1.61	9.24	11.07	12.83	15.09	16.75
6		0.68	0.87	1.24	1.64	2.20	10.64	12.59	14.45	16.81	18.55
7		0.99	1.24	1.69	2.17	2.83	12.02	14.07	16.01	18.48	20.28
8		1.34	1.65	2.18	2.73	3.49	13.36	15.51	17.53	20.09	21.95
9		1.73	2.09	2.70	3.33	4.17	14.68	16.92	19.02	21.67	23.59
10		2.16	2.56	3.25	3.94	4.87	15.99	18.31	20.48	23.21	25.19
11		2.60	3.05	3.82	4.57	5.58	17.28	19.68	21.92	24.72	26.76
12		3.07	3.57	4.40	5.23	6.30	18.55	21.03	23.34	26.22	28.30
13		3.57	4.11	5.01	5.89	7.04	19.81	22.36	24.74	27.69	29.82
14		4.07	4.66	5.63	6.57	7.79	21.06	23.68	26.12	29.14	31.32
15		4.60	5.23	6.26	7.26	8.55	22.31	25.00	27.49	30.58	32.80
16		5.14	5.81	6.91	7.96	9.31	23.54	26.30	28.85	32.00	34.27
17		5.70	6.41	7.56	8.67	10.09	24.77	27.59	30.19	33.41	35.72
18		6.26	7.01	8.23	9.39	10.86	25.99	28.87	31.53	34.81	37.16
19		6.84	7.63	8.91	10.12	11.65	27.20	30.14	32.85	36.19	38.58
20		7.43	8.26	9.59	10.85	12.44	28.41	31.41	34.17	37.57	40.00
21		8.03	8.90	10.28	11.59	13.24	29.62	32.67	35.48	38.93	41.40
22		8.64	9.54	10.98	12.34	14.04	30.81	33.92	36.78	40.29	42.80
23		9.26	10.20	11.69	13.09	14.85	32.01	35.17	38.08	41.64	44.18
24		9.89	10.86	12.40	13.85	15.66	33.20	36.42	39.36	42.98	45.56
25		10.52	11.52	13.12	14.61	16.47	34.38	37.65	40.65	44.31	46.93
26		11.16	12.20	13.84	15.38	17.29	35.56	38.89	41.92	45.64	48.29
27		11.81	12.88	14.57	16.15	18.11	36.74	40.11	43.19	46.96	49.64
28		12.46	13.56	15.31	16.93	18.94	37.92	41.34	44.46	48.28	50.99
29		13.12	14.26	16.05	17.71	19.77	39.09	42.56	45.72	49.59	52.34
30		13.79	14.95	16.79	18.49	20.60	40.26	43.77	46.98	50.89	53.67
40		20.71	22.16	24.43	26.51	29.05	51.81	55.76	59.34	63.69	66.77
50		27.99	29.71	32.36	34.76	37.69	63.17	67.50	71.42	76.15	79.49
60		35.53	37.48	40.48	43.19	46.46	74.40	79.08	83.30	88.38	91.95
70		43.28	45.44	48.76	51.74	55.33	85.53	90.53	95.02	100.43	104.21
80		51.17	53.54	57.15	60.39	64.28	96.58	101.88	106.63	112.33	116.32
90		59.20	61.75	65.65	69.13	73.29	107.57	113.15	118.14	124.12	128.30
100		67.33	70.06	74.22	77.93	82.36	118.50	124.34	129.56	135.81	140.17



- 수평축(x): 확률(신뢰구간)
- 수직축(y): 자유도(n-1)



양쪽 동시 가설검정하는 경우




Continuous Probability distribution

4. 카이제곱 분포 (χ^2 제곱, chi-squared distribution)

(예제1)

표본이 10개이고 $\alpha=0.05$ 이다.
이에 해당하는 카이제곱의 값은?

→ 자유도는 $10-1=9$ 이므로 카이제곱표에서 해당하는 값을
찾으면 16.92




(예제2)

표본 11개이고, $\alpha=0.05$ 이다.
이에 해당하는 왼쪽 카이제곱의 값은?

→ 자유도 10이고, 왼쪽 카이제곱값은 $1-\alpha$ 를 해주면
0.95이다. 해당 값을 찾으면 3.94이다.

α df	0.995	0.99	0.975	0.95	0.9	0.1	0.05	0.025	0.01	0.005
1	0.00004	0.0002	0.001	0.004	0.02	2.71	3.84	5.02	6.63	7.88
2	0.01	0.02	0.05	0.10	0.21	4.61	5.99	7.38	9.21	10.60
3	0.07	0.11	0.22	0.35	0.58	6.25	7.81	9.35	11.34	12.84
4	0.21	0.30	0.48	0.71	1.06	7.78	9.49	11.14	13.28	14.86
5	0.41	0.55	0.83	1.15	1.61	9.24	11.07	12.83	15.09	16.75
6	0.68	0.87	1.24	1.64	2.20	10.64	12.59	14.45	16.81	18.55
7	0.99	1.24	1.69	2.17	2.83	12.02	14.07	16.01	18.48	20.28
8	1.34	1.65	2.18	2.73	3.49	13.36	15.51	17.53	20.09	21.95
9	1.73	2.09	2.70	3.33	4.17	14.68	16.92	19.02	21.67	23.59
10	2.16	2.56	3.25	3.94	4.87	15.99	18.31	20.48	23.21	25.19
11	2.60	3.05	3.82	4.57	5.58	17.28	19.68	21.92	24.72	26.76
12	3.07	3.57	4.40	5.23	6.30	18.55	21.03	23.34	26.22	28.30
13	3.57	4.11	5.01	5.89	7.04	19.81	22.36	24.74	27.69	29.82
14	4.07	4.66	5.63	6.57	7.79	21.06	23.68	26.12	29.14	31.32
15	4.60	5.23	6.26	7.26	8.55	22.31	25.00	27.49	30.58	32.80
16	5.14	5.81	6.91	7.96	9.31	23.54	26.30	28.85	32.00	34.27
17	5.70	6.41	7.56	8.67	10.09	24.77	27.59	30.19	33.41	35.72
18	6.26	7.01	8.23	9.39	10.86	25.99	28.87	31.53	34.81	37.16
19	6.84	7.63	8.91	10.12	11.65	27.20	30.14	32.85	36.19	38.58
20	7.43	8.26	9.59	10.85	12.44	28.41	31.41	34.17	37.57	40.00





(예제3)

표본이 7이고, $\alpha=0.1$ 이다.

이에 해당하는 양쪽 카이제곱 값은?

→ 오른쪽 확률은 $\alpha/2=0.05$ 이고, 자유도는 6이므로 해당하는 값은 12.59

→ 왼쪽확률은 $1-\alpha/2=0.95$ 이고, 자유도는 6이므로 해당하는 값은 1.64



Continuous Probability distribution

5. F 분포(F-distribution , Fisher-Snedecor distribution)

- 연속확률분포로, F 검정과 분산분석(ANOVA) 등에서 주로 사용
- 1925년 R.A.Fisher에 의해 제안되었으며, 이후 George W. Snedecor가 Fisher의 이름을 기려 F분포로 명명
- **확률변수는 항상 양의 값만을 갖고**, 카이제곱 분포와 달리 자유도를 2개(n_1-1, n_2-1)가지고 **있으며 자유도가 커질수록**

정규분포에 수렴

→ **회귀분석 결과 모형 적합도, 분산분석(ANOVA)에 주로 사용**

- 두개의 모집단(정규분포) : X_1, X_2
- 각 모집단의 분산 : σ_1^2, σ_2^2
- 각 모집단에서 표본 n_1, n_2 추출하여 표본분산을 계산 : S_1^2, S_2^2
- 표본분산과 모분산의 비율로 이루어진 두개의 카이제곱 비율은 자유도가 2개인 F-분포를 이룬다.

F-value = 두 분산의 비

$$F = \frac{S_1^2}{S_2^2} \sim F(n_1-1, n_2-1)$$


→ **두 집단의 분산값을 나눴셈 한 것을 확률분포로 나타낸 것이 F분포이다.**

나눴셈을 활용하여 두 집단의 분산의 값이 동일한지(=1) 다른지를 비교 가능

→ **1에 가까운 값일수록 두 집단의 분산이 비슷하고, 1과 멀어진 값일수록 두 집단의 분산의 크기가 다르다는 것을 의미**

Continuous Probability distribution


5. F 분포(F-distribution , Fisher-Snedecor distribution)



$$F = \frac{S_1^2}{S_2^2} \sim F(n_1 - 1, n_2 - 1)$$

- 왼쪽에서 1일 때 분산이 동일
- 1을 기준으로 왼쪽면적은 F 계산시 분모값이 큰 경우로 1보다 작게 나오는 경우
- 표본수가 많아 지면 1을 중심으로 뾰족한 정규분포와 비슷해짐.

F분포 특성



- F분포는 χ^2 분포와 마찬가지로, 종형의 **대칭 분포가 아니다.**
 - 표준정규분포를 제공하여 합한 χ^2 분포 2개를 서로 나눈 값이므로, **0보다 큰 영역에서만 그려진다.**
 - **t분포를 제공하면 F분포를 하게 된다.**
 - 자유도가 n인 t분포를 제공하면,

$$t = Z / \sqrt{(\chi^2(n) / n)} \sim t(n) \text{에서, } t^2 = Z^2 / (\chi^2(n) / n) \text{ 이고, } Z^2 \sim \chi^2(1) \text{이므로,}$$

$$= (Z^2(1) / 1) / (\chi^2(n) / n) \sim F(1, n) \text{이 된다.}$$
- 결국 t-value 를 제공하면 F- value

Continuous Probability distribution

5. F 분포(F-distribution , Fisher-Snedecor distribution)

F분포 활용

- 1) 두 분포의 분산을 비교 활용 : 분산분석
- 2) ANOVA(분산분석)에서는 그룹내 변동과 그룹간 변동으로 여러 개의 평균값을 비교하는데 활용
- 3) 회귀모형 자체 유의성 검정
: 회귀분석에서 t-Value 개별 회귀계수의 유의성을 검정하는데 쓰이고,
회귀모형 자체의 유의성 검정을 위해서는 F-value 사용

Continuous Probability distribution

5. F 분포(F-distribution , Fisher-Snedecor distribution)

$\alpha = 0.05$

F-distribution 표 ($\alpha=0.05$)


$df_1 \backslash df_2$	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
1	161.4	199.5	215.7	224.6	230.2	234.0	236.8	238.9	240.5	241.9	243.9	245.9	248.0	249.1	250.1	251.1	252.2	253.3	254.3
2	18.51	19.00	19.16	19.25	19.30	19.33	19.35	19.37	19.38	19.40	19.41	19.43	19.45	19.45	19.46	19.47	19.48	19.49	19.50
3	10.13	9.55	9.28	9.12	9.01	8.94	8.89	8.85	8.81	8.79	8.74	8.70	8.66	8.64	8.62	8.59	8.57	8.55	8.53
4	7.71	6.94	6.59	6.39	6.26	6.16	6.09	6.04	6.00	5.96	5.91	5.86	5.80	5.77	5.75	5.72	5.69	5.66	5.63
5	6.61	5.79	5.41	5.19	5.05	4.95	4.88	4.82	4.77	4.74	4.68	4.62	4.56	4.53	4.50	4.46	4.43	4.40	4.36
6	5.99	5.14	4.76	4.53	4.39	4.28	4.21	4.15	4.10	4.06	4.00	3.94	3.87	3.84	3.81	3.77	3.74	3.70	3.67
7	5.59	4.74	4.35	4.12	3.97	3.87	3.79	3.73	3.68	3.64	3.57	3.51	3.44	3.41	3.38	3.34	3.30	3.27	3.23
8	5.32	4.46	4.07	3.84	3.69	3.58	3.50	3.44	3.39	3.35	3.28	3.22	3.15	3.12	3.08	3.04	3.01	2.97	2.93
9	5.12	4.26	3.86	3.63	3.48	3.37	3.29	3.23	3.18	3.14	3.07	3.01	2.94	2.90	2.86	2.83	2.79	2.75	2.71
10	4.96	4.10	3.71	3.48	3.33	3.22	3.14	3.07	3.02	2.98	2.91	2.85	2.77	2.74	2.70	2.66	2.62	2.58	2.54
11	4.84	3.98	3.59	3.36	3.20	3.09	3.01	2.95	2.90	2.85	2.79	2.72	2.65	2.61	2.57	2.53	2.49	2.45	2.40
12	4.75	3.89	3.49	3.26	3.11	3.00	2.91	2.85	2.80	2.75	2.69	2.62	2.54	2.51	2.47	2.43	2.38	2.34	2.30
13	4.67	3.81	3.41	3.18	3.03	2.92	2.83	2.77	2.71	2.67	2.60	2.53	2.46	2.42	2.38	2.34	2.30	2.25	2.21
14	4.60	3.74	3.34	3.11	2.96	2.85	2.76	2.70	2.65	2.60	2.53	2.46	2.39	2.35	2.31	2.27	2.22	2.18	2.13
15	4.54	3.68	3.29	3.06	2.90	2.79	2.71	2.64	2.59	2.54	2.48	2.40	2.33	2.29	2.25	2.20	2.16	2.11	2.07
16	4.49	3.63	3.24	3.01	2.85	2.74	2.66	2.59	2.54	2.49	2.42	2.35	2.28	2.24	2.19	2.15	2.11	2.06	2.01
17	4.45	3.59	3.20	2.96	2.81	2.70	2.61	2.55	2.49	2.45	2.38	2.31	2.23	2.19	2.15	2.10	2.06	2.01	1.96
18	4.41	3.55	3.16	2.93	2.77	2.66	2.58	2.51	2.46	2.41	2.34	2.27	2.19	2.15	2.11	2.06	2.02	1.97	1.92
19	4.38	3.52	3.13	2.90	2.74	2.63	2.54	2.48	2.42	2.38	2.31	2.23	2.16	2.11	2.07	2.03	1.98	1.93	1.88
20	4.35	3.49	3.10	2.87	2.71	2.60	2.51	2.45	2.39	2.35	2.28	2.20	2.12	2.08	2.04	1.99	1.95	1.90	1.84
21	4.32	3.47	3.07	2.84	2.68	2.57	2.49	2.42	2.37	2.32	2.25	2.18	2.10	2.05	2.01	1.96	1.92	1.87	1.81
22	4.30	3.44	3.05	2.82	2.66	2.55	2.46	2.40	2.34	2.30	2.23	2.15	2.07	2.03	1.98	1.94	1.89	1.84	1.78
23	4.28	3.42	3.03	2.80	2.64	2.53	2.44	2.37	2.32	2.27	2.20	2.13	2.05	2.01	1.96	1.91	1.86	1.81	1.76
24	4.26	3.40	3.01	2.78	2.62	2.51	2.42	2.36	2.30	2.25	2.18	2.11	2.03	1.98	1.94	1.89	1.84	1.79	1.73
25	4.24	3.39	2.99	2.76	2.60	2.49	2.40	2.34	2.28	2.24	2.16	2.09	2.01	1.96	1.92	1.87	1.82	1.77	1.71
26	4.23	3.37	2.98	2.74	2.59	2.47	2.39	2.32	2.27	2.22	2.15	2.07	1.99	1.95	1.90	1.85	1.80	1.75	1.69
27	4.21	3.35	2.96	2.73	2.57	2.46	2.37	2.31	2.25	2.20	2.13	2.06	1.97	1.93	1.88	1.84	1.79	1.73	1.67
28	4.20	3.34	2.95	2.71	2.56	2.45	2.36	2.29	2.24	2.19	2.12	2.04	1.96	1.91	1.87	1.82	1.77	1.71	1.65
29	4.18	3.33	2.93	2.70	2.55	2.43	2.35	2.28	2.22	2.18	2.10	2.03	1.94	1.90	1.85	1.81	1.75	1.70	1.64
30	4.17	3.32	2.92	2.69	2.53	2.42	2.33	2.27	2.21	2.16	2.09	2.01	1.93	1.89	1.84	1.79	1.74	1.68	1.62
40	4.08	3.23	2.84	2.61	2.45	2.34	2.25	2.18	2.12	2.08	2.00	1.92	1.84	1.79	1.74	1.69	1.64	1.58	1.51
60	4.00	3.15	2.76	2.53	2.37	2.25	2.17	2.10	2.04	1.99	1.92	1.84	1.75	1.70	1.65	1.59	1.53	1.47	1.39
120	3.92	3.07	2.68	2.45	2.29	2.18	2.09	2.02	1.96	1.91	1.83	1.75	1.66	1.61	1.55	1.50	1.43	1.35	1.25
∞	3.84	3.00	2.60	2.37	2.21	2.10	2.01	1.94	1.88	1.83	1.75	1.67	1.57	1.52	1.46	1.39	1.32	1.22	1.00

자유도 2개

- 수평(X):분자 자유도(분산이 큰 집단)
 - 수직(Y):분모자유도(분산이 작은 집단)
- 우측검정을 위해 분자가 큰 값으로 설정 (이유)

F분포표의 가장 작은 값은 항상 1이다.

그래서 왼쪽 면적보다는 오른쪽 면적 사용이 편리




$$F = \frac{V_1/k_1}{V_2/k_2} \sim F(k_1, k_2)$$

Continuous Probability distribution

5. F 분포(F-distribution , Fisher-Snedecor distribution)

F-distribution 표 ($\alpha=0.05$)



$df_1 \backslash df_2$	1	2	3	4	5	6	7	8	9	10	12	15
1	161.4	199.5	215.7	224.6	230.2	234.0	236.8	238.9	240.5	241.9	243.9	245.9
2	18.51	19.00	19.16	19.25	19.30	19.33	19.35	19.37	19.38	19.40	19.41	19.43
3	10.13	9.55	9.28	9.12	9.01	8.94	8.89	8.85	8.81	8.79	8.74	8.70
4	7.71	6.94	6.59	6.39	6.26	6.16	6.09	6.04	6.00	5.96	5.91	5.86
5	6.61	5.79	5.41	5.19	5.05	4.95	4.88	4.82	4.77	4.74	4.68	4.62
6	5.99	5.14	4.76	4.53	4.39	4.28	4.21	4.15	4.10	4.06	4.00	3.94
7	5.59	4.74	4.35	4.12	3.97	3.87	3.79	3.73	3.68	3.64	3.57	3.51
8	5.32	4.46	4.07	3.84	3.69	3.58	3.50	3.44	3.39	3.35	3.28	3.22
9	5.12	4.26	3.86	3.63	3.48	3.37	3.29	3.23	3.18	3.14	3.07	3.01
10	4.96	4.10	3.71	3.48	3.33	3.22	3.14	3.07	3.02	2.98	2.91	2.85
11	4.84	3.98	3.59	3.36	3.20	3.09	3.01	2.95	2.90	2.85	2.79	2.72
12	4.75	3.89	3.49	3.26	3.11	3.00	2.91	2.85	2.80	2.75	2.69	2.62
13	4.67	3.81	3.41	3.18	3.03	2.92	2.83	2.77	2.71	2.67	2.60	2.53
14	4.60	3.74	3.34	3.11	2.96	2.85	2.76	2.70	2.65	2.60	2.53	2.46
15	4.54	3.68	3.29	3.06	2.90	2.79	2.71	2.64	2.59	2.54	2.48	2.40
16	4.49	3.63	3.24	3.01	2.85	2.74	2.66	2.59	2.54	2.49	2.42	2.35
17	4.45	3.59	3.20	2.96	2.81	2.70	2.61	2.55	2.49	2.45	2.38	2.31
18	4.41	3.55	3.16	2.93	2.77	2.66	2.58	2.51	2.46	2.41	2.34	2.27

(예제)

두 집단 X,Y가 있다.

집단 X의 표본분산 40이고 $n=8$ 이다. 집단 Y의 표본분산 50이고, $n=5$ 이다.

$\alpha=0.05$ 에 해당하는 F 값은?

→ 집단Y 분산이 크므로 분자가 되고 집단 X가 분모가 된다.

$n_1 - 1 = 4$ 이고, $n_2 - 1 = 7$ 이다.

F분산표에서 해당 값을 찾아보면 4.12이다.

Continuous Probability distribution


5. F 분포(F-distribution , Fisher-Snedecor distribution)

-왼쪽 F값을 구하는 경우

:분자와 분모의 자유도가 서로 바뀐다.

F분포표 해당값을 찾는다

역수를 취한 값이 F 통계량이다.



(예제)

두 집단 X,Y가 있다.

집단 X의 표본분산 25이고 $n=12$ 이다. 집단 Y의 표본분산 17이고, $n=9$ 이다. $\alpha=0.05$ 에 해당하는 왼쪽F값은?

→ 집단X 분산이 크므로 분자가 되고 집단 Y가 분모가 된다.

$n_1 - 1 = 11$ 이고, $n_2 - 1 = 8$ 이다.

이때 왼쪽 F값을 구하는 것이므로 분자와 분모 자유도가 서로 바뀐다.

그런 다음 0.05 F분산표에서 해당 값을 찾아보면 2.95다. 결국 F-value는 2.95 역수 **0.339**가 된다.

Continuous Probability distribution


5. F 분포(F-distribution , Fisher-Snedecor distribution)

양쪽 F값을 구하는 경우

: 주어진 α 에서 $\alpha/2$ 가 변한다.

: 오른쪽 F값은 자유도-1 해당 F값을 찾으면 된다.

: 왼쪽 F값은 분자와 분모 자유도가 서로 바뀌고 해당 F값을 찾은 후 역수를 취한다.



$\alpha = 0.05$

$df_1 \backslash df_2$	1	2	3	4	5	6	7	8	9	10	12	15
1	161.4	199.5	215.7	224.6	230.2	234.0	236.8	238.9	240.5	241.9	243.9	245.9
2	18.51	19.00	19.16	19.25	19.30	19.33	19.35	19.37	19.38	19.40	19.41	19.43
3	10.13	9.55	9.28	9.12	9.01	8.94	8.89	8.85	8.81	8.79	8.74	8.70
4	7.71	6.94	6.59	6.39	6.26	6.16	6.09	6.04	6.00	5.96	5.91	5.86
5	6.61	5.79	5.41	5.19	5.05	4.95	4.88	4.82	4.77	4.74	4.68	4.62
6	5.99	5.14	4.76	4.53	4.39	4.28	4.21	4.15	4.10	4.06	4.00	3.94
7	5.59	4.74	4.35	4.12	3.97	3.87	3.79	3.73	3.68	3.64	3.57	3.51
8	5.32	4.46	4.07	3.84	3.69	3.58	3.50	3.44	3.39	3.35	3.28	3.22
9	5.12	4.26	3.86	3.63	3.48	3.37	3.29	3.23	3.18	3.14	3.07	3.01
10	4.96	4.10	3.71	3.48	3.33	3.22	3.14	3.07	3.02	2.98	2.91	2.85
11	4.84	3.98	3.59	3.36	3.20	3.09	3.01	2.95	2.90	2.85	2.79	2.72
12	4.75	3.89	3.49	3.26	3.11	3.00	2.91	2.85	2.80	2.75	2.69	2.62
13	4.67	3.81	3.41	3.18	3.03	2.92	2.83	2.77	2.71	2.67	2.60	2.53
14	4.60	3.74	3.34	3.11	2.96	2.85	2.76	2.70	2.65	2.60	2.53	2.46
15	4.54	3.68	3.29	3.06	2.90	2.79	2.71	2.64	2.59	2.54	2.48	2.40
16	4.49	3.63	3.24	3.01	2.85	2.74	2.66	2.59	2.54	2.49	2.42	2.35
17	4.45	3.59	3.20	2.96	2.81	2.70	2.61	2.55	2.49	2.45	2.38	2.31
18	4.41	3.55	3.16	2.93	2.77	2.66	2.58	2.51	2.46	2.41	2.34	2.27

(예제)

두 집단 X,Y가 있다.

집단 X의 표본분산 50이고 N=13이다. 집단 Y의 표본분산 30이고, N=10이다. $\alpha=0.10$ 에 해당하는 양쪽F값은?

→ 양쪽 F값은 $\alpha/2 = 0.05$ 가 됨을 주의하자.

집단X 분산이 크므로 $N1-1=12$ 이고, $N2-1=9$ 이다.

해당하는 값을 0.05 F분산표에서 찾아보면 오른쪽 F값은 3.07이다.

왼쪽 F값은 자유도가 서로 바뀌므로 (9,12)에 해당하는 값2.8를 역수를 취하면 F값은 0.357이 된다.

* Gamma distribution

* 감마분포

- 감마분포는 정규분포로 해결할 수 없는 부분을 보완하기 나온 확률 분포
- 평균 소요시간이 λ 인 사건이 k 번째 일어날 때까지 걸리는 시간에 대한 연속 확률분포 → 감마분포는 지수분포를 여러 개의 사건으로 확장한 것

- 감마분포 : k 번의 사건이 일어날 때까지 걸리는 대기시간에 대한 분포
- 지수분포 : 사건이 1번 일어날 때까지 걸리는 시간에 대한 분포

감마분포는 지수분포를 한 번의 사건이 아닌 여러 개의 사건으로 확장한 것으로 이해하면 됨.

- 감마분포는 두 개의 매개변수 α (모양 매개변수, shape parameter)와 β (척도 매개변수, scale parameter)에 의해 정의된다.
- 감마분포는 주로 대기 시간이나 서비스 시간 등을 모델링하는 데 사용되며, 특히 그 사건들이 특정 시간 동안 일어나는 사건의 횟수와 관련 있을 때 적합하다.

확률 밀도 함수 (Probability Density Function, PDF)

$$f(x; \alpha, \beta) = \frac{x^{\alpha-1} e^{-x/\beta}}{\beta^{\alpha} \Gamma(\alpha)}$$

여기서 $x \geq 0, \alpha > 0, \beta > 0$
 $\Gamma(\alpha)$ 는 감마 함수로, α 의 값에 따라 계산

* Gamma distribution

* 감마분포 특성

1.모양과 척도

: 감마분포의 모양은 α 에 의해 결정되며, 이 모양 매개변수는 분포의 정점(peak)의 위치와 길이를 결정한다.
 β 는 척도 매개변수로서, 분포의 분산 정도를 조절한다.

2. 특수 케이스:

$\alpha=1$ 일 때, 감마분포는 지수분포(Exponential(β))와 동일합니다.

$\beta=2$ 이고 α 가 반정수일 때, 감마분포는 카이제곱 분포의 일반화된 형태로 볼 수 있다.

기대값과 분산

- 기대값 = $E(X) = \alpha\beta$
- 분산 = $Var(X) = \alpha\beta^2$

감마분포 활용


- 감마분포는 베이저안 통계학에서 사전 분포로 사용되는 경우가 많다.
(예시)
- 포아송 분포의 파라미터를 추정하는 데 사용
- 공학, 자연과학, 경제학 등 여러 분야에서 다양한 확률 과정과 대기 시간을 모델링하는 데 활용
- 복잡한 생물학적 현상과 보험 수학에서의 청구 금액 등의 모델링에도 중요한 역할을 한다.

* Gamma distribution


* 감마분포

$$f_X(x) = \frac{\lambda^k x^{k-1} e^{-\lambda x}}{\Gamma(k)}, \quad x \geq 0$$

k: shape parameter
 λ : scale parameter 1인 경우



k: shape parameter 3인 경우
 λ : scale parameter



λ 가 고정된 상태에서 k 가 증가하면 평균과 분산이 커지면서 분포는 점점 오른쪽으로 퍼진다.
 $\rightarrow$ 사건개수 k 가 많을수록 대기시간은 길어진다.

* Gamma distribution

* 감마함수 $\Gamma(p)$

$$\Gamma(p) = \int_0^{\infty} x^{p-1} e^{-x} dx = 2 \int_0^{\infty} x^{2p-1} e^{-x^2} dx \quad (\text{Re}(p) > 0)$$

계승 (Factorial) 함수를 보다 일반화시킨 함수

- n 이 정수일 때 : 계승 함수
- n 이 정수가 아닌 임의의 수 p 일때 : 감마 함수

감마함수 성질

- 1) $\Gamma(k) = (k-1) \Gamma(k-1) \quad (k > 1)$
- 2) $\Gamma(n) = (n-1)! \quad (n : \text{자연수})$
- 3) $\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$

Factorial Function

$$\int_0^{\infty} x^n e^{-\alpha x} dx = \frac{n!}{\alpha^{n+1}}$$

$$\int_0^{\infty} x^n e^{-x} dx = n! \quad (n = 1, 2, 3, \dots)$$

* Exponential distribution

지수분포는 감마분포에서 $k=1$ 인 케이스

- 사건이 서로 독립적일 때, 일정 시간동안 발생하는 사건의 횟수가 포아송 분포를 따른다면, 다음 사건이 일어날 때까지 대기시간은 지수분포를 따른다.
- 지수분포는 특정 사건이 일어나고 다음에 같은 사건이 일어날 때까지 걸리는 시간에 대한 분포
- 독립적인 사건들 사이의 시간 간격을 모델링하는 데 주로 사용→ 이 분포는 '무기억성'(memoryless property)의 특성을 가지고 있으며, 이는 과거의 어떤 정보도 미래의 예측에 영향을 주지 않는다는 것을 의미

(예시)

평균적으로 10분에 한번씩 도착하는 버스가 있을 때, 버스를 놓친 후 그 다음 버스가 올 때까지 걸리는 시간은 지수 분포를 따른다고 할 수 있다.

- 여기서 다음 사건이 발생할 때까지 걸리는 시간을 알려면 사건의 발생 횟수에 대해 알아야 한다.
- → 어떤 사건의 발생 횟수가 포아송 분포를 따르면 사건 사이의 대기 시간은 지수 분포를 따르게 된다.

Exponential 확률변수


- 시간내 확률, 고장시간, 대기시간, inter-arrival time을 모형화하는데 사용

* Exponential distribution

확률질량함수(PDF)

: parameter λ (빈도) > 0

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x} & x \geq 0 \\ 0 & x < 0 \end{cases}$$



- 지수 분포는 포아송 분포와 밀접한 관련
- 포아송 분포는 단위 시간동안 어떤 사건이 평균적으로 λ 회 발생한다고 했을 때, 단위시간동안 사건이 k 번 일어날 확률에 대한 분포를 지칭

$$P(K=k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

- $P(K=0)$ 이 T 번 일어날 확률은 $P(K=0)$ 을 T 번 곱해서 계산

확률밀도함수(PDF)를 $f(t)$ T 단위시간에 첫 사건이 일어날 확률

$$Pr(0 \leq t \leq T) = \int_0^T f(t) dt$$

$$(P(K=0))^T$$

- T 시간만에 해당 사건이 일어날 확률

$$1 - (P(K=0))^T = 1 - \left(\frac{\lambda^k e^{-\lambda}}{k!} \right)^T = 1 - e^{-\lambda T}$$

포아송 분포를 이용해 위 문제를 풀기 위해선 여사건을 이용하는 것이 좋은 접근일 수 있다.

포아송 분포를 이용해 T 단위시간동안 사건이 일어나지 않을 확률을 계산해서 전체 확률값(1)에서 빼주면 그 결과가 바로 T 시간만에 해당 사건이 일어날 확률이기 때문!!

지수 분포라고 할 수 있을만한 확률밀도함수 $f(t)$ 를 이용해 계산한 확률

$$\int_0^T f(t) dt = 1 - e^{-\lambda T} \quad f(t) = \frac{d}{dt}(1 - e^{-\lambda t}) = \lambda e^{-\lambda t}$$


누적 분포 함수(CDF)

For $x \geq 0$

$$F_X(x) = \int_0^x \lambda e^{-\lambda u} du = [-e^{-\lambda u}]_0^x = 1 - e^{-\lambda x}$$

For $x < 0$

$$F_X(x) = 0$$



* Exponential distribution

Exponential 확률변수

평균

$$\begin{aligned}
 E[X] &= \int_{-\infty}^{\infty} x f_X(x) dx = \int_0^{\infty} x \lambda e^{-\lambda x} dx = \int_0^{\infty} x (-e^{-\lambda x})' dx \\
 &= [x(-e^{-\lambda x})]_0^{\infty} - \int_0^{\infty} (-e^{-\lambda x}) dx = \left[-\frac{1}{\lambda} e^{-\lambda x} \right]_0^{\infty} = \frac{1}{\lambda}
 \end{aligned}$$

분산

$$\begin{aligned}
 E[X^2] &= \int_{-\infty}^{\infty} x^2 f_X(x) dx = \int_0^{\infty} x^2 \lambda e^{-\lambda x} dx = \int_0^{\infty} x^2 (-e^{-\lambda x})' dx \\
 &= [x^2(-e^{-\lambda x})]_0^{\infty} - \int_0^{\infty} 2x(-e^{-\lambda x}) dx = 2 \int_0^{\infty} x e^{-\lambda x} dx = \frac{2}{\lambda} \underbrace{\int_0^{\infty} x \lambda e^{-\lambda x} dx}_{E[X]} \\
 &= \frac{2}{\lambda^2}
 \end{aligned}$$

$$Var(X) = E[X^2] - (E[X])^2 = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}$$

지수분포 응용

- 신뢰성 엔지니어링: 장비나 시스템의 고장 시간을 분석할 때 사용
- 통신 이론: 메시지나 데이터 패킷이 도착하는 시간 간격을 모델링한다.
- 대기열 이론: 서비스 시스템에서 고객이 도착하는 시간 간격을 분석하는 데 사용

* beta distribution

- 베타분포(Beta distribution)는 연속확률분포 중 하나로서, 0과 1 사이의 값에 대해 정의되며, 두 개의 모수, 즉 알파(α)와 베타(β)에 의해 형태가 결정
- 이 분포는 주로 비율이나 확률 같은 제한된 범위의 값에 대한 정보를 모델링하는 데 사용

베타 분포의 확률밀도함수

베타함수(beta function)는 이항계수(binomial coefficient)를 일반화한 것

$$X \sim \text{Beta}(\alpha, \beta)$$

$$f_X(x) = \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1}$$

$$(0 < x < 1, \alpha, \beta > 0)$$

$$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}$$

$$B(x, y) := \int_0^1 t^{x-1} (1-t)^{y-1} dt, \quad (\text{Re}(x), \text{Re}(y) > 0)$$

$\Gamma(n)$ 은 감마 함수로 팩토리얼의 일반화된 형태

베타 분포는 확률에 대한 분포

x 의 도메인이 '0에서 1 사이'

$\alpha-1, \beta-1$: 각각 어떤 사건의 '성공 횟수', '실패 횟수'

$B(\alpha, \beta)$: 확률밀도함수의 0부터 1사이 integral sum이 1이 되도록 하는 상수

$$1 = \int_0^1 \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1} dx$$

$$B(\alpha, \beta) = \int_0^1 x^{\alpha-1} (1-x)^{\beta-1} dx$$

(사용) 베이지안에서 사전확률을 가정할때 베타분포를 가정

베타분포의 성질

1. 모수

베타분포는 두 모수 α 와 β 에 의해 그 형태가 결정

이 모수들은 분포의 모양을 결정하는데, 예를 들어 분포가 얼마나 좌우 대칭인지, 어디에 더 많은 질량이 집중되어 있는지 등을 나타낸다.

2. 지지 집합

베타분포의 값은 항상 0과 1 사이에 있다.

이는 비율이나 확률을 모델링하는 데 적합하다는 것을 의미한다.

3. 유연성

: α 와 β 값을 변화시킴으로써 베타분포는 다양한 형태를 취할 수 있다.

예를 들어, $\alpha=\beta=1$ 일 경우 균등 분포가 되고, α 와 β 중 하나가 1보다 크고 다른 하나가 1보다 작으면 J자 형태의 분포가 된다.

기대값과 분산

$$1. \text{ 기대값} = E(X) = \frac{\alpha}{\alpha + \beta}$$

$$2. \text{ 분산} = Var(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$$

Discrete probability distribution

1. 베르누이 분포 (Bernoulli's distribution)

베르누이 시행 (Bernoulli's trials)

: 서로 **반대되는 사건이 일어나는 실험을** 반복적으로 실행하는 것

→ 반드시 결과가 두 개만 존재하며, 반대되는 사건이 동시에 나오지 않음 (어느 한 시행결과가 다른 시행결과에 영향을 미치지 않는 두 시행은 서로 독립.배타적 사건이 돼야 함)

예시) 동전 던지기 : 앞/뒤 , 주사위던지기 : 짝수, 홀수

→ **베르누이 시행의 결과를 바탕으로 이항 분포를 설명함**

시행마다 오직 두가지 가능한 결과만 일어난다고 할 때, 이러한 **실험을 1회 시행하여** 일어난 두 가지 결과에 의해 그 값이 각각 0과 1로 결정되는 확률변수 X 에 대해서 $P(X=1)=p$, $P(X=0)=q$, $q=1-p$, 를 만족하는 확률변수 X 가 따르는 확률분포를 베르누이분포, **→ 이항분포의 특별한 경우**

- **이항분포** : 불확률이 p 이고 뽑힌 상품의 수를 n 일 때 불량품 수(X)의 분포이며 다음과 같이 표현한다. 여기에서 $n=1$ 인 경우는 **베르누이 분포**이다.

베르누이 시행을 확률 분포로 나타낸 것을 베르누이 분포라고 함.

표본공간에 상호 배타적인 두 가지 사건만이 존재하는 **시행을 단 한 번 실험했을 때 얻어진다.**

-> 성공 확률을 $p(x=1 \text{ 인 경우})$ 라 할 때, 실패 확률은 $1-p (x=0 \text{ 인 경우})$ 라고 가정.

서로 반대되는 배반 사건이기 때문에 확률은 100%에서 빼는 것

- 스위스의 수학자 **야코프 베르누이** (Jakob Bernoulli) 의 이름에 따라 명명

(사례) 동전 한번 던지기(앞면/뒷면), 합격/불합격, 당첨/탈락, 성공/실패, 참/거짓, 등 논리를 활용하는 상황에 적용

Discrete probability distribution

1. 베르누이 분포 (Bernoulli's distribution)

베르누이 분포 : 평균과 분산

$$X = \begin{cases} 1 : & \text{with probability } p \text{ (성공확률)} \\ 0 : & \text{with probability } (1-p) \text{ (실패확률)} \end{cases}$$

- 평균 = p
- 분산 = $p(1-p)$

$$\mu = \sum xp(x) = 1 \times p + 0 \times (1-p) = p$$

$$\begin{aligned} \sigma^2 &= \text{Var}(X) = E(X^2) - [E(X)]^2 \\ &= 0^2 \times p^0(1-p)^{1-0} + 1^2 \times p^1(1-p)^{1-1} - p^2 \\ &= p - p^2 \\ &= p(1-p) \end{aligned}$$

베르누이 확률변수

베르누이 실행의 결과에 따라 0 (실패) 또는 1 (성공)의 값을 대응시키는 확률 변수 (Random Variable)
→ 이 확률변수의 확률분포를 베르누이 확률분포

$$P(Y = y_i) = p^{y_i}(1-p)^{1-y_i}$$

($y_i=0,1$)

베르누이 확률변수 Y에 대한 우도함수 → $L = \prod p^{y_i}(1-p)^{1-y_i}$

베르누이 분포를 따르는 확률변수 X의 Entropy : 이진 엔트로피(binary entropy)

$$\rightarrow H(X) = - [p \log p + (1-p) \log(1-p)]$$

Discrete probability distribution

2. 이항 분포 (binomial distribution)

베르누이분포가 한 번 시행하는 경우를 다룬다면 → 이항분포는 n번 시행하는 경우까지 확장한다.

→ 서로 독립인 베르누이분포를 모두 합치면 이항분포가 된다.

→ 독립적이고 동일한 분포를 따르는 (iid: independent and identically distributed) n번의 베르누이 시행 결과 : 두 가지의 항목으로 된 분포 , 상호 배반적인 두 사건만 나타나는 경우 발행할 확률의 기준이 되는 분포

연속적인 베르누이 시행을 거쳐 나타나는 확률 분포

독립된 베르누이시행을 n번 만큼 반복했을 때, X가 나타나는 확률

$$X \sim B(n, p) \quad B : \text{Binomial distribution}$$

이항분포의 성질 (이항분포의 확장)

- 이항분포를 확대하였을 때 얻을 수 있는 이항 계수는 그 항이 일어날 수 있는 가지 수
- 이항분포를 확대시켜 가면 확률의 분포는 정규성에 가까워 진다. ($n > 30$)
- 포아송분포로 수렴

Discrete probability distribution

2. 이항 분포 (binomial distribution)

이항분포 확률

이항분포의 확률 : n 번의 시행에서 성공확률 (p)이 r 번 나타날 확률이며, n번의 시행에서 r번 관찰되는 것(이항계수)을 nCr 로 표현할 수 있음

- r 번 성공할 확률과 (n-r)번의 실패할 확률을 곱하면, 이항분포의 확률 함수

$(n \ r) = n! / r! * (n-r)! = nCr$ 을 의미함 : 이항계수

n : 총횟수 / r = 성공 횟수 / n-r : 실패 횟수

$$P(X=r) = \binom{n}{r} p^r (1-p)^{(n-r)} = \frac{n!}{r! * (n-r)!} * p^r * (1-p)^{(n-r)}$$

$$P(X=r) = {}_n C_r p^r q^{n-r} \quad (\text{단, } p+q=1, r=0, 1, 2, \dots, n)$$

이항분포 평균과 분산

- 평균 = np
- 분산 = np(1-p)

$$\begin{aligned} E(X) &= \sum_{r=0}^n \{r \times P(X=r)\} \\ &= \sum_{r=0}^n \{r \times {}_n C_r p^r q^{n-r}\} \\ &= \sum_{r=1}^n \{n \times {}_{n-1} C_{r-1} p^r q^{n-r}\} \\ &= np \times \sum_{r=1}^n \{{}_{n-1} C_{r-1} p^{r-1} q^{n-r}\} \\ &= np(p+q)^{n-1} \\ &= np \end{aligned}$$

Discrete probability distribution

2. 이항 분포 (binomial distribution)

**이항분포 분산(증명)

$$\begin{aligned}
 E(X^2) &= \sum_{r=0}^n \{r^2 \times P(X=r)\} \\
 &= \sum_{r=0}^n \{r^2 \times {}_nC_r p^r q^{n-r}\} \\
 &= \sum_{r=0}^n \{(r^2 - r + r) \times {}_nC_r p^r q^{n-r}\} \\
 &= \sum_{r=0}^n \{r(r-1) \times {}_nC_r p^r q^{n-r}\} + \sum_{r=0}^n \{r \times {}_nC_r p^r q^{n-r}\} \\
 &= \sum_{r=0}^n \{r(r-1) \times {}_nC_r p^r q^{n-r}\} + np \\
 &= \sum_{r=2}^n \left\{ r(r-1) \times \frac{n!}{(n-r)! \times r!} \times p^r q^{n-r} \right\} + np \\
 &= n(n-1)p^2 \times \sum_{r=2}^n \left\{ \frac{(n-2)!}{(n-r)! \times (r-2)!} \times p^{r-2} q^{(n-2)-(r-2)} \right\} + np \\
 &= n(n-1)p^2 \times \sum_{k=0}^{n-2} \{ {}_{n-2}C_k p^k q^{n-2-k} \} + np \quad \leftarrow k=r-2 \\
 &= n(n-1)p^2 (p+q)^{n-2} + np \\
 &= n^2 p^2 - np^2 + np
 \end{aligned}$$

- 평균 = np
- 분산 = $npq = np(1-p)$
- 표준편차 = $\sqrt{npq}$

$$P(X=r) = {}_nC_r p^r q^{n-r} \quad (\text{단, } p+q=1, r=0, 1, 2, \dots, n)$$

- $\text{Var}(X) = E(X - \mu_X)^2 = E(X^2) - [E(X)]^2$

$$= n^2 p^2 - np^2 + np - (np)^2$$

$$= np(1-p)$$

$$= npq$$
- $\sigma(X) = \sqrt{V(X)} = \sqrt{npq}$

Discrete probability distribution

2. 이항 분포 (binomial distribution)


- 평균 = np
- 분산 = $npq = np(1-p)$
- 표준편차 = $\sqrt{npq}$

- 확률변수 X 가 : $X \sim B(n, p)$
- 이항분포를 따르는 경우 ($q=1-p$)
- 사건이 일어날 확률 : p , 일어나지 않을 확률 : q
- N 번의 독립시행 중 특정사건이 r 번 일어날 확률

$$P(X=r) = {}_nC_r p^r q^{n-r} \quad (\text{단, } p+q=1, r=0, 1, 2, \dots, n)$$


$$\begin{aligned} r \times {}_nC_r &= r \times \frac{n!}{(n-r)! \times r!} \\ &= n \times \frac{(n-1)!}{(n-r)! \times (r-1)!} \\ &= n \times {}_{n-1}C_{r-1} \end{aligned}$$

* Francis Galton



Francis Galton

<https://ko.wikipedia.org/>



베루누이 시행 → 정규분포(Normal Distribution)

<https://www.youtube.com/watch?v=AwEaHCjgeXk&t=50s>

Discrete probability distribution

3. 기하분포(geometric distribution)

- 베르누이 시행에서 첫번째 성공할 때까지의 시행 횟수(x)의 분포를 말한다.
- 성공확률 p 인 베르누이 시행에 대해, k 번 시행 후 첫 번째 성공을 얻을 확률

$n-1$ 번 실패하고 n 번째 성공할 확률

기하확률질량함수의 모든 합은 1

$$P\{X = n\} = (1 - p)^{n-1}p \quad n = 1, 2, \dots$$

기하 분포의 기대값과 분산 (증명 : 다음 page)

$$E[X] = \frac{1}{p}$$

$$\text{Var}(X) = \frac{q+1}{p^2} - \frac{1}{p^2} = \frac{q}{p^2} = \frac{1-p}{p^2}$$

예시) 주사위를 던져서 6 눈이 4번째 시행까지는 안 나오고 5번째 나올 확률?

$$\rightarrow \left(\frac{5}{6}\right)^4 \times \frac{1}{6} = 0.08037$$

Discrete probability distribution

3. 기하분포(geometric distribution)

* 기하 분포의 기대값(평균)과 분산 (증명)

평균

$$E(X) = \sum x \times p(x) = \lim_{n \rightarrow \infty} \sum_{x=1}^n x \times (1-p)^{x-1} \times p$$

$$P\{X = n\} = (1-p)^{n-1} p \quad n = 1, 2, \dots$$

$$E(X) = \lim_{n \rightarrow \infty} \sum_{x=1}^n p \{1 + 2 \times (1-p) + 3 \times (1-p)^2 + \dots + (n-1) \times (1-p)^{n-2} + n \times (1-p)^{n-1}\}$$

(1-p) 양변에 곱해주고

$$(1-p) \times E(X) = \lim_{n \rightarrow \infty} \sum_{x=1}^n p \{(1-p) + (1-p)^2 + 2 \times (1-p)^2 + 3 \times (1-p)^3 + \dots + (n-1) \times (1-p)^{n-1} + n \times (1-p)^n\}$$

위 두 식의 빼면

$$p \times E(X) = \lim_{n \rightarrow \infty} p \{1 + (1-p) + (1-p)^2 + (1-p)^3 + \dots + (1-p)^{n-1} + n(1-p)^n\}$$

양변 p 약분, 등비수열 합을 계산

두 식을 분리하여 표시

$$E(X) = \lim_{n \rightarrow \infty} \left\{ \frac{1 - (1-p)^n}{1 - (1-p)} + n(1-p)^n \right\}$$

$$E(X) = \lim_{n \rightarrow \infty} \left\{ \frac{1 - (1-p)^n}{1 - (1-p)} \right\} + \lim_{n \rightarrow \infty} \{n(1-p)^n\}$$

첫번째 항은 $\frac{1}{p}$ 로 수렴
오른쪽 항은 0에 수렴

$$E(X) = \frac{1}{p}$$

→ 어떤 확률변수 x가 기하분포를 따르고 성공확률이 p일때, 이 확률변수 x의 평균은 $\frac{1}{p}$ 이다.


분산

$$V(X) = E(X^2) - \{E(X)\}^2 = \frac{1}{p^2} - \frac{1}{p} = \frac{1-p}{p^2}$$

Discrete probability distribution

3. 기하분포(geometric distribution)

기하 분포의 기대값(평균)과 분산 (증명)



기대값

$$E(X) = \sum_{x=1}^{\infty} x(1-p)^{x-1}p$$

기하분포의 전체 확률 값이 1

$$\sum_{x=1}^{\infty} (1-p)^{x-1}p = 1 \implies \sum_{x=1}^{\infty} (1-p)^x = \frac{1-p}{p}$$

$$\begin{aligned} \frac{d}{dp} \sum_{x=1}^{\infty} (1-p)^x &= \sum_{x=1}^{\infty} \frac{d}{dp} (1-p)^x = \sum_{x=1}^{\infty} x(1-p)^{x-1} \cdot (-1) \\ &= -\frac{1}{p^2} = \frac{d}{dp} \frac{1-p}{p} \\ \therefore \sum_{x=1}^{\infty} x(1-p)^{x-1} &= \frac{1}{p^2} \end{aligned}$$

$$E(X) = \sum_{x=1}^{\infty} x(1-p)^{x-1}p = \frac{1}{p^2} \cdot p = \frac{1}{p}$$

Discrete probability distribution

4. 음이항분포(Negative Binomial Distribution)

- 음이항분포는 기하분포를 일반화시킨 것
- 기하분포는 첫번째 성공까지를 보는 분포인데 반하여,
- 음이항분포는 r번째 성공까지로 일반화 확장시킨 것
- → 확률변수 X를 r번째 성공을 얻을 때 까지 걸리는 시행횟수라면 X는 음이항확률변수이고 음이항확률분포
- 베르누이시행에서 r번째 성공까지 시도한 횟수 X의 분포
- 베르누이시행에서 r번째 성공까지 실패한 횟수 $Y=X-r$ 의 분포

$$f_X(x) = \binom{x-1}{r-1} p^r (1-p)^{x-r}, \quad x = r, r+1, \dots$$

음이항분포는 이항분포와 반대 개념 ?

- 전체 시행 횟수 n , 성공횟수 r
 - $X \sim NB(r, p)$, $Y \sim B(n, p)$ 이라 할때, 실제로 확률변수 X와 Y는 관계
 - 음이항 분포 : 시행 횟수 n 이 확률변수이고 성공 횟수 r 이 고정
 - 이항분포 : 시행 횟수 n 이 고정되어 있고 성공 횟수 r 이 확률변수
- 둘의 기준점이 다르다

$$P(X \leq n) = P(Y \geq r)$$

Discrete probability distribution

4. 음이항분포(Negative Binomial Distribution)

$$f_X(x) = \binom{x-1}{r-1} p^r (1-p)^{x-r}, \quad x = r, r+1, \dots$$

음이항분포 기대값과 분산

$$X_1, \dots, X_r \stackrel{iid}{\sim} GEO(p) \implies X = X_1 + \dots + X_r \sim NB(r, p)$$

$$E(X) = E(X_1) + \dots + E(X_r) = r \cdot \frac{1}{p}$$

$$Var(X) = Var(X_1) + \dots + Var(X_r) = r \cdot \frac{1-p}{p^2}$$

▪ r 이 커질수록 평균과 분산은 커진다.

→ r 이 커질수록 성공횟수 x 가 높은 값에서 발생할 확률이 높아진다는 말

Discrete probability distribution

5. 포아송 분포 (Poisson distribution)

19세기 시메옹 드니 포아송이 1838년 저서 《민사 사건과 형사 사건 재판에서의 확률에 관한 연구 및 일반적인 확률 계산 법칙에 대한 서문》에서 최초 사용

한쪽으로 치우치는 이항분포

- 특정한 사건이 발생할 가능성이 매우 드문 경우의 확률분포
- 어떤 시간이나 공간과 같은 관심의 단위 속에서 사건이 발생할 확률을 다루는 확률분포
→ 각 시행이 일어날 확률이 랜덤하므로, 일정 시간동안 평균적으로 몇 번 발생했는지를 나타낸다
- 일정한 단위 시간, 단위 공간에 어떤 사건이 랜덤하게 발생하는 경우에 사용할 수 있는 이산형 확률분포
- → 일정 기간 동안에 확률이 낮은 특정 사건이 일어날 확률을 나타내기 위해 활용하는 것이 포아송 분포

(금융) 일반적으로 시간의 경과에 따른 증권가격의 급등의 유입률을 시뮬레이션하는데 사용

- 포아송분포는 베르누이 시행을 무한대로 시행한 경우로 나타내며, 아래와 같이 정의

$$P(X=x) = \lim_{n \rightarrow \infty} \binom{n}{x} p^x (1-p)^{n-x} = \frac{e^{-\lambda} \lambda^x}{x!}$$

- K : 발생 가능한 이벤트의 수
- → 0, 1, 2, ... 등의 정수값을 가진다.
- λ : 단위 시간이나 단위 공간에서 평균적으로 발생하는 이벤트의 수

포아송 분포를 적용하기 위해서는 세 가지 가정을 만족해야 한다.


- 1) 사건의 평균 발생횟수는 구간의 길이에만 영향을 받는다.
→ 단위 구간의 크기 대비 사건의 평균 발생 횟수의 비율은 일정하다.
- 2) 같은 사건이 거의 동시에 일어날 확률은 거의 0에 가깝다.
- 3) 한 구간에서 발생한 사건은 다른 구간에서 발생한 사건에 영향을 주지 않는다.(서로 독립)
→ 위의 3가지 성질을 만족하면서 일어나면 이 사건은 포아송 확률과정 을 따른다고 말하며, 포아송 확률과정을 따르는 사건이 단위 구간에서 발생하는 횟수는 포아송 분포를 따르게 된다.

Discrete probability distribution

5. 포아송 분포 (Poisson distribution)

포아송 분포 특징

- 평균(기대값)과 분산은 동일하다.(λ) (다음 면 증명 참조)
- λ (lambda) : 일정한 단위 시간 / 단위 공간에서 랜덤하게 발생하는 사건의 평균 횟수를 의미
- λ 가 커지면 평균이 커지므로 그래프가 우측으로 이동하고, 분산이 커지므로 좌우가 퍼짐.



이항 분포와의 관계

$$X \sim B(n, p) \longrightarrow X \sim \text{Pois}(np)$$

- 포아송분포는 이항분포의 특수한 형태
- 이항분포를 따르는 확률변수 X 에서, n 이 대단히 크고 p 가 대단히 작을 경우, 이 확률변수 X 는 $\lambda=np$ 인 포아송 분포로 근사할 수 있다.

Discrete probability distribution

5. 포아송 분포 (Poisson distribution)

포아송 분포 특징

- 평균(기대값)과 분산은 동일하다.(λ)

평균(기대값)

$$p(x; \lambda) = \frac{e^{-\lambda} \cdot \lambda^x}{x!}; x = 0, 1, 2, \dots$$

$$\begin{aligned} E(X) &= \sum_{x=0}^{\infty} x \cdot p(x; \lambda) \\ &= \sum_{x=0}^{\infty} x \cdot \frac{e^{-\lambda} \lambda^x}{x!} \\ &= \sum_{x=0}^{\infty} \frac{e^{-\lambda} \cdot \lambda \cdot \lambda^{x-1}}{(x-1)!} \\ &= \lambda e^{-\lambda} \sum_{x=0}^{\infty} \frac{\lambda^{x-1}}{(x-1)!} \\ &= \lambda e^{-\lambda} \left[1 + \lambda + \frac{\lambda^2}{2!} + \dots \right] \\ &= \lambda e^{-\lambda} \cdot e^{\lambda} \\ &= \lambda \end{aligned}$$

분산

$$V(X) = E(X^2) - (E(X))^2$$

$$E(X^2) = E[X(X-1)] + E(X)$$

$$\begin{aligned} E[X(X-1)] &= \sum_{x=0}^{\infty} x(x-1) p(x; \lambda) \\ &= \sum_{x=0}^{\infty} x(x-1) \cdot \frac{e^{-\lambda} \cdot \lambda^x}{x!} \\ &= \sum_{x=2}^{\infty} \frac{e^{-\lambda} \cdot \lambda^2 \cdot \lambda^{x-2}}{(x-2)!} \\ &= \lambda^2 e^{-\lambda} \sum_{x=2}^{\infty} \frac{\lambda^{x-2}}{(x-2)!} \\ &= \lambda^2 e^{-\lambda} \left[1 + \lambda + \frac{\lambda^2}{2!} + \dots \right] \\ &= \lambda^2 e^{-\lambda} \cdot e^{\lambda} \\ &= \lambda^2 \\ E(X^2) &= E[X(X-1)] + E(X) \\ &= \lambda^2 + \lambda \end{aligned}$$

$$\begin{aligned} V(X) &= E(X^2) - (E(X))^2 \\ &= (\lambda^2 + \lambda) - \lambda^2 \\ &= \lambda \end{aligned}$$

Discrete probability distribution

5. 포아송 분포 (Poisson distribution)

포아송 분포 응용

•자연과학 및 사회과학

: 생물학적 현상, 교통 흐름, 보험 사고 발생 등의 모델링에 사용

•공학

: 통신 네트워크에서의 데이터 패킷 도착 등의 현상을 분석하는 데 활용

•경제학

: 특정 시간 동안 특정 상품의 판매량 예측 등에 적용될 수 있다.

예시)

- 'A 마을' 에서 일어나는 범죄의 수가 몇 건 이상일 확률
- 어떤 콜센터가 '하루 종일' 잘못 걸린 전화를 몇 건 이상 받을 확률
- 생산된 제품에서 불량품 개수
- 10:00~11:00 시간에 은행창구에 도착한 고객의 수
- 하루에 걸려오는 핸드폰 전화건수
- 회계장부 한 페이지당 오자의 수

Discrete probability distribution

6. 초기하분포(Hypergeometric distribution)

- 시행마다 발생하는 결과가 이항분포처럼 두가지 경우만 있으나 유한모집단에서 **비복원추출**되므로 베르누이 시행조건이 만족되지 않는 경우 적용되는 확률분포 (이항분포 : 복원추출)
- **비복원추출에서 N개의 모집단 중 n개를 추출할 때, k번의 성공을 할 확률에 대한 분포**
- 초기하분포의 확률변수는 위와 같은 조건 하에서 성공할 횟수
- 초기하분포는 모집단이 충분히 크기만 하다면 이항분포에 근사한다.

(사례)

- 평균과 분산은 공주머니에 담긴 공의 수(모집단)를 N이라고 하고,
- 꺼낼 공의 수(표본)를 n이라고 하고, 올바른 색상의 공의 수를 m이라고 하자.
- 성공확률은 당연히 올바른 색상 공의 수에 대한 전체 공의 수($p = m/N$)이고,
- 평균은 표본의 수에 성공확률을 곱하면 되며(np)
- 분산은 평균에다 실패확률을 곱한 뒤($np(1 - p)$) 여기에 추가로 $(N - n)/(N - 1)$ 을 곱해서 보정해 주면 된다. (다음 면 참조)

(사례)

로또 당첨 확률로, 45개의 공 중에서 6개의 공을 비복원 추출하는 복권

Discrete probability distribution

6. 초기하분포(Hypergeometric distribution)

초기하분포 확률질량함수

확률변수 X 를 성공횟수라고 할 때 확률질량함수

$$X \sim \text{hypergeo}(N, m, n)$$

$$P(X=x) = \frac{{}_m C_x \cdot {}_{N-m} C_{n-x}}{{}_N C_n}$$

- N : 전체 모집단의 크기
- m : 원하는 개체의 크기
- N : 총 시행횟수
- 분모 : 전체 N 에서 총 n 번을 비복원추출하는 경우의 수
- 분자: 원하는 개체의 크기인 m 에서 성공횟수 x 만큼 추출하는 경우의 수와 전체 모집단에서 원하지 않는 개체 $N-m$ 개에서 총 시행횟수 중 남은 $n-x$ 를 추출할 경우의 수의 곱

초기하분포의 평균과 분산

초기하분포에서 만약 모집단의 크기인 $N(=A+B)$ 이 무한대로 커진다면

$$X \sim \text{hypergeo}(A+B, A, n)$$

$$E(X) = \frac{nA}{A+B}, \text{Var}(X) = \frac{nAB}{(A+B)^2} \cdot \left(\frac{nA+B-n}{A+B-1} \right)$$

$$E(X) = \frac{nA}{A+B}$$

$$p = \frac{A}{A+B}$$

$$E(X) = np$$

$$\text{Var}(X) = \frac{nAB}{(A+B)^2} \cdot \left(\frac{nA+B-n}{A+B-1} \right)$$

$$p = \frac{A}{A+B}, A+B = N$$

$$\text{Var}(X) = np(1-p) \frac{N-n}{N-1}$$

$$\text{if } N \rightarrow \infty, \frac{N-n}{N-1} \rightarrow 1, \text{Var}(X) = np(1-p)$$

N 이 무한대로 발산하면 초기하분포의 확률질량함수는 이항분포의 확률질량함수로 근사

* Uniform distribution

균등분포(uniform distribution)

- 정의된 범위 내의 모든 값이 동일한 확률로 발생하는 특성을 가진다.
- 균등분포는 연속적인 경우와 이산적인 경우 두 가지 형태가 있다.

(1) 연속 균등분포 (continuous uniform distribution)

연속 균등분포는 주어진 구간 $[a, b]$ 내에서 모든 값이 발생할 확률이 동일하게 분포하는 경우

연속형 균일분포의 확률밀도함수(PDF)

$$X \sim \text{Uniform}(a, b)$$

$$f_X(x) = \frac{1}{b-a}, \quad a < x < b$$

a 와 b 는 각각 분포의 최소값과 최대값을 나타낸다.

기대값(평균): $E(X) = \frac{a+b}{2}$

분산: $Var(X) = \frac{(b-a)^2}{12}$

$$E(X) = \int_a^b \frac{1}{b-a} x \, dx$$

$$= \frac{1}{b-a} \cdot \frac{1}{2} x^2 \Big|_a^b = \frac{b+a}{2}$$

$$E(X^2) = \int_a^b \frac{1}{b-a} x^2 \, dx$$

$$= \frac{1}{b-a} \cdot \frac{1}{3} x^3 \Big|_a^b = \frac{a^2 + b^2 + ab}{3}$$

$$Var(X) = E(X^2) - E(X)^2 = \frac{(b-a)^2}{12}$$

* Uniform distribution

균등분포(uniform distribution)

(2) 이산균등분포 (Discrete Uniform Distribution)

이산 균등분포는 구간 내의 모든 이산값이 동일한 확률로 발생한다.

예시)

주사위를 던지는 경우 1부터 6까지의 숫자가 나올 확률이 모두 동일하다면 이것은 이산 균등분포의 예이다.

n 개의 균일하게 분포된 값이 있다면, 각 값이 발생할 확률은 $\frac{1}{n}$

균등분포는 자연 및 공학과학에서 다양한 응용을 가지며, 특히 시뮬레이션과 모델링에서 중요한 역할을 한다. 이 분포는 복잡한 확률 분포를 모델링하거나 샘플링할 때 기초가 되는 경우가 많다.

예시)

몬테 카를로 방법에서 난수를 생성할 때 균등분포를 사용하여 시작 값들을 생성한다.

이런 특성 때문에 균등분포는 확률론 및 통계학에서 기본적인면서도 중요한 분포 중 하나이다.

1부터 N까지 제곱의 덧셈

$$X \sim \text{unif}\{1, N\}$$

$$E[X] = \sum_{x=1}^N x f_X(x) = \frac{1}{N} \sum_{x=1}^N x = \frac{N+1}{2}$$


$$\sum_{i=1}^n i^2 = \frac{n(n+1)(2n+1)}{6}$$

$$\begin{aligned} E[X^2] &= \sum_{x=1}^N x^2 f_X(x) \\ &= \frac{1}{N} \sum_{x=1}^N x^2 \\ &= \frac{(N+1)(2N+1)}{6} \end{aligned}$$

$$\begin{aligned} \text{Var}(X) &= E[X^2] - (E[X])^2 \\ &= \frac{(N+1)(2N+1)}{6} - \left(\frac{N+1}{2}\right)^2 \\ &= \frac{(N+1)(N-1)}{12} \end{aligned}$$

* Summary

확률분포간 관계



*



Francis Bacon, 1st Viscount of Saint Alban, 1561~1626)

경험론(empiricism)


철학에서 **감각의 경험을** 통해 얻은 증거들로부터 비롯된 지식을 강조하는 이론



John Locke(1632~ 1704)

잉글랜드


왕국의 철학자·정치사상가



Francis Galton (1822~1911)

- 찰스 다윈

https://ko.wikipedia.org/wiki/%ED%94%84%EB%9E%9C%EC%8B%9C%EC%8A%A4_%EA%B3%A8%ED%84%B4



Sir Ronald Aylmer Fisher, Fisher (1890~1962)

통계학 기초 정립

-F분포, ANOVA, 귀무가설

https://ko.wikipedia.org/wiki/%EB%A1%9C%EB%84%90%EB%93%9C_%ED%94%BC%EC%85%94

Karl Pearson (1857~1936)

현대 수리통계학의 창시자, 피어슨상관계수, 카이제곱 검정

The Grammar of Science

Pearson then offered to have his staff at the Galton Laboratories

https://ko.wikipedia.org/wiki/%EC%B9%BC_%ED%94%BC%EC%96%B4%EC%8A%A8

*

통계학 가정

1. Data에 대한 가정
2. Model에 대한 가정

과학의 통계학으로 필요 충분 조건

1. 질 좋은 Data
2. 모델의 적절성
 - 자료구조 이해
 - 현실을 제대로 반영한 모형 사용
 - 결론의 정확성 향상
 - → 통계학적 결론은 과학적 근거

공학으로써의 통계학(인간중심)

- Machine learning (기계중심)과의 경쟁
- M.L 에서 data의 편견문제 vs 통계학의 대표성, 측정문제와 연관
- Data 편견을 보정할 때 인간의 개입문제 (통계학적 접근법 사용)

Statistical Inferences

1. 표본분포 이해


추정 :점추정, 구간추정

2. 표본평균의 확률분포

3. 추정

모집단 평균 추정

* Review



표본분포(sampling distribution)의 개념

- 관심의 대상이 되는 전체를 모집단(population), 조사 및 측정되는 모집단의 일부를 표본(sample)
- 표본으로부터 도출되는 표본통계량은 표본을 어떻게 구성하는가에 따라 다양하게 나타날 수 있다.
- 표본통계량은 결과를 예측할 수 없으므로 확률변수가 되며 표본통계량의 확률분포를 표본분포(sampling distribution)라고 정의
 - 표본평균의 분포, 표본비율의 분포, 표본분산의 분포 등이 대표적
- 모수(parameter): 알고 싶은 모집단의 특성 값
- 통계량(statistic): 표본으로부터 모수를 추정하기 위한 표본의 함수
- **검정 통계량 (test Statistic): 귀무가설이 참이라는 가정에서 얻어진 통계량**
- 대수의 법칙: 표본의 수가 커지면 표본평균은 모평균에 접근한다. 표본의 수가 커지면 표본비율은 모집단의 비율에 접근한다.

Statistical Inferences

통계적 추론이란?

그 모집단으로부터의 표본에 근거하여 모집단에 대한 정보를 알아내는 과정
→ 추정(estimation)과 가설검정 (Hypothesis Test) 으로 구분

추정(Estimation)

- 표본으로부터 미지의 모수를 추측하는 것 → 표본의 통계량으로부터 모수의 특성을 추측하는 것
- 점추정과 구간추정
- **추정량** : 모수를 추정하기 위한 표본의 함수인 통계량
- **추정값** : 추정량에 관측값을 대입하여 얻은 추정량의 값
- **추정량의 분포** : 추정량은 표본추출결과에 따라 변함 ~ 표본 분포(sampling distribution)

가설검정 (Hypothesis Test)

'모수가 어떠할 것이다'라는 가설을 세우고 그 가정이 맞는지에 대한 확인 과정

Statistical Inference : Estimation

추정방법 구분

Parameter(θ)에 대한 구간 추정 기본 형식

1. 점추정 (Point Estimation)

- 모수가 특정한 값일 것이라고 추정하는 것 $\rightarrow \hat{\beta}_0, \hat{\beta}_1$
- 표본의 정보로부터 모집단의 모수 (β_0, β_1)를 하나의 값으로 추정

2. 구간추정 (Interval Estimation)

- 점추정을 보완하기 위해 표본에서 얻어지는 정보를 이용하여 모수가 특정구간에 있을 것이라고 추정하는 것
- 항상 추정량의 분포에 대한 전제가 주어져야 하고, 구해진 구간 안에 모수가 있을 가능성의 크기(신뢰 수준)가 주어져야 함 $\rightarrow$ 구간으로 추정하여 보다 유연한 정보를 제공하고자 할 때.

$\rightarrow \hat{\theta} - (\text{상수값})(\hat{\theta} \text{의 표준편차}) \leq \theta \leq \hat{\theta} + (\text{상수값})(\hat{\theta} \text{의 표준편차})$

$\hat{\theta}$: Parameter(θ)에 점추정치


신뢰구간(confidence interval)

- $\rightarrow$ 모수를 포함할 것으로 추정한 구간
- $\rightarrow$ 상한치와 하한치로 범위가 주어진다. $\rightarrow$ 차이 값이 거리(d)가 된다.

신뢰수준(level of confidence) ,

- $\rightarrow$ 신뢰구간이 모수를 포함할 확률
- $\rightarrow$ 신뢰수준 = $(1 - \alpha)$, 유의수준(α) : 0.05, 0.01 ...

유용한 추정범위(신뢰구간)
그 추정범위를 얼마나 믿을 수
있는지?(신뢰수준)



$$100(1 - \alpha)\% = P\left(-z_{\frac{\alpha}{2}} \leq Z \leq z_{\frac{\alpha}{2}}\right)$$


Statistical Inference : Estimation

구간 추정(interval estimation)

유의수준 (level of significance, α)

- 귀무가설(H_0)이 사실임에도 불구하고 귀무가설(H_0)을 기각하는 **제1종 오류를 범할 최대 확률을 의미**
- (즉, 유의수준 5%의 의미는 "의사결정시 위험성을 5%까지만 감수하겠다." 라는 의미로 해석이 가능)
- 가설 검정에서는 **유의수준을 미리 결정하고** (5%를 가장 많이 사용) 결과의 **p값과 비교**하여 p값이 결정한 유의수준보다 작다면 귀무가설을 기각하게 된다. (대립가설 채택)
- 유의수준은 절대적인 값이 아니므로 상황에 맞추어 탄력적으로 적용할 수 있다.
- 95% 신뢰도 (1-0.95) 0.05가 유의수준

(a) $\alpha=0.05$ 일 때



통계적 유의성

: 모집단에 대한 가설이 지니는 통계적 의미

“통계적으로 유의하다” : 결과가 우연히 발생한 것이라고 생각하지 않을 정도로 의미가 있다.!!!

Statistical Inference : Estimation

모집단 평균 추정 (점추정)

- 1) 모집단의 평균 (μ) : 점추정
- 2) 모집단의 평균 : 신뢰구간 추정

1) 모집단 평균 μ : 점추정 (point estimation)

- 모집단의 관심 있는 정보 : 확률분포의 중심인 모평균 μ
- 표본평균, 표본평균의 불편성, 표본평균의 분산 :

→ 점추정은 선정된 추정량을 추출된 표본자료에 대입하여 얻은 단일 추정치에 의하여 모수를 추정하는 방법

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$E(\bar{X}) = \mu$$

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$$

- 분산은 효율성을 나타낸다.
- n 이 커질수록 효율성이 증대된다. 즉, n 이 커질수록 밀집된 결과를 얻는다.
- 대수의 법칙 : n 이 무한대로 커지면 표본평균은 모평균으로 수렴한다.
- 중심극한정리 : n 이 무한대로 커지면서, (모집단이 어떤 분포를 따르는지 상관없다)

Statistical Inference : Estimation

구간 추정(interval estimation) '표본평균'의 확률분포

1. 정규분포를 따르는 경우

1) 모집단이 정규분포이며 모분산(모표준편차)을 알려져 있는 경우

표본평균은 모평균(μ)과 동일하며 표준편차는 ($\frac{\sigma}{\sqrt{n}}$) 인 정규분포를 따른다.

$$\bar{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

$$Z = \frac{\bar{X} - \mu_0}{\frac{\sigma}{\sqrt{n}}}$$

2) 중심극한정리가 적용 가능한 경우 : 대표본의 경우

- 대표본인 경우 표본평균의 분포는 모집단의 분포 및 모분산이 알려져 있는 것과 상관없이 정규분포를 따른다는 정리
- 대표본은 일반적으로 30개 이상의 표본으로 정의

**표본평균의 기댓값과 분산

- $E(\bar{X}) = \mu$
- $\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$
- 표본평균 표준편차(표준오차, S.E) = $\frac{\sigma}{\sqrt{n}}$, $\rightarrow \frac{s}{\sqrt{n}}$ (모분산을 모르는 경우)

Statistical Inference : Estimation

구간 추정(interval estimation) '표본평균'의 확률분포

1. t분포를 따르는 경우

1) 모분산이 알려져 있지 않고 소표본이며 정규모집단인 경우

- 모분산이 알려져 있지 않은 경우 표본의 크기가 크지 않다면 ($n < 30$) 표본평균의 확률분포는 자유도(df)가 $(n - 1)$ 인 t분포를 따르게 된다.
- t분포를 사용하는 경우에는 반드시 모집단의 확률분포가 정규분포이어야 한다.
- t분포를 사용하여 신뢰구간을 추정할 때에도 점추정량은 표본평균을 사용한다.

2) 모분산이 알려져 있지 않고 대표본의 경우

- 표본이 대표본인 경우 표본평균의 확률분포는 모집단의 분포와 상관없이 정규분포를 따르게 되지만
- 모분산이 알려지지 않은 경우 t분포를 이용해서 모평균의 구간 추정을 수행하기도 한다.

$$\left[\bar{X} - t_{n-1, \alpha/2} \frac{s}{\sqrt{n}}, \quad \bar{X} + t_{n-1, \alpha/2} \frac{s}{\sqrt{n}} \right]$$

$t_{n-1, \alpha/2}$: t분포의 오른쪽 꼬리 $\alpha/2$ 에 해당하는 면적에 대한 자유도 $n - 1$ 을 가지는 t 값

Statistical Inference : Estimation

구간 추정(interval estimation)

모평균 구간 추정

1) 모평균의 구간추정을 위한 요소

신뢰구간 : 점추정량 $\pm$ 신뢰계수 $\times$ 표준오차

- 1) 점추정량(point estimator) : 모평균 추정에는 표본평균 ($\bar{X}$) 사용
 2) 표준오차(standard error) : 표본평균의 표준편차
 모분산이 알려진 경우: $S.E = \frac{\sigma}{\sqrt{n}}$, 모분산이 알려지지 않은 경우: $S.E = \frac{s}{\sqrt{n}}$
 3) 표준정규분포의 신뢰계수(reliability factor)
 신뢰계수(95%신뢰수준:1.96, 99%:2.58) : t 분포표에서 양측검점(단측) 유의수준과 자유도와 만나는 값
 유의수준 (α)에 따른 신뢰계수 값
- 0.05 (신뢰수준 95%) = ± 1.96
 - 0.01 (신뢰수준 99%) = ± 2.575 (약 2.58)
 - 0.10 (신뢰수준 90%) = ± 1.645

Confidence Interval	Z
80%	1.282
85%	1.440
90%	1.645
95%	1.960
99%	2.576
99.5%	2.807
99.9%	3.291

2) 모평균 추론위해 사용되는 분포

대표본 (n>30)	z분포 사용, t분포 사용 (모분산을 알려지지 않은 경우)		
소표본 (n<30)	정규모집단	모분산을 알려져 있는 경우	z분포 사용
		모분산을 알려지지 않은 경우	t분포 사용 (df = n-1)
	비정규 모집단	비모수검정 (신뢰가 낮음)	


Statistical Inference : Estimation

구간 추정(interval estimation)

모평균 신뢰구간

표본 n 인 표본평균 ($\bar{X}$) → 모평균(μ)에 대한 95% 신뢰구간

- $P(-1.96 \leq Z \leq 1.96) = 0.95 \rightarrow 95\%$
- $-1.96 \leq \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \leq 1.96 = 0.95$
- $\bar{X} - 1.96 \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + 1.96 \frac{\sigma}{\sqrt{n}}$

신뢰구간 : 점추정량 $\pm$ 신뢰계수 $\times$ 표준오차

표준정규분포표 참조할것!

모평균(μ) 99% 신뢰구간

$$\bar{X} - 2.58 \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + 2.58 \frac{\sigma}{\sqrt{n}} \rightarrow 99\%$$

$$\bar{X} - z \left(\frac{\sigma}{\sqrt{n}} \right) \leq \mu \leq \bar{X} + z \left(\frac{\sigma}{\sqrt{n}} \right)$$

$$\bar{X} - z_{\frac{\alpha}{2}} \left(\frac{\sigma}{\sqrt{n}} \right) \leq \mu \leq \bar{X} + z_{\frac{\alpha}{2}} \left(\frac{\sigma}{\sqrt{n}} \right)$$

- 정규분포 $N(\mu, \sigma^2)$ 인 모집단에서 n 개의 표본을 임의 추출한 표본평균 ($\bar{X}$)인 경우모표준편차(σ)를 모르는 경우 → 표본표준편차 s 이용

- 신뢰수준 95%의 신뢰구간 : $P\left(\bar{X} - 1.96 \frac{s}{\sqrt{n}} \leq \mu \leq \bar{X} + 1.96 \frac{s}{\sqrt{n}}\right)$
- 신뢰수준 99%의 신뢰구간 : $P\left(\bar{X} - 2.58 \frac{s}{\sqrt{n}} \leq \mu \leq \bar{X} + 2.58 \frac{s}{\sqrt{n}}\right)$

Statistical Inference : Estimation

구간 추정(interval estimation)

모평균 신뢰구간

- **신뢰수준 95%**의 신뢰구간 : $P\left(\bar{X} - 1.96 \frac{s}{\sqrt{n}} \leq \mu \leq \bar{X} + 1.96 \frac{s}{\sqrt{n}}\right)$
- **신뢰수준 99%**의 신뢰구간 : $P\left(\bar{X} - 2.58 \frac{s}{\sqrt{n}} \leq \mu \leq \bar{X} + 2.58 \frac{s}{\sqrt{n}}\right)$

(예시)

대학생 64명의 평균 키가 175cm, 표준편차 20cm인 경우

➔ 모표준편차는 모르고 관측된 샘플의 표준편차를 사용 ($n > 30$ 이상 관측개수)

- 신뢰수준 95% : $175 \pm 1.96 \times \frac{20}{\sqrt{64}}$ $175 \pm 1.96 \times 2.5 = 175 \pm 4.9 = 170.1 \sim 179.9$

- 모집단의 평균이 170.1~179.9cm의 신뢰할 수 있는 구간에 있을 것이라 추정

4.9 = 오차 한계

- **표본크기가 클수록 신뢰구간은 좁아진다.** → 표본이 클수록 보다 더 정확하게 모집단의 평균을 추정할 수 있다.
- **즉 신뢰구간이 좁을수록 모집단 평균 추정치가 정확해진다.**

<https://www.mathsisfun.com/data/confidence-interval-calculator.html>

Statistical Inference : Estimation

모집단 평균 추정 (구간추정)

- 1) 모집단의 평균 (μ) : 점추정
- 2) 모집단의 평균 : 신뢰구간 추정

모분산이 알려져 있지 않고 소표본이며 정규모집단인 경우

2) 모집단 평균 : 신뢰구간 추정

- 모표준편차를 알 수 없는 경우 → 구간 추정값은 t 분포에 기초
- 모표준편차를 대부분 모르므로 일반적으로 표본표준편차 S를 이용한다.
표본표준편차를 이용하면 → 모평균은 정규분포가 아닌 t-분포를 따르게 된다.
- t-분포를 따를 때, 모평균의 100(1- α)% 신뢰구간

$$S = \sqrt{\frac{\sum (X_i - \bar{X})^2}{n - 1}}$$

$$t\text{-value} = \frac{\bar{X} - \mu_0}{\frac{s}{\sqrt{n}}}$$

$$\begin{aligned} & \bullet - t_{n-1, \alpha/2} \frac{s}{\sqrt{n}} \leq t \leq t_{n-1, \alpha/2} \frac{s}{\sqrt{n}} \\ & \bullet - t_{n-1, \alpha/2} \frac{s}{\sqrt{n}} \leq \frac{\bar{X} - \mu_0}{\frac{s}{\sqrt{n}}} \leq t_{n-1, \alpha/2} \frac{s}{\sqrt{n}} \end{aligned}$$

$$P \left(\bar{X} - t_{n-1, \alpha/2} \frac{s}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{n-1, \alpha/2} \frac{s}{\sqrt{n}} \right) = (1 - \alpha)$$

$t_{n-1, \alpha/2}$: t분포의 오른쪽 꼬리 $\alpha/2$ 에 해당하는 면적에 대한 자유도 $n - 1$ 을 가지는 t 값

두 집단 평균차이 검정 통계량

$$t\text{-value} = \frac{\bar{X}_A - \bar{X}_B}{\frac{s}{\sqrt{n}}}$$

Statistical Inference : Estimation

모집단 평균 추정 (구간추정) 모분산이 알려져 있지 않고 소표본이며 정규모집단인 경우

(예제) 00대학교에서 5km 이내에 원룸주택 16개 표본을 조사해 보니 1개월 평균 월세가 50만원 이고, 표준편차가 10만원이었다.

00대학교에서 거리가 5km이내에 있는 원룸주택 모집단의 평균 월세에 대하여 95% 신뢰수준의 구간 추정값?
(단, 모집단은 정규분포임을 가정, 모표준편차는 모른다)

일방향(One-sided)	75% (0.25)	80% (0.2)	85% (0.15)	90% (0.1)	95% (0.05)	97.5% (0.025)
양방향(Two-sided)	50%	60%	70%	80%	90%	95%
1	1.000	1.376	1.963	3.078	6.314	12.71
2	0.816	1.080	1.386	1.886	2.920	4.303
3	0.765	0.978	1.250	1.638	2.353	3.182
4	0.741	0.941	1.190	1.533	2.132	2.776
5	0.727	0.920	1.156	1.476	2.015	2.571
6	0.718	0.906	1.134	1.440	1.943	2.447
7	0.711	0.896	1.119	1.415	1.895	2.365
8	0.706	0.889	1.108	1.397	1.860	2.306
9	0.703	0.883	1.100	1.383	1.833	2.262
10	0.700	0.879	1.093	1.372	1.812	2.228
11	0.697	0.876	1.088	1.363	1.796	2.201
12	0.695	0.873	1.083	1.356	1.782	2.179
13	0.694	0.870	1.079	1.350	1.771	2.160
14	0.692	0.868	1.076	1.345	1.761	2.145
15	0.691	0.866	1.074	1.341	1.753	2.131

95% 신뢰수준 $\alpha=0.05$ $\alpha/2 = .025$. 자유도 = $n-1 = 15$ 이다.

$$\bar{X} - t_{n-1, \alpha/2} \frac{s}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{n-1, \alpha/2} \frac{s}{\sqrt{n}} \text{ 에 대입하면}$$

$$500,000 \pm 2.131 \frac{100,000}{\sqrt{16}}$$


계산해보면

$$500,000 \pm 53,275$$

결국 00대학교 5km 이내 원룸주택 월세는

446,725원~553,275원 사이에 있을 확률 95% 신뢰한다.

모집단 평균 : 구간 추정 절차



Statistical Inference : Estimation

표본비율을 통한 모비율 추정

one sample 비율 검정

표본비율의 확률변수 : 경험적 연구결과 $np \geq 5, n(1-p) \geq 5$ 인 경우 정규분포에 근사한 것으로 알려 짐.
 → 표준정규분포로 전환하여 확률 계산

모집단에서 n 개의 표본을 뽑았을 때, 찬성자 수 X 는 이항분포 $B(n, p)$ 를 따른다.
 -만약, 모집단의 찬성비율 p , 반대비율 $(1-p)$, 중심극한정리에 의해 $\hat{p}$ 은 정규 근사가 가능하다. → $\hat{p}$ 은 베르누이 분포의 표본 평균이기 때문이다.

$$\hat{p} = \frac{X}{n}, \quad E(\hat{p}) = p$$

$$\hat{p} \sim N\left(p, \frac{p(1-p)}{n}\right)$$

- $\text{Var}(\hat{p}) = \frac{p(1-p)}{n} = \frac{pq}{n}$
- 표준오차(S.E) = $\sqrt{\frac{pq}{n}}$

표준정규분포로 변화과정

$$Z = \frac{\hat{p}-p}{\sqrt{\frac{pq}{n}}} \sim N(0, 1)$$

(예제)

경찰청은 B은행과 협조를 통해 교통사고에 대하여 긴급 서비스를 제공 하고 있다. B은행은 A통신사와 협조를 통해 무상단말기 지급 협조로 다른 통신사 고객 확보를 기대하는 상황이다. 현재 A통신사로 이동하려는 잠정고객은 40%일 것으로 추정된다. 다른 통신사 가입 중에서 B은행 고객인 100명을 대상으로 50명이상 A통신사로 이동할 확률은?

$$P(\hat{p} > 0.5) = P\left(Z > \frac{0.5-0.4}{\sqrt{\frac{0.4 \times 0.6}{100}}}\right) = P(Z > 2.04)$$

표준정규분포표를 활용하면

$P(Z < 2.04)$ 의 확률이 0.9793이므로 $P(Z > 2.04)$ 는 $(1-0.9793)$

0.0207, 50명이상 A통신사로 이동할 확률은 2.07%이다.

Statistical Inference : Estimation

표본비율을 통한 모비율 추정

표준정규분포로 변화과정

$$Z = \frac{\hat{p} - p}{\sqrt{\frac{pq}{n}}} \sim N(0, 1)$$

모비율 (P) 신뢰구간

$$\hat{p} - z_{\alpha/2} \sqrt{\frac{pq}{n}} \leq P \leq \hat{p} + z_{\alpha/2} \sqrt{\frac{pq}{n}}$$

(예제)

밤 늦은 시간에 강력범죄가 늘어 나고 있다. 늦은 시간 골목길에 귀가여성을 위해 귀가 도움서비스 실시하고 있다. 이용고객 중 100명 여성을 대상으로 이 서비스를 받을 것인가를 조사했더니 90명이 받기를 원하는 것(90% 동의)으로 조사되었다. 이용 여성 전체의 의견에 대하여 95% 신뢰구간을 구하면?

$$\text{모비율 (P) 95\% 신뢰구간} \rightarrow 0.9 - 1.96 \sqrt{\frac{(0.9)(0.1)}{100}} \leq P \leq 0.9 + 1.96 \sqrt{\frac{(0.9)(0.1)}{100}} = 0.9 - 0.0588 \leq P \leq 0.9 + 0.0588 = 0.8412 \leq P \leq 0.9588$$

전체 의견의 비율은 95% 신뢰수준에서 84.12% 와 95.88% 사이에 동의한다고 볼 수 있다.

모집단 분산 추정

표본분산 확률분포

카이제곱 분포

- 분포가 자유도에 따라 상이하며 오른쪽으로 꼬리가 갖는 비대칭 분포
- 카이제곱 분포의 확률변수는 항상 0 보다 크다.
- 자유도가 (n-1)인 카이제곱 분포와 표본분산과는 선형관계가 성립
- $\chi_{n-1}^2 = \frac{(n-1)}{\sigma^2} S^2$

모집단의 분산 추정

- 표본분산의 분포는 카이제곱 분포를 따른다.
- 모분산의 100(1- α)% 신뢰구간

$$\frac{(n-1)}{\sigma^2} S^2 \sim \chi_{n-1}^2$$

$$\left[\frac{(n-1)s^2}{\chi_{n-1,\alpha/2}^2}, \frac{(n-1)s^2}{\chi_{n-1,(1-\alpha)/2}^2} \right]$$

Statistical Inference : Estimation

바람직한 추정량? → 평균적으로 모수에 근접하고 그 밀집도가 높은 추정량

Point Estimation 특징

불편성

- 표본 추정량의 기댓값이 모수와 같아지는 것→ 이때의 추정량을 불편추정량(unbiased estimator)이라 한다.
- 추정량과 모수에 차이가 있다는 것을 **편의(biased)**가 있다고 한다.
- 추정량에 대한 기대값이 모수와 동일하게 나타나면, 이는 표본추출이 오류가 나타날 만한 영향이 없다는 불편성(unbiasedness)을 만족한다는 의미

효율성(Efficiency, 유효성)

- 두개 이상의 불편성의 추정량이 존재할때, 어느 추정량의 분포가 더 모수에 집중적으로 분포하게 되는지를 나타내는 성질 : 즉, 추정량의 분산 → **추정량의 분산(Variance)**이 **최소값**이어야 한다.
- 모수에 대한 추정량의 분산(분포)이 작을수록 추정량이 바람직하다는 의미이다.
- 이러한 조건은 추정량이 여러 개일 경우, 이들을 서로 비교하여 가장 유효한 추정량을 확인할 때 필요하다.

일치성 (Consistency)

표본의 크기 n 이 무한히 증가함에 따라 추정량이 모수에 가까워지는 것을 의미.

충족성

- 추정량이 모수에 대하여 가장 많은 정보를 제공할 때, 그 추정량에 충족성이 있다고 한다.
(표본이 모집단의 대표성을 가져야 한다.)

Statistical Inference : Hypothesis Test

1. 가설검정 개념

- 가설검정 개념 이해
- 신뢰수준, 유의수준(level of significance)
- 가설검정의 오류 (제1종 오류 , 제2종 오류)

2. 주요 모수에 대한 가설 검정

- 가설검정 개념
- 주요모수에 대한 가설검정
(모평균,모비율,모분산에 대한 가설 검정)
- Z-test
- T- test
- F- test

Statistical Inference : Hypothesis Test

1. 통계적 가설검정 (statistical hypothesis)이란?

- 통계학에서 표본을 통해서 모수를 추정하는 것을 추론이라고 함.
- '모수가 어떠할 것이다'라는 가설을 세우고 그 가정이 맞는지에 대한 확인 과정도 추론 → 가설검정이라고 한다.
- 가설검정은 일정 유의수준 하에서 주장이나 추측이 일정 신뢰구간에 포함될지의 여부를 판단하는 것
- 두 개의 가설 (귀무가설, 대립가설) 을 설정하고, 두 가설 중 어느 가설이 적합한지 파악하는 것

2. 가설 유형

- 귀무가설 (null hypothesis : H_0)** : 차이 또는 유의성이 없음을 나타내는 가설. 기존의 가설
(초능력은 없다, 피고인이 무죄이다)
- 대립가설 (alternative hypothesis : H_1)** : 관심이 있는 사건에 유의성이 있음을 나타내는 가설, 연구자가 밝히고자 하는 주장
(초능력이 있다, 피고인이 유죄이다)
- 가설을 세우고 가설을 입증하기 위한 데이터를 수집하고 가설검정에 적합한 도구인 검정통계량을 구한 후 귀무가설하의 검정통계량의 분포와 비교하여 유의수준을 고려하여 최종판단을 하게 된다.

3. 통계적 의사결정 원리

- 확실한 근거가 있기 전에는 대립가설을 선택하지 않고 귀무가설을 받아들인다.
- 대립가설 채택을 위해서는 귀무가설을 기각 (대립가설이 참이라는 확실한 근거가 있음) 할 수 있어야 한다.
→ 확률 값(p-value) < 유의수준 (통상 0.05) : 귀무가설을 기각하여 연구자의 주장인 대립가설을 채택 → 통계적 '유의성이 있다'고 표현한다.
→ 확률 값(p-value) > 유의수준 : 귀무가설을 기각시키지 못한다. 즉, 대립가설이 참이라는 확실한 근거는 없는 것이다.

Statistical Inference : Hypothesis Test

4. 제1종 오류와 제2종 오류

1. 통계적 오류(statistical error): 오차가 무작위적이며 예측할 수 없는 변동에 의해 생기는 오류

1) 제1종 오류(type I error) : 귀무가설이 참 인 경우인데 기각하여 오류를 범하는 확률, $\rightarrow \alpha$ error

$\rightarrow$ 유의수준(significant level) : 제1종 오류를 범할 최대 허용 확률을 의미 (0.05, 0.01) $\rightarrow$ 상수 값.

$\rightarrow$ 피의자가 무죄인데 유죄로 판단 (2종 오류 보다 더 큰 문제)

2) 제2종 오류(type II error) : 귀무가설이 참이 아닌데, 잘못하여 채택하는 오류, $\rightarrow$. β error .

$\rightarrow$ 피의자가 유죄인데 무죄로 판단

3) 검정력 (statistical power)

제2종 오류를 범할 최대 허용 확률 β 일때, 귀무가설이 참이 아닌 경우 이를 기각할 수 있는 확률을 말함.

$\rightarrow$ 검정력 : $1-\beta$ 로 표시

$\rightarrow$ 검정력이 95%라고 하면, 대립가설이 사실임에도 불구하고 귀무가설을 채택할 확률 (2종 오류, β error)의 확률은 5%이다.

$\rightarrow$ 검정력이 좋아지게 되면, 2종 오류(β error)를 범할 확률은 작아지게 된다.

2. 시스템적 오류(systematic error)

: 오차가 시스템 상의 잘못으로 인한 것


실제 통계 결정	귀무가설(H_0) 참	귀무가설(H_0) 거짓
귀무가설(H_0) 채택	옳은 결정	제2종 오류 (β)
귀무가설(H_0) 기각	제1종 오류 (α)	옳은 결정 (검정력 = $1 - \beta$)

1928년에 유니버시티 칼리지 런던에 근무하던 통계학자 에르지 네이만, 피어슨은 특정한 표본이 모집단으로부터 무작위로 골라졌는지를 판단할 수 있는가에 대한 판정의 문제를 논의

Statistical Inference : Hypothesis Test

4. 제1종 오류와 제2종 오류

제1종 오류와 제2종 오류 Trade-off



- 유의수준(α)
: α 를 이용한 검증 : H_0 가 참 임을 증명
- 검정력 ($1-\beta$)
: β 를 이용한 검증 : H_1 이 참 임을 증명

제1종 오류와 제2종 오류는 각각 귀무가설을 기각할 확률과 기각하지 못할 확률을 의미하므로 반대되는 상황에서 발생된다.

→ 제1종 오류와 2종 오류는 서로 상반되는 관계에 있다. → 만약 1종 오류를 감소시키면 2종 오류는 증가하게 된다.

→ 제1종 오류와 2종 오류를 동시에 감소시키거나 어느 한쪽의 오류를 고정한 상태에서 다른 한쪽의 오류를 감소시킬 수 있는 방법은 표본의 크기를 증가시키면 가능

→ 표본의 크기를 증가시킨다는 것은 더 정확한 의사결정이 가능하다는 의미이므로 통계적 의사결정의 오류는 감소되는 것

Statistical Inference : Hypothesis Test


5. 가설 설정(검정 방법)

양측검정

귀무가설을 기각하는 영역이 양쪽에 있는 검정으로 대립가설이 000가 아니다.

크거나 작다 인 경우 양측검정을 사용


- 귀무가설 (H_0) : 기존 알려진 사실과 동일하다. 두 집단간 차이가 없다(두 집단 평균차이 = 0)
- 대립가설 (H_1) : 기존 알려진 사실과 다르다. 두 집단간 차이가 있다(두 집단 평균차이 $\neq 0$)



단측검정


우측검정

- 귀무가설을 기각하는 영역이 오른쪽에 있는 검정
- 대립가설이 000 보다 크다 인 경우
- 귀무가설 (H_0) : 기존 알려진 사실과 동일하다.
- 대립가설 (H_1) : 기존 알려진 사실보다 **크다**.



좌측검정

- 귀무가설을 기각하는 영역이 왼쪽에 있는 검정
- 대립가설이 000 보다 작다 인 경우
- 귀무가설 (H_0) : 기존 알려진 사실과 동일하다.
- 대립가설 (H_1) : 기존 알려진 사실보다 **작다**.



유의수준 = 0.05 경우

양측검정이나, 단측검정이나 **95% 안에 두 집단 평균차이 값이 오면** 두 집단의 차이는 **우연히 발생한 것이므로**

→ 통계적으로는 두 집단간 평균 차이는 없다. = 평균차이는 통계적으로 유의하지 않다고 해석한다.

Statistical Inference : Hypothesis Test

6. 검정통계량/ 임계치/ 기각역, 채택역

1) 검정 통계량 (test Statistic)

- 통계적 가설을 검정하기 위한 기준으로 사용되는 통계량
- 귀무가설이 참이라는 가정에서 얻어진 통계량**
- 모평균에 대한 가설검정에서는 표본평균, 모비율의 경우에는 표본비율, 모분산의 경우 표본분산
- 통계량이므로 확률표본의 함수
- 귀무가설과 대립가설 중에서 하나의 가설을 선택하는데 사용하는 표본 통계량
- **계산된 검정통계량(computed statistic)**
표본정보를 이용하여 실제로 계산된 검정통계량

● 임계치 (critical value, threshold value)

- 주어진 유의수준에서 귀무가설의 채택과 기각여부를 결정 할 때 그 기준이 되는 값
- **표준정규분포표에서 자유도 (n-1)에 유의수준에 해당하는 값.**

→ **계산된 검정통계량과 임계치를 비교하여 귀무가설의 기각 여부 판단**

2) 기각역(rejection region)

확률분포에서 귀무가설을 기각되는 검정통계량의 값이 포함된 영역

- 검정통계량 절대값 > 임계치 : 기각역 → 귀무가설을 기각, 대립가설 채택
- 검정통계량 절대값 < 임계치 : 채택역 → 귀무가설을 채택 (기각 못함)
- 양측검정인 경우 : 기각역은 (유의수준=α) / 2, 만약 유의수준=0.05이면 0.025
- 단측검정인 경우 기각역은 유의수준과 같다. (기각역 면적(합)은 유의수준과 동일)**
- 기각역 또는 채택역은 유의수준을 어떻게 정하느냐에 따라 달라진다. (보통 0.05)

검정 통계량

$$t\text{-value} = \frac{\bar{X}_A - \bar{X}_B}{\frac{s}{\sqrt{n}}}$$



Statistical Inference : Hypothesis Test

7. p-value (probability-value , 유의확률)

P값(p-value) : 검정통계량(t-value)에 의해 구해지는 유의확률 (Significance Probability)

→ '확률'로 유의성을 점검할 수 있는 지표, 검정통계량이 귀무가설(H_0) 지지하는 정도 !!!

- 귀무가설이 참일 때, 검정통계량이 현재 가지고 있는 자료로 부터 계산한 검정통계량의 값보다

대립가설 H_1 방향으로 더 극단적으로 나올 확률값 p-값

→ 즉, 어떠한 sample data로부터 온 결과가 우연히 일어났을 확률을 의미 (0% ~ 100%)

→ P-value 가 매우 작을 값일 수록, 우연히 일어 났을 확률이 작으므로 귀무가설 H_0 을 기각할 수 있는 근거를 가지게 된다.

p-value 계산

- p-값을 계산하는 방법은 가설 검정의 종류와 사용하는 통계량에 따라 다양(t-검정, z-검정, 카이제곱 검정 등)
- t- value와 자유도(Degrees of Freedom_을 이용하여, 해당하는 p value를 T distribution table에서 찾을 수 있다.
- 그러나 우리에게 python
- 검정통계량 (t-value) 값에 해당하는 p- value도 하나의 값을 갖는다. t-value 커질수록 p-value 는 작아진다.

검정통계량 t-value → p-value , <https://www.graphpad.com/quickcalcs/pvalue1.cfm>

Statistical Inference : Hypothesis Test

7. p-value (probability-value , 유의확률)

(예시)

PBL – FBA O기 김00은 수업시간 지각이 빈번하다. (공식적으로 10분이상이면 지각처리)

- 귀무가설 : 수업시간 평균 지각이 10분 이상이다. $\mu \geq 10$ 분
- 대립가설 : 수업시간 평균 지각이 10분 이상이 아니다. $\mu < 10$ 분

김 00은 최근 5일간 지각한 평균시간이 5분이라서 위 주장이 아니라고 한다. 즉 5분이하라는 항변이다..

과거 20일을 살펴보니, 조사한 지각시간 샘플데이터는 다음과 같다. (평균 11분) 유의수준=0.05

-5, -1, 3, 4, 6, 7, 8, 12, 13, 15, 18, 20, 25, 30, 40, 3, 6, 6, 6, 4,

전체 20개 일자 중에서 5분이하로 지각 건수를 살펴보니

$\frac{6}{20} = 0.3$ **p-value 가 0.3이다**, 30% 정도가 5분이하로 지각할 확률이다.

p-value 0.3이라는 값이 유의수준 0.05보다 크기 때문에 평균이 10분 이상이라는 귀무가설을 기각할 수 없다.
→ 우연히 최근 5일 평균이 10분이 되지 않은 것 !!!

이는 최근 5일간 평균 5분 지각이 관측되었더라도
'평균 지각시간은 10분이상이다' 라는 귀무가설을 기각 할 수 없다.

Statistical Inference : Hypothesis Test

7. p-value (probability-value, 유의확률)



가설검정에서 p -value 활용 : 통계적 유의성 판단

- $p\text{-value} < \text{유의수준}(0.05)$: 귀무가설 기각하고 대립가설 채택 $\rightarrow$ 연구자의 주장(대립가설)이 통계적으로 유의하다.

(유의하다 : 의미를 갖는다. 회귀분석에서는 인과관계가 있다, $x \rightarrow y$) 즉 우연히 발생할 가능성이 5% 미만이다. $\rightarrow$ 유의한 차이가 있다고 할 수 있다.!!!

(차이가 우연에 의한 건지?, 진짜 효과가 있는 건지를 결정하는데 사용하는 것 !!)

결국 주장하고자 하는 것을 신뢰할 수 있는 의미있는 확률이 95% 보다 크므로 대립가설 주장을 받아 들일 수 있는 것!!!)

- $p\text{-value} > \text{유의수준}(0.05)$: 귀무가설 기각하지 못함

Statistical Inference : Hypothesis Test

7. p-value (probability-value , 유의확률)

- Brian and Jaission
- p-값은 해당 변수와 관련된 실제 계수가 0일 때 우리가 추정했던 것과 같거나 더 극단적인 결과를 얻었을 확률을 계량화한다. → 데이터가 설정된 통계 모델과 얼마나 일치하지 않는지를 나타낸다.
- → p-값은 귀무가설이나 대립가설이 참이 아니거나 데이터가 랜덤일 확률을 측정하지 않는다.
- → p-값은 효과의 크기나 결과의 유의성을 측정하지 않는다.

- 미국통계협회 : 통계적 유의성의 척도로서 앞으로 P-value 적용을 권장하고 있지 않다(Wasserstein et al. 2019)
- → 금융에서의 수십 년간의 실증 연구에 의문을 제기

p-value 역효과 : 효과의 크기(effect size)와 표본의 크기(n 수)의 정보 내포

효과의 크기가 커지거나 표본의 크기가 커지거나 둘 중 하나만 변하더라도 p-value는 작아져서 통계적으로 유의하게 됨. 동일한 n수에 대해 effect size가 변함으로써 p-value가 변한다.

•표본의 크기(n 수)

•ex) t-value에서 표본의 크기는 불확실도, 자유도에 모두 포함된 개념

n수가 커짐으로써 p-value가 작아지는 현상도 확인할 수 있다.

즉, 실제로 한 모집단에서 두 표본 집단이 나왔음에도 p-value는 0.05보다 낮을 수 있다. → 귀무가설이 기각되어 대립가설이 채택됨에도 불구하고 대립 가설이 참이 아닐 수도 있다.

통계적 검증 단계에서 p-value를 맹신하지 않도록 특히 주의를 기울여야 할 것!!

7. p-value (probability-value , 유의확률)

p-값 결함

1) 가정에 의존

- → 그러한 가정들이 정확하지 않을 때 p-값 계수의 참 값이 0이더라도 p-값이 낮을 수 있고(거짓 양성), 계수의 참 값이 0이 아님에도 p-값이 높을 수 있다(거짓 음성)

2) 높은 다중 공선성 설명 변수

→ 이 경우 p-값을 강건하게 추정할 수 없다는 것

→ 다중공선시스템에서 전통적인 회귀분석 방법은 중복 설명 변수를 구별할 수 없으므로 관련 **p-값 간의 대체 효과가 발생한다.**

3) 샘플의 유의성을 평가한다는 것

→ 전체 샘플은 계수 추정과 유의성 결정이라는 두 가지 과제를 해결하는 데 사용된다.


따라서 p-값은 샘플 외 설명(즉 예측) 값이 없는 변수에 대해 낮을 수 있다.(즉 유의할 수 있다).

동일한 데이터셋에 대해 여러 번의 샘플 내 테스트를 실행하면 잘못된 발견이 발생할 가능성이 높으며, 이는 p - 해킹으로 알려진 관행이다.

4) 완전히 관련이 없는 확률을 평가한다는 것

- 귀무가설과 추정된 계수 가 주어졌을 때 p-값은 H_0 이 참인 경우 확률

* Review




집단간 평균 차이를 다시 표준편차와 비교

- 두 집단의 평균 차이를 표준오차(표본평균의 표준편차)와 비교하는 것!!
- 집단간 차이가 없는지?(귀무가설) 집단간 차이가 있는지 ? (대립가설)를 알아봐야 한다.
- 0 을 기준으로 95% 내에 두 집단 평균차이가 존재하면 차이는 우연히 발생한 것이므로 집단간 차이가 없는 것 (귀무가설 기각 못함)
- 얼마 정도 평균 차이가 있을 때 유의한가?
: 두 집단 평균 차이가 표준편차 보다 매우 작으면 평균 차이가 거의 없으므로 우연히 발생한 것!
→ 두 집단 간 평균 차이가 없다(귀무가설 기각 못함)
: 두 집단 평균 차이가 표준편차 보다 매우 크면 차이가 있으므로, 우연히 발생한 것이 아니라는 판단

Statistical Inference : Hypothesis Test

가설검정 과정



1단계 : 가설 설정

귀무가설(null hypothesis) H_0

- 아무 관련이 없다. (β (베타) = 0) → 회귀분석에서 인과관계가 없다.
- 두 집단간에는 평균(분산)차이가 없다
- 범죈자자 아니다.

대립가설(alternative hypothesis), 대안가설 H_1

- 어떤 관련이 있다. (β (베타) $\neq 0$) → 인과관계가 있다.
- 두 집단간에는 평균(분산)차이가 있다

2단계 : 가설 검정 오류(유의수준)

유의수준 (significant level) 사전적으로 설정 (통상 0.05)

✓ 1종 오류(α 수준)

- 유의수준 : 사회과학에서는 주로 0.05 또는 0.1, 0.01 사전적으로 정함
- 결국 1종오류는 유의수준 이내에서 허용되지 않으면 유의하지 않게 됨.

✓ 신뢰수준(level of confidence) : 귀무가설이 참일 때 이를 참이라고 판단하는 확률 → $(1 - \alpha)$

✓ 2종 오류(β 수준)

✓ 검정력 : 대립가설이 사실일 때, 이를 사실로서 결정할 확률 $(1 - \beta)$

Statistical Inference : Hypothesis Test

3단계 : 검정 통계량과 기각역

$$t\text{-value} = \frac{\bar{X}_A - \bar{X}_B}{\frac{s}{\sqrt{n}}}$$


검정 통계량

기각역의 값 임계치 (c.v) (t분포표 참조)

- 검정통계량이 기각역에 들어가면 귀무가설을 기각하고
- 들어가지 않으면(채택역, 검정통계량, 절대값2) 귀무가설을 기각하지 못한다.

모평균의 가설검정

- 통계적 가설검정은 표본평균의 표본분포와 관련된 기준값(critical value) C.V를 선정하고
- 'X'가 C.V보다 작으면 귀무가설을 채택하고, 아니면 귀무가설을 기각하고 대립가설을 채택 한다.



가설검정 결과의 해석

p-값 (p - value)

- 양측검정 경우 : $p\text{-value} < \text{유의수준}/2 \rightarrow$ 귀무가설 기각
- 단측검정 경우 : $p\text{-value} < \text{유의수준}(0.05) \rightarrow$ 귀무가설 기각

*p-value < 0.05 가지는 의미는?**: 어떤 확률(p)이 5%보다 작다. 이는 어떤 확률의 신뢰가 95% 보다 크다.**: 즉 통계로 추정된 회귀계수가 참일 확률이 95%보다 크다. 즉 귀무가설을 기각하고 대립가설을 채택할 수 있다.*1) $p\text{-value} < 0.05$ (주어진 유의수준)

귀무가설이 기각되면 주어진 유의수준 하에서 "귀무가설을 기각한다"라는 결론을 내리게 된다.

2) $p\text{-value} > 0.05$ (주어진 유의수준)

귀무가설이 기각되지 못하면 "귀무가설을 기각하지 못한다"라는 결론을 내리게 된다.


→ 이러한 이유는 귀무가설을 기각할 때는 제1종오류가 발생할 수 있고 귀무가설을 기각하지 못할 때에는 제2종오류가 발생할 수 있기 때문이다.

Statistical Inference : Hypothesis Test

통계적 비교 : 두 모집단의 평균을 비교하는 문제 → 두 모집단의 평균의 차가 없거나(0), 크거나 작을까? 등을 검정하는 것

독립표본과 대응표본

- **독립표본** : **두 모집단에서** 각각 추출된 표본이 서로 독립적 추출된 경우
- **대응표본** : 독립표본이 아닌 경우 (동일집단내에서의 실험)
(사례)
 - **(독립표본)**
 - 남녀간 음주사고율의 차이가 있을까?
 - 두 생산 라인에서 생산되는 제품의 무게에 차이가 있을까?
 - **(대응표본)**
 - 음주사고를 줄이기 위하여 위해서 범죄자들에게 실시한 예방특별교육이 과연 음주사고를 줄이는데 효과를 가져왔을까?



Statistical Inference : Hypothesis Test

가설검정 비교 예시

구분	가설 검정 구분	
두 표본(집단) 모평균 비교	• 두 모평균의 차이가 얼마라는 가설에 대한 검정 • 모집단에서 서로 독립적으로 표본을 추출했을 때 모평균의 차 $\mu_1 - \mu_2 (= D_0)$의 추정량은 표본평균의 차이	
	1. Z-검정 (Z-test)	• 두 모집단이 정규분포를 따르고 모분산이 같다는 가정 • <u>모집단의 평균과 표준편차가 얼마라는 것이 알려져 있을 때,</u> • <u>새롭게 조사된 표본의 평균이 모집단의 평균과 같은 지를 추정하는 검정</u> • 정규 모집단인 경우 • Z 통계량 사용
	2. t 검정 (t-test)	• <u>모집단이 정규분포이며 소표본인 경우</u> ▪ 두 독립표본의 평균 비교하는 경우 → 3개 이상 집단 비교 : ANOVA ▪ 대응표본의 평균 비교하는 경우 • t 통계량 사용
모비율 차이 검정	1. Z-검정 (Z-test)	모비율 p의 추정량인 표본비율이 알려지거나, 표본의 크기 n 큰 경우 ($n > 30$)
	2. t 검정 (t-test)	모집단의 데이터의 분포 (표준편차)를 알고 있기 어렵기 때문에 t검정을 사용
모분산 비교	• 두 모집단의 분산을 비교하는 경우에는 분산의 차이를 비교하지 않고, 분산의 비를 계산한다. • 분산비가 1보다 큰가, 작은가, 같은가를 알아보면 분산의 크기를 알 수 있다. (이유 : 수학적 용이성) • 분산분석 (ANOVA) : 시험계획법에서 가장 많이 사용되는 분석 방법	
	1. F 검정	실험 집단의 분산이 동일한지 여부를 검정하는 방법 F 통계량 사용
	2. 카이제곱 검정	• 관찰된 빈도가 기대되는 빈도와 의미 있게 차이 있는지 여부를 검정하기 위해 사용하는 검정 방법 • 빈도나 명목척도 (성별, 나이 등) 형태의 자료 분석에 주로 활용 카이제곱 통계량 사용

1. Z -test

Z 검정

모평균 검정

- 단일집단(1개) 검정
- 독립 2개 집단 검정

$$Z = \frac{\bar{x} - \mu_0}{\frac{\sigma}{\sqrt{n}}} = \frac{\bar{x} - \mu_0}{\sigma_{\bar{X}}}$$

$$Z = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$$

모비율 검정

- 단일집단 (1개) 검정
- 독립 2개 집단 검정

$$Z = \frac{\tilde{p} - p_0}{\sqrt{\frac{p_0 q_0}{n}}}$$

$$Z = \frac{(\tilde{p}_1 - \tilde{p}_2) - p_0}{\sqrt{\frac{p_1 q_1}{n_1} + \frac{p_2 q_2}{n_2}}}$$

1. Z -test

(1) Z검정 : 모평균에 대한 검정

표준정규분포를 이용하여 모수를 검정하는 경우

- 표본통계량의 확률분포가 정규분포를 따르는 경우에 Z검정을 실시할 수 있다.

어떤 상황에서 Z- test 사용?

- 1) 모분산이 알려져 있고 정규모집단인 경우
 - 유의수준이 주어지면 양측검정, 단측검정의 여부에 따라 임계치 계산하고 표본정보에 따라 검정통계량을 계산
 - 검정통계량은 Z값으로 계산되며 임계치보다 검정통계량의 값이 더 멀리 발생하여 기각역에 속하면 귀무가설을 기각

검정통계량

$$Z = \frac{\bar{x} - \mu_0}{\sigma_{\bar{x}}} = \frac{\bar{x} - \mu_0}{\frac{\sigma}{\sqrt{n}}}$$

- 2) 대표본의 경우
 - 중심극한정리에 의해 표본의 크기가 충분히 크면 표본평균은 정규분포를 근사적으로 따르게 되므로
 - Z검정으로 귀무가설을 검정할 수 있다.
 - → 모분산이 알려져 있지 않다면 표본분산으로 대체하여 검정통계량을 계산

검정통계량

$$Z = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}}$$

독립 두 집단간 비교

$$Z = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

1. Z -test

(1) Z검정 : 모평균에 대한 검정

1. Z검정

1개 집단(A) : 검정 절차

1. 가설

- 양측검정 : 귀무가설(H_0) : $\mu_A = \mu_0$ 대립가설(H_1) : $\mu_A \neq \mu_0$
- 우측검정 : 귀무가설(H_0) : $\mu_A \leq \mu_0$ 대립가설(H_1) : $\mu_A > \mu_0$
- 좌측검정 : 귀무가설(H_0) : $\mu_A \geq \mu_0$ 대립가설(H_1) : $\mu_A < \mu_0$

2. 검정통계량


$$Z = \frac{\bar{x} - \mu_0}{\frac{\sigma}{\sqrt{n}}}$$

$\bar{x}$ = 표본평균, μ = 모평균, σ = 모표준편차, n = 표본수

3. 기각역

- 대립가설(H_1) : $\mu_A \neq \mu_0$ 일 때, $|Z| \geq z_{\alpha/2}$
- 대립가설(H_1) : $\mu_A > \mu_0$ 일 때 $|Z| \geq z_{\alpha}$
- 대립가설(H_1) : $\mu_A < \mu_0$ $|Z| \leq -z_{\alpha}$

→ 검정통계량이 기각역에 오면 대립가설 채택



유의수준	양측검정	단측검정
10%	$\pm z_{\alpha/2} = \pm 1.645$	$z_{\alpha} = 1.28$ or $-z_{\alpha} = -1.28$
5%	$\pm z_{\alpha/2} = \pm 1.96$	$z_{\alpha} = 1.645$ or $-z_{\alpha} = -1.645$
1%	$\pm z_{\alpha/2} = \pm 2.575$	$z_{\alpha} = 2.33$ or $-z_{\alpha} = -2.33$

1. Z -test

(1) Z검정 : 모평균에 대한 검정 (예제)

00대학교 1학년 학생에 대한 역대 범죄통계학 평균 점수는 70점, 표준편차는 15점이다.

금년 신입생들이 1학기 시험결과 25명에 대한 표본 평균을 조사해봤더니 평균이 78점이 나왔다. 이 평균점수가 역대 평균점수와 동일한지를 유의수준 0.05에서 검정하면?

모집단이 정규분포이며 모분산(모표준편차)을 알고 있는 경우 : Z검정 이용

(가설설정)

- 귀무가설: 평균값이 동일하다.(차이가 없다)
- 대립가설: 평균값이 동일하지 않다.(차이가 있다)

(검정)

동일한것인지 여부 검정 = '양측 검정' 사용

유의수준 0.05 기각역은 0.025가 되고, 표준정규분포에서 확률이 0.025가 되는 값은 1.96.

검정통계량 = $(78-70)/(15/5) = 2.67$


(의사결정)

임계치 1.96보다 더 큰 값이기에, 기각역에 놓이고 있다.

→ 귀무가설을 기각한다. : 평균값이 동일하지 않다. 즉, 금년 신입생들의 평균성적이 역대 평균성적과 차이가 있다.

$$Z = \frac{\bar{x} - \mu_0}{\frac{\sigma}{\sqrt{n}}}$$

(유의수준 α)	Z 값
0.1	1.28
0.05	1.645
0.025	1.96
0.01	2.33



Z=2.67

1. Z -test

(1) Z검정 : 모평균에 대한 검정

독립 두 모집단 경우

- 서로 독립인 두 모집단(A, B)의 각각의 모분산이 알려진 경우
 - 두 모집단의 분포가 정규분포인 경우
 - 임의의 분포(정규분포 아님)라도 서로 독립인 두 집단의 각각의 표본의 크기가 큰 경우(≥ 30)의 경우
Z검정을 통해 모평균의 차이를 검정하는 경우는 단일 모수에 대한 검정과 마찬가지로 양측검정, 단측검정의 형태로 가설을 세울 수 있다.
귀무가설 : 평균 차이가 없다.
- > 두 모평균에 대한 가설검정

1. 가설

- 양측검정 : 귀무가설(H_0) : $\mu_A - \mu_B = \mu_0$ 대립가설(H_1) : $\mu_A - \mu_B \neq \mu_0$
- 우측검정: 귀무가설(H_0) : $\mu_A - \mu_B \leq \mu_0$ 대립가설(H_1) : $\mu_A - \mu_B > \mu_0$
- 좌측검정: 귀무가설(H_0) : $\mu_A - \mu_B \geq \mu_0$ 대립가설(H_1) : $\mu_A - \mu_B < \mu_0$

2. 검정통계량

$$Z = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

$$Z = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

3. 기각역

검정통계량 z값을 계산하고 주어진 유의수준에 따른 임계치와 비교한 후
귀무가설의 기각여부를 결정하는 절차도 단일 모수인 경우와 동일하다.

- 양측검정 : 대립가설(H_1) : $\mu_A \neq \mu_B$ 일 때, $|Z| \geq z_{\alpha/2}$
- 우측검정: 대립가설(H_1) : $\mu_A > \mu_B$ 일 때, $|Z| \geq z_{\alpha}$
- 좌측검정: 대립가설(H_1) : $\mu_A < \mu_B$ 일 때, $|Z| \leq -z_{\alpha}$

→ 검정통계량이 기각역에 오면 대립가설 채택

1. Z -test

(1) Z검정 : 모평균에 대한 검정

one sample 비율 검정

$$\text{표본비율 : } \tilde{p} = \frac{X}{n}$$

모비율 p 의 추정량인 표본비율이 알려지거나, 표본의 크기 n 큰 경우 ($n > 30$)

가설검정을 이용한 방법

표본비율의 확률분포는 근사적으로 정규분포를 따르게 된다. 따라서 모비율에 대한 가설 검정을 Z검정으로 수행

1. 가설

- 우측검정: 귀무가설(H_0) : $p = p_0$, 대립가설(H_1) : $p > p_0$
- 좌측검정: 귀무가설(H_0) : $p = p_0$, 대립가설(H_1) : $p < p_0$
- 양측검정 : 귀무가설(H_0) : $p = p_0$, 대립가설(H_1) : $p \neq p_0$

2. 검정통계량

모비율 검정을 위한 검정통계량

$$Z = \frac{\tilde{p} - p_0}{\sqrt{\frac{p_0 q_0}{n}}}$$

(단, $q_0 = 1 - p_0$)

3. 유의수준

4. 기각역

- 우측검정: $H_1 : p > p_0$ 일 때 $Z \geq z_\alpha$
- 좌측검정: $H_1 : p < p_0$ 일 때 $Z \leq z_\alpha$
- 양측검정 : $H_1 : \neq p_0$ 일 때 $|Z| \geq z_{\alpha/2}$

→ 검정통계량이 기각역에 오면 대립가설 채택

5. 의사결정

- $p\text{-value} > \text{유의수준}(0.05)$: 귀무가설을 기각할 수 없다.
- $p\text{-value} < \text{유의수준}(0.05)$: 귀무가설을 기각

1. Z -test

(1) Z검정 : 모평균에 대한 검정

(예제)

한국남자 흡연율은 52%로 알려져 있다. 최근 정부는 국민건강을 위하여 담뭇값 인상을 통한 결과 흡연율이 52%로 낮아졌다고 생각하고 있다. 이를 확인하기 위하여 성인남자 500명을 표본 추출하여 흡연여부를 조사해보니 흡연자가 250명으로 조사되었다.
흡연율이 50%로 낮아졌다고 할 수 있는지 유의수준 5%에서 검정하시오.

(가설)

귀무가설 : 52%로 동일하거나 높다.

대립가설 : 52% 보다 낮아 졌다. (좌측검정)

(검정통계량)

$$\text{표본비율} = \frac{250}{500} = 0.5 \quad \frac{0.5-0.52}{\sqrt{\frac{0.52(1-0.52)}{500}}} = -0.9016$$

$$Z = \frac{\tilde{p} - p_0}{\sqrt{\frac{p_0 q_0}{n}}}$$

(의사결정)

유의수준=0.05일때 Z값 1.645 기각역은 -1.645

→ -1.645 < -0.9016 이므로 귀무가설을 기각할 수 없다.

(해석) 담뭇값 인상을 통해 흡연율이 기존 52% 보다 낮아졌다고 볼 수 없다.

(유의수준 α)	Z 값
0.1	1.28
0.05	1.645
0.025	1.96
0.01	2.33

1. Z -test

(1) Z검정 : 모평균에 대한 검정

(예제)

202x년 선거철이다. A 후보에 대한 지지율이 40%로 알려져 있다. 일부 매체에 의하면 40%를 넘을 것으로 보도하고 있다. 이를 확인하기 위하여 리서치에 의뢰하여 확인하고자 한다.

무작위로 유권자 500명을 대상으로 지지후보를 조사하였더니, 240명이 A 후보를 지지하는 것으로 조사되었다.

이 조사를 근거로 A 후보에 대한 지지율이 40%로 높다고 할 수 있는지 유의수준 5%에서 검정하시오.

(가설)

귀무가설 : 지지율이 40% 이거나 보다 낮다.

대립가설 : 지지율이 40% 보다 높다. (우측검정)

(검정통계량)

$$\text{표본비율} = \frac{240}{500} = 0.48 \quad \frac{0.48 - 0.4}{\sqrt{\frac{0.4(1-0.4)}{500}}} = 3.6514$$

$$Z = \frac{\tilde{p} - p_0}{\sqrt{\frac{p_0 q_0}{n}}}$$

(의사결정)

유의수준=0.05 Z값 1.645 기각역 1.645

→ 1.645 < 3.6514 기각역에 있다 : 귀무가설을 기각한다

(해석) A후보에 대한 지지율이 40%보다 높다고 할 수 있다.

(유의수준 α)	Z 값
0.1	1.28
0.05	1.645
0.025	1.96
0.01	2.33

1. Z -test

(1) Z검정 : 모평균에 대한 검정

(예제)

S전자는 수익성 개선을 위하여 전사적으로 품질관리를 통한 생산성 제고를 금년 최대 목표로 삼고 있다.
 이 회사의 제품에 대한 불량율은 5%로 알려져 있다. 그러나 생산라인에서는 5%가 아니라는 의견이다.
 이에 대하여 알아보기 위해 조사를 실시하였다. 표본 100개를 뽑았더니 불량품이 4개가 나왔다. 이때 제품의 불량률에 대하여 유의수준 5%에서 검정하시오.

(가설)

귀무가설 : 불량률이 5%이다.

대립가설 : 불량률이 5%가 아니다. (양측검정)

(검정통계량)

$$\text{표본비율} = \frac{4}{100} = 0.04 \quad \frac{0.04 - 0.05}{\sqrt{\frac{0.05(1-0.05)}{100}}} = -0.4588$$

$$Z = \frac{\tilde{p} - p_0}{\sqrt{\frac{p_0 q_0}{n}}}$$

(의사결정)

유의수준=0.05 양측검정 $\alpha/2=0.025$ 해당하는 Z값 1.96 기각역은 ± 1.96

→ -1.96과 +1.96 사이에 -0.4588이 있다.

→ 귀무가설을 기각할 수 없다.

(해석) 불량률이 5%가 아니라고 할 수 없다.

(유의수준 α)	Z 값
0.1	1.28
0.05	1.645
0.025	1.96
0.01	2.33

1. Z -test

(1) Z검정 : 모평균에 대한 검정

두 모집단의 모비율의 차이에 대한 검정
: two sample 비율 검정

표본 비율

$$\tilde{p}_1 = \frac{\sum_{i=1}^{n_1} X_i}{n_1}$$

$$\tilde{p}_2 = \frac{\sum_{i=1}^{n_2} Y_i}{n_2}$$

표본비율은 베르누이 분포의 표본평균-중심극한정리에 의해 표본비율 우측분포로 근사

1. 가설

- 귀무가설(H_0) 0으로 가정한다.
- 귀무가설 (H_0) : 두 모집단의 모비율의 차이가 없다고 가정하는 것이다.
- 대립가설 (H_1) : 두 모집단의 모비율의 차이가 있다. 크다. 작다고 주장하는 것

$$\tilde{p}_1 \sim N(p_1, p_1(1-p_1)/n_1)$$

$$\tilde{p}_2 \sim N(p_2, p_2(1-p_2)/n_2)$$

- 우측검정: 귀무가설(H_0) : $p_1 - p_2 \leq 0$, 대립가설(H_1) : $p_1 - p_2 > 0$
- 좌측검정: 귀무가설(H_0) : $p_1 - p_2 \geq 0$, 대립가설(H_1) : $p_1 - p_2 < 0$
- 양측검정 : 귀무가설(H_0) : $p_1 - p_2 = 0$, 대립가설(H_1) : $p_1 - p_2 \neq 0$

2. 검정통계량

표본 정보가 주어지면 이를 통해 검정통계량 z값을 계산하고 주어진 유의수준에 따른 임계치와 비교한 후 귀무가설의 기각 여부를 결정하는 절차도 모평균의 차이를 검정하는 경우와 동일

Z검정을 위한 검정통계량

$$Z = \frac{(\tilde{p}_1 - \tilde{p}_2) - p_0}{\sqrt{\frac{p_1 q_1}{n_1} + \frac{p_2 q_2}{n_2}}}$$

2. t -test

t검정 (t-test) 이란?

- t분포를 이용한 모평균의 차이 검정 : 표본에서 구한 분산/표준편차로 어떤 변수를 표준화를 하면 z값이 아닌 t값이 되고, 이를 이용하여 검증하기 때문에 **t-test** 라고 함

적용 상황

- 모집단이 정규분포이며 소표본인 경우
- 모분산이 알려져 있지 않고 표본이 소표본이라면 정규분포를 이용할 수 없다. → 이런 경우 t분포를 이용한 추론
- 모평균에 대한 추정과 마찬가지로 각각의 모집단이 정규분포라는 가정이 필요하다.


표본 집단

- (1) 단일표본 t-검정(One-sample t-test)
- (2) 독립표본 t-검정 (Independent-samples t-test) Two-sample t-test
- (3) 대응표본 검정 (Paired t-test)

2. t -test

(1) 단일표본 t-검정(One-sample t-test) : 단일모집단 모평균 검정

- 사용목적 : 기준값 비교
- 집단의 수 : 1개
- 자료의 성질 : 연속형
- 측정 회차 : 1회
- 주요전제 : 모집단 정규성



(가설설정)

(1) 양측검정

해당 표본을 통해서 실제로 추정된 모평균이 기존에 알려져 있는 모평균(기준값)과 동일한지(=) 다른지(≠)

- H_0 (귀무가설): 표본으로부터 추정된 모평균은 기존에 알려진 모평균과 차이가 없을 것이다.
- H_1 (대립가설): 표본으로부터 추정된 모평균은 기존에 알려진 모평균과 차이가 있을 것이다.

(2) 단측검정 : 좌측, 우측검정

크거나, 작다. (<, >)를 판단하는 경우 사용

(우측검정)

- H_0 (귀무가설): 표본에서 얻어진 평균은 사전에 지정된 값과 차이가 없을 것이다.
- H_1 (대립가설): 표본에서 얻어진 평균은 사전에 지정된 값보다 크다.

(좌측검정)

- H_0 (귀무가설): 표본에서 얻어진 평균은 사전에 지정된 값과 차이가 없을 것이다.
- H_1 (대립가설): 표본에서 얻어진 평균은 사전에 지정된 값보다 작다.

(검정통계량)

(의사결정)

95% 신뢰수준

P-value < 0.05(유의수준) 인 경우 : 귀무가설을 기각하고 대립가설 채택 : ~ 차이가 있다.

$$t = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}}$$

분모값: 표준오차, Z 값과 비교 : 자유도의 차이

2. t -test

(1) 단일표본 t-검정(One-sample t-test) : 단일모집단 모평균 검정

(예제)

최근 반려견 키우는 가정이 늘고 있다. 강아지 평균수명은 15년으로 알려져 있는데, 15년이 아니라는 새로운 주장이 나왔다.

그래서 표본 100마리를 대상으로 평균수명을 조사하였다.

결과 평균수명이 16년이 나왔고 표준편차는 4년이 나왔다.

기존 의견이 맞는지? 새로운 주장이 타당한지를 검정하시오. (유의수준 0.05)

- 귀무가설 : 평균수명은 15년이다
- 대립가설 : 평균수명은 15년이 아니다 → 양측검정

(검정통계량) $\frac{16-15}{4/\sqrt{100}} = \frac{1}{4/10} = 2.5$

$$t = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}}$$

(유의수준, 의사결정)


유의수준 = 0.05 양측검정이므로 $0.05/2 = 0.025$

자유도 $100-1=99$

t분포표 해당하는 값을 찾으면 약 2.0

검정통계량(2.5) 이 임계치 2.0 오른쪽 기각역에 위치하고 있으므로 귀무가설을 기각, 대립가설을 채택

(해석) 반려견의 평균수명이 15년이 아니라고 말할 수 있다.



2. t -test

(1) 단일표본 t-검정(One-sample t-test) : 단일모집단 모평균 검정

(예제)

경찰관들이 복무시간이 과도한 상황이다. 정부는 경찰관들의 평균 근무시간이 8시간이라고 주장하고 있다. 그러나 경찰관들은 과중한 업무로 근무시간이 8시간 보다 많다고 주장한다. 어느 주장이 맞는지 확인하기 위하여 경찰관 30명의 평균근무시간을 조사하였더니, 평균근무시간이 8.5시간이었고. 표준편차는 1시간이었다. 어느 주장이 맞는지를 유의수준 5%에서 검정하면?

(가설)

귀무가설 : 근무시간이 8시간보다 작거나 같다.

대립가설 : 근무시간이 8시간 보다 많다.

검정통계량

$$\frac{8.5-8}{1/\sqrt{30}} = 2.7386$$


$$t = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}}$$

자유도 29(=30-1), 유의수준 우측 해당 값 1.697

검정통계량 2.7386은 임계치(1.697) 오른쪽인 기각역에 위치한다.

귀무가설 기각하고 대립가설을 채택한다.

(해석) 경찰관의 근무시간은 8시간보다 많다고 할 수 있다.



2. t -test

(예제)

대한민국 남성 경찰관들 평균 키가 174cm 라고 알려져 있다. 평균 키가 알려진 174cm 보다 작다는 주장이 있다.
주장이 맞는지를 확인하기 위하여
서울경찰청 소속 남성 경찰관 25명을 표본을 무작위 추출하여 측정해 보았다.
표본의 평균 키는 173 cm이고 표준편차는 5cm이다. 유의수준 5%에서 검정하면?

(가설)

귀무가설 : 대한민국 남성 경찰관들 평균 키가 174cm 이다.

대립가설 : 대한민국 남성 경찰관들 평균 키가 174cm 보다 작다

검정통계량

$$t = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}}$$


$$\frac{173-174}{5/\sqrt{25}} = -1$$

자유도 24 (= 25-1)에서 0.05에 해당하는 임계치를 찾아보면

-1.711 로 검정통계량은 채택역에 위치한다.


귀무가설 기각을 기각할 수 없다.

(해석) 남성경찰관의 평균 키는 174 cm 라고 할 수 있다.



2. t -test

(2) 독립표본 t-검정(Independent-samples t-test) : Two-sample T-test



- 상호 독립적인 두 집단으로부터 얻어진 평균의 차이가 통계적으로 의미를 부여할 수 있을 만큼 차이가 있는지?
- 집단 간 차이를 검정하는 방법일 뿐.→ 두 집단이 서로 이질적이라는 독립표본 t-검정 결과를 놓고서 집단 간 차이에 대한 인과적 설명을 하는 것은 불가능하다.

2. t -test

(2) 독립표본 t-검정(Independent-samples t-test) : Two-sample T-test

독립표본 t-검정 전제 조건

기존 전제	내용	검증방법	가설
정규성 검정	- 수집된 데이터가 특정한 값에 편중되지않고 적절하게 수집이 되었는지를 확인하는 과정 → 이를 확인하기 위하여 자료가 정규분포 여부를 검정 - 독립표본t-test에서 두 집단의 수치를 하나 하나 비교하는것이 아니라 각각의 집단의 평균을 비교하는 것→ 따라서 정규성을 가지는 것은 평균이 가지는 정규성을 의미한다.	- Shapiro-Wilk test - Kolmogorov-Smirnov test - p value < 0.05 귀무가설 기각 (비모수통계.검정 진행)	H_0 : 정규분포를 따른다. H_1 : 정규분포 아니다. p value > 0.05 귀무가설 기각 못함→정규분포를 따른다.
등분산성	모든 그룹에 데이터에 대한 분산이 동일해야 한다. 등분산은 두 모집단의 모분산은 알려져 있지 않지만 동일한 값을 갖는다는 가정이다. 독립표본 (A, B)에 대하여 분산 가정 : $\sigma_A^2 = \sigma_B^2 = \sigma^2$	- levene test - bartlett test (이분산성hetero) : Welch's t-test를 적용	H_0 등분산이다 H_1 : 등분산이 아니다. p value > 0.05 귀무가설 기각 못함→등분산성이다.
독립성	독립변수의 그룹군은 서로 독립적 두 개의 범주형 변수/요인(2 factors)이 서로 연관성이 있는지, 상관이 있는지, 독립적 여부 확인	카이제곱 검정 (chisquared test)을 통해 통계적으로 판단하는 방법	

2. t -test

* t -test 생각하고 하기

A 집단(표본 25)

- 평균 (85)
- 분산 (2^2)

B집단(표본 25)

- 평균(84)
- 분산

- 두 집단의 평균값이 차이가 있다 → 통계적으로 차이가 유의한 지를 확인한다는 의미 ?
- 두 집단의 평균 차이 1점은 차이가 커서 의미있는지를 알기 위하여는 표준편차(분산) 이 필요하다. → 즉 우연한 차이가 아니라고 말을 하려면... (표본의 표준편차 → S.E : 평균 퍼진 정도 이므로)
- 두 집단의 차이 1점이 우연히 발생했을 확률은? 두 집단의 평균점수 차이 1점은 평균적인 차이로 거리 의미
- → **결국 평균점수 차이가 두 집단의 표준편차 보다 현저히 크면 의미를 둘 수 있지만, 평균점수 차이가 두 집단의 표준편차 보다 현저히 작다면 의미를 둘 수 없는 것!!!**
- 아래 t-value (검정통계량) 가 두 집단의 평균값의 차이를 표준편차(다만, 표본일때 표준오차 사용)와 비교한 것

$$t\text{-value} = \frac{\text{표본 평균값 차이}}{\text{불확실도}}$$

$$t\text{-value} = \frac{\bar{X}_A - \bar{X}_B}{S.E} = \frac{\bar{X}_A - \bar{X}_B}{\frac{s}{\sqrt{n}}}$$

- 유의수준(0.05), 검정통계량 $t = (85 - 84) / (2 / \sqrt{25}) = 1 / (2/5) = 2.5$
- 자유도(24) → 임계치 2.064
- 검정통계량(2.5)이 임계치(2.064)보다 우측 기각역 오른쪽에 위치한다.
- (해석) 두 집단의 평균점수 차이가 있다.(통계적으로 유의하다)

24	0.685	0.857	1.059	1.318	1.711	2.064
----	-------	-------	-------	-------	-------	-------

$$Z = \frac{X - \mu}{\sigma}$$

- **표본(n)이 커지면 t-value 커진다.**
- 표본(n)이 커지면 t분포는 표준정규분포에 근사
- 자유도(df = n-1)는 표본이 커지면 자유도도 커지므로 분포에 대한 선택이 자유로워져 표준정규분포 사용 할 수 있게 된다.

https://github.com/freejyb/fin_stats

T 검정 : (주가수익률 차이)

2. t -test

(2) 독립표본 t-검정(Independent-samples t-test) : Two-sample T-test

1) 분산이 같은 경우의 검정통계량

$$t\text{-value} = \frac{\bar{X}_A - \bar{X}_B}{\frac{S_p}{\sqrt{n}}}$$

S_p : 두 집단을 pooled한 표본 표준편차

$$S_p = \sqrt{\frac{(n_A - 1)S_A^2 + (n_B - 1)S_B^2}{n_A + n_B - 2}}$$

→ 분모값 ($n_A + n_B - 2$) : 자유도(df)

2) 분산이 다른 경우의 검정통계량

$$t\text{-value} = \frac{(\bar{X}_A - \bar{X}_B)}{\sqrt{\frac{s_p^2}{n_A} + \frac{s_p^2}{n_B}}}$$

$$df = \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2} \right)^2}{\frac{\left(\frac{s_1^2}{n_1} \right)^2}{n_1 - 1} + \frac{\left(\frac{s_2^2}{n_2} \right)^2}{n_2 - 1}}$$

t 검정과 회귀분석 차이

T-test	- 검정(test)하는 내용이 가설의 유의확률내에 들어가는지 아닌지를 판단한다. - 따라서 각 변수별로 어떠한 영향력을 미치는지 분석하지 않는다. - t 검정은 이러한 인과관계 분석이 아니라 '차이'를 검정하는 방법
회귀분석	- 변수에 투입을 하여 얻어지는 결과량의 변화를 측정하는 것으로 인과관계(원인과 결과)의 분석 - t분포는 평균 검정을 하기 위해 고안된 평균과 관련된 분포로 표본수가 충분하면 Z 분포를 이용하지만, 표본수가 충분하지 못하면 (일반적 $n < 30$) 예측범위를 넓게 잡는 꼬리가 긴 분포인 t 분포 사용

2. t -test

독립 표본 : 2개의 독립 모집단에 대한 모평균 차이에 대한 통계량 이해하기

독립표본(A, B)에서 모평균의 차이 ($\mu_A - \mu_B$)에 대한 추론을 하기 위하여는
표본평균의 차이에 대한 평균과 분산 이해가 필요하다.

만일 정규분포를 따르는 두 모집단이 존재하고 각각의 모집단에서 표본을 추출하여 평균을 계산 한 다음
계산된 각각의 평균값 차이를 계산한다면 그 값의 분포는 정규분포를 따를 것이다.
또한 두 모집단이 정규분포를 따르지 않지만 표본크기가 충분히 크다면 근사적으로 두 표본평균의 차이의 분포는
정규분포를 따른다.
이 때 두 표본평균의 분포의 기대치와 분산 표준편차는 다음과 같다.

- $E(\bar{\theta}) = E(\bar{X}_A - \bar{X}_B) = E(\bar{X}_A) - E(\bar{X}_B) = \mu_A - \mu_B$
- $\sigma_{\bar{\theta}}^2 = \text{Var}(\bar{X}_A - \bar{X}_B) = \text{Var}(\bar{X}_A) + \text{Var}(\bar{X}_B) = \frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}$

$$Z = \frac{(\bar{X}_A - \bar{X}_B) - (\mu_A - \mu_B)}{\sqrt{\frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}}}$$

그러나 !!!! 알려져 있지 않은 두 모분산이 동일한지에 대한 여부에 따라 다르게 사용되어진다.
만일 모분산이 동일하다는 가정하에서 모평균의 차이의 검정통계량은 다음과 같다.

$$t = \frac{(\bar{X}_A - \bar{X}_B) - (\mu_A - \mu_B)}{\sqrt{S_p^2 \left(\frac{1}{n_A} + \frac{1}{n_B} \right)}}$$

$$S_p^2 = \frac{(n_A - 1)S_A^2 + (n_B - 1)S_B^2}{n_A + n_B - 2}$$

Pooled 분산추정량 → 각 표본의 자유도를 가중치로 사용하면서 구해지는
두 표본분산의 가중평균이다.

H_0 (null hypothesis) : 두 모집단의 모평균 차이는 0이다

2. t -test

3) 대응표본 t-검정(Paired T-test) : 평균차이 검정

서로 대응인 두 모집단의 표본의 크기 작은 경우($n < 30$) 두 모평균에 대한 가설검정

1) 의의

- **동일집단을 대상으로** 실험 이전(사건시행 이전)과 실험 이후(사건 시행 이후)의 집단 평균차이를 검정
- 한 사람이 처리 이전과 이후 각 1번씩 측정을 해서 사전/사후를 비교하는 것 (paired comparison)

2) 과정

- 귀무가설(H_0): 두 변수의 차이(b-a)가 정규분포를 따른다.
- 대립가설(H_1): 두 변수의 차이(b-a)가 정규분포를 따르지 않는다.

가설 설정

- 양측검정: 귀무가설(H_0): $\mu_0 - \mu_1 = 0$, 대립가설(H_1): $\mu_0 \neq \mu_1$
- 좌측검정: 귀무가설(H_0): $\mu_0 - \mu_1 = 0$, 대립가설(H_1): $\mu_0 - \mu_1 < 0$
- 우측검정: 귀무가설(H_0): $\mu_0 - \mu_1 = 0$, 대립가설(H_1): $\mu_0 - \mu_1 > 0$

(1) 정규분포를 따르는 경우: 사후-사전 값 차이의 평균이 0인지 검정하는 one sample t-test를 이용

→ t분포를 이용한 대응표본의 모평균 차이 검정

- 귀무가설(H_0): 모평균의 차이가 없다
- 대립가설(H_1): 모평균의 차이가 있다.

(2) 정규분포를 따르지 않는 경우: 비모수적 검정방법을 적용: wilcoxon.test를 사용

- 귀무가설 H_0 : 사후-사전 차이의 중위수(median) 값 차이가 없다(median = 0 이다.)
- 대립가설 H_1 : 사후-사전 차이의 중위수(median) 값 차이가 있다(median= 0이 아니다.)

검정통계량

$$t_{n-1} = \frac{\bar{d} - \mu_0}{\frac{s_d}{\sqrt{n}}}$$

$$\bar{d} = \frac{\sum d_i}{n}, s_d^2 = \frac{\sum (d_i - \bar{d})^2}{n-1}$$

- 표본평균 = $\bar{d}$
- 표본표준편차는 s_d

기각역/ 판단

- p-value > 0.05 귀무가설(H_0) 기각 못함
- p-value < 0.05 귀무가설(H_0) 기각

2. t -test

3) 대응표본 t-검정(Paired T-test) : 평균차이 검정

(예시)

최근 증권거래세 인하가 단행되었다. 서울 인하로 한국거래소에 상장되어 있는 주식에 대하여 시장변화에 대한 민감도 지표인 베타(β)에 영향을 주는지 여부를 확인하고자 한다.

서울 인하 전, 후에 30개의 종목에 대한 베타값의 변화를 측정한 결과는 다음과 같다.

- (시행 종목 베타 - 시행 후 종목 베타의 평균) : 0.2
- 평균에 대한 표준편차 : 0.1

서울 인하로 한국거래소 상장 종목의 베타값이 변화했는지의 여부를 검정하라. (유의수준 = 0.05)

- 귀무가설 : 서울 시행 전(μ_1), 후(μ_2)에 베타 값의 변화가 없다. $\mu_1 = \mu_2$
- 대립가설 : 서울 시행 전 후에 베타 값의 변화가 있다.
- 임계치 : 자유도(n-1), 유의수준 (0.05) $t_{29,0.025} = 2.042$
- 검정통계량 : $t = \frac{\bar{d} - \mu_0}{\frac{s_d}{\sqrt{n}}} = \frac{0.2}{\frac{0.1}{\sqrt{30}}} = 10.954$
- 검정통계량(10.954)이 임계치(2.042) 보다 크므로 우측 기각역에 위치한다.
- 귀무가설 기각, 대립가설을 채택할 수 있다.
- 즉, 서울 인하로 베타값에 영향을 주는 것으로 보인다. 서울인하로 평균 베타 0.2 감소한 것을 통계적으로 유의하다고 볼 수 있는 것!!

29	0.683	0.854	1.055	1.311	1.699	2.045
30	0.683	0.854	1.055	1.310	1.697	2.042

2. t -test : Summary

구분	단일표본 t-검정 (One-sample t-test)	독립표본 t-검정 (Independent-samples t-test)	대응표본 t-검정 (Paired-samples t-test)
t-test 사용목적	기준값 비교 (기준값 : 이미 알려진 값)	두 집단(A,B) 평균 비교	한 개 집단 두 번 측정 비교 (평균 쌍대 비교)
집단의 수	1개	2개	1개
자료의 성질	연속형	범주형, 연속형	연속형
측정 회차	1회	1회	2회
주요전제	모집단 정규성	- 집단 간 독립성 - 모집단 정규성, - 분포의 등분산성	집단간 종속성

t 검정통계량

평균 차이

$$t\text{-value} = \frac{\bar{x} - \mu_0}{s_{\bar{x}}} = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}}$$

$$t\text{-value} = \frac{\bar{X}_A - \bar{X}_B}{\frac{s}{\sqrt{n}}}$$

$$t\text{-value} = \frac{(\bar{X}_A - \bar{X}_B)}{\sqrt{\frac{s_A^2}{n_A} + \frac{s_B^2}{n_B}}}$$

$$t\text{-value} = \frac{\bar{d} - \mu_0}{\frac{s_d}{\sqrt{n}}}$$

3. F- test


F 검정

F검정 : 실험 집단의 분산이 동일한지 여부를 검정하는 방법

분산을 비교하는 이유

: 자료 비교의 신뢰성을 표현하기 때문이다

: 두 집단 간 평균 값의 차이가 없더라도 평균의 변동(분산) 크면 검정에 대한 신뢰가 없기 때문!!



- 낮은 F-값 그래프는 집단 평균이 각 집단 내 변동성에 비해 밀집한(변동성이 낮은) 경우 : 왼쪽 그래프
- 높은 F-값 그래프는 집단 평균의 변동성이 집단 내 변동성에 비해 큰 경우 : 오른쪽 그래프
- 집단 평균이 동일하다는 귀무가설을 기각하려면 F-값이 높아야 한다. → 기준값이 애매??

$$F\text{-통계량}(F\text{-value}) = \frac{\text{집단 간 변동}}{\text{집단 내 변동}}$$

모분산 차이에 대한 추론

- 두 모집단(A, B) 에서 각각 독립적으로 표본을 추출할 때 표본분산을 구할 수 있으며 표본분산의 확률분포에 따라 모분산의 차이를 추론할 수 있다. (모집단은 정규분포를 따르는 것으로 가정)
- 두 개의 독립표본에서 추출된 두 개의 표본분산이 결합하여 이루는 확률분포는 F분포를 따르게 된다.
→ 사실상의 F검정은 우측검정만을 수행한다. (F분포 특성 참조)
- F검정의 검정통계량은 두 개의 독립표본에서 표본분산을 구하여 두 표본분산의 비율로 정의되기 때문에
- 분자를 항상 표본분산이 큰 것으로 설정한다면 우측검정만으로도 모분산의 차이를 검정할 수 있다.

3. F- test

F 검정

F분포를 이용한 두 모집단(A, B) 모분산 차이 검정

가설검정

- 양측검정 : 귀무가설(H_0) : $\frac{\sigma_A^2}{\sigma_B^2} = 1$, 대립가설(H_1) : $\frac{\sigma_A^2}{\sigma_B^2} \neq 1$
- 좌측검정 : 귀무가설(H_0) : $\frac{\sigma_A^2}{\sigma_B^2} \geq 1$, 대립가설(H_1) : $\frac{\sigma_A^2}{\sigma_B^2} < 1$
- 우측검정 : 귀무가설(H_0) : $\frac{\sigma_A^2}{\sigma_B^2} \leq 1$, 대립가설(H_1) : $\frac{\sigma_A^2}{\sigma_B^2} > 1$

F검정의 검정통계량은 두 개의 독립표본에서 표본분산을 구하여 두 표본분산의 비율로 정의되기 때문에 분자를 항상 표본분산이 큰 것으로 설정한다면 우측검정만으로도 모분산의 차이를 검정할 수 있다.

검정통계량

$$F = \frac{S_1^2}{S_2^2} \sim F(n_1 - 1, n_2 - 1)$$

$$F = \frac{S_1^2 \sigma_2^2}{S_2^2 \sigma_1^2}$$

$$F \text{ value} = \frac{MSR}{MSE} = \frac{\frac{1}{df_R} \sum (\hat{Y}_i - \bar{Y})^2}{\frac{1}{df_E} \sum (Y_i - \hat{Y}_i)^2}$$

F검정의 검정통계량 : 두 독립표본의 표본분산의 비

회귀식이 데이터의 인과관계를 얼마나 잘 설명하는지 계산하기 위해 설명을 하지 못하는 영역 대비(MSE), 설명을 할 수 있는 영역(MSR)을 비교 필요함 → F-통계량(F-Value)

→ 회귀로도 잡힐 수 없는 예측 오차(MSE) 대비, 회귀로 인해 잡혀진 예측 오차(MSR)가 얼마나 큰가를 표현한 수치

→ 이 통계량이 크면 클 수록 (우리가 증명하고 싶은) 이 회귀모델이 유용하다는 것

: 분자값이 크거나, 분모값이 작은 경우 F 통계량이 크다.

해석 . 판단

→ p value 유의수준(0.05) $p < 0.05$: 귀무가설 기각, 대립가설 채택,

→ p-value > 0.05 : 귀무가설을 기각하지 못함

3. F- test

F 검정

(사용)

- 회귀분석 모형 전체 유의성 검정
- 특정 회귀항 검정
- 평균의 동질성 검정 _ 두 집단 분산이 동일 한지 여부 검정
- 여러 모형의 적합성 비교

$$F^*(1, n-2) = \frac{\beta^2 \sum (X_i - \bar{X})^2}{MSE} = \frac{\hat{\beta}^2}{s^2(\hat{\beta})} = \left(\frac{\hat{\beta}}{s(\hat{\beta})} \right)^2 = t^2(n-2)$$

t검정과 F 검정

구분	t 검정	F 검정
분포	• t분포 사용	• F 분포 사용
자료	• 범주형 자료 집단 2개	• 범주형 자료 집단 3개
검정방식	• 두 집단 평균차이가 통계적으로 유의여부 검증 방식	• 분산차이 가 통계적으로 유의여부 검증 방식
사용	• 모집단 분산이나 표준편차를 알지 못할 때 사용	• t 검정을 이용해 반복된 비교를 했을 때 발생하는 오류를 배제 할 수 있다.
값(value)	• t값이 커야 하고 • 표준오차(s.e) 값이 작아야 하며 • 표본크기가 충분해야 함.	• F 값이 클수록 유의
표본	• 단일표본, 독립표본, 대응표본	• 독립변수에 따라 N원 분산분석
가설	• H_0 : 두 집단 간의 평균차이는 없다 • H_1 : 두 집단 간의 평균차이는 있다	• H_0 : 집단 간 분산이 동일하다. • H_1 : 집단 간 분산이 다르다.
유의사항	• 집단간 상호작용을 고려하지 않는 경우 3개 집단이라도 t검정 활용	• F검정으로 통계적 유의하더라도 어떤 집단 간의 차이 인지를 분명하게 확인하기 위하여는 사후 검정 필요 (Scheffe, Turkey)

4. Chi-squared test

카이제곱 검정(chi-squared test)

모분산 검정을 위한 가설 형태

- 모분산에 대한 가설을 검정하기 위해서는 카이제곱(χ^2) 분포를 이용 : 카이제곱분포는 Z 제곱에 대한 분포

- 명목형인 두 변수 (성별, 나이 등) 간의 연관성에 대한 검증 분석에 활용
- 관찰 빈도가 기대 빈도와 의미 있게 차이 여부를 검정하기 위해 사용하는 검정 방법 (카이제곱 검정 목적)
- 독립변수와 종속변수 (반응변수) 모두 명목형 변수 간의 연관성 분석에 활용

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} \sim \chi^2_{(k-1)} = \frac{(\text{관측빈도} - \text{기대빈도})^2}{\text{기대빈도}}$$

- 관측빈도 : 자료(data)에서 얻어지는 빈도
- 기대빈도 : 기대수치(통상)

자유도(df)=k(범주수) -1

→ 분모의 값을 표준편차로 나누어야 논리적으로 맞으나, 기대값(기대빈도)로 나누므로 자유도가 1개 낮은 카이제곱분포를 따른다.

카이제곱 검정을 위한 전제 (가정)

- 1) 연구가설의 종속변수는 범주형 자료이어야 한다. 만약, 비율, 등간척도인 경우 범주형자료로 변환 필요 (예시) 연소득자료가 있으면 이를 고소득, 저소득 으로 구분, 학생 시험성적을 학점으로 구분
- 2) 빈도표에서 각 칸의 빈도들은 서로 독립적이다.

4. Chi-squared test

카이제곱 검정(chi-squared test)

검정 대상

1. 적합도 검정 (goodness of fit test)

: 표본을 대상을 조사하는데 이 여기서 나온 통계량이 모집단을 대표하는 지 여부, 관찰된 빈도가 모집단이 기대값과 동일한지 여부

→ 관측값들이 어떤 이론적 분포를 따르고 있는지를 검정. 한 개의 요인을 대상으로 함

2. 동질성 검정 (homogeneity test)

두 집단 분포가 동질성 여부

관측값들이 정해진 범주 내에서 서로 비슷하게 나타나고 있는지를 검정.

3. 독립성 검정 (test for independence)

변수(feature)가 두 개 이상일 때 사용되며, 기대빈도는 '독립적'이라고 기대하는 것을 의미한다.

서로 다른 요인들에 의해 분할되어 있는 경우 그 요인들이 관찰값에 영향을 주고 있는지 아닌지, 요인들이 서로 연관이 있는지 없는지를 검정. 두 개의 요인을 대상으로 함.

- 귀무가설 H_0 : 두 변수는 독립이다. (두 변수간 무관하다)
- 대립가설 H_1 : 두 변수는 독립이 아니다.

4. Chi-squared test

카이제곱 검정(chi-squared test)

모분산 검정을 위한 가설 형태

- 모분산에 대한 가설을 검정하기 위해서는 카이제곱 분포를 이용 : 카이제곱분포는 Z 제곱에 대한 분포

가설검정

- 양측검정 : $H_0 : \sigma^2 = \sigma_0^2$, $H_1 : \sigma^2 \neq \sigma_0^2$
- 좌측검정 : $H_0 : \sigma^2 \geq \sigma_0^2$, $H_1 : \sigma^2 < \sigma_0^2$
- 우측검정 : $H_0 : \sigma^2 \leq \sigma_0^2$, $H_1 : \sigma^2 > \sigma_0^2$

검정통계량

모분산 검정을 위한 검정통계량

- 검정통계량은 카이제곱 변수로 전환하는 식에 표본의 정보를 대입하여 계산
- 주어진 임계치와 비교하여 검정통계량의 값이 더 멀리 나타나면 귀무가설을 기각
- 검정통계량의 분포 : 자유도 (n-1)인 카이제곱 분포

$$\chi^2 = \frac{(n-1) s^2}{\sigma_0^2}$$

기각역

- 양측검정 $H_1 : \sigma^2 \neq \sigma_0^2 \rightarrow R : x^2 \geq x_{\alpha/2}^2 (n-1)$, $x^2 \leq x_{\alpha/2}^2 (n-1)$
- 좌측검정 $H_0 : \sigma^2 < \sigma_0^2$, $R : x^2 \leq x_{\alpha}^2 (n-1)$
- 우측검정 $H_0 : \sigma^2 > \sigma_0^2 \rightarrow R : x^2 \geq x_{\alpha}^2 (n-1)$

- p-값이 유의수준(α) 0.05인 경우
- P 값 > 0.05 귀무가설 기각 못함. , p 값 < 0.05 귀무가설 기각, 대립가설 채택

4. Chi-squared test

카이제곱 검정(chi-squared test)

카이제곱분포를 활용한 신뢰구간 검정 및 추론 방법

신뢰수준($1-\alpha$) 라고 하면 신뢰구간

모분산의 $100(1-\alpha)\%$ 의 신뢰구간

모표준편차는 모분산의 제곱근이므로
모분산 신뢰구간에 제곱근

모표준편차가 σ 인 모집단으로부터 추출한 표본의 표준편차 추정량

σ 에 대한 $100(1-\alpha)\%$ 의 신뢰구간:

$$\chi^2 = \frac{(n-1)s^2}{\sigma_0^2}$$

$$P(\chi_{1-\alpha/2}^2(n-1) < \frac{(n-1)s^2}{\sigma^2} < \chi_{\alpha/2}^2(n-1)) = 1 - \alpha$$

$$P(\frac{(n-1)s^2}{\chi_{\alpha/2}^2(n-1)} < \sigma^2 < \frac{(n-1)s^2}{\chi_{1-\alpha/2}^2(n-1)}) = 1 - \alpha$$

$$(\frac{(n-1)s^2}{\chi_{\alpha/2}^2(n-1)}, \frac{(n-1)s^2}{\chi_{1-\alpha/2}^2(n-1)})$$

$$(s\sqrt{\frac{(n-1)}{\chi_{\alpha/2}^2(n-1)}}, s\sqrt{\frac{(n-1)}{\chi_{1-\alpha/2}^2(n-1)}})$$

$$s = \sqrt{\frac{\sum (X_i - \bar{X})^2}{n-1}}$$

$$(s\sqrt{\frac{(n-1)}{\chi_{\alpha/2}^2(n-1)}}, s\sqrt{\frac{(n-1)}{\chi_{1-\alpha/2}^2(n-1)}})$$

- 양측검정 $H_1 : \sigma^2 \neq \sigma_0^2 \rightarrow R : x^2 \geq x_{\alpha/2}^2(n-1), x^2 \leq x_{\alpha/2}^2(n-1)$
- 좌측검정 $H_0 : \sigma^2 < \sigma_0^2, R : x^2 \leq x_{\alpha}^2(n-1)$
- 우측검정 $H_0 : \sigma^2 > \sigma_0^2 \rightarrow R : x^2 \geq x_{\alpha}^2(n-1)$

* Statistical analysis

모수적 방법 (Parametric Test)

- 중심극한정리에 의해서 본래의 분포에 상관없이 무작위로 복원 추출된 연속형 자료의 평균의 분포는 정규분포를 가정
- 비교하고자 하는 두집단이 모두 정규분포를 보이는 경우 그 두 집단은 **평균**을 비교함으로써 차이 비교

모수적 통계의 3가지 전제조건

- 정규성(Normality)
- 등분산성(Equal Variance)
- 독립성(Independence)

-변인은 등간척도나 비율척도로 측정 가능

→이 조건이 충족되지 않으면 비모수 통계를 사용해야 함.

모수 검정방법의 사용 예

- 사용 예
 - 모평균과 표본평균의 차이
 - z분포, t분포
 - 모분산과 표본분산과의 차이
 - F분포, 카이제곱분포
- 모집단의 평균에 대한 검정
 - 표본집단의 크기가 $n > 30$ 이면 정규분포로 가정하여 z분포를 이용
 - 표본이 30이하면 t분포 이용, 이때 자유도를 고려함

비모수적 방법(Non-parametric test)

- 모집단의 분포 유형에 관계없이 적용할 수 있는 방법
- 1945년 Wilcoxon 검정이 효시
- 비모수통계학(Nonparametric Statistics)은 모집단에 대한 가정이 필요 없고, 표본크기가 작을 경우에는 계산이 복잡하지 않다는 장점

- 검정통계량의 신뢰성이 부족함.

비모수적 통계(검정)의 전제조건

- 정규성 검정에서 정규분포를 따르지 않을 경우
- 표본 data가 작은 경우 정규성을 확보가 어려운 경우
- 모집단이 정규분포한다는 가정을 할 수 없는 경우
- 모집단의 분포 유형에 관계없이 적용
- 변수가 명목척도나 서열척도로 측정하는 경우
- 추정, 분산분석(Analysis of Variance: ANOVA), 회귀분석, 시계열분석 등에 응용

(비모수 검정의 사례)

- 부호검정(Sign test)
- 윌콕슨의 순위합 검정 Mann-Whitney U 검정
- 윌콕슨의 부호순위합검정
- kolmogorov-smirnov test
- 스피어만의 순위 상관계수

Parametric Test & Non-parametric test

shapiro wilk 검정

정규성이 확보(0)

모수적방법 : t test검정 또는 ANOVA

정규성이 확보(x)

비모수방법 : wilcoxin rank sum test

샘플의 수가 적을 때 정규성을 확인하는 검정법

일반적 : kolmogorov는 샘플이 50개 이상인 경우 shapiro는 샘플이 50개 미만인 경우 사용

구분	모수적방법	비모수적방법
사용	검정의 가정을 만족하는 경우 (주로 모집단의 정규성)	- 정규성이 만족하지 않을 가능성이 있는 경우 순위 데이터 - 표본수가 아주 적을 때 t검정이나 ANOVA를 대신하여 사용하는 통계 방법 - 부호검정(sign.test): - 모집단의 중앙값에 대한 가설 검정
통계량	평균값 비교	중위수 비교
검정(2집단)	t test	wilcoxon rank sum test
3집단	ANOVA	Kruskall-Wallis Test

* Non-parametric test

1. 변수간 확률분포 동질성 검정

통계수치 참조

<https://kr.mathworks.com/help/stats/ranksum.html>

두 개 이상의 변수값들이 이루는 확률분포의 동일여부를 검정하는 방법

구분	내용
부호검정(Sign test)	: 모집단의 중앙값에 대한 검정으로 관찰된 표본 중에서 중앙값 을 초과하는 값이 몇 개인지를 파악 하며, 모평균과 모중앙 값은 분포의 위치를 나타내는 모수으로써 분포의 형태가 대칭이면 두 모수는 일치한다.
윌콕슨 순위-합 검정 (Wilcoxon Rank-Sum Test, Mann-Whitney U-test)	독립된 두 집단의 비교검정 → 모수적 검정인 t-test : 모수인 평균 을 가지고 검정하는 방법 → 윌콕슨 순위-합 검정 : 비모수인 중앙값(Median) 을 가지고 검정하는 방법 검정결과 p-value < 0.05 이면 대립가설 채택 → 두 집단 간 중위수 값에 차이가 있다.
윌콕슨 부호-순위 검정 (Wilcoxon Signed Rank Test)	대응표본(paired sample)인 경우 그룹 간 중심의 차이에 대한 검정법 → 두 집단 간 전과 후의 중앙값 차이가 있는지 여부를 판단하는 검정법 → 검정결과 값 p-value < 0.05 대립가설 채택 → 전(before group)과 후(after group)의 차이가 있다고 할 수 있다.
크루스칼-왈리스 검정 (Kruskall-Wallis Test)	▪ 세 그룹 이상이 차이를 비교할 수 있는 검정법 ▪ ANOVA의 비모수 버전으로 윌콕슨 순위-합 검정(Mann-Whitney U-test)은 비모수 검정버전으로 이해하면 됨.
맥네마르 검정(Mc Nemar test)	▪ 이항변수로 되어 있는 두 변수간의 분포차이를 검정할 때 이용
코크란 Q(Cochran Q test)	▪ 이항변수로 되어 있는 3개 이상의 변수간 비율차이를 검정하는 방법 ▪ 맥네마르 검정의 확장
프리드만 검정(Friedman test)	▪ 3개 이상의 변수들의 평균순위에 차이가 있는지의 여부를 검정하는 경우에 이용
켄달의 검정(Kendall test)	▪ 순위자료로 측정된 2개 이상의 변수값들이 동일 모집단에서 추출되었는지의 여부를 검정하는 방법

* Non-parametric test

2. 적합도 검정

모집단이 일정한 확률분포 형태를 갖는다고 가정할 경우 표본에서 얻어진 분포가 모집단에서 가정하고 있는 분포에 적합여부를 판단하고자 검정하는 방법

구분	내용
카이스퀘어(chi square) 검정	한 표본의 값에 대한 실제빈도가 기대빈도와 일치하는지 검정할 때 이용
이항분포 검정	이항변수의 각 관찰치가 기대도수와 일치하는지 또는 실제확률이 기대확률과 일치하는지를 검정하는 방법
단일표본 콜모고로프-스미르노프 검정 (kolmogorov-smirnov test)	- 주어진 어떤 표본의 분포가 이론적으로 기대되는 분포, 예를 들면 정규분포, 균일분포, 포아송분포와 일치하는지 여부를 검정할 때 이용 - 모수적 통계분석이 주어진 자료가 정규분포를 따른다는 것을 가정하기 때문에 콜모고로프 스미르노프 검정은 정규분포와 관련된 모수적 통계분석 제약조건인 자료의 정규성을 검정하는데 유용하게 이용

3. 변수간의 상관관계분석

구분	내용
스피어만 순위상관분석 (Spearman test)	순위자료를 이용하여 변수간의 상관정도를 분석하는 방법
교차분석(cross analysis)	명목척도로 측정된 자료를 이용하여 두 변수간의 상호독립성을 검정함으로써 두 변수의 도수분포상의 상관정도를 검정