

빅데이터를 활용한 디지털금융전문가 과정

부실예측모형연구 3.1

(Statistics Analysis. Machine Learning)

Statistical Analysis / Machine Learning

1. Statistics Analysis : Review

2. Data Set Issue

- Data Preprocessing : Missing Value, Outlier
- Data Conversion : MinMax, Standard....
- Resampling : Under , Over

3. Modelling Issue

- Bias vs Variance : Trade off
- Cross Validation

Statistical Analysis / Machine Learning

통계모형:

M.L

샘플자료

자료를 분석을 통해 인과관계 등을 설명하고 이해하는데 초점

-사람들이 그 영화를 좋아하는 이유를 찾기 위해 노력
정확한 숫자 예측보다는 왜 병원 가? 분석
독감 발생을 예측할 수 있는 요인을 분석하는 게 중요

모든 자료

데이터를 통해서 **예측(Prediction)**에 활용 : 영화 평가 예측의 정확성

: 내년에 병원에 갈 사람 숫자 예측
: 독감 발생 가능성 예측

확률모형 기반

데이터와 알고리즘 기반

- **통계모형** : 확률모형 기반 추정 ⑦ 가설검정 : 결과에 대한 **설명**이 주 목적
- **머신러닝** : 분류(Classification) 군집분석(Cluster Analysis), 예측.회귀(Regression) 등의 기술, 모델과 알고리즘을 이용하여 문제를 해결하려는 것을 컴퓨터 과학의 관점에서 바라보는 것. ⑦ 결과의 **예측**이 목적
- **인공지능 방법론** : 통계, 예측분석, 머신러닝, 딥러닝, 자연어 처리 등 과학적이고 복합적인 활용(Artificial Intelligence A Modern Approach)

통계모형

ML

모수 (parameter)
독립변수(설명변수, X), 종속변수(반응변수, Y)

가중치(weights) 특성
(Feature), LABEL

추론(추정, 가설검정), 적합(fitting)

학습(Learning)

모형평가 : 적합도, 유의성
(목적) 설명력을 중점으로 한 인과모델

(목적) 예측력 평가
제한된 설명력

회귀분석, 분류분석/ 군집분석, 연관분석
⑦ **전형적으로 선형**

지도학습(Supervised Learning)/비지도학습
⑦ **비선형**

모형구조 : 데이터=생성구조 + 오차
(오차항은 특정확률분포를 가정)

오차가 중요문제 아님

Statistical Analysis : Process



문제의 제기	분석하고자 하는 문제 정의를 명확히 한다..
모집단 정의	모집단 정의 : 문제제기에 의해 관심대상인 모집단 정의
표본 추출	모집단을 가장 잘 대표하는 표본을 임의추출법으로 뽑아 표본을 구한다. 편향 고려
Data 수집	표본으로 부터 실제 관측을 통해 자료를 얻는다.
Data 전처리	- 데이터 정제 수행 (결측치, 이상치 등) 산점도 - 필요시 데이터 변환, 데이터 스케일링 - 시각화 : 기초통계량 (집단 간), box plot, Violin plot, RADAR chart, Pie chart
통계분석	- 자료를 각종 통계분석을 실시하여 정보화 한다. - 모수 추정 : 통계는 모집단을 대상으로 하지 않고 표본을 대상으로 분석하는 것이므로, 표본의 분석을 통해 모집단의 모수를 추정할 수 있는 좋은 자료가 뒷받침 되어야 한다. - 검정통계량 (표본) ⑦ 통계적 유의성? ⑦ 통계조사의 목적은 연구자의 주장이 실제로 옳은지? 아닌지? 를 확인 하는 것
최종 의사결정	(6) 의사결정 : 분석된 정보를 근거로 의사결정의 행동 및 조치를 취한다.

Review : Sample


관측 전체수 (N)
모평균(μ) 모표준편차(σ) 모분산(σ^2)

Z - test

- Z분포 (표준정규분포)사용

$$z\text{-value} = \frac{X - \mu}{\sigma}$$

집단간 평균차이 검정
Z-검정, t-검정, ANOVA



표본 수(n)
표본평균($\bar{X}$) 표본표준편차(s)
표본분산(s^2)

t - test

- 대부분
- t분포 사용
- n커지면 t분포는 표준정규분포

$$t\text{-value} = \frac{\bar{X}_A - \bar{X}_B}{\frac{s}{\sqrt{n}}}$$

집단간 평균 차이를 다시 표준편차와 비교

- 두 집단의 평균 차이를 표준오차(표본평균의 표준편차)와 비교하는 것!!
- 집단간 차이가 없는지? (귀무가설 H_0) 집단간 차이가 있는지? (대립가설 H_1)를 알아봐야 한다.
- 0 을 기준으로 95% 내에 두 집단 평균차이가 존재하면 차이는 우연히 발생한 것이므로 집단간 차이가 없는 것 (귀무가설 기각 못함)
- 얼마 정도 평균 차이가 있을 때 유의한가?

: 두 집단 평균 차이가 표준편차 보다 매우 작으면 평균 차이 가 거의 없으므로 우연히 발생한 것!

- ⑦ 두 집단 간 평균 차이가 없다(귀무가설 기각 못함)

: 두 집단 평균 차이가 표준편차 보다 매우 크면 차이가 있으므로, 우연히 발생한 것이 아니라는 판단

Review : Data type

1. 이산형 (discrete) 데이터 vs 연속형 (continuous) 데이터

- 이산형 (discrete) 데이터 : 변수가 취할 수 있는 값을 하나하나 셀 수 있음
- 연속형 (continuous) 데이터 : 변수가 구간 안의 모든 값을 가질 수 있는 경우 (중량, 길이 등)

2. 척도 : 관측대상에 대한 특성을 수량화하기 위해 규칙이나 단위를 가지고 숫자로 부여하는 것, 바꿔 말해 질적data를 양적 data로 변환시키는데 사용하는 도구

구분		내용	사례	통계방법
수치형자료/양적 척도 / 수치형 (numerical)자료 (연속형변수)	비율척도	• 수치가 크기의 차이 뿐 아니라, 그 비율까지 나타내 주는 것 • 하나의 측정치가 다른 측정치의 몇 배가 되느냐 하는 비율의 정보를 가르쳐 줄 수 있는 척도 • 명목,서열, 등간척도에 대한 정보 포함 • 동간성, 절대영점을 갖추고 있어 가감승제가 가능해 통계적 조작이 가능	원점수를 가공해서 얻은 표준점수인 Z점수, T점수 IQ검사의 원점수를 가공해서 얻은 편차 IQ 등	모수통계 (피어슨상관분석)
	등간척도 (간격 척도)	• 측정대상이 갖고 있는 속성의 양을 측정하는 것으로 구간사이의 간격이 의미가 있는 자료 • 순위를 부여하되 순위 사이의 간격이 동일하여 양적인 비교 가능	온도 선호도 : 점수화 한 경우 리커트 척도	모수통계 (피어슨상관분석)
범주형자료/질적 척도 (qualitative) / 숫자들의 크기 차이가 계산되지 않는 척도 수학적 연산 결과는 의미가 없다. (이산형변수)	명목척도	• 측정 대상이 어느 집단에 속하는지 분류할 때 사용 • 단순히 측정 대상의 특성을 분류하거나 확인하기 위한 목적으로 숫자 부여 • 범주별 상호배타적 (한 그룹에만 속함)	▪성별(남자=1, 여자=2) ▪1학년, 2학년, 3학년 ▪혈액형 ▪출생지역 ▪자동차 브랜드명	비모수통계 교차분석 빈도분석
	서열척도	• 크기나 중요성에 기준하여 측정결과에 순위를 부여 • 명명척도 분류기능에 순위를 나타내는 것을 추가 한 것 • 척도가 나타내고 있는 속성이 정확하게 얼마나 되느냐는 정보는 알려 주지 못함.	학급석차 키순서 신용등급 내신등급	비모수통계 스 피어만상관분석
명명(命名)척도		어떤 사물을 지칭하거나 분류하기 위해 부여한 임의의 수치나 기호	우편번호, 학생 학번	

Review : Data type

구분	내용
시계열자료 (Time Series data)	일정 시간 간격(일별, 주별, 월별, 분기별, 연도별 등) 으로 수집된 데이터들의 수열 -거시경제변수를 측정한 자료에서 많이 발생 -시계열 분석(time series analysis) : 시계열을 해석하고 이해하는 데 쓰이는 여러 가지 방법을 연구하는 분야 -일반적으로 공학이나 과학계산, 주가 예측 등에서 사용
횡단면자료 (Cross-Sectional data)	특정한 일정 시점에서 여러 대상을 통해 수집된 자료
종단면자료(longitudinal data)	여러 개체를 여러 시점에서 관측된 자료
패널자료Panel data	▪ 횡단면 자료와 시계열 자료가 혼합된 형태 ▪ 여러 시점에 대해 관측된 여러 변수의 자료가 모두 존재하는 경우 ▪ 종단면자료(longitudinal data) 중에서도 관측시점이 여러 개체에 대해 모두 동일하게 맞춰져 있으면 패널자료(panel data)라고 한다. ▪ 금융데이터분석에서 연구자들은 패널자료를 이용하여 분석

Review : Hypothesis test

1. 통계적 가설검정 (statistical hypothesis)이란?

- 통계학에서 표본을 통해서 모수를 추정하는 것을 추론이라고 함.
- '모수가 어떠할 것이다'라는 가설을 세우고 그 가정이 맞는지에 대한 확인 과정도 추론 ⑦ 가설검정이라고 한다.
- 가설검정은 일정 유의수준 하에서 주장이나 추측이 일정 신뢰구간에 포함될지의 여부를 판단하는 것
- ⑦ 두 개의 가설 (귀무가설, 대립가설) 을 설정하고, 두 가설 중 어느 가설이 적합한지 파악하는 것

2. 가설 유형

- 귀무가설 (Null hypothesis : H_0)** : 차이 또는 유의성이 없음을 나타내는 가설. 기존의 가설
(초능력은 없다, 피고인이 무죄이다)
- 대립가설 (Alternative hypothesis : H_1)** : 관심이 있는 사건에 유의성이 있음을 나타내는 가설, 연구자가 밝히고자 하는 주장
(초능력이 있다, 피고인이 유죄이다)
- 가설을 세우고 가설을 입증하기 위한 데이터를 수집하고 가설검정에 적합한 도구인 검정통계량을 구한 후 귀무가설하의 검정통계량의 분포와 비교하여 유의수준을 고려하여 최종판단을 하게 된다.

3. 통계적 의사결정 원리

- 확실한 근거가 있기 전에는 H_1 을 선택하지 않고 H_0 을 받아들인다.
- H_1 채택을 위해서는 H_0 을 기각 할 수 있어야 한다. ⑦ H_1 이 참이라는 확실한 근거가 있음
⑦ 확률 값(p-value) < 유의수준 (통상 0.05) ⑦ H_0 reject, H_1 accept. 이를 통계적으로 '유의성이 있다'고 표현한다.
⑦ 확률 값(p-value) > 유의수준 : H_0 을 기각시키지 못한다. 즉, H_1 이 참이라는 확실한 근거는 없는 것이다.


Review : Hypothesis test

4. 가설 설정(검정 방법)

양측검정

H_0 을 기각하는 영역이 양쪽에 있는 검정으로 H_1 이 000가 아니다. 크거나 작다 인 경우 양측검정을 사용


- 귀무가설 (H_0) : 두 집단간 차이가 없다(두 집단 평균차이 = 0)
- 대립가설 (H_1) : 두 집단간 차이가 있다(두 집단 평균차이 $\neq 0$)



단측검정


우측검정

- H_0 을 기각하는 영역이 오른쪽에 있는 검정
- H_1 이 000 보다 크다 인 경우
- 귀무가설 (H_0) : 기존 알려진 사실과 동일하다.
- 대립가설 (H_1) : 기존 알려진 사실보다 크다.



좌측검정

- H_0 을 기각하는 영역이 왼쪽에 있는 검정
- H_1 이 000 보다 작다 인 경우
- 귀무가설 (H_0) : 기존 알려진 사실과 동일하다.
- 대립가설 (H_1) : 기존 알려진 사실보다 작다.



유의수준 = 0.05 경우

양측검정이나, 단측검정이나 95% 안에 두 집단 평균차이 값이 오면 두 집단의 차이는 우연히 발생한 것이므로

통계적으로는 두 집단간 평균 차이는 없다. = 평균차이는 통계적으로 유의하지 않다고 해석한다.

Review : Hypothesis test

4. 가설 설정(검정 방법)

신뢰수준 (1- α)

- 가설을 검정할 때 얼마나 정확도 높게 검정할 것인지를 결정하는 수준
- 신뢰구간 : 신뢰수준에 포함되는 x값 구간 : 일반적으로는 95% 신뢰수준을 사용

유의수준 (α)

- 가설을 검정할 때 이 정도까지 벗어나면 귀무가설이 오류라고 인정하겠다 하는 최대 허용 수준 ● 유의수준 = 1 - 신뢰수준(Confidence level), ● 통상 α



5. 검정통계량과 기각역

1) 검정 통계량 (test Statistic)

- 통계적 가설을 검정하기 위한 기준으로 사용되는 통계량 (대표적 사례: t-value)
- 통계량이므로 확률표본의 함수
- 귀무가설과 대립가설 중에서 하나의 가설을 선택하는데 사용하는 표본 통계량

2) 기각역/채택역

- 확률분포에서 귀무가설을 기각되는 검정통계량의 값이 포함된 영역
- 검정통계량 절대값 > 임계치 : 기각역 ● 귀무가설을 기각, 대립가설 채택
- 검정통계량 절대값 < 임계치 : 채택역 ● 귀무가설을 채택 (기각 못함)
- 양측검정인 경우 : 기각역은 (유의수준= α) / 2, 만약 유의수준=0.05이면 0.025
- 단측검정인 경우 기각역은 유의수준과 같다. (기각역 면적(합)은 유의수준과 동일)
- 기각역 또는 채택역은 유의수준을 어떻게 정하느냐에 따라 달라진다. (보통 0.05)

3) 임계치 (critical value, threshold value)

- 주어진 유의수준에서 귀무가설의 채택과 기각에 관련된 의사결정을 할 때 그 기준이 되는 값
- 표준정규분포표에서 자유도 (n-1)에 유의수준에 해당하는 값.

$$\text{검정 통계량} \\ t\text{-value} = \frac{\bar{X}_A - \bar{X}_B}{\frac{s}{\sqrt{n}}}$$

Review : Hypothesis test

6. 유의확률 (probability-value : p - value , p 값)


P값(p-value) : p값은 계산된 검정통계량(t-value)에 의해 구해지는 확률 ⑦ '확률'로 유의성을 점검할 수 있는 지표

- p-값 : 귀무가설이 참이라는 가정에 따라 주어진 표본 데이터를 희소 또는 극한값으로 얻을 확률값 p-값
- 어떠한 sample data로부터 온 결과가 우연히 일어났을 확률을 의미 (0% ~ 100%)

검정통계량(t-value) 값에 해당하는 p- value도 하나의 값을 갖는다.

t- value와 자유도(Degrees of Freedom_을 이용하여, 해당하는 p value를 T distribution table에서 찾을 수 있다.

⑦ 그러나 우리에게는 python



통계적 유의성 판단

- $p - value < \text{유의수준}(0.05)$: 귀무가설 기각하고 대립가설 채택 ⑦ 연구자의 주장(대립가설)이 통계적으로 유의하다.

(유의하다 : 의미를 갖는다. 회귀분석에서는 인과관계가 있다, $(x \rightarrow y)$ 즉 우연히 발생할 가능성이 5% 미만이다.

결국 주장하고자 하는 것을 신뢰할 수 있는 의미있는 확률이 95% 보다 크므로 대립가설 주장을 받아 들일 수 있는 것!!!!)

- $p - value > \text{유의수준}(0.05)$: 귀무가설 기각하지 못함

Review : Hypothesis test

7. 제1종 오류와 제2종 오류

구분	내용
통계적 오류 (statistical error):	오차가 무작위적이며 예측할 수 없는 변동에 의해 생기는 오류
	제1종 오류 (type I error) - 귀무가설이 참 인데 기각하여 오류를 범하는 확률 α error 라고도 한다. - 유의수준(significant level) : 제1종 오류를 범할 최대 허용 한계 (0.05, 0.01) 상수 값
	제2종 오류 (type II error) - 귀무가설이 거짓인데 채택하는 오류 β error 라고도 한다.
	검정력 (statistical power) - 대립가설이 사실일 때, 이를 사실로서 결정할 확률 - 검정력이 95%라고 하면, 대립가설이 사실임에도 불구하고 귀무가설을 채택할 확률 (2종 오류, β error)의 확률은 5%이다. - 검정력이 좋아지게 되면, 2종 오류(β error)를 범할 확률은 작아지게 된다. 검정력은 $1-\beta$ 로 표시된다.
시스템적 오류 (systematic error)	오차가 시스템 상의 잘못으로 인한 것

실제 통계 결정	H_0 참	H_0 거짓
H_0 채택	옳은 결정	제2종 오류 (β)
H_0 기각	제1종 오류 (α)	옳은 결정 (검정력 = $1 - \beta$)

1928년에 [유니버시티 칼리지 런던](#)에 근무하던 통계학자 [에르지 네이만](#), [피어슨](#)은 특정한 표본이 모집단으로부터 무작위로 골라졌는지를 판단할 수 있는가에 대한 판정의 문제를 논의

* Degree of Freedom

자유도(degree of freedom : df) 정의

표본으로 모집단을 통계적 추정을 할 때 표본자료 중 모집단에 대한 정보를 주는 독립적인 자료의 수
(예시) 10개의 값으로 이뤄진 표본에서 평균과 9개의 값을 알고있는 경우

⑦ 10번째 값은 정해 짐, 결국 자유도는 $n-1$, $10-1 = 9$ 가 된다.

추정해야 할 미지수의 개수를 내가 가진 정보(n)의 수에서 뺀 값이라고도 정의 함

자유도 수

1) 단순회귀분석에서의 회귀계수 검정을 위한 t-검정의 경우

: SSE는 절편 α 와 회귀계수(기울기) β 2개 값이 추정되기 때문에 $(n-2)$, SSR : 1개 ⑦ SST : $(n-1)$

2) 다중회귀분석에서 : SSE : 자유도 $n-k-1$ (k : 독립변수의 개수), SSR : k 개, ⑦ SST : $(n-1)$

3) ANOVA(일원 [분산분석](#))

그룹간 자유도 = $(k-1)$ 그룹내 자유도 = $(n-k)$ 총 자유도 = $(n-1)$ n : 표본의 수, k : 표본 평균의 수

자유도가 필요한 이유는?

표본 평균은?

모집단에서 표본을 추출하면 표본평균은 모집단의 평균 보다 클 수도 있고 적을 수도 있으나,
그 가능성은 공평 (= 불편 추정),

표본분산은?

표본분산은 모집단의 분산보다 항상 작아지는 경향을 보인다(= 편향성)

⑦ 따라서 표본의 분산을 모집단의 분산에 근사해지게 하는 비율을 찾게 되었다. 이 비율은 $n/(n-1)$ 이고, 표본의 분산에 이 비율을 곱하면 모집단의 분산에 근사하게 된다.

$$\text{모분산 } \sigma^2 = \frac{\sigma(x_i - \mu)^2}{n} \text{ 에 비율 } n/(n-1) \text{ 곱하면}$$

$$s^2 = \frac{\sigma(x_i - \bar{x})^2}{n-1}$$

EDA (Exploratory Data Analysis)

Garbage in Garbage out

데이터 유형에 맞는 적합한 모델링을 위한 전 단계

- Data 종류 확인
- 변수의 분포를 확인 : 시각화 (Box plot, Violin Plot ..)
- 데이터 이상치, 결측치 등
- 데이터 스케일링
- 피처 후보군 ⑦ Feature 선정방법 ⑦ 최종 피처 선정
- 분포의 그룹 비교
- 변수간 선형관계(상관관계) 존재 여부 : 변수 갯수 변화에 따른 변화 고려
- 기존변수 집합을 사용해 특징을 생성 가능 여부 : 파생변수 (변동성, 현금흐름)
- 기초 통계량 :
 - 수치형 변수 : `df. Describe().transpose().round(2)`
 - 범주형 변수: `df. describe(include=object'). transpose()`

Data preprocessing / Feature Engineering

1. Feature Engineering ?

: 해결하고자 하는 문제를 컴퓨터가 잘 이해할 수 있도록 **변수(피처)들의 형태를 변형하거나 적절하게 처리하는** 과정

2. 피처 엔지니어링 방법

1) 수치형 데이터

구분	경우	처리방법
결측값 (missing value)	데이터에 값이 없는 경우	- 대체값 입력 : 평균(mean)값, 중앙값(median), 최빈값(mode) - 삭제 : 결측값이 너무 많은 피처의 경우 삭제(drop) , 해당 데이터를 삭제 - kNN imputation과 같은 머신러닝(ML) 기법으로 데이터셋의 다른 피처들을 입력값으로 결측값을 예측해 채우는 방식으로 처리
이상값 (outlier)	존재할 수 없는 값이 포함된 경우	이상값을 판단하는 데 많이 사용하는 방법인 '상자그림(box plot)'이용 이상값을 찾는 방법 winsorizing : 상.하한값을 벗어나는 양쪽 꼬리 값을 상.하한값으로 조정 (1%, ...) - 절단 (trimming) - 극한값을 더 작은 값으로 대체하는 것 --이상치들을 변수별로 분포상 누적확률 0.01, 0.99에 해당하는 값들로 변환 ⑦ 즉, 극한값의 영향을 줄임으로써 기존의 통계로도 충분히 해석할 수 있게 해주는 것
비닝 (binning)	데이터를 n개의 빈(bin)으로 나누어 담는 것	비닝(binning)은 피처의 데이터의 비슷한 값들을 새로운 그룹으로 묶어 연산하기 때문에 데이터가 적은 관찰값들이 무시되는 것을 막고 모델의 성능을 높일 수 있다. ★ 연속변수의 이산화(bin) : 연속변수를 유한 개수의 빈(bin)으로 변화 ⑦ (사례) 특정 개수의 빈 (pd.cut) , 사분위수를 기준으로 분할 (pd.qcut)

Data preprocessing / Feature Engineering

2. 피처 엔지니어링 방법

2) 명목형 데이터

(1) 레이블 인코딩

문자열 데이터를 수치로 표현하는 방식

⑦ patsy 패키지 이용 : `from patsy import dmatrix`

- 각 범주(category)를 0부터 $k-1$ 까지의 정수로 매핑

구분	내용
풀랭크(full-rank) 방식	예) 여자 female : 0, 남자 male : 1로 표현 ⑦ d_1, d_2 ⑦ X가 남자인 경우 ($d_1 = 1, d_2 = 0$), X가 여자인 경우 ($d_1 = 0, d_2 = 1$) 예) 혈액형 A, B, AB, O형 4가지. ⑦ d_1, d_2, d_3, d_4 ⑦ X가 A형 ($d_1 = 1, d_2 = 0, d_3 = 0, d_4 = 0$), X가 B형 ($d_1 = 0, d_2 = 1, d_3 = 0, d_4 = 0$) ⑦ X가 AB형 ($d_1 = 0, d_2 = 0, d_3 = 1, d_4 = 0$), X가 O형 ($d_1 = 0, d_2 = 0, d_3 = 0, d_4 = 1$)
축소랭크(reduce-rank) 방식	k개의 카테고리 중 하나(보통 기준범주(reference category)를 하나) 더미 변수를 제외하여 $k-1$개의 열을 생성

(2) 원 핫 인코딩 (one-hot encoding)

▪ 더미(dummy) 변수화

- ⑦ 선택해야 하는 선택지의 개수만큼 차원을 가지면서, 각 선택지의 인덱스에 해당하는 원소에는 1, 나머지 원소에는 0의 값을 가지도록 하는 표현 방법
- 자연어처리방식에서 많이 언급되는 용어

Data preprocessing / Feature Engineering

* 풀랭크(full-rank) 방식과 축소랭크(reduced-rank) 방식의 차이

구분	풀랭크 (Full-Rank)	축소랭크 (Reduced-Rank)
열(column) 개수	카테고리 수 K 만큼 (각 범주마다 하나씩)	K-1개 (기준 범주 1개를 제외)
벡터 표현	각 범주가 독립된 0/1 열로 표현	기준 범주 제외 열들만 0/1, 제외된 범주는 모든 열이 0으로 표현
공선성(collinearity)	모든 더미의 합이 1이 되어 완전 공선성(dummy trap) 발생 가능 → 선형/로지스틱 회귀 등에서 설계행렬이 완전 공선성에 빠져 역행렬 연산 불안정 ("더미 트랩")	한 열을 뺌으로써 다중공선성 제거
회귀 모델 적용 시	설계행렬 $X'X$ 역행렬 연산 불가능해질 수 있음	역행렬 안정적, 기준 대비 계수 해석 용이
트리 계열 모델 적용 시	다중공선성이 문제되지 않으므로 그대로 사용 가능	불필요한 기준 범주 정보 손실될 수 있음
계수 해석(interpretation)	'기준'이 없으므로 개별 계수 해석 어려움	각 계수가 "기준 범주 대비 효과 크기"로 직관적 해석 가능
사용 예시	Decision Tree, Random Forest, XGBoost 등	선형 회귀, 로지스틱 회귀

언제 어떤 방식을 선택할까?

- 트리 계열 모델(Decision Tree, Random Forest, XGBoost 등) : → 풀랭크(one-hot) 인코딩이 편리
- 선형 회귀, 로지스틱 회귀, GLM 계열 → 축소랭크(dummy-drop-one) 인코딩으로 다중공선성 방지
- 딥러닝(신경망) 입력 → 보통 one-hot 후 임베딩 레이어(Embedding) 활용

Data Scaling

Data Scaling 필요성

- 설명변수의 크기와 범위, 단위가 다른 경우
 - ➔ 머신러닝 모형의 학습이 특정 변수의 영향을 과도하게 받는 경향이 있으므로 특정 변수의 영향이 지배적이지 않도록 조정할 필요
 - ⑦ 머신러닝 모형의 성능은 설명변수의 스케일(값의 크기와 범위)에 영향을 받는 것으로 알려져 있기 때문에

Data Scaling 유용성

- 다차원의 값들을 비교 분석하기 쉽게 만들어 준다.
- 메모리에 표현 범위를 초과하는 수의 값을 저장할 때 발생하는 overflow나 메모리가 표현 범위보다 작은 수의 값을 저장할 때 발생하는 underflow 방지해 줌.
- 고유값(Eigenvalue)과 관련된 독립 변수의 공분산 행렬의 조건수(Condition Number)를 감소
- 최적화 과정 안정성 수렴 속도 향상
- 기계 학습 알고리즘의 일반적인 요구 사항 : 경사하강법 (K-means, SVM, 인공신경망 등에 자주 사용되는 최적화 알고리즘). 피쳐들이 각각 다른 척도에 있는 경우
 - ⑦ 가중치 업데이트의 역할을 하기 때문에 특정 가중치(w_1)가 다른 가중치(w_2)보다 더 빨리 업데이트 될 수 있다.
 - ⑦ 반대로, 피쳐값의 범위가 비슷하면 경사하강법을 더 빠르게 동작하여 최저값으로 수렴하게 된다.

조건수(Condition Number) : argument에서의 작은 변화의 비율에 대해 함수가 얼마나 변화할 수 있는지에 대한 argument measure.

- ⑦ 만약, 조건수가 크면 약간의 오차만 있어도 해가 전혀 다른 값을 가진다.
- ⑦ 조건수가 크면 회귀분석을 사용한 예측값 오차가 커진다.

Data Scaling 시행 시기

Data 변환전에

이상치 제거 후 → 스케일링 과정

데이터를 정규화 변환을 통해 상대적 크기에 대한 영향력 감소
분석 시작

Data Scaling

StandardScaler : 표준화(standardization)

*from sklearn.preprocessing import **StandardScaler***

$$Z = \frac{X - \mu}{\sigma}$$

- 각 피쳐 값들이 평균을 기준으로 얼마나 멀리 떨어져 있는지를 표현하는 값으로 변환하는 작업
- 값의 스케일이 다른 피쳐들로 이루어진 학습데이터에서 이 스케일 차이를 없애 주는 효과
- 각 변수들의 값에서 평균값을 뺀 후 표준편차로 나누어 준 값 (평균=0, 표준편차=1)
- ⑦ 정규분포를 표준화

MinMaxScaler : 정규화(normalization) 클래스

*from sklearn.preprocessing import **MinMaxScaler***

$$x_n = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

- 각 피쳐들의 값에서 최소값을 뺀 다음 최대값과 최소값의 차이로 나누어 준 값
- 값의 범위 0과 1사이로
- variance를 감소시켜 일반화 성능을 높이는 기법
- 이 과정에서 bias가 증가 가능성 존재

RobustScaler

*from sklearn.preprocessing import **RobustScaler***

$$X' = \frac{X - \text{median}}{\text{IQR}}$$

- 중앙값(median)과 IQR(interquartile range)을 사용 ⑦→ StandardScaler와 비교해보면 표준화 후 동일한 값을 더 넓게 분포 시킨다.
- $IQR = Q3 - Q1$

MaxAbsScaler

*from sklearn.preprocessing import **MaxAbsScaler***

$$X' = \frac{X}{|X_{\max}|}$$

- 절대값이 0~1사이에 매핑되도록 한다.
- -1~1 사이로 재조정한다

Data Scaling

구분	Standardization (StandardScaler)	MinMaxScaler	RobustScaler	MaxAbsScaler
스케일링 방법	Z 값(평균,표준편차)	Min, Max	중앙값(median)과사분위범위 (IQR, Interquartile Range)를 사용하여 데이터를 정규화하는 방법	
범위	제한 하지 않음	최대값을 1 로 최소값을 0으로	StandardScaler와 비교하 면 표준화 후 동일한 값을 더 넓게 분포시키고 있음	최대절대값을 1로 0 값은 0이 되도록 스 케일링
사용	평균0, 표준편차 1로	피쳐 크기가 다른 경우		
유용	피쳐가 정규분포인 경우	분포에 모르는 경우	이상치 영향을 최소화하길 원할 때	MinMaxScaler와 유사 양수와 음수값에 따 른 대칭 분포 유지하 게 되 는 특징

★ log transformation (common log)

데이터 분석을 하기 위해 log를 취하는 이유는 정규성을 높인다.

- ⑦ 상관분석, 회귀분석, 분산분석 등의 가정에 부합을 통해 정확한 값을 얻기 위함이다.
- ⑦ 데이터 간 편차를 줄여 skewness와 Kurtosis를 줄일 수 있기 때문에 정규성이 높아진다.

Data Scaling : Q&A

1. 적절한 Scaler ??

⑦ 데이터의 분포 특징을 EDA 한 후 적절한 Scaler를 적용 !!

2. Scaling을 해야 하는 경우가 따로 있는가? (data 분포에 대한 가정 여부)

⑦ : Linear Regression , Support Vector Machine

3. Feature 모두를 Scaling 해야 하는가 ??

⑦ 특성에 따라 어떤 피쳐는 원본데이터의 분포를 유지하는 것이 유의 !!

4. Scaling은 모델 성능 향상(효과)에 항상 도움이 되는가?

▪ 거리 기반 모델의 경우(K-최근접 이웃, K-Means , 정규화가 중요한 알고리즘(예: 선형 회귀, 로지스틱 회귀, 신경망)

⑦ 유의미한 효과

▪ decision tree 기반 모델 : ?

5. Scaling은 어느 단계에서 해야 하는가?

▪ 전처리 과정에서 Data leakage 문제점을 고려해야 함.

▪ ⑦ data scaling 적용 시 test data 활용하면 data leakage 문제가 발생

⑦ feature 선택 과정을 거친 후에 선택된 특성들에 대해 스케일링을 수행

6. 훈련용데이터에 대한 스케일링 값이 테스트데이터에 스케일링에 영향을?

Data Leakage

Data leakage

학습모델링 : training data를 이용하여 학습하여 모델링 ⑦ 훈련과정에 예측 정보 data가 들어와 있다!!!

(문제점) leakage는 **model로 decision을 내리기 시작할 때까지는 정확해 보이지만**, 예측에서 새로운 data로 적용시 모델링의 성능 저하 문제가 심각해 짐.

유형1. Train-Test Contamination

Data leakage 는 학습모델링 과정에서 training data 이 외의 정보가 포함되어 있는 경우 발생
training data와 validation data 구별하지 못한 경우 ⑦ validation data 가 전처리에 영향을 준 경우
: train_test_split() 함수를 호출하기 전에 전처리를 실행하면!!!



⑦ cross-validation(교차검증)을 사용할 때 : pipeline 내에서 전처리 수행

- data scaling 적용 할 때 : test data 함께 사용 (train : 0~100 , test : 50~200
- encoding (label encoding, one-hot encoding) 적용할 때 : test data 함께 사용
- test data set 결측치 처리 할 때 : test data set의 통계값 활용
- 모델 학습에 test data가 활용되는 경우

유형2. Target Leakage

예측 시에 사용할 수 없는 data가 포함된 상태에서 예측을 할 때 발생 → 그러니 데이터를 이용할 수 있는 타이밍이나 정방향 순서대로(chronological order)의 관점

- ⑦ feature는 target value가 실현화된 후 생성되거나 갱신된 feature 삭제 해야 함.
- ⑦ (예시: 암 – 방사선치료여부 , 예시: 주택가격 – 주변 매매가격)
- ⑦ leakage가 발생할 수 있는 feature를 **common sense** 활용

Data Leakage

Tips to Combat Data Leakage

1. Data를 완전 분리하라

: Hold back a validation dataset for final sanity check of your developed models.

- split your training dataset into train and validation sets, and store away the validation dataset.
- **(Use a Holdout Dataset)** : training dataset 훈련셋, 검증셋, 테스트셋
- : training dataset : 모델 훈련, validation dataset : 모델 최적 파라미터 찾고,
- training dataset 테스트셋 : 모델 성능 평가

2. 교차검증 : pipeline 내에서 전처리 수행

: Use Pipelines. Heavily use pipeline architectures that allow a sequence of data preparation steps to be performed within cross validation folds, such as the caret package in R and Pipelines in scikit-learn.

3. 누출 변수(feature) 제거하라.

Remove Leaky Variables.

4. 시간을 고려 데이터 일부 제거 (Temporal Cut off)

Remove all data just prior to the event of interest, focusing on the time you learned about a fact or observation rather than the time the observation occurred.

<https://machinelearningmastery.com/data-leakage-machine-learning/>

Data Leakage

Further Reading on Data Leakage

- [Leakage in Data Mining: Formulation, Detection, and Avoidance](#) [pdf], 2011. (recommended!)
- [Mini episode on Data Leakage on the Data Skeptic podcast.](#)
- [Chapter 13: Lessons Learned from Data Competitions: Data Leakage and Model Evaluation, from Doing Data Science: Straight Talk from the Frontline, 2013.](#)
- [Ask a Data Scientist: Data Leakage](#), 2014
- [Data Leakage on the Kaggle Wiki](#)
- [Fascinating Discussion on data leakage in the ICML 2013 Whale Challenge](#)

<https://machinelearningmastery.com/data-leakage-machine-learning/>

* Data Cleansing

불완전하고 오류가 있는 데이터를 보완/수정하는 일련의 과정 raw data를 이용해서 분석 전에 정제과정을 거치는 이유는 다양한 오류, 수기 입력 오류, 매핑(mapping) 오류 등 인한 왜곡된 데이터로 분석을 실시할 경우 사실과는 다른 결과를 도출해 낼 수 있기 때문이다.

- 표본기업들을 산업별로 그룹화 하여 적절한 규모로 분류 경우
- 한국표준산업분류(KSIC) 기준에 따라 제조업/건설업/도소매업/서비스업으로 구분
- 제조업과 건설업/도소매업/서비스업 구분 등
- **건설업 더미변수**
- **특정기간(충격사건) 이전과 이후를 더미변수**
- **규모 통제 : log**
- 변수의 선정 전
- 극단치(이상치) **how**, 단위문제
- 결측치 **how**, 이유가 있다.

에러의 주된 원인을 처리

•objective : Cleaning and preparing time series data


1.누락데이터가 있는지 확인한다. 어떻게 확인하는가?

2.누락 데이터는 fillna(method='ffill')

Imbalance data : Resampling

- 데이터가 불균형한 분포를 가지는 경우 ⑦ **분류모형에서는 일반적으로 발생 !**
- 프로젝트에서 부도기업은 정상기업에 비해 그 비율이 매우 낮기 때문에 class imbalance 문제 발생
- 모든 예측치를 정상으로 예측하더라도 정확도(accuracy)가 높아지는 경향이 있으므로 분석 목적인 부도 개체의 식별력(sensitivity 또는 recall)이 저하
- 모델 학습이 제대로 이루어지지 않을 확률이 높아, 이런 문제를 해결하기 위해 나온 개념

Undersampling	• 불균형한 dataset에서 높은 비율을 차지하던 class의 data 수를 줄임으로써 data 불균형을 해소 • 학습에 사용되는 전체 데이터 수를 감소시켜 성능 저하 문제 발생 가능성 • 특히 대용량 데이터셋에서 처리 시간과 메모리 사용량을 줄이는 효과적인 방법이 될 수 있다. • 정보 손실이 발생할 수 있으므로, 어떤 기법을 사용할지 신중하게 결정 ⑦ 일부를 선택하더라도 데이터를 잘 대표하는 제대로 된 관측치를 선택하고자 하는 clustering 방법을 가미한 방법론들도 이슈이다.
Oversampling	▪ 낮은 비율 클래스의 데이터 수를 증가시켜 불균형을 해소. ▪ 데이터의 특성을 잘 이해하고 적절한 방법을 선택하는 것이 중요하다. ▪ Oversampling은 minority class에 대한 중복 데이터가 많아지므로 모델이 train셋에 있는 minority class에 과적합되어 test셋에서는 성능을 발휘하지 못한다는 점이 발생할 수 있다. ⑦ 합성샘플(synthetic sample) 을 생성하는 방법론들이 많이 등장한다. ▪ 각 방법은 특정 상황에서 장점을 가질 수 있으며, 때로는 여러 기법을 조합하여 사용하는 것이 더 효과적일 수 있다.





<https://www.kaggle.com/rafjaa/resampling-strategies-for-imbalanced-datasets?scriptVersionId=1747689>

Imbalance data : Resampling

Undersampling 방법

방법	내용
Random Undersampling	- 다수 집단에 속해 있는 관측치들 중 무작위로 샘플링하는 것 - 수행할 때마다 다른 결과가 도출된다. ⑦ 샘플링 마다 모델의 성능이 달라진다.
Tomek Links	- 소수 집단 데이터와 가장 낮은 유클리디안 거리를 갖는 다수 클래스를 삭제하여 두 클래스 사이의 공간을 늘렸고 분류 프로세스를 용이하게 했다. - 서로 다른 클래스에 속하는 쌍 중에서 서로 가장 가까이 있는 샘플들을 찾아낸다. ⑦ 이 중 다수 클래스에 속하는 샘플을 제거 한다. ⑦ 두 범주 사이를 탐지하고 정리를 통해 부정확한 분류경계선을 방지하는 방법 - 우측 그림에서는 초록색 동그라미 안에서 파란색 데이터들을 모두 삭제해주어 언더샘플링을 수행하는 것
Condensed Nearest Neighbor (CNN Rule)	- 다수 집단에 밀집된 데이터가 없을 때까지 데이터를 제거하여 데이터 분포에서 대표적인 데이터만 남도록 하는 방법 - 소수 집단에 속하는 데이터 전체와 다수 범주에 속하는 데이터 중 임의로 선택한 데이터 한 개 (A) 로 구성된 서브 데이터를 생성 - 다수 집단에 속하는 나머지 데이터들 중 하나씩 $K=1$ 인 1-NN 방식을 이용하여 A와 가까운지 소수 집단과 가까운지 확인하여 가까운 집단으로 임시 분류 2번이 끝나면 정상 분류된 다수 범주 관측치를 제거하여 언더 샘플링
Cluster Centroids	- 소수 집단에 속하는 데이터 전체와 다수 범주에 속하는 데이터 중 임의로 선택한 데이터 한 개(A) 로 구성된 서브 데이터를 생성 - 그리고 다수 집단에 속하는 나머지 데이터들 중 하나씩 $K=1$ 인 1-NN 방식을 이용하여 해당 데이터가 처음에 선택한 다수 범주 데이터 (A) 와 가까운지 아니면 소수 범주와 가까운지 확인하여 가까운 범주로 임시로 분류 ⑦ 이 과정이 끝나면 정상 분류된 다수 범주 관측치를 제거하여 언더 샘플링
Edited Nearest Neighbors (ENN)	가장 가까운 이웃을 고려하여, 해당 이웃의 대부분이 다른 집단에 속한다면 해당 샘플을 제거한다.



Imbalance data : Resampling

Oversampling 방법


방법	내용
Random Over-Sampling	- 소수 집단에 속하는 data(부실기업)의 관측치를 다수 범주 데이터(정상기업) 수와 비슷하도록 무작위로 copy하는 방법으로 data를 증가시키는 방법 - 소수 클래스(부도기업)에 과적합이 발생할 수 있다는 단점이 있고 이를 보완하기 위해 나온 방법이 SMOTE 방법
SMOTE (Synthetic Minority Over-sampling Technique)	- 소수 집단에서 가상의 데이터를 생성하는 방법 - 오버샘플링과 언더샘플링을 합성한 방법으로 KNN을 이용한 랜덤 샘플링을 이용 - 소수집단에서 단순 임의 추출하여 복제를 하는 것이 아니라, 소수집단 개체의 최근접 이웃(k-Nearest Neighbors) k개 중에서 임의로 추출하는 방법 - 선택한 데이터와 가장 가까운 k개의 데이터 중 하나를 무작위로 선정해 Synthetic 생성 공식을 통해 가상의 데이터를 생성하는 방법
Borderline SMOTE	Borderline 부분에 대해서만 SMOTE 방식을 사용하는 것 - Borderline 을 찾는 것은 임의의 소수 클래스의 데이터 한 개에 대해서 주변의 K개 데이터를 탐색하고 그중 다수 범주 데이터의 수를 확인 - 이때 다수 범주 데이터의 수가 K와 같을 경우 소수 범주의 데이터를 Noise 관측치라고 하며, 다수 범주 데이터의 수가 $K/2 \sim K$ 에 속할 경우 Danger 관측치, $0 \sim K/2$ 에 속할 경우 Safe 관측치 - 여기서 Danger 관측치에 대해서만 SMOTE를 적용하여 오버 샘플링을 진행 <pre>from imblearn.over_sampling import BorderlineSMOTE</pre> <pre>X_resampled, y_resampled = BorderlineSMOTE(random_state=0).fit_resample(X, y)</pre> <pre>count_and_plot(y_resampled)</pre> 사례) Bankruptcy Prediction Using Deep Learning Approach Based on Borderline SMOTE Salima Smiti1 & Makram Soui 2020
ADASYN (Adaptive Synthetic Sampling)	각 소수 집단 샘플 주변의 다수 클래스 샘플 수를 기반으로 합성 샘플을 생성한다. 훈련시키기 어려운 샘플일수록 더 많은 합성 샘플이 생성된다. <pre>from imblearn.over_sampling import ADASYN</pre> <pre>X_resampled, y_resampled = ADASYN(random_state=42).fit_resample(X, y)</pre> <pre>count_and_plot(y_resampled)</pre>

*Imbalance data : Resampling

SMOTE : Synthetic Minority Over-sampling Technique

- **소수 집단에서 가상의 데이터를 생성하는 방법**
- Knn -K값을 정한 후 소수 범주에서 임의의 데이터를 선택
- 선택한 데이터와 가장 가까운 K개의 데이터 중 하나를 무작위로 선정해 synthetic 공식을 통해 가상의 데이터 생성
- 소수 범주 내 모든 관측치에 대해 과정을 반복하고 가상 관측치 생성
- k-nearest neighbors (knn)를 이용하여 knn으로 가까운 minority class 들을 찾은 후
- 0과 1사이의 랜덤한 값을 선택한 후 해당 값으로 내분하는 점을 새로운 샘플로 생성하는 기법
- minority 관측치들 사이의 linear 상에서 새로운 관측치가 생성된다.
- 이런 방식은 minority class에 변주를 주기 때문에
- minority class에 대한 중복 데이터가 많아져 모델이 train셋에 있는 minority class에 과적합되어 test셋에서는 성능을 발휘하지 못한다는 Oversampling의 단점을 보완하게 된다.

3-nearest neighbors 200% Oversampling 적용 방식



빨간색 점이 minority class인 경우

- 가장 가까운 3개의 다른 minority 관측치를 찾는다.
 - 샘플생성을 2배를 하는 경우 두 점을 선택 후
 - linear 상의 랜덤한 초록색 별 위치를 새로운 샘플로 생성하는 것 !
- 이를 모든 minority class에 이를 적용하면 된다.

Minority sample

: 분류 작업에서 소수 클래스(minority class)에 속하는 개별 데이터 포인트를 의미

SMOTE: Synthetic Minority Over-sampling Technique. International Conference of Knowledge Based Computer Systems, pp. 46-57. National Center for Software Technology, Mumbai, India, Allied Press

Chawla, N., Bowyer, K., Hall, L., & Kegelmeyer, P. (2000).

SMOTE: Synthetic Minority Over-sampling Technique

Chawla, N., Kevin W. Bowyer, Lawrence O. Hall

Journal of Artificial Intelligence Research 16 (2002)

*Imbalance data : Resampling

SMOTE

SMOTE 알고리즘 과정

1. 소수 클래스 샘플 선택

소수 클래스에서 한 샘플 x 를 랜덤으로 선택한다.

2. k-최근접 이웃(k-NN) 계산

선택한 샘플 x 의 k-최근접 이웃을 찾는다. 보통 $k=5$).

3. 새로운 샘플 생성

이웃 중 하나를 무작위로 선택하여, 선택한 이웃 x_{neighbor} 와 원래 샘플 x 사이에 새로운 데이터를 생성한다.

새로운 샘플 x_{new} 은 다음과 같이 계산된다:

$$x_{\text{new}} = x + \lambda \cdot (x_{\text{neighbor}} - x) \quad \lambda \text{는 } [0, 1] \text{ 사이의 임의의 값}$$

4. 반복

이 과정을 필요한 수의 샘플이 생성될 때까지 반복한다.

*Imbalance data : Resampling

SMOTE : 장.단점

구분	장점	단점
오버샘플링 방식 (과적합 방지)	- 소수 클래스 데이터를 단순 복제하지 않고, 인접 이웃 간 선형 보간으로 새로운 샘플 생성 - 오버피팅(overfitting) 위험 감소	- 보간 과정에서 실제 분포를 벗어난 노이즈 샘플이 생성될 수 있어서 모델 성능이 약화될 수 있음
클래스 불균형 해소	- 소수 클래스의 데이터 양을 증가시켜 분류모델이 불균형데이터에서 더 나은 성능을 발휘하도록 지원	- 소수 클래스 샘플이 희박한 경우(이웃 찾기 어려움) 적절한 보간이 어려워 효과 저하
데이터 다양성	- 단순 복제보다 다양한 합성 샘플 생성으로 학습 데이터의 분산(variance) 유지 또는 확대	- 신호와 노이즈 영역이 중첩될 경우, 경계(boundary) 샘플들이 클래스 간 중첩(overlap)을 악화시킬 수 있음
모델 성능 개선	- 여러 연구에서 F1-score, AUC 등 불균형 데이터 지표 개선 효과 확인됨	- 계산 비용이 늘어날 수 있으며, 대규모 데이터셋에 적용 시 시간·메모리 부담 발생
적용 유연성	- 다양한 분류 알고리즘(트리, SVM, 신경망 등)과 함께 사용 가능	- 연속형 변수에는 적합하지만, 범주형 변수가 많은 데이터에는 직접 적용 어려움

*Imbalance data : Resampling

SMOTE의 변형

1. Borderline-SMOTE

소수 클래스 샘플 중 경계 근처에 있는 샘플을 중심으로 새로운 데이터를 생성하여 클래스 경계를 더 명확히 함.

2. ADASYN (Adaptive Synthetic Sampling)

소수 클래스 중 더 어려운 샘플(즉, 다수 클래스와 더 가까운 샘플)에 대해 새로운 데이터를 생성하는 방식.

3. SMOTE-ENN (Edited Nearest Neighbors)

SMOTE로 샘플을 생성한 후, 다수 클래스의 노이즈 데이터를 제거하여 데이터 품질을 높임.

*Imbalance data : Resampling

Borderline SMOTE

Borderline 부분만을 샘플링

SMOTE를 사용했을 때는 outlier minority data가 있을 때 중간에 noise같은 값이 생성된다는 문제점이 발생

1. 우선 minority class의 데이터 중 임의로 하나를 선택한다.

1.경계 샘플의 식별

: k-최근접 이웃(k-Nearest Neighbors, k-NN) 알고리즘을 사용하여 각 소수 클래스 샘플의 이웃을 찾는다.

이웃 중 다수 클래스 샘플이 일정 비율 이상을 차지하는 소수 클래스 샘플들을 경계 샘플로 식별한다.

3. 샘플링 비율

: 경계 샘플이 식별되면, 이 샘플들을 기반으로 새로운 샘플을 합성(synthetic) 한다.

합성은 선택된 경계 샘플과 그의 소수 클래스 이웃 사이에서 진행된다.

4.샘플의 생성: ⑦ 경계에 있는 소수 클래스 샘플들 사이의 선행정보간을 통해 새로운 샘플을 생성하는 것
위 공식을 통해, 각 경계 샘플에 대해 여러 합성 샘플이 생성될 수 있다. 이 합성 샘플들은 원래 데이터셋에 추가되어 소수 클래스의 표본을 인위적으로 늘린다.

$$d'_i = d_i + p(d_{izi} - m)$$

d_i : 경계 샘플,
 d_{izi} :의 소수 클래스 이웃 중 하나
 p : 0과 1 사이의난수

Minority sample

: 분류 작업에서 소수 클래스(minority class)에 속하는 개별 데이터 포인트를 의미

Borderline-SMOTE의 경우 majority와 minority 사이의 경계를 보다 분명하게 만들긴 하지만, 여전히 새로 생성한 minority 주변에 majority가 섞일 수 있다는 문제점이 완전히 해소되진 않는다.

Algorithm : Borderline SMOTE algorithm

Input: T-Training set

M-Minority examples set

r,k-Number of nearest neighbors

s-Number of synthetic examples that account for the number of original examples in the given class

Output: Synthetic minority samples set: M'

1. $D = \phi$ //D is a set containing borderline samples

2. for all m_i in M do

3. $N_{mi} \leftarrow r$ nearest neighbors of m_i in T

4. $n \leftarrow$ the number of samples in N_{mi} and not in M

5. if $r/2 \leq n < r$ then // m_i is a borderline sample

6. add m_i to D

7. end if

8. end for

9. $M' = \phi$ //M' is a set containing synthetic samples

10. for all d_i in D do

11. $N_{di} \leftarrow k$ nearest neighbors of d_i in M

12. for $i = 1$ to s do

13. $m \leftarrow$ choose a random sample from N_{di}

14. $d'_i \leftarrow d_i + p * (d_i - m)$ //p is a random number in(0, 1), d'_i is a synthetic sample

15. add d'_i to M'

16. end for

17. end for

18. $M' = M' \cup M$ //M' is the union of minority samples and synthetic samples


19. return M'

Bankruptcy Prediction Using Deep Learning Approach Based on Borderline SMOT
2020 Salima Smiti1 & Makram Soui2

*Imbalance data : Resampling

Borderline SMOTE

Borderline-SMOTE: A New Over-Sampling Method in Imbalanced Data Sets
Learning Hui Han¹, Wen-Yuan Wang¹, and Bing-Huan Mao² (2005)



- (a) The original distribution of Circle data set.
- (b) The borderline minority examples (solid squares).
- (c) The borderline synthetic minority examples (hollow squares).

*Imbalance data : Resampling

ADASYN (Adaptive Synthetic Sampling Approach)



ADASYN: Adaptive Synthetic Sampling Approach for Imbalanced Learning Haibo He, Yang Bai, Edwardo A. Garcia, and Shutao Li (2008)

- Borderline SMOTE 방법과 비슷하지만 샘플링 개수를 데이터 위치에 따라 다르게 설정하는 것이 차이
- 기존의 SMOTE 방법은 모든 **minority class**로부터 **동일한 개수의 synthetic 샘플을 생성했지만**,
- **ADASYN은 각 관측치마다 생성하는 샘플의 수가 다르다는 점이 특징이다.**
- 일종의 weight로 synthetic 샘플 수를 결정하고 이 weight는 knn 범위 내로 들어오는 majority class의 개수에 비례하도록 한다.
- 모든 소수 집단 데이터에 대해 주변의 k개의 데이터를 탐색하고 그중 다수 범주 데이터의 비율을 계산한다.
- 계산된 각 비율들을 비율의 총합으로 나눠 스케일링을 진행한다.
- (다수 범주 데이터 수 - 소수 범주 데이터 수)를 스케일링이 진행된 비율에 곱해주고
- 반올림된 정수의 값만큼 각 소수 범주 데이터 주변에 SMOTE 방식으로 가상 데이터를 생성한다.

스케일링방법

$$\rightarrow \frac{r_i}{\sum_{i=1}^m r_i}$$

소수 집단 데이터 주변의 다수 집단 데이터의 수에 따라 유동적으로 생성이 가능하다는 장점이 있다.



Imbalance data : Resampling

장.단점

구분	장점	단점
Under-Sampling		
Random Under-Sampling	구현이 매우 쉽다.	중요한 정보를 잃어버릴 위험이 있으며, 이는 모델의 성능 저하를 초래할 수 있다.
Tomek Links	클래스 경계를 명확히 하면서 데이터를 줄인다.	매우 희소한 데이터 세트에서는 유의미한 양의 데이터를 제거하지 못할 수 있다.
Cluster Centroids	데이터의 대표성을 유지하면서 샘플 수를 줄일 수 있다.	클러스터링 과정에서 발생하는 계산 비용이 높을 수 있다.
Edited Nearest Neighbors (ENN)	클래스 경계 주변의 잡음을 제거하여 모델의 일반화 능력을 향상시킨다.	선택적으로 샘플을 제거하는 과정에서 중요한 정보를 손실할 수 있다.
Over-Sampling		
Random Over-Sampling	구현이 매우 간단	샘플의 복제로 인해 과적합이 발생할 수 있다.
SMOTE	새로운 샘플을 생성함으로써 데이터의 다양성을 증가시킨다.	소수 클래스의 데이터 분포가 균일하지 않은 경우, SMOTE가 잘못된 샘플을 생성할 수 있다.
Borderline-SMOTE	경계선에 위치한 샘플에 집중하여 학습의 효율성을 높인다.	경계선을 정확하게 판단하기 어렵고, 경우에 따라서 과적합을 유발할 수 있다.
ADASYN (Adaptive Synthetic Sampling)	모델이 소수 클래스의 더 어려운 샘플을 학습하는데 도움을 준다.	계산 비용이 높고, 때로는 너무 많은 합성 샘플을 생성할 수 있다.

Wang and Japkowicz, (2009)

Under-Sampling이 Over-Sampling에 비하여 데이터 불균형 문제를 효과적으로 해결하는 것으로 보고되고 있다. 이는 Over-Sampling의 데이터 생성과정에서 소수 범주 데이터의 편차가 크게 증가하기 때문이다

Imbalance data : Resampling

SMOTE for Imbalanced Classification with Python <https://machinelearningmastery.com/smote-oversampling-for-imbalanced-classification/> This tutorial is divided into five parts; they are:

1. Synthetic Minority Oversampling Technique
2. Imbalanced-Learn Library
3. SMOTE for Balancing Data
4. SMOTE for Classification
5. SMOTE With Selective Synthetic Sample Generation
 1. **Borderline-SMOTE**
 2. Borderline-SMOTE SVM
 3. **Adaptive Synthetic Sampling (ADASYN)**

Resampling strategies for imbalanced datasets Python · [Porto Seguro's Safe Driver Prediction](https://www.kaggle.com/code/rafjaa/resampling-strategies-for-imbalanced-datasets)
<https://www.kaggle.com/code/rafjaa/resampling-strategies-for-imbalanced-datasets>

Imbalance data : Resampling

Oversampling 방법

Radius-SMOTE

A New Oversampling Technique of Minority Samples Based on Radius Distance for Learning From Imbalanced Data (2021)

Radius SMOTE는 새로 생성한 데이터의 오버랩 문제를 가장 잘 해결할 수 있는 기법

(Radius-SMOTE의 작동원리)

- 1.반경 기반 이웃 선택:** 각 소수 클래스 샘플에 대해 지정된 반경 r 내에 있는 모든 소수 클래스 샘플을 이웃으로 선택한다. 이 반경은 사용자가 지정하거나 데이터를 기반으로 최적화될 수 있다.
- 2.샘플 생성:** 선택된 이웃들 사이에서 새로운 샘플을 합성한다.
합성 방식은 기존 SMOTE와 유사하게, 두 샘플 사이의 선형보간을 통해 이루어진다:

(Radius-SMOTE의 장점)

적응적 이웃 선택: 고정된 수의 이웃 대신 반경을 사용함으로써, 각 샘플의 지역적 밀도에 따라 적응적으로 이웃을 선택할 수 있다. 이는 데이터의 국지적 특성을 더 잘 반영할 수 있게 한다.

향상된 학습 능력: 데이터 세트의 복잡한 구조에서 소수 클래스의 정보를 더욱 효과적으로 확장하고, 모델이 더 정교한 경계를 학습하도록 도와준다.

(사용 상의 주의점)

파라미터 설정: 반경 r 의 크기는 매우 중요하며, 너무 크거나 작게 설정되면 잘못된 샘플을 생성하거나 적절한 수의 샘플을 생성하지 못할 수 있다.

계산 비용: 반경 내의 모든 이웃을 찾는 과정이 계산적으로 비용이 많이 들 수 있으므로, 큰 데이터 세트에 적용할 때는 성능 저하가 발생할 수 있다.

Radius-SMOTE는 데이터의 불균형을 해결하기 위해 특정 지역의 데이터 특성을 보다 세밀하게 고려하고자 할 때 유용한 방법

Imbalance data : Resampling

생성적 적대 신경망

방법	내용
GAN (Generative Adversarial Networks)	GAN은 생성자와 구분자로 구성되어 있고 모델은 딥러닝을 사용하는 오버 샘플링 기법 ▪ 두 신경망 모델인 생성자(Generator, G)와 판별자(Discriminator, D)가 경쟁적으로 대립하면서 학습 ▪ 무작위로 노이즈를 생성하고 생성자를 통해 가짜 샘플을 생성 ⑦ 구분자에서 진짜 샘플과 가짜 샘플을 판별하고 너무 쉽게 판별될 경우 생성자에게 피드백 ⑦ 생성자는 더욱 진짜 샘플과 비슷한 가짜 샘플을 생성하고 구분자에게 판별을 시킨다. → 별도 한글 배포 한글자료 참조
CGAN (Conditional GAN)	▪ 기존의 GAN은 생성되는 데이터의 제어가 불가능했다면 이를 보완하기 위한 방법으로 등장 ▪ CGAN은 조건부 확률적 생성 모델을 사용 ▪ GAN과 학습 방식은 유사하며 손실함수의 생성자와 판별자에 조건 y 가 추가되었다는 차이
WGAN (Wasserstein GAN)	GAN 에서 발생하는 모드 붕괴 현상(Mode Collapse) 문제를 해결하기 위해 제안 WGAN 은 판별자(D) 대신 비평자(Critic, C)를 설정하고 최적화를 위해 생성적 적대 신경망의 비용함수에 WL(Wasserstein loss)를 사용
WGAN-GP (Wasserstein GAN with Gradient Penalty)	▪ WGAN 의 문제점을 고려하여 개선된 방법 ▪ WGAN-GP(Wasserstein GAN with Gradient Penalty)을 제안 립셔츠 제약을 실행할 수 있는 대안으로 가중치 클리핑 대신 비평자의 손실함수에 경사 패널티(Gradient Penalty)를 적용 ▪ 미분이 가능한 함수는 모든 곳에서 Norm이 1 이어야만 하고 벗어나면 모델에 패널티를 부과
CTGAN (Conditional Tabular GAN)	일반적으로 테이블 형식의 데이터는 연속형 변수와 범주형 변수로 이루어져 있는데 GAN 의 경우 연속형 변수와 범주형 변수를 동시에 생성하는 것과 카테고리 변수에서 심한 불균형을 띄고 있다는 문제점이 발생한다. CTGAN 는 CGAN 를 사용하여 위의 문제점을 개선

CTGAN 및 TabNet 기법을 활용한 불균형 정형 데이터 이진분류 모델링 개발 (2022)

* Time Series Data set : Generation

Sliding Window Technique vs Reshape

1. Sliding Window Technique

1) 개념

연속된 데이터(시계열, 텍스트, 이차원 이미지 등)를 일정 크기의 "윈도우(window)" 단위로 잘라내되, 윈도우끼리 일정 부분씩 겹치거나 겹치지 않도록 이동시키면서(슬라이딩) 처리하는 방법

예시)시계열 데이터가 $[x_1, x_2, x_3, \dots, x_n]$ 일 때, window size (W)가 4, stride (S)가 1이라면,

윈도우1: $[x_1, x_2, x_3, x_4]$

윈도우2: $[x_2, x_3, x_4, x_5]$

윈도우3: $[x_3, x_4, x_5, x_6]$

...

식으로 다음 샘플 하나씩 밀면서(W만큼의 길이) 추출한다.

2) 주요 용도

- 시계열 분석 및 예측: 일정 길이의 과거 데이터로부터 다음 값을 예측하거나 특징(feature)을 추출할 때, 과거 구간을 겹치며 잘라서 모델 입력으로 사용.
- 텍스트 처리: 문장을 N-그램(n-gram)으로 나눌 때, 연속된 단어나 문자 집합을 슬라이딩 윈도우로 생성.
- 영상 처리(CNN 등): 이미지나 특징 맵(feature map)을 일정 크기 패치(예: 3×3 , 5×5)로 겹치며 잘라내어 국소 패턴을 학습하거나, 객체 검출 시 윈도우 영역마다 분류기를 적용.
- 데이터 증강(Data Augmentation): 원본 시계열 혹은 텍스트 데이터가 짧을 때, 윈도우를 겹치도록 추출하여 샘플 개수를 늘림.

3) 장·단점

장점

- 국소구간에 집중된 특징을 추출할 수 있어, 변동이 큰 데이터에서도 세부 패턴을 잘 포착
- 데이터 양이 적은 경우 겹침(스트라이드가 1인 경우)을 통해 훈련 샘플 수를 효과적으로 증대
- 유연하게 윈도우 크기나 스트라이드(겹침 정도)를 조절하며 원하는 스케일의 특징을 얻을 수 있음

단점

- 겹침이 많을수록 샘플 간 중복이 커져 계산량 증가
- 윈도우 경계에서 잘려나간 패턴(경계효과, boundary effect)이 발생할 수 있어, 패딩(padding)이나 보정이 필요
- 전체 길이에서 윈도우 크기를 선택하는 것이 중요하며, 윈도우 크기가 부적절하면 맥락 정보를 놓칠 수 있음

* Time Series Data set : Generation

Sliding Window Technique vs Reshape

2. 재조정 기법 (Reshape)

1) 개념

N차원 배열(array) 혹은 행렬(matrix)의 형태(shape)만 바꿀 뿐, 메모리 내 원소 순서는 그대로 유지하면서 차원(dimensionality) 구조를 변경하는 연산이다.

예시) 길이가 12인 1차원 배열 [1,2,3,...,12]을 3×4 형태로 바꾸면

[[1, 2, 3, 4],

[5, 6, 7, 8],

[9, 10, 11, 12]]

과 같이 재배치된다. (원소 자체의 순서나 값은 변하지 않음)

2) 주요 용도

- 모델 입력 형태 맞추기: 딥러닝 라이브러리(TensorFlow, PyTorch 등)에서 요구하는 배치(batch)·채널(channel)·높이(height)·너비(width) 차원을 맞춰줄 때 자주 사용.

예: (batch_size, sequence_length) → (batch_size, sequence_length, 1)로 바꿔서 1차원 CNN에 입력

예: (batch, height, width) → (batch, channel=1, height, width)로 바꿔서 2차원 CNN에 입력

- 벡터화 연산을 위한 전처리: 2차원 데이터(이미지)를 1차원 벡터로 변환해 Fully Connected(FC) 레이어에 넣거나, 반대로 출력 벡터를 이미지 형태로 재구성
- 배열 간 차원 연결(concatenation) 전 정렬: 서로 다른 차원의 배열을 연산하기 전에 동일한 차원 구조로 맞추기 위해 사용

3) 장·단점

장점

- 원소 순서를 유지하면서 차원만 바꾸므로 연산 비용이 거의 없음(보통 뷰(view) 형태로 처리)
- 딥러닝 모델이나 계산 라이브러리에 필요한 형태로 데이터를 쉽게 맞출 수 있어 매우 유연함
- 데이터 자체를 변경하지 않으므로, 재학습 없이 다양한 실험을 위해 자유롭게 형태를 변경 가능

단점

- 재조정만으로는 새로운 정보나 샘플을 생성하지 않음: 단순히 동일한 데이터의 형태만 바꿀 뿐, 추가 학습용 샘플을 늘리거나 패턴을 추출해내지 못함
- 차원 수와 원소 개수가 일치해야 하므로, shape 불일치 오류 발생 시 디버깅 필요
- 사용자 입장에서 "어떤 축이 어느 의미인지" 헷갈리기 쉬워 실수로 잘못된 차원 배열을 만들면 학습 오류나 예측 오류를 초래

* Time Series Data set : Generation

Sliding Window Technique vs Reshape


3. 두 기법의 비교

구분	슬라이딩 윈도우 기법	재조정(Reshape) 기법
목적	데이터를 부분 구간(윈도우)으로 나누어, 국소 특징을 추출하거나 샘플 수 증대	데이터를 다른 차원 구조로 변경하여 모델 입력 형태나 연산 형태를 맞추기
결과	원본 데이터로부터 겹치거나 비겹치게 잘린 새로운 샘플들이 생성됨	동일 원소를 유지하며, 배열의 **차원(shape)**만 변함 (샘플 수는 변하지 않음)
연산 비용	윈도우 크기·스트라이드에 따라 샘플 수가 크게 늘어나면 계산량 증가	메모리 뷰(view) 수준에서 처리되므로 연산 비용 거의 없음
데이터 생성	새로운 부분 구간 데이터를 생성 → 데이터 증강(data augmentation) 가능	데이터 자체 변경 없이 단순 차원 재배열 → 증강 아닌 전처리(preprocessing) 목적
특징 추출	좁은 시간/영역 윈도우 내 세부 패턴을 강조 → 주로 국소 패턴(local feature) 사용	재조정 자체는 특징 추출 목적이 아니며, 차원 맞춤 후 별도 방법(convolution, FC)이 특징 추출 수행


Re-sampling Methods

"Performance Evaluation for Learning Algorithms", Nathalie Japkowicz, School of Electrical Engineering & Computer Science University of Ottawa pt 자료

Evaluating Learning Algorithms: A Classification Perspective Nathalie Japkowicz & Mohak Shah Cambridge University Press, 2011



Overview of Re-Sampling Methods



* Feature Selection

설명변수(Feature)가 많은 경우 문제점 발생

- 회귀모델에서 설명변수가 많을 경우에는 설명변수를 줄일 필요가 있다.
- ⑦ **설명변수가 많으면 예측 성능이 좋지 않기 때문이다.**
- 설명변수가 많아 진 경우 회귀분석의 경우 설명변수들 사이의 독립성 등의 가정을 만족시키기 어렵고,
- 또한 설명변수의 증가는 모형의 결정계수(설명력 R^2) 등을 증가시키기는 하지만 다중 공선성 문제 등을 일으킨다.
- ⑦ 결과적으로 추정의 신뢰성을 저하 문제 발생

- **Feature Engineering** : 도메인 지식을 사용하여 데이터에서 Feature 를 변형/생성
- **Feature Extraction** : 차원축소(dimension reduction) 등 새로운 중요 Feature를 추출
- **Feature Selection** : 수집된 후보 Feature에서 원하는 Feature만 (변경하지 않고) 선택

Feature Selection 이점

- 사용자가 해석하기 쉽게 모델 단순화
- 일반화
- 훈련 시간 축소
- 차원의 저주 방지

(Feature 판단 지표)

- adjusted 결정계수
- AIC(Akaike Information Criterion) 228~229p 참고
- BIC(Bayes Information Criterion)

* Feature Selection

*정형 데이터마이닝_변수선택

• 후보 독립변수가 k 개 있으면 ⑦ 가능한 독립변수의 조합은 2^k 경우의 수

* Feature Selection

1. 변수 선정 사유

데이터의 설명변수(X) 중 에서 Y값에 가장 관련성이 높은 Feature를 선정하는 방법

⑦ 이를 통해 모델의 정확도와 성능을 향상시키고 + 과적합 제어

2. 선정 방법

방법	내용	사례
Filter Method	각각의 변수들에 대해 통계적인 점수를 부여하여 부여된 점수를 바탕으로 변수 순위를 매겨 변수를 선택하는 방법 Feature 간 관련성을 측정하는 방법 (높은 영향력을 가지는지 Feature 를 사용하는 방법)	▪ <u>correlation coefficient</u>, ▪ Chi squared test, information gain
Wrapper Method (Subset Selection)	변수간 상호작용을 감지할 수 있도록 변수의 일부만을 모델링에 사용한 후 그 결과를 평가하는 작업을 반복하면서 변수를 선택해 가는 방법 예측 정확도 측면에서 가장 좋은 성능을 보이는 Feature subset을 뽑아 내는 방법	▪ Backward elimination ▪ Forward selection ▪ stepwise selection
Embedded Method	▪ Filter Method와 Wrapper Method를 결합한 방법 ▪ 각각의 Feature를 직접 학습하며, 모델의 정확도에 기여하는 Feature를 선택 ▪ <u>어떤 변수가 가장 크게 기여하는지를 찾아내는 방법으로</u> overfitting을 줄이기 위해 모델내부 자체적으로 벌점을 가하는 방식이 사용됨	▪ LASSO Regression (L1 Regression) , ▪ Ridge Regression (L2 Regression) ▪ Elastic Net 등

* Feature Selection

판별분석과 로짓분석 : 재무비율의 경우

- 후보 변수에 대해 t-검증을 실시 (수십개~100여개) ⑦ 부도기업과 정상기업 간에 유의한 차이가 존재하는가를 확인
- 후보변수를 1차 축소
- 축소된 변수들 중에는 다중공선성 (multicollinearity) 점검 ⑦ 범주별* 변수 제한 원칙 : 변수 조합시 단계적 변수선택(stepwise variable selection) 이용하여 다중공선성을 진단
- 최종변수는 축소된 후보변수들을 가능한 모든 조합으로 판별분석과 로짓분석을 실시한 후 판별력(discriminant power)과 모형 적합성(goodness of fit)이 가장 우수한 조합을 선정

***범주별** : 안정성, 수익성, 성장성, 건전성, 규모, 현금흐름, 활동성, 등...(6-7개정도)

- ⑦ 재무비율이 특정 범주에 치우치지 않도록 적정하게 배분 함.

비재무정보???

* Feature Selection

*기업부실화 원인 검토 재무변수

구분	안정성 변수	수익성 변수	활동성 변수	성장성 변수	생산성 변수
변수	자기자본비율	총자본순이익률	총자본회전율	총자본증가율	총자본투자효율
	부채비율	총자본경상이익률	자기자본회전율	유형자산증가율	부가가치율
	유동비율	자기자본순이익률	고정자산회전율	매출액증가율	노동소득분배율
	당좌비율	매출액경상이익률	유형고정자산회전율	순이익증가율	
	차입금의존도	매출액영업이익률	매출채권회전율	자기자본증가율	
	매출액규모	금융비용대비 매출액	재고자산회전율		
	총자산규모	매출원가율	운전자산회전율		
	부채상환계수	이자보상배율			
	현금흐름				

자료: 김상봉 외(2011), 부도예측모형을 이용한 기업부실화의 원인분석.

시장가치비율 전무함. → 분자값 P (시가총액)

EV/ EBITDA ⚡ EV (FV) = 시가총액 + 순차입금 (총차입금 - 현금등가물)
PER = P / EPS

알트만 k1모형
X1 : log 총자산
X2 : log 총자산 회전율
X3 :
X4: 시가총액/총부채

현금흐름표 관련

- 영업현금흐름 등
- 잉여현금흐름 (FCF)

자본조달

: 유보금 ⚡ 부채(은행차입, 채권발행) ⚡ 주식 발행 (유상증자)

- 재무변동성 : (-), 비
- 산업변동성 : 평균비교

* Feature

*파생변수(derived variable)

- 기존 데이터로부터 새롭게 생성되거나 계산된 변수를 의미
- 이러한 변수들은 분석의 정확도를 높이고, 데이터에 대한 통찰력을 증가시키며, 모델의 성능을 개선
- 분석 목적에 맞게 새롭게 개발해 낸 유의미하고 적합한 변수 ⑦ 주관적 요소
- 기존변수를 가지고 특정 조건을 만족하거나 특정 함수에 의해 값을 만들어 의미를 부여한 함수
- 사전 도메인
- EDA 활용 데이터 자체에 대한 지식
- 상호작용 변수(교호작용 변수) 추가

파생변수의 예시

비율/ 비	두 변수의 비율이나 차이를 나타내는 파생변수는 원본 데이터의 관계를 더 명확하게 드러낼 수 있다.
시간 관련파생변수	날짜 데이터로부터 요일, 월, 분기, 연도 등을 추출하여 시간의 흐름에 따른 패턴을 분석
텍스트에서 추출된 변수	텍스트 데이터로부터 특정 키워드의 출현 빈도, 문서의 길이, 감성 점수 등을 계산하여 분석에 사용할 수 있다.
거리 계산	:지리적 데이터를 사용할 때, 특정 지점으로부터의 거리를 계산하여 파생변수로 사용할 수 있다. 예를 들어, 가장 가까운 공항이나 상점까지의 거리는 부동산 가격 예측에 유용할 수 있다.
집계변수	고객별 구매 횟수, 평균 구매 금액 등과 같이 개인 또는 그룹 수준에서 집계된 데이터를 생성하여 사용자의 행동 패턴을 분석할 수 있다.
상호작용 변수*	두 변수의 곱으로 생성되는 상호작용 변수는 변수들 간의 관계가 종속변수에 미치는 영향을 모델링하는 데 사용 예를 들어, 광고 지출과 계절이 상호작용하여 판매량에 미치는 영향을 분석할 수 있다.

* Feature

*파생변수(derived variable)

상호작용(교호작용) 변수 (interaction variable)

: 변수(X_1)의 효과가 다른 변수(X_2)의 수준에 의존하는 경우

⑦ 파생변수 (승법적) : ($X_1 \times X_2$)

(활용)

1. 범주형 $\times$ 범주형
2. 범주형 $\times$ 연속형 변수의 관계

(유의점)

연속형 $\times$ 연속형 변수의 경우는 교호작용을 잘 보지 않는다.

⑦ 해석이 애매하게 되기 때문에 상호작용을 고려하지 않음

승법적 파생변수 (feature : p개 경우)

⑦ $2^p - p - 1$

파생변수 생성의 중요성

• 성능 개선

: 파생변수는 모델이 데이터의 중요한 패턴이나 관계를 더 잘 이해하도록 도와, 예측 성능을 개선

• Insight 제공

: 파생변수를 통해 데이터에 숨겨진 인사이트를 발견하고, 비즈니스 문제에 대한 해결책을 제시

• 데이터의 차원 축소

: 유용한 정보를 함축적으로 표현함으로써, 분석을 위한 데이터의 차원을 효과적으로 축소 가능

* Feature

*파생변수(derived variable)


금융분석에서 파생변수 사례

이동 평균 (Moving Averages)	원본 데이터	일일 주식 가격	이동 평균은 주식 가격의 단기적 변동성을 줄이고, 장기적인 가격 추세를 파악하는 데 도움
	파생변수	N일 이동 평균 가격	
변동성 지표 (Volatility Measures)	원본 데이터	일일 주식 수익률	- 역사적 변동성은 과거 일정 기간 동안의 주식 수익률 변동성을 측정하는 지표 - 이는 일반적으로 표준편차나 분산을 사용하여 계산
	파생변수	역사적 변동성 (Historical Volatility)	
부채비율 (Debt-to-Equity Ratio)	원본 데이터	기업의 총부채 자기자본	높은 부채비율은 기업이 높은 재무 위험을 가지고 있음을 의미할 수 있으며, 투자자와 신용 평가 기관에 중요한 정보를 제공
	파생변수	부채비율	
기술적 지표 (Technical Indicators)	원본 데이터	일일 주식가격 거래량	- 상대강도지수(RSI)는 과매수 또는 과매도 상태를 나타내며, 시장의 반전 시점을 예측하는 데 도움을 줄 수 있다. - 이격도(MACD)는 두 이동 평균 간의 관계를 나타내며, 추세의 방향과 강도를 파악하는 데 사용
	파생변수	상대강도지수 (RSI) 이격도 (MACD)	

* Feature

1. 조절변수 (Moderator Variable)

- 통계분석에서 조절변수(control variable) 또는 공변량(covariate)은 연구 설계에서 주요 관심 변수의 효과를 명확하게 파악하기 위해 **통제되는 변수**
- 조절변수는 연구 결과에 영향을 줄 수 있는 외부 요인을 통제함으로써, 주요 독립 변수와 종속변수 사이의 관계를 더 정확하게 이해하고 해석할 수 있도록 해준다.
- 독립변수와 종속변수 사이의 관계에 영향을 주는 제3의 변수로, 이 변수의 존재로 인해 주요 변수들 간의 관계가 어떻게 달라지는지를 설명한다.
- 조절변수는 연구 설계에서 특히 중요한데, 이를 통해 변수들 간의 **상호작용 효과를 파악하고**, 특정 조건이나 상황에서의 관계의 변화를 이해할 수 있다.



조절변수의 역할

1. 외부 변동성 제어

: 연구에서 관심 있는 주요 효과 외에 다른 요인들이 결과 변수에 영향을 줄 수 있다. 조절변수를 사용하여 이러한 외부 변동성을 통제함으로써, 주요 독립변수의 순수한 효과를 더 정확하게 추정할 수 있다.

2. 정확한 인과 관계 파악

: 조절변수를 통해 다른 변수들의 영향을 통제함으로써, 독립변수와 종속변수 사이의 인과 관계를 더 명확하게 파악할 수 있다.

3. 편향 감소

: 연구 설계에서 무시되었을 때 결과를 왜곡시킬 수 있는 변수를 조절함으로써, 연구 결과의 편향을 감소시킬 수 있다.

* Feature

조절변수의 사용 예

• **연령, 성별, 교육 수준:** 사회과학 연구에서, 연령, 성별, 교육 수준과 같은 인구 통계학적 변수는 종종 조절변수로 사용
 ⑦ 이러한 변수들은 연구 대상의 다양한 배경이 결과에 미치는 영향을 통제하는 데 도움을 준다.
 (예시) 광고 효과(독립변수)가 소비자 구매 의사결정(종속변수)에 미치는 영향을 연구할 때, 소비자의 연령(조절변수)이 이 관계를 조절할 수 있다. ⑦ 연령대에 따라 광고 효과의 정도가 달라질 수 있기 때문
 • **경제적 배경:** 경제 연구에서, 개인이나 가구의 경제적 배경은 소비 패턴, 투자 결정 등의 연구에서 중요한 조절변수가 될 수 있다. ⑦ 이를 통해 경제적 배경이 연구 결과에 미치는 영향을 분리하여 분석할 수 있다.

금융분석에서 조절변수 사례


시장 변동성	주식 수익률 연구에서 시장 변동성을 조절변수로 사용 ⑦ 이는 개별 주식이나 포트폴리오의 수익률이 전반적인 시장 조건에 영향을 받을 수 있기 때문
경제 성장률	기업의 성장성 분석 에서 국가의 경제 성장률 을 조절변수로 포함시킬 수 있다. ⑦ 이를 통해 경제 전반의 성장이 특정 기업의 성과에 미치는 영향을 분리하여 볼 수 있다.
이자율	부동산 투자분석에서 이자율을 조절변수로 사용할 수 있다. ⑦ 이자율 변화는 대출 비용에 영향을 미치며, 이는 다시 부동산 시장의 수요와 가격에 영향을 줄 수 있기 때문.
기업 규모	기업의 재무성과 연구에서 기업 규모를 조절변수로 사용할 수 있다. ⑦ 기업 규모는 투자 결정, 자본 구조, 위험 관리 전략 등 다양한 재무적 결정에 영향을 미칠 수 있기 때문
업종	주식 수익률이나 기업 가치평가 연구에서 업종을 조절변수로 사용할 수 있다. ⑦ 특정 업종의 경제적 사이클, 경쟁 구조, 규제 환경 등은 해당 업종의 기업들에게 고유한 영향을 미칠 수 있기 때문
거시경제 지표	투자 전략 분석에서 인플레이션, 실업률, 소비자 신뢰지수와 같은 거시경제 지표를 조절변수로 사용할 수 있다. ⑦ 이러한 지표는 경제 전반의 상태를 반영하며, 시장의 투자 분위기에 영향을 줄 수 있기 때문

* Feature

2. 매개변수 (Mediator Variable)

- 독립변수와 종속변수 사이의 관계에서 중간 역할을 하는 변수
- 독립변수가 종속변수에 미치는 영향을 전달하거나 설명하는 역할을 한다.
- 매개변수는 독립변수의 영향을 받아 변화하고, 이 변화가 종속변수에 영향을 미치는 과정을 나타낸다.
- 매개변수를 통해 독립변수와 종속변수 사이의 **인과관계를 더 명확하게 이해할** 수 있다.

부분 매개변수(Partial Mediation)와 완전 매개변수(Complete Mediation)



구분	부분 매개변수 (Partial Mediation)	완전 매개변수 (Complete Mediation)
의의	- 독립변수가 종속변수에 직접적으로도 영향을 미치지만, 그 영향의 일부가 매개변수를 통해 전달될 때 발생한다. - 이 경우, 독립변수와 종속변수 사이에는 직접적인 관계와 매개변수를 통한 간접적인 관계가 동시에 존재한다. ❷ 독립변수는 종속변수에 직접적으로도 영향을 미치고, 동시에 매개변수를 통해서도 영향을 미친다.	독립변수와 종속변수 사이의 관계가 전적으로 매개변수를 통해 설명될 수 있을 때 발생 이 경우, 독립변수와 종속변수 사이의 직접적인 관계는 통계적으로 유의미하지 않게 되며, 모든 영향은 매개변수를 통해 전달된다. ❷ 독립변수의 영향이 종속변수에 도달하기 위해서는 반드시 매개변수를 거쳐야만 한다.
사례	광고 캠페인(독립변수)이 소비자의 구매 의사결정(종속변수)에 직접적으로도 영향을 미치지만, 소비자의 브랜드 인식(매개변수)을 통해서도 간접적으로 영향을 미친다면 부분 매개변수	광고 캠페인(독립변수)이 소비자의 구매 의사결정(종속변수)에 미치는 영향이 완전히 소비자의 브랜드 인식(매개변수)을 통해 설명될 수 있는 경우라면 완전 매개변수

* Feature

2. 매개변수 (Mediator Variable)

예시: 직장 내 교육 프로그램(독립변수)이 직원의 직무 만족도(종속변수)를 향상시키는 과정에서, 직원의 역량 강화(매개변수)가 중요한 역할을 할 수 있다.

여기서 교육 프로그램은 직원의 역량을 강화시키고, 이 강화된 역량이 직무 만족도를 높이는 과정을 설명한다.

금융분석에서 매개변수 사례

인과관계	변수	항목	흐름
기업 성과와 주식 수익률	종속변수	주식 수익률	- 연구개발 투 자 ⑦ 장기적으로 매출 증가 ⑦ 이후 주식 시장에서 기업의 가 치를 재평가받게 하여 주식 수익률을 증가 - 여기서 **기업 성과(매출 증가율)**는 연구개발 투자가 주식 수익률에 미치는 영향을 중개하는 매개변수로 작용한다. ⑦ 이러한 분석을 통해 투자자들은 단순히 R&D 투자 규모만을 보는 것이 아니라, 그러한 투자가 실제로 기업 성과를 어떻게 개선시키는지 이해 할 수 있다.
	독립변수	연구개발투자	
	매개변수	기업성과(매출증가율)	
금리 변동과 소비자 대출	종속변수	소비자 대출 금액	- 중앙은행이 기준금리 인상 ⑦ 은행 대출 금리 인 상 ⑦ 소비자들이 대출 받는 것에 대한 부담을 증가 ⑦ 최종적으로 소비자 대출 금액의 감소 - 미치는 영향을 중개하는 역할을 한다.
	독립변수	중앙은행의 금리 인상	
	매개변수	은행의 대출 금리	
기업의 사회적책임(CSR) 활동과 기업 가치	종속변수	기업 가치(예:시가총액)	- 기업이 CSR 활동에 적극적으로 참 여 ⑦ 기업의 명성이 향 상 ⑦ 개선된기업 명성은 장기적으로 기업 가치 상승 - 이 경우, 기업의 명성은 CSR 활동이 기업 가치에 미치는 영향을 중개하는 매개변수로 작용 - 이를 통해 기업은 CSR 활동이 단순히 비용이 아니라 장기적인 가치 창출의 수단임을 이해할 수 있다.
	독립변수	기업의 CSR 활동	
	매개변수	기업의 명성	

* Feature

3. 통제변수 (Control Variable)

- 통제변수는 연구에서 의도적으로 일정하게 유지하거나 변화를 제한하는 변수
- 이는 독립변수와 종속변수 사이의 관계를 분석할 때, 다른 외부 요인이 결과에 미치는 영향을 최소화하기 위해 사용된다.
- 통제변수를 통해 연구자는 독립변수와 종속변수 사이의 순수한 관계를 더 명확하게 파악할 수 있다.

•예시: 심리학 실험에서 스트레스(독립변수)가 기억력(종속변수)에 미치는 영향을 연구할 때, 참가자의 나이, 성별, 교육 수준 등을 통제변수로 설정할 수 있다. ⚡ 이는 연구 결과가 이러한 다른 요인들에 의해 왜곡되는 것을 방지하기 위함이다.

금융분석에서 통제변수 사례

인과관계	변수	항목	흐름
기업 성과 분석	종속변수	기업의 시장가치	- 기업의 시장 가치는 R&D 투자 외에도 여러 요인에 의해 영향을 받을 수 있다.. - 예를 들어, 큰 기업은 작은 기업보다 더 높은 시장 가치를 가질 수 있다. - 부채 비율이 높은 기업은 재무적 위험이 더 크기 때문에 시장 가치가 낮을 수 있다. - 업종에 따라 기업의 평가가 달라질 수 있다. - 이러한 요인들을 통제변수로 설정함으로써, 연구자는 R&D 투자와 기업 시장 가치 사이의 관계를 보다 명확하게 분석할 수 있다. ⚡ 더미변수화, log
	독립변수	연구개발투자	
	통제변수	기업 규모, 부채 비율, 업종	
주식 수익률 예측	종속변수	주식수익률	- 주식 수익률은 단순히 기업 실적 발표에 의해서만 결정되지 않는다. - 시장의 전반적인 변동성, 해당 주식의 이전 수익률 추세, 거시경제 지표(예: 금리, 인플레이션) 같은 다양한 요인들이 주식 수익률에 영향을 미칠 수 있다. - 이러한 변수들을 통제변수로 포함시킴으로써, 연구자는 기업 실적 발표가 주식 수익률에 미치는 순수한 영향을 더 정확하게 평가할 수 있다.
	독립변수	기업 실적 발표(예: 분기별 이익)	
	통제변수	시장 변동성, 이전수익률, 거시경제 지표	
신용 위험 평가	종속변수	신용위험 (예: 대출 상환 능력)	- 개인의 신용 위험을 평가할 때, 단순히 소득 수준만을 고려하는 것은 충분하지 않다. - 개인의 나이, 교육 수준, 고용 상태, 존의 부채 수준과 같은 다양한 요인들이 신용 위험에 영향을 미칠 수 있다. - 이러한 변수들을 통제변수로 설정함으로써, 연구자는 소득 수준과 신용 위험 사이의 관계를 보다 정확하게 분석할 수 있다.
	독립변수	개인의 소득 수준	
	통제변수	나이, 교육 수준, 고용 상태, 기존 부채 수준	

* Feature

조절변수 & 매개변수 & 통제변수 비교

구분	조절변수 (Moderator Variable)	매개변수 (Mediator Variable)	통제변수 (Control Variable)
역할 차이	독립변수와 종속변수 사이의 관계의 강도나 방향을 변화시키는 역할	독립변수와 종속변수 사이의 관계를 매개하거나 중개하는 역할	분석 과정에서 다른 변수들의 영향을 제거하거나 줄이기 위해 일정하게 유지된다.
관계 차이 (목적의 차이)	- 주로 상호작용 효과를 검토하는데 사용 - 변수들 간의 관계가 어떠한 조건이나 상황에서 변화하는지를 보여준다.	독립변수가 종속변수에 미치는 영향의 과정이나 메커니즘을 설명한다.	연구 결과에 영향을 줄 수 있는 외부 요인을 제어하려는 목적으로 사용
분석 방법 차이	조절변수의 효과를 분석하기 위해서는 상호작용항을 모델에 포함시켜야 한다.	매개변수의 역할을 검증하기 위해서는 매개 효과 분석을 수행해야 하며, 이는 독립변수가 매개변수를 통해 종속변수에 미치는 간접적인 영향을 평가한다.	실험 설계나 데이터 분석 단계에서 다루어지며, 연구의 정확도를 높이기 위해 사용된다.

https://github.com/freejyb/fin_stats

Modeling : Explanatory, Predictive

1. 잘 설명하는 모델 (Explanatory modeling)

- 주어진 데이터 (training data) 를 가장 잘 설명하는 모델

2. 예측을 잘 하는 모델 (Predictive modeling)

- 새로운 데이터(testing data) 에 대한 예측 성능이 좋은 모델

Machine Learning 이슈

1. 잘 설명하는 모델 (Explanatory modeling)

MSE를 최소화하는 모델

Ordinary Least Square Method (OLS)

최소제곱법으로 MSE(평균제곱오차)를 최소화하는 회귀계수 계산

$$\beta = \operatorname{argmin} \{ \sum_{i=1}^n (y_i - x_i \beta)^2 \} = (X^T X)^{-1} X^T y$$

- 회귀계수에 대한 불편추정량 중 분산이 가장 작은 추정량 (BLUE : Best Linear Unbiased Estimator)

여러 설명변수 중 일부만을 선택 (Feature Selection : Forward, Backward stepwise, Lasso, Ridge....) 함에 따라 편의 (bias)는 증가할 수 있지만, 분산(Var)는 감소한다.!!

Modeling : Explanatory, Predictive

2. 예측을 잘 하는 모델 (Predictive modeling)



Machine Learning 이슈

- 새로운 데이터(testing data)에 대한 예측 성능이 좋은 모델
- Expected error가 낮은 모델

Bias-Variance Trade-off

구분	발생 이유	학습 오류
Bias오차	Bias 에러가 높아진 경우 : 예측치와 실제치와의 오차가 큰 경우를 말함. 이는 많은 데이터(또는 피쳐)를 고려하지 않아(=모델이 단순) 정확한 예측을 할 못하는 경우	높은 Bias Underfitting (모델복잡도 : 단순)
Variance오차	Variance오차가 높아진 경우 : 예측의 범위가 넓다는 것을 의미 Variance 에러는 노이즈까지 전부 학습해(=모델이 복잡) 약간의 input에도 예측 Y 값이 크게 변동(불안정)	높은 Variance Overfitting (모델복잡도 : 복잡)

dilemma



<https://scott.fortmann-roe.com/docs/BiasVariance.html>

Modeling : Explanatory, Predictive

Bias-Variance Trade-off

확률변수 X 에 대해

$$Y = f(X) + \epsilon$$

$$E[(Y - \hat{f}(X))^2] = E[(\hat{f}(X) - E[\hat{f}(X)])^2] + (E[\hat{f}(X)] - f(X))^2 + \sigma^2$$

Expected mean-squared error (MSE) on the validation sample (for prediction modeling) = Variance of the fit + (Bias of the fit)² + Variance of the error (noise)

Trade-off (Dilemma)

Irreducible errors (noise)

X 와는 의존적이지 않지만, Y 에 영향을 미치는 요소

❶ 줄일 수 없는 불가피한 error

기대 오차 (E(MSE))

= 추정량의 분산과 (편향)²의 합 ❶ trade off

수학 전개 참조

https://ko.m.wikipedia.org/wiki/%ED%8E%B8%ED%96%A5-%EB%B6%84%EC%82%B0_%ED%8A%B8%EB%A0%88%EC%9D%B4%EB%93%9C%EC%98%A4%ED%94%84#

실제 관계함수 $y = f(x)$ 를 학습알고리즘을 통해

Error (= $y - \hat{f}(x)$)의 제곱평균(MSE)를 최소화하는 찾는 다.!!

X 에 대한 기대오차는 아래와 같다.

$$E[(y - \hat{f}(x))^2] = \text{Bias}[\hat{f}(x)]^2 + \text{Var}[\hat{f}(x)] + \sigma^2$$

$$\text{Bias}[\hat{f}(x)] = E[\hat{f}(x) - f(x)]$$

$$\text{Var}[\hat{f}(x)] = E[(\hat{f}(x) - E[\hat{f}(x)])^2]$$

$$O/\text{하 } f = f(x), \hat{f} \neq f(x) \text{ 일기}$$

$$\text{Var}[\epsilon] = \sigma^2$$

$$\text{Var}[y] = E[(y - E[y])^2] = E[(y - f)^2] = E[(f + \epsilon - f)^2] = E[\epsilon^2] = \text{Var}[\epsilon] + E[\epsilon]^2 = \sigma^2$$

$$E[(y - \hat{f})^2] = E[y^2 + \hat{f}^2 - 2y\hat{f}]$$

$$= E[y^2] + E[\hat{f}^2] - E[2y\hat{f}]$$



$$= \text{Var}[y] + E[y]^2 + \text{Var}[\hat{f}] + E[\hat{f}]^2 - 2fE[\hat{f}]$$

$$= \text{Var}[y] + \text{Var}[\hat{f}] + (f - E[\hat{f}])^2$$


$$= \sigma^2 + \text{Var}[\hat{f}] + \text{Bias}[\hat{f}]^2$$

Modeling : Explanatory, Predictive

회귀(Regression) 모델



분류(classification) 모델



Model Complexity: 모델이 데이터를 반복 학습하는 횟수가 늘어날수록 모델이 복잡한 정도

- ⑦ 학습횟수가 증가하면 MC도 따라서 늘어나게 되는데, 훈련용 데이터를 그대로 외우는 방향이기 때문....
- ⑦ Training Error는 점차 감소하게 되지만, Validation Error는 **아수** 준까지는 감소하다가, 어느 지점 이후부터는 다시 증가한다 ⑦ **모델을 훈련시키는 도중에 Validation Error가 최소인 지점에서 훈련을 멈추는 것이 필요!!!**
- ⑦ 모델을 한번 학습을 시켰다면 그것을 Validation Set으로 에러율이 얼마나 내려가는지 한번 더 확인해 보는 것 ⑦ Validation Set이 최적의 Error율을 보인다면 그 지점이 가장 학습이 잘 된 지점으로 생각하고 학습 중단
- ⑦ **그런 후에 Test Set으로 실제 모델 평가**

- **Training Error**: training data로 모델을 훈련시킬 때 발생하는 오차 ⑦ 데이터가 모델의 내부 구조를 변화시키면서 오차를 감소하는 것이 모델의 지향 방향
- **Validation Error**: 데이터로 모델을 평가할 때 발생하는 오차, 데이터가 모델의 내부 구조를 변화시키지 않고, 단지 validation용 데이터를 입력했을 때 모델이 어떤 결과를 반환하는지를 관찰

Model : Generalization

- **데이터 첨가(Data augmentation) 또는 데이터 증강**
 - ⑦ 주로 기계학습을 위해 새로운 데이터를 첨가하거나, 수를 늘리는 기법
- **Ensemble model**
- **Dropout** : Dropout은 딥러닝 학습에 있어서의 문제 중 하나인 Overfitting을 해소하기 위한 방법으로 네트워크의 유닛의 일부만 동작하고 일부는 동작하지 않도록 하는 방법

머신러닝 : Overfitting

1. Resampling 기법과 몬테카를로 방법을 통해 일반화 오류 평가

⑦ test set 과적합 : Resampling

- Up sampling : 시계열을 Low frequency에서 high frequency로 변환한다. 누락된 데이터를 채우거나 보간하는 방법을 포함한다. (월간data ⑦ 일간 data)
- Down sampling : 시계열을 high frequency에서 lo frequency로 변환한다. 기존 데이터를 집계하는 것을 포함. (주간 data -> 월 data) or (일간 data -> 주간 data)

2. 모델 복잡화를 규제화 하는 방법

- Ridge regression, **Lasso** regression

3. 추정기 집합의 예측을 결합 오차의 분산을 감소시키는 방법

- 앙상블 기법 : 예측 교차 검증, 각 트리 깊이 제한- 트리 추가

Model : Generalization

Overfitting 방지하자.!!!

Training Set vs. Validation Set

보유 데이터셋을 Training : Validation : Test set = 60% : 20% : 20% 로 분할)

1) **Training set** : 예측 혹은 분류 모델 훈련 Training + Validation

2) **Validation data** : Training set을 가지고 훈련 중인 모델이 혹시 **overfitting** 또는 **under-fitting**인 것은 아닌지 검증 하면서 최적의 적정 적합(**generalized-fitting**) 구간을 찾아 모델을 선택 후

3) **Test set** : 1)과 2)의 고려한 final model에 대하여 평가

Cross Validation

교차검증 통해 **일반화**(generalization)된 모델을 선택하는 데 도움

교차검증 목적


- : 보유하고 있는 데이터의 크기가 작아서 검증 데이터 세트를 분리 해내기가 여의치 않으면 교차 유효성 기법을 사용
- : 머신러닝 알고리즘의 일반화 오차를 알아내어 과적합을 막는 것
- : 데이터 일반구조를 알아내어 새로운 특징을 보고 미래를 예측할 수 있게 된다.

Cross Validation 방법

- 데이터 분포가 IID 만족하는 경우
: K-fold , Repeated K-Fold, Leave One Out (LOO), Leave P Out (LPO),) **Shuffle & Split**
- Data의 분포가 다른 경우 : Stratified K-Fold , Stratified Shuffle & Split
- 시계열 데이터의 경우 : Time Series Split

* Training data, Validation data, Test data

year-by-year rolling-over estimation



(사례1)

2001년부터 2007년의 자료를 추정표본(in-sample)으로 이용하여 추정된 모형으로 2008년 (예측표본; out-of-sample)에 부도예측모형을 평가

2002년부터 2008년의 자료를 추정표본으로 이용하여 추정된 모형으로 2009년(예측표본)에 부도예측모형을 평가

2001년부터 설정한 이유는 국내 기업이 1997년 외환위기 이후 진행된 기업구조조정에 의한 구조적 변화(structural change)를 경험한 것으로 판단

(사례2)

- 2000~2006년(7년) 학습 데이터
- 2007~2008년(2년) 검증 데이터
- 2009년 (1년) 테스트 데이터

* Robust 통계량

Robust 한 통계량

⑦ 이상치/에러값으로 부터 영향을 크게 받지 않는 통계량

▪ **robust Correlation**

▪ **robust regression**

OLS를 적용하는 모든 예측상황에서 사용 가능하며, 가중치 메커니즘을 사용해 영향력 있는 관측치를 낮춰 줌

⑦ 데이터에서 이상치를 제외시킬 강력한 이유가 없는 경우에 유용함

➔ 잔차의 제곱을 이용하는 최소제곱법 대신에 절대값의 합이 최소가 되도록 계수를 추정하는 방식

Training data 를 기반으로 만들어진 모델이 견고 한지를 테스트하는 것


⑦ 주어진 data (training data) 로 만들어 진 모델이 새로운 data나.

⑦ 극단치와 결측치가 모형의 결과에 어떤 영향을 주는지를 확인하기 위해 극단치와 결측치를 조정하지 않은 데이터에 기초해 모형을 구축하고 그 결과를 확인.

Hyperparameter Tuning (Optimization)

방법	내용
GridSearchCV	: <u>일정한 간격을</u> 두고 실험할 하이퍼파라미터들을 2차원으로 그려보면 모양이 마치 <u>격자와 유사해서 Grid Search</u> 명명 : 모든 조합에 대해 교차검증 후 가장 좋은 성능을 내는 하이퍼파라미터 조합을 찾음 - 검증하고 싶은 <u>하이퍼파라미터 명시적으로 수치를 지정하는 것</u> 🔗 데이터가 너무 크다면 일단 트리 수를 줄이고, 기본적인 파라미터만 튜닝한 이후에 점차적으로 늘려가는 방법 사용
RandomizedSearchCV	hyperparameter의 <u>최소, 최대값을 정해두고 범위 내에서</u> 무작위 값을 정해진 횟수만큼 반복적으로 추출하여 최적의 조합을 찾는 것을 의미 🔗 Grid Search 와 달리 <u>하이퍼파라미터로 시도할 숫자의 구간과, 횟수를 정해주는 것!!!</u> 🔗 결과적으로 <u>랜덤하게 적절한 수의 조합으로 최적 파라미터 테스트를 해주는 객체</u> 🔗 <u>분류에만 쓸 수 있는 알고리즘</u>

Random Search for Hyper-Parameter Optimization : James Bergstra , Yoshua Bengio 2012



Hyperparameter Tuning (Optimization)

leave it alone unless you know what you are doing.

하이퍼파라미터 튜닝보다는 파생변수 생성에 집중하는 것이 성능을 높이는데 더 효과적인 방법 !!!

방법	내용
GridSearchCV	- Curse of Dimensionality가 발생 : 검색해야 할 hyperparameter의 수가 많아질수록, 검색하는 횟수가 exponential 하게 증가 - 구간마다 탐색을 수행하기 때문에 Global Optimum 를 찾기 어렵다. - 만약 설정된 구간 내 2 혹은 18이 최적해라고 할 때, grid search를 통해 최적해를 찾는 경우 (구간이 5로 결정) 5, 10, 15, 20, ..의 경우값을 바탕으로 최적해 탐색 → 위의 경우 결정된 최적해의 경우 Local Optimum이 되는 것
RandomizedSearchCV	- 무작위로 hyperparameter를 선택하여 그에 대한 결과를 만들고, 그중 가장 좋은 값을 도출한 hyperparameter를 최적해 결정-무작위 함수를 수식으로 표현하기 위해 활용되는 파라미터는 random seed 하나로, 이 값만 설정되어 있다면 확인해 볼 hyperparameter를 결정 가능 - 한정된 비용(=탐색 횟수) 안에서 유용한 방법 ① grid search의 문제 중 하나였던 Curse of Dimensionality 해소 - 최적해를 찾는데 다소 부적합 - Random search를 통해 도출된 결과값은 표본(샘플)으로서 활용되어, 목표를 달성하기 위한 힌트로서 활용될 수 있지만, 그러나 무작위로 값을 선택하기 때문에, 도출된 값이 최적인지 아닌지 판단할 수 있는 방법이 없다.

Hyperparameter Tuning (Optimization)

구분	GridSearchCV	RandomizedSearchCV
주요 매개변수	- estimator : 모델 객체를 지정 변수 - param_grid : 하이퍼파라미터 목록을 dictionary로 전달 - scoring : 평가 지표 - cv : 교차검증 시 fold 개수 - n_jobs : 사용할 CPU 코어 개수 (1: 기본값, -1: 모든 코어 다 사용)	- estimator : 모델 객체 지정 - param_distributions : 하이퍼파라미터 목록을 dictionary로 전달 - n_iter : 파라미터 검색 횟수
<u>메소드</u>	- fit(X, y) : 학습 - predict(X) : 분류-추론한 class, 회귀-추론한 값, 제일 좋은 성능을 낸 모델로 예측 - predict_proba(X) : 분류문제에서 class별 확률을 반환, 제일 좋은 성능을 낸 모델로 predict_proba() 호출	
<u>결과 조회 변수</u>	- cv_results_ : 파라미터 조합별 평가 결과를 Dictionary로 반환 - best_params_ : 가장 좋은 성능을 낸 parameter 조합 조회 - best_estimator_ : 가장 좋은 성능을 낸 모델 반환	

Hyperparameter Tuning (Optimization)

방법	내용
Manual search	▪ 사용자가 뽑은 조합 내에서 최적의 조합을 찾는 것을 의미
. Bayesian optimization	단순히 무작위 추출을 반복하는 것보다, 기존에 추출되어 평가된 결과를 바탕으로 앞으로 탐색할 범위를 더욱 좁혀 효율적이게 시행하는 아이디어에서 시작 ⑦ Bayesian theory 및 Gaussian process(GP)를 통해 구현한 것이 베이지안 최적화 방법 B. Shahriari, K. Swersky, Z. Wang, R. P. Adams and N. de Freitas, "Taking the Human Out of the Loop: A Review of Bayesian Optimization," in Proceedings of the IEEE, 2015 (장점) <u>불필요한 파라미터의 반복 탐색을 줄여 시간 대비 탁월한 성능</u> ⑦ 현재 hyperparameter 최적화의 주류 ⑦ 베이지안 최적화의 속도 향상을 목적으로 한 연구가 주로 진행 ⑦ Bayesian optimization은 알려지지 않은 목적 함수를 최대/최소로 하는 최적해를 찾는 기법 ⑦ <u>surrogate model과 acquisition function로 구성</u> : surrogate model : 현재까지 조사된 입력값-함수값 점들을 바탕으로 미지의 목적함수 $f(x)$를 추정하는 확률모델 : Acquisition Function: 목적 함수에 대한 현재까지의 확률적 추정 결과를 바탕으로, '최적 입력값을 찾는 데 있어 가장 유용할 만한' 다음 입력값 후보를 추천해 주는 함수


* Model : Summary

구분	모형설명	장점	단점
회귀모형	· 부도예측에 필요한 독립변수를 선형결합하여 지표를 산출해서 부도가능성을 파악	· 부도와 밀접한 상관관계 또는 인과관계를 갖는 변수들을 독립변수로 이용해서 기업의 상태를 파악 · 분석방법이 단순하면서도 실증적임	· 각 독립변수가 부도에 미치는 영향이 일정하다고 강조
판별분석	· 회귀분석과 구조 동일 · 부도기업의 종속변수와 비부도기업의 종속변수의 값이 평균적으로 가장 큰 차이를 갖도록 하는 추정방법	· 독립변수와 부도와의 인과관계나 상관관계의 원인 등에 대한 뚜렷한 규명 없이도 비교적 단순한 방법으로 부도여부를 판정 가능	· 동일한 독립변수를 사용할 경우 회귀분석 결과와 크게 다르지 않음 · 부도여부를 판정하는 것 외에는 다른 의미를 해석하기 어려움
로짓모형	· 독립변수는 연속값을 갖고 종속변수는 이산적(discrete) 범주형 변수 사용	· 부도여부를 판별하는 것 외에도 신용등급과 같이 등급을 구분하는 것에도 활용하기에 용이	· 부도발생원인과 독립변수 간 명확한 관계규명에 한계
프로빗모형	· 개별 독립변수들이 독립적으로 특정한 분포를 따르고 이들 분포들이 결합확률분포에 의해 부도확률이 결정됨을 가정 · 독립변수가 부도 가능성에 미치는 영향이 일정하지 않음을 가정	· 종속변수의 값이 부도확률을 나타내기 때문에 부도 여부의 판정 외에도 부도 가능성을 점수화 할 수 있음	· 부도발생원인과 독립변수간의 관계를 명확하게 규명하지는 못함
생존모형	· 독립변수들을 이용하여 기업의 수명을 추정하는 모형	· 기업이 소멸한다는 현실을 감안한 모델	· 전통적인 부도예측모델의 문제점, 즉 부도발생원인과 독립변수와의 관계를 명확하게 규명하지는 못함

전문건설업체 부도예측모형에 관한 연구(대한건설정책연구원)


* Team Project

Project Design




➡ ⑦ Rank Feature Selection ➡


Modeling



Analysis package




Test evaluation



Correlation Analysis

1. Statistical Analysis?
2. Correlation Analysis
3. Pearson correlation analysis
4. 기타 correlation analysis
 - Spearman 순위 상관계수
 - Kendall의 순위상관계수
 - 시차상관계수
 - 자기상관계수
 - 양류상관계수
 - 양분상관계수
5. Correlation Analysis Issue

Statistical Analysis?



차이검정	• 집단 (집단 2개 이내) 평균차이 검정 → t검정 • 분산(집단3개 이상) 차이 검정 ⑦ ANOVA 분석
관계검정	▪ 상관분석 : 연속변수 + 연속변수 , 두 변수간 선형관계 ▪ 회귀분석 : 연속변수, 연속변수, 변수간 인과관계 ▪ 교차분석 : 명목형변수 (범주형 변수) 간 빈도이용 연관성 분석

Statistical Analysis

통계분석을 할 때 어떤 모델로 해야 하나요?

1. 분석가가 수행하고자 하는 분석인 무엇인가?

- 1) 집단들간 차이가 있는지 알기 위한 분석인지? (**차이검정**)
- 2) 각 변수 간 연관성이 있는지를 알아보기 위한 통계분석인지(**관계검정**)를 파악한다.

2. 차이검정인 경우

- 1) 비교 대상 집단이 2개인지?(t-test) , 비교대상 집단이 3개이상 인지(ANOVA)를 확인한다.
- 2) 집단 간 자료가 독립적인 자료인지를 파악한다. (독립표본, 대응표본)
- 3) 종속변수가 연속변수인지? 범주형 변수인지를 파악한다.
 - 연속변수인 경우 정규분포 (모수적 통계기법) 경우, 또는 비모수적 통계기법을 사용
 - 범주형변수인 경우 명목변수인지? 서열척도인지를 파악한다.

3. 관계검정인 경우

- ⑦ 기술통계량 계산을 선행적으로 실시
- 1) 변수간 상관관계를 파악하는 것인지? (상관분석)
 - ⑦ 피어슨상관계수 : 비율척도, 등간척도 인 경우 스피어만, 켄달 : 순위척도인 경우 비모수 통계
 - 2) 연속형변수간 인과관계를 분석하고자 하는 것인지? (회귀분석)
 - 3) 명목형 변수간 연관성 분석하고자 하는 경우? (카이제곱 검정)

* Linear

Linear ?

1. Additivity (가법성) , superposition (중첩성)

- ⑦ 각각 다른 두 입력에 대한 두 출력이, 그 두 입력을 더해서 입력하면 출력도 더해져서 나타난다는 것

$$f(x_1 + x_2) = f(x_1) + f(x_2)$$

2. Homogeneity(동질성, 동차성, 비례성)

- 어떤 입력에 대한 출력을 가지는 시스템이 그 입력에 상수배를 하면 출력도 그대로 상수배로 나타난다는 것

$$f(ax_1) = af(x_1)$$

superposition principle

개별 요소의 연산 결과를 합한 것이 개별 요소를 합한 후 연산한 결과와 같은 것

- ⑦ 가산성과 비례성을 모두 만족하는 것으로 중첩의 원리가 적용되는 시스템을 선형 시스템이라고 한다.

→ 위 2가지 조건을 만족하는 function/operation에 대하여 선형성을 가진다고 한다.

$$f(a_1x_1 + a_2x_2) = a_1f(x_1) + a_2f(x_2)$$

- 직선의 그래프 경우라도, $f(x) = mx+b$ 처럼 $bias(b)$ 를 가지고 있는 경우 선형성을 만족하지 않는다.

- ⑦ $m(a_1x_1 + a_2x_2) + b \neq a_1(mx_1 + b) + a_2(mx_2 + b)$

- ⑦ $f(x) = 2x + 5$ 인 경우 $f(1) + f(2) \neq f(3)$

- 선형성을 가질 경우 예측이 가능하고 (중첩 원리를 만족하므로), 비선형성을 가질 경우 예측이 어렵다.(머신러닝)

(주의) 선형함수에서 선형의 의미는 "차수가 1 이하인 다항식" 임을 주의

- *Linear regression is linear model*

- *Logistic regression is nonlinear model*

Linear ?

1. 수학적 정의

: 선형(linear)은 일차방정식 형태로 표현될 수 있는 관계를 의미

예를 들어, 함수 $f(x)=mx+b$ 는 선형 함수이다.

여기서 m 과 b 는 상수

2. 수학 및 대수학에서의 선형 변환

: 특정 벡터 공간의 요소에 적용되는 변환으로, 이 변환은 덧셈과 스칼라 곱셈에 대해 닫혀 있다.

즉, $f(x+y)=f(x)+f(y)$ 및 $f(ax)=af(x)$ 와 같은 성질을 만족한다.

3. 통계학에서의 선형 회귀

: 독립변수의 선형 조합을 사용하여 종속변수의 값을 예측하는 모델이다.

선형 회귀는 데이터 사이의 직선적 관계를 가정한다.

4. 컴퓨터 과학에서의 선형 알고리즘

: 시간이나 공간이 입력 크기에 비례하여 증가하는 알고리즘을 의미한다.

예를 들어, 선형 탐색 알고리즘은 입력 크기에 직접적으로 비례하는 시간이 소요된다.

Correlation Analysis


1. 상관(관계)분석이란?

- 두 변수 사이의 관련성(선형관계)을 파악하는 방법 (상호 연관성 정도) ⑦ 동일 방향여부(공분산) + 강도
- ⑦ 두 변수간의 관계의 강도를 상관관계로 나타내는 것이며, 인과관계를 설명하는 것은 아님(인과관계는 회귀분석으로)
- ⑦ X_1 변수가 상승함에 따라 X_2 변수도 상승되는지 혹은 하락하는지를 분석하는 것
- ⑦ 상관분석은 두 변수의 선형관계만을 의미, 인과관계를 의미하는 것은 아니다.
- ⑦ 회귀분석을 수행하기 위해서는 우선적으로 독립변수와 종속변수 간에 의미있는 상관관계가 있는지를 파악해야 한다.

2. 상관관계 파악하는 방법

1) 산점도 그래프

두 변수간 관련성은 각 케이스의 값을 좌표위에 점으로 표시한 산점도(scatter plot) 그래프를 통해 한 눈에 확인 가능



상관분석이나, 회귀분석을 위한 회귀식을 만들 때도 사전에 산점도부터 그리는 것은 무조건!!

Correlation Analysis

3. 상관관계 구분

- 상관분석은 두 변수 간 선형적인 관계 정도를 분석하는 방법
 - ⑦ **상관계수(correlation coefficient)**를 사용
- 상관분석에는 **측정 데이터, 표본 분포에 따라** 피어슨 상관분석 (Pearson correlation coefficient), Spearman 순위 상관계수 등의 여러가지 분석 방법

구분	데이터 유형	분포
. Pearson 상관계수 (Pearson correlation analysis)	연속형 변수, 등간척도, 비율척도 간 상관관계 ⑦ 수치적 데이터 변수의 상관분석 활용	• 모수적 방법 • (Parametric method) : 정규분포
Spearman 순위 상관계수 (Rank correlation coefficient)	명목변수 (서열척도/순위척도)	비모수적 방법 (Non-parametric method)
Kendall 의 순위상관계수 (rank correlation coefficient)	명목변수 (서열척도/순위척도) 표본이 작을 때	비모수적 방법(Non-parametric method)

Correlation Analysis

4. 상관분석 실시 전 유의할 점

1. 이상치(outliers)에 의한 인위적 상관 존재 가능성

- ⑦ 데이터 집합에 나머지 값들과 매우 다른 값이 하나 있으면 상관계수의 값이 크게 변경될 수 있다.
- ⑦ 극단값의 원인을 식별해야 한다.
- ⑦ 자료 내에 극단치가 있을 때: 존재하지 않는 상관관계가 포착되거나, 존재하는 상관관계가 포착되지 못하는 경우가 생기기도 함

2. 등분산성이 어느 정도 만족해야 한다.

- ⑦ X변수가 변할 때, Y 변수의 변화 정도가 어느 정도 동일 해야 한다.

3. 두 변수의 관계가 선형적인지 여부를 산점도로 사전 확인할 것

- ⑦ 명확하게 두 변수의 관계가 비선형형태라면 spearman이나 kendall의 방법 사용이 필요

5. 상관분석 결과 해석 시 유의할 점

• 두 변수의 상관관계는 인과관계를 담보하지 않음 (Direction of causality) : 상관관계가 있다고 반드시 인과관계가 있는 것은 아님

제3변수 문제 (The third-variable problem) : 제3의 변수가 두 변수 사이의 관계에 영향을 줄 수 있다.

- ⑦ 측정되거나 측정되지 않는 다른 변수들이 결과에 영향을 주기 때문에
 - 도시 내 범죄 발생 건수와 종교 시설의 수는 양의 상관 관계가 있음
 - 범죄가 많아서 종교에 의존하는가? 또는 종교가 범죄를 부추기는가?
 - 사실은 인구가 많아지면 범죄도 늘고, 종교 시설도 많아진다.
- 이질적인 집단들의 합 (심슨의 역설)
 - 각 집단별 상관관계와 전체 총합의 상관관계는 다를 수 있음
 - 상관분석 결과가 예상과 다를 경우, 이질적인 하위집단들이 존재하는지 살펴봐야 할 수도 있음

Correlation Analysis : Pearson

1. 피어슨 상관분석(Pearson correlation analysis)

- 연속형 변수, 등간척도, 비율척도 간 상관관계
- 수치적 데이터 변수로 이루어진 두 변수 간의 선형적 연관성을 계량적으로 파악하기 위한 통계적 기법
- ➔ 피어슨 (+correlation analysis)을 선형관련성 정도로 측정하는 척도로 사용 계산
- 두 자산수익률의 공분산(Covariance)를 두 변수 간의 표준편차 곱으로 나눈 값
- ⑦ 적률상관계수 (Pearson product moment correlation)
- ⑦ 모수적 방법 (Parametric method)

가정

1. **선형성**
: 변수간 선형(linear)의 관계 여부 파악 ⑦ 산점도로 살펴보기
2. **등분산성**
: X 값과 관계없이 Y의 분포에 대한 산포도가 동일 ⑦ Levene test
3. **정규분포**
: 두 변수의 측정치 분포가 모집단에서 정규분포를 이룬다
독립된 집단 두 개이기 때문에 정규성 과정 두 번 실시 ⑦ Shapiro-Wilk. test
4. **독립성**
: 모집단에서 표본을 추출할 때 표본대상이 확률적으로 선정된다는 것
두 확률변수 X, Y가 서로 독립이면 $Cov(X, Y) = 0$


Correlation Analysis : Pearson

1. 피어슨 상관분석(Pearson correlation analysis)

상관계수 계산

피어슨의 표본상관계수 (sample correlation coefficient)는 확률표본을 사용하여 모상관계수 ρ 를 추정한 추정치이며 기호로 r 로 표현

- **두 변수의 공분산을 각각의 표준편차의 곱으로 나누어 표준화 한 값**
- **값의 범위 : -1에서 1사이의 값**
- **1 또는 -1에 가까울수록 상관관계는 높아짐. 0 이면 선형상관관계가 없는 것**



$$\begin{aligned}\text{모상관계수 } (\rho_{XY}) &= \text{Corr } X(Y) \\ &= \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} \\ &= \frac{E(X - \mu_X)(Y - \mu_Y)}{\sqrt{E(X - \mu_X)^2} \sqrt{E(Y - \mu_Y)^2}}\end{aligned}$$

$$\text{표본상관계수 } (r_{XY}) = \frac{\sigma_{\bar{X}\bar{Y}}}{\sqrt{\sigma(\bar{X}-\bar{X})^2} \sqrt{\sigma(\bar{Y}-\bar{Y})^2}}$$

$$r = \frac{s_{XY}}{s_X \cdot s_Y} = \frac{\frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{(n-1)}}{\sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{(n-1)}} \cdot \sqrt{\frac{\sum_{i=1}^n (y_i - \bar{y})^2}{(n-1)}}}$$

$$S_{XY} = \frac{\sigma_{\bar{X}\bar{Y}}}{n-1}$$

주가수익률(x,y)간 상관계수

$$\text{Cor}(R_x, R_y) = \frac{\text{Cov}(R_x, R_y)}{\sigma_{R_x} \sigma_{R_y}}$$

⑦ 가격의 로그수익률로 사용시 정규분포를 이룰 가능성

Correlation Analysis : Pearson

1. 피어슨 상관분석(Pearson correlation analysis)

(활용)

- EDA (Exploratory Data Analysis)
- 다중선형회귀분석: 다중공선성 존재 여부를 사전 점검하는 경우

Correlation Analysis 다시 보기

$$\begin{aligned}\text{모상관계수}(\rho_{XY}) &= \text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} \\ &= \frac{E(X - \mu_X)(Y - \mu_Y)}{\sqrt{E(X - \mu_X)^2} \sqrt{E(Y - \mu_Y)^2}}\end{aligned}$$



$$\text{표본상관계수}(r_{XY}) = \frac{\sigma_{i=1}^n (X - \bar{X})(Y - \bar{Y})}{\sqrt{\sigma(X - \bar{X})^2} \sqrt{\sigma(Y - \bar{Y})^2}}$$

Pearson Correlation : Z- scores 의 평균

$$Z = \frac{X - \mu}{\sigma} = \frac{\text{관측값} - \text{평균}}{\text{표준편차}}$$



$$r_{XY} = \frac{1}{n-1} \sigma_{i=1}^n \left(\frac{x_i - \bar{x}}{s_x} \right) \left(\frac{y_i - \bar{y}}{s_y} \right)$$

Correlation Analysis : Pearson

상관분석에 대한 가설검정 (유의성 검증)

- **표본상관계수(r_{xy})**가 통계적 유의한지 여부 검증
- 연구자가 구한 상관계수는 표본에서 구한 것 ❶ 동일한 모집단에서도 표본에 따라 상관계수가 달라질 수 있으므로 통계적 검증이 필요

(가설 검정)

- 귀무가설 (H_0) : 상관계수는 0이다 (상관관계가 없다 ❷ $\rho = 0$)
- 대립가설 (H_1) : 상관계수는 0이 아니다 (상관관계가 있다. ❷ $\rho \neq 0$)

검정통계량(t-value)

$$t_{stat} = \frac{r - \rho_0}{\frac{\sqrt{1 - r^2}}{\sqrt{n - 2}}}$$

$$r \sqrt{\frac{n - 2}{1 - r^2}} \sim t(n - 2)$$

#두 변수의 피어슨 상관계수와 p 값을 계산 : python

상관분석 자유도가 n-2인 이유는
독립변수 X와 종속변수 Y의 관계를 설명하는
회귀분석에서 추정하는 모수가 2개이기 때문 !!!

$$t\text{-value} = \frac{\bar{X}_A - \bar{X}_B}{\frac{s}{\sqrt{n}}}$$

(결과)

- 만약, 상관계수는 0.92이고 p 값은 0.001 인 경우
- p-value < 0.05 : 귀무가설을 기각하고 대립가설 채택으로 통계적으로 유의미하다"라고 할 수 있다. ❷ 상관계수가 0 과 다르다는 결론

상관분석 결과를 해석하는 데 주의할 점

상관분석 결과 귀무가설이 기각되지 않았다는 것은 변수 간에 선형관계(linear relationship)만 없다는 의미이지, 두 변수 사이에 아무런 관계가 없다는 의미가 아니라는 것이다.

만약 두 변수가 상호 독립이라면 상관계수의 값은 0이 나오지만 상관계수가 0이 나왔다는 것이 변수간에 독립성을 의미하는 것은 아니라는 것이다.

Correlation Analysis : Pearson

1. 피어슨 상관분석(Pearson correlation analysis)

Pearson 상관 계수는 정규 분포에 대한 두 변수 간의 상관관계를 추정하는 좋은 방법

(문제점)

- 극단값의 영향을 크게 받는다.
- Winsorized 상관관계는 꼬리 값을 특정 백분위수 값과 동일하게 설정하여 이 문제를 해결
- 90% Winsorized 상관 관계의 경우 값의 하위 5%는 5번째 백분위수에 해당하는 값과 동일하게 설정되고 값의 상위 5%는 95번째 백분위수에 해당하는 값과 동일하게 설정

* Correlation & Feature Importance

Correlation 과 Feature Importance의 관계

feature importance

- Tree-based model에서 사용
- (의미) 특정 feature가 트리를 분할하는데 얼마나 기여를 했는지에 따라 중요도가 결정되는 것

머신러닝

- **상관분석** : Target과 Feature 간에 선형 상관관계를 파악하기 위해 Correlation Heatmap을 그려서 상관계수 확인
- **트리계열 머신러닝** : Feature importance를 통해 변수의 중요도 파악

Correlation이 높은 Feature들이 feature importance도 높다.??

- Target과의 상관계수가 높은 Feature가 0과 1로 Target을 Split할 때 많이 인용될 것이므로

(그러나)

Pearson Correlation은 연속형 피쳐들 끼리 비교 ⑦ 그런데, classification 문제에서는 Target 이 0 과 1

- ⑦ Feature와 Target간의 상관관계는 classification 문제에서는 많이 감안하지 않는다.
- **Feature importance** 역시 Feature와 Target간 상관도가 높으면 역시 높은 경향은 있지만 반드시 비례하지는 않는다.
- Feature importance는 트리 기반에서 불확실성을 줄여주는 레벨로 평가 ⑦ Feature의 특정 값 범위에 따라서 확실하게 타겟값에 이를 수 있다면 상관정도와 무관하게 높은 평가

* Correlation Analysis : Practice example

$$\text{모상관계수}(\rho_{XY}) = \text{Corr}(X,Y) = \frac{\text{Cov}(X,Y)}{\sigma_X \sigma_Y}$$

$$= \frac{E(X - \mu_X)(Y - \mu_Y)}{\sqrt{E(X - \mu_X)^2} \sqrt{E(Y - \mu_Y)^2}}$$

$$\text{상관계수}(\rho_{XY}) =$$

	X	Y	X 편차 (X_D) ($X_i - m$)	Y 편차 (Y_D) ($Y_i - m$)	X편차 제곱 ($X_i - m$) ²	Y편차 제곱 ($Y_i - m$) ²	편차의 곱 ($X_D \times Y_D$)
	5	2					
	5	8					
	6	2					
	4	4					
σ	20	16					
mean	5	4			(Variance)	((Variance)	(Covariance)
N	4	4			(SD)	(SD)	

- **제곱합**(Sum of Square : SS) : 제곱합의 특성상 N 이 많아지면 커진다
- **분산**(변량)(Variance) : 제곱합을 N으로 나누어주어 단위당으로 표준화
- **공분산**(공변량)(Covariance)
- **표준편차**(standard deviation :SD) : 분산을 제곱근한 것

X와 Y 상관계수

* Correlation Analysis : Practice example

$$\begin{aligned} \text{모상관계수}(\rho_{XY}) &= \text{Corr}(X,Y) = \frac{\text{Cov}(X,Y)}{\sigma_X \sigma_Y} \\ &= \frac{E(X - \mu_X)(Y - \mu_Y)}{\sqrt{E(X - \mu_X)^2} \sqrt{E(Y - \mu_Y)^2}} \end{aligned}$$

$$\text{상관계수}(\rho_{XY}) =$$

	X	Y	X 편차 (X_D) ($X_i - m$)	Y 편차 (Y_D) ($Y_i - m$)	X편차제곱 ($X_i - m$) ²	Y편차제곱 ($Y_i - m$) ²	편차의 곱 ($X_D \times Y_D$)
	5	10					
	5	5					
	6	5					
	4	12					
σ	20	32					
mean	5	8					
N	4	4					

X와 Y 상관계수 !!!!!!!!!!!!!

-0.80295


* Correlation Analysis : Practice example

피어슨 상관계수

	Y (target) 평점	X (feature)	편차의 제곱 y_i $(Y_i - \bar{Y})^2$	편차의 제곱 x_i $(X_i - \bar{X})^2$	편차의 곱
A	10	32	15.21	94.09	37.83
B	7	18	0.81	18.49	-3.87
C	8	25	3.61	7.29	5.13
D	5	13	1.21	86.49	10.23
E	9	29	8.41	44.89	19.43
F	6	21	0.01	1.69	0.13
G	2	10	16.81	151.29	50.43
H	7	43	0.81	428.49	18.63
I	3	12	9.61	106.09	31.93
J	4	20	4.41	5.29	4.83
합	61	223	60.9	944.1	174.7
평균	6.1	22.3	6.09	94.41	17.47
분산	6.76666667	104.9	37.9306667	16376.5973	315.078222
표준 편차	2.60128174	10.2420701			

공분산 $COV(X, Y) = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{n - 1} \Rightarrow \frac{174.7}{(10 - 1)} \approx 19.411$

피어슨 상관계수 $r(X, Y) = \frac{COV(X, Y)}{\sigma_X \times \sigma_Y} \Rightarrow \frac{19.411}{(2.60128 \times 10.242)} \approx 0.72857$



$$\sigma_Y = \sqrt{\frac{\sum (Y_i - \bar{Y})^2}{n}}$$

$$\sigma_X = \sqrt{\frac{\sum (X_i - \bar{X})^2}{n}}$$

* Correlation Analysis : Practice example


결정 계수 (R²)

$$R^2 \text{ 결정 계수} = 1 - \frac{SSE}{SST} (= \frac{SSR}{SST}) \quad \text{전체의 변동 중 설명 가능한 변동의 비율 (회귀 식의 설명력)}$$

$$= 1 - \frac{28.57282067577587}{60.9} \approx 0.53082$$

$$R^2 = 1 - \frac{SSE : \sum (Y_i - \hat{Y}_i)^2}{SST : \sum (Y_i - \bar{Y})^2}$$

SSE (잔차의 제곱 합) SST (편차의 제곱 합)




피어슨 상관계수

$$r(X, Y) = \frac{COV(X, Y)}{\sigma_X \times \sigma_Y} \Rightarrow \frac{19.411}{(2.60128 \times 10.242)} \approx 0.72857$$

$$r(X, Y)^2 \approx 0.72857^2 = 0.53082 \Rightarrow R^2$$

피어슨 상관계수의 제곱 = 결정 계수



* Correlation Analysis : Practice example

1. kospi 와 삼성전자
2. kospi 와 소형주(선택)
3. 삼성전자와 sk하이닉스



Insight

주식시장 분석시 주의 할 점!!!

Correlation Analysis : Spearman

2. Spearman 순위 상관계수(Rank correlation coefficient)

- 순서가 중요한 의미가 있는 **순서적 데이터 (서열척도/순위척도)**들로 이루어진 두 변수 간의 연관성 및 상관관계를 검정하기 위한 통계적 분석 기법
- 스피어만 순위 상관계수는 원 데이터 대신 이들의 **순위(rank)를 이용하여 상관계수를 결정** (예시:학점, 내신등급..)

언제 사용?

- 정규성을 만족하지 않는 경우
- 순위형 자료인 경우
- 비모수적 방법(Non-parametric method) : 자료의 수가 적을 경우나, 치우침을 큰 경우 사용

$$\rho = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2} \sqrt{\sum_i (y_i - \bar{y})^2}}$$

$$r = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

$d_i = x_i - y_i$

d 는 x 의 순위와 y 순위의 차를 의미

⑦ **상관계수 값의 범위 : -1부터 +1까지**

⑦ 계수의 절대값이 클수록 변수 사이에 강한 상관관계

(사례)

고객의 매장방문 빈도 와 월별 구매액 간의 상관관계를 파악하고자 하는 문제가 이에 해당

- **영어 점수와 수학 점수 간의 상관 계수는 피어슨 상관 계수로 계산**
- **영어 성적 석차와 수학 성적 석차의 상관 계수는 스피어만 상관 계수로 계산**

Correlation Analysis : Kendall

3. Kendall의 순위상관계수(rank correlation coefficient)

- 비모수적 방법 (Non-parametric method)
- 정규성 가정이 성립하지 않는 경우 사용
- 비선형적 관계이거나 순서형변수일 때 사용
- 켄달 타우는 두 변수들 간의 순위를 비교하여 연관성을 계산
- 특히 표본이 작을 때 spearman의 상관계수보다 믿을 만한 것으로 알려짐
- 설문조사에서 리커드 척도 문항 각각의 상관계수를 구할 때 이용

$$\text{Kendall tau} = \frac{C - D}{C + D}$$

- concordant pair(C): 각 변수의 비교 대상의 상하 관계가 동일한 경우 수
- discordant pair(D) : concordant pair가 아닌 수
- 값의 범위 : -1 ~ 1

검정통계량

$$T = \frac{\sum_{i < j} \text{sgn}(x_i - x_j) \text{sgn}(y_i - y_j)}{\sqrt{(T_0 - T_1)(T_0 - T_2)}}, \text{ where } \begin{cases} T_0 = n(n-1)/2 \\ T_1 = \sum t_i(t_i-1)/2 \\ T_2 = \sum u_i(u_i-1)/2 \end{cases}$$

Lag correlation coefficient

교차상관계수(cross correlation)

- 동일한 시점에서 두 변수 간의 관계를 평가

: GDP와의 동행성(comovement) 측정 · 경기순응적(pro-cyclical) / 경기중립적(a-cyclical) / 경기역행적(counter-cyclical)

시차상관계수 (Lag correlation coefficient)

- 시계열 분석에서 두 시계열 데이터 간의 상관관계를 시차(lag)를 적용하여 측정하는 지표
- 특정 시간 간격(시차)을 두고 한 시계열이 다른 시계열과 얼마나 잘 일치 여부 제공
- 시차상관계수는 시계열 데이터에서 시간적 지연이 다른 변수에 어떤 영향을 미치는지 이해하는 데 유용
GDP에 대한 선행성 측정 · 경기선행적(leading) / 경기동행적(coincident) / 경기후행적(lagging)
- **시차(Lag)**: 한 시계열이 다른 시계열보다 얼마나 늦게(또는 빠르게) 움직이는지를 나타내는 시간 단위
- ❶ 시차가 양수(+)라면 첫 번째 시계열이 두 번째 시계열보다 후행한다는 의미이며, 음수(-) 라면 선행한다는 의미

시차상관계수 계산

두 시계열 x 와 y 가 주어졌을 때, x 를 일정 시간만큼 지연시킨 후 y 와의 상관계수를 계산하여 얻는다.

$$r_k = \frac{\sum_{t=1}^{N-k} (X_t - \bar{X})(Y_{t+k} - \bar{Y})}{\sqrt{\sum_{t=1}^N (X_t - \bar{X})^2} \sqrt{\sum_{t=1}^N (Y_t - \bar{Y})^2}}$$

시차상관계수 해석

양(+)의 시차상관계수	x 의 과거 값이 y 의 미래 값과 양의 상관관계를 가질 때 나타난다. ❶ x 가 증가하면 y 도 시차를 두고 증가한다는 것을 의미
음(-)의 시차상관계수	x 의 과거 값이 y 의 미래 값과 음의 상관관계를 가질 때 나타난다. ❶ x 가 증가하면 y 는 시차를 두고 감소한다는 것을 의미
0에 가까울 경우	x 와 y 사이에는 시차를 두고 별다른 상관관계가 없다는 것을 의미

Lag correlation coefficient

(교차상관계수와 시차상관계수)

- t 기의 특정(기준)변수 x 의 값(x_t)과 $t+k$ 기에 관찰된 y 값(y_{t+k}) 간의 상관관계의 정도
- $k=0$ 인 경우 즉, γ_0 인 경우를 교차상관계수(cross correlation coefficient)
- $k \neq 0$ 인 경우를 시차상관계수(leads and lags correlation)

교차상관계수 해석

양(+)의 교차상관계수	두 변수들이 서로 같은 방향으로 변화 ⑦ pro-cyclical: <u>경기 순응적</u>
음(-)의 교차상관계수	두 변수들이 서로 반대 방향으로 변화 ⑦ counter-cyclical: <u>경기 역행적</u>
0에 가까울 경우	두 변수들이 서로 경기 독립적(중립적)

시차상관계수 해석 (금리와 주가)

- γ_k 의 값이 최대가 되는 시차 k 가 양(+)이면 해당변수 y_t 는 x_t 의 후행지표
- γ_k 의 값이 최대가 되는 시차 k 가 음(-)이면 해당변수 y_t 는 x_t 의 선행지표
- γ_k 의 값이 최대가 되는 시차 k 가 0이면 해당변수 y_t 는 x_t 와 동행지표

Lag correlation coefficient

시차상관관계분석 절차

1. **데이터 준비:** 분석하고자 하는 두 시계열 데이터를 준비
2. **시차 결정:** 분석할 최대 시차를 결정 ⑦ 이는 분석의 범위를 정하는 단계
3. **상관계수 계산:** 각 시차에 대해 두 시계열 간의 상관계수를 계산 ⑦ 이를 통해, 특정 시차에서의 두 시계열 간의 상관 관계를 파악할 수 있다.
4. **결과 해석:** 계산된 상관계수를 바탕으로, 두 시계열 간의 시차상관관계를 해석 ⑦ 상관계수가 높은 시차를 중심으로 두 시계열 간의 영향력과 그 시점을 파악할 수 있다.

유의사항

- 시차상관관계분석은 두 시계열 간의 선형적 관계만을 탐색한다. ⑦ 비선형 관계는 이 방법으로 파악하기 어렵다.
- 상관관계는 인과관계를 의미하지 않는다. ⑦ 두 시계열이 상관관계를 가진다고 해서, 한 시계열이 다른 시계열을 원인이라고 단정할 수 없다. 인과관계를 파악하기 위해서는 추가적인 분석이 필요하다.

예시

1. 주가와 금리 일별변화율에 시차상관분석
 2. 통화량 변화와 소득의 변화에 대한 시차상관분석
 3. 기업의 광고 지출과 이후의 판매량 사이의 시차상관관계를 분석
- ⑦ 광고 지출이 증가한 후 몇 달 뒤에 판매량이 증가하는 경향이 있는지, 그리고 그 시차는 몇 달인지를 파악할 수 있다. 이러한 분석을 통해 기업은 광고 캠페인의 효과를 평가하고, 미래의 광고 전략을 계획하는 데 유용한 정보를 얻을 수 있다.

https://github.com/freejyb/fin_stats_correlation_analysis

Auto correlation

자기상관계수(Auto correlation)

: 경기변동의 지속성 여부 측정

- 시계열 데이터에서 **시간에 따른 변수 자신과의 상관관계**를 측정하는 통계적 지표
- 자기상관계수: 특정 시차 간격 만큼의 지연(lag : 과거시점으로)을 이동시켜 자기(자신)와의 상관관계를 표현
 - 시계열 데이터의 패턴, 주기성, 추세 등을 이해하고 예측하는데 도움
- (계산) 자기상관계수는 일반적으로 피어슨 상관계수나 켄달의 타우와 같은 상관계수를 사용하여 계산
- (활용) 시계열 분석, 통계적 예측 및 모델링에서 중요한 개념 중 하나이며, 데이터의 패턴을 이해하고 시계열 모델을 개발하는 데 활용

시차			2018	2019	2020	2021	2022
0			2700	2750	2850	2650	2770
1		2700	2750	2750	2650	2770	
2	2700	2750	2850	2650	2770		

그래프로 시각화:

- 자기상관계수는 주로 자기상관 함수(autocorrelation function, ACF)를 시각화하여 표현
- ACF : lag에 따른 자기상관계수를 그린 그래프 이 를 통해 주기성이나 추세를 갖는 시계열 데이터의 패턴을 파악
- 시차가 커지면 ACF는 0 으로 ~

$\rho(k)$ 차 자기상관계수

$$\rho(1) = \rho(Y_t, Y_{t-1}) = \frac{E[Y_t Y_{t-1}] - \mu_Y^2}{\sigma_Y^2}$$

* 자기상관계수 특성

- $-1 \leq \rho(k) \leq 1$
- $\rho(0) = 1$
- $\rho(-k) = \rho(k)$

$$\begin{aligned} \rho(k) = \rho(Y_t, Y_{t-k}) &= \frac{\text{Cov}(Y_t, Y_{t-k})}{\sqrt{\text{Var}(Y_t)} \sqrt{\text{Var}(Y_{t-k})}} \\ &= \frac{E[Y_t Y_{t-k}] - E(Y_t)E(Y_{t-k})}{\sqrt{\sigma_Y^2} \sqrt{\sigma_Y^2}} \\ &= \frac{E[Y_t Y_{t-k}] - \mu_Y^2}{\sigma_Y^2} \end{aligned}$$

* Biserial correlation coefficient

양분 상관계수(biserial correlation coefficient)

- 한 변수가 연속변수이지만 분석가가 인위적으로 2개로 분류(이분화)하여 질적변수로 표시한 후 ⑦ 나머지 변수는 연속변수일때 사용
- 2개 분류 : 분석가가 인위적으로 2개 분류(이분화)하여 1인 대상자와 0의 대상자(명명척도)로 나눈다.
- 연속형 변수와 이진형 변수 간의 상관관계를 측정하는 통계량 ⑦ 이는 피어슨 상관계수의 특수한 경우로 볼 수 있으며 연속형 변수의 값이 이진형 변수의 각 범주에 따라 어떻게 달라지는지를 나타낸다.
- 이연 상관계수라고도 함.

$$r_b = \frac{\bar{Y}_1 - \bar{Y}_0}{S_Y} \left(\frac{pq}{y} \right)$$

- $\bar{Y}_1$: 이분화된 X 변수가 1인 대상자들의 평균점수
- $\bar{Y}_0$: 이분화된 X 변수가 0인 대상자들의 평균점수
- S_Y : Y 변수의 표준편차
- p : 이분화된 X변수가 1인 대상자들의 비율
- q : 이분화된 X변수가 0인 대상자들의 비율
- Y : 정규분포에서 p와 q로 이분화하는 z 점수가 갖는 수직좌표

양분상관계수를 구하기 위해서 연속변수를 명명척도(0또는 1)로 양분했기 때문에 **정보 손실이 큰 문제 발생하는 점을 유의할 것!!!**

* Biserial correlation coefficient

예제

경찰관 근무연수와 근무성적과의 상관관계

근무연수(X) 10년 이상의 경우 1, 10년미만의 경우 0 부여하여 이원화
(분석가의 판단)

구분	근무연수(X) (이진형변수)	근무성적(Y) (연속형변수)
김OO	0	80
박OO	0	90
홍OO	1	70
전OO	1	60
백OO	1	50
고OO	0	80
양OO	0	60
부OO	1	60
정OO	0	50
송OO	0	60
(평균)		(66)

$$r_b = \frac{\bar{Y}_1 - \bar{Y}_0}{S_Y} \left(\frac{pq}{y} \right)$$

- $\bar{Y}_1$: 이분화된 X 변수가 1인 대상자들의 평균점수
- $\bar{Y}_0$: 이분화된 X 변수가 0인 대상자들의 평균점수
- S_Y : Y 변수의 표준편차
- p : 이분화된 X변수가 1인 대상자들의 비율
- q : 이분화된 X변수가 0인 대상자들의 비율
- Y : 정규분포에서 p와 q로 이분화하는 z 점수가 갖는 수직좌표

- $\bar{Y}_1$: (70+60+50+60)/4=60
- $\bar{Y}_0$: (80+90+80+60+50+60)/6=70
- S_Y : $\sqrt{\frac{1,640}{10}} = 12.8$
- p : 0.4
- q : 0.6
- Y : 0.6과 0.4 정규분포에서 각각 차지하는 면적(종축치) 0.38

$$r_b = \frac{60-70}{12.8} \left(\frac{0.4 \cdot 0.6}{0.38} \right) = 0.4934$$

- ⑦ 결과 근무연수와 근무성적간 양분상관계수는 0.4934이다.
- ⑦ 상관 여부값이 애매한 수준으로 나왔다.

* Biserial correlation coefficient

예제

주식 시장의 일간 수익률과 시장 상승/하락 간의 양분상관계수 계산

- pykrx 라이브러리를 사용하여 KOSPI 지수의 일간 종가 데이터 수집
- 일간 수익률을 계산
- 일간 수익률이 양수인 날을 시장이 상승한 날로, 음수인 날을 시장이 하락한 날로 간주하여 이진형 변수를 생성
- 두 변수 간의 양분상관계수를 계산

연속형 변수(일간 수익률)와 이진형 변수(시장 상승/하락) 간의 상관관계를 나타내며,
이 값이 양수(+) 이고 통계적으로 유의미하다면(즉, p-value가 0.05 미만이라면), 시
장이 상승할 때 일간 수익률이 더 높은 경향이 있음을 의미

https://github.com/freejyb/fin_stats
05 correlation_analysis

* Point biserial correlation

양류 상관관계(Point biserial correlation)

- 이분변인인 명명척도와 등간/비율척도로 측정된 연속변인 간의 상관 정도를 추정할 때 사용
- (예제) 성별과 학점과의 상관관계

$$r = \frac{\bar{Y}_1 - \bar{Y}_0}{s_Y} \sqrt{pq}$$

- $\bar{Y}_1$: 이분화된 X 변수가 1인 대상자들의 평균점수
- $\bar{Y}_0$: 이분화된 X 변수가 0인 대상자들의 평균점수
- s_Y : Y 변수의 표준편차
- p : 이분화된 X변수가 1인 대상자들의 비율
- q : 이분화된 X변수가 0인 대상자들의 비율

* Point biserial correlation

예제

경찰관중 남자경찰관과 여자경찰관 연수성취도 비교

성명	성별	근무성적(Y)
김OO	1	80
박OO	0	60
홍OO	1	70
전OO	1	60
백OO	0	70
(평균)		(68)

$$r = \frac{\bar{Y}_1 - \bar{Y}_0}{s_Y} \sqrt{pq}$$

$$r = \frac{70 - 65}{7.483} \sqrt{0.6 \times 0.4} = 0.3274$$

- $\bar{Y}_1$: 이분화된 X 변수가 1인 대상자들의 평균점수
- $\bar{Y}_0$: 이분화된 X 변수가 0인 대상자들의 평균점수
- s_Y : Y 변수의 표준편차
- p : 이분화된 X변수가 1인 대상자들의 비율
- q : 이분화된 X변수가 0인 대상자들의 비율

* Partial correlations

편 상관관계(Partial Correlation) 란?

두 변수간의 상관관계를 나타내는 상관계수에서 제3의 변수를 제거한 후 두 변수간의 순수한 상관관계를 분석하는 방법

- ⑦ 제3의 변수를 제어변수로 여기서 제어변수는 제3의 변수의 영향을 제거시킴으로써 두 변수에 미치는 영향을 고정시켜 보다 정확한 상관관계를 구할 수 있게 한다. ⑦ 편상관분석을 통해서 얻게 되는 상관계수가 편상관계수
- ⑦ 제3변수가 나머지 변수에 미치는 상관관계가 높다고 할 때 이를 제거한 후 남은 잔존변수간의 관계도를 파악하고자 하는 경우 이용
- 2변수 이외에 관련된 1개의 변수의 영향을 제거했을 때의 2개 변수 간의 순수한 상관관계를 분석하는 방법
- 한 개 이상의 추가 변수의 효과를 제어하는 동시에 두 변수간 선형 관계를 설명하는 편상관계수를 계산.
- 편상관계수 값이 1보다 크게 나타나기도 한다. (작은 사례를 갖고 실험하는 경우)

(사례)

연소득과 질병 발병 여부 상관계수 측정시

- ⑦ 연소득이 나이에 영향이 있다고 보면 '나이' 변수를 통제한다 (동일한 나이만으로 상관계수 측정)
- 귀무가설 : 연소득과 질병발병 간 상관관계가 없다.
- 대립가설 : 상관관계가 있다.

데이터프레임(DataFrame)에서 .pcorr() 매서드를 통해서 사용 가능

pingouin: pandas와 numpy를 기반으로 한 오픈소스 통계 패키지

<https://pingouin-stats.org/build/html/index.html>

```
pip install pingouin
import pingouin as pg
pg.partial_corr(data=df, x='변수1', y='변수2', covar='통제할 변수')
```

```
import pandas as pd
import seaborn as sns
import pingouin as pg
df = sns.load_dataset('데이터셋명칭')
df.corr()
df.pcorr()
```

Fisher's Z transformation

Fisher의 Z 변환 (Fisher's Z transformation)

상관계수(correlation coefficient)를 정규분포에 가깝게 변환하는 방법

- 이 변환은 주로 두 변수 간의 상관계수의 통계적 유의성을 검정하거나, 여러 상관계수를 평균할 때 사용
- 상관계수의 분포가 정규 분포와는 다르게, 특히 표본 크기가 작을 때 비대칭적이라는 점에 기반한다.
- Z 변환을 통해, 상관계수의 분포를 보다 정규분포에 가깝게 만들어 통계적 분석을 용이하게 한다.

상관계수 r에 대한 Fisher의 Z 변환 공식 • 회귀분석에서 Chow test 와 함께 참조 할 것

$$Z = \frac{1}{2} \ln \left(\frac{1+r}{1-r} \right) = \operatorname{atanh}(r)$$

Z 점수 ($Z_score = Z / SE$) 와 p-값을 계산

p-값이 통계적 유의수준(예: 0.05)보다 작으면, 두 변수 간의 상관관계가 통계적으로 유의미하다고 해석

atanh: 쌍곡탄젠트의 역함수

Fisher의 Z 변환의 사용

- 상관계수의 비교:** 두 상관계수가 통계적으로 유의미하게 다른지 비교할 때, 먼저 각각의 상관계수를 Z 값으로 변환한 후, 이들의 차이를 검정
- 상관계수의 평균:** 여러 상관계수의 평균을 구할 때, 직접 평균을 내는 대신 각 상관계수를 Z 값으로 변환하고, 이들의 평균을 구한 다음, 이 평균 Z 값을 다시 상관계수로 역변환한다.

Fisher의 Z 변환의 장점 및 한계

- 정규성 향상:** 상관계수의 분포는 표본 크기가 작을 때 비대칭적이지만, Z 변환을 통해 분포의 정규성을 향상 가능
- 통계적 분석 용이:** 변환된 Z 값은 덧셈과 뺄셈과 같은 연산에 적합하며, 이를 통해 상관계수의 비교나 평균 계산이 용이
- 역변환 시 비대칭성:** Z 값에서 다시 상관계수로 역변환할 때, 원래의 상관계수 분포의 비대칭성이 완전히 사라지는 것은 아니다. 따라서, 표본 크기가 매우 작은 경우에는 여전히 주의가 필요
- 극단값의 처리:** 상관계수가 -1이나 1에 매우 가까운 경우, Z 변환 값이 매우 크거나 작아질 수 있다.

https://github.com/freejyb/fin_stats

* Effect Size

효과크기(Effect Size)

- 두 변수 간의 관계의 강도나 차이, 혹은 연구 결과의 중요성을 정량적으로 나타내는 지표
- 통계적 유의성과 함께, 효과 크기는 연구 결과의 실질적인 의미와 중요성을 평가하는 데 중요한 역할을 한다.

- **통계적 유의성** : 연구 결과가 우연히 발생했을 가능성을 평가
- **효과크기**: 그 결과가 실제로 얼마나 의미 있는지를 나타낸다.

효과 크기는 다양한 형태로 표현될 수 있으며, 연구의 설계나 분석 방법에 따라 적절한 효과 크기 지표를 선택해야 한다.

효과크기 지표

Cohen's d	▪ 두 집단 간의 평균 차이를 표준편차로 나눈 값 ▪ 주로 두 집단 간의 차이를 측정할 때 사용
Pearson's r	▪ 두 변수 간의 선형 관계의 강도를 측정하는 상관계수 ▪ 절대값이 클수록 두 변수 간의 선형 관계가 강하다는 것을 의미
Odds Ratio (OR) 및 Risk Ratio (RR)	▪ Odds Ratio와 Risk Ratio는 주로 이분법적 결과(예: 발병 여부)를 가진 연구에서 두 집단 간의 상대적 위험 또는 기회를 비교하는 데 사용 ▪ OR: 사건 발생의 확률 대 사건 미발생의 확률의 비율의 비율 ▪ RR: 한 집단에서의 사건 발생률 대 다른 집단에서의 사건 발생률의 비율을 나타낸다.
Eta-squared (η^2) 및 Partial Eta-squared (η^2)	▪ Eta-squared와 Partial Eta-squared는 분산분석(ANOVA)에서 사용되며, 독립변수가 종속변수의 분산을 얼마나 설명하는지 지표 ▪ 이 지표들은 전체 효과 크기(η^2)와 각 독립변수에 대한 효과 크기(η^2)를 제공

효과크기는 연구 결과를 해석하고, 연구 간 또는 연구 내에서 결과를 비교하는 데 필수적인 도구
연구의 실질적인 중요성을 평가하고, 연구 결과의 일반화 가능성을 판단하는 데 도움을 준다.

* Effect size : Cohen's d

- 효과 크기(Effect size)를 측정하는 데 사용
- 두 집단 간의 차이가 얼마나 큰지를 표준화된 형태로 나타내며, 연구 결과의 실질적인 중요성을 평가하는 데 유용
- Cohen's d는 주로 독립 표본 t-검정에서 두 집단 간의 차이를 평가할 때 사용

두 집단의 평균차이 검증(t-test)에서 두 표본의 평균 차이가 모집단 차원에서도 있는 것인지 아니면 표본에서만 우연히 차이가 있는지 검증하는 방법 ⑦ 표본(n)이 충분히 크면 대부분 통계적으로 유의하다고 나온다. (문제점_ 실제적인 유의성이 필요하다.!!! ⑦ 효과크기

⑦ 통계적 유의성 (p-value로 확인) 뿐만 아니라 효과크기(Effect Size) 값도 함께 고려

Cohen's d (effect size) 의 계산 방법

$$d = \frac{\bar{X}_1 - \bar{X}_2}{S_{pooled}}$$

$$d = t \sqrt{\frac{n_1 + n_2}{n_1 n_2}}$$

두 집단 간(X_1, X_2)의 평균 차이를 표준편차로 나눈 값
 X_1 : 실험집단, X_2 : 대조집단

$$S_p = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{(n_1 + n_2 - 2)}}$$

S_{pooled} 두 집단의 표준편차를 풀링한 값
 ⑦ 두 집단의 표준편차를 가중평균한 것

효과크기(d, difference) = $\frac{\text{두 표본 집단의 평균 차이}}{\text{추정된 표본평균의 표준편차}}$

* Effect size : Cohen's d

효과크기(d, difference) = $\frac{\text{두 표본 집단의 평균 차이}}{\text{추정된 표본평균의 표준편차}}$

표본상관계수(r_{XY}) = $\frac{\sigma_{XY}}{\sigma_X \sigma_Y}$

Cohen's d 효과 크기 해석

- 분자 : 두 표본 평균의 차이
 - ⑦ 정규분포하는 모집단 A에서 표본 a 그룹을 추출해 평균을 구하고, 정규분포하는 모집단 B에서 표본 b 그룹을 추출해서 평균을 구한 후에 ⑦ 이 작업을 수회 반복하면 다양한 평균차이 값이 계산된다.
- 분모 : 위 분포의 표준편차


(효과 크기 d 해석)

효과크기 = 1이면,

두 표본 집단의 평균 차이 = 추정된 표준편차


- 효과크기(d) 값이 클수록, 두 집단이 겹치는 부분이 작아 두 집단은 분포가 많이 다른 것 !!!
- 효과크기(d) 값이 작을수록, 두 집단이 겹치는 부분이 많아서 두 집단 분포가 비슷하다

두 표본의 평균차이의 분포



A 집단 분포

B 집단 분포



Effect size	Cohen's d	Pearson's r
▪ Small effect size ▪ 두 집단 간의 차이가 있지만 그 차이가 작다는 것을 의미	0.2 이하	0.1~0.3 , -0.1~ -0.3
Medium effect size	0.5 수준	0.3~0.5, -0.3 ~ -0.5
▪ Large effect size ▪ 두 집단 간의 차이가 매우 크며, 이는 매우 중요한 실질적 차이를 의미	0.8 이상	0.5~1 , -0.5 ~ -1

Cohen's d의 값이 음수가 될 수도 있다. Cohen's d의 절대값에 주목하여 효과의 크기를 해석하는 것이 중요

* Cohen's d & t-statistic

구분	Cohen's d	t-statistic
목적	- 두 집단 간의 평균 차이를 표준화하여 나타내는 효과 크기(effect size)의 척도 두 집단 간의 차이가 얼마나 큰지를 상대적으로 비교할 수 있게 해준다.	- 통계적 검정에서 사용되며, 특정 가설(예: 두 집단 간의 평균 차이가 없다는 가설) 하에서 관측된 결과가 얼마나 극단적인지를 나타내는 지표 두 집단 간의 평균 차이의 통계적 유의성을 평가
계산	두 집단 간의 평균 차이를 표준편차로 나눈 값	두 집단 간의 평균 차이를 표준오차(S.E. : 표본의 표준편차)로 나눈 값 $S.E = \frac{s}{\sqrt{n}}$
해석	Cohen's d 값은 효과의 크기를 나타낸다. 일반적으로 0.2는 작은 효과, 0.5는 중간 효과, 0.8은 큰 효과	t 값이 크면 클수록, 또는 p-값이 작으면 작을수록, 두 집단 간의 평균 차이가 우연히 발생했을 가능성이 낮다고 해석 🕒 관측된 차이가 통계적으로 유의미하다는 것을 의미

* Cramer v

Cramer v 계수 (크레머 파이계수)

- 1946년 [Harald Cramér](#)가 피어슨 카이제곱 통계량에 기반을 두고 개발
- 두 개의 명목상 변수사이의 연관성을 척도
- **값의 범위 : 0에서 1까지**
 - ⑦ 두변수가 최대의 관련성을 가질 때 1, 아무런 상관이 없을 때 0
 - ⑦ 명목상 변수 사이에 상관이 없을수록 작은 값으로 0에 가까워진다.
- 두개 이상의 이산형 변수 사이의 상관관계를 측정하기 위해서 이용된다.
- 행과 열의 수에 구애받지 않는다.
- 1 행 k 열로 이루어진 카이제곱 모형의 적합도에도 적용 가능

$$V = \sqrt{\frac{\varphi^2}{\min(k-1, r-1)}} = \sqrt{\frac{\chi^2/n}{\min(k-1, r-1)}}$$

- **k:열의 수**
- **r: 행의 수**
- **N: 관측치의 총계**

한계점

- 카이제곱값은 셀의 수와 함께 증가되어지는 경향을 가지기 때문에 행과열의 차이가 커지면 커질수록 크레머 값은 상관성이 있다는 증거가 없음에도 불구하고 1에 근접하는 경향이 있다.

* Correlation Analysis

변수별 상관관계		설명변수		
종속변수	비율변수 등간변수	서열변수	이분화 한 양적변수(명명척도)	이분화 한 질적변수(명목변수)
비율변수 등간변수	Pearson 상관관계	다류 상관관계	양분상관관계 (biserial correlation coefficient)	Cramer's 양류 상관관계
서열변수 (순위변수)		Spearman's rho Kendall tau		등위 양분 상관관계
이분화 한 양적변수 (명명척도)			사분 상관관계 tetrachoric correlation	Yule's Q
이분화 한 질 적변수(명목변수)				Phi 계수 유 관계수 카이 제곱 검정

예시) 사분상관계수 : IQ지능의 상하와 시험의 합격-불합격 상관

- 모수적 방법 (2개 변수 정규분포 경우) : Pearson 상관계수
- 비모수적 방법 (2개 변수 비정규분포 경우) : Spearman's rho

Regression Analysis

1. 회귀분석 이해

- 개념
- 회귀분석 종류
- 회귀분석의 가정
- 상관분석과 회귀분석

2. 회귀분석 과정

- 결정계수
- 가설검정 (귀무가설: H_0 , 대립가설: H_1)
- p-value

3. 회귀분석 실습 사례

4. Multiple Regression Analysis


5. Regularized Method

6. 회귀분석 이슈 : 정규성, 등분산성, 더미변수.....

Regression Analysis

森羅萬象

Causal Loop Diagram 국토부 자료



가정성립(o)

가정성립(x)

Linear Regression

- Simple Linear Regression
- Multiple Linear Regression

- Quantile Regression
- Weighted Regression

Generalized Linear Model

- Logistic regression $y_{\text{값}} : 0 \sim 1$

Regularization

overfitting

- LASSO (Least Absolute Shrinkage and Selection Operator) L1 Norm
- Ridge Regression : L2 Norm

Regression Analysis

회귀분석이란?

- 종속변수(목표변수, y)가 독립변수(입력변수, 설명변수, x)들에 의해서 **원인과 결과간 인과(因果)관계를 설명하는** 분석 방법
- 훈련 데이터세트 (X, Y) 로 부터 학습알고리즘을 이용하여 가설을 생성하고, 생성된 가설에 데이터를 입력하여 예측 값 데이터를 얻는 것

Francis Galton(1822-1911)

통계학 교과서에서 회귀(regression)라는 용어를 처음 사용
 “아버지 키(x)와 아들 키(y)와의 유전관계 ”



르장드르

가우스

갈톤

<https://galton.org/>

#회귀 : 표본에 의한 경우 **평균**으로 돌아가려는 현상을 설명

- 역사적 배경 " 통계학이 학문으로서 독립된 지위를 가지려 하던 시기
- 연구분야: 유전학(heredity), 다윈의 종의기원
- Galton은 부모의 특징과 자녀의 특징 사이에는 선형함수관계가 성립해야 한다. ❶ 그 관계를 하나의 유전 법칙(law of heredity)이라고 여겼으므로 이를 회귀법칙(law of regression)이라고 불렀다.
- 사람의 여러 특징 중에 키를 측정한 데이터를 가지고 회귀법칙을 구했는데, 사람 키의 변이 폭이 여러 세대에 걸쳐 일정하게 나타나는 이유가 바로 평균보다 크거나 작은 키는 다음 세대에 평균 쪽으로 돌아간다는 **회귀법칙 때문이라고** 주장
- 회귀법칙이 선형함수라고 생각했으므로 부모 키와 자녀의 키 사이의 관계를 나타내는 선형함수의 기울기, 즉 일종의 비례상수에 해당하는 단 하나의 상수만 찾으려 하였다.
- ❷ 회귀비 (ratio of regression)라고 명명, 값은 반드시 0과 1 사이의 상수여야만 했다.
- ❸ 결국, 회귀라는 이름으로 구하려했던 것은 두 변수 사이의 양(+)의 상관관계수에 국한된 것임!!!

1911년 University College London: Department of Applied Statistics

- K. Pearson 교수

Regression Analysis


<https://galton.org/>

Francis Galton Bibliography: Complete Works.

<https://galton.org/bibnew/all.html>

- (1865). Hereditary talent and character, Macmillan's Magazine, Vol. 12, 157-166, 318-327.
- (1869). Hereditary Genius, Macmillan, London.
- (1877). Typical laws of heredity. Proceedings of the Royal Institution, Vol. 8, 282-301.
- (1886a). Family likeness in stature. Proceedings of the Royal Society of London, Vol. 40, 42-73. [9] Galton, F.
- Regression towards mediocrity in hereditary stature. Journal of the Anthropological Institute, Vol. 15, 246-263.
- (1888). Co-relations and their measurement, chiefly from anthropometric data. Proceedings of the Royal Society, Vol. 45, 135-45.
- (1890) Kinship and correlation. North American Review, Vol. 150, 419-431.

* inductive method



존 스튜어트 밀(1806-1873)
1823년 런던 동인도회사 입사

temporal precedence !!!

귀납법(inductive method) 5가지 원칙

⑦ 인과관계를 명확히 밝히는 것을 목적으로 하기에 '인과적 귀납법'이라고도 한다.
(참고)

인과 법칙의 시험 : 통제된 실험의 필요성 강조

- **일치법(the Method of Agreement)**

: 고려되는 원인은 동일하게 유지하고, 나머지 조건은 다양한 상황에서 동일한 결과가 산출되는지 확인

- **차이법(the Method of Difference)** : 고려되는 원인 외에는 차이가 없는 두 그룹에서 서로 다른 결과가 산출되는지 확인

- **일치 차이 병용법(the Joint Method of Agreement and Difference)**

- **잉여법 (the Method of Residues)**


- **공변법 (the Method of Concomitant Variations)**

https://ko.wikipedia.org/wiki/%EB%B0%80%EC%9D%98_%EB%B0%A9%EB%B2%95

Regression Analysis & Correlation Analysis

회귀분석	상관분석
- 독립변수가 종속변수와 어떻게 수치적으로 연관여부를 설명 - 원인과 결과인지를 파악하려면, 인과관계를 파악 ⑦ 회귀계수 - 독립변수의 단위 변화가 종속변수에 미치는 영향을 반영	- 두 변수의 상호 관계 또는 연관성을 결정하는 통계적 척도를 상관관계 1 또는 -1에 가까울수록 상관관계가 높다. ⑦ 상관계수
- 회귀분석을 사용하여 최적의 변수를 구하고 변수 하나를 다른 변수를 기반으로 추정 ⑦ 독립변수(feature)의 값을 기준으로 종속변수의 값을 예측	- 두 변수 간의 선형관계를 나타내기 위해 사용 ⑦ 변수 간의 관계를 나타내는 숫자 값을 찾는 것을 목표
x에 대한 y의 회귀는 y에 대한 x의 회귀와 차이	- 종속변수와 독립변수간에 차이가 없다. ⑦ x와 y 간의 상관관계는 y와 x와 유사
(가정 필요) 등분산성, 정규성, 독립성, 선형성 등 ⑦ 검증 필요	(가정 필요) 등분산성, 정규성, 독립성, 선형성 등 - 두 변수의 관계를 예측할 수 있는 정도일 뿐 정확한 예측치를 제시하지 못함

상관관계가 높은 변수라고 반드시 인과관계가 있지는 않다!!!!



Regression Analysis : Introduction

회귀분석 목적

1. 독립변수(x)와 종속변수(y) 간의 관계 설명 ⑦ 관심있는 y에 대해 x가 어떻게, 얼마나 영향을 주는지 **설명(explanation)**
: 종속변수에 가장 영향력 있는 독립변수는 ?
2. 최적 회귀 모델을 이용해서 **Y값을 예측(prediction)**
 - 1) 수치 예측
 - 2) 범주 예측 ⑦ 분류

회귀분석 변수

독립변수 (Independent variable)	: 선형회귀분석에서 원인의 역할을 하는 변수, 설명변수(Explanatory variable) 입력변수(Input variable), 예측변수 → 머신러닝에서 판단근거 자료들은 피쳐(feature), X 변수
종속변수 (Dependent variable)	설명(예측)되어지는 결과 변수 ⑦ 머신러닝에서 레이블(label), Y변수 반응변수(Response variable), 목표변수 (Target variable)

Regression Analysis : Introduction

독립변수 수

Simple Linear Regression	독립변수가 하나인 경우 $Y = \beta_0 + \beta_1 X_1 + \varepsilon$, ⑦ linear, nonlinear
Multiple Linear Regression	- 독립변수가 여러 개인 경우 (독립변수 q개, 선형) $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_q X_q + \varepsilon$ ⑦ linear, nonlinear

선형 여부

선형회귀모델은 비교적 간단하며 예측을 생성하기위한 해석하기 쉬운 수학적 공식을 제공

선형(linear) 회귀모델 (단순선형, 다중선형회귀모델)	결과변수(Y) 조건부평균은 입력변수(X)들의 <u>선형결합으로 표현(+, -)한 모형</u> <u>선형 방정식에 의해서 관계를 표현하는 것</u> $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_q X_q + \varepsilon$ ⑦ $\bar{Y} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_q X_q$, $\bar{Y}$(결과변수)- 조건부평균 ⑦ 결과변수 $\bar{Y}$은 예측변수들이 주어졌을때의 Y의 평균이므로 조건부평균
비선형(nonlinear) 회귀모델	: 비선형 방정식에 의해서 표현하는 것 (선형관계가 아닌 경우) : $Y = \beta_0 + e^{\beta_1 X_1} + \varepsilon$ ▪ 선형가능 회귀모형 : $Y = \beta_0 + \beta_1 \ln X_1 + \varepsilon$

종속변수

일변량 (univariate) 회귀모델	종속변수가 하나인 경우
다변량 (multivariate) 회귀모델	종속변수가 여러 개인 경우 $(Y_1, Y_2, \dots, Y_p) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_q X_q$

다항 회귀분석 (Polynomial Regression)

$$Y = w_0 + w_1 x + w_2 x^2 + \dots + w_d x^d$$

Regression Analysis : Introduction

Linear Regression Analysis : Assumption

확정적 관계 (Deterministic Relationship)

$$Y=f(X), Y=\beta_0+\beta_1X$$

- 한 변수의 변화가 다른 변수의 변화를 정확하게 예측할 수 있을 때 존재
- 이러한 관계에서는 변수 간에 정확한 수학적 함수나 공식이 존재하며, 어떠한 불확실성이나 변동성도 포함하지 않는다.

확률적 관계 (Stochastic or Probabilistic Relationship)

$$Y=f(X)+\varepsilon, Y=\beta_0+\beta_1X+\varepsilon$$

- 확률적 관계는 한 변수의 변화가 다른 변수의 변화를 완벽하게 예측할 수 없을 때 존재
- 이러한 관계에서는 변수 간의 상호작용에 **불확실성이나 랜덤성이 포함되어** 있으며, 결과를 확률적으로만 예측할 수 있다.
- 확률적 관계에서는 주어진 입력에 대해 여러 가능한 출력이 존재할 수 있으며, 이러한 출력들은 **특정 확률분포를** 따른다.

→ 오차에 대한 가정?

- 오차(ε , random error) = 모집단으로부터 추정된 회귀식으로부터 얻은 예측값 - 실제값

❶ 회귀식으로 설명되지 않는 부분

단순선형모델

- 회귀분석에서는 **관측할 수 없는 오차에 대한 몇가지 가정을 전제로 회귀식의 모수들을 추정**

오차항 가정

: $\varepsilon_i \sim 1)$ 정규분포 2) $E(\varepsilon_i) = 0$ 3) $Var(\varepsilon_i) = \sigma^2$

❶ $\varepsilon_i \sim \text{Normal}(0, \sigma^2)$ $i = 1, 2, \dots, n$

$\varepsilon_i \sim N(0, \sigma^2)$

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$$

$$\bullet E(Y_i) = E(\beta_0 + \beta_1 X_i + \varepsilon_i) = \beta_0 + \beta_1 E(X_i)$$

$$\bullet Var(Y_i) = Var(\beta_0 + \beta_1 X_i + \varepsilon_i) = Var(\varepsilon_i) = \sigma^2$$

$$Y_i \sim N(\beta_0 + \beta_1 X_i, \sigma^2)$$

오차항이 정규분포를 따른다면 ❶ 회귀모형 역시 정규분포를 따른다

❶ 잔차는 회귀모형에 선형결합으로 표현될 수 있기에, 잔차 역시 정규분포를 따른다.

ε_i 가정 ❶ Y_i

Regression Analysis : Introduction


Linear Regression Analysis : Assumption

원칙적으로는 가정을 모두 만족해야 모델을 적용하는 것!!!!

but 모델 내부에서는 해당 조건이 만족되었다고 가정하고 연산을 실행하기 때문에 조건에 맞지 않는 데이터를 입력하면?

가정 만족여부
검증 필요 →

- **Simple Linear Regression** : 독립변수와 종속변수(Y)간의 선형성 점검하기 위해 산점도, 회귀계수 유의성을 통해 확인
- **Multiple Linear Regression** : 회귀분석의 가정 4가지 모두를 만족하는지 여부 확인

가정		주요 내용
선형성		▪ 종속변수는 독립변수의 선형 함수 ⑦ machine learning에서는 parameter (가중치 w_i) 간 선형성 
오차항 (Error, ε) 3가지 가정 : iid (independent and identically distributed) ⑦ 오차항을 실제로 추정할 수 없으므로 추정치인 잔차(Residual) 로 평가	등분산성 (Homoscedasticity)	• 독립변수 값에 대해 대응되는 종속변수들의 분포는 모두 동일한(일정한) 분산을 갖는다. ⑦ 추정오차들의 동일한 분산 : $\text{Var}(\varepsilon_i) = \sigma^2$ ⑦ 오차의 분산이 x_i에 관계없이 일정하다.
	정규성(정상성) (Normality)	오차항은 정규분포를 띄어야 한다. 평균이 0 이고, 분산이 σ^2 인 정규분포를 따른다. • 독립변수 값에 대해 대응되는 종속변수들의 분포는 정규분포이다.
	독립성 (Independent)	(1) 오차값들간 서로 독립적 ⑦ <u>$\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$</u> ⑦ Y의 변화에 따라 오차항이 어떤 패턴(추세)을 가져서는 안됨 (2) 독립변수와 오차항 또는 독립변수간의 상관관계가 없어야 한다. ⑦ 회귀식의 설명력을 약하게 만든다. → 외생성(exogeneity): 독립변수가 외생변수임을 가정하는 것, 즉 독립변수와 오차항과 상관관계가 없어야 한다. ⑦ 또한 독립변수들 간에 상관관계가 있어도 안 된다. ⑦ 왜냐하면 이 경우에도 오차항과 독립변수가 상관관계를 가지기 때문이다. 외생성 가정이 만족되지 않을 경우, 추정된 계수값이 편의가 존재한다. ⑦ 오차항은 계열상관(serial correlation) 또는 자기상관(autocorrelation) 문제 발생

Regression Analysis : Introduction

선형회귀분석 한계

1. 가정 위배

1) 선형성의 가정

: 계수들(β)에 대해 선형이라는 것을 의미

⑦ 변수의 증가량에 대한 응답이 일정하게 증가하거나 감소하는 것을 예측할 수 있다.

실제 데이터에서 이러한 선형 관계가 항상 성립하지 않을 수 있으며, 비선형 관계를 가진 데이터에 대해서는 적절한 예측을 하기 어렵다.

2) 변수 간 독립성: 다중선형회귀분석에서는 독립변수들이 서로 독립적이라는 가정이 필요

- ⑦ 실제 데이터에서는 변수들 간에 상관관계가 있을 수 있으며(다중공선성), 이는 회귀 모델의 정확도를 저하시킬 수 있다.

3) 정규성 가정

⑦ 가정이 위배될 경우, 통계적 추정치가 부정확해질 수 있다. ⑦ **확장모델 GLM**

4) 등분산성 가정

⑦ 이 가정이 위배될 경우, 회귀 모델의 예측 성능이 저하될 수 있다

- 결과변수(Y)는 연속형변수이어야 한다.
- 결과변수(Y)가 정규분포를 따라야 한다.

- 결과변수가 범주형변수(1,0)인 경우 문제 : 로지스틱함수
 - ⑦ **로지스틱 회귀분석**
- 결과변수가 횡수변수인 경우 문제 : 로그함수
 - ⑦ **포아송 회귀분석**

2. 이상치의 영향

: 선형회귀모델은 이상치에 매우 민감

⑦ 데이터에 이상치가 포함되어 있을 경우, 회귀선이 크게 왜곡될 수 있으며, 이는 분석 결과의 신뢰성을 저하

3. 인과관계의 해석

: 선형회귀분석은 변수 간의 관계를 밝힐 수는 있지만, 인과관계를 입증할 수는 없다.

⑦ 어떤 변수가 다른 변수에 영향을 미친다고 확실히 말할 수 없다.

Regression Analysis : Introduction

$$E(Y_i) = \beta_0 + \beta_1 X_i \quad \text{Parameter } (\beta_0, \beta_1) \text{ 를 추정}$$

회귀계수를 추정하는 방법

점추정(Point Estimation)과 구간추정(Interval Estimation)이 사용

점추정 (Point Estimation)	- 회귀계수(기울기나 절편)의 하나의 최선의 추정치를 제공 - 회귀분석 결과에서 일반적으로 보고되는 회귀계수의 값 ⑦ 독립변수가 종속변수에 미치는 평균적인 영향 - 기울기 점추정치는 독립변수 x가 한 단위 변할 때 종속변수 y가 평균적으로 얼마나 변하는지를 나타낸다. - 점추정만으로는 추정치의 불확실성이나 신뢰성에 대한 정보를 제공하지 않는다.
구간추정 (Interval Estimation)	- 회귀계수의 추정치가 특정 신뢰수준(예: 95%) 하에서 존재할 것으로 예상되는 값의 범위를 제공 - 점추정치 주변에 신뢰구간(Confidence Interval, CI)을 설정함으로써, 추정치의 불확실성을 정량화 한다. 구간추정은 추정치의 정확도와 신뢰성에 대한 정보를 제공하며, 실제 회귀계수가 이 구간 내에 있을 확률을 나타낸다. - 예를 들어 β_1의 95% 신뢰구간이라면, 95%의 신뢰수준으로 실제 β_1 값이 이 구간 내에 있을 것이라고 예상할 수 있다.

추정 단계 ⑦ 검정 단계

- 추정단계 : 다양한 추정방법
- 검정단계 ; 검정 통계량(test statistic)을 계산하고, 이를 통해 모집단 파라미터에 대한 가설을 검정하는 과정을 포함
- ⑦ t-검정(t-test), z-검정(z-test)

Regression Analysis : Introduction

Preliminary considerations

1. 이상치 문제

- EDA 확인
- 전처리 (제거, 대체값) 입력

2. 변수 선택

- 후진제거법 등
- 간결, 일반화 성능 제고

3. 다중 공선성 문제

- 모형의 불안정성
- 상관분석, VIF
- 차원축소 방법 고려

4. 비선형성 문제

5. Overfitting 문제 : 예측 성능 저하 문제

1) 교차검증

2) 벌점화 (Regularization : L1, L2)

Linear Regression Analysis : Process

No	순서	주요 내용
1	- 독립변수와 종속변수 산점도 (상관분석) - 독립변수 간 산점도 (상관분석) - 종속변수와 독립변수 정규성 검정	- 선형관계-문제 야기 독립변수 변환 - 다중공선성 문제 변수 사전 제거 - 변수 분포 : 문제 야기 변수 변환
2	회귀계수(parameter) 추정 (OLS) 및 유의성 검정	- 개별 독립변수 유의성 검정 (t-검정) ⑦ (p-value < 0.05) - 모형 전체 유의성 검정 (F검정, ANOVA)
3	유의적인 독립변수 선택	- 후진, 전진, stepwise - 산점도 행렬
4	(다중회귀분석) 다중 공선성 진단 & 해결	- VIF - 산점도 행렬 ⑦ 문제 야기 변수를 제거
5	모형 진단	- 잔차검정(가정 : 선형성, 정규성, 독립성, 등분산성) ⑦ 이상치 제거 필요
6	모형 회귀분석 최종 결정 활용 평가	- robust - 결정계수 (수정결정계수) - 독립변수 부호 해석

Linear Regression Analysis : Process

1. 독립변수(x)와 종속변수(y) , 산점도 그리기

- 두 변수가 **선형성 존재 여부**를 알아보기 위하여 Scatter plot를 그리거나,
- 피어슨 상관계수를 계산해 보며 대략적으로 선형관계 여부 판단 가능
- ⑦ 선형회귀분석은 독립변수(x)와 종속변수(y)간의 직선관계만 분석 가능하므로 선제적으로 산점도로 점검하는 것
선형 회귀 모델의 의미 있을 것이라고 추측 ⑦ 다중회귀분석의 경우 다중공선성의 문제를 미리 파악 가능

(주의할 점) 모형 타당성을 위해서는 **인과관계 설정은 이론이나, 타당성에 근거를 두고 있어야 한다.** 종속변수 : 종속변수에 대한 정보를 **종속변수의 변동(분산)** 인 경우 ⑦ **분산분석 (ANOVA) 실시**

$$\text{종속변수의 총변동} = \sigma(y_i - \bar{y})^2$$


산점도 (Scatter plot)

1. 의의

두 변수간의 관계를 2차원 그래프(y축 종속변수, x축 설명변수)로 관측치 쌍을 그려준다.

2. 활용

- 1) 종속변수와 설명변수 간의 **선형성 존재 여부**를 **시각적으로** 파악 가능
- 2) 다중회귀분석에서 설명변수가 여러 개 경우 설명변수간 높은 상관관계 일때 다중공선성 문제발생을 사전에 파악 가능



데이터가 퍼진 모습이 곡선형태이거나, 원 형태인 경우 회귀식 기울기 0이 되어 분석 불가!!

Linear Regression Analysis : Process

2. 회귀계수 추정 (OLS) 및 유의성 검정

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p + \varepsilon \quad \text{모회귀식}$$

- β : 회귀계수(regression coefficients), 가중치(w), **모수(parameter)**
- ε : 오차항 ($\varepsilon \sim N(0, \sigma^2)$)

⑦ 설명변수(x 예측변수)와 종속변수(y) 평균과의 관계를 설명하는 **선형식을 찾는 것!!**

$$y = \beta_0 + \beta_1 x_1 + \varepsilon$$

선형회귀모델

$$E(y) = f(x) = \beta_0 + \beta_1 x_1$$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x : \text{표본으로 추정된 식}$$

- 최소제곱법(ordinary least squares, OLS)**을 주로 사용
- OLS는 오차항의 제곱의 합($\sum \varepsilon^2$)을 최소화하는 모수(β_0, β_1)를 한정된 표본에서 추정

$$\hat{\beta}_1 = \frac{\sigma(x - \bar{x}_1) \sigma(y - \bar{y})}{\sigma(x - \bar{x}_1)^2} \cdot \text{기울기}(\beta_1) \text{ 계산}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \quad \cdot y \text{의 절편}(\beta_0) \text{ 계산}$$


$$X=0 \quad \textcircled{7} \quad \beta_0$$

$$X=1 \quad \textcircled{7} \quad \beta_0 + \beta_1$$

$$\hat{\beta}_1 = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}$$

$$\hat{\beta}_0 = E(Y) - E(X)$$

2.1 회귀계수 (β) 추정 방법



- 회귀분석을 통한 예측값에는 오류(e)가 필연적 !!!
- 잔차(residual)
- 표본(sample)**으로 추정한 **회귀식과 실제 관측값의 차이(오류)**
- 머신러닝에서는 주로 거리(d)로 표현
- 최적의 회귀 모델을 만든다는 것은 전체 데이터의 잔차(오류 값) 합이 **최소화 되는 모델을 만든다는 의미**

* Least Squares Estimates : Formulation

Simple Linear Regression Least Squares Estimates of β_0 and β_1 (통계연구- 최소제곱법, 별도 자료)

$$y = \beta_0 + \beta_1 x_1 + \varepsilon$$

(대안) robust linear regression

<https://www.geeksforgeeks.org/linear-regression-python-implementation/?ref=lbp> (파이썬 코드 참조)

잔차제곱합

$$SSE = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

잔차제곱합 최소화

$$\min \sum_{i=1}^n e_i^2 = \min \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \min \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

절편 β_0 과 기울기 β_1
편미분

$$\frac{\partial L}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\frac{\partial L}{\partial \beta_1} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) x_i = 0$$

$$\hat{\beta}_1 = \frac{\sigma(x - \bar{x}_1)(y - \bar{y})}{\sigma(x - \bar{x}_1)^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}_1$$



Gradient descent !!!

$$\text{Min } \sigma(y_i - y_0)^2$$

$$\text{Min } \sigma(y_i - (\beta_0 + \beta_1 x_i))^2$$

y의 절편 (β_0)

$$\frac{\partial L}{\partial \beta_0} (\sigma(y_i - (\beta_0 + \beta_1 x_i))^2) = 0$$

$$\sigma 2(y_i - \beta_0 - \beta_1 x_i)(-1) = 0$$

$$\sigma(y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\sigma \beta_0 = \sigma y_i - \sigma \beta_1 x_i$$

$$n \times \beta_0 = \sigma y_i - \sigma \beta_1 x_i$$

$$\beta_0 = \frac{1}{n} \sigma y_i - \frac{1}{n} \sigma \beta_1 x_i$$

$$\beta_0 = \bar{y} - \beta_1 \bar{x}_1$$

회귀계수 (β_1)

$$\frac{\partial L}{\partial \beta_1} (\sigma(y_i - (\beta_0 + \beta_1 x_i))^2) = 0$$

$$\sigma 2(y_i - \beta_0 - \beta_1 x_i)(-x_i) = 0$$

$$\sigma 2(y_i - \beta_0 - \beta_1 x_i)(-x_i) = 0$$

$$-2 \sum (y_i - \bar{y} + \beta_1 \bar{x}_1 - \beta_1 x_i)(x_i) = 0$$

$$\sigma x_i(y_i - \bar{y}) - \beta_1 \sigma x_i(x_i - \bar{x}_1) = 0$$

$$\beta_1 = \frac{\sigma x_i(y_i - \bar{y})}{\sigma x_i(x_i - \bar{x}_1)}$$

$$\text{■ 분모} = \frac{\sigma x_i(x_i - \bar{x}_1) - \bar{x}_1 \sigma(x_i - \bar{x}_1)}{\sigma(x_i - \bar{x}_1)^2}$$

$$\sigma [x(x - \bar{x}_1) - \bar{x}_1(x - \bar{x}_1)]$$

$$\sigma x(x - \bar{x}_1) - \bar{x}_1 \sigma(x - \bar{x}_1)$$

$\sigma(x - \bar{x}_1)$ 에서 $\sigma x - \sigma x \bar{x}_1 = n \times x - n \times \bar{x}_1$
 ⑦ $\bar{x}_1 = \frac{1}{n} \sigma x$ 이므로 결국 전체는 0 이 된
 ⑧ 결국 분모는 $\sigma x(x - \bar{x}_1)$

■ 분자 $\sigma x_i(y_i - \bar{y}) \rightarrow \sigma(x - \bar{x}_1) \bar{y} (y - \bar{y}) \sigma$
 $x(y - \bar{y}) - \bar{x}_1 \sigma \bar{y} (y - \bar{y})$
 여기서 우변 $\sigma \bar{x}_1 (y - \bar{y})$ ⑦ $\bar{x}_1 (\sigma y - \sigma \bar{y})$
 $\bar{x}_1 (\sigma y - \sigma \bar{y})$ ⑦ $\sigma \bar{y} = n \times \bar{y}$ 이고
 $\bar{y} = \frac{1}{n} \sigma y$ 이고 바꿔 쓰면
 $n \times \bar{y} = \sigma y$ 이므로 결국 0 이 된다.
 결국 분자 $\sigma x(y - \bar{y})$ 가 된다.

* Least Squares Estimates : Formulation

두 변수간 상관계수 값의 부호와 회귀계수 값의 부호(양+, 음-)는 동일하다.

표본상관계수

$$r_{XY} = \frac{\sigma_{i=1}^n (X - \bar{X})(Y - \bar{Y})}{\sqrt{\sigma(X - \bar{X})^2} \sqrt{\sigma(Y - \bar{Y})^2}}$$

회귀계수

$$\beta_1 = \frac{\sigma(x - \bar{x})(y - \bar{y})}{\sigma(x - \bar{x})^2}$$

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

Ordinary Least Squares (OLS) is a type of [linear least squares](#) method

$$y_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \varepsilon_i,$$

$$y_i = \mathbf{x}_i^T \boldsymbol{\beta} + \varepsilon_i.$$

$$\mathbf{X} = \begin{bmatrix} X_{11} & X_{12} & \cdots & X_{1p} \\ X_{21} & X_{22} & \cdots & X_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} & X_{n2} & \cdots & X_{np} \end{bmatrix}, \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

$$\beta_{OLS} = \operatorname{argmin} \{ \sigma_{i=1}^n (y_i - x_i \beta)^2 \} = (X^T X)^{-1} X^T y$$

* Gauss-Markov Theorem

Gauss-Markov Theorem : BLUE: Best Linear Unbiased Estimator

- **최소제곱 추정량(OLS: Ordinary Least Squares estimator)**이 **선형회귀모델의** 계수를 추정하는 데 있어서 '최선의 선형 비편향 추정량(BLUE: Best Linear Unbiased Estimator)'임을 명시한다.
- '최선' : 모든 선형 비편향 추정량 중에서 가장 작은 분산을 가진다는 것을 의미한다. (정규성 가정 추가시) 가장 작은 표분분산값을 갖는 효율적 추정량이다.

Gauss-Markov Theorem 가 적용되기 위한 주요 가정

1. **선형성**: 종속변수 y 는 독립변수 $x_1, x_2, \dots, x_k$ 의 선형 결합으로 표현될 수 있어야 한다.
2. **오차항의 평균(기댓값) = 0**: 오차항의 기대값은 0이어야 한다. $E(\epsilon) = 0$
3. **등분산성(Homoscedasticity)**: 모든 관측치에 대한 오차항의 분산이 동일해야 한다. $Var(\epsilon_j) = \sigma^2$
4. **오차항의 독립성**: 오차항들은 서로 독립적이어야 한다. 즉, 어떤 오차항도 다른 오차항과 상관관계를 가지지 않는다.
 ⑦ $Cov(\epsilon_i, \epsilon_j) = 0$
5. **오차항과 독립변수의 무상관성**: 오차항은 독립변수와 상관관계가 없어야 한다. ⑦ $Cov(X_i, \epsilon_i) = 0$

MVUE(Minimum Variance Unbiased Estimator)

위의 가정에 + 오차항(변수)은 정규분포를 따른다. 가정 추가시
 → 가장 좋은 **불편추정량** 이면서 **분산이 가장 작은 추정량**이 된다.

- OLS 추정량이 주어진 조건에서 가장 신뢰할 수 있는 추정량임을 의미한다.
- 가우스-마르코프 정리의 중요성은 이론적으로 OLS 방법이 선형 회귀모델의 계수를 추정하는 데 있어서 최적의 방법임을 보장한다는 점에 있다.
 - **But 실제 데이터 분석에서는 모든 가정이 완벽하게 충족되지 않는 경우가 많으므로, 이러한 가정들을 검토하고 필요한 경우 다른 추정 방법을 고려해야 한다.**

* Gauss-Markov Theorem

Gauss-Markov Theorem : BLUE: Best Linear Unbiased Estimator

최소제곱법으로 추정한 선형관계 추정량이 Gauss-Markov Theorem의 네 가지 조건을 만족했을 때 불편성을 가지는지 증명하는 것

실제 각 데이터와의 거리가 최소가 되게 하는 직선 식

$$Y_i = \beta_0 + \beta_1 X_i + e$$

추정의 직선 식

최소제곱법

$$y = \beta_0 + \beta_1 X_1 + \varepsilon$$

$$\begin{aligned}\hat{\beta}_1 &= \frac{\text{Cov}(X,Y)}{\text{Var}(X)} \\ \hat{\beta}_0 &= E(Y) - E(X)\end{aligned}$$

과연 이렇게 최소제곱법으로 추정한 직선 회귀식이 정말 각 데이터 사이의 거리가 최소가 되도록 항상 결정되는 Unbiased Estimator인가?

최소제곱법으로 추정한 직선식의 기댓값이 실제 각 데이터의 거리가 최소가 되게 하는 직선식이 되길 기대한다.
즉, 최소제곱법으로 추정한 직선식의 기댓값이 실제 각 데이터의 거리가 최소가 되게 하는 직선식이 되어야 한다는 것이다.

→ 추정치의 기댓값이 모수가 되는 성질 **불편성 (Unbiasedness)**

가우스-마코프 정리에서 오차에 대해 일정 조건을 충족한다면 최소제곱법으로 추정한 직선이 실제 각 데이터의 거리가 최소가 되게 하는 직선의 Unbiased Estimator가 되는 것이다. 결국, 최소제곱법은 BLUE가 된다 라는 것 !!!!!!!!!!!.

이 직선식에서 중요한 것은 기울기 β_1 이다.

가우스-마코프 정리에 의한 β_1 의 기댓값

$$\begin{aligned}\hat{\beta}_1 &= \frac{\text{Cov}(X,Y)}{\text{Var}(X)} \\ \hat{\beta}_0 &= E(Y) - E(X)\end{aligned}$$

이 식을 공분산과 분산의 정의에 따라 정리하면

$$E(\hat{\beta}_1) = \frac{\text{Cov}(X,Y)}{\text{Var}(X)} = E\left[\frac{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(Y - Y)}{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2} \right]$$

* Gauss-Markov Theorem

Gauss-Markov Theorem : **BLUE: Best Linear Unbiased Estimator**

실제 각 데이터와의 거리가 최소가 되게 하는 직선 식

$$Y_i = \beta_0 + \beta_1 X_i + e$$

$$E(Y) = \beta_0 + \beta_1 E[X] + E(e)$$

$$Y_i - E(Y) = \beta_1 (X_i - E[X]) + e - E(e) \text{ 이 식을}$$

아래 식에 대입하면

$$E(\beta_1) = \frac{Cov(X, Y)}{Var(X)} = E\left[\frac{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2} \right]$$

$$= E\left[\frac{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(\beta_1 (X_i - \bar{X}) + e - E(e))}{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2} \right]$$

$$= E\left[\frac{\sum_{i=1}^n (X_i - \bar{X}) \beta_1 (X_i - \bar{X}) + \sum_{i=1}^n (X_i - \bar{X}) e - \sum_{i=1}^n (X_i - \bar{X}) E(e)}{\sum_{i=1}^n (X_i - \bar{X})^2} \right]$$

$$= E\left[\frac{\sum_{i=1}^n (X_i - \bar{X})^2 \beta_1 + \sum_{i=1}^n (X_i - \bar{X}) e - \sum_{i=1}^n (X_i - \bar{X}) E(e)}{\sum_{i=1}^n (X_i - \bar{X})^2} \right]$$

$$E\left[\frac{\sum_{i=1}^n (X_i - \bar{X})^2 \beta_1}{\sum_{i=1}^n (X_i - \bar{X})^2} \right] + E\left[\frac{\sum_{i=1}^n (X_i - \bar{X}) e}{\sum_{i=1}^n (X_i - \bar{X})^2} \right] +$$

$$E\left[\frac{-\sum_{i=1}^n (X_i - \bar{X}) E(e)}{\sum_{i=1}^n (X_i - \bar{X})^2} \right]$$

$$= \beta_1 + E\left[\frac{\sum_{i=1}^n (X_i - \bar{X}) e}{\sum_{i=1}^n (X_i - \bar{X})^2} \right] + E\left[\frac{-\sum_{i=1}^n (X_i - \bar{X}) E(e)}{\sum_{i=1}^n (X_i - \bar{X})^2} \right]$$

$$= \beta_1 + E\left[\frac{\sum_{i=1}^n (X_i - \bar{X}) e}{\sum_{i=1}^n (X_i - \bar{X})^2} \right]$$

$$= \beta_1 + \left[\frac{\sum_{i=1}^n (X_i - \bar{X}) E(e)}{\sum_{i=1}^n (X_i - \bar{X})^2} \right]$$

$E(e_i)$ 는 가우스 마코프 정리에 의해 0 이므로

$$= \beta_1 \rightarrow \text{결국 } E(\beta_1) = \beta_1$$

$$\sum_{i=1}^n (X_i - \bar{X}) =$$

$$\sum_{i=1}^n (X_i - \frac{1}{n} \sum_{i=1}^n X_i)$$

$$= \sum_{i=1}^n X_i - \sum_{i=1}^n \frac{1}{n} \sum_{i=1}^n X_i = 0$$

최소제곱법으로 추정된 직선식의 기울기가 실제 각 데이터 사이의 거리가 최소가 되게 하는 직선식의 기울기에 대한 Unbiased Estimator가 된다.


Linear Regression Analysis : process

2.2 회귀 계수 추정 (OLS) 및 유의성 검정

$$SST = SSR + SSE$$

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

회귀식이 설명 가능한 영역



회귀식이 설명 불가능한 영역

$$SSE = \sum (Y_i - \hat{Y}_i)^2$$

$$MSE = \frac{1}{df_E} \sum (Y_i - \hat{Y}_i)^2$$

회귀제곱합(SSR : Regression sum of squares))

: 회귀예측값과 평균의 차이

회귀제곱 평균(MSR)

: 회귀로 설명할 수 있는 편차

⑦ 계산: 회귀제곱합(SSR)/자유도

$$SSR = \sum (\hat{Y}_i - \bar{Y})^2$$

$$MSR = \frac{1}{df_R} \sum (\hat{Y}_i - \bar{Y})^2$$

$$R^2 = \frac{SSR}{SST} = \frac{\text{회귀식으로 설명되는 변동}}{\text{총 변동}}$$

오차 제곱합(SSE: Sum Squared Error, SSE)

잔차의 부호가 (+),(-)부호 간 계산으로 잔차의 합이 상쇄되는 것을 방지하기 위하여 잔차를 제곱하여 이에 합을 계산

➤ 오차 평균 제곱합(MSE : Mean Squared Error) 회귀로도 설명할 수 없는 잔차 : (계산) SSE/오차 자유도 실제 값과 회귀예측값과의 차이를 제곱해서 평균한 값

평균제곱근 오차 (Root Mean Square Error, RMSE)

⑦ MSE 가 오차의 제곱을 구한 것이므로 실제 오차보다 커지는 문제를 없애기 위하여 다시 루트를 한 값

SSE를 오차의 자유도(df: 단순회귀, n-2, 다중회귀: n-k-1, k:독립변수 개수)로 나누어 주는 이유

• 제곱된 값은 항상 양수

• 양수를 모두 더하게 되면, 데이터가 많을 수록 값은 커지게 된다.

⑦ SSE 자체가 데이터가 많을 수록 단순히 커지는 의미이기 때문에, 정말 오차가 높은가? 에 대한 평가기준이 잘못 해석될 수가 있기 때문에 ⑦ 자유도로 나눔으로써 평균이 계산되고, 보정된 평균오차를 모형의 Error 수준으로 판단하게 됨.

Linear Regression Analysis : process

2. 회귀계수 추정 (OLS) 및 유의성 검정

2. 3 회귀계수 해석

- 선형 회귀모형에서는 입력변수 x 가 1단위 증가할 때 목표변수 y 가 변화하는 양을 회귀계수 β 해석
- 회귀계수가 양(+)의 값으로 추정 ⑦ x 가 증가하면 y 가 증가
- 회귀계수가 음(-)의 값으로 추정 ⑦ x 가 증가하면 y 가 감소

⑦ 가설 검정을 통해 검증 (귀무가설, 대립가설)

→ 합한 회귀선이 자료에 잘 들어맞는지 결정계수 (coefficient of determination : R^2)로 확인

Linear Regression Analysis : process

2. 회귀계수 추정 (OLS) 및 유의성 검정

- 모수에 대한 추정 : β_0, β_1 추정 ⑦ 최소제곱법 이용
- 가설검정 : 선형회귀모형이 통계적으로 유의한가를 검정

2. 4 회귀계수 (기울기) 검증 : t-test

t 검정은 회귀식 기울기 회귀계수(β)검정 **회귀계수(기울기)가 0이면 독립변수와 무관(유의하지 않음)**

- 귀무가설(Null hypothesis) H_0 : β (베타) = 0 ⑦ 입력변수(x)와 y간에 인과관계가 없다.
- 대립가설(Alternative hypothesis) H_1 : β (베타) $\neq 0$ ⑦ 입력변수(x)와 y간 어떤 인과관계가 있다.

검정통계량
(test statistic)

$$t\text{-value}^* = \frac{\hat{\beta} - \beta}{s.e(\hat{\beta})} = \frac{\hat{\beta}}{s.e(\hat{\beta})} = \frac{\hat{\beta}}{\sqrt{MSE/S_{XX}}} \sim t(n-2)$$

회귀계수가 우연일 확률을 알기 위해 표준오차(s.e)로 조정해주는 것!!

$\hat{\beta}$: 회귀계수의 추정치, $s.e(\hat{\beta})$: 회귀계수추정치인 표준오차

통계적 유의성 판단

P-value = $2P(T > |t\text{-value}^*|)$ Where $T \sim t(n-2)$

- $|t\text{-value}^*| > \text{임계치}$: H_0 reject, H_1 accept, $|t\text{-value}^*| < \text{임계치}$: H_0 reject 못함.
- P-value < 유의수준 : H_0 reject, H_1 accept : **회귀계수가 통계적으로 유의**
- P-value > 유의수준 : H_0 reject 못함

구분	귀무가설(H_0)	귀무가설(H_1)	p-value	기각역
양측검정	$H_0: \beta_1 = 0$	$H_1: \beta_1 \neq 0$	$P = p(T \geq t)$	$ t \geq t_{\alpha/2}(n-2)$
좌측검정	$H_0: \beta_1 = 0$	$H_1: \beta_1 < 0$	$P = p(T \geq t)$	$t \geq t_{\alpha}(n-2)$
우측검정	$H_0: \beta_1 = 0$	$H_1: \beta_1 > 0$	$P = p(T \leq t)$	$t \leq -t_{\alpha}(n-2)$

Linear Regression Analysis : process

2. 회귀계수 추정 (OLS) 및 유의성 검정

2. 4 회귀계수 (기울기) 검증 : t-test

$$t\text{-value} = \frac{\hat{\beta} - \beta}{s.e(\hat{\beta})}$$

- ✓ (분자 값) 회귀계수 추정치가 클수록
- ✓ (분모 값) 회귀계수 추정치 표준오차(S.E)가 작을 수록



통계적 유의성

자유도(df) : 단순회귀모형(독립변수 = 1개)에서는 1
 ⑦ 독립변수가 증가하면 자유도 증가 (cost 증가)

구분		표준오차(S.E _b)	
		낮은 값	높은 값
회귀계수($\hat{\beta}$)	높은 값	O	Δ
	낮은 값	Δ	X

Δ영역에 대하여는?

유의수준(0.05) 경우 :

|t| > 2 회귀계수(회귀계수($\hat{\beta}$)) 를 쓸 수 있다. (귀무가설 기각)

|t| < 2 회귀계수($\hat{\beta}$)를 쓸 수 없다. (귀무가설 기각할 수 없다)

표준오차(standard error, SE) : 표본 평균들의 표준편차

: 표준오차가 커지면 유의성이 낮아지고, 표준오차가 작아지면 유의성이 높아진다.

⑦ 표준오차가 크다는 의미는 회귀선에서 멀리 떨어져 퍼져 있는 것 ⑦ 회귀계수가 우연일 확률이 높다는 것을 의미한다. 우연여부를 따지는 확률이 t-test이다.

Linear Regression Analysis : process

2. 회귀계수 추정 (OLS) 및 유의성 검정

2. 4 회귀계수 (기울기) 검증 : t-test

$$t\text{-value} = \frac{\hat{\beta}_1 - \beta}{se(\hat{\beta}_1)}$$



통계적 유의성 p-value

- t-value는 하나의 p-value를 갖는다.
- t-value와 자유도(Degrees of Freedom)을 이용하여, 해당하는 p-value를 T distribution table에서 찾을 수 있다.

p-value 의미

- 어떠한 sample data로부터 온 결과가 우연히 일어났을 확률을 의미 (0% ~ 100%).
- 따라서 P value는 낮을수록 좋다(우연에 의해 발생한 사건이 아닌, 실제로 인과관계가 있어서 일어난 일이므로). 일반적으로, P value = 0.05 (5%) 이하일 때 해당 data가 유의하다고 보며, 이 기준치를 alpha level / significance level이라고 한다.
- Alpha level의 값은 연구자가 결정할 수 있다. ⑦ 일반적으로 alpha level = 0.05로 설정 ⑦ 이 경우 해당 실험이 95%의 신뢰도(confidence)를 갖고 있다고 해석할 수 있다.

Linear Regression Analysis : process

2. 4 회귀계수 (기울기) 검증 : t-test

* 회귀분석에서 회귀계수에 대한 t-test를 하는 이유?

- 두 집단 간 평균 차이가 통계적 유의성 검정하는 방법
- 회귀분석에서 t-test는 얻어진 기울기에 대한 테스트
- 회귀계수에 대한 t-test = (회귀계수) / (표준오차), 이때 자유도(df)는 1
- 만약 다중회귀분석으로 가면 독립변수가 증가하고 이는 자유도가 증가하는 결과 $\Rightarrow$ 이는 표준오차 증가 $\Rightarrow$ t 값 낮아짐
- 결국 독립변수를 증가 시킬수록 비용(cost)이 증가 : 선형회귀분석에서 비용함수(cost function) MSE

회귀분석

t-test

- 귀무가설(H_0) : 회귀계수 = 0
- 대립가설(H_1) : 회귀계수 $\neq$ 0

- 귀무가설(H_0) : $\mu_A = \mu_B$
- 대립가설(H_1) : $\mu_A \neq \mu_B$

F검정과 t검정 관계

$$\begin{aligned} & \bullet \text{ SSR} = \beta^2 \sum (X_i - \bar{X})^2 \\ & \bullet \text{ } s^2(\hat{\beta}) = \frac{MSE}{\sum (X_i - \bar{X})^2} \end{aligned}$$

$$F^*(1, n-2) = \frac{\beta^2 \sum (X_i - \bar{X})^2}{MSE} = \frac{\hat{\beta}^2}{s^2(\hat{\beta})} = \left(\frac{\hat{\beta}}{s(\hat{\beta})} \right)^2 = t^2(n-2)$$

- F 값은 t 값을 제곱해서 구해진다.
- 두가지 검정이 동일함을 알 수 있다.

* MSE : Mean Squared Error


➤ MSE : Mean Squared Error ㉠ ㉠ ㉠

➤ *RMSE : Root Mean Square Error*

㉠ MSE 가 오차의 제곱을 구한 것이므로 실제 오차보다 커지는 문제를 없애기 위하여 다시 루트를 한 값

Loss function = cost function : MSE

- 실제값과 예측값의 차이를 제곱 합을 **평균**



손실 함수로부터 얻어진 **손실값 (Loss value)**은 훈련 과정에서 Neural Network가 **얼마나 잘 훈련되었는지 확인하는 지표**

- 회귀모델 손실함수 : MSE, MAE, RMSE
- 분류모델 손실함수 : Binary cross-entropy, **cross entropy error**: 소프트맥스 함수의 손실함수로 사용
Categorical cross-entropy

* Standardized Regression Coefficient

비표준화 회귀계수 (b) (Regression Coefficient)	표준화 회귀계수 (β)(Standardized Regression Coefficient)
1. 회귀분석은 편차 제곱의 합이 최소가 되는 최적선을 구하는 즉, 최적선의 기울기 (Slope)와 절편을 구하는 통계 분석 방법 ⑦ 최적선을 비표준화 회귀식이라고 함. ⑧ 최적선의 기울기와 절편을 비표준화 회귀계수(unstandardized regression coefficients)	- 표준화한 회귀계수 의미는 종속변수 Y와 독립변수 X에 대해 평균이 0 이고, 표준편차가 1인 표준정규분포화 한 의미 - 다중 회귀분석의 경우, 표준화 회귀계수를 구하면 X 변수들의 종속변수 Y에 대한 상대적 영향도를 의미
X가 1 단위 증가할 때 Y 는 회귀계수 배 평균적으로 증가하는 것으로 해석 가능	표준화 회귀계수는 X 가 1 표준편차 증가할 때, Y 표준편차의 평균적인 증가량을 의미
b는 X와 Y의 측정 단위의 영향을 받는다.	측정단위의 영향을 받지 않는다.
⑦ 비표준화 회귀계수는 측정 단위의 영향을 받기 때문에 이를 표준화 하여 사용하기도 한다.	표준화계수가 가장 큰 경우 해당 독립변수가 가장 영향력이 크다. (단, 우연 발생 여부는 테스트가 별도 필요) - 모든 독립변수들의 단위를 통일화 시킨 회귀계수 ⑧ 독립변수 회귀계수 비교 가능 ⑧ 독립변수를 표준화 시킨 후 회귀분석한 경우와 동일 한 것 임!!!!
절편 값 : X가 0일 때, Y	절편 = 0 (원점을 지나는 회귀 직선이므로)
예측모형으로 활용시 (경제, 금융) : 수입이 0이라도 지출이 0 ??	독립변수 중 우선(상대적) 중요도가 무엇? 만족도 조사

$$\text{표준화 회귀계수} = \frac{\text{비표준화 회귀계수}}{\frac{SD_Y}{SD_X}}$$

$$\begin{aligned} \text{표준화 회귀계수} &= \text{비표준화 회귀계수} \div \frac{SD_Y}{SD_X} \\ &= \text{비표준화 회귀계수} \times \frac{SD_X}{SD_Y} \end{aligned}$$

Linear Regression Analysis : Process

2. 회귀계수 추정 (OLS) 및 유의성 검정

2.5 모형 검증 분산분석(ANOVA)

F검정 : 단순회귀분석의 적합성 검정을 위한 분산분석(ANOVA)

표 : 모형적합도, 회귀식이 유용한지를 판단?

⑦ 모든 회귀계수에 대한 유의성 검정

구분	자유도	평균 제곱	F 값
회귀(SSR)	1	MSR	$F = \frac{MSR}{MSE}$
오차(SSE)	$n - 2$	MSE	
총변동(SST)	$n - 1$		

• 총변동의 자유도(SST) = $(n - 1)$, 오차(SSE)의 자유도 = $(n - 2)$
인 이유

- ⑦ 총변동의 경우는 $\bar{Y}$ 한 개 값이 추정되므로 $(n - 1)$
- ⑦ SSE는 절편 α 와 회귀계수 β 두 개 값이 추정되기 때문에 $(n - 2)$
- SSR 자유도 = SST자유도 - SSE 자유도 = $n - 1 - (n - 2) = 1$

- 귀무가설(H_0) : 회귀식이 유의하지 않다. ($\beta = 0$ 이다)
- 대립가설(H_1) : 회귀식이 유의하다. ($\beta = 0$ 이 아니다)

- H_0 유의성($H_0: \beta = 0$) 기각되면 F 값이 1보다 크게 된다. ⑦ H_1 채택
- F값이 크다는 것은 회귀식으로 설명하는 부분이 더 많다는 의미로 회귀식이 유의하다는 판단을 내릴 수 있다.
- F분포표 기각역값 < F값 : H_0 기각 (회귀식 유의성)

t검정에서 R square 값이 사용되는 것과 같은 의미로 ANOVA 분산분석에서는 η square 값 사용

평균 변동

- 평균 변동: 제곱합 값 즉, 변동 합을 자유도로 나눈 값이 평균 변동
- $MSR = \frac{SSR}{1}$
- $MSE = \frac{SSE}{(n-2)}$

회귀모형에서 설명변수의 귀무가설 유의성($H_0: \beta = 0$)을 검정하기 위하여 검정통계량

검정통계량

$$F\text{-value} = \frac{MSR}{MSE}$$

$$F^* = \frac{MSR}{MSE} = \frac{\frac{SSR}{\sigma^2} / 1}{\frac{SSE}{\sigma^2} / (n-2)} = \frac{\chi^2(1)/1}{\chi^2(n-2)/(n-2)} \sim F(1, n-2)$$

$$MSR \uparrow, \quad MSE \downarrow$$

Linear Regression Analysis : Process

3. 유의적 독립변수 선택방법

구분	내용
후진 제거법 (Backward elimination)	<u>모든 독립변수를 사용하여</u> 하나의 회귀식을 수립 후 ❶ 회귀식에서 중요하지 않은 독립변수 값들에 대한 검정을 한 후, 그 값이 <u>가장 유의하지 않은 변수(p-value 큰 값)부터 차례로 제거하고</u> 남은 나머지 독립변수들을 바탕으로 회귀식을 다시 추정하는 방법
전진 선택법 (Forward selection)	종속변수에 <u>가장 큰 영향을 줄 것으로 판단되는 하나의 독립변수 (p-value 낮은 값)를 이용하여</u> 회귀식을 수립 후 ❷, <u>단계마다 중요하다고 판단되는 독립변수를 하나씩 회귀식에 추가하여</u> 회귀모델을 다시 추정하는 방법 ❶ 통계적으로 유의한 설명변수가 없을 때 까지 반복
단계별 선택법 (Stepwise selection)	• 후진 제거법과 전진 선택법의 절충적인 형태 • 전진 선택법에 따라 종속변수에 가장 설명력이 높고 <u>(p-value 낮은 값) 유의한 변수를 선택</u> • 이미 선택된 설명변수의 설명부분을 제외하고 설명력이 가장 크고 유의한 변수 선택 • 새로 선택된 변수의 설명 부분을 제외한 부분에 대해 이미 존재한 설명변수의 유의성을 검정하여 유의하지 않을 경우 제외시킨다.


Linear Regression Analysis : Process

4. 모형진단 : 잔차 분석 (Residual Analysis)

오차 값을 알 수 없으므로

잔차는 오차항의 관찰값(추정치)이므로 잔차들을 분석해 봄으로써 회귀분석의 가정 즉, 오차항에 대한 3가지 가정들의 성립여부를 확인 가능하게 됨. ❶ 회귀분석에서는 이를 잔차분석이라고 한다.

잔차 분석	비고	해결
정규성 검정	- 오차항이 정규분포이면 종속변수(y_t)도 정규분포를 따른다. - zero mean ; $E(\varepsilon_i) = 0$ - F분포를 따르므로 모형검정을 위해 F 검정 - 검증방법 : Shapiro-Wilk test, Anderson-Darling 통계량	정규성을 따르지 않으면 변수 변환 ❶ 가장 자주 사용되는 것은 log 변환(예시 : 총자산 변환)
등분산성 검정	- 잔차 산점도등 통해 확인해 본다 - 등분산성(homoskedasticity)이 아닌 경우 이분산성모형(Heteroskedasticity)의 부적합성 발생 $Var(\varepsilon_i) = \sigma^2$ 등분산성 테스트 : Levene's test	WLS(Weight Least Square)을 이용 GLS regression변수변환
독립성 검정	- 자료 수집 과정이 무작위 표집(random sampling)을 하였다면, 잔차의 독립성은 만족하는 것으로 볼 수 있음. $cov(\) = 0$ - 시계열자료의 경우 독립성 확보가 어려운 경우 독립성 검정 필요 - nonautocorrelation : $Cov(\varepsilon_i, \varepsilon_j) = 0$ - 오차의 자기상관 - Durbin-Waston 통계량(약 0 ~ 4사이의 값) - 0에 가까울수록 → 양의 상관관계 - 4에 가까울수록 → 음의 상관관계 - 2에 가까울수록 → 오차항의 자기상관이 없음	독립성이 아닌 경우 1차 차분($y_t - y_{t-1}$)을 이용하여 시계열자료에 대한 독립성 확보



Linear Regression Analysis : Process

5. 최종 회귀모형 결정

- 모델 결정 후 : 데이터 분할을 통한 검증 ⑦ 예측 모델에 활용
- 추정(표본통계량을 가지고 모집단 모수 값을 추측하는 과정) 등 활용

결정계수(coefficient of determination)

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

$$= \frac{\sigma(\hat{Y}_i - Y)^2}{\sigma(Y - \bar{Y})^2}$$

$$= \frac{\text{회귀식으로 설명되는 변동}}{\text{총 변동}}$$

수정결정계수(Adjusted R Square)

$$R_{ad}^2 = 1 - \left[\frac{n-1}{n-(k+1)} \right] \frac{SSE}{SST}$$

$$R^2 \geq R_{ad}^2$$

- n: 표본 데이터에서 자료의 갯수
- k: 독립변수의 개수(모형에서 사용한 상수를 제외한 변수의 개수)

- 추정한 선형 모형이 주어진 자료에 **적합성 척도**
- 반응변수의 변동량 중(SST)에서 적용한 모형으로 설명가능한 부분(SSR)의 비 ⑦ 회귀직선의 설명력
- 총제곱합(SST): 관측값과 평균의 차이(편차)에서 기인
- 회귀제곱합(SSR) : 회귀예측값과 평균의 차이: 편차 중 회귀로 설명되는 부분에서 기인 → 결국, 전체 편차 중 회귀로 설명 가능한 편차가 몇 %인지 계산하겠다는 의미
- 결정계수 값 : 0~1 사이의 값
- 1에 가까울 수록 모든 데이터들이 회귀식에 접근한다는 것으로, 설명력이 높다)
- ⑦ 결정계수는 단순히 선형 관계의 정도를 나타내는 수치
- 독립변수 개수가 많아질수록 결정계수 값이 커지게 된다. 따라서 종속변수의 변동을 별로 설명해 주지 못하는 변수가 모형에 추가되도 결정계수 값이 커질 수 있다.

- 표본의 크기와 독립변수의 수를 고려하여 계산
- 단순회귀분석을 하는 경우에는 일반 결정계수를 사용하면 되지만 ⑦ 다중회귀분석을 수행하는 경우에는 수정된 결정계수를 함께 고려해야 함.

값이 애매한 수치의 경우

⑦ 가설검정을 병행 필요하게 됨!!!!!!!!!!!!

결정계수 값으로 모형 적합 판단하기는 애매

⑦ t 검정, p-value 판단


단순회귀의 경우 상관계수의 제곱 = 결정계수

- ⑦ 문제점을 보완하기 위해 나타난 것이 수정결정계수

Regression Analysis : Practice examples

Sample Data

	Y (target) 근무평점	X (feature) 연 검거 건수
A	10	32
B	7	18
C	8	25
D	5	13
E	9	29
F	6	21
G	2	10
H	7	43
I	3	12
J	4	20
평균	6.1	22.3
분산	6.76666667	104.9
표준편차	2.60128174	10.2420701




Regression Analysis : Practice examples

Sample Data

	Y (target) 근무평점	X (feature) 연 검거 건수
A	10	32
B	7	18
C	8	25
D	5	13
E	9	29
F	6	21
G	2	10
H	7	43
I	3	12
J	4	20
평균	6.1	22.3
분산	6.76666667	104.9
표준편차	2.60128174	10.2420701

각 개인별 검거건수, 근무평점 (X,Y)를 그래프에 점으로 표시하여 산점도 완성




Regression Analysis : Practice examples

Sample Data

	Y (target) 근무평점	X (feature) 연 검거 건수
A	10	32
B	7	18
C	8	25
D	5	13
E	9	29
F	6	21
G	2	10
H	7	43
I	3	12
J	4	20
평균	6.1	22.3
분산	6.76666667	104.9
표준편차	2.60128174	10.2420701

Y값의 평균은 Y 전체 합을 Y 개수만큼 나눈 값으로 도출한다.



편차 : 평균값으로부터 관측값이 떨어진 정도

Regression Analysis : Practice examples

회귀식 도출 순서

잔차제곱합 : $\sum \hat{u}_i^2 = \sum (Y_i - \hat{Y}_i)^2$ $\hat{Y}_i = \hat{\beta}_1 + \hat{\beta}_2 * X_i$ 이므로

$$\sum \hat{u}_i^2 = \sum (Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_i)^2$$

여기서 회귀계수에 대해 편미분 시행으로 최소제곱합을 도출할 수 있음

절편 $\frac{\partial \sum \hat{u}_i^2}{\partial \hat{\beta}_1} = -2 \sum (Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_i) = 0$

$$\sum Y_i = n \hat{\beta}_1 + \hat{\beta}_2 \sum X_i$$


회귀계수 $\frac{\partial \sum \hat{u}_i^2}{\partial \hat{\beta}_2} = -2 \sum (Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_i) X_i = 0$

$$\sum Y_i X_i = \hat{\beta}_1 \sum X_i + \hat{\beta}_2 \sum X_i^2$$


정리한 두 식에 대해 연립방정식으로 풀면 된다.

$$\hat{\beta}_2 = \frac{\sum (X_i - \bar{X})(\sum (Y_i - \bar{Y}))}{\sum (X_i - \bar{X})^2} \xrightarrow{\text{일반화}} \hat{\beta}_2 = \frac{\sum (x_i * y_i)}{\sum (x_i^2)} = \frac{x, y \text{ 편차의 곱셈합}}{x \text{ 편차 제곱합}}$$

최소제곱법은 잔차의 제곱 합이 최소가 되도록 만드는 회귀 계수를 추정하는 방식



C : (25, 8)



$$SST : \sigma(Y_c - \bar{Y})^2$$

$$SSR : \sigma(Y_c - \bar{Y})^2$$

$$SSE : \sigma(Y_c - \bar{Y})^2$$


Regression Analysis : Practice examples

Sample Data

	Y (target) 평점	X (feature) 건수	편차 x * y	편차의 제곱 x ²
A	10	32	37.83	94.09
B	7	18	-3.87	18.49
C	8	25	5.13	7.29
D	5	13	10.23	86.49
E	9	29	19.43	44.89
F	6	21	0.13	1.69
G	2	10	50.43	151.29
H	7	43	18.63	428.49
I	3	12	31.93	106.09
J	4	20	4.83	5.29
합	61	223	174.7	944.1
평균	6.1	22.3	17.47	94.41
분산	6.76666667	104.9	315.078222	16376.5973
표준 편차	2.60128174	10.2420701	17.7504429	127.97108

회귀 계수

$$\beta_2 = \frac{\sum(X_i - \bar{X})(\sum(Y_i - \bar{Y}))}{\sum(X_i - \bar{X})^2} \xrightarrow{\text{일반화}} \beta_i = \frac{\sum(x_i * y_i)}{\sum(x_i^2)} = \frac{x_{i,Y} \text{ 편차의 곱셈 합}}{x \text{ 편차 제곱합}}$$



Regression Analysis : Practice examples


회귀계수의 분산

$$Var(\hat{\beta}_2) = \frac{\sigma_e^2}{\sum_{i=1}^{10} (X_i - \bar{X})^2}$$

= $\frac{\text{잔차의 분산}}{\text{feature의 편차제곱합}}$

$$\sigma_e^2 = \frac{\sum_{i=1}^{10} (Y_i - \hat{Y}_i)^2}{n - 2} = \frac{\text{잔차제곱합}}{\text{잔차의 자유도}} \quad \left(\frac{28.572819}{10 - 2} = 3.5716 \right)$$

	Y (target) 평점	X (feature) 건수	편차 x * y	편차의 제곱 x ²	잔차의 제곱 e ²
A	10	32	37.83	94.09	4.43133655
B	7	18	-3.87	18.49	2.87536118
C	8	25	5.13	7.29	1.96106695
D	5	13	10.23	86.49	0.38552799
E	9	29	19.43	44.89	2.75628064
F	6	21	0.13	1.69	0.01975627
G	2	10	50.43	151.29	3.32682643
H	7	43	18.63	428.49	8.58730277
I	3	12	31.93	106.09	1.42574824
J	4	20	4.83	5.29	2.80361201
합	61	223	174.7	944.1	28.572819
평균	6.1	22.3	17.47	94.41	2.8572819
분산	6.76666667	104.9	315.078222	16376.5973	5.83980853
표준 편차	2.60128174	10.2420701	17.7504429	127.97108	2.41656958



$$Std(\hat{\beta}_2) = \sqrt{Var(\hat{\beta}_2)} = \sqrt{\frac{3.5716}{944.1}} = 0.06151$$

Regression Analysis : Practice examples

결정 계수 (R2)


$$R^2 \text{ 결정 계수} = 1 - \frac{SSE}{SST} (= \frac{SSR}{SST}) \quad \text{전체의 변동 중 설명 가능한 변동의 비율 (회귀 식의 설명력)}$$

$$= 1 - \frac{28.57282067577587}{60.9} \approx 0.53082$$

	Y (target) 평점	X (feature) 건수	편차 $x * y$	편차 x^2	잔차 e	잔차의 제곱 e^2
A	10	32	37.83	94.09	2.105074	4.43133655
B	7	18	-3.87	18.49	1.695689	2.87536118
C	8	25	5.13	7.29	1.400381	1.96106695
D	5	13	10.23	86.49	0.620909	0.38552799
E	9	29	19.43	44.89	1.660205	2.75628064
F	6	21	0.13	1.69	0.140557	0.01975627
G	2	10	50.43	151.29	-1.823959	3.32682643
H	7	43	18.63	428.49	-2.93041	8.58730277
I	3	12	31.93	106.09	-1.194047	1.42574824
J	4	20	4.83	5.29	-1.674399	2.80361201
합	61	223	174.7	944.1	0	28.572819
평균	6.1	22.3	17.47	94.41	0	2.8572819
분산	6.76666667	104.9	315.078222	16376.5973	$\frac{3.1747576}{7}$	5.83980853
표준 편차	2.60128174	10.2420701	17.7504429	127.97108	$\frac{1.7817849}{7}$	2.41656958

조정된 결정 계수 (Adjusted R2)

$$\text{Adj } R^2 = 1 - \frac{SSR / (n-k-1)}{SST / (n-1)} = 1 - \frac{28.5728T(10-1-1)}{60.9T(10-1)} \approx 0.47218$$



$$R^2 = \frac{SSR = \sum (Y_i - \hat{Y}_i)^2}{SST = \sum (Y_i - \bar{Y})^2}$$

SSR (잔차의 제곱 합) / SST (편차의 제곱 합)

Regression Analysis : Practice examples

F 값


SSE, SSR은 분산으로서 카이제곱 분포를 따르며, 이 두 비율 값은 F분포를 따른다.

$$\frac{MSE}{MSR} \rightarrow \left\{ \begin{array}{l} \frac{SSE \text{ (편차와 잔차의 차이 제곱 합)} / \text{Feature 개수 } (k) - 1}{SSR \text{ (잔차의 제곱 합)} / (\text{Obs 개수 } (n) - \text{feature 개수 } (k) - 1)} \end{array} \right\} F = \frac{32.32717}{(28.57282)/(10 - 1 - 1)} = 9.051169$$

요인	제곱합	자유도	평균제곱합	F 값
Error	SSE 32.32717	1	MSE 32.32717	MSE/MSR 9.05116
Residual	SSR 28.57282	n-k-1 8	MSR 3.57160	

귀무가설 (H_0): $\beta_1 = \beta_2 = \dots = \beta_k = 0$ 대립가설 (H_1): $\beta_j \neq 0$ (for some j)

	Y (target) 평균	X (feature) 개수	편차 x * y	편차 x ²	잔차 e	잔차의 제곱 e ²
A	10	32	37.83	94.09	2.105074	4.43133655
B	7	18	-3.87	18.49	1.695689	2.87536118
C	8	25	5.13	7.29	1.400381	1.96106695
D	5	13	10.23	86.49	0.620909	0.38552799
E	9	29	19.43	44.89	1.660205	2.75628064
F	6	21	0.13	1.69	0.140557	0.01975627
G	2	10	50.43	151.29	-1.823959	3.32682643
H	7	43	18.63	428.49	-2.93041	8.58730277
I	3	12	31.93	106.09	-1.194047	1.42574824
J	4	20	4.83	5.29	-1.674399	2.80361201
합	61	223	174.7	944.1	0	28.572819
평균	6.1	22.3	17.47	94.41	0	2.8572819
분산	6.76666667	104.9	315.078222	16376.5973	3.17475767	5.83980853
표준편차	2.60128174	10.2420701	17.7504429	127.97108	1.78178497	2.41656958



참고) 결정 계수를 통해 F 값 구하는 법

$$F = \frac{R^2}{(1 - R^2)/(n - k - 1)} \Rightarrow \frac{0.53082}{0.469177(10 - 1 - 1)} = 9.05116$$

Regression Analysis : Practice examples

귀무가설 (H_0) : $\beta_j = 0$ T값기울기 = 0 (변수간 인과성이 전혀 없다) $t = \frac{\hat{\beta}}{se(\hat{\beta})}$ 대립가설 (H_1) : $\beta_j \neq 0$


t = 회귀계수 / 회귀계수의 표준편차

기울기 0인 집단과 회귀계수 추정치 집단 간 평균값이 유의한 차이를 보이는지 t-test 시행

$$t = \frac{\hat{\beta} - 0}{se(\hat{\beta})}$$

$$t = \frac{0.18504}{0.06151} = 3.00829$$

	Y (target) 평점	X (feature) 건수	편차 $x * y$	편차 x^2	잔차 e	잔차의 제곱 e^2
A	10	32	37.83	94.09	2.105074	4.43133655
B	7	18	-3.87	18.49	1.695689	2.87536118
C	8	25	5.13	7.29	1.400381	1.96106695
D	5	13	10.23	86.49	0.620909	0.38552799
E	9	29	19.43	44.89	1.660205	2.75628064
F	6	21	0.13	1.69	0.140557	0.01975627
G	2	10	50.43	151.29	-1.823959	3.32682643
H	7	43	18.63	428.49	-2.93041	8.58730277
I	3	12	31.93	106.09	-1.194047	1.42574824
J	4	20	4.83	5.29	-1.674399	2.80361201
합	61	223	174.7	944.1	0	28.572819
평균	6.1	22.3	17.47	94.41	0	2.8572819
분산	6.76666667	104.9	315.078222	16376.5973	3.17475767	5.83980853
표준편차	2.60128174	10.2420701	17.7504429	127.97108	1.78178497	2.41656958




$$\hat{\beta}_i = \frac{\sum(x_i * y_i)}{\sum(x_i^2)} \Rightarrow \hat{\beta} = \frac{174.7}{944.1} = 0.18504$$

$$se(\hat{\beta}) = \sqrt{Var(\hat{\beta})} \Rightarrow \sqrt{\frac{\sigma(Y_i - \hat{Y}_i)^2(n-k-1)}{\sigma(X_i - \bar{X})^2}} = \sqrt{\frac{28.572819}{944.1}} = 0.003783 \approx 0.06151$$

Regression Analysis : Practice examples

참고) t값의 p값 시각화



양방향(Two-sided)	50%	60%	70%	80%	90%	95%	98%	99%
1	1.000	1.376	1.963	3.078	6.314	12.71	31.82	63.66
2	0.816	1.080	1.386	1.886	2.920	4.303	6.965	9.925
3	0.765	0.978	1.250	1.638	2.353	3.182	4.541	5.841
4	0.741	0.941	1.190	1.533	2.132	2.776	3.747	4.604
5	0.727	0.920	1.156	1.476	2.015	2.571	3.365	4.032
6	0.718	0.906	1.134	1.440	1.943	2.447	3.143	3.707
7	0.711	0.896	1.119	1.415	1.895	2.365	2.998	3.499
8	0.706	0.889	1.108	1.397	1.860	2.306	2.896	3.355

유의수준 : 1종 오류를 허용하는 최대치로 연구자의 주관적인 설정을 반영 (5% 유의수준 등)

참고) 회귀 분석 표

OLS Regression Results					
Dep. Variable:	Y	R-squared:	0.531		
Model:	OLS	Adj. R-squared:	0.472		
Method:	Least Squares	F-statistic:	9.051		
Date:	Tue, 12 Apr 2022	Prob (F-statistic):	0.0169		
Time:	12:53:59	Log-Likelihood:	-19.439		
No. Observations:	10	AIC:	42.88		
Df Residuals:	8	BIC:	43.48		
Df Model:	1				
Covariance Type:	nonrobust				
	coef	std err	t	P> t	[0.025 0.975]
const	1.9735	1.496	1.319	0.224	-1.477 5.424
X	0.1850	0.062	3.009	0.017	0.043 0.327
Omnibus:	2.019	Durbin-Watson:	0.440		
Prob(Omnibus):	0.364	Jarque-Bera (JB):	0.946		
Skew:	-0.328	Prob(JB):	0.623		
Kurtosis:	1.644	Cond. No.	61.0		

Simple Regression Analysis : Interpretation

- Statsmodel 라이브러리
- Sklearn 라이브러리
- Scipy 라이브러리
- linearmodels

<https://pypi.org/project/linearmodels/>

단순회귀분석 결과를 해석

- 모형의 적합도(F) 확인
- 회귀계수 확인(t)
- 유의확률(p-value) 확인
- 결정계수 확인

OLS Regression Results						
Dep. Variable:	전체형법범죄		R-squared:	0.574		
Model:	OLS		Adj. R-squared:	0.564		
Method:	Least Squares		F-statistic:	53.94		
Date:	Mon, 14 Feb 2022		Prob (F-statistic):	6.24e-09		
Time:	14:15:16		Log-Likelihood:	-307.98		
No. Observations:	42		AIC:	620.0		
Df Residuals:	40		BIC:	623.4		
Df Model:	1					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
const	-788.8905	275.455	-2.864	0.007	-1345.698	-232.175
살인	1101.2122	149.933	7.345	0.000	798.185	1404.239
Omnibus:	5.833	Durbin-Watson:	0.310			
Prob(Omnibus):	0.054	Jarque-Bera (JB):	5.128			
Skew:	0.854	Prob(JB):	0.0770			
Kurtosis:	3.127	Cond. No.	11.1			

$$\frac{1101.2122}{149.933}$$

$$p\text{-value} = 0.000 < 0.05$$

참고 : <https://bashtage.github.io/linearmodels/panel/examples/using-formulas.html>

* Example 1

A 항공에 가장 큰 영향을 미치는 경제변수는 무엇일까 ?

1개, 2개, 다수

유류할증료로 유가(WTI) 1개로 설정 ! ,

$$y = \beta_0 + \beta_1 x_1 + \varepsilon$$

$$\text{A항공 월별수익률} = \beta_0 + \beta_1 \text{WTI 수익률} + \varepsilon$$

설정 대상기간에 대한 월별수익률

- EDA: Exploratory Data Analysis) : Scatter plot

- ⑦ Correlation analysis
- ⑦ regression analysis
- ⑦ regression coefficient 산정
- ⑦ regression coefficient 통계적 검증
- ⑦ 유의한 경우 : regression equation 도출 투자에 이용

Sklearn LinearRegression

on클래스

- Fit: 기울기계수, 절편, 상관계수
- Predict메소드를 통해 예측

<https://github.com/freejyb/kdigital>

예측분석

* W.Sharpe : Market Model

단일지수모형: Simple Index Model

: 단순회귀식을 이용

1) 가정

- ① 증권시장 전체의 수익률 변동을 적절하게 나타내는 시장지표(Market Index) 존재
- ② 각 증권의 수익률과 시장지표 사이에 **단순회귀관계가 존재 (인과관계)**


2) 모형

$$R_i = a_i + \beta_i R_M + \varepsilon_i$$

기울기 β_i 계산?

$$\sigma_i^2 = \beta_i^2 \sigma_m^2 + \sigma^2(\varepsilon_i)$$

$$\sigma_p^2 = \beta_p^2 \sigma_m^2 + \sigma^2(\varepsilon_p)$$



<https://github.com/freejyb/kdigital>

예측분석 단순선형회
귀(시장모형)

Multiple Regression Analysis

1. 다중회귀분석 의미

- 독립변수가 2개 이상 : 중회귀분석
- 독립변수 x_1 이외 다른 독립변수의 영향력을 **고정(통제)**된 상태에서 편회귀계수 (partial regression coefficients)로 특정 독립변수의 영향력 정도를 보여주는 분석
- $\beta_0, \beta_1, \beta_2, \dots, \beta_p$: 추정되어야 할 $(p+1)$ 개의 회귀계수
- ε 는 $N(0, \sigma^2)$ 를 갖는 오차항
- ➔ 회귀계수들의 추정치 $\beta_0, \beta_1, \beta_2, \dots, \beta_p$ 오차제곱합을 최소로 하는 최소제곱법에 의해서 수식화
- 각 회귀계수들에 대한 검정도 : 단순선형 회귀모형에서와 유사하게 t 통계량을 이용하여 수행

$$y = f(x) + \varepsilon = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p + \varepsilon = \beta_0 + \sum_{i=1}^p \beta_i x_i + \varepsilon$$

2. 가정

1. 선형성 : 독립변수의 변화에 대한 종속변수 값의 변화가 일정(비례적)해야 함. (위배시:비선형회귀분석으로)
2. 정규성 : 특정한 독립변수에 대한 종속변수 값들은 정규분포해야 한다
3. 등분산성 : 잔차 분포가 평균=0 을 중심으로 동일하게 분포. 모든 정규분포의 분산은 동일해야 함.
4. 독립성 : 독립변수간에 관련이 없어야 한다. (다중공선성 문제와 연결)

Multiple Regression Analysis : Significance test

- 단순선형회귀분석 : 입력변수(x)와 출력변수(y)간의 선형성을 점검하기 위해 산점도로 확인 (직선관계만 분석 가능하므로)
- 다중선형회귀분석 : 회귀분석의 가정 4가지 모두 만족하는지 확인

$$Y = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p + \varepsilon = \beta_0 + \sum_{i=1}^p \beta_i x_i + \varepsilon$$

가설검정(H_0, H_1), 회귀계수 t-value 확인, p-value 확인 (유의수준)

- 귀무가설 (H_0) : $\beta_1 = \beta_2 = \dots = \beta_p = 0$
- 대립가설 (H_1) : β (베타) $\neq 0$

p 개의 독립변수 $x_1, x_2, \dots, x_p$ 가 종속변수(y)를 설명하는 데 있어서 통계적으로 유의한지를 검정

검정통계량 t-value

t 검정

검정통계량 |t-value| > 임계치 : 귀무가설 기각, 대립가설 채택

검정통계량 |t-value| < 임계치 : 귀무가설 기각 못함.

$$t_j = \frac{\beta_j - \beta_j^0}{s.e.(\beta_j)} \sim t(n-p-1)$$

$$|t_j| > t_{(p-n-1, \frac{\alpha}{2})}$$

p-value

- p-value < 0.05 귀무가설 기각 : 대립가설이 채택되어 계산된 회귀계수 값이 통계적으로 유의하다.
- P-value > 0.05 귀무가설 기각하지 못한다.

Multiple Regression Analysis : Interpretation

다중회귀분석 결과를 해석

- 모형의 적합도 확인 (F)
- 회귀계수 확인 (t)
- 유의확률 확인 (p-value)
- 조정결정계수 확인 R^2

OLS Regression Results

```

=====
Dep. Variable:          MEDV    R-squared:                0.741
Model:                  OLS     Adj. R-squared:             0.734
Method:                 Least Squares    F-statistic:          108.1
Date:                   Mon, 18 Nov 2019    Prob (F-statistic):    6.72e-135
Time:                   21:54:23    Log-Likelihood:        -1498.8
No. Observations:      506    AIC:                   3026.
Df Residuals:          492    BIC:                   3085.
Df Model:              13
Covariance Type:       nonrobust
=====

```

```

=====
               coef      std err          t      P>|t|      [0.025      0.975]
-----
const          36.4595      5.103        7.144      0.000      26.432      46.487
CRIM           -0.1080      0.033       -3.287      0.001      -0.173     -0.043
ZN             0.0464      0.014        3.382      0.001       0.019      0.073
INDUS          0.0206      0.061        0.334      0.738      -0.100      0.141
CHAS           2.6867      0.862        3.118      0.002       0.994      4.380
NOX            -17.7666      3.820       -4.651      0.000     -25.272     -10.262
RM             3.8099      0.418        9.116      0.000       2.989      4.631
AGE            0.0007      0.013        0.052      0.958      -0.025      0.027
DIS            -1.4756      0.199       -7.398      0.000      -1.867     -1.084
RAD            0.3060      0.066        4.613      0.000       0.176      0.436
TAX            -0.0123      0.004       -3.280      0.001      -0.020     -0.005
PTRATIO        -0.9527      0.131       -7.283      0.000      -1.210     -0.696
B              0.0093      0.003        3.467      0.001       0.004      0.015
LSTAT          -0.5248      0.051     -10.347      0.000      -0.624     -0.425
=====

```

Multiple Regression Analysis : Issue

1. 효과크기(effect size) 문제

- 독립변수가 종속변수에 미치는 **영향의 정도나 강도를 나타내며**, 연구 결과의 실질적 중요성을 평가하는 데 사용
- 다중회귀분석에서 효과크기 문제를 다루는 것은 연구 결과의 해석과 일반화에 있어 중요한 역할

효과크기의 중요성

- 정확한 해석:** 통계적 유의성만으로는 연구 결과의 실질적 중요성을 완전히 이해할 수 없다. 효과 크기는 연구 결과가 실제로 얼마나 의미 있는지를 제공한다.
- 결과의 비교 가능성:** 다른 연구들과의 비교를 가능하게 하여, 특정 분야에서의 연구 결과들 간의 일관성을 평가하는 데 도움을 준다.
- 샘플 크기 계획:** 연구설계 단계에서 적절한 샘플 크기를 결정하는 데 필요한 정보를 제공 ⑦ 효과 크기가 크면 작은 샘플로도 통계적 유의성을 검출할 수 있다.

다중회귀분석에서의 효과크기 문제

- 변수 간 상관관계:** 다중회귀분석에서 사용되는 여러 독립변수들 사이에 상관관계가 있을 경우, 개별 변수의 효과 크기를 정확히 추정하기 어려울 수 있다. ⑦ 다중공선성 문제와 관련
- 표준화 계수:** 효과크기를 평가하기 위해 표준화된 회귀계수(베타 계수)를 사용할 수 있다. ⑦ 이는 변수들이 서로 다른 척도로 측정되었을 때 유용하며, 변수들 간의 상대적 중요성을 비교하는 데 도움을 준다.
- 부분 효과 크기:** 다중회귀분석에서는 각 독립변수의 부분 효과 크기를 평가할 수 있다. ⑦ 이는 다른 변수들의 영향을 통제된 상태에서 특정 변수가 종속변수에 미치는 영향의 크기를 나타낸다.
- 결정계수(R^2)와 조정된 결정계수:** 모델 전체의 효과크기를 나타내는 지표 ⑦ 조정된 결정계수는 독립변수의 수를 고려하여 조정된 값으로, 모델의 과적합을 방지하는 데 도움을 준다.

다중회귀분석에서 효과크기를 적절히 평가하고 해석하는 것은 연구 결과의 실질적 중요성을 이해하고, 연구 설계와 결과의 비교 가능성을 높이는 데 중요
다중공선성과 같은 문제를 인식하고, 표준화 계수, 부분 효과 크기, 결정계수 등을 통해 효과 크기를 정확히 평가 !!!!

Multiple Regression Analysis : Issue

2. 다중 공선성(Multi collinearity)

- 공선성(collinearity)

: 다중회귀분석에서 하나의 독립변수가 다른 하나의 독립변수로 잘 예측되는 경우, 또는 서로 상관이 높은 경우

- 다중공선성(multicollinearity)

: 하나의 독립변수가 다른 여러 개의 독립변수들로 잘 예측되는 경우

- 독립변수(x)들 간의 독립적이어야 하는 가정에 반하여 **상관관계가 높은 것을 의미**

다중공선성 문제점

1) 회귀계수 추정치 불안정성

-다중공선성이 높으면 회귀계수 추정치 표준오차(S.E)가 큰 값을 갖게 되므로 새로운 변수를 포함시키거나 새로운 관측치를 추가하면 회귀계수 추정치의 값이 크게 달라진다.

독립변수(x)들 간의 독립적이어야 하는 가정에 반하여 상관관계가 높은 것을 의미한다.

만약 독립변수(x)들 간에 상관 정도가 높으면 분석 시 부정적인 영향 ⑦ 표준오차가 커짐 ⑦ t 값이 작아진다.

⑦ 유의한 독립변수에 대하여도 회귀계수가 통계적으로 유의미하지 않은 것처럼 나올 수 있다.

⑦ 과적화(over-fitting) 문제가 발생하여 회귀 결과의 안정성을 해칠 가능성이 높아진다.

2) 독립변수들 사이의 높은 상관관계

-다중공선성의 있다면 상관관계는 높지만, 상관관계가 높다고 해서 반드시 다중공선성이 있다는 것은 아님.

⑦ 데이터 수가 충분하지 않은 경우 독립변수간에 상관관계가 높아도 다중공선성이 없는 경우도 존재

⑦ 다중공선성이 높다는 것은 예측 결과의 값의 신뢰구간이 넓게 형성될 수 있다고 해석

3) 결정계수 오해

결정계수(R^2)가 높아 회귀식의 설명력이 높지만, 각 독립변수의 p값이 커서 독립변수가 유의하지 않을 수 있음

~~: 이 경우 독립변수들 간에 높은 상관관계가 있을 수 있으므로 상관분석을 이용해서 확인 필요~~

⑦ 표준오차가 매우 크다는 것을 의미)

Multiple Regression Analysis : Issue

2. 다중 공선성(Multi collinearity)

다중공선성 (Multicollinearity) 존재 여부 확인

구분	내용
Scatter plot Matrix	- sns.pairplot을 통해 독립 변수간 1대 1 상관 관계를 눈으로 파악할 수 있다. - 독립변수간 상관관계 (다중공선성)을 대략 파악
상관계수 - 히트맵	피어슨 상관계수를 계산해 보며 대략적으로 선형관계 여부 판단 가능
VIF (Variance Inflation Factors)	- VIF는 다중회귀 모델에서 독립변수간 상관관계가 있는지 측정하는 척도 - VIF 가 크다는 의미는 독립변수가 다른 독립변수에 의해 선형함수로 표현 될 수 있다는 것 ⑦ 이는 다중공선성 문제 발생 - VIF를 계산하여 이 값이 보통 10 을 넘는 경우 다중공선성 문제가 있다고 판단 (이유 : R^2가 0.9인 경우이므로 해당 독립변수가 다른 독립변수에 의해 설명되므로, 하나의 독립적인 변수로 역할을 못함)
상태지수 (CI : Condition Index)	$(X'X)$의 대각행렬이 1이 되도록 상관변환 후 고유치(eigen value)를 구하고 가장 큰 고유치 값으로 나눈 후 제곱근을 구한 값 10 이상이면 독립변수들간 약한 상관관계가 존재 100 이상이면 다중 공선성 발생하는 것으로 해석
Tolerance 확인	하나의 독립변수를 종속변수로 하고 나머지를 독립변수로 회귀분석을 한 경우 R^2 가 나오면 $(1 - R^2)$ 가 tolerance를 말함. 이 값이 0 에 가까우면 다중공선성 발생

	X1	X2	X3
X1	1		
X2		1	
X3			1

$$VIF_i = \frac{1}{1 - R_i^2}$$

- R_i^2 (결정계수) : 다른 독립 변수로 i 번째 변수를 선형 회귀했을 때 얻어지는 성능 값
- ⑦ 다른 독립변수에 의존적 일 수록 VIF가 커진다

$$CI = \sqrt{\frac{\lambda_{max}}{\lambda_k}}$$

Multiple Regression Analysis : Issue

2. 다중 공선성(Multi collinearity)

다중공선성 해결 방법

구분	해결방법
통계적으로 유의한 독립변수 여부?	통계적으로 <u>유의하지 않으면</u> 독립변수(설명변수)를 제거 – 주의 요함. 통계적으로 <u>회귀계수가 유의하면</u> VIF가 크더라도 특별히 대처하지 않음. ; 표준오차가 팽창함에도 유의한 것은 회귀계수가 이 매우 커서 그대로 두어도 무방함.
독립변수가 다른 독립변수에 의존적인 경우	VIF 10 이상인 변수 중 하나를 drop - 독립변수 중에서 VIF가 높은 것 전부가 아니라 <u>하나 혹은 일부를 삭제하여 회귀분석을 다시 하면</u> 다중공선성 문제가 해결 ❶ 종속변수와 상관관계가 낮은 독립변수를 제거한다. - 제거후에 결정계수(R^2)가 유지되는 독립변수를 제거한다.
독립변수 변환	독립변수 데이터 정규화(scale) 한다.
주성분분석(PCA)으로 변수를 재조합	주성분분석(PCA) 방법을 이용하여 설명력이 높은 변수만을 선택 : 변수간 독립적
별점화를 통해 변수 제거, 감소	LASSO회귀분석, Ridge 회귀분석
평균 중심화(mean centering)	독립변수 값과 독립변수 평균 값 차이 ❶ (개별변수 x_i - 평균 $\bar{x}$)

* Simple L.R : Formulation

최소제곱법(Least Square Method , Ordinary Least Square)

❶ 오차를 최소화 시키는 회귀계수(β_0, β_1) 를 추정하는 방법

❷ (대응치) 잔차(Residual, e) : 데이터가 추정된 모델(회귀식에 의한 값)로부터 얼마나 떨어진 값

❸ 잔차(e) = $y - \hat{y}$, $e = y - (\beta_0 + \beta_1 x)$, 확률오차 (ε) 이 실제로 구현된 값, 오차가 알려져 있지 않기에 주로 잔차 활용

• 오차(ε) = $y - E(y)$ ❹ 오차(ε) = $y - (\beta_0 + \beta_1 x)$ 확률오차

$\sigma_{i=1}^n [Y_i - (\beta_0 + \beta_1 x)]^2$ 최소로 하는 회귀계수 β_0, β_1 를 찾는다. (실제 Y 값과 가장 가까운 값을 찾자!!)

❶ 여기서 $[Y_i - (\beta_0 + \beta_1 x)]^2$ 는 Cost function , 결국 비용함수를 최소로 하는 회귀계수를 찾는 것

결국 β_0, β_1 을 찾아야 함. (globally optimal solution 존재)

$$\frac{\partial C(\beta_0, \beta_1)}{\partial \beta_0} = -2 \sigma_{i=1}^n [Y_i - (\beta_0 + \beta_1 x)] = 0$$

$$\frac{\partial C(\beta_0, \beta_1)}{\partial \beta_1} = -2 \sigma_{i=1}^n [Y_i - (\beta_0 + \beta_1 x)] x = 0$$

두개의 정규방정식(Normal Equations)에서 미지수 2개 β_0, β_1 을 찾으려 한다.

2차 편미분 (Second Order Partial Derivative) 행렬을 사용하여 해를 구한다.

$$H = \begin{bmatrix} \frac{\partial^2 S}{\partial \beta_0^2} & \frac{\partial^2 S}{\partial \beta_0 \partial \beta_1} \\ \frac{\partial^2 S}{\partial \beta_1 \partial \beta_0} & \frac{\partial^2 S}{\partial \beta_1^2} \end{bmatrix}$$

Positive definite 행렬
만족해야 함. ❷

$$\frac{\partial^2 S}{\partial \beta_0^2} = 2n > 0$$

$$|H| = \begin{vmatrix} 2n & 2 \sum x_i \\ 2 \sum x_i & 2 \sum x_i^2 \end{vmatrix} = 4n \sum (x_i - \bar{x})^2 > 0$$

양정치 행렬 만족하므로, 정규방정식 오차제곱합을 최소로 하는 해가 된다. 방정식을 풀면 다음과 같다.

$$\beta_1 = \frac{\sigma(x_i - \bar{x})(y_i - \bar{y})}{\sigma(x_i - \bar{x})^2}$$

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

* Multiple L.R : Formulation

종속변수 Y , 설명변수 x (k 개 : $x_1, x_2, \dots, x_k$)

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + \varepsilon_i$$



$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + \varepsilon_i$$

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + \varepsilon_i$$

$\vdots$

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + \varepsilon_i$$

- 피처가 k 개인 훈련 데이터가 샘플이 n 개 경우
- x 데이터는 $(n \times k)$ 의 배열
- Y 데이터는 $(n \times 1)$ 의 배열

다중회귀분석 행렬로 표현

$$Y = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix} \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix} \quad X = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1k} \\ 1 & x_{21} & x_{22} & \dots & x_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nk} \end{pmatrix} \quad \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

$$\begin{matrix} y & \beta_0 & + & \beta_k & x_k & + & \varepsilon \\ (n \times 1) & (n \times 1) & & (k \times 1) & (n \times k) & & (n \times 1) \end{matrix}$$

회귀 모형 : 행렬 표현

$$Y = X\beta + \varepsilon$$

* Example 2

A 항공 주가 예측

$$\text{A항공 월수익률} = \beta_0 + \beta_1 WTI \text{ 수익률} + \beta_2 \text{환율수익률} + \beta_3 KOSPI \text{ 수익률} + \beta_4 \text{금리수익률} + \varepsilon$$

-OLS 방식 다중회귀분석 실행

회귀계수 추정 : 회귀계수 검토

* Example 2

Portfolio

$$\text{Portfolio 월수익률} = \beta_0 + \beta_1 \text{WTI 수익률} + \beta_2 \text{환율수익률} + \beta_3 \text{KOSPI수익률} + \beta_4 \text{금리수익률} + \varepsilon$$

-OLS 방식 다중회귀분석 실행

회귀계수 추정 : 회귀계수 검토

GitHub 참고

표본기업에 대한 평균수익률 (RET)

$$RET_i = \frac{1}{N} \sigma_{i=1}^N R_i$$

R_{it} : i기업 t월 주식수익률

N : 표본 기업수

- 독립변수 기초통계량
- 시장수익률 : EWI (동일가중수익률) , KCI

분석시 유의사항

통계적 유의성 검증

- 기간별 구분 연구
- 기업 규모별 집단 구분

* Example 3

A 항공 주가 예측

$$\text{A항공 월수익률} = \beta_0 + \beta_1 \text{WTI 수익률} + \beta_2 \text{환율수익률} + \beta_3 \text{KOSPI수익률} + \beta_4 \text{금리수익률} + \varepsilon$$

-OLS 방식 다중회귀분석 실행

회귀계수 추정 : 회귀계수 검토

LASSO 회귀분석 실시

람다 기준을 0.0001로 설정한 LASSO 회귀분석 결과: (만약 $\beta_4 = 0$) 아래 새로운 회귀식

$$\text{A항공 월수익률} = \beta_0 + \beta_1 \text{WTI 수익률} + \beta_2 \text{환율수익률} + \beta_3 \text{KOSPI수익률} + \varepsilon$$

```
import pandas as pd
from sklearn.datasets import _XXXX
from sklearn.linear_model import LinearRegression
from sklearn.linear_model import Ridge, Lasso, ElasticNet
```

<https://github.com/freejyb/kdigital>

예측분석 다중회귀분
석 주가예측

* Hierarchical Multiple Regression Analysis

- 위계적 회귀분석은 다중회귀분석의 한 종류
- ⑦ 프로그램에서 진행하는 것이 아닌 독립변수가 연구자가 경험에 의해 영향력이 큰 변수를 하나씩 직접 단계적(순차적)으로 투입해 가면서 가장 영향력이 큰 변수가 무엇인지 찾아내는 방법
- 독립변수의 투입순서는 연구자의 경험적, 이론적, 논리적 근거에 의해서 결정되어야 함
- 독립변수의 변화에 따른 종속변수의 변화를 검증하는 분석방법
- 주로 통계적인 통제를 하거나, 기존 모형의 확장을 위해 사용하는 기법
- 연구자가 가설을 가지고 접근하더라도, 실제로 유의미하지 않은 예측변수들이 포함되어 있을 수도 있기 때문에 이를 확인하는 기법

단계	독립변수(설명)	종속변수(반응)
1단계	$Y = \beta_0 + \beta_1 X_1$	Y
2단계	$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2$	
3단계	$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3$	

- ⑦ 단계별 모형별로 R^2 값을 계산 한 후
- ⑦ 단계별로 R^2 얼마나 변화하는 지를 확인한다.

단계별로 진행하다 보면 변수별 t -value 변화를 확인 가능 !!!

1. Simultaneous

: 동시적으로 모든 후보 설명변수 투입 ⑦ Multiple linear regression analysis

2. Stepwise : 독립변수를 하나씩 추가/제거 하여 종속변수를 잘 예측하는 변수들을 선택하는 기법

- 예측력이 (통계적으로) 유의미한 예측변수들만을 골라준다.

⑦ 단계적 회귀분석 (stepwise regression)

3. Hierarchical : 연구자가 나름 이론적 근거나 경험으로 설명변수를 단계별로 추가 투입

- 1단계 : X_1 ⑦ 2단계 : X_1, X_2 ⑦ 3단계 : X_1, X_2, X_3

* Hierarchical Multiple Regression Analysis

다중회귀분석과 위계적 회귀분석

공통점

독립변수와 종속변수 간 인과 관계를 분석하는 것


차이점

구분	다중회귀분석	위계적 회귀분석
목적 (변수 포함 방식)	독립변수가 종속변수에 미치는 영향력을 한번에 (동시에) 분석	독립변수를 추가적으로 (단계적으로) 변화를 통해중요도와 영향력을 파악
장점	다양한 변수의 영향력을 동시에 분석할 수 있으며, 변수들 간의 상호작용을 고려할 수 있다.	변수를 이론적 근거나 연구 가설에 따라 순차적으로 모델에 포함시키며, 각 단계별로 모델의 설명력 변화를 분석한다.
사용	경제학, 금융시장, 사회과학, 생물학 등 다양한 분야에서 복잡한 현상을 분석하고 예측하는 데 사용	다양한 분야의 가설 검증이나 특정 이론을 테스트하는데 주로 사용

Regularization / Generalization


Regularization 란?

: 회귀모델에서의 모델 변환 또는 변수 통제를 통해 **Overfitting**을 완화해 일반화 성능을 높여 주기 위한 기법




Underfitted

A.



Good Fit/Robust



Overfitted

B.

A. high bias

train data와 test data간의 차이가 커서 train data로만 학습한 모델은 test data를 예측하기 어렵다는 것을 의미

B. high variance

train data에 over-fitting ⑦ test data에서 오차가 심하게 발생한 것을 의미

Regularization / Generalization

Regularized Method, Penalized Method (벌점 회귀) , Regularized 로지스틱

선형회귀계수(weight)에 대한 제약조건을 추가함으로써 모형이 과도하게 최적화되는 현상인 과적합을 막는 방법

⑦ 제약조건을 줌으로써 Bias가 증가할 수 있지만, Variance 감소함.

- LASSO 회귀모형
- Ridge 회귀모형
- Elastic Net 회귀모형

shrinkage method

⑦ 계수 추정치를 줄여주는 정규화 방법


**alpha = lamda = penalty term
= regularization parameter**

Hyper parameter

정규화의 강도를 조절해주는 패널티 값

*L1 Norm , L2 Norm

- **Norm** : 벡터의 구성요소의 크기(magnitude)(길이) → 원점에서 좌표까지 거리
- Norm 활용
 - ⑦ 딥러닝에서 관측된 데이터의 확률을 최대화하거나, 예측과 실제 값의 차이를 최소화하는 최적화 문제
 - ⑦ 벡터로 표현해서 비슷한 것들은 거리를 최소화하고,
 - ⑦ 비슷하지 않은 것들은 거리를 최대화할 때 Norm의 개념 활용



왼쪽 그림에서 두 개의 검은 점(벡터)를 잇는 여러 선들이 존재
벡터 사이의 거리를 재는 서로 다른 Norm을 표기한 셈

- **맨해튼 거리(택시거리)**: 빨간색, 파란색, 노란색 선의 길이 = 모두 12
가장 짧은 맨해튼 거리 → **L1 Norm**
- **유클리드 거리** : 초록색 선 $6\sqrt{2} \approx 8.485$ 가장 길이가 짧다.
 - ⑦ 6제곱과 6제곱을 합하여 제곱근 한 값과 동일

- $p = 1$ 이면 L1 norm
- ⑦ **맨해튼 거리** 측정방법을 사용, 벡터 차에 대한 절대값을 취한 값들의 합이 결과 값
- ⑦ 빨간, 파란, 노란 선은 다른 경로를 움직이지만 사실 모두 동일한 L1 Norm
- $p = 2$ 이면 L2 norm
- ⑦ 초록색선이 Euclidean distance, L2 Norm

Manhattan 거리 : the minimal distance between two places(taxi driver)
LASSO 회귀분석에 벌점 사용
p 는 norm의 차수를 의미 : L1 은 1차로 절대값의 합으로 계산

목표까지의 최단거리 : used by helicopterpilots
L2는 2차 : 값의 제곱을 모두 합한 값의 제곱근
문서유사도 : 유클리드 유사도

*L1 Norm , L2 Norm

- **Norm** : Norm은 V라는 벡터 공간에서 실수 집합 R로 보내는 함수
- **르베그 공간(Lebesgue space)** : 절댓값의 p 제곱이 르베그 적분 가능한 가측 함수들의 동치류들로 구성된 노름 공간

 L_p Norm


$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}$$

$$L^p(\Omega) := \left\{ f : \int_{\Omega} |f(x)|^p dx < \infty \right\}$$

For $p = 1$, we get $\ell_1 = |x_1| + |x_2| + \dots + |x_n|$ For $p = 2$, $\ell_2 = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$ For $p = 3$, $\ell_3 = \sqrt[3]{|x_1|^3 + |x_2|^3 + \dots + |x_n|^3}$ For $p \rightarrow \infty$, $\ell_{\infty} = \max_i (|x_1|, |x_2|, \dots, |x_n|)$

p=2인 경우가 가장 일반적

$$\|A\| = \|A\|_2 = \|A\|_F = \sqrt{\sum_{i=1}^N \sum_{j=1}^M a_{ij}^2}$$



L_1 : 회귀계수가 움직일 수
있는 범위가 마름모꼴

*L1 Norm , L2 Norm Regularization

Regularization 주목적

모델의 오버피팅(Overfitting) 감소 → 모델 일반화(General) 성능 향상

L1 Regularization

- 람다 작아질 수록, 약한 정규화가 적용
- Sparse feature에 의존한 모델에 L1 Regularization을 사용하면, 불필요한 Feature에 대응하는 Weight를 정확히 0으로 만들어 Feature 제거한다.
- Feature selection의 효과를 가져온다.

"Sparse feature"

- 데이터에서 대부분의 값이 0이고 일부만 값이 있는 특성을 의미한다.
- 특히 머신러닝과 딥러닝에서 이러한 특성은 많은 정보가 0으로 채워져 있는 희소한 형태의 데이터로 나타난다.

L2 Regularization

불필요한 Feature에 대응하는 Weight를 0에 가깝게 만들지만, L1 Reg와는 달리 0으로 만들지는 않는다.

이런 특성 때문에, L1 Reg반해 L2 Reg는 선형모델의 일반화 능력을 개선시키는 것으로 알려 짐

LASSO Regression

LASSO (Least Absolute Shrinkage and Selection Operator)

Tibshirani's Original Paper (1996)

A critical review of LASSO and its derivatives for variable selection under dependence among covariates

- 독립변수들이 종속변수에 영향을 미치는 **다중공선성을 고려하여 최적의 변수를 도출하는 변수 선정 모델**
- 선형 회귀 : 적절한 가중치와 편향을 찾아내는 것이 주 목적
- **L1-norm 페널티**를 가진 선형 회귀 방법
- LASSO 회귀는 예측 변수 중 일부를 선택하고 나머지를 제거하는 특성으로 인해 **subset selection 효과**를 가져온다.
- 특정 설명변수 **회귀계수 절대값이 매우 낮은 (영향력이 적은) 경우 0으로 수렴하게** 하여 overfitting을 방지한다는 의미

Lasso 회귀계수 추정 →

L1- Norm

arguments of min

$$J = \underbrace{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}_{\text{Mean Squared Error}} + \lambda \underbrace{\sum_{j=1}^m |w_j|}_{\|w\|_1 \text{ penalty}}$$

$$= \underset{\beta}{\operatorname{argmin}} \sum_{i=1}^n (y_i - x_i \beta)^2$$

subject to $\sum_{j=1}^p |\beta_j| \leq t$

- LASSO : minimize SSE + lambda($\sum |\beta_j|$)
- 우측 식 m = **모델 피쳐의 수**

가중치의 절대값의 합을 특정 값 이하가 되도록 규제
 $|w_1| + |w_2| + \dots + |w_n| \leq t$

[**MSE와 penalty항의 합**] 이 **Min이 되게 하는 가중치(β)와 편향(b)을 찾는 것이 바로 라쏘의 목적**
 → 가중치의 모든 원소가 0이 되거나 0에 가깝게 되도록 해야 한다.

파이썬

LASSO alpha값에 변화에 따른 라쏘 회귀 성능 보기(참고)

LASSO Regression : Hyper parameter

정규화의 강도를 조절해주는 패널티 값
alpha = lamda = penalty term
= regularization parameter

$$J = \underbrace{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}_{\text{Mean Squared Error}} + \underbrace{\lambda \sum_{j=1}^m |w_j|}_{\|w\|_1 \text{ penalty}}$$

중요한 것은 **Alpha (α) 값** : **Hyper parameter** → → LASSO 식에서 **λ** 값

▪ 람다 $\lambda = 0$ 인 경우 (매우 작은 경우) → Overfitting, OLS 와 동일

▪ 람다 $\lambda = \infty$ 인 경우 (매우 큰 경우) → Underfitting

λ 값이 크면 모델의 매개변수 w_j 곱 $\lambda \|w\|_1$ 이 되도록 0을 향해 밀어야 하므로 최소화이 된다

즉, λ 값을 증가시키면 (α=1) 전체 페널티의 값도 줄여야 |가중치|의 합도 줄이도록 학습하게 된다

→ 계속해서 특정상수의 값을 빼나가는 것이므로 몇몇 가중치들은 0으로 수렴하고 이에 따라 feature의 수도 제거되어 감소하게 된다. → 결국, λ 값이 커지면 커질수록 회귀계수들은 점점 더 0으로 수렴한다.

λ 값 작아지는 경우

- 제약을 적게 주는 경우
- 변수제거가 많이 발생하지 않아 변수가 많이 남는다.
- 모델이 복잡해지고 모형 해석이 어렵다.
- 낮은 학습오차 (overfitting 발생)

λ 값 커지는 경우

- 제약을 많이 주는 경우
- 변수제거로 남는 변수가 작아진다.
- 모델이 단순해지고 모형 해석이 쉬어진다.
- 높은 학습오차 발생 가능성 (underfitting 발생)



Lasso 회귀분석 적용이
어려운 경우



- 변수 선택 성능이 저하된다.
- 예측 성능이 저하된다.
- 독립변수 간 상관관계를 고려할 필요가 있다.

```
# 파이썬 --> Lasso
from sklearn.linear_model import Lasso
# 규제 계수(alpha) : 선형회귀에 L1 규제 계수 적용
가중치(weight)의 절대 값의 합을 최소화 하는 계수 추가
```

* L_1 Penalty Term : Formulation

J : cost function

$$J = \text{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

 L_1 penalty term

$$J = \underbrace{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}_{\text{Mean Squared Error}} + \underbrace{\lambda \sum_{j=1}^m |w_j|}_{\|w\|_1 \text{ penalty}}$$

m = the number of model's parameters

 $\hat{y} = w \cdot x + b$ 인 1차 함수 경우

$$L_1 = (\hat{y} - y)^2 + \lambda |w|$$

$$= (w \cdot x + b - y)^2 + \lambda |w|$$

w에 대하여 미분

$$\frac{\partial L_1}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{\partial |w|}{\partial w}$$

$$\rightarrow 2x(w \cdot x + b - y) + \lambda \quad (w > 0)$$

$$\rightarrow 2x(w \cdot x + b - y) - \lambda \quad (w < 0)$$

위식에서 좌측값을 A로 치환하여

경사하강법에 대입하면

1) $w^* = w - \alpha \cdot (A + \lambda) \quad (w > 0)$

2) $w^* = w - \alpha \cdot (A - \lambda) \quad (w < 0)$


⇒

경사하강법

$$w^* = w - \alpha \cdot \frac{\partial L_1}{\partial w}$$

$$w > 0: \frac{dy}{dw} = 1$$

$$w < 0: \frac{dy}{dw} = -1$$

Graph of $y = |w|$ and its Derivative dy/dw 

1) $w^* = w + \alpha \cdot (A - \lambda) \quad (w > 0)$

가중치 $w > 0$ 경우 새로운 가중치 w^* 는 람다 λ 에 비례하여 작아지도록 한다.

2) $w^* = w - \alpha \cdot (A - \lambda) \quad (w < 0)$

가중치 $w < 0$ 경우 새로운 가중치 w^* 는 람다 λ 에 비례하여 커지도록 한다.

→ 양(+)가중치는 값을 줄이고,
음(-)의 가중치는 값을 키우면서
0의 값에 가까워져야 하는 경향을 띠게 된다.

<https://github.com/freejyb/deeplearning>
딥러닝(수학1)

LASSO Regression : Hyper parameter

	alpha = 0.0001	alpha = 0.001	alpha = 0.01	alpha = 0.1	alpha = 1	alpha = 10	alpha = 100
Unnamed: 0	-0.0032	-0.0032	-0.0033	-0.0032	-0.0005	0.0024	0.0000
CRIM	-0.1105	-0.1104	-0.1091	-0.1037	-0.0688	-0.0000	-0.0000
ZN	0.0433	0.0434	0.0440	0.0461	0.0447	0.0249	0.0000
INDUS	0.0478	0.0466	0.0350	0.0000	-0.0000	-0.0000	-0.0000
CHAS	2.7833	2.7665	2.5977	1.0799	0.0000	0.0000	0.0000
NOX	-13.3563	-13.0623	-10.1208	-0.0000	-0.0000	0.0000	-0.0000
RM	4.7660	4.7656	4.7613	4.5452	1.4742	0.0000	0.0000
AGE	-0.0159	-0.0161	-0.0181	-0.0214	0.0158	0.0029	-0.0000
DIS	-1.4559	-1.4513	-1.4058	-1.2234	-0.7733	-0.0000	0.0000
RAD	0.3226	0.3221	0.3171	0.3056	0.2838	0.0000	-0.0000
TAX	-0.0114	-0.0114	-0.0117	-0.0132	-0.0145	-0.0103	-0.0199
PTRATIO	-0.8886	-0.8857	-0.8567	-0.7719	-0.7727	-0.0000	-0.0000
B	0.0104	0.0104	0.0106	0.0110	0.0090	0.0076	0.0058
LSTAT	-0.5207	-0.5214	-0.5285	-0.5701	-0.7796	-0.5914	-0.0000
R^2 of Train	0.7573	0.7573	0.7569	0.7486	0.7022	0.5104	0.2054
R^2 of Test	0.6203	0.6199	0.6155	0.6015	0.6474	0.5959	0.2546
intercept	27.4290	27.2467	25.4238	20.6635	39.1548	30.5096	28.9067
mse_train	20.9521	20.9525	20.9876	21.7070	25.7093	42.2650	68.5991
mse_test	28.4877	28.4877	28.4877	28.4877	28.4877	28.4877	28.4877
n_iter	98.0000	71.0000	68.0000	32.0000	43.0000	14.0000	7.0000

https://github.com/freejyb/fin_stats

Ridge Regression

Ridge Regression

- 비용함수(MSE)에 **L2-Norm 규제항** 더한 것
- 모델의 설명력에 기여하지 못하는 독립변수의 회귀계수(가중치, β) 크기를 0에 근접하도록 축소시키는 분석방법
- 작아져도 0은 되지 않는다.

$$J = \underbrace{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}_{\text{Mean Squared Error}} + \underbrace{\lambda \sum_{j=1}^m |w_j|^2}_{\|w\|_2^2 \text{ penalty}}$$

$$= \underset{\beta}{\operatorname{argmin}} \sum_{i=1}^n (y_i - x_i \beta)^2$$

subject to $\sum_{j=1}^p \beta_j^2 \leq t$

가중치의 제곱의 합을 특정 값 이하가 되도록 규제
 $w_1^2 + w_2^2 + w_3^2 \dots + w_n^2 \leq t$

- 미분 값의 음수(-)를 취하면 각 항의 부호가 바뀌기 때문에 가중치가 양수일 땐 L2 패널티가 음수,
- 반대로 가중치가 음수일 땐 L2 패널티가 양수로 되어 **가중치를 0의 방향으로 잡아당기는 역할** 함.

→ **가중치의 절댓값을 가능한 작게 만들려는 작업을 하는 것**

이를 weight decay라고 하며 weight decay는 특정 가중치가 비이상적으로 커지고, 그것이 학습 효과에 큰 영향을 주는 것을 방지할 수 있다.

→ 중요한 것은 람다(λ) : 람다가 증가하면 기울기 감소 → 특성의 영향 감소

- $\lambda = 0$ 일 때, penalty 항 (the penalty term)은 효과가 없고, 이때, ridge regression은 최소제곱추정치를 생성한다.
- $\lambda \rightarrow \infty$ 일 경우, the shrinkage penalty의 영향이 커지고, 리지 회귀(ridge regression) 계수 추정치는 0에 가까워진다.

LASSO와 Ridge 회귀계수 축소법은 꼭 쓸모 없는 변수를 줄이는 것이 아니라, 단순하게 다중공선성을 해결하고자 하는 방법

LASSO의 경우 회귀계수가 완전히 "0"으로 수렴한 것을 확인할 수 있지만, Ridge의 경우 0에 가까워졌을 뿐 0은 아닌 것을 확인할 수 있다.
 LASSO는 완전하게 특정 계수의 영향력을 무시하고 Ridge는 전반적인 모델의 회귀계수의 영향력을 줄이는(정규화 작업) 것을 확인할 수 있다.

L_2 Penalty Term : Formulation

J : cost function

$$J = \text{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

L_2 penalty term

$$J = \underbrace{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}_{\text{Mean Squared Error}} + \underbrace{\lambda \sum_{j=1}^m |w_j|^2}_{\|w\|_2^2 \text{ penalty}}$$

$\hat{y} = w \cdot x + b$ 인 1차 함수 경우

$$L_1 = (\hat{y} - y)^2 + \lambda w^2$$

$$= (w \cdot x + b - y)^2 + \lambda w^2$$

w 에 대하여 미분

$$\frac{\partial L_1}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{\partial w^2}{\partial w}$$

$$\rightarrow 2x(w \cdot x + b - y) + 2\lambda w$$

위식에서 좌측값을 A 로 치환하여 경사하강법에 대입하면

$$\Leftrightarrow w^* = w - \alpha \cdot (A + 2\lambda w)$$

경사하강법

$$w^* = w - \alpha \cdot \frac{\partial L_1}{\partial w}$$

$$1) w^* = w + \alpha \cdot (A - 2\lambda w) \quad (w > 0)$$

가중치 $w > 0$ 경우 새로운 가중치 w^* 는 람다 λ 에 비례하여 작아지도록 한다.

$$2) w^* = w - \alpha \cdot (A - 2\lambda w) \quad (w < 0)$$

가중치 $w < 0$ 경우 새로운 가중치 w^* 는 람다 λ 에 비례하여 커지도록 한다.

$\rightarrow L_1$ 마찬가지로 양(+)가중치는 값을 줄이고, 음(-)의 가중치는 값을 키우면서 0의 값에 가까워져야 하는 경향을 띠게 된다.

$\rightarrow L_2$ 의 경우 차이점은 $2w$ 에서 가중치에 좀 더 영향을 받음으로써 기울기 0으로 만드는 L_1 규제 보다는 유연함.

ElasticNet Regression

ElasticNet

가중치의 절대값의 합(L1)과 제곱 합(L2) 규제를 동시에 제약 조건(패널티)으로 가지는 모형

→ LASSO 와 Ridge 혼합

$$J = \underbrace{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}_{\text{Mean Squared Error}} + \lambda \underbrace{\left[\alpha \sum_{j=1}^m |w_j| + (1 - \alpha) \sum_{j=1}^m |w_j|^2 \right]}_{\text{Combined } \|w\|_1 \text{ and } \|w\|_2^2}$$

$$\hat{\beta}^{enet} = \underset{\beta}{\operatorname{argmin}} \sum_{i=1}^n (y_i - x_i \beta)^2$$

subject to $s_1 \sum_{j=1}^p |\beta_j| + s_2 \sum_{j=1}^p \beta_j^2 \leq t$

#파이썬 : ElasticNet

```
from sklearn.linear_model import ElasticNet
```

#주요 hyperparameter

alpha: 규제 계수

l1_ratio (default=0.5)

l1_ratio = 0 (L2 규제만 사용).

l1_ratio = 1 (L1 규제만 사용).

0 < l1_ratio < 1 (L1 and L2 규제 혼합사용)

* Regularized Method

회귀 유형	정규화 유형	주요 효과	활용 사례
라쏘 회귀	L1 정규화	특징 선택 및 모델 단순화	고차원 데이터에서 중요 특징 선택, 유전자 데이터 분석
리지 회귀	L2 정규화	과적합 방지, 모든 변수 활용	다중공선성 문제 해결, 경제 예측, 날씨 데이터 예측
엘라스틱 넷	L1 + L2	특징 선택과 정규화 효과 결합	고차원 및 다중공선성 데이터에서 변수 선택 및 과적합 방지

벌점 회귀(Penalized Regression) 금융 시장 활용

- 금융 데이터는 일반적으로 **고차원 특성을 가지며, 변동성이 크고 상관관계가 높은 변수가 많기 때문에** 과적합을 방지하고 중요한 변수만 선택하는 것이 중요
- Lasso Regression와 Ridge Regression는 이러한 특성을 반영하여 금융 분야에서 데이터 분석과 예측 모델에 널리 활용

활용 분야	벌점 회귀 기법 활용 사례
주가 예측	리지 회귀를 통해 다양한 경제 지표와 기술적 지표를 반영하여 주가 예측
자산 선택 및 포트폴리오 최적화	라쏘 회귀로 중요한 자산만 선택하여 최적화된 포트폴리오 구성
리스크 관리	리지 회귀로 리스크 요인을 분석하여 포트폴리오의 리스크 관리
경제 지표 예측	엘라스틱넷 회귀를 통해 중요한 경제 지표를 선택하여 GDP 성장률 등 예측
신용 리스크 평가	라쏘 회귀를 통해 대출 상환 가능성 예측 시 중요 변수만 선택하여 신용 리스크 평가
사기 탐지	라쏘 회귀로 사기 거래에 중요한 변수만 선택하여 사기 탐지 모델의 성능 향상
옵션 및 파생상품 가격 모델링	리지 회귀를 통해 옵션 가격 모델의 변수를 모두 사용하면서 과적합 방지

1. Least Square Method : Alternatives

2. Regression Equation : Test

- Normality test
- Homogeneity of variance : Bartlett 's test , Levene's test
- independent observation : Durbin Watson(DW) test

3. Dummy variable

4. Endogeneity problem

5. Spurious regression : problem

6. Chow Test

1. Least Square Method : Alternatives

Robust Linear Regression

- Linear Regression에서 Least Squares는 잔차제곱합(Residual Sum of Squares)을 최소화하는 회귀계수를 찾는 것을 목적으로 한다.
- (문제점)
- 전통적 선형회귀방법은 데이터의 중심 경향을 잘 나타내지만, 이상치에 매우 민감하여 이상치가 포함된 데이터에서는 부정확한 추정을 초래 ❶, 이것이 모델을 왜곡할 가능성이 크다. ❷ RSS는 에러를 제곱하여 더하는 형태이기 때문

기본 원리

- 가중치 부여:** 데이터 포인트마다 가중치를 다르게 부여하여, 이상치의 영향을 줄인다. 이상치에 낮은 가중치를 부여함으로써, 이들이 회귀선에 미치는 영향을 감소시킨다.
- 손실 함수 변경:** 최소제곱법 대신, 이상치의 영향을 덜 받는 손실 함수를 사용한다. 예를 들어, Huber 손실 함수는 작은 오차에 대해서는 제곱을, 큰 오차에 대해서는 절대값을 사용하여 이상치의 영향을 줄입니다.

Robust 회귀분석의 종류

https://github.com/freejyb/fin_stats 참조

1) RANSAC (Random Sample Consensus)

: 데이터의 서브셋을 무작위로 선택하여 모델을 피팅하고, 이 모델에 잘 맞는 데이터 포인트들을 이용해 최종 모델을 구축하는 방식 ❶ 이상치에 매우 강건

2) Least Absolute Deviation (LAD)

: 오차의 절대값의 합을 최소화하는 방식으로, 이상치에 대한 저항성이 더 높다.

3) Huber 회귀

: 오차가 작을 때는 제곱 오차를, 큰 오차에 대해서는 선형 오차를 사용하는 방식 ❷ 이는 이상치에 대한 민감도를 줄이면서도, 데이터의 대부분에 대해서는 최소제곱 추정과 유사한 결과 제공

Robust 회귀분석의 적용

- 이상치가 존재하거나, 데이터가 비선형적인 경향을 보이는 경우에 유용
- 예를 들어, 금융 데이터 분석, 환경 데이터 분석, 생물학적 데이터 분석 등 다양한 분야에서 활용

1. Least Square Method : Alternatives

1. RANSAC이란?

"Fischler & Bolles 1981, **Random Sample Consensus**: A Paradigm for Model Fitting with Applications to Image Analysis and Automated Cartography" (**RANdom SAMple Consensus : RANSAC**)

- 무작위(랜덤)하게, 데이터 샘플을 뽑아서 모델을 추정하고, 모델에 대한 데이터의 합의도 (Consensus : 일치여부) 를 구해 정확한 모델임을 평가한다.
- 컴퓨터 비전 분야에서의 사용 방법을 제안
- 많은 양의 데이터로부터 outlier를 거르고 model fitting을 하는 방식으로 RANSAC이 많이 사용

https://scikit-learn.org/stable/auto_examples/linear_model/plot_ransac.html

RANSAC 작동 방식

뽑은 데이터로 모델 추정

parameter : T , threshold,

T 번 반복

- 전체 데이터로부터 무작위 (random)로 **minimal set의 데이터 추출**
 - 정한 sample에서 직선을 구하고,
 - 구한 직선과 data의 residual을 구하고,
 - threshold보다 residual이 작으면 inlier
 - ⑦ **가장 많은 inlier를 포함하고 있는 직선을 반환** : 가장 많은 inlier를 포함하고 있다는 것은 consensus가 가장 높다고 함
- RANSAC 알고리즘에서 Inlier와 Outlier는 데이터와 모델의 Residual이 미리 정한 **threshold**에 보다 작은가? 로 판단
residual이 threshold보다 작은 데이터를 inlier라고 가정

$$T = \frac{\log(1 - p)}{\log(1 - (1 - e)^s)}$$

- p: 분석자가 고른 데이터가 inlier인 확률
- ⑦ p = 0.99 (99%의 확률로 정확한 모델을 얻고 싶은 경우)
- e: 전체 데이터의 inlier:outlier 비율
- ⑦ e = 0.50 (전체 데이터 중 inlier:outlier 비율이 50:50)
- s: Minimal set을 만들기 위한 데이터의 갯수

1. Least Square Method : Alternatives

RANSAC의 장/단점

(장점)

- 성공 시 Outlier를 효과적으로 걸러낼 수 있음.
- 대략적인 성공 시간을 알 수 있음 (i.e. X번의 iteration 후 Y%의 확률로 정확한 모델 추론~)
- 이해하기 쉬움

(단점)

- **무작위 샘플링이라 매번 결과가 다름** (i.e. 동일한 input 데이터임에도, seed 값에 따라서 다른 결과가 나옴.)
 - ❗ 이 때문에 deterministic test를 할 때는 seed를 고정해야 함.
- Outlier의 비중이 많아지면 돌려야 하는 iteration 수가 급격하게 늘어남
- 실패할 경우 model 추론에 완전히 실패함
- Threshold 값을 분석자가 직접 튜닝해야 함
- Multi-model 추론을 할 수 없음.

Python

scikit-learn 라이브러리의 `linear_model.RANSACRegressor` 클래스를 사용하여 RANSAC 회귀를 구현

https://github.com/freejyb/fin_stats 참조

1. Least Square Method : Alternatives

2. M-Estimator란?

<http://users.stat.umn.edu/~sandy/courses/8053/handouts/robust.pdf> 2013.10.8 John Fox & Sanford Weisberg

- Least-squares는 모든 데이터 포인트가 unbiased한 노이즈를 가진다는 것을 전제로 삼는다. ❶ but, bias가 포함된 데이터 포인트가 계산에 포함되면 least-squares 과정이 무너지게 된다.
- ❷ 이러한 bias를 가진 데이터 포인트를 찾아내고 계산에서 제외하는 기술들을 robust estimation이라고 한다.
- 이 중, kernel 기법을 사용하여 데이터 포인트들의 residual 값에 weight를 걸어 optimization을 수행할 수 있게 해주는 기술이 M-estimator이다.
- M-estimator는 사전에 정해 둔 커널의 모양을 따라, residual 값에 따른 weight를 새로 지정한다**

The M-estimator is more efficient than Ordinary Least Squares (OLS) under certain conditions:

1. Your data contains y outliers,
2. The model matrix X is measured with no errors (Anderson, 2008).

M-estimators are especially useful when your data has outliers or is contaminated because one outlier (or heavy tailed errors) can render the normal-distribution based OLS useless; In that case, you have two options: remove the badly-behaving outliers, or use the robust M-estimator.

M-estimation *isn't* recommended when:

- Anomalous data reflects the true population, or
- The population is made up of distinct mixture of distributions (Little, 2013).

M estimation attempts to reduce the influence of outliers by replacing the squared residuals in OLS by another function of the residuals:

<https://ijpam.eu/contents/2014-91-3/7/7.pdf>

$$\sum_i r_i^2 \xrightarrow{\text{OLS}} \min \sum_i \rho(r_i), \quad \text{M-Estimation}$$

https://www.statsmodels.org/dev/examples/notebooks/generated/robust_models_1.html

2. Regression Equation : Test

1. Normality test

Normal Distribution — which one to use?

<https://machinelearningmastery.com/a-gentle-introduction-to-normality-tests-in-python/> <https://towardsdatascience.com/6-ways-to-test-for-a-normal-distribution-which-one-to-use-9dcf47d8fa93>

1. Histogram
2. Box Plot
3. QQ Plot
4. Kolmogorov Smirnov test
5. Lilliefors test
6. Shapiro Wilk test

For quick and visual identification of a normal distribution, use a QQ plot if you have only one variable to look at and a Box Plot if you have many. Use a histogram if you need to present your results to a non-statistical public. As a statistical test to confirm your hypothesis, use the **Shapiro Wilk test**. It is the most powerful test, which should be the decisive argument.

▪ the **Lilliefors test**

is a normality test based on the Kolmogorov–Smirnov test. It is used to test the null hypothesis that data come from a normally distributed population, when the null hypothesis does not specify *which* normal distribution; i.e., it does not specify the expected value and variance of the distribution

Monte Carlo 시뮬레이션은 Shapiro–Wilk, Kolmogorov–Smirnov 및 Lilliefors를 비교할 때 Shapiro –Wilk가 주어진 의미에 대해 최고의 검정력을 가지며 Anderson–Darling이 그 뒤를 따른다는 것을 발견

https://en.wikipedia.org/wiki/Shapiro%E2%80%93Wilk_test#cite_note-6

2. Regression Equation : Test

1. Normality test

(1) 분산도

- **Skewness(왜도)** : 어떤 확률변수의 분포가 평균을 중심으로 얼마나 비대칭인가를 나타내는 척도
 - ⑦ 정규분포 Skewness = 0 이다. 왜도 > 0 (평균값 < 중앙값) , . 왜도 < 0 (평균값 > 중앙값)
- **Kurtosis(첨도)** : 어떤 확률변수의 분포가 얼마나 뾰족한가를 나타내는 척도
 - ⑦ 정규분포 Kurtosis=3 이다. (또는 0)

→ EDA 할 때

```
from scipy.stats import skew, kurtosis
skew()
kurtosis(data, fisher=True)
```

(2) 히스토그램

표로 되어 있는 도수 분포를 정보 그림으로 나타낸 것

- *matplotlib.pyplot* : *plt.hist()* 함수에 *X*변수의 데이터와 *bin*의 개수를 입력
- *pandas.DataFrame.hist* 를 이용 : *hist()* 함수 사용
- *seaborn* 패키지의 *distplot()* 함수

```
import seaborn as sns
sns.distplot(train['ooooooooo'])
```


2. Regression Equation : Test

1. Normality test

(3) Q-Q plot (Quantile - Quantile plot)

Quantile 자료의 크기 순서에 따른 위치 값

- 수집된 data를 표준정규분포의 분위수와 비교하여 그린 그래프 (분위수 대조표)
- 용도 : 수집된 data가 정규성 가정이 만족되는지 시각적으로 확인하는 방법
- Q-Q도는 비교하고자 하는 분포의 분위수끼리 좌표 평면에 표시하여 그린 그림
- X축 : 이론적으로 data가 정규성을 따를 때 분위수 값**
- Y축 : 수집된 data의 분위수 값**



- ① 두 data의 이론적 정규분포와 data의 실제분포가 일치하는 선

데이터가 정규분포화하면 평균을 중심으로 좌우대칭
이를 표준정규분포화후의 z값과 매치시키고 선을 그어보면 45각의 선이 형성되는 것을 의미

- Q-Q plot : 대각선(①)을 따라서 표본 값들이 분포②하게 되면 정규성을 만족하는 것으로 판단

```
import scipy.stats as stats
stats.probplot(col, plot=plt)
```

2. Regression Equation : Test

1. Normality test

(3) Q-Q plot (Quantile - Quantile plot), 분위수 대조도

수학적 이해

정규분포함수(확률밀도함수)

$F(x) = \int_{-\infty}^x f(t)dt$, $F(x)$ = x이하인 데이터의 비율

$f(x)$: $F(x)$ 의 역함수 ⑦ 확률 분위수 함수

만약, 집단 A의 역누적분포함수 $A(x)$, 집단B 역누적분포함수 $B(x)$

두집단의 분포가 동일한 경우

$A(p) = mB(p) + n$: 한 집단의 선형변환을 통해 다른 집단을 만들 수 있다.

⑦ 결국 동일한 원리로 모든 분위수들은 서로 선형 관계를 가진다.

두 집단 data

두 집단 data의 분위수가 서로 선형관계를 일는지 확인?

RMSE 이용하여 회귀식을 그리고

두 집단 데이터의 분포가 여기에 오는지 확인

표준정규분포함수

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

누적표준정규분포함수

$$F(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$

2. Regression Equation : Test

1. Normality test

(4) Shapiro-Wilk test

The Shapiro-Wilk test: is a test of normality in frequentist statistics. It was published in 1965 by Samuel Sanford Shapiro and Martin Wilk

The Shapiro-Wilk test tests the null hypothesis that a sample $x_1, \dots, x_n$ came from a normally distributed population. The test statistic is

검정통계량
(test statistic)

$$W = \frac{(\sum_{i=1}^n a_i x_{(i)})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

⑦ 자료의 값들과 표준정규점수와의
선형상관관계를 측정하여 검정하는 방법

https://en.wikipedia.org/wiki/Shapiro%E2%80%93Wilk_test

표준정규분포에서 샘플링된 독립적이고 동일하게 분포된 확률 변수의 순서 통계의 기대값으로 구성

$W = 0 \sim 1$

해석: 1가까우면 정규분포, 0에 가까우면 정규분포를 이루지 않는다.

- 귀무가설 (H_0): 표본의 모집단이 정규분포를 따른다.
- 대립가설 (H_1): 표본의 모집단이 정규분포를 따르지 않는다.

유의수준 = 0.05

- p-value > 0.05 : 귀무가설을 기각하지 못했다는 것은 정규분포를 따르지 않는다고 말할 근거가 부족한 것일 뿐 100% 정규성이 만족된다는 뜻은 아니다. (참고용 정도로 활용)
- p-value < 0.05 : 귀무가설을 기각, 대립가설 채택 → data분포가 정규분포를 따르지 않는다는 것을 의미

(참고) 표본data의 정규성 검정 방법

- Shapiro-Wilk test** : 표본 개수 2,000 개 이하인 경우 사용
- Kolmogorov-Smirnov test** : 표본 개수 2,000 개 이상인 경우 사용

2. Regression Equation : Test

1. Normality test

(4) Shapiro–Wilk test

```
from scipy.stats import shapiro , normaltest , anderson , kstest
normal = []
notnormal = []
for var in num_var :
    stat, p = shapiro(train[var].dropna().values)
    at, p = normaltest(train[var].dropna().values)
    alpha = 0.05
    if p > alpha : normal.append(var)
    else : notnormal.append(var)
```

만약

P-value > 0.05이면 데이터가 정규분포를 따른다는 귀무가설을 기각할 수 없다

H_0 기각시 분석자의 결정 !!!!

: "정규성을 만족하지 못하였음"에도 불구하고 모수적 통계기법을 적용할 수 밖에 없는 이유를 제시하거나

⑦ 다른 정규성 검정을 검토해 보자.!!

⑦ 데이터 스케일링

⑦ 비모수 통계 분석

2. Regression Equation : Test

1. Normality test

(5) K-S 통계량 (Kolmogorov-Smirnov Statistics)


데이터의 누적 분포함수와 비교하고자 하는 분포의 누적분포함수 간의 최대 거리를 통계량으로 사용하는 가설검정방법

⑦ 비교하고자 하는 두 분포의 empirical distribution function의 차이를 특정 기준(두 집단의 샘플 수로 계산)과 비교하여 기각의 여부를 결정하는 것

. 서로 다른 2개 집단이 동일한 분포를 이루고 있는지 여부를 검증하는 지표

두 집단에 대한 각각의 구성비를 누적해서 산출한 후

그 누적 구성비의 차이가 가장 많이 벌어지는 지점이 수치로 계산



- 귀무가설(H_0); 표본의 모집단이 정규분포를 이루고 있다.
- 대립가설(H_1); 표본의 모집단이 정규분포를 이루고 있지 않다.


- $p\text{-value} > 0.05$ (유의수준) 귀무가설 기각할 수 없다
- $p\text{-value} < 0.05$ (유의수준) 귀무가설 기각
→ 대립가설을 채택하게 되어 정규분포를 따른다고 할 수 없다.

(활용) 신용평가모형 : 신용등급이나, 신용점수에 기반한 상환 가능성 신용평가모형에서 K-S통계량은 미래에 부실고객일 확률이 증가함에 따른 실제 미래에 돈을 잘 상환하는 고객(정상집단)과 실제로 상환 못하는 (부실집단)의 누적 구성비를 각각 산출한 후 누적구성비의 차이가 가장 큰 값으로 계산

K-S 통계량 = $\text{Max} [\text{누적 정상집단 구성비} - \text{누적 부실집단 구성비}]$

⑦ 신용평가모형의 변별력 평가 시 주요 판별 통계량으로 활용

K-S 통계량이 통상 20 이상인 경우 신용평가모형의 변별력이 확보되는 것으로 판단



2. Regression Equation : Test

1. Normality test

(6) Jacque-Bera (JB) Normality test

Jarque, Carlos M.; Bera, Anil K. (1980). "Efficient tests for normality, homoscedasticity and serial independence of regression residuals". *Economics Letters*. 6 (3): 255–259

- 표본 데이터의 왜도와 첨도가 정규분포와 일치하는지 여부를 확인하는 적합도 검정
- Carlos Jarque와 Anil K. Bera의 이름을 따서 명명
- 0에서 멀리 떨어져 있으면 데이터에 정규 분포가 없다는 신호이다.

- $H_0: X \sim N(X, X^2)$
- $H_1: H_0$ is not true

X가 정규분포라면 그 경험적 비대칭도와 경험적 첨도는 각각 0과 3에 가까운 값일 것이므로

JB의 값은 0에 가까운 값이 됨.

- JB가 0보다 충분히 큰 경우, 즉 오른쪽 꼬리의 값이 나올 때 귀무가설을 기각한다.

검정통계량


$$JB = \frac{n}{6} \left(S^2 + \frac{1}{4}(K - 3)^2 \right)$$

$$S = \frac{\hat{\mu}_3}{\hat{\sigma}^3} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{\left(\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right)^{3/2}},$$

$$K = \frac{\hat{\mu}_4}{\hat{\sigma}^4} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{\left(\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right)^2},$$

- n : the number of observations (or degrees of freedom in general)
- S : the sample skewness
- K : the sample kurtosis

기각역



기각할 수 없을 때, X 의 분포가 정규분포라고 볼 수 있음

$$\gamma_1 = E \left[\left(\frac{X - \mu}{\sigma} \right)^3 \right] = \frac{\mu_3}{\sigma^3} = \frac{\mu_3}{\mu_2^{3/2}}$$

$$\text{Kurt}[X] = \frac{E[(X - E[X])^4]}{E[(X - E[X])^2]^2}$$

2. Regression Equation : Test

1. Normality test

(7) Anderson-Darling 검정

- 데이터가 특정 분포를 따르는지 검정하는 적합도 검정
- Anderson-Darling 통계량은 데이터가 특정 분포를 얼마나 잘 따르는지 측정한다.
- 지정된 데이터 집합 및 분포의 경우, 분포가 데이터에 더 적합할수록 이 통계량의 값은 더 작아진다.
- Anderson-Darling 통계량을 사용하여 데이터가 t-검정의 정규성 가정을 충족하는지 확인할 수 있다.

- H_0 : 데이터가 특정 분포를 따른다.
- H_1 : 데이터가 특정 분포를 따르지 않는다.

p-value < 0.05 (유의수준=0.05 인 경우) 귀무가설 기각

Anderson-Darling 통계량을 사용하면 여러 분포를 비교하여 적합도가 가장 높은 분포를 찾아낼 수 있다.

- 가장 적합하다는 결론을 내리려면 해당 분포의 Anderson-Darling 통계량이 다른 분포의 통계량보다 상당히 작아야 한다.
- 통계량이 서로 가까운 경우에는 확률도 등 추가 기준을 사용하여 여러 분포 중에서 선택해야 한다.



- Cramér-von-Mises 검정
- Epps-Singleton 검정
- Mann-Whitney U 검정

2. Regression Equation : Test

2. 등분산성

분산이 집단별로 동일하다는 가정 (*Homogeneity of variance*)

일반화된 최소제곱 추정(Generalized Least Square)은 변수들을 표준적 가정에 부합되게 변환하고, 변환된 변수들에 대해 최소제곱 추정을 적용하여 모수들에 대한 유효한 추정을 얻음



최소제곱추정량 문제점

최소제곱추정은 BLUE

- 최소제곱 추정은 유효 추정이 아님, 즉 BLUE가 아님
- 통상적인 공식은 최소제곱 추정량에 대한 잘못된 표준 오차를 제공함
- 이러한 잘못된 표준오차에 근거한 신뢰구간이나 가설검정은 모두 잘못된 것

t-test, ANOVA

- ❶ 등분산 가정이 성립하지 않은 경우 비교의 기준이 되는 표본편차를 다시 고려해야 하는 문제점 발생

Levene's test

- ❶ p-value < 0.05보다 작은 경우 (귀무가설 : 등분산이다) ❶ 귀무가설 기각시, 등분산 가정이 무너진다.

2. Regression Equation : Test

2. 등분산성

(1) 데이터가 정규성을 충족하는 경우

Bartlett 's Test

from scipy.stats import bartlett

- 집단간 등분산 여부를 알아볼 때 사용
- 독립 2표본 t-검정 또는 일원분산분석(one-way ANOVA) 실시 전에 가정 때문에 확인하는 용도로 사용
- 두 집단 뿐만 아니라 세 집단 이상에서도 사용할 수 있으며 표본이 정규성을 보일때만 사용 가능

검정 통계량

$$T = \frac{(N - k) \ln s_p^2 - \sum_{i=1}^k (N_i - 1) \ln s_i^2}{1 + (1/(3(k - 1)))((\sum_{i=1}^k 1/(N_i - 1)) - 1/(N - k))}$$

$$s_p^2 = \sum_{i=1}^k \frac{(N_i - 1)}{(N - k)} s_i^2$$

N : 표본 크기, N_i : i 번째 집단의 표본 크기, k : 집단의 수

s_p^2 : pooled variance

s_i^2 : i 번째 집단의 variance

s_p^2 : pooled variance

- 귀무가설 (H_0): k 개의 집단에 대한 분산이 동일하다. P-value > 0.05
- 대립가설 (H_1): k 개 표본 중 하나라도 다른 분산이 존재한다

만약 표본이 정규성에 근접하는 분포를 띄고 있다면 Levene Test보다는 Bartlett Test 로

2. Regression Equation : Test

2. 등분산성

(2) 데이터가 정규성을 충족하지 않는 경우

Levene's test

- 임의의 다른 표본(k)에 대하여 분산의 동일(등분산성) 여부를 검정 방법
- ⑦ 상관분석, 회귀분석, 분산분석(ANOVA) 가정
- 정규성을 충족하지 않는 비모수 데이터에 대해 유용하게 사용
- 2개 이상의 집단에서 활용 가능.

- H_0 : k개의 집단에 대한 분산이 동일하다
- H_1 : k개 표본 중 하나라도 다른 분산이 존재한다

등분산 검정의 결과

- p-value > 0.05 경우 : 귀무가설을 지지하여 '분산에 차이가 없다.'고 말할 수 있다.
- p-value < 0.05 경우 : 대립가설을 지지하여 '분산에 차이가 있다.'고 말할 수 있다.

```
from scipy.stats import levene
```

데이터의 중앙을 median, mean, trimmed로 설정할 수 있음

⑦ 비모수데이터에서는 median이 더 강건한 것으로 알려짐

Fligner - Test

- 정규성을 충족하지 않는 비모수 데이터에 대해 유용하게 사용
- 2개 이상의 집단에서 활용 가능
- 비모수 데이터에 더 강건하게 검정할 수 있는 방법

```
from scipy.stats import fligner
```

2. Regression Equation : Test

2. 등분산성

Levene 테스트 vs Bartlett 테스트 비교

공통점	항목	설명
	목적	집단 간 등분산성(homoscedasticity) 검정
	귀무가설 (H_0)	모든 집단의 분산이 같다
	대립가설 (H_1)	적어도 하나의 집단의 분산이 다르다

항목	Levene 테스트	Bartlett 테스트
민감도	정규성에 덜 민감	정규성에 민감
사용 조건	데이터가 정규분포를 따르지 않을 때 사용 가능	데이터가 정규분포를 따라야 신뢰성 있음
중심값 기준	기본적으로 평균 기준 (옵션으로 중앙값 가능: Brown-Forsythe 변형)	분산 자체를 기반으로 계산
견고성	이상치(outlier)에 더 강함	이상치에 민감함
추천 상황	대부분의 실제 데이터 분석에서 널리 사용됨	정규성이 강하게 만족된 경우에만 적합
구현 함수 (Python)	<code>scipy.stats.levene()</code>	<code>scipy.stats.bartlett()</code>

- 데이터가 정규분포를 따름 → Bartlett 사용 가능
- 데이터가 정규분포를 따르지 않거나, 정규성에 의심 있는 경우 → Levene 사용 권장
- 이상치 존재 가능 → Levene 추천

2. Regression Equation : Test

2. 등분산성

이분산성(Heteroskedasticity) 확인

1. 산포도와 잔차도등 시각화 그래프로 확인

오차항의 분산의 이분산성에 있어서 의심되는 설명변수 잔차를 그려 봄

2. Breusch-Pagan test

- 선형회귀 모델에서 이분산성을 테스트하는 데 사용
- 오차항의 분산이 의존할 것으로 의심되는 설명변수들이 특정될 때, 이들의 분산에 대한 체계적이고 유의한 영향을 확인

Python : statsmodels.stats.diagnostic het_breuschpagan

3. White's heteroscedasticity test

- 회귀 모델의 오차 분산이 일정 한지 여부를 설정 하는 통계 검정
- 전체적인 설명변수들의 오차항의 분산에 대한 체계적이고 유의한 영향을 확인함 (설명변수들을 특정할 필요 없음)

Python : statsmodels.stats.diagnostic.het_white

4. 골드펠드-퀀트 검정(The Goldfeld-Quandt test)

- 비례적 이분산성 혹은 분할된 이분산성의 경우 모두 이분산성을 확인 이용
- 두 그룹의 관측치들 간에 그 신뢰성에 체계적이고 유의한 차이를 확임

2. Regression Equation : Test

2. 등분산성

등분산 성립하는 경우(P-value > 0.05)

t-test

$$\frac{\tilde{X} - \tilde{Y}}{\sqrt{s_p^2(\frac{1}{n_1} + \frac{1}{n_2})}} \sim t(n_1 + n_2 - 2)$$

(등분산성이 무너진 경우)

(1) Welch's t-test

Welch, B. L. (1947). "The generalization of "Student's" problem when several different population variances are involved".

이분산 t-검정(Welch's t-test)

- 두 모집단의 평균이 같다는 가설을 검정하는데 사용되는 검정
- Bernard Lewis Welch의 이름을 따서 명명
- **두 표본의 분산 및 또는 표본 크기가 같지 않을 때 더 신뢰한다.**

$$\frac{\tilde{X} - \tilde{Y}}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} \sim t(v) \quad v = \frac{(s_1^2/n_1 + s_2^2/n_2)^2}{\frac{(s_1^2/n_1)^2}{n_1-1} + \frac{(s_2^2/n_2)^2}{n_2-1}}$$

(2) Mann-Whitney U test

- 비모수 독립 표본 중앙값 검정
- 정규성을 따르지 않는 경우 Wilcoxon rank sum test (윌콕슨 순위 합 검정) Mann과 Whitney가 개정을 하였고 그 때 U 통계량을 사용

(3) 데이터 변환

1) 정규화(normalization)

- (각 변수들의 값 - 최소값) / (최대값 - 최소값)
- 변수 값들의 범위를 0과 1 사이로 축소하여 데이터 분포를 일정한 범위로 조정하는 작업

2) 표준화(standardization)

- $Z = (\text{각 변수들의 값} - \text{평균}) / (\text{표준편차})$
- 값의 스케일이 다른 변수들로 이루어진 학습데이터에서 이 스케일 차이를 없애 주는 효과

3) 데이터 변환(transformation) : 데이터에 자연log 를 붙이는 방법

2. Regression Equation : Test

3. 독립성 (independent observation) Durbin Watson(DW) test

: James Durbin and Geoffrey Watson. (1951) 유래

1. 검정 시기 : 시계열을 이용한 회귀 모형

- 회귀 모형의 오차항에 **자기상관 여부 검정하기 위해 사용**
- **오차항이 독립성 만족하는지 확인해야 하는 이유**는 회귀분석 주요 가정이기 때문
- 오차항간 상관성이 있으면 최소제곱법이 계수의 표준오차를 과소 추정할 수 있다.
- 표준오차가 과소 추정되면 **예측 변수가 유의하지 않는데 유의한 것으로 보일 수 있다.**
- 양(+)**의 자기상관을 갖는 주식: 전날 주가가 하락했다면 오늘 하락할 가능성이 있음을 의미하고,
- 자기상관계수 값이 양 (0~1) 인 경우 DW 값은 0 ~ 2 사이 값을 가짐**
- 음(-)**의 자기상관을 갖는 주식: 전날 하락했다면 오늘 상승할 가능성이 더 크다는 것을 의미한다.
- 자기상관계수 값이 음 (-1~0) 인 경우 DW 값은 2 ~ 4 사이 값을 가짐**
- Durbin Watson 테스트는 특정 유형의 직렬 상관, 즉 1차 상관을 찾는다.

DW 검정 통계량

$$DW = \frac{\sum_{t=2}^T (e_t - e_{t-1})^2}{\sum_{t=1}^T e_t^2}$$

e_t : OLS 회귀의 잔차
 e_{t-1} : 잔차의 1차 차분

2. Durbin Watson 테스트 가설

- 귀무가설 (H_0) : 1차 자기상관이 존재하지 않는다.
- 대립가설 (H_1) : 1차 상관관계가 존재한다.

$$DW = \frac{\sum_{t=2}^T (e_t)^2 + \sum_{t=2}^T (e_{t-1})^2 - 2 \sum_{t=2}^T e_t e_{t-1}}{\sum_{t=1}^T e_t^2}$$

3. 판단

- DW 통계량 : 0 ~ 4사이의 값을 갖을 수 있음
- 0에 가까울수록 $\Rightarrow$ 양(+)**의 상관관계**
- 4에 가까울수록 $\Rightarrow$ 음(-)**의 상관관계**

만약 1-시차 전 오차항의 제곱합과 오차항의 제곱합이 근사적으로 같다고 가정 $\frac{\sum_{t=2}^T e_{t-1}^2}{\sum_{t=1}^T e_t^2} \cong 1$
 $\cong 2 - 2 \frac{\rho_{000}}{1} = 2 (1 - \frac{\rho_{000}}{1})$

- 2에 가까울수록 $\rightarrow$ 오차항의 자기상관이 없음(독립성 가정 만족) $\rho_{000} \cong 0$

최소제곱추정량은 오차항이 비정규분포를 갖는 경우에도 BLUE(Best Linear Unbiased Estimator)가 된다.

그러나 오차항이 비정규분포인 경우 회귀모수에 대한 유의성 검정이나 신뢰구간 추정이 유효하지 못하다.

2. Regression Equation : Test

i.i.d (independent identically distributed)

i.i.d : 변수들 간 서로 독립적, 동일한 확률분포

- 각각의 random variable들이 독립 + 동일한 확률분포를 가지는 분포
 - (사례) 주사위 던지기
- 던지기를 N번 했을 때 각각 던졌을 때의 random variable은 서로 독립적이
 며, 주사위 숫자도 1/2/3/4/5/6이 나올 확률이 각각 1/6으로 동일 ⑦ **각 variable들은 독립적, 동일 분포를 따른다고 할 수 있다.**

- 확률밀도함수(probability density function) : 데이터가 연속적인 값을 가질 경우 사용
- 확률질량함수(probability mass function) : 데이터가 불연속적인 값(이산값)을 가질 경우 사용

확률밀도함수가 $p_X(x)$ 인 모집단에서 추출한 N개의 샘플
 각 샘플이 독립적이고 공평하게 추출됐다면 각 샘플이 추출될 확률 동일 →
 디랙 델타(Dirac delta) 함수 $\delta(x)$ 를 이용하면 확률밀도함수 $p_X(x)$ 를 근사화 ⑦

랜덤변수 X가 극소 구간 $(x, x+\Delta x]$ 에 속할 확률 $P\{x < X \leq x+\Delta x\}$ 을 아래와 같이 계산

$$\begin{aligned} \int_x^{x+\Delta x} p_X(x) dx &\approx \frac{1}{N} \int_x^{x+\Delta x} \sum_{i=1}^N \delta(x - x^{(i)}) dx \\ &= \frac{(\text{구간}(x, x + \Delta x] \text{에 속해있는 샘플의 개수})}{N} \end{aligned}$$

$$\omega_i = P\{X = x^{(i)}\} = \frac{1}{N}$$

$$\begin{aligned} p_X(x) &\approx \sum_{i=1}^N \omega_i \delta(x - x^{(i)}) \\ &= \frac{1}{N} \sum_{i=1}^N \delta(x - x^{(i)}) \end{aligned}$$

2. Regression Equation : Test

i.i.d (independent identically distributed)


- 임의의 구간(bin)에 속해 있는 샘플의 개수를 그림으로 표시한 것이 히스토그램(histogram)
- 식에 의하면 히스토그램은 확률밀도함수의 근사식과 모양이 같다.
- 확률밀도함수가 히스토그램과 다른 점은 확률밀도함수의 면적이 1 이어야 한다는 것이다.
- 히스토그램의 면적을 1로 정규화한다면 추출한 샘플의 히스토그램을 이용해 확률밀도함수의 모양을 근사적으로 얻을 수 있다.
- 추출된 샘플의 개수 n 이 클수록 좀 더 실제 값에 근접한 확률밀도함수를 얻을 수 있을 것이다.

확률밀도함수 $p_X(x)$ 가 평균 0, 표준편차 1인 가우시안으로 주어졌을 때

$$p_X(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right)$$

100,000개의 샘플을 추출해 $p_X(x)$ 의 그림을 히스토그램을 이용해서 근사적으로 그린 것

시사점???



2. Regression Equation : Test

회귀분석에서 기본 가정이 충족되지 않는 경우, 분석 결과의 신뢰성과 유효성이 저하

구분	문제점	해결
정규성 위반	- 종속변수의 오차항이 정규분포를 따른다고 가정 ❶ 이 가정이 위반되면, 통계적 검정의 유효성이 문제가 될 수 있다.	- 데이터의 log변환 같은 변환 기법을 사용하여 정규성을 개선 - 스케일링
독립성 위반	- 오차항들이 서로 독립적이라고 가정 - 시계열 데이터에서는 이 가정이 종종 위반되며, 자기상관 (autocorrelation)이 존재	ARIMA 등 을 사용하여 자기상관 문제를 해결
등분산성 위반	- 모든 독립변수의 값에 대해 종속 변수의 분산이 일정하다고 가정 ❶ 이 가정이 위반되면, 이분산성(heteroscedasticity)이 발생	가중 최소제곱법(Weighted Least Squares, WLS)을 사용하여 이분산성 문제를 해결
선형성	- 독립변수와 종속변수 간의 관계가 선형이라고 가정 ❶ 이 가정이 위반되면, 모델이 데이터의 관계를 제대로 반영하지 못할 수 있다.	

3. Dummy variable

더미변수 ?

- 범주형 데이터의 독립변수를 연속형 변수처럼 표현하기 위해 사용되는 변수
- 더미변수는 값이 0 과 1로만 이루어진 변수

더미변수 생성 시 고려사항

• 더미변수 함정 (dummy variable trap)

: 하나의 범주형 변수에 대해 k개의 범주가 있다면, k-1개의 더미변수만 생성

→ 모든 범주에 대해 더미변수를 생성하면 다중공선성 문제가 발생할 수 있다. 이를 '더미변수 함정'이라고 한다.

• 기준범주 (Reference group)의 선택

: 더미변수를 생성할 때 하나의 범주를 기준범주로 설정하고, 나머지 범주에 대해서만 더미변수를 생성한다.

→ 기준범주는 분석의 기준으로 사용된다.

더미변수의 주요 사용 사례

1. 회귀분석에서의 사용

: 더미변수는 범주형 독립변수가 종속변수에 미치는 영향을 분석할 때 사용

예를 들어, 성별(남성/여성)차이, 지역(도시/농촌)차이, 제품 유형(가전제품/가구)차이, 업종차이(건설업/그외업종) 등의 범주형 변수를 회귀모델에 포함시킬 수 있다.

2. 분산분석(ANOVA)에서의 사용

: 더미변수는 여러 그룹 간의 평균 차이를 분석할 때 사용

이 경우, 각 그룹을 대표하는 더미변수가 생성되어 분석에 사용

3. 기계학습 모델에서의 사용

: 범주형 변수를 모델에 포함시키기 위해 더미변수를 사용

: 특히 의사결정트리, 랜덤 포레스트, 로지스틱 회귀 등의 알고리즘에서 중요

3. Dummy variable

기준범주(Reference group)

- **기준범주 (참조범주)** : 범주 중에서 하나를 기준이 되는 범주로 설정 → 0
- **더미변수** : 기준범주외에 나머지 범주를 더미변수로 설정 → 1

예시

예시1) "남성"과 "여성" 두 범주가 있다고 가정
 "여성"(0)을 기준범주로 선택하면, **"남성"(1)에 대한 더미변수만 생성**
 → 더미변수는 "남성"이 "여성"(참조변수)에 비해 어떤 차이를 보이는지를 나타내게 된다.
 → 기준범주는 명시적으로 모델에 포함되지 않지만, 모든 다른 범주(여기서는 "남성")의 결과는 기준범주("여성")에 대한 상대적인 효과로 해석된다.
 예시2) 건설업과 그외 업종 비교
 → 건설업(1) 더미변수 , 그외업종 기준범주(0)

기준범주 역할

기준점 설정: 기준범주는 분석에서 비교의 기준점으로 사용

(예시) 성별을 나타내는 더미변수에서 여성을 기준범주로 설정하면, **남성은 여성에 대한 상대적인 효과를 나타내게 된다.**

더미변수 해석

- 더미변수인 해당 범주(1)와 기준범주(0)간에 유의한 차이가 있는지? 없는지?로 해석 한다.
- 기준범주와의 비교가 아니라 더미변수간에 비교는 불가

3. Dummy variable

범주형 변수 2개

범주형 변수 : 남성, 여성 , 건설업과 그외 업종

더미변수 1개 필요 : 남성(1), 건설업(1) → 참조변수(기준변수) 여성(0), 그외 업종(0)

$$Y = \beta_0 + \beta_1 D_1$$

β_0 : 코드값 0인 범주 (여성 or 건설업외 업종)의 Y에 대한 영향

β_1 : 코드값 1인 범주 (남성 or 건설업)의 Y에 대한 영향 → $\beta_0 + \beta_1$

범주형 변수 3개

- 범주형 변수 : 현금결제, 카드결제, 00페이 → 결제수단 차이에 따른 소비액(y)
- 더미변수 2개 필요: 00페이를 기준범주(0)로 하고 나머지를 더미변수(2개)로 변환

$$Y = \beta_0 + \beta_1 D_1 + \beta_2 D_2$$

- β_1 : 현금결제(더미변수 1)와 00페이 (0, 기준범주)에 비해 소비액의 평균차이로 해석
- β_2 : 카드결제(더미변수1)와 00페이 (0, 기준범주)에 비해 소비액의 평균차이로 해석

범주형 변수 4개

$$Y = \beta_0 + \beta_1 D_1 + \beta_2 D_2 + \beta_3 D_3$$

- 범주형 변수 : 봄, 여름, 가을, 겨울 → 계절차이에 따른 매출액(y)
- 더미변수 3개 필요: 봄을 기준범주로 한 더미변수로 변환

범주형변수	D_1	D_2	D_3
봄	0	0	0
여름	1	0	0
가을	0	1	0
겨울	0	0	1

- 봄 일때 : β_0 , 여름 일때 : $\beta_0 + \beta_1$
- 가을 일때 : $\beta_0 + \beta_2$, 겨울 일때 : $\beta_0 + \beta_3$

- β_1 : 여름(더미변수 1)과 봄(0, 기준범주)간의 매출액의 평균차이로 해석
- β_2 : 가을(더미변수1)과 봄(0, 기준범주)간의 매출액의 평균차이로 해석
- β_3 : 겨울(더미변수1)과 봄(0, 기준범주)간의 매출액의 평균차이로 해석

https://github.com/freejyb/fin_stats 다중회귀(더미변수)

3. Dummy variable

1. 부동산 가격 예측

사례 : 주택 가격 결정 요인 분석

- **목적** : 주택의 판매 가격을 예측하는 것.
- **데이터** : 주택 유형(아파트, 단독주택, 타운하우스), 지역(강남, 서초, 송파 등).
- **활용 방법** : 주택 유형을 각각 더미변수로 변환
(아파트: 0 또는 1, 단독주택: 0 또는 1, 타운하우스: 0 또는 1).
지역 변수도 더미변수로 변환 가능

2. 경제 분석

사례: 경제 성장 예측

- **목적** : 국가의 경제 성장률 예측.
- **데이터** : 정부 형태(민주주의, 공산주의, 군주제 등), 경제 활동 주요 산업(농업, 제조업, 서비스업 등).
- **활용 방법** : 정부 형태를 더미변수로 변환
(민주주의: 0 또는 1, 공산주의: 0 또는 1, 사회주의: 0 또는 1).
산업 분야도 각각 더미변수로 변환하여 경제 성장 예측 모델에 포함.

https://github.com/freejyb/fin_stats

로지스틱회귀 대출승인여부, 경제사례

4. Endogeneity problem

내생성(endogeneity) 문제

- 회귀분석에서 내생성 (endogeneity) 문제는 독립변수와 오차항 사이에 상관관계가 존재할 때 발생한다.
- 이러한 상관관계는 회귀모델의 추정치가 편향되거나 일관성이 없게 만들어, 실제로는 없는 관계를 나타내거나 실제 관계를 잘못 추정하게 만든다.

내생성 문제 주요 원인

양방향 인과관계 (Bilateral Causality or Reverse Causality)	- 독립변수가 종속변수에 영향을 주는 동시에 종속변수도 독립변수에 영향을 줄 때 발생한다. - 예를 들어, 물가 수준이 환율에 영향을 주지만, 동시에 환율 수준이 물가에 영향을 줄 수 있다.
누락된 변수 (Omitted Variable Bias)	- 모델에 포함되어야 할 중요한 변수가 누락되었을 때 발생한다. - 이 누락된 변수가 모델의 독립변수와 상관관계를 가지고 있으면, 추정치가 편향될 수 있다.
측정 오류 (Measurement Error)	- 독립변수나 종속변수의 측정에서 오류가 발생했을 때 발생한다. - 이러한 측정 오류는 변수 간의 실제 관계를 왜곡시킬 수 있다.

내생성 문제 해결방법

차분 (Differencing)	시계열 데이터에서 발생할 수 있는 내생성 문제를 해결하기 위해 데이터의 차분을 사용하여 시간에 따른 변화를 분석한다.
도구변수 (Instrumental Variables, IV)	내생적인 변수와 상관관계가 없고, 종속변수에만 간접적으로 영향을 미치는 외생적인 변수를 사용하여 내생적인 변수의 영향을 추정한다.
고정 효과 모델 (Fixed Effects Model)	개체별 또는 시간별 고정 효과를 포함시켜 누락된 변수 문제를 완화한다.
패널 데이터 분석 (Panel Data Analysis)	개체와 시간에 걸친 데이터를 사용하여 내생성 문제를 다룬다.

5. Spurious regression : problem

가성적 회귀 현상 (Spurious regression)

회귀모형은 외견상 매우 적합한 것으로 보이나 실제로는 별 의미가 없는 경우

→ R^2 값이 매우 높고, t -value 가 유의하게 나오고, DW 통계량이 매우 낮게 추정되는 경향을 보임.

시계열 회귀모형

회귀모형에 포함된 시계열의 평균 또는 분산이 증가하여 불안정성시계열을 나타내는 경우

(시계열이 단위근을 가지는 경우)

- ⑦ 확률적 추세가 있는 적분계열의 경우에도 유사한 현상이 나타남.
- ⑦ ~~시계열에 추세변동이 포함된 경우, 회귀분석 결과가 통계적으로 유의하게 나타나더라도 그 결과를 그대로 이용할 수 없음~~

6. Chow Test

Chow Test 영향력 비교

- 1960년 Gregory Chow 가 제안
- 서로 다른 데이터 세트에 대한 두 선형회귀분석의 실제 계수가 동일한 지 여부를 테스트하는 것
- 시계열 데이터나 패널 데이터에서 구조적 변화(structural break: 회귀 계수가 시간에 따라 변하는 지점을 의미)가 있는지를 검정하는 데 사용
- 독립변수가 모집단의 여러 하위 그룹에 서로 다른 영향을 미치는지 여부를 확인하는 데 자주 사용
- T-test, ANOVA: 단변량에 대한 집단(2개, 3개이상)간 차이검정

Chow Test의 기본 원리

두 개의 하위 기간(sub-period)으로 나누어진 데이터 세트에 대해 3가지 회귀 모델을 추정하고, 이 모델들의 적합도를 비교함으로써 구조적 변화를 검정

1. 전체 기간에 대한 회귀 모델
2. 첫 번째 하위 기간에 대한 회귀 모델
3. 두 번째 하위 기간에 대한 회귀 모델

1. 전체기간 : $y_t = a + b_1x_{1t} + b_2x_{2t} + \varepsilon$
2. 첫번째 기간: $y_t = a_1 + b_1x_{1t} + b_2x_{2t} + \varepsilon$
3. 두번째 기간: $y_t = a_2 + b_1x_{1t^2} + b_2x_{2t^2} + \varepsilon$

6. Chow Test

Chow Test의 수행 과정

1. 데이터 분할

: 데이터를 두 개의 하위 기간으로 분할 ⑦ 분할은 연구자가 관심 있는 특정 시점이나, 구조적 변화가 의심되는 지점을 기준으로 할 수 있다.

2. 모델 추정

: 전체 기간, 첫 번째 하위 기간, 두 번째 하위 기간에 대해 각각 회귀 모델을 추정

3. 통계량 계산

: F-통계량을 계산하여 두 하위 기간에 대한 모델들이 전체 기간에 대한 모델보다 유의미하게 나은 적합도를 보이는지 검정

▪ H_0 : 두 기간 회귀계수 차이가 없다. (회귀계수가 동일하다.)

▪ H_1 : 두 기간 회귀계수 차이가 있다.

4. 판단

: 계산된 F-통계량을 기반으로, 사전에 정의된 유의 수준(예: 0.05)에서 F-분포표를 참조하여 p-value 계산하고, 구조적 변화의 유무를 결정 ⑦ p-값이 사전에 정의된 유의 수준(예: 0.05)보다 작으면, 구조적 변화가 통계적으로 유의미하다고 해석

Chow 테스트 F통계량

$$F = \frac{(RSS_{combined} - RSS_{separate})/k}{RSS_{separate}/(N - 2k)}$$


$$F = \frac{(S_c - (S_1 + S_2))/k}{(S_1 + S_2)/((N_1 + N_2) - 2k)}$$

- $RSS_{combined}$: 전체기간에 대한 모델의 잔차제곱합(residual sum of squares)
- $RSS_{separate}$: 두 하위기간 (S_1, S_2)에 대한 모델들의 잔차제곱합
- K : 모델 파라미터의 수 (절편+회귀계수)
- N : 전체 관측수

https://github.com/freejyb/fin_stats/blob/main/chow_test.ipynb

* Summary

모집단



Logistic Regression

Logit 모델(Logistic Regression 모델)

- 1) 로지스틱 회귀분석 이해
- 2) 로지스틱 회귀분석 입문
- 3) 로지스틱 회귀분석 과정별 이해
- 4) 로지스틱 회귀분석 이슈

2. 기타 회귀분석 소개

3. 회귀분석 비교

Linear Regression : Expansion


Linear Regression



GLM : Generalized Linear Model



OLS
(**Ordinary** Least Squares)



Generalized Linear Models

J. A. Nelder and R. W. M. Wedderburn
Journal of the Royal Statistical Society. Series A (General)
Vol. 135, No. 3 (**1972**), pp. 370-384 (15 pages)
Published By: Oxford University Press

GLM의 등장

- **GLM은 종속변수가 정규분포를 이루지 않는 경우를 포함하는 선형모형의 확장**
 - ⑦ 종속변수가 **이항분포**, **포아송분포**, 감마분포 등의 지수족(exponential family) 분포를 따른다고 가정
- **GLM은 종속변수를 적절한 함수로 변화시킨 $f(y)$ 를 독립변수와 회귀계수의 선형결합으로 모형화한 것**

GLM의 중요성

- GLM의 도입으로 통계학자와 데이터 과학자는 이전보다 훨씬 더 넓은 범위의 데이터 유형과 복잡한 관계를 모델링할 수 있게 되었다.
- 이는 의학, 생물학, 경제학, 사회학 등 다양한 분야에서 복잡한 데이터를 분석하는 데 크게 기여하였다.

Linear Regression : Expansion

Linear Regression



Generalized Linear Model



Generalized Additive Model(GAM)

Linear Regression

- 종속변수의 평균이 독립변수와 회귀계수(Regression Coefficient)들의 **선형결합(Linear Combination)**으로 된 **회귀모형**
- 회귀계수를 선형 결합으로 표현할 수 있는 모형
- (가정) 선형성, 독립성, 등분산성, 정규성
- (한계) 종속변수가 연속형 변수가 아닌 경우, 대표적으로 오차항의 정규성 가정이 성립 안함

Generalized Linear Model (GLM)

$$f(\mu_y) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots \dots \beta_q X_q$$

$f(\mu_y)$: 조건부평균의 함수, link function

1. **확률 분포**: 종속 변수의 분포가 지수족(exponential family) 분포에 속하는 경우를 다룬다. ⑦ 이는 정규 분포, 이항 분포, 포아송 분포 등 다양한 분포를 포함한다.
 2. **선형 예측자 (Linear Predictor)**: 독립변수의 선형 조합으로 구성
 3. **링크 함수(Link Function)**: 선형 예측자와 종속변수의 기대값 사이의 관계를 정의 ⑦ 이 함수는 선형 예측자의 범위를 종속변수의 가능한 범위로 변환
- ⑦ **로지스틱 회귀분석(Logistic regression)** : 로지스틱함수
 - ⑦ **포아송 회귀분석(Poisson regression)** : 로그함수

Generalized Additive Model(GAM)

- 정규분포를 가정한 전통적인 선형모형 ⑦ 종속변수에 대한 분포 가정을 다양화 한 일반화선형모형 ⑦ 종속변수와 설명변수의 관계가 선형이 아닌 비모수적 함수인 경우까지 확장
- 비모수적 회귀모형에서 차원이 높은 경우에 발생하는 **차원의 저주(Curse of dimensionality)** 문제를 해결하기 위한 일환으로 개발된 가법모형(Additive Model)은 종속변수를 각 개별 설명변수들만의 **비모수적 함수의 합**으로 표현하는 방법 ⑦ **종속변수를 설명변수의 가법(Additive) 관계로 설명할 수 있다는 것을 상정한 모델**

Linear Regression : Expansion

Generalized Additive Model(GAM)

- Hastie와 Tibshirani (1986)
- **일반화** 선형모형 + **가법**모형 개발·제시
- 일반화 가법모형에서 종속변수에 대한 분포가정 측면은 일반화 선형모형과 동일

$$G(\mu_i) = \sum_{k=1}^p f_k(x_{ik}),$$

G: 연결함수(link function)

$\mu_i: E(y_i)$

y_i : exponential family 분포를 따른다(Exponential family에 포함 분포:Normal distribution, Exponential distribution, Gamma distribution 등)

- ❶ GAM은 기존 선형회귀모형의 문제점을 대부분 해결한 통계모형이지만 의미있는 독립변수의 수를 줄이는 방법이 적용되지 않을 경우 **과대적합(overfitting)** 문제가 발생
- ❷ GAM에서 변수 축소방법(shrinkage method)을 적용하는 연구가 필요

독립변수가 p개이고, 자료의 수가 n개인 경우에 다음과 같은 식으로 표현

$$y_i = \sum_{k=1}^p f_k(x_{ik}) + \varepsilon_i, \quad i = 1, 2, \dots, n,$$

y_i : 종속변수의 i번째 관측치

x_{ik} : k번째 독립변수의 i번째 관측치

f_k : k번째 독립변수에 의존하는 회귀함수

ε_i : 오차항, x와 독립, $E(\varepsilon_i) = 0$, $\text{Var}(\varepsilon_i) = \sigma^2$

* OLS, GLS, WLS

회귀분석에서 잔차 (Residual, error) 값을 구할 때, 등분산 및 상관관계에 따라 계산결과가 상이하게 나타난다.

구분	정의	가정
OLS (Ordinary Least Squares, 최소제곱법)	- OLS는 회귀분석에서 가장 기본적이고 널리 사용되는 방법 - 종속변수와 독립변수 간의 선형 함수관계를 모델링하며, 잔차의 제곱합을 최소화하는 회귀선을 찾는다. <u>데이터가 기본 가정을 충족할 때 사용되는 기본적인 회귀분석 방법</u>	- 등분산성 - 오차 항의 정규성 - 오차 항의 독립성 (분산-공분산 행렬에서 대각값은 분산(동일값)이고, 나머지 = 0)
GLS (Generalized Least Squares, 일반화 최소제곱법)	- OLS의 가정 중 일부가 만족되지 않을 때 사용 - 오차항의 분산이 <u>이분산성(heteroscedasticity)</u>일때 사용 - 오차항들 <u>사이에 상관관계가 있을 때(자기상관)</u> 사용	GLS는 오차항의 분산과 공분산 구조를 알고 있다고 가정 이 정보를 사용하여 변환을 적용하고, 변환된 모델에 대해 OLS를 수행 (분산-공분산 행렬에서 대각값은 분산이고, 나머지는 ≠ 0)
WLS (Weighted Least Squares, 가중 최소제곱법)	- 오차항의 분산이 <u>이분산성일때 사용</u> - 각 관측치에 가중치를 부여하여 이분산성을 보정한다.	각 관측치의 가중치를 알고 있다고 가정 가중치는 일반적으로 오차의 분산의 역수로 설정 오차 항의 독립성 (분산-공분산 행렬에서 대각값은 분산이고, 나머지 = 0)

* OLS, GLS, WLS

수학적 접근

GLS (Generalized Least Squares) Paul Johnson October 24, 2005

통계연구 참고 할 것

<https://www.statsmodels.org/dev/examples/notebooks/generated/ols.html>

<https://www.statsmodels.org/dev/examples/notebooks/generated/wls.html>

https://github.com/freejyb/fin_stats

OLS, GLS

Introduction Background

- 영국의 통계학자인 **D. R. Cox**가 1958년에 제안한 **확률 모델**
- 독립변수**의 **선형결합을 이용하여** 사건의 발생 가능성을 예측하는데 사용되는 통계 기법
- 종속변수가 범주형 데이터일 때 사용하는 통계 기법 : **성공 or 실패 등 target(종속)변수가 이항변수인 경우** $\rightarrow$ 선형회귀분석식을 통해 분석하는 경우 여러가지 문제 발생
- 종속변수**의 로그 오즈(log odds)를 독립변수의 선형 조합으로 모델링

OLS를 통한 분류분석 한계점

- feature의 값에 상관없이 Y와 선형관계가 있음을 가정한다.
- 확률은 0에서 1 사이의 값으로 도출되어야 하지만, 여기서 추정된 Y는 0,1사이의 값을 가진다고 보장하지 못한다. (애초에 OLS추정이 가진 특성)
- 만약 feature를 조정하여 y를 0,1 사이의 값으로 조정하더라도 그렇게 되면 오차항이 정규분포를 따른다는 가정에 어긋난다.
- 오차항이 이분산성을 가지기 때문에, 통상적인 추론을 하지 못한다.

OLS를 통한 분류 분석의 한계점을 극복하기 위해 Logistic Regression 시행

선형 회귀모형의 단점을 극복하기 위해 확률에 대한 로짓변환을 고려하여 모형화

- 종속변수가 "성공 또는 실패", "부도 또는 정상", "생존 또는 사망" 경우처럼 이항변수로 되어 있을 때 종속변수와 독립변수 간의 관계식을 이용하여 두 집단 또는 그 이상의 집단을 분류하고자 할 때 사용되는 분석기법
- ➔ 목표변수(종속변수)가 이항변수일때 기존 선형회귀모형의 단점을 극복하기 위한 확률에 대한 logit transformation(자연로그 취함)을 고려하여 분석하는 것
- ➔ binary data(이항변수) 데이터를 적용하는 경우 종속변수의 결과의 범위가 0 or 1로 제한

로지스틱함수의 누적확률분포(Cumulative Distribution Function)를 이용하여 모델의 적합치가 항상[0,1] 사이에 놓이도록 함으로써 선형회귀분석의 문제점을 해결 ➔ 확률데이터의 분석과 결과 해석 용이한 모델

Introduction : Type

OLS를 통한 분류분석 한계점

1) 분류 문제에 사용

추정된 확률 값 > 임계치(0.5) : 1, < 임계치 미만 : 0

: 새로운 data가 들어왔을 때 기존 데이터의 분류되어 있는 그룹 중 어느 그룹에 속하는지를 분류하는 문제.

Ex. 기업 feature 를 통해 ⑦ 부도기업(1) vs 정상기업(0)

- 금융 : 금융 사기거래 행위 분석, 부실기업 예측, 불공정거래 판단, 개인고객 연체 예측
- 마케팅 : 이탈고객 예측, 광고 클릭여부 예측,
고객 feature 를 통해 ⑦ 고객이탈(1) 유지고객 예측, 메일 스팸여부
- 제조/ 의료 : 불량품 예측, 질병 발생 예측

2) 머신러닝에서 정확한 예측을 생성하는 데 사용

로지스틱 회귀분석 종류

구분	내용
이항(이진) 로지스틱 회귀 (Binary Logistic Regression)	종속변수가 두 개의 범주(예: 0 또는 1)를 가질 때 사용 ⑦ 각각의 경우로 분류될 확률의 합은 1
다항형 로지스틱 회귀 (multinomial logistic regression)	▪ 종속변수가 세 개 이상의 상호 배타적인 범주를 가질 때 사용 ▪ ⑦ 종속 변수의 범주 중 하나를 기준(참조) 범주로 설정하고, 나머지 범주들이 기준 범주에 비해 얼마나 다른지를 모델링한다. ▪ 여러 범주 중 하나에 속할 확률을 예측
순서 로지스틱 회귀 (Ordinal Logistic Regression)	▪ 종속변수가 순서가 있는 범주(예: 만족도 평가처럼 순서가 있는 등급, 좋음, 보통, 나쁨)를 가질 때 사용 ▪ 이 방법은 범주 간의 순서를 고려하여 모델링 ▪ 목적: 순서가 있는 범주형 결과를 예측하고, 각 범주로 분류될 확률을 추정

Linear Regression vs Logistic Regression

구분	선형 회귀분석	이항 로지스틱 회귀분석
독립변수	비율척도, 간격척도, 명목척도(dummy 변수 변환)	비율척도, 간격척도, 명목척도(dummy 변수 변환)
종속변수	연속형 변수(continuous variance) (명목, 서열척도)	범주형 변수(categorical variance) (명목변수-이항변수)
회귀계수 추정	최소제곱법	최대우도추정법
모형에 대한 검정	F 검정	카이제곱 검정
회귀계수 검정	t-검정, (t 통계치) p 값 <0.05	Wald 통계량, p 값 <0.05
회귀계수(β)	회귀계수(설명변수 1변화에 대한 종속변수 변화량)	로짓회귀계수 (설명변수 1변화에 대한 종속변수 logit)
모형 설명력	결정계수 (R^2)	Pseudo R^2 , Cox and Snell R^2 (종속변수와 독립변수들간의 관계의 강도)
가정	오차항 : 정규분포 등분산성 선형성 정규분포	- 오차에 대한 정규분포 가정 필요 없음 ⑦ $y: 0 \sim 1$ - 등분산 가정 필요 없음 - 선형성 가정(독립변수와 종속변수(Logit 오즈)간 선형관계) - 종속변수가 이항분포를 따르고 그 모수 μ가 독립변수 x에 의존한다고 가정
독립성 가정	가정오차항 독립성 (다중공선성 부재 필요)	독립변수간 서로 독립적 (다중 공선성 부재 필요)
비용함수 한계	MSE가 Cost function으로 사용	- cross entropy를 cost function으로 사용 - 로지스틱 회귀분석으로는 비선형 문제를 해결 불가 - 과적합 문제

(로지스틱 회귀분석)

예측변수가 다변량 정규 분포를 따른다면 현재 해법이 좀더 안정적으로 적용될 수 있다.

또한 다른 형식의 회귀분석에서 처럼 예측변수 간의 다중공선성은 편향된 추정값과 팽창한 표준오차를 유발 가능

Logistic Regression Formulation


이항 로지스틱 회귀분석

$y = a + bx$ 단순선형회귀식에서 y 대신 확률값 p 를 대입하고 ⑦ $p = a + bx$ 도
 $\pi \pi$

⑦그 래 서 odds 값 대입하고 $\ln$ 변환을 통해 종속변수의 값을 0~1 사이의 값으
 로 제한해야 함.

⑦로 지 스틱 회귀분석에서는 Odds를 Logit 변환 ⑦ 부도확률이 0과 1사이의
 값을 가지도록 변환해주는 것!!!

⑦일 반 화 선형모델(GLM : Generalized Linear **Model**) → 종속변수가 이항 분
 포를 따른다고 가정




로지스틱 회귀분석은 독립변수의 선형결합을 활용해 사건의 발생 가능성을 예측한다.
 하지만, OLS를 통해서 y 의 값을 0,1 사이의 확률로 도출할 수 없기에 **시그모이드 (sigmoid)**함수를 사용한다,

시그모이드 함수

$$S(x) = \frac{1}{1 + e^{-x}} = \frac{e^x}{e^x + 1}$$

⑦ x 가 0일 때 $y=0.5$



▪ x : 무한대, y : 0과1

* Odds & Odds ratio

Odds 의미와 해석

$$\text{오즈(Odds)} = \frac{\text{성공률}}{\text{실패률}} = \frac{p}{1-p} = \frac{\text{사건이 발생할 확률(부도기업)}}{\text{사건이 발생하지 않을 확률(정상기업)}} = \frac{\frac{p_1}{1-p_1}}{\frac{p_0}{1-p_0}} = \frac{e^{(\beta_0 + \beta_1)}}{e^{\beta_0}} = e^{(\beta_1)}$$

(성공=1, 실패=0, 이항자료에서 성공률을 p인 경우 (p는 연구자의 관심 대상이 됨))

Odds는 성공확률이 실패확률의 몇배인지 나타내는 항목)

- 성공이 일어날 가능성이 높은 경우 Odds는 1.0 보다 크다
- 실패가 일어날 가능성이 높은 경우 Odds는 1.0 보다 작다.
- Odds = 1 이면, 성공확률과 실패확률이 같다

- $0 \leq p \leq 1$
- $0 \leq \text{odds} \leq \infty$
- $\text{Logit}(p) = \ln\left(\frac{p}{1-p}\right)$
- Odds를 정규분포로 연결하는 고리
- $-\infty < \ln(\text{odds}) < \infty$

1:1 인 경우


$$\text{Odds ratio} = \frac{0.5}{1-0.5} = 1$$

$\ln(\text{오즈}) = 0$ 이므로 분포의 중심 위치.


Odds 값이 0 과 멀어지면 분포의 양쪽으로

Odds 값의 범위는 $0 < \text{Odds} < \infty$ 이므로 로짓변환을 하면 로지스틱 회귀모형

$$\ln\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 X_1 \text{에서 자연로그 } e \text{를 취하면 } \frac{p}{1-p} = e^{\beta_0 + \beta_1 X} \quad (\text{where } p = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}})$$



- 일반적 모형: $\ln \frac{p}{1-p} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p$
- 오즈(Odds) = $\frac{p}{1-p} = e^{\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p}$



비선형 함수 사용하여 종속변수 확률(p) $0 \leq p \leq 1$

* Odds & Odds ratio

확률(p)과 오즈(Odds), 오즈비 (Odds Ratio)

- 확률(Probability : p) = 비율(proportion), 전체 중에서 어떤 사건(A : event)이 차지하는 크기 ⑦ $\frac{P(A)}{\text{전체}}$
- Odds : 어떤 사건이 발생할 확률이 발생하지 않을 확률 대비 몇배? ⑦ $\frac{P(A)}{1-P(A)}$

오즈비(Odds Ratio) : 오즈의 비

(정의)

- 다른 설명변수는 모두 고정시킨 상태에서 한 변수(x_j)를 1단위 증가시킬 때 변화하는 Odds의 비율을 의미

$$\text{Odds ratio} = \frac{e^{\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_i (x_i + 1) + \dots + \beta_p x_p}}{e^{\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_i x_i + \dots + \beta_p x_p}}$$


- 회귀계수가 음(-)의 값 일 때 : **Odds Ratio** 가 1보다 작게 나옴. 설명변수 x가 감소방향 으로 영향을 미침을 의미
- 회귀계수가 양(+)의 값 일 때 : **Odds Ratio** 가 1보다 크게 나옴 , 증가방향으로 영향을 미침을 의미
- **회귀계수 값(β_1)에 대한 x_1 를 1단위 증가시키게 되면 오즈의 예측 값은 $\exp(\beta_1)$ 만큼 증가**
- 회귀계수 양수(+) : 사건 발생확률(성공확률) 증가 ⑦ $\beta_j > 0$ ⑦ $e^{\beta_j} > 1 \rightarrow \text{Odds ratio} > 1$: Odds 증가
- 회귀계수가 음수(-) : 성공확률 감소 ⑦ $\beta_j < 0$ ⑦ $e^{\beta_j} < 1 \rightarrow \text{Odds ratio} < 1$: Odds 감소

* Odds & Odds ratio

동아일보 [스포츠](#)

카타르 월드컵 우승 확률, 프랑스 18%-브라질 16%

입력 2022-06-17



$$\frac{0.18}{0.82} = 0.2195$$

$$\frac{0.0035}{0.9965} = 0.0035$$

배당?

!; 4 배당 → 우승확률 ?

1:100 배당 → 우승확률

* Odds & Odds ratio

World Cup 2022 Outrights

OUTRIGHTS

Team	Odds
Brazil	5.50
England	6.58
France	6.61
Spain	9.06
Argentina	9.98
Germany	11.97
Portugal	13.06
Netherlands	13.07
Belgium	13.10
Denmark	28.63
Uruguay	51.14
Croatia	51.14
Senegal	79.96
Switzerland	79.96
USA	107.52
Poland	123.22
Serbia	128.50
Mexico	138.50
Canada	148.01
Ecuador	148.28
Peru	201.54
Cameroon	201.54
Ukraine	211.02
Morocco	251.66
Ghana	251.66
Japan	251.66
South Korea	282.91
Greece	299.08
Ireland	299.08
Bosnia & Herzegovina	299.08
Wales	304.13
Tunisia	348.80
Qatar	420.67
Scotland	441.00
Australia	496.05
Saudi Arabia	502.91
Iran	596.66
Costa Rica	1379.68
Northern Ireland	1588.97
Bulgaria	1588.97
New Zealand	1755.80
Malta	5103.80

선수·도박사·AI 모두 "우승은 너"... 20년 만에
왕좌 노리는 브라질 2022.11.18 16:24

영국의 베팅업체 윌리엄 힐, 미국 스포츠베팅
업체 시저스스포츠북에 따르면,

브라질의 우승 배당률은 4대 1로 아르헨티나
와 프랑스, 잉글랜드 등 경쟁국을 상회한다.

$$\frac{1}{282} = 0.0035$$

* Odds & Odds ratio

오즈비 사례

(예시) 방역강화는 코로나 환자와의 접촉을 피하기 위함으로 알려져 있다. 그렇다면
코로나 환자와 접촉 후 코로나 감염될 확률은 코로나 환자와 접촉하지 않고 감염될 확률 대비 몇배 정도 될까?

구분		코로나 감염 여부	
		예	아니오
코로나 환자와 접촉 여부	예	50	200
	아니오	100	1,000

오즈비(Odds Ratio)

$$\text{오즈비} = \frac{\text{코로나 환자와 접촉 후 감염확률}}{\text{코로나 환자와 접촉하지 않고 감염될 확률}} = \frac{\frac{50}{200}}{\frac{100}{1,000}} = \frac{0.25}{0.1} = 2.5$$

결과 코로나 환자와 접촉 후 코로나 감염될 확률은 코로나 환자와 접촉하지 않고 감염될 확률 대비 2.5 배 높다.

- 분자 값: (위험인자에 노출된 사람 중 질병에 걸린 사람 수 A) / (질병에 걸리지 않은 사람 수 B)
- 분모 값: (위험인자에 노출되지 않은 사람 중 질병에 걸린 사람 수 C) / (질병에 걸리지 않은 사람 수 D)

사례-대조군 연구 (case-control study)

- 사후 결과를 토대로 연구하는 경우로 두 변수간 상관성 여부 확인 하기 위한 검정(독립성 검정)
예를 들어 이미 질환이 발생한 환자군과 질환이 발생하지 않은 대조군을 모집한 후 위험인자 노출 여부를 후향적으로 조사하여 위험인자와 질환 발생 간의 연관성을 추정
- ⑦ 이러한 경우에는 위험인자에 노출된 전체 모집단과 노출되지 않은 전체 모집단을 파악할 수가 없으므로(특정 시점에서의 집단 수만 파악할 수 있기 때문에) 승산비를 사용할 수밖에 없는 것

* Odds & Odds ratio

오즈비 사례

구분		코로나 감염 여부	
		예	아니오
코로나 환자와 접촉여부	예	50 (A)	200(B)
	아니오	100(C)	1,000 (D)

- 상대위험도(RR) : 위험인자에 노출되었을 때 질병이 발생할 확률에서, 위험인자에 노출되지 않았을 때 질병이 발생할 확률을 나눈 값.

$$\text{상대적위험도} = \frac{\text{코로나 환자 접촉한 경우}_{(A+B)} \text{ 중에서 코로나 감염}_{(A)}}{\text{코로나 환자와 접촉하지 않은 경우}_{(C+D)} \text{ 에서 코로나 감염}_{(C)}}$$

⑦ 위험인자에 노출된 경우가, 노출되지 않은 경우보다 감염될 확률이 얼마나 높은지 확인?

코호트 연구(Cohort Study)

- 사전에 그룹의 수를 결정해서 실험 연구설계로 집단간 분포의 동질성 여부분석을 통해 차이를 검정(동질성 검정)
- ⑦ 특정 요인에 노출된 집단과 노출되지 않은 집단을 추적하고 연구 대상 질병의 발생률을 비교하여 요인과 질병 발생 관계를 조사하는 연구 방법, 요인 대조 연구(factor-control study)

- Odds ratio : 사례- 대조군 연구 하는 경우
- 상대위험도 : 코호트 연구일 경우

⑦ 교차분석 활용

* Sigmoid 함수

Sigmoid 함수 란?

- 실수 값을 **입력받아 0과 1 사이의 출력을 생성한다.**
- S자 곡선을 그리면서 y값을 일정사이의 값으로(통상: 0~1) 항상 Monotonically
- 증가하는 함수를 "통칭"해서 부른다.
- 로지스틱회귀분석에서 Activation Function 역할


Sigmoid 함수 수학적 표현

sigmoid함수

$$S(x) = \frac{1}{1 + e^{-x}} = \frac{e}{e^x + 1}$$

Sigmoid 함수의 특징

- S자 형태:** Sigmoid 함수는 S자 형태의 곡선을 가진다.
- 출력 범위:** Sigmoid 함수의 출력은 항상 0과 1 사이 ⑦ 이 특성은 확률을 나타낼 때 유용
- 비선형성:** Sigmoid는 비선형 함수이기 때문에, 신경망에서 선형적으로 구분할 수 없는 데이터를 분류할 수 있게 해준다.
- 미분 가능성:** Sigmoid 함수는 미분 가능하다. ⑦ 이 특성은 신경망 학습에서 역전파 알고리즘을 적용할 때 중요
- 입력값에 따른 포화:** 매우 크거나 작은 입력값에 대해, sigmoid 함수는 0 또는 1에 매우 가까운 값을 출력한다. 이는 기울기 소실 문제를 일으킬 수 있다



$$e^x - e^{-x}$$

Sigmoid 함수의 종류

- 로지스틱 Sigmoid 함수:** 가장 일반적인 형태의 Sigmoid 함수 ⑦ 초기 인공신경망과 로지스틱 회귀에서 널리 사용된다.
- 하이퍼볼릭 탄젠트 함수 (tanh):** 하이퍼볼릭 탄젠트 함수는 로지스틱 Sigmoid 함수와 비슷한 S자 형태를 가지지만, 출력 범위가 $[-1, 1]$ 이다.
 - ⑦ $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$
- Gompertz 함수:** 이는 생물학과 인구학에서 사용되는 Sigmoid 형태의 함수
 - ⑦ $f(x) = ae^{-be^{-cx}}$. 여기서 a, b, c 는 상수
- Arctangent 함수(아크탄젠트 함수):** $[-\frac{\pi}{2}, \frac{\pi}{2}]$ 의 출력범위
 - ⑦ $\arctan(x)$ 로 표현
- Softsign 함수:** 출력 범위는 $[-1, 1]$ 로 하이퍼볼릭 탄젠트 함수 (tanh) 와 유사한 형태로 계산이 간단하다.
 - ⑦ $\frac{x}{1+|x|}$

Logistic Regression Formulation

이항 로지스틱 회귀분석

확률(Probability)

- : 클래스 1에 속할 확률 추정 (클래스 1: 관심있는 사건 ㉠ 부도기업)
- : 실제 값 y 는 1과 0의 값 2가지만 가진다. ㉠ 확률로 변환 ㉠ $p = P(Y=1)$, $(1-p) = P(Y=0)$
- 선형함수 사용시는 종속변수 확률(p) : $-\infty \leq p \leq \infty$
- 비선형 함수 사용하여 종속변수 확률(p) : $0 \leq p \leq 1$

$y = \beta^0 x_1 + \dots + \beta^0 x_k + \varepsilon \rightarrow y = BX \dots$ (선형결합식을 행렬을 사용해 간단화 작업)

$0 \leq p \leq 1$ 인 p 를 도출해야 하지만, OLS는 무한의 값이므로 **odds 비를 도입한다**

, $0 \leq \text{Odds Ratio} = \frac{p}{1-p} \leq \infty \dots$ (양의 무한 범위 성립)

$-\infty \leq \ln\left(\frac{p}{1-p}\right) \leq \infty \dots$ (Odds ratio에 음의 무한 값도 포함하기 위해 자연로그를 취하면 OLS의 결과 범위와 동일)

$$\ln\left(\frac{p}{1-p}\right) = y = BX \Rightarrow (e^x \text{로 변환}) \Rightarrow \frac{p}{1-p} = e^{BX}$$

$$\frac{1-p}{p} \left(= \frac{1}{p} - 1 \right) = \frac{1}{e^{BX}} \text{ 이므로 } \frac{1}{p} = \frac{1+e^{BX}}{e^{BX}} \text{ 성립 } \dots (\text{Odds에 역수를 취하고 식을 정리})$$

$$p = \frac{e^{BX}}{1+e^{BX}} \dots (\text{다시 역수를 취하면 sigmoid 함수 형태 완성})$$

$$p = \frac{e^{BX}}{1+e^{BX}} * \frac{1 \odot e^B}{1 \odot e^B} = \frac{1}{e^{-BX} + 1} \dots (\text{확률 } p \text{ 는 다음과 같이 정리할 수 있음})$$

$$\ln\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 \dots + \beta_n X_n$$

로그 오즈 추정치를 다시 확률로 변환하여, 주어진 독립변수 값에 대한 성공확률을 예측할 수 있다. 로그 오즈를 확률로 변환하는 공식

$$P = \frac{e^{\beta_0 + \beta_1 X_1 + \beta_2 X_2 \dots + \beta_p X_p}}{1 + e^{\beta_0 + \beta_1 X_1 + \beta_2 X_2 \dots + \beta_p X_p}}$$

$$p = \frac{\text{Odds}}{1 + \text{Odds}} = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \beta_2 X_2 \dots + \beta_p X_p)}}$$

Logistic Function

로지스틱 함수 (Logistic function)

- 입력변수 x 값이 음의 무한대와 양의 무한대까지의 값을 0부터 1 범위의 확률값으로 출력하는 함수
- 이 함수는 로지스틱 회귀 분석에서 예측된 로그 오즈를 확률로 변환하는 데 사용
- 로짓 함수의 역함수: 로지스틱 함수(sigmoid function)

로짓 함수의 수학적 유도

1단계: 확률을 Odds로 변환

$$\begin{aligned} \text{Odds} \\ \bullet \text{ Odds}(Y=1) &= \frac{p}{1-p} \\ \bullet p &= \frac{\text{Odds}}{1+\text{Odds}} \end{aligned}$$

2단계: Odds의 자연로그 취하기



$$\text{Logit} = \ln(\text{Odds})$$

Logit = Log + Probit (= Probability Unit)


Logit 변환

$$\ln \frac{p}{1-p} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p$$



Logistic function

$$\begin{aligned} \bullet \ln \left(\frac{p}{1-p} \right) &= \beta + \beta \times x_1 \\ \bullet p(x) &= \frac{e^{\beta_1 X}}{1 + e^{\beta_1 X}} \end{aligned}$$



$$p = \frac{\text{Odds}}{1+\text{Odds}} = \frac{1}{1+e^{-(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p)}}$$

sigmoid함수

$$S(x) = \frac{1}{1+e^{-x}} = \frac{e^x}{e^x+1}$$

sigmoid함수

Logistic function : linear regression + sigmoid 함수의 결합 !!!!!

Logistic Function

Logistic function : linear regression + sigmoid 함수의 결합 !!

Linear Regression

$$\ln(\text{Odds}) = \ln\left(\frac{p(y=1|x)}{1-p(y=1|x)}\right) = \beta_0 + \beta_1 x$$



Logistic Regression

$$p(y=1|x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}$$

$$\ln\left(\frac{p(y=1|x)}{1-p(y=1|x)}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$$

$$\frac{p(y=1|x)}{1-p(y=1|x)} = e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p}$$

$$p(y=1|x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p)}}$$

$$p(y=1|x) = \frac{1}{1 + e^{-w^T x}}$$

예시) 로지스틱회귀 결과 $\beta_0=1.5$, $\beta_1=2$ 가 유의하게 나왔다면

$$\ln(\text{Odds}) = \ln\left(\frac{p(y=1|x)}{1-p(y=1|x)}\right) = 1.5 + 2x \quad \Rightarrow \quad p(y=1|x) = \frac{1}{1 + e^{-(1.5 + 2x)}}$$

결과적으로 x가 입력되면 나온 확률값에 따라 범주 분류

⑦ 확률값 > 임계치 : 1로 분류, 확률값 < 임계치 : 0으로 분류

Logistic Regression Analysis

로지스틱 회귀모형

$$\ln(\text{Odds}) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \dots + \beta_p X_p$$

선형회귀와 로지스틱 회귀 : 회귀계수 해석 비교

선형회귀분석	설명변수(입력변수)가 1단위 증가할 때 종속변수(출력변수)의 변화량
로지스틱 회귀분석	설명변수(입력변수)가 1단위 증가할 때 종속변수(출력변수) $\ln(\text{Odds})$ 의 변화량 • 회귀계수 값(β_1)에 대한 X_1 를 1단위 증가시키게 되면 오즈의 예측 값은 $\exp(\beta_1)$ 만큼 증가

다음 기간 동안 부도가 발생할 확률

$$\ln \frac{p}{1-p} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p, \quad P = \frac{e^{\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p}}{1 + e^{\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p}}$$

로지스틱 모형은 $\beta_1 > 0$,

독립변수 x 의 값이 작아질수록 예측값은 '0'에 가까워지고,

독립변수 x 값이 증가함에 따라 예측값은 S자 형태의 모양으로 증가하면서 점점 '1'로 접근하는 모형

• 이 곡선을 시그모이드(sigmoid)함수이 함수는 경계값인 0 근처에서 기울기가 급속하게 커져서 두 개의 범주에 대한 구분을 쉽게 한다.

Cost function : 머신러닝

$$\bullet \text{Odds}(Y=1) = e^{\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots}$$

• Linear regression : MSE가 Cost function으로 사용

• Logistic Regression : Cross Entropy를 Cost function으로 사용

logistic regression은 비선형인 sigmoid함수를 활성화 함수로 사용해 비선형 값을 출력하기 때문에 MSE를 사용 불가

• MSE의 식처럼 제곱을 하게 되면 한 개의 최저점을 갖는 볼록함수가 아닌 여러 개의 최저점을 갖는 함수가 나오기 때문에 비용함수로 사용 불가

• cross entropy를 비용함수로 사용하면 목표와 예측이 얼마나 가까워지고 있는지 확인

Logistic Regression: Process

1. 회귀계수 추정 : Maximum Likelihood Estimation

: 각 집단 (class) 에 속하는 확률 값을 반환
 ⑦ 로지스틱 회귀는 연속이고 증가함수이면서, 독립변수의 범위 $-\infty, \infty$ 에서 종속변수의 값이 $[0, 1]$ 사이에 있는 함수여야 한다.



2. 회귀계수 통계적 유의성 검정

검정통계량 : Wald-test()



3. 변수 선택 방법

후진 제거법 (backward elimination), 전진 등 ⑦ **AIC 낮은 값**



4. 추정확률 분류 기준값 (threshold , cut-off) 적용 : 특정 범주로 분류

예) 종속변수 값이 $P(Y=1) \geq 0.5$ 집단(class) 1로 분류
 ⑦ 집단 1 (관심 대상 : 부도기업, 암 환자) 종속
 변수 값이 $P(Y=1) < 0.5$ 집단(class) 0으로 분류



5. test data 이용한 모델 성능 평가


C.M (Acc, F1) ROC curve, AUC

https://ml-cheatsheet.readthedocs.io/en/latest/logistic_regression.html#id12

Regression coefficient Estimation

1.회귀계수 추정 : Maximum Likelihood Estimation (최대우도추정법 / 최우추정법)

- 우도(likelihood)를 최대화하는 방향으로 모수를 추정하는 방법
- ⑦ 우도가 높다는 것은 해당 모수를 가진 분포가 관측치에 적합하다는 의미
- 우도를 최대가 되는 모수를 찾는 의미는 해당 데이터를 잘 설명하는 분포를 찾게 되는 것 (아래그림 빨간색 분포 참조)



통계입문1: 최우추정법 참조

우도(likelihood)

- 확률 : 분포가 정해지고, 분포의 모수가 정해졌을 때 관측치가 나올 가능성
- 우도 : 분포가 정해지고, 관측치가 주어졌을 때 **모수가 발생할 가능성도**
- 수치적으로 가능도를 계산하기 위해서는 각 데이터 샘플에서 후보 분포에 대한 높이(likelihood 기여도)를 계산해서 다 곱한 것을 이용할 수 있을 것이다.
- (계산된 높이를 곱해주는 이유 : 관찰한 관측치가 서로 *i.i.d(independent identically distributed)* 하다는 것)

Regression coefficient Estimation

1. 회귀계수 추정 : Maximum Likelihood Estimation (최대우도추정법 / 최우추정법)

- $P(y_i=1) = p$
- $P(y_i=0) = 1-p$

$$f(y_i) = p(x_i)^{y_i} (1 - p(x_i))^{1-y_i}$$

$$L = \prod_{i=1}^n f(y_i) = \prod_{i=1}^n p(x_i)^{y_i} (1 - p(x_i))^{1-y_i}$$

$$\ln L = \ln \left[\prod_{i=1}^n p(x_i)^{y_i} (1 - p(x_i))^{1-y_i} \right]$$

$$= \ln \left[\left(\frac{p(x_i)}{1-p(x_i)} \right)^{y_i} + \sigma \ln(1 - p(x_i)) \right]$$

$$= \sum_{i=1}^n y_i \ln \left[\left(\frac{p(x_i)}{1-p(x_i)} \right) \right] + \sigma \ln(1 - p(x_i))$$

$$= \sum_{i=1}^n y_i (\beta_0 + \beta_1 X_1 + \beta_2 X_2 \dots + \beta_p X_p) + \sigma \ln(1 + e^{\beta_0 + \beta_1 X_1 + \beta_2 X_2 \dots + \beta_p X_p})$$

log likelihood function

$$\ln L = \sum_{i=1}^n y_i (\beta_0 + \beta_1 X_1 + \beta_2 X_2 \dots + \beta_p X_p) + \sigma \ln(1 + e^{\beta_0 + \beta_1 X_1 + \beta_2 X_2 \dots + \beta_p X_p})$$

결국 로그-우도함수가 최대가 되는 parameter β 결정

여기서 로그 우도함수는 parameter β 에 대하여 비선형이므로 선형회귀모델과 같이 명시적 해가 존재하지 않음

Regression coefficient Estimation

MLE : Maximum Likelihood Estimation

likelihood function 자연로그를 이용 log-likelihood function $L(\theta|x)$ 를 이용.


$$P(x|\theta) = \prod_{k=1}^n P(x_k|\theta)$$

$$L(\theta|x) = \log P(x|\theta) = \sum_{i=1}^n \log P(x_i|\theta)$$

Maximum Likelihood Estimation : **Likelihood 함수의 최대값을 찾는 방법**

- 계산의 편의를 위해 log-likelihood의 최대값을 찾는다.
- 미분계수를 이용, 찾고자 하는 파라미터 θ 에 대하여 편미분하고 그 값이 0이 되도록 하는 θ 를 찾는 과정을 통해 likelihood 함수를 최대화 시켜줄 수 있는 θ 를 찾을 수 있다.
- 로그우도함수는 parameter β 에 대하여 비선형이므로 선형회귀모델과는 달리 명시적인 해가 존재하지 않는다.
(수치 최적화 알고리즘 이용)

$$\frac{\partial}{\partial \theta} L(\theta|x) = \frac{\partial}{\partial \theta} \log P(x|\theta) = \sum_{i=1}^n \frac{\partial}{\partial \theta} \log P(x_i|\theta) = 0$$



likelihood function 최대값 = Cross entropy 최소 값
(다음 면 참조)

* MLE & Cross entropy

likelihood function 최대값 = Cross entropy 최소 값

Cross entropy : 두 확률분포 (입력분포: $p(x)$, 출력분포: $q(x)$)의 차이

- Cross entropy = $-\sum p(x) \log q(x)$
- 우도함수 최대치 = 입력분포 $p(x)$ 와 parameter 가 주어졌을 때 출력분포 $q(x)$ 의 확률을 최대
- **Cross entropy 최소 값** = 입력분포 $p(x)$ 와 출력분포 $q(x)$ 와의 차이를 최소

분류 모델에 대한 손실 함수(deep learning) : cross-entropy

$$\text{cross-entropy} = -\frac{1}{n} \sum_{i=1}^n \sum_{c=1}^C L_{ic} \log(P_{ic})$$

n = 데이터 갯수
 C = 범주 갯수
 L = 실제 값 (주로 0 또는 1)
 P = 실제 값에 대한 확률 값 (0~1)

$$\text{Cross entropy} = -\sum p(x) \log q(x)$$

🔗 기계학습부도모형 자료(pt3..2) 참조할 것

신경망 학습방법 개선 : The cross-entropy cost function

내용참조: <http://neuralnetworksanddeeplearning.com/chap3.html>

Cost function : 머신러닝

- **Linear regression** : MSE가 Cost function으로 사용
 - **Logistic Regression** : Cross Entropy를 Cost function으로 사용
- logistic regression은 비선형인 sigmoid함수를 활성화 함수로 사용해 비선형 값을 출력하기 때문에 MSE를 사용 불가
- 🔗 MSE의 식처럼 제곱을 하게 되면 한 개의 최저점을 갖는 볼록함수가 아닌 여러 개의 최저점을 갖는 함수가 나오기 때문에 비용함수로 사용 불가
 - 🔗 cross entropy를 비용함수로 사용하면 목표와 예측이 얼마나 가까워지고 있는지 확인

Regression coefficient : Significance Test

2. 회귀계수 통계적 유의성 검정 : *Wald-test t*

구분	독립변수에 대한 회귀계수의 유의성 검정	검정통계량
선형회귀분석	Student's t-test	t통계량
로지스틱회귀분석	<i>Wald-test</i>	Wald 통계량

Wald test

- 모수(parameter)의 추정치가 특정 값과 얼마나 차이가 있는지를 검정하기 위해 사용되는 방법 중 하나이다.
- Abraham Wald**에 의해 제안
- 최대우도추정값(Maximum Likelihood Estimate, MLE)을 사용하여 모수의 가설을 검정할 때 활용
- ❶ 로지스틱 회귀분석에서 오즈비(odds ratio)가 특정 값과 다른지를 검정할 때 사용

$$\text{Wald 통계량} = \left(\frac{\text{회귀계수 추정치}}{\text{표준오차}} \right)^2$$

$$W = \frac{(\hat{\theta} - \theta_0)^2}{\text{Var}(\hat{\theta})}$$

Wald 통계치는 카이제곱 분포 (카이제곱분포는 Z 제곱에 대한 분포)를 따르므로 이에 대한 유의확률 (p-value) 역시 자유도(df)를 고려한 카이제곱 분포에서 찾아야 한다.

Wald신뢰구간 안에

Odds값이 1을 포함하고 있으면 통계적 유의성이 없는 것이고, 1에서 크게 벗어나면 유의성이 있다고 해석 가능

- 귀무 가설(H_0) : 보통 모수가 특정 값 θ_0 과 동일하다.
- 대립 가설(H_1) : 모수가 귀무가설에서 주장하는 값과 다르다.

- p-값 $\leq$ 유의 수준: H_0 기각, 대립가설 채택
- p-값 $>$ 유의수준(α): H_0 을 기각할 충분한 근거가 없다. ❶ 이것이 H_0 이 참이라는 증거는 아니다.

Regression coefficient : Interpretation

Logit Regression Results

```

=====
Dep. Variable:    Survived    No. Observations:    889
Model:            Logit      Df Residuals:          883
Method:           MLE        Df Model:            5
Date:            Fri, 11 Feb 2022    Pseudo R-squ.:      0.3099
Time:            16:57:47    Log-Likelihood:     -408.15
converged:        True        LL-Null:           -591.41
Covariance Type: nonrobust    LLR p-value:        4.834e-77
=====

```

```

=====
              coef    std err          z      P>|z|      [0.025    0.975]
-----
Pclass      -0.6247     0.076     -8.239     0.000     -0.773    -0.476
Sex          2.7472     0.193     14.209     0.000      2.368     3.126
SibSp       -0.2572     0.100     -2.582     0.010     -0.452    -0.062
Parch       -0.1029     0.113     -0.913     0.361     -0.324     0.118
Fare         0.0058     0.002      2.846     0.004      0.002     0.010
Embarked    -0.1238     0.099     -1.254     0.210     -0.317     0.070
=====

```

- 선형회귀계수 : X 1단위 증가 $\Rightarrow$ Y 변화량
- 로지스틱 회귀계수 : X 1단위 증가 $\Rightarrow$ $\ln(\text{odds})$ 변화량

	logit	odds ratio	p-value	above 5.0%
Pclass	-0.624685	0.535430	0.0000	Yes
Sex	2.747236	15.599452	0.0000	Yes
SibSp	-0.257217	0.773200	0.0098	Yes
Parch	-0.102936	0.902184	0.3614	No
Fare	0.005845	1.005862	0.0044	Yes
Embarked	-0.123848	0.883514	0.2097	No

- 회귀계수(coef) 가 양수(+) 이면 종속변수가 일어날 확률(성공확률)과 양의 상관관계, 음수(-)이면 일어날 확률과 음(-)의 상관관계
- 회귀계수 수치는 $\ln$ 가 붙어 있는 odds이므로 $\ln$ 를 제거하여 해석해야 함.
 - $\Rightarrow$ Odds ratio로 보면 된다. (우측 분석결과)(
 - 예시) Fare 경우 0.0058
 - `import numpy as np`
 - `np.exp(0.0058)`
 - 1.0058168525658735 : $\Rightarrow$ 요금 1불 증가하는 경우 *survived* 1.00586 배 증가한다는 것이다.
 - (예시) Parch : 동반 부모와 자녀 수
 - `import numpy as np`
 - `(np.exp(-0.1029)-1)*100`
 - 9.77828093103501
 - $\Rightarrow$ 동반한 Parent(부모) Child(자녀)의 수가 1명 증가하는 경우 생존율 9.778% 감소한다.

참고) https://github.com/freejyb/statistics/blob/main/Week_12/regression.ipynb

Regression coefficient : Selection

3. 변수 선택 방법

- 전진 선택법(조건)(Forward Selection (Conditional))

: 스코어 통계의 유의수준을 기반으로 진입 검정을 수행하고 조건 모수 추정값에 따른 우도비 통계의 확률을 기반으로 제거 검정을 수행하는 단계별 선택 방법

- 전진 선택법(우도비)(Forward Selection (Likelihood Ratio))

: 스코어 통계의 유의수준을 기반으로 진입 검정을 수행하고 최대 편우도 추정값에 따른 우도비 통계의 확률을 기반으로 제거 검정을 수행하는 단계별 선택방법

- 전진 선택법(Wald)(Forward Selection (Wald))

: 스코어 통계의 유의수준을 기반으로 진입 검정을 수행하고 Wald 통계의 확률을 기반으로 제거 검정을 수행하는 단계별 선택 방법

- 후진제거법(조건)(Backward Elimination (Conditional))

: 조건부 모수 추정값에 기반한 우도비 통계의 확률을 토대로 제거 여부를 검정

- 후진제거법(우도비)(Backward Elimination (Likelihood Ratio))

: 최대 편우도 추정값에 기반한 우도비 통계의 확률을 토대로 제거 여부를 검정

- 후진제거법(Wald)(Backward Elimination (Wald))

: Wald 통계의 확률을 기반으로 제거 여부를 검정

R – Squared

What's the Best R-Squared for Logistic Regression?

Paul D. Allison (University of Pennsylvania) :
<https://statisticalhorizons.com/r2logistic/>

1. 독립변수에 기반하여 종속변수를 얼마나 잘 분류하는지를 측정하는 것
2. 모형이 더 복잡해질 필요가 있는지, 구체적으로 데이터를 잘 대표하기 위하여 추가적인 비선형항(nonlinearity)과 상호작용항이 필요한지를 검증하는 것

McFadden R2 (유사(pseudo) R2)

$$\text{공식 : } R^2_{\text{MCF}} = 1 - \ln(L_M) / \ln(L_0)$$

1. L_0 를 아무런 예측변수로 포함하지 않은 모형에 대한 우도함수의 값
2. L_M 을 추정된 모형에 대한 우도

이 공식의 원리는 $\ln(L_0)$ 이 선형 회귀분석에서의 잔차제곱합(residual sum of squares)과 동일한 역할
 결과적으로 이 공식은 "오차 분산(error variance)"의 감소비율에 해당

Cox and Snell R²

$$\text{공식 : } R^2_{\text{C\&S}} = 1 - (L_0 / L)^{2/n} \cdot (n = \text{표본수})$$

- ① 선형 회귀분석과 동일
 - ② 선형 회귀분석에서의 일반적인 R^2 는 정확히 이 공식에 의해 예측변수가 없는 모형과 있는 모형의 우도로 결정된다
 는 것이다. 그렇다면 이 측정치는 유사(pseudo) R^2 보다는 "일반화(generalized)" R^2 라고 부르는 것이 적절할 것이다.
 이와 대조적으로, McFadden R^2 는 OLS R^2 를 특별한 사례로 가지고 있지 않다.
 - ③ 이러한 Cox-Snell R^2 의 특성이 매우 매력적이라고 생각했는데, 특히 이 공식이 최우(maximum likelihood) 추정을 하는 다른 종류의 회귀분석에 자연스럽게 확장될 수 있기 때문이다.
- Cox-Snell R^2 는 상한값이 1.0보다 작다는 큰 문제가 있다. 상한값은 $1 - L_0^{2/n}$ 이 된다. 이는 1.0보다 상당히 작을 수 있으며, 오직 사건이 발생한 사례의 비중인 p 에 의존한다.

$$\text{upper bound} = 1 - [p(1-p)]^2$$

$p=0.5$ 일 때 0.75의 최대값을 가지며, $p=0.9$ 혹은 $p=0.1$ 일 경우 상한값은 0.48에 불과하다.

Model Fitness : AIC, BIC

***AIC(Akaike's information criterion) Akaike 정보 기준** : 로그우도를 독립변수의 수로 보정

- 1974년 일본 통계학자 [Hirotugu Akaike](#) 의 이름을 따서 명명
- 주어진 데이터 셋에 대한 통계 모델의 상대적인 품질을 평가하는 것 (*VAR 모형에서 차수 결정시 기준으로 사용*)
- 모델에 의해 손실된 정보의 양을 추정할 때 AIC는 모델의 **적합도**와 모델의 **단순성** 간의 균형을 다룬다.
- 적합성(Goodness of fit)**을 측정해주는 지표 : OLS 에서 adj R-Squared 역할과 동일하게 이해하면 됨.

AIC : 최대우도추정법에 의한 파라미터(β)에 대한, 변수 추가에 따른 penalty 항을 추가한 것!!!!

$$AIC = 2\ln(L) - 2k$$

Feature 판단 지표

- $2\ln(L)$** : 모형의 **적합도**를 의미, L : 모델이 데이터에 대해 얻은 최대 우도(maximum likelihood)
우도(Likelihood) L : 우도는 주어진 모델 파라미터가 관측된 데이터를 얼마나 잘 설명하는지를 나타내는 척도
- ⑦ L 이 크다는 것은 모델이 데이터를 잘 설명한다는 의미
AIC 계산에서는 우도의 로그 값을 사용하며, 이는 우도 값의 범위를 조정하고, 곱셈 대신 덧셈을 사용할 수 있게 해준다.
- $2k$** : k 는 모형의 추정된 **parameter** 개 수 ⑦ 해당 모형에 **벌점요소(penalty)**를 주기 위해 사용 :
 - ⑦ 실제로 어떤 모형이 $2\ln(L)$ 즉 적합도를 높이기 위해 여러 불필요한 파라미터를 사용할 수도 있다
 - ⑦ k 는 모델의 복잡성을 나타낸다. ⑦ 파라미터가 많을수록 모델은 더 복잡해지며, 과적합(overfitting)의 위험이 증가
- AIC에서는 모델의 복잡성에 대한 벌점(penalty)으로 $2k$ 를 사용 : **penalty Likelihood****
- ⑦ 즉 독립변수 수가 증가할수록 $2k$ 를 증가시켜 패널티를 부여하여 모델의 품질을 평가하는 의미로 이해하면 됨.
- ⑦ $2k$ 값이 커지면 AIC가 커진다.

AIC의 해석

변수 갯수 증가시 줘진 데이터에 대한 Likelihood는 증가하지만 패널티 항에 AIC가 증가하므로, 여러 모델 경우 중에서 **AIC 값이 낮은 것을 선택 : AIC가 낮다는 것은 즉 모형의 적합도가 높은 것을 의미**

$$AIC = T \log\left(\frac{SSE}{T}\right) + 2(k+2)$$

T : 추정에 사용하는 관측값의 수
 k : 모형에 있는 예측변수(predictor variable)의 수
 $k+2$: 예측변수(predictor variable) k 개의 계수, 절편, 잔차 고려하면 ⑦ $k+2$

Model Fitness : AIC, BIC

*SBC(Schwarz-Bayesian Information Criterion), BIC , 슈바르츠의 베이زي안 정보기준

$$SBC = 2\ln(L^*) - k \ln(n)$$

$2\ln(L^*)$: 적합도(goodness of fit)를 대변해주는 수 ⑦ 이 수가 커지면 SBC는 값이 감소

$k \ln(n)$: 벌점요소(penalty) , n : data 개수 ,

⑦ n 이 충분

(*)가 붙은 것은 이미 최적화가 된 어떤 상수(constant)라는 의미

⑦ 어떤 모형이 가장 적절한지 판단을 하기 위해 $2\ln(L^*)$ 를 이용해서 값을 추정하더라도 이 값을 높이기 위해 실제로 불필요하게 모형을 복잡하게 많은 parameter로 구성할 수도 있다. 이러한 경우를 방지하기 위해 이런 벌점요소(penalty) 주어 짐.

$k\ln(n)$ 은 값이 커지면 SBC가 커진다. SBC의 값이 크면 좋지 못한 모형이기때문에 $k\ln(n)$ 은 벌점요소(penalty)

$$BIC = T \log\left(\frac{SSE}{T}\right) + (k + 2) \log(T)$$

BIC는 AIC보다 매개변수의 수에 더 큰 제한을 주기 때문 n 이 충분히 큰 경우 대부분의 경우 $2k$ 의 2보다는 $\ln(n)$ 이 크기 때문에 SBC의 벌점요소(penalty)는 AIC의 경우보다 더 큰 제한 (harsher)은 두는 것 !!!

⑦ 큰 T 값에 대해 BIC를 최소화하는 것

Model Fitness : AIC

AIC 수학적 유도

- 정보 이론에서 모델의 예측 정보량으로 쿨백-라이블러 발산 (Kullback-Leibler divergence) 값으로 측정
- 쿨백-라이블러 발산 : 실제 분포와 모델 분포 간의 차이
- AIC는 이 발산을 최소화하는 모델을 선택하는 기준으로 사용

1. 로그 우도의 최대화

: 데이터 X 가 주어졌을 때, 모델의 파라미터 θ 에 대한 로그우도 함수 $\ln(L(\theta; X))$ 를 최대화하는 것이 목표이다.

2. 쿨백-라이블러 발산의 추정

: 모델이 실제 데이터 생성 과정을 얼마나 잘 근사하는지 측정하기 위해 쿨백-라이블러 발산 ($D_{KL}(p \parallel q)$)을 추정한다.
이 발산은 실제 분포 p 와 모델 분포 q 사이의 차이를 측정한다.

$$D_{KL}(p \parallel q) = \int p(x) \ln \frac{p(x)}{q(x|\theta)} dx, \quad p(x): \text{실제 데이터의 분포}, \quad q(x|\theta): \text{모델에 의해 추정된 분포}$$

3. AIC의 근사

: Akaike는 이 발산을 직접 계산하는 대신 로그 우도를 사용해 근사한다.
 실제 발산에 근접하기 위해 모델의 복잡성을 고려하는 항 $2k$ 를 더한다.

$AIC = -2\ln(L(\theta; X)) + 2k$, $-2\ln(L)$: 로그 우도의 최대화로 얻어지는 값, $2k$: 모델 복잡성을 보정하는 항

$$L(\beta, \sigma^2 | X, Y) = \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right)^n \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (Y_i - X_i^T \beta)^2 \right)$$

$$\log L(\beta, \sigma^2 | X, Y) = -\frac{n}{2} \log(2\pi) - n \log \sigma - \frac{1}{2\sigma^2} \|Y - X\beta\|^2$$

Classification Threshold

4. 추정확률 분류 기준값 (Threshold) 적용

▪ Classification Threshold (임계값)

로지스틱 회귀 값을 이진 카테고리에 매핑(Mapping)하려면 **분류 임계값(Classification Threshold, 결정 임계값)**을 정의

- ⑦ 값의 범위 : 0~1 사이
- ⑦ 로지스틱 회귀 알고리즘의 결과 값은 '분류 확률'이고, 그래서 이 확률이 특정 수준 이상 확보되면 훈련데이터가 해당 집단에 포함될지 여부를 결정
- ⑦ 대부분의 알고리즘에서 기본 임계값은 0.5 , 보수적일수록 임계값은 ?

(그러나 기업수가 불균형(정상기업 수 와 부도기업 수)인 경우 세분화하여 결과 확인 필요)

- 임계점 (Threshold) 가 1이면
- 확률이 1일때만 True 라고 예측하기 때문에 FP (실제값 False, 예측값 True 경우) 가 0, fall out = 0
- 임계점 (Threshold) 가 0이면
- 확률이 모두 True 라고 예측하기 때문에 TN (실제값 False, 예측값 False 경우) 가 0 , fall out = 1
- ⑦ 따라서, 임계점을 1~0 에서 거꾸로 조절이 필요하게 됨.
- ⑦ 일반적으로 Threshold 기준을 [0.025, 0.05, 0.075, ..., 0.3]와 같이 12가지로 세분화 하여 분석 결과 확인

Hyper-Parameter

2. Grid Search CV

```
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import GridSearchCV

lg = LogisticRegression()

params = {'penalty':['l2'],'C':[0.01, 0.1, 1, 5, 10]}

grid_clf = GridSearchCV(estimator = lg, param_grid=params,
                        scoring='roc_auc', cv=3, refit=True, n_jobs=-1)

grid_clf.fit(X_train,Y_train)

print('최적 하이퍼 파라미터 :{0}, 최적 평균 정확도 :{1:.3f}'.format(
    grid_clf.best_params_, grid_clf.best_score_))
>>>
최적 하이퍼 파라미터 :{'C': 5, 'penalty': 'l2'}, 최적 평균 정확도 :0.834
```

로지스틱회귀분석의 **feature** 독립성 가정 (다중공선성 X)

이를 규제하는 방법이 **panalty**로 L1, L2 규제가 있음.

하이퍼파라미터 값(C)은 규제강도 (α)의 역수인 ($\frac{1}{\alpha}$)의 의미 함.

Scoring : accuracy, roc_auc, f1 등 다양한 종류가 있다. 모델의 성능을 평가하는 지표로 사용된다.

CV (Cross Validation) : 교차검정을 의미하며 기본 값은 5로 설정되어 있다. 해당 코드는 데이터 셋을 3개로 분할하여 train,validation을 총 3번 진행하게 된다.

refit : 최적의 파라미터를 찾고 입력된 개체에 해당 하이퍼파라미터를 넣어 재학습하는 효과를 준다.

n_jobs : sklearn에는 CPU 병렬처리를 지원한다. 보통 Grid서치를 진행할 때 시간이 많이 소요되는 점이 있는데, 이를 코어 개수 만큼 병렬로 수행하면 빠른 결과 도출이 가능해진다.

참고)


GridSearchCV의 결과 값 보기
pd.DataFrame(grid_clf.cv_results_)

	mean_fit_time	std_fit_time	mean_score_time	std_score_time	param_C	param_penalty	params	split0_test_score	split1_test_score	split2_test_score	mean_test_score	std_test_score	rank_test_score
0	0.037433	0.002785	0.005716	0.001156	0.01	l2	{'C': 0.01, 'penalty': 'l2'}	0.753212	0.807558	0.864524	0.808431	0.045447	5
1	0.048315	0.011945	0.009007	0.006554	0.1	l2	{'C': 0.1, 'penalty': 'l2'}	0.807137	0.840152	0.855965	0.834418	0.020342	3
2	0.049477	0.003461	0.007789	0.002948	1	l2	{'C': 1, 'penalty': 'l2'}	0.813033	0.847502	0.840152	0.833562	0.014823	4
3	0.037029	0.008367	0.005054	0.002030	5	l2	{'C': 5, 'penalty': 'l2'}	0.814423	0.849001	0.839910	0.834445	0.014636	1
4	0.044900	0.009611	0.004585	0.002008	10	l2	{'C': 10, 'penalty': 'l2'}	0.814471	0.849098	0.839717	0.834429	0.014622	2

Hyper-Parameter

2. Grid Search CV 순서도

로지스틱 회귀분석의 Hyper-Parameter



Logistic Regression Analysis

로지스틱 회귀분석 이점 로지스틱 회귀 : AI & 머신러닝 분야 중요한 기법

1) 간편성/ 편리성

- 다른 ML 기법/ 딥러닝 보다 수학적으로 덜 복잡하고, 계산 집약적이지 않다. ⑦ 쉽게 구현 가능
- 계산이 덜 복잡하기 때문에 문제 해결 및 오류 수정도 더 쉽다

2) 속도

ML 프로젝트를 시작하는 조직이 성과를 빠르게 실현하는 데 이상적

3) 유연성

로지스틱 회귀분석을 사용하면 두 개 이상의 유한한 결과가 있는 질문에 대한 해답 제시

4) 가시성

다른 데이터 분석기법을 사용할 때보다, 개발자에게 내부 소프트웨어 프로세스에 대한 더 높은 가시성

5) 데이터 전처리 사용

은행 거래와 같이 값의 범위가 넓은 데이터를 더 작고 유한한 값 범위로 정렬 ⑦ 보다 정확한 분석을 위해 다른 ML 기법을 사용하여 작은 데이터 세트를 처리 가능

Confounding Variable / Spurious Variable

로지스틱 회귀분석 이점

- 로지스틱 회귀분석 : 선형 분류
- 변수 자체에 correlated된 관계가 있을 경우 하나의 변수만을 이용하는 것은 다른 결과를 가져 올 수 있다.

Confounding Variable / Spurious Variable

Confounding Variable

원인변수(X)와 결과변수(Y) 모두에 영향을 미치면서, 그리고 이때, X와 Y 사이에도 인과관계가 존재할 경우에 원인변수(X)와 결과변수(Y) 모두에 영향을 미치는 변수가 교란변수(Z)

- ⑦ 교란변수(Z)의 존재는 X와 Y 사이의 인과관계의 크기를 실제보다 크거나 작은 것으로 보이게 교란시키게 된다.

Spurious Variable

원인변수(X)와 결과변수(Y) 모두에 영향을 미치지만, 이들 간의 공동변화를 모두 설명하는 변수를 의미

- ⑦ X와 Y 사이에는 실제로는 인과관계가 없으나 있는 것처럼 보이게 하는 변수

Confounding Variable / Spurious Variable

Simpson's Paradox and Experimental Research

Suzanne Ameringer, PhD, RN, Assistant Professor, Ronald C. Serlin, PhD, Chair, and Sandra Ward, PhD, RN, FAAN Helen Denne Schulte Professor (2009)

There are three conditions that must be present for **confounding** to occur:

1. The confounding factor must be associated with both the risk factor of interest and the outcome.
2. The confounding factor must be distributed unequally among the groups being compared.
3. A confounder cannot be an intermediary step in the causal pathway from the exposure of interest to the outcome of interest.

https://sphweb.bumc.bu.edu/otlt/mph-modules/bs/bs704-ep713_confounding-em/BS704-EP713_Confounding-EM3.html

Confounding Variable / Spurious Variable

<https://sphweb.bumc.bu.edu/otlt/MPH-Modules/PH717-QuantCore/PH717-Module11-Confounding-EMM/PH717-Module11-Confounding-EMM5.html>

Confounding Variable : 분석 전 Research Design 단계에서 최소화 방안

- **Randomization** : 무작위 실험 ⑦ Confounding Variable 가 그룹 간에 균등 분배되기 때문에 Confounding Variable 가 주는 영향을 통제
- **Restriction of Enrollment** : 실험 대상이 모두 교란 변수의 동일 레벨을 가지도록 한다.
- **Matching Compared Groups** : 비교 대상이 되는 실험군, 대조군을 구성하는 집단이 다르게 분포되었다면, Confounding Variable 에 맞게 각 집단 내 피실험자들을 매칭하여 비교

Confounding Variable : Analysis 단계에서 최소화 방안

- **Standardization** : 표준정규분포(Z-score)의 속성을 갖도록 피처가 재조정되는 것
- Stratified Analysis (계층적, 층화적 분석) : 모집단을 먼저 서로 겹치지 않는 여러 개의 계층으로 분할 후, 각 층에서 단순임의추출법에 따라 배정된 표본을 추출하는 방법
- Multiple Variable Regression Analysis

⑦ 2개 이상의 범주에서의 로지스틱 회귀분석은 성능 저하 ⑦ (대안) ⑧

Multinomial Logistic Regression

- 다항 로지스틱 회귀(Multinomial Logistic Regression)는 종속변수가 세 개 이상의 상호 배타적인 범주를 가지는 경우에 사용되는 통계 기법
- 이 방법은 각 범주에 속할 확률을 모델링하며, 특히 순서가 지정되지 않은 범주형 데이터에 적합
- 다항 로지스틱 회귀는 이진 로지스틱 회귀의 확장으로 볼 수 있으며, 여러 개의 로짓(logit) 함수를 사용하여 각 범주에 대한 확률을 추정

모델 추정

종속변수 Y 가 k 개의 범주를 가진다고 할 때, 다항 로지스틱 회귀는 특정 범주 j 에 대한 확률을 다음과 같이 모델링

$$\log \left(\frac{P(Y=j|X)}{P(Y=k|X)} \right) = \beta_{j0} + \beta_{j1}X_1 + \beta_{j2}X_2 + \dots + \beta_{jn}X_n$$

- $P(Y=j|X)$: 주어진 독립변수 X 에 대해 종속변수 Y 가 특정 범주 j 에 속할 확률
- $P(Y=k|X)$ 는 기준범주 k 에 속할 확률
- $\beta_0, \beta_1, \dots, \beta_{jn}$ 은 회귀 계수 ● 로짓(logit) 함수의 절편과 기울기
- $X_1, X_2, \dots, X_n$: 독립변수.

- 다항 로지스틱 회귀에서는 일반적으로 하나의 범주를 기준범주로 설정하고,
- 나머지 범주들의 로짓을 이 기준범주와 비교하여 모델링한다.
- 기준범주에 대한 로짓은 0으로 설정되며, 이는 모델의 식별성(identifiability)을 보장하기 위함이다.

사례: 각 독립변수가 졸업생이 특정 직업 분야를 선택하는 데 어떻게 영향을 미치는지를 분석

•종속변수(Y): 선택한 직업 분야

•독립변수: X_1 : 전공 분야(공학=0, 의료=1, 교육=2, 예술=3), X_2 : 졸업 성적(GPA), X_3 : 인턴 경험의 유무(없음=0, 있음=1)

예술 분야를 기준 범주로 설정

- 공학 분야에 대한 확률 $\log \left(\frac{P(Y=\text{공학}|X)}{P(Y=\text{예술}|X)} \right) = \beta_{10} + \beta_{11}X_1 + \beta_{12}X_2 + \beta_{13}X_3$
- 의료 분야에 대한 확률 $\log \left(\frac{P(Y=\text{의료}|X)}{P(Y=\text{예술}|X)} \right) = \beta_{20} + \beta_{21}X_1 + \beta_{22}X_2 + \beta_{23}X_3$
- 교육 분야에 대한 확률 $\log \left(\frac{P(Y=\text{교육}|X)}{P(Y=\text{예술}|X)} \right) = \beta_{30} + \beta_{31}X_1 + \beta_{32}X_2 + \beta_{33}X_3$

Multinomial Logistic Regression

회귀계수 추정

- 다항로지스틱 회귀 모델의 계수는 최대우도추정법(Maximum Likelihood Estimation, MLE)을 사용하여 추정
 - 이 방법은 관측된 데이터가 주어진 모델 파라미터에 대해 얼마나 "우도(likelihood)"가 높은지를 계산하고, 이 우도를 최대화하는 파라미터 값을 찾는다.

해석

- 다항 로지스틱 회귀 모델의 계수는 로짓 스케일에서 해석.
- 계수의 부호와 크기는 독립변수가 특정 범주에 속할 로그 오즈(log odds)에 미치는 영향의 방향과 강도를 나타냅니다.
- 예를 들어, 어떤 계수가 양수(+)라면 해당 독립변수의 증가는 기준범주에 비해 해당 범주에 속할 확률의 증가와 관련이 있음을 의미한다.

Multinomial Logistic Regression

사례

1. 신용등급 분류

- 문제 정의: 개인이나 기업의 신용 정보를 바탕으로 신용등급(예: AAA, AA, A)을 분류
- 종속변수: 신용등급 범주
- 독립변수: 연소득, 부채 비율, 연체 이력, 신용 이용기간, 신용 조회 횟수 등

→ 다항 로지스틱 회귀를 사용하여 각 신용정보가 특정 신용등급에 속할 확률을 예측할 수 있다. 이는 은행이나 금융기관이 대출 승인, 이자율 설정, 위험 관리 등을 결정하는 데 도움을 준다.

2. 투자자 유형 분류

- 문제 정의: 투자자의 특성과 행동을 바탕으로 투자 성향(예: 보수적, 중립적, 공격적)을 분류
- 종속변수: 투자자의 투자성향 범주
- 독립변수: 투자 경험, 소득 수준, 자산 규모, 위험 선호도, 투자 목표 등

→ 다항 로지스틱 회귀 분석을 통해 투자자의 특성과 행동이 투자 성향에 미치는 영향을 분석할 수 있다. 이 정보는 금융 상품의 맞춤형 추천이나 투자 조언 서비스에 활용

3. 경제 위기 예측

- 문제 정의: 경제 지표를 바탕으로 경제 상황(예: 호황, 보통, 침체)을 예측
- 종속변수: 경제 상황의 범주 (호황, 보통, 불황)
- 독립변수: GDP 성장률, 실업률, 인플레이션율, 주가지수, 이자율 등

→ 다항 로지스틱 회귀를 사용하여 경제 지표가 특정 경제 상황에 속할 확률을 예측할 수 있다. 이는 정부나 중앙은행이 경제 정책을 수립하고 위기 관리 전략을 개발하는데 도움을 준다.

4. 시장 세분화

- 문제 정의: 소비자의 소득, 소비 패턴, 라이프스타일 등을 바탕으로 시장세분화 실시
- 종속변수: 시장 세그먼트의 범주 (예: 고소득 젊은 전문가, 가족 중심의 중산층 등)
- 독립변수: 연령, 소득, 교육 수준, 구매 이력, 라이프스타일 특성 등

→ 다항 로지스틱 회귀 분석을 통해 소비자 그룹을 명확하게 분류하고, 각 세그먼트의 특성과 필요를 이해할 수 있다. 이는 타겟 마케팅 전략과 제품 개발에 중요한 정보를 제공

* 참조 : 개별 주식 예측 3

A 항공 주가 상승 또는 하락을 예측,

- p = 상승확률
- $(1-p)$ = 하락확률

$$\text{Log}\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 \text{WTI 수익률} + \beta_2 \text{환율수익률} + \beta_3 \text{여행객수} + \varepsilon$$

- 회귀계수 추정

MLE(maximum likelihood estimation) 이용

- ⑦ 확률값 계산
- ⑦ 확률 값 > 임계치 : 상승, 확률값 < 임계치 : 하락

Sklearn

```
from sklearn.linear_model import LogisticRegression
```

`predict` : input에 따른,분류결과(회귀분석)결과를 반환하는 (1또는 0) 메서드

`predict_proba` : 예측과정에서 각분류별 확률을 보여주는 메서드

- ⑦ [y가 0이 될 확률, 1이 될 확률]

GitHub 참고

* Poisson Regression

포아송 회귀분석(Poisson Regression)

- 포아송 회귀분석(Poisson Regression)은 계수 데이터(count data) 또는 이벤트 발생 횟수 데이터를 분석하는 데 사용되는 통계 기법
- 종속변수가 포아송 분포를 따르고**, 평균발생빈도가 독립변수에 의해 설명될 수 있다고 가정
- 포아송 회귀분석은 특히 시간 간격 내 이벤트 발생 횟수와 같이 비음수(-)정수 값을 가지는 데이터에 적합

포아송 회귀분석의 기본 형태

$$\log(\lambda_i) = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_k X_{ki}$$

종속변수 : i번째 관측치의 기대값 (평균발생빈도)

사용

- 사고 발생 횟수, 병에 걸린 사람의 수, 특정 지역에서의 범죄 발생 횟수 등 이벤트 발생 횟수를 분석할 때
- 데이터가 비음수 정수이며, 평균과 분산이 비슷한 수준일 때(과분산이 심각하지 않을 경우)

한계

•과분산(Overdispersion)

: 포아송 분포는 평균과 분산이 같다는 성질을 가지고 있다. 실제 데이터에서 분산이 평균보다 훨씬 클 경우(과분산), 포아송 회귀모델은 적합하지 않을 수 있다.

⑦ 이런 경우 음이항 회귀(Negative Binomial Regression) 같은 대안적 모델을 고려할 수 있다.

•제로 인플레이션(Zero Inflation)

: 데이터에 예상보다 많은 0이 포함되어 있을 경우, 표준 포아송 모델보다 제로 인플레이션 포아송 모델(ZIP)이나 제로 인플레이션 음이항 회귀모델(ZINB)을 사용하는 것이 적합할 수 있다.

* Poisson Regression

Poisson Regression과 Logistic regression 비교

- 포아송 회귀분석과 로지스틱 회귀분석은 모두 일반화 선형 모델 (Generalized Linear Models, GLMs)의 일종
- 종속변수의 분포와 링크 함수(link function)가 다르다는 점에서 차이가 있다.

구분	Poisson Regression	Logistic regression
목적	시간 간격 내 이벤트 발생 횟수나 공간 단위 내 이벤트 발생 횟수와 같은 데이터를 분석할 때 적합	▪ 이진 결과(예: 성공/실패, 예/아니오)를 가지는 종속변수를 모델링하는 데 사용 ▪ 특정 조건이나 특성이 주어졌을 때 이벤트의 발생 확률을 추정하는데 적합
종속변수	횟수변수 (비음수 정수 값, 예: 사고 횟수, 전화 통화 횟수).	범주형변수 : 이진 값(0 또는 1)
분포	▪ 포아송 분포를 가정 ▪ 이벤트 발생이 독립적이며, 특정 시간 간격이나 공간에서의 평균 발생 빈도가 일정하다는 가정에 기반	▪ 이항 분포를 가정 ▪ 종속변수의 결과가 성공 또는 실패와 같은 두 가지 가능한 결과 중 하나를 가진다는 것을 의미
Link function	$\ln(\lambda)$, $\lambda = y$ 의 평균 로그 링크함수를 사용하여 종속변수의 평균과 독립변수 간의 선형 관계를 모델링	$\ln\left(\frac{p}{1-p}\right)$, $p =$ 사건발생확률, y 의 조건부확률 ▪ 로짓 함수(logit function)를 사용하여 종속변수의 성공 확률과 독립변수 간의 관계를 모델링 ▪ 로짓 링크 : 확률을 0과 1 사이의 값으로 제한

예제

https://github.com/freejyb/fin_stats

Seemingly Unrelated Regression, SUR

SUR (Seemingly Unrelated Regression)

- 여러 회귀 모델이 서로 독립적으로 보이지만, 오차항이 상관되어 있을 때 이를 고려하여 효율적인 추정을 제공하는 통계적 방법 ⑦ 무관회귀분석
- 1962년 아놀드 진버그(Arnold Zellner)에 의해 개발
- 여러 다른 종속 변수에 대한 회귀 모델들이 있을 때, 이 모델들 사이에 오차 항의 상관관계가 존재하는 경우에 유용

SUR의 기본 아이디어

- 여러 회귀 방정식으로 구성하는데, 각 방정식은 다른 종속변수를 가지지만, 같은 독립변수를 사용할 수 있다.
- 이 모델들은 "무관해 보이지만(seemingly unrelated)" 실제로는 오차항이 상관되어 있어, 이 상관관계를 고려하여 추정하는 것이 중요하다.

SUR 모델의 형태

$$\begin{aligned} Y_1 &= X_1\beta_1 + \epsilon_1 \\ Y_2 &= X_2\beta_2 + \epsilon_2 \\ &\vdots \\ Y_k &= X_k\beta_k + \epsilon_k \end{aligned}$$

Y_i 는 i 번째 종속 변수
 X_i 는 i 번째 회귀 모델의 설명 변수 행렬
 β_i 는 i 번째 회귀 모델의 계수 벡터
 ϵ_i 는 i 번째 회귀 모델의 오차 항

SUR 추정 방법

- 일반적으로 최대우도법(Maximum Likelihood Estimation, MLE) 또는 일반화된 최소제곱법(Generalized Least Squares, GLS)을 사용하여 수행
- 이 과정에서 모든 회귀 방정식의 오차 항의 공분산 행렬을 추정하고, 이를 사용하여 계수 벡터의 추정치를 얻는다.

Seemingly Unrelated Regression, SUR

사례

사례1: CAPM 검증

n개의 식을 추정하는데 있어 오차 연관되어 있어 변수오차문제(error-in variables problem)가 발생하면 잘못된 추정문제 해결을 위해

사례2 : 경제학 분야에서의 소비 패턴 분석

저소득층과 고소득층이 식료품, 의류, 교육, 여가 활동에 지출하는 비율이 어떻게 다른지 알아보고자 할 수 있다.

문제 설정

각 소득 그룹별로 다른 종류의 지출(식료품, 의류, 교육, 여가)에 대한 회귀모형을 설정

이때, 각 모델의 오차항은 서로 상관관계를 가질 수 있다. 왜냐하면 특정 외부 요인(예: 경제 상황, 인플레이션, 정책 변화 등)이 모든 지출 유형에 공통적으로 영향을 줄 수 있기 때문

사례 3 : 마케팅 분야에서의 제품별 판매량 예측

대형 소매업체는 다양한 제품군(예: 가전제품, 의류, 식료품)에 대한 판매량을 예측하고자 합니다. 각 제품군의 판매량은 서로 다른 요인들에 의해 영향을 받을 수 있지만, 마케팅 캠페인이나 계절적 요인과 같은 공통적인 요인에 의해 동시에 영향을 받을 수도 있다.

문제 설정

각 제품군별로 판매량에 영향을 미치는 요인들을 분석하는 여러 회귀모형을 설정합니다. 이때, 마케팅 캠페인이나 계절적 요인과 같은 공통적인 요인으로 인해 모델 간의 오차항이 상관관계를 가질 수 있습니다.

SUR 적용

무관회귀분석을 통해 모든 제품군에 대한 회귀모형을 동시에 추정함으로써, 각 제품군의 판매량에 영향을 미치는 독립적인 요인과 공통적인 요인을 모두 고려할 수 있습니다. 이를 통해 소매업체는 보다 정확한 판매량 예측을 할 수 있으며, 효과적인 마케팅 전략을 수립할 수 있다.

Seemingly Unrelated Regression, SUR

장점	단점
▪ 효율성: 오차 항의 상관관계를 고려함으로써, SUR은 각 회귀 모델을 개별적으로 추정하는 것보다 더 효율적인 추정치를 제공할 수 있다. ▪ 일관성: 오차 항 사이의 상관관계가 있을 때, SUR 추정치는 일관성(consistency)을 유지한다. ▪ 유연성: 다양한 종속 변수에 대한 모델을 동시에 추정할 수 있어, 복잡한 경제적, 사회적 상호작용을 모델링하는데 유용	• 모델의 복잡성과 계산량이 증가 • 모든 회귀식의 오차항 간에 상관관계가 없다면, OLS와 같은 전통적인 방법이 더 효율적일 수 있다. • 무관회귀분석은 복잡한 데이터 구조를 가진 연구에서 유용하게 사용될 수 있으며, 변수 간의 상호작용과 관계를 더 깊이 이해하는 데 도움을 준다.

Statsmodels

SUR 클래스를 사용하여 모델을 정의

fit() 메소드를 통해 모델을 추정

summary() 메소드를 사용하여 추정 결과를 출력

https://github.com/freejyb/fin_stats

대안적 접근 방법

개별 회귀 모델 추정: 각각의 회귀 모델을 독립적으로 추정하고, statsmodels의 OLS 클래스를 사용한다.

오차항의 상관관계 분석: 추정된 모델의 잔차(residuals)를 분석하여, 모델 간의 잔차가 상관관계를 가지는지 확인할 수 있다.

Quantile Regression


분위수 회귀분석 : Quantile Regression

$$Q_{\tau}(y_i) = \beta_0(\tau) + \beta_1(\tau)x_{i1} + \cdots + \beta_p(\tau)x_{ip}$$

선형회귀분석 대안으로 활용되며 **회귀계수는 τ 분위의 효과로 인해 τ 에 따라 변동**

Quantile Regression Model Equation for the τ th quantile

구분	분위수 회귀분석	선형회귀분석
주정 계수	종속변수의 조건부 분위수 값 (conditional τ -quantile) 추정	최소제곱법을 이용하여 설명변수에 따른 종속변수의 조건부 평균 을 추정
내용	Koenker, Basset(1978)에 의해 제안 선형회귀분석의 조건 (정규성, 등분산성) 이 충족되지 않는 경우 사용할 수 있는 선형회귀분석 대안 : 데이터 평균 외부의 변수 관계를 이해할 수 있으므로 비정규분포를 따르고 예측 변수와 비선형 관계를 갖는 결과를 이해하는데 유용 ⑦ 선형 회귀의 확장 버전 ⑦ 분위수 회귀는 데이터의 다양한 분위수에 대한 조건부 값을 모델링하여 더 폭넓은 데이터 구조를 이해할 수 있게 한다.	- 독립변수에 대한 종속변수의 평균적 관계만 파악할 수 있는 정보만 제공 - 정규성이나 등분산성의 가정 특히 이상치에 영향을 받는다.
loss function)	Mean Squared Error	Pinball loss 함수 ⑦ Quantile Loss Function)또는 체크함수 (Check Function)



Quantile Regression

Quantile regression 특징

- **이상치에 대한 강건함**: 분위수 회귀는 이상치에 대해 더 강건하며, 특히 중앙값(0.5 분위수) 회귀는 이상치의 영향을 받지 않는다.
- **데이터의 비대칭성 탐색**: 데이터가 비대칭적일 때, 분위수 회귀를 사용하면 데이터의 다양한 측면을 탐색할 수 있다. **조건부 분포의 다양성**: 분위수 회귀는 종속변수의 조건부 분포가 균일하지 않고 변화할 수 있음을 인정하고, 이를 모델링할 수 있다.

Quantile regression 사용

- 중위수, 혹은 분위수 값을 예측하고 싶을 때
- 점 추정이 아닌 **구간추정을 통해 결과의 정확도를 높이고 싶을 때**
- 평균이 아닌 **상위 또는 하위 등 극값에서의 분포에 관심이 있는 경우 유용하며**, 자료의 분포나 이상치에 크게 영향을 받지 않는 강건성(robustness)을 가진다.
- 각 분위수별 **독립변수의 범주들 간 종속변수의 격차에 큰 차이가 존재하는 경우**
- 선형 회귀분석 가정 위배시 (정규성을 만족하지 않을 때, 오차항의 분포에 대한 이분산성(heteroscedasticity)이 존재할 경우는 경우)
- 결과 변수 증가에 따른 오차의 분산도 커질 때
- **증권시장 분석에 많이 활용**
- **계량경제학에서 사용**

머신러닝 활용

1) GradientBoostingRegressor

: loss='quantile' 명령어를 통해 분위회귀를 할 수 있게 제공. **분위수 회귀의 주요 특징**은 원하는 분위 수를 입력

2) Quantile Random Forests

- 일반적인 랜덤포레스트 모델은 각각의 의사결정나무의 타겟변수의 평균 값을 계산
- 분위 RF는 전체 분포로 변환하여 분위 예측

Quantile Regression

Quantile Regression Model Equation for the τ th quantile

$$Q_{\tau}(y_i) = \beta_0(\tau) + \beta_1(\tau)x_{i1} + \cdots + \beta_p(\tau)x_{ip}$$

i: data index

$$y_i = \beta_{\tau}x_i + u_{\tau i}, \quad Q_{\tau}(y_i | x_i) = \beta_{\tau}x_i \quad (i = 1, 2, \dots, n)$$

y의 τ 번째 조건부 분위(conditional quantile)

$$\text{Min} \left[\sum_{y_i > \beta x_i} \tau | y_i - \beta x_i | + \sum_{y_i < \beta x_i} (1 - \tau) | y_i - \beta x_i | \right]$$

양의 오차에는 τ 의 가중치를 부여
음의 오차에는 $(1 - \tau)$ 의 가중치 부여

Quantile regression 손실함수

Pinball loss 함수

- 선형회귀분석 : MSE
- 분위 회귀분석 : **Pinball loss**

최적의 분위수 방정식 : **중위수 절대편차(MAD: Median Absolute Deviation) 값을 최소화**

$$MAD = \frac{1}{n} \sum_{i=1}^n \rho_{\tau}(y_i - (\beta_0(\tau) + \beta_1(\tau)x_{i1} + \cdots + \beta_p(\tau)x_{ip}))$$

ρ 함수는 오차의 분위수와 전체적인 부호에 따라 오차에 비대칭 가중치를 부여하는 손실함수 ρ 은 아래의 형태를 취함.

$$* \rho_{\tau}(u) = \tau \max(u, 0) + (1 - \tau) \max(-u, 0)$$

- result = quantreg.fit(q=0.5)
- 만약 분위수가 0.5 보다 크게 설정한 경우: 과소 추정된 예측값에 대한 **penalty**를 더 부여함
- 만약 분위수가 0.5 보다 작을 경우: 과대 추정된 예측값에 대한 **penalty**를 더 부여함

$$\rho_{\tau}(y - \hat{y}) = (y - \hat{y}) \times (\tau - I(y < \hat{y}))$$

τ : 관심있는 분위수 값(0.1, 0.2, ..., 0.9)
y: 실제 값, $\hat{y}$: 예측값
I: 지시함수로, 조건이 참이면 1, 거짓이면 0

https://www.statsmodels.org/devel/examples/notebooks/generated/quantile_regression.html

<https://github.com/freejyb/kdigital/blob/main/Quantile%20regression.ipynb> 참고

Quantile Regression

Quantile regression 연구사례

- 자본시장연구원 : 통화정책과 자본시장 여건 변화가 자산시장에 미치는 영향 : 주택시장
- 분위회귀분석을 적용한 단독주택의 가격형성요인에 관한 연구: 서울시 소재 단독주택을 대상으로 대한지리학회지 제49권 제5호 2014(690~704)
- 상업용 부동산 실거래가에 영향을 미치는 요인에 관한 연구: 부산시를 사례로 2022 분석방법으로 다중회귀분석과 분위회귀분석으로 변수 간의 인과관계를 조사
- 분위회귀분석을 활용한 기업규모별 고용 성장에 관한 연구 2015
- 청소년 삶의 만족도 관련요인 분석 2018

statsmodels 라이브러리의 QuantReg 클래스를 사용하여 분위수 회귀를 구현

https://github.com/freejyb/fin_stats 참고

Weighted Regression

가중회귀분석 필요성

- 선형 회귀분석 가정 : 잔차분산이 일정(등분산성) ❶ 성립하지 않은 경우 즉, **이분산성 (heteroscedasticity)인 경우가 중최소제곱법을 활용하여 잔차의 이분산성을 해결 사용할 수 있는 방법** → 올바른 가중치를 사용하여 가중된 잔차제곱합을 최소화함으로써 분산이 일정한(등분산성) 잔차를 생성
- ❷ 회귀 모델에서 모든 관측치가 동일한 중요도를 가지지 않을 때 사용하는 기법
- 1) 이상치(outlier)에 영향을 받는 Robust 회귀모형을 만들고자 하는 경우

가중치 결정

- 분산을 아는 경우 (거의 없지만) ❶ **이상적인 가중치는 오차 분산의 역수**
- 대용치로 분산이 예측 변수에 비례하는 경우,

$$W_{ii} = \frac{1}{\sigma_i^2}$$

 먼저 가중치가 없는 최소제곱법을 이용하여 회귀모형을 구하고 여기서 잔차를 구한 후
 - ❶ 잔차의 절대 값을 반응변수, 오차 분산에 영향을 주는 변수를 설명변수로 하는 가중치 없는 최소제곱법을 이용하여 회귀모형을 구한 후
 - ❶ 첫번째 와 두번째 대응하는 적합 값을 구하고 가중치를 분산의 역수를 설정한 한 후
 - ❶ 가중 최소제곱법을 이용하여 회귀모형을 구함.
- ❶ 일반적으로 분산이 작은 관측치에는 상대적으로 큰 가중치가 부여되고 분산이 큰 관측치에는 상대적으로 작은 가중치가 부여 : 가중치가 크다는 것 - 해당 가중치가 제곱합에 많은 기여를 한다 - 분산이 작은 관측치는 신뢰할 수 있다 - 분산이 큰 관측치는 신뢰하기 어렵다.

가중 회귀분석의 적용

- **이분산성이 있는 데이터**: 오차의 분산이 일정하지 않고, 특정 패턴을 따르는 경우(예: 오차의 분산이 독립변수의 값에 따라 증가하는 경우)에 사용
- **신뢰도가 다른 관측치**: 일부 데이터 포인트가 다른 데이터 포인트보다 더 신뢰할 수 있는 경우, 신뢰도가 높은 데이터에 더 많은 가중치를 줄 수 있다.
- **표본 크기 조정**: 다른 크기의 표본에서 온 데이터를 분석할 때, 표본크기에 비례하여 가중치를 부여하여 분석할 수 있다.

<https://www.statsmodels.org/devel/examples/notebooks/generated/wls.html>

Weighted Regression

가중 최소제곱법

: 회귀 모수의 오차항 분산에 반비례(역수)하는 가중치를 부여하여 가중 오차제곱합을 최소화 하는 방법

⑦ 등분산성이 성립하지 않는 경우, 즉 어떠한 오차의 분산은 크고, 어떠한 오차항의 분산은 작다면 여기에 가중치를 적용하여 등분산성을 맞춰주는 것

일반 선형회귀계수 추정

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \epsilon$$

$$\hat{\beta} = (X^T X)^{-1} X^T \mathbf{y}$$

일반 회귀 Gradient equation

$$-2 \sum_i r_i \frac{\partial f(x_i, \beta)}{\partial \beta_j} = 0, \quad j = 1, \dots, m.$$

가중 선형회귀계수 추정

$$\sum_{i=1}^n w_i (Y_i - (\beta_0 + \beta_1 X_{1i} + \dots + \beta_n X_{ni}))^2$$

$$\hat{\beta} = (X^T W X)^{-1} X^T W \mathbf{y}$$

가중 회귀 Gradient equation

$$-2 \sum_i w_{ii} \frac{\partial f(x_i, \beta)}{\partial \beta_j} r_i = 0, \quad j = 1, \dots, m$$

https://github.com/freejyb/fin_stats
가중 회귀분석(Weighted Regression)

* Geographically Weighted Regression

지리가중회귀분석(Geographically weighted regression)

지리가중회귀분석은 공간 단위로 수집된 자료를 분석할 때 쓰이는 기법

- 도시 및 지역에서 수집된 공간자료는 근접한 위치에서 수집된 사례일수록 더 높은 관련성을 가지는 특징
- 교육 성과와 소득의 관계가 연구 영역에 걸쳐 일관되는지?
- 높은 산불 빈도를 설명하는 주요 변수는 무엇인지?
- 아이들의 시험 성적이 높은 지역은 어디인가요? 관련 있는 특성은 무엇인가요? 각 특성이 가장 중요한 곳은 어디인가?

Geographically Weighted Regression (GWR) is one of several spatial regression techniques used in geography and other disciplines. GWR evaluates a local model of the variable or process you are trying to understand or predict by fitting a regression equation to every feature in the dataset. GWR constructs these separate equations by incorporating the dependent and explanatory variables of the features falling within the neighborhood of each target feature. The shape and extent of each neighborhood analyzed is based on the **Neighborhood Type and Neighborhood Selection Method** parameters. GWR should be applied to datasets with several hundred features. It is not an appropriate method for small datasets and does not work with multipoint data

<https://pro.arcgis.com/en/pro-app/latest/tool-reference/spatial-statistics/how-geographicallyweightedregression-works.htm>

* Locally Weighted Regression

Locally Weighted Regression

- 1964년 Savitsky와 Golay
 - ⑦ 일반적으로 Savitzky-Golay 필터 라고 하는 LOESS (locally estimated scatterplot smoothing)에 해당하는 방법을 제안
 - William S. Cleveland 는 1979년에 이 방법을 재발견하여 고유한 이름을 부여
 - Cleveland와 Susan J. Devlin (1988)에 의해 추가로 개발
 - LOWESS : locally weighted polynomial regression.
-
- 선형 회귀분석 : 입력(X)과 출력(Y) 간의 선형 관계를 계산하는데 사용되는 지도학습 알고리즘
 - **Locally Weighted Regression : 지도학습 알고리즘이면서, 비모수적 알고리즘**
 - ⑦ X와 Y 사이에 비선형 관계가 있는 경우 예측에 사용
 - ⑦ 계산하는 동안 멀리 떨어져 있는 점보다 근처에 있는 학습 세트의 점에 더 높은 "선호도"가 부여

LWR 비용함수

$$J(\theta) = \sum_{i=1}^m w^{(i)} (\theta^T x^{(i)} - y^{(i)})^2 \quad w^{(i)} = \exp\left(\frac{-(x^{(i)} - x)^2}{2\tau^2}\right)$$

<https://www.geeksforgeeks.org/implementation-of-locally-weighted-linear-regression/> (코드 참조)

Partial least squares regression

1. PLS 회귀분석 필요성

원 데이터 대신 상관관계가 없는 성분 집합으로 예측 변수를 줄이고 이러한 성분에서 최소 제곱법을 수행하는 방법 (유용한 경우)

부분 최소 제곱법은 예측 변수가 매우 다중공선성이거나, 예측변수의 수가 관측치의 수보다 많으며 최소제곱법(OLS)에서 계수를 생성하지 못하거나 표준오차가 높은 계수를 생성할 경우에 특히 유용

❶ **PLS 접근법은 상호연관성이 있는 독립변수에 대해 안정적으로 정확히 예측하는 분석 방법**

2. 분석 원리

Partial Least Squares 회귀분석은 수많은 원본 데이터를 적은 수의 직교요소(orthogonal factors)들로 표현되는 새로운 변수 공간으로 선형투영 (linear transition) 하는데 기초하고 있다.

- ❶ principle component regression (PCR) 과 같은 몇몇 유사한 접근법과 달리 이러한 직교 factor들은 종속변수와 무관화된 상관관계를 갖도록 하는 방향으로 선택
- ❷ 이러한 factor들을 많이 갖게 되면 PLS 모델은 기존의 multiple linear regression과 동일한 형태를 띠도록 된다.
- ❸ PLS 접근은 핵심 직교 factor들이 주요 몇개의 주성분 (principle components)들에 낮은 연관성을 가지고 있더라도 독립변수와 종속변수 사이에 관계를 예측할 수 있도록 해준다.

https://en.wikipedia.org/wiki/Partial_least_squares_regression 참조

Panel Analysis (Regression)

패널자료(panel data)

panel data = cross-sectional data + time series data : 패널자료에는 패널그룹과 시간이 변수로 특정되어 있어야 함.

패널자료(panel data)

: 동일한 조사대상개체(예: 개인, 가구, 기업, 국가)들로부터 여러시점에 걸쳐 반복적으로 수집한 자료

패널데이터를 이용한 계량경제분석으로서

시계열 분석과 횡단면 분석을 동시에 수행하는 회귀분석의 분석 방법

- **Balanced panel data** : 각 패널 그룹에서 모든 시간에서 변수데이터에 결측값이 없는 경우
- **Unbalanced panel data** : 결측값이 있는 경우

패널 data 특징

- 동태적 변화 포착
- 다중공선성 문제 축소
- 개별특성효과 (individual effect) 와 시간특성(time effect) 효과 통제
- 누락변수에 대한 한계 극복 : 패널데이터에 대한 분석은 패널회귀분석으로 하는 것이 유용한 것으로 알려 짐.
- Data bias 통제
- 추가적 정보 추출
- 복잡한 형태적 모형 구축

Panel Analysis (Regression)

패널 회귀분석 방법

1. Pooled OLS(Ordinary Least Square)

2. 고정효과(Fixed Effect) 패널 회귀분석

: 개체별로 고유한 효과를 가정하며, 이러한 고정효과는 시간에 따라 변하지 않는다. $Corr(X_{it}, \alpha_i) \neq 0$

고정효과 모델은 개체 간 차이를 제어하여 시간에 따른 변화를 더 명확하게 파악할 수 있게 한다

❶ 이자율의 변화가 국가간 공통적으로 적용되는 효과

(1) 패널 그룹의 특성을 이진 더미변수로 처리하여 OLS를 적용하는 방법: LSDV(Least Squares Dummy Variable)

(2) 평균을 이동하는 Within Estimation

(3) 시차를 구해 추정하는 Time-demeaned estimation 방법

3. 임의효과 패널 회귀분석(Random Effect Panel Regression) $Corr(X_{it}, \alpha_i) = 0$

개체별 고유효과가 임의적으로 분포한다고 가정 ❷ 임의효과 모델은 개체 간 차이와 시간에 따른 변화를 모두 고려하지만, 개체 내 변동성과 개체 간 변동성이 독립적이라는 가정 하에 분석

❸ 각 국가가 이자율 변화에 대해 보이는 고유한 반응을 나타낸다. 이는 각 국가별로 이자율의 영향이 어떻게 다른지를 보여준다

고정 효과 모델 (Fixed Effects Model)

고정 효과 모델은 각 개체가 고유한 상수항(Intercept)을 가진다고 가정

$$Y_{it} = \alpha_i + \beta X_{it} + \epsilon_{it}$$

- α_i : 개체 i 에 대한 고정 효과(고유 상수항, 개별특성효과)
- X_{it} : 개체 i 의 시간 t 에서의 독립 변수, $i(\text{국가}) = 1, 2, \dots, n$, $t = \text{시간}$

공통 가정

$$Corr(X_{it}, u_i) = 0$$

$$Corr(u_{it}, \alpha_i) = 0$$

임의 효과 모델 (Random Effects Model)

임의 효과 모델은 개체별 고정 효과가 개체 간에 임의적으로 변한다고 가정

$$Y_{it} = \alpha + \beta X_{it} + u_i + \epsilon_{it}$$

- α : 전체 모델에 대한 공통 상수항
- X_{it} : 개체 i 의 시간 t 에서의 독립 변수,
- u_i : 개체 i 에 대한 임의 효과 ❹ 개체 간 변동
- ϵ_{it} : 오차항, 시간에 따른 개체 내 변동

공통 가정

$$Corr(X_{it}, u_i) = 0$$

$$Corr(u_{it}, \alpha_i) = 0$$

Hausman, J. A. (1978), Specification Tests in Econometrics, Econometrica, Vol, 46, No. 6. pp. 1251-1271

Panel Analysis (Regression)

패널 회귀분석 방법

- 단일오차모형 : 관찰되지 않은 개별특성효과(u_i)만 고려한 모형
- 이중오차모형 : 관찰되지 않은 개별특성효과(u_i)와 관찰되지 않은 시간효과까지 고려한 모형

(단일오차모형)

- 고정효과모형 : 시간의 흐름에 따라 변하지 않으며, 관찰되지 않은 특정변수가 개인마다 잠재해 있다는 가정
- 확률효과모형 : 시간에 따라 변한다는 가정

(이중오차모형)

- 고정효과모형 : 시간의 흐름에 따라 변하지 않으며, 관찰되지 않은 특정변수가 개인마다 잠재해 있고, 시계열별 독특한 특성이 매기간 잠재해 있음을 가정
- 확률효과모형 : 지역마다, 시간마다 모두 고정되지 않고 확률적으로 변화한다고 가정

1. Pooled OLS (Ordinary Least Square)

- iid 가정
- 통합 OLS 방법 : 패널자료의 특성을 고려하지 않고 OLS를 적용
- : 관찰되지 않은 패널 그룹별 특성을 고려하여 각각 독립적으로 OLS를 적용한 회귀계수 부호와 이런 패널 자료의 특성을 고려하지 않고 통합 OLS를 사용하는 경우 회귀계수는 부호가 달라진다.
- 🔊 ⚠️ 불편추정량(unbiased estimator)이 되지 못하고, 또 관찰수가 증가해도 일치통계량(consistent estimator)의 성격을 갖지 못한다.
- ➔ 관찰되지 않는 패널 그룹의 특성을 고려하는 패널 회귀분석의 모형이 필요 !!!

Panel Analysis (Regression)

패널 회귀분석 방법

고전적인 회귀분석: 시계열을 무시하고 다중회귀분석을 실시한 결과

2. 고정효과 패널 회귀분석(Fixed Effect Panel Regression)

u_i = 관찰되지 않은 개별특성효과 (individual effects) (패널그룹효과)

각 패널그룹에 특성에 따른 상수항 차이 의미 ⑦ 확률변수로 인식하지 않고 특정한 고정된 값으로 인식

→ u_i 를 독립변수들과 상관되어 있다고 보고 모수로 간주해 추정한다.

- ⑦ 확률효과 (random effects) 모형에서는 u_i 를 확률변수로 가정한다는 점이 차이

(1) LSDV(Least Squares Dummy Variable) 방법

패널 그룹의 특성을 이진 더미변수로 처리 후 ⑦ OLS 추정방식을 적용하는 것

⑦ 예를 들어 패널그룹의 수 만큼을 고려하여 그룹수와 시간 고려하여 더미변수로 만드는 것
(문제점)

- 추정해야 할 모수가 너무 많아 Over-Fitting이 문제 : 패널 그룹의 수가 n 이고 측정 시간이 t 인 경우

⑦ 전체 자료 수(N)는 $n*t$ 가 된다. ⑦ 더미변수 갯수

(사용) 패널 그룹의 개수가 적은 경우

- 패널 그룹의 특성 차이가 연구에 중요한 주제인 경우 사용하는 모형

통상적으로 조사대상의 관찰되지 않은 내재적속성이 관찰된 속성과 관련이 있는 경우가 많아 고정효과모형을 사용하게 되는 경우가 일반적임.

고정효과가 존재하는 경우에 OLS모형을 사용하면 개체의 고유한 속성으로 인한 공통성이 인과관계로 오인(spurious regression)될 수 있음

Panel Analysis (Regression)

패널 회귀분석 방법

Hausman, J. A. (1978), Specification Tests in Econometrics, Econometrica, Vol, 46, No. 6. pp. 1251-1271

2. 고정효과 패널 회귀분석(Fixed Effect Panel Regression)

$$Y_{it} = u + \beta X_{it} + u_i + \epsilon_{it}$$

u_i : 개별효과(individual effects)
 ϵ_{it} : 고유오차(idiosyncratic error)

(2) Within Estimator 방법

각 패널 그룹에서 시간에 걸친 평균값을 구한 후 ⑦ 원 모형에서 평균값을 제거한 모형을 뺀 모형
 ⑦ 아래 마지막 모형에 OLS 적용

$$\begin{aligned} Y_{it} &= u + \beta X_{it} + u_i + \epsilon_{it} \\ - \overline{Y_{it}} &= u + \beta \overline{X_{it}} + u_i + \epsilon_{it} \\ (Y_{it} - \overline{Y_{it}}) &= \beta (X_{it} - \overline{X_{it}}) + \epsilon_{it} \end{aligned}$$

(3) First-Differencing 방법(1차 차분 방법)

$$\Delta Y_{it} = u + \beta \Delta X_{it} + \Delta \epsilon_{it}$$

$$\Delta Y_{it} = Y_{it} - Y_{i(t-1)}$$

(한계점)

시간이 변화에도 거의 불변인 변수가 독립변수로 있는 경우

평균을 빼면 변수의 값은 모두 0의 값을 가지게 되어 추정이 불가능하게 된다.

⑦ 결론적으로 시간 변화에 따라 그룹별 변수 값이 불변인 경우 적용 불가

Panel Analysis (Regression)

3. 임의효과 패널회귀분석(Random Effect Panel Regression), 확률효과모형

$$Y_{it} = u + \beta X_{it} + u_i + \epsilon_{it} = u + \beta X_{it} + v_{it}$$

u_i (패널그룹효과)는 특정한 고정된 값으로 인식하는 고정효과 모형과 달리 확률효과모형에서는 확률변수로 인식
(가정)

- u_i 평균이 0이고 표준편차 σ_u 각각 독립인 정규분포를 가정
- 오차항 ϵ_{it} : 각각 독립적이고 동일한 분포를 가진다고 가정 (iid)
- 독립변수 X_{it} 와 패널그룹효과 u_i 는 서로 독립적이라는 가정

Hausman(1978) : 확률효과 모형에서는 위 조건을 만족하면 best linear unbiased estimator(BLUE) 성격을 가지고 일치 통계량 된다.

(고려사항)

패널그룹 특성 효과는 오차항 ϵ_{it} 에 일정하게 영향을 미친다. ❶ 결국 자기상관관계 존재로 가정에 위배된다. (intra class correlation coefficient(ICC)로 정의) • ICC(집단내 상관): 종속변수의 총분산 가운데 집단 간 차이에 의해 설명되는 분산량 의미

❷ 따라서 확률효과 패널회귀분석시 생겨날 수 있는 자기상관관계와 이분산성 문제를 해결하기 위해서는 OLS가 아니라 GLS(Generalized Least Squares) 방법을 통한 추정이 필요

Panel Analysis (Regression)

- **하향식방법(top-down)**

: 모든 고정효과와 확률효과를 고려한 전체모델로부터 시작하여 유의미하지 않은 효과를 제거시켜 나가는 방법

- **상향식방법(bottom-up)**

: 가장 단순한 모델로부터 시작하여 처음에는 고정효과만으로 고려한 모델을 구축하고 통계적으로 유의미하게 추정되면 그 다음 단계로 확률효과를 추가하여 모델을 확장시키는 방법

(가정)

등분산성 homoskedasticity) → 패널 개체와 시간에 따라 오차항의 분산이 변하지 않아야 한다.패널 개체의 오차항이 서로 상관관계가 없어야 한다 → 동시적 상관(contemporaneous correlation)이 없어야 한다.

한 개체의 서로 다른 시점의 오차항 사이에 상관관계가 없어야 한다. → 자기상관(autocorrelation, serial correlation)이 없어야 한다.오차항과 설명변수 사이에 상관관계가 존재하지 않는다.→ 설명변수의 외생성(exogeneity : 변수가 외적으로 영향 받아 만들어지게 되는 상태를 의미)을 만족한다.

Panel Analysis (Regression)

패널분석 장점

1) 횡단면분석과 시계열분석의 한계 극복

횡단면데이터는 특정 시점에서 여러 개체에 대한 조사이기 때문에 변수들 간 정적(Static) 관계만을 추정할 수 있지만 패널데이터에서는 연구집단에 대하여 반복하여 관찰되기 때문에 **동적(Dynamic) 관계 추정 가능**

2) 내생성 (endogeneity) 문제가 있는 설명변수의 **추정 편의(bias) 감소**

3) 개체들의 관찰되지 않는 이질성(unobserved heterogeneity) 요인을 모형에서 고려할 수 있다.

4) 패널자료는 횡단면 또는 시계열자료에 비해 더 많은 정보와 변수의 변동성(variability)을 제공한다.

- 결과적으로 효율적인 **추정량** (efficient estimator)을 얻을 수 있는 장점이 있다.
- ➔ 선형회귀모형에서 다중공선성(multi-collinearity) 문제를 완화시킬 수 있다.
- ⑦ 패널분석은 누락된 변수에 대한 한계를 극복하는 데에 가장 큰 의의를 가지고 있다.

패널분석 단점 및 유의점

1. 특정개체를 반복적으로 조사할 경우 결측치가 발생할 가능성이 높아져 추정량의 효율성과 모수 식별(identification)에 문제가 생길 수 있음. 조사기간이 길어지면 표본탈락의 증가로 가중치 및 대표성 문제 발생

➔ 결측치로 인해 추정량의 비효율성(Inefficiency) 문제, 추정해야 할 모수의 식별(Identification)에 문제가 발생

2. 국가나 지역을 패널 그룹으로 설정하여 조사한 데이터의 경우에는 패널 그룹간 상관관계(Group-wise correlation)가 존재할 수 있다. 따라서 이러한 그룹간 상관관계를 모형 추정에서 고려해야만 올바른 추론 결과를 얻을 수 있다.

3. 개인이 패널 그룹인 경우 시간변수의 길이가 짧다는 단점

Panel Analysis (Regression)

확률효과, 랜덤효과(Random Effect: RE) 모형과 고정효과(Fixed Effect: FE) 모형

모형의 적합도 검정법

Hausman 검정

고정효과모형과 확률효과모형 중에 어느 것이 더욱 적합한지에 대한 검정 방법

- 개별특성효과가 독립변수들과 관련이 없을 경우 확률효과모형의 추정치는 일관성과 효율성을 가지게 된다. 이 경우 고정효과모형의 추정치는 일관성을 가지지만 효율적이지 못하게 된다.
- 반대로 개별특성효과가 독립변수와 관련이 있을 경우 고정효과모형의 추정치는 일관성과 효율성을 가지게 되지만, 확률효과모형의 추정치는 일관성을 잃게 된다.
- 하우스만 검정의 통계량에 대한 기본 가설은 확률효과모형의 추정치가 적합하다고 설정되어 있으며 이를 기각할 경우 고정효과모형이 선택된다.

우도비 검정(likelihood ratio)

- 두 통계 모형의 적합도를 비교하는 데 사용되는 방법
- 특히 제약이 없는 모형(보다 많은 파라미터를 가진 모형)과 제약이 있는 모형(보다 적은 파라미터를 가진 모형) 사이의 적합도를 비교할 때 유용
- 우도비검정은 패널최소자승법과 고정효과모형 중 어느방법이 적합한가 여부를 판단하는 방법

https://github.com/freejyb/fin_stats
Panel analysis (regression)

Panel Analysis (Regression)

(연구 사례)

- 패널분석을 이용한 대도시 주택가격 추이 분석* 2013
- 인터넷뱅킹시스템이 은행의 경영성과에 미치는 영향에 대한 분석 2014
- 패널자료 시계열분석기법을 활용한 환경성과와 재무성과 간의 인과관계 분석 -온실가스배출량을 중심으로- 2018
- P2P금융 시장에서의 부동산PF 대출 비중이 연체에 미치는 영향 2021 - 살펴보기
- 여러 국가의 연도별 GDP 성장률 데이터를 분석하여 특정 경제 정책이 성장률에 미치는 영향을 평가

Regression : Summary

구분	내용
선형회귀	단순 선형, 다중 선형 → 잔차제곱합(RSS : residual sum of squares)을 최소화
로지스틱 회귀분석 Logistic regression analysis	종속변수(반응변수)가 범주형데이터인 경우에 적용하는 회귀분석
Ridge regression (Penalized Least Squares)	과적합 문제 해소 ⑦ 잔차제곱합(RSS : residual sum of squares) + 패널티 항(베타 값)의 합으로 계산 릿지회귀의 패널티항 = 파라미터의 제곱을 더해진 것 릿지회귀의 패널티항은 파라미터의 제곱을 더해진 것 ⑦ 이것은 미분이 가능해 Gradient Descent 최적화가 가능하고, 파라미터의 크기가 작은 것보다 큰 것을 더 빠른 속도 축소 → 라쏘는 가중치들이 0이 되지만, 릿지의 가중치들은 0에 가까워질 뿐 0이 되지는 않는다.
LASSO regression (Least Absolute Shrinkage and Selection Operator)	- 라쏘회귀는 릿지회귀와 유사하지만 패널티 항에 절대값의 합 - MSE가 최소가 되게 하는 가중치와 편향을 찾으면서 동시에, 가중치들의 절댓값의 합이 최소가 되게 한다는 것

Overfitting을 해결하는 방법

1. 특성(Feature)의 갯수를 줄여기

• Model selection algorithm을 사용한다.

2. Regularization를 수 행 ⑦ 베타값(파라미터값)에 제약을 줌으로써 모델을 정돈을 해주는 것이 정규화

• 모든 특성을 사용하되, 파라미터(세타)의 값을 줄인다.

*Summary : Multivariate analysis

다변량 분석(Multivariate analysis)?

여러 현상이나 사건에 대한 측정치를 개별적으로 분석하지 않고 **동시에 한번에 분석하는** 통계기법

다변량 분석 구분

1. 변수들간의 **인과관계 (causal relationship)**: 설명변수, 종속변수) 분석
 - ➔ 다중회귀분석(t-test), 로지스틱 회귀분석(Wald-test), 분산분석(ANOVA, F-검정)
2. 변수들간의 **상관관계 (correlationship)**를 이용하여 데이터의 차원 축소
 - ➔ 주성분분석(PCA), 요인분석(FA)
3. 개체들의 **유사성에** 의해 개체 분류
 - ➔ 다변량판별분석(MDA) , 군집분석

*Summary : 변량 통계분석

★ 단일변량 통계분석(Univariate statistical analysis) ⑦ 분산분석(ANOVA)에서 단변량분석하고 혼동하지 말 것!!

-단 한 개의 변수 가지고 통계 분석 하는 경우 : 기초통계학 중심 (기술통계량)

ex) 빈도, 백분율, 대표값, 분산

★ 다변량 통계분석(multivariate statistical analysis)

- 변수가 두 개 이상인 기법들의 통칭으로, 사회과학조사에서 이용하는 중요한 분석기법들의 대부분
- 2개 이상의 변수들간의 관계를 파악하기 위한 통계기법
- 독립변수가 명목측정치, 종속변수가 범주별 응답자인 경우: 카이제곱
- 독립변수가 명목측정치, 종속변수가 등간, 비율측정된 경우: 분산분석(ANOVA),
- 독립변수가 등간 또는 비율측정치, 종속변수 명목측정치: 판별분석(discriminant analysis) , 로짓분석(logit analysis),
- 독립변수와 종속변수가 모두 등간 또는 비율측정치 경우 : 회귀분석(regression analysis) 등

- simple, 단순(회귀분석) multiple, 다중(회귀분석)
- Univariate, 일변량, 단변량 , bivariate, 이변량 (종속변수 2개)
- multivariate, 다변량

* Python : Scikit-learn


*https://scikit-learn.org/stable/modules/linear_model.html#

https://www.statsmodels.org/devel/generated/statsmodels.discrete.discrete_model.Logit.html

• 1.1. Linear Models

- [1.1.1. Ordinary Least Squares](#)
- [1.1.2. Ridge regression and classification](#)
- [1.1.3. Lasso](#)
- [1.1.4. Multi-task Lasso](#)
- [1.1.5. Elastic-Net](#)
- [1.1.6. Multi-task Elastic-Net](#)
- [1.1.7. Least Angle Regression](#)
- [1.1.8. LARS Lasso](#)
- [1.1.9. Orthogonal Matching Pursuit \(OMP\)](#)
- [1.1.10. Bayesian Regression](#)
- [1.1.11. Logistic regression](#)
- [1.1.12. Generalized Linear Regression](#)
- [1.1.13. Stochastic Gradient Descent - SGD](#)
- [1.1.14. Perceptron](#)
- [1.1.15. Passive Aggressive Algorithms](#)
- [1.1.16. Robustness regression: outliers and modeling errors](#)
- [1.1.17. Quantile Regression](#)
- [1.1.18. Polynomial regression: extending linear models with basis functions](#)

* Machine Learning / Deep Learning



1. Supervised learning

Regression

- Linear regression
- Multiple Variable/Features

Gradient Descent Algorithm
: COST 함수를 최소화하는 계수를 찾는 방법

Classification

- Logistic regression
- Softmax classification

Logistic function (sigmoid function)
Binary Classification: 1과 0으로 부호화(encoding)

Softmax Function : Cross-Entropy
(Multinomial Classification)

$$\text{softmax}(x)_i = \frac{\exp(x_i)}{\sum_j \exp(x_j)}$$

입력받은 값을 0~1사이의 값으로 출력 ⑦ 모두 정규화하며
출력 값들의 총합은 항상 1이 되는 특성을 가진 함수

2. Deep Learning : ANN

Activation Function (sigmoid function ⑦ ReLu)
:chain rule

- Overfitting
- train / val / test sets

1. 분산분석 (ANOVA)

- 분산분석 이해
- 일원분류분산분석
- 이원분류분산분석

2. 판별분석(Discriminant Analysis)

3. 교차분석 (카이제곱 검정)

ANOVA : Analysis Of Variance

1. 분산분석 (ANOVA : Analysis Of Variance) 정의

1) 분산분석이란?

- 3개 이상 다수의 집단 (3분위 범주 이상)을 평균에서 분산 값을 비교하는데 사용되는 분석 (variance ratio)
- 집단 간 분산 비교로 얻은 F분포 이용 가설검정을 수행하는 방법 : F검정
- 모집단이 두 개일 때라면 표준정규분포나 t분포를 이용하여 모평균의 차이를 분석 ⑦ 비교 대상이 되는 모집단이 세 개 이상이 되는 경우에는 두 모집단을 각각 비교하는 것이 아니라(이 경우 세 번의 서로 다른 Z검정이나 t검정을 사용하게 된다.) 한 번에 세 개의 모집단을 비교할 필요가 있다.
- 이 경우 분석을 수행하는 것이 분산분석(ANOVA) ⑦ F분포를 이용하여 가설검정을 하는 방법
- 분산분석을 변량분석이라고도 함.

$$F \text{ 통계량 (F-value) } = \frac{\text{그룹간 변동}}{\text{그룹내 변동}} = \frac{\text{Between variance}}{\text{Within variance}}$$

- 등분산성 가정이 만족하는 경우 : ANOVA분석, t-test 진행
- 등분산성 가정이 만족하지 않는 경우 : Welch's t-test 진행

ANOVA : Analysis Of Variance

1. 분산분석 (ANOVA : Analysis Of Variance) 정의

1) 분산분석이란?

ANOVA 필요이유 (평균분석 t-test과 분산분석 ANOVA) 비교

- 3개 이상의 집단에 대해 평균비교를 하고자 할 때
- ⑦ 만약 3개 집단 비교에 대하여 t-test를 사용한다면, 두 집단씩 짝을 지어 t-test를 진행해야 함
- 만약 세 개의 집단이 있을 때, 2개씩 짝을 짓는 경우의 수가 3번 t-test로만 진행 $\Rightarrow$ 과잉검증(over testing problem) 발생

제1종 오류 증가

- 통계적 검증 절차를 남용하여, 확률적 의사 결정에서 발생할 수 있는 오류의 확률이 필요 이상으로 증가하는 문제
예) 3개 집단에 대한 평균비교를 시행할 때, 한 번이라도 1종오류가 발생할 확률 (유의수준 0.05)
 - ⑦ 1종 오류 확률은 $1 - (1 - 0.05)^3 = 0.14$ 로 오류확률 증가 (**상호독립성 결핍은 제 1종 오류를 확
증가 의미**) $3C2, H_0$ 개 (최대 오류 15%)
 - ⑦ 오류의 확률을 통제된 상황에서 통계분석을 진행하기 위해서 ANOVA를 실시한다.
- 집단을 구별하는 변수가 두 개 이상인 경우 상호작용을 파악하기 용이함

평균 비교인데 분산분석?

- 1) ANOVA : 그룹내 분산의 비율을 이용해서 그룹간 평균의 차이를 검정하는 것
: t-test 가 1~2개 집단의 평균 차이를 검정, ANOVA : 3개 이상의 집단의 분산 이용(분포)
- 1) 표본 선택 오류 : 다양한 그룹의 평균값이 다른 경우 이는 독립변수가 종속변수에 미치는 영향이 아니라 표본 선택 오류의 경
우 이 경우 평균 차이는 의미가 없다.
 - ⑦ ANOVA를 사용하여 평균값의 차이가 통계적으로 유의한지 확인 가능하다.
- 3) ANOVA는 독립변수가 종속변수에 영향을 미치는지를 간접적으로 보여 주어 표본 오류에 따른 그룹간 평균 차이를 구분

ANOVA : Analysis Of Variance

2) 분산분석 가정

- 분석의 대상이 되는 모집단은 정규분포를 따른다. **(정규성)**
- 각 모집단의 모분산은 알려져 있지 않지만 모두 같다고 가정한다. **(등분산성)**
- 분산분석을 위해 추출되는 관찰치는 무작위로 추출되며 독립표본이다. **(독립성)**

정규성 확인 - 집단(수준)별로 실시 from scipy.stats import shapiro

- *Levene's test: 분산의 동질성(equality of variances) 검정*
- *이분산인 경우의 평균차이를 검정하는 Welch t-test, Brown-Forsythe을 사용*

3) 분산분석 변수

- 독립변수(**Independent variable**), 설명변수, 예측변수 : 명목척도(이산형/범주형) ⑦ 변수가 1개라도 복수의 범주(level)가 존재
(예시) 학년별(독립변수변수 1개- 범주 여러 개) 영양상태 (종속변수) 비교
- 종속변수(**Dependent variable**), 반응변수, 결과변수: 등간 또는 비율척도 (연속형 변수)
- 통제변수 (**Control variable**) : 연구/조사의 주된 관심사가 되는 변수가 아닌 경우로 통제하는 독립변수
(예시) 고객 만족도(독립변수)에 따른 제품 재구매율 (종속변수)
- ⑦ 여기서 제품 재구매율에 영향을 주는 변수가 고객 만족도 외에도 다른 요인이 있다(예 : 가격). 그런데 이를 무시하면 모형에 부적합!!
(예시) 결제방식별 고객의 결제금액의 차이가 있는지 여부 분석
결제방식(독립변수 1개, 범주 4가지 : 현금결제, 계좌이체, 신용카드, 00 pay) 결제금액 (종속변수) 차이 비교 (ANOVA)

ANOVA : Analysis Of Variance

4) 분산분석 검정통계량 (F -value)

- F-통계량 ⑦ 두 개의 분산 비(variance ratio) : 두개의 평균값이 필요하게 된다!!!!
 - 분산은 산포의 측정치 또는 데이터가 평균에서부터 얼마나 산재되어 있는지를 나타내는 수치.
 - ⑦ F-통계량을 이용 검정하는 분석을 분산분석이라고 함.
 - 분산 값이 크면 산포도 더 큰 것으로 집단간 차이로 통계적 유의성을 가질 수는 있다.
 - ⑦ 그룹들 중 적어도 하나 이상 차이가 있다.
- 판단은 P-value : 유의수준 0.05 인 경우 $p\text{ 값} < 0.05$ ⑦ 귀무가설 기각

$$F\text{-value} = \frac{\text{그룹간 변동}}{\text{그룹내 변동}} = \frac{\text{Between variance}}{\text{Within variance}} = \frac{\text{mean squares.B}}{\text{mean squares.W}}$$

평균 제곱합(mean squares)
: 제곱합을 자유도로 나눈 것

(예시) 결제방식(독립변수 1개, 범주 4가지 : 현금결제, 계좌이체, 신용카드, 00 pay)

(분자 값) **Between variance** : 그룹간 분산 (4가지 범주별 분산 값)이 크다는 의미(그룹간 평균값이 차이가 클 것이다.)는 결국 전체 평균(독립변수 평균)으로 부터 각 그룹간 평균 값이 떨어져 있다. (이는 적어도 어떤 그룹 한 개는 다른 그룹과 평균 차이가 있을 것이라라고 추론)

- ⑦ 전체 평균으로부터 각 그룹의 평균사이의 분산 값
- 얼마나 분산이 커야 통계적으로 유의하다고 볼까? (t-value ⑦ 분모 값을 표준오차와 비교 : 두 집단 평균 차이 / 표준편차)(**분모 값**) 분산분석에서 **Within variance**을 동원하여 비교해본다. : t-value 에서 표준편차로 나누는 것처럼 random 한 변동 값인 **Within variance**로 분모값을 대응치 사용하는 것!!!!!!)

ANOVA : Analysis Of Variance

5) 분산분석 유형

구분.		독립변수	종속변수
단일변량 분산분석	일원분산분석(one-way ANOVA, 일변량분석)	1개	1개
	이원분산분석(two-way ANOVA)	2개	
	다중분산분석(Multi-way ANOVA)	3개 이상	
	반복측정 분산분석	1개 이상	1개(시간변수)
다변량 분산분석	다원분산분석(MANOVA)	1개 이상	2개 이상

(2) 이원분산분석(two-way ANOVA)

독립변수(집단)가 두 개 이상, 종속변수 1개 일 때 집단 간 차이가 유의한지를 검증하는 데 사용

⑦ 주효과와 상호작용효과를 분석

사례) 독립변수 2개, 종속변수 동일한 경우

학력 및 성별에 따른 휴대폰요금의 차이를 분석하는 경우

⑦ 학력, 성별은 독립변수이고 종속변수는 휴대폰요금

⑦ 주효과와 상호작용효과를 분석할 수 있다.

⑦ 주효과 : 학력(a), 성별(b)

⑦ 상호작용효과(교호효과)는 이를 곱한 $a*b$ 이다.

사례) 한/중/일 국가간 성별과 학력에 따른 체중비교의 경우

⑦ 독립변수 : 2개(성별/학력), 독립변수의 집단 : 3개 (한/중/일), 종속변수 : 1개 (체중)

(1) 일원분산분석(one-way ANOVA, 일변량분석)

- 종속변수 1개이며, 독립변수 집단도 1개인 경우
- ⑦ 두 독립적인 집단의 평균을 F-분포를 이용해서 비교하는데 사용. ⑦ 주효과 차이
- 사례) 가구소득에 따른 식료품소비 정도의 차이 : 가구소득은 독립변수로 가구소득집단의 구분-저소득, 중산층, 고소득층 등으로 2개 이상.
- 사례) 한/중/일 국가간 10세 남자의 체중 비교 : 독립변수:10세 남자, 독립변수 집단(범주) : 3개 (한/중/일), 종속변수 : 1개(체중)

(3) 다원분산분석(MANOVA)

- 두개 이상의 종속변수의 서로 관계된 상황에 적용시킨 것
- 둘 이상의 집단간 차이를 검증 가능
- 단순한 분산분석을 확장하여 두개 이상의 종속변수 서로 관계된 상황에 적용시킨 것
- 둘 이상의 집단간 차이를 검증

(4) 공분산 분석(ANCOVA)

연속형 외생변수가 종속변수에 미치는 영향을 제거 한 후 ⑦ 순수한 집단 간 종속변수의 평균차이를 평가하는 방법

One-way ANOVA

일원분산분석

(1) 기본 모형

만일 표본 자료의 총변동량 중에 그룹간 변동이 차지하는 비중이 높다면 그룹내 변동에 차이를 보이게 된다는 것.


- 그러나 총변동량에서 그룹간 변동이 차지하는 비중이 적다면 : 표본 자료의 변동은 군내변동에 의해 영향을 많이 받는다는 것이고 표본간에 유의한 차이를 발견할 수 없게 된다.

개별 표본자료의 총 변동량 (SST)


= 표본 내에서 변동하는 그룹내변동 (SSW)

+ 표본 간의 차이에서 발생하는 그룹간변동 (SSB)

$$F\text{-value} = \frac{\text{그룹간 변동}}{\text{그룹내 변동}} = \frac{\text{Between variance}}{\text{Within variance}}$$



군간(그룹간) 차이가 없는 경우



군간(그룹간) 유의한 차이가 존재

(2) 가설 설정

일원분류 분산분석은 하나의 요인에 따라 구분된 모집단의 평균에 차이가 있는지 여부를 분석하는 것

- 귀무가설(H_0) : 집단별 종속변수 평균값이 동일하다. $\mu_1 = \mu_2 = \dots = \mu_k$
- 대립가설(H_1) : H_0 중 적어도 하나의 모평균은 다르다.

One-way ANOVA

일원분산분석(one-way ANOVA)

(3) 유의수준 설정 : 통상 유의수준 (α) = 0.05

(4) 분산분석 가정 충족 여부 검토

(5) 검정통계량 1) 각 그룹간 간독립성 2) 각 그룹 정규분포 3) 그룹별 등분산성

$$F\text{-value} = \frac{\text{그룹간 변동}}{\text{그룹내 변동}} = \frac{\text{Between variance}}{\text{Within variance}}$$

F검정의 적용

- 일원분류 분산분석을 위한 가설검정은 F검정을 실시
- 그룹간 변동이 그룹내 변동에 비해 상대적으로 크면 표본 간의 유의한 평균 차이가 있는 것으로 보이기 때문에 변동의 비율로 차이를 분석하는 F검정을 사용
- t검정에서 R square 값이 사용되는 것과 같은 의미(모형의 설명력, 결정계수)
- ANOVA 분산분석에서는 η square 값 사용 (0과 1사이 값) ⑦ size effect
- ⑦ 에타 제곱값이 클 수록, 그룹을 나눈 요인이 그룹의 평균을 다르게 만드는 요인으로 얼마나 많이 기여했는가를 알려준다.
- ⑦ 모형의 설명력

$$\begin{aligned} \eta \text{ square} &= \frac{\text{표본 간의 차이에서 발생하는 그룹간변동(SSB)}}{\text{표본 내에서 변동하는 그룹내변동(SSW) + 표본 간의 차이에서 발생하는 그룹간변동(SSB)}} \\ &= \frac{\text{sum of squares . B}}{\text{sum of squares . W} + \text{sum of squares . B}} \end{aligned}$$

One-way ANOVA

일원분산분석(one-way ANOVA)

(6) 분산분석표에 따른 결과 해석

변동요인	제곱합(SS)	자유도(df)	평균제곱합(MS)	F-value
그룹간	SSB	k-1	MSB (=SSB/k-1)	$\frac{MSB}{MSW}$
그룹내	SSW	n-k	MSW (=SSW/n-k)	
총 합	SST	n-1		

➤ 제곱합(sum of squares) 개념

개별자료와 평균과의 차이를 제곱한 값

- **그룹간변동 (SSB)** : 각각의 표본평균을 개별자료로 보고 총평균과의 차이에 대해 제곱합을 구한 것
- **그룹내변동 (SSW)** : 개별자료와 개별 표본평균과의 차이에 대해 제곱합을 구한 것

➤ 평균 제곱합(mean squares) 개념

- 평균 제곱합(mean squares) : 제곱합을 자유도로 나눈 것 (분산의 개념)
- 표본분산을 구할 때에도 개별 자료와 표본평균과의 편차를 제곱하여 자유도 $n - 1$ 로 나누게 된다.
- 그룹간 변동의 자유도 : 각 표본의 평균 자체를 하나의 개별 자료로 취급하기 때문에 표본평균의 수(k개) - 1이 된다.
- 그룹내 변동의 자유도: 전체 표본자료(n개)에서 각각의 표본평균의 개수(k개)를 차감하여 구한다.
- 자유도는 표본의 수에서 추정되는 모수의 개수를 차감하여 구하기 때문이다.

One-way ANOVA

일원분산분석(one-way ANOVA)

(6) 분산분석표에 따른 결과 해석

➤ 검정통계량 도출 및 해석

- 평균 제곱합은 표본분산의 개념이므로 두 개의 표본분산을 비교하여 그룹내 변동에 비해 그룹간 변동이 더 큰지를 F검정하게 된다.
- F -value 검정통계량 > 임계치 : 귀무가설을 기각하고 대립가설 채택
- ⑦ 따라서 적어도 하나 이상의 그룹 모평균이 다르다고 할 수 있다.

귀무가설 기각의 의미

- 일원분류 분산분석으로 가설검정을 할 때 귀무가설이 기각될 경우 대립가설을 해석하는데 주의해야 한다.
- 귀무가설이 기각되면 대립가설을 지지하게 되지만 분산분석에서 대립가설의 의미는 적어도 어느 한 모집단의 모평균은 다르다는 것이며 k개의 모집단 중에서 하나의 모평균만이 다른지 k개가 각각 다 다른지는 설명하지 못하고 있다.

⑦ 사후 추가 검정을 통해 분석 필요

https://github.com/freejyb/fin_stats

One-way ANOVA

일원분산분석(one-way ANOVA)

ANOVA의 한계

사후검정 (post hoc analysis, posterior analysis)

ANOVA는 최소 두 그룹의 평균간에 유의한 차이가 있는지 여부만 알 수 있지만 어떤 그룹간에서 평균이 다른지는 설명할 수 없다.

⑦ 유의한 결과의 경우 사후검정 (post hoc analysis, posterior analysis) 필요

- ANOVA를 통한 결과가 대립가설을 채택해 유의하다는 결과가 나오면 ANOVA의 결과만으로는 어떤 그룹이 다른지 알 수 없기 때문에 사후검정을 해야 한다.
- 여러 다발의 t-test 하는 것인데 1종오류가 발생하지 않는다.
각 그룹의 평균이 다른 그룹의 평균과 동일한지 여부를 개별 비교가 가능하다.

(사후검정의 종류)

- 비교 대상 집단간 표본수가 동일 한 경우 : **Tukey HSD** (Honestly Significant Difference), Duncan , Fisher's LSD
- 집단 간 표본 수가 다른 경우 : Bonferroni 방법 , **Scheffe 방법** (가장 보수적이고 엄격한 방법으로 알려 짐) ,

One-way ANOVA : post hoc analysis

Scheffé Method

- 분산분석(ANOVA) 후에 수행되는 사후검증(post-hoc) 기법 중 하나
- ANOVA를 수행한 후 귀무가설이 기각되면, 이는 그룹 평균 간에 유의미한 차이가 있음을 나타냅니다. 그러나 ANOVA 자체로는 어떤 그룹들 간에 차이가 있는지를 명확히 알 수 없다.
- Scheffe 방법은 이러한 차이를 확인하는 데 도움을 준다.

1. 목적:

유의미한 ANOVA 결과 후에 그룹 평균 간의 여러 비교를 수행한다.

2. 특징:

- 1) 다른 사후검증 방법들(Tukey의 HSD 등)보다 보수적입니다.
- 2) 가족 단위 오류율(familywise error rate)을 제어하여 많은 비교가 있는 상황에서 적합하다.

3. 절차:

- 1) 전체 ANOVA에 대한 F-통계량을 계산한다.
- 2) 각 쌍별 비교 또는 그룹 평균의 선형 결합에 대해 수정된 F-통계량을 사용한다.
- 3) Scheffe 검증의 임계값은 F-분포에서 도출되며, 그룹 간 및 그룹 내 분산의 자유도를 고려한다.

4. 공식:

특정 대비(contrast) C 를 테스트하기 위해 Scheffe 방법은 다음 공식을 사용한다:

$$\frac{(\sum c_i \bar{X}_i)^2}{(\frac{K-1}{K-2} \cdot MSE \cdot \sum c_i^2 / n_i)}$$

- c_i : 대비의 계수
- $\bar{X}_i$: 그룹 평균
- K : 그룹의 수
- MSE : ANOVA의 평균제곱오차.
- n_i : 각 그룹의 표본 크기

5. 장점:

- 1) 쌍별 비교뿐만 아니라 임의의 수의 대비에 적용할 수 있다.
- 2) 모든 가능한 비교에 대해 보수적인 검증을 제공하여, 여러 비교로 인한 오류를 최소화한다.

⑦ Scheffe 방법은 특히 여러 그룹 간의 복잡한 비교를 수행해야 할 때 유용한 도구이다. 이 방법은 보수적이지만, 비교의 수가 많을 때 신뢰할 수 있는 결과를 제공한다.

One-way ANOVA :

일원분산분석(one-way ANOVA)

세 개의 그룹(A, B, C)

	sum_sq	df	F	PR(>F)
group	10.737434	2.0	5.268739	0.007951
Residual	58.081616	57.0	NaN	NaN

Comparison	Mean Difference	F Value	Significant
0 A vs B	0.486416	2.321942	False
1 A vs C	1.035582	10.524596	True
2 B vs C	0.549167	2.959677	False

<https://github.com/freejyb/kdigital/tree/main/머신러닝>

ANOVA 활용

- 소셜 미디어 광고 (독립변수1개, 범주 다양(유튜브, 네이버, 포털)에 따른 매출액(종속변수) 효과 비교
- 광고 효과 분석: 다양한 광고 캠페인이 소비자 행동에 미치는 영향을 평가
- 제품 테스트: 여러 제품 변형(예: 맛, 포장)이 소비자 선호도에 미치는 영향을 비교

One-way ANOVA

일원분산분석(one-way ANOVA)

Between variance

성명	ID	회복소요	그룹	그룹평균	B.V
김 OO	1	5	A	6	0.16
박 OO	2	6	A	6	0.16
홍 OO	3	7	A	6	0.16
이 OO	4	5	B	5.5	0.81
전 OO	5	6	B	5.5	0.81
정 OO	6	6	B	5.5	0.81
송 OO	7	5	B	5.5	0.81
윤 OO	8	7	C	8	2.56
진 OO	9	8	C	8	2.56
서 OO	10	9	C	8	2.56

Within variance

성명	ID	회복소요	그룹	그룹평균	W.V
김 OO	1	5	A	6	1
박 OO	2	6	A	6	0
홍 OO	3	7	A	6	1
이 OO	4	5	B	5.5	0.25
전 OO	5	6	B	5.5	0.25
정 OO	6	6	B	5.5	0.25
송 OO	7	5	B	5.5	0.25
윤 OO	8	7	C	8	1
진 OO	9	8	C	8	0
서 OO	10	9	C	8	1

사례

코로나 확진자(n=10명)에 대한 약 A,B,C (k=3)투약 회복일자 비교 차이 검정 유의수준 0.05

- 전체 평균 = $\frac{5+6+\dots+9}{10} = 6.4$ 일
- A그룹간 편차제곱합(SS) = $(6 - 6.4)^2 \times 3 = 0.48$
- B그룹간 편차제곱합(SS) = $(5.5 - 6.4)^2 \times 4 = 3.24$
- C그룹간 편차제곱합(SS) = $(8 - 6.4)^2 \times 3 = 7.68$
- 그룹 변동 총합 = $0.48 + 3.24 + 7.68 = 11.4$

변동요인	제곱합(SS)	자유도(df)	평균제곱합(MS)	F-value
그룹간(B.V)	11.4	2 ($df_1 = k-1$)	5.7	7.671
그룹내(W.V)	5	7 ($df_2 = n-k$)	0.743	
총합	16.4	9 (n-1)		

자유도 합(9)은 t-test 자유도(n-1)과 일치

$$F\text{-value} = \frac{\text{그룹간 변동}}{\text{그룹내 변동}} = \frac{\text{Between variance}}{\text{Within variance}} = \frac{\frac{11.4}{2}}{\frac{5}{7}} = \frac{5.7}{0.743} = 7.671$$

- $F\text{-value} = 7.671 > \text{임계치}(c.v) 4.74$: 귀무가설 기각하고 대립가설 채택
- ● 투약 집단간에서는 적어도 하나 이상 차이가 있다.
- $P\text{-value} < 0.05$ 가 된다.

$$\sum = 5$$

One-way ANOVA

이원분산분석

1) 반복이 없는 이원분류분산분석

- ① **자료 구조** : 두 가지 요인에 의한 자료를 각각 하나씩 추출하여 차이가 있는지의 여부를 분석하는 것
- ② **변동 구조** : 이원분류 분산분석에서는 자료를 구분하는 기준이 두 개이므로 각각의 요인에 따른 그룹간변동이 발생하는지를 파악해야 함.
- ⑦ 일원분류 분산분석에서는 총변동(SST)이 그룹간변동(SSB)과 그룹내변동(SSW)으로 구분되었는데
- ⑦ 이원분류 분산분석에서는 그룹간변동(SSB)을 다시 두 부분으로 나누어야 한다.
- 만약 자료를 구분하는 요인을 A, B로 본다면 그룹간변동(SSB)은 A요인에 의한 그룹간변동(SSA)과 B요인에 의한 그룹간변동(SSB)으로 나뉘어진다.

③ 가설 설정

자료를 구분하는 기준이 두 개에 대하여 각각 하나의 표본을 조사하고 이에 대해 각각의 요인에 따른 그룹간변동이 발생하는지를 파악

- $H_0: \mu_{A1} = \mu_{A2} = \dots = \mu_{AP}$
- $H_1: H_0$ 는 사실이 아니다. 즉, 요인A에 대한 차이 검정
- $H_0: \mu_{B1} = \mu_{B2} = \dots = \mu_{Bq}$
- $H_1: H_0$ 는 사실이 아니다. 즉, 요인B에 대한 차이 검정

④ 반복이 없는 이원분류분산분석표

표에서 제시하는 변동요인 중에 오차 항목은 그룹내변동(SSW)과 동일한 개념이며 SSE라고 표기

변동요인	제곱합	자유도	평균제곱합	F
요인A	SSA	p-1	MSA (=SSA/(p-1))	FA=MSA/MSE FB=MSA/MSE
요인B	SSB	q-1	MSB (=SSB/(q-1))	
오차	SSE	(p-1)/(q-1)	MSE (=SSE/(p-1)(q-1))	
총합	SST	pq-1		

Two-way ANOVA

이원분산분석(two-way ANOVA)

2) 반복이 있는 이원분류분산분석

① 자료 구조 : 반복이 있는 이원분류 분산분석은 두 가지 요인에 의해 구분된 자료를 반복하여 추출한 후 집단간의 평균차이가 있는가를 분석하는 것

② 변동 구조 : 반복이 있는 이원분류분산분석의 총변동은 주효과와 교호효과의 그룹간변동과 그룹내변동으로 구성된다.

$$SST = SSA + SSB + SSAB + SSE$$

$$\text{총변동} = \text{주효과} + \text{교호효과} + \text{오차 (그룹내변동)}$$

▪ 주효과(main effect)

총변동(SST)은 그룹간변동(SSB)을 A요인에 의한 그룹간변동(SSA)과 B요인에 의한 그룹간변동(SSB)으로 나눈다.
A, B 각각의 요인에 의한 변동인 SSA, SSB는 주효과라고 한다.

• 교호효과(interaction effect) : 상호작용효과

요인 A, B가 동시에 작용하여 평균의 차이를 나타내는지 여부를 검정하게 되는데 이것을 교호효과(interaction effect)라고 한다.

Two-way ANOVA

이원분산분석(two-way ANOVA)

2) 반복이 있는 이원분류분산분석

③ 가설 설정

가설검정은 주효과 분석을 위해 요인 A, B에 대해 각각 수행하며 교호효과 분석을 위해서도 수행되어야 함.

- $H_0: \mu_{A1} = \mu_{A2} = \dots = \mu_{Ap}$
- $H_1: H_0$ 는 사실이 아니다. 즉, 요인A에 대한 차이 검정)
- $H_0: \mu_{B1} = \mu_{B2} = \dots = \mu_{Bq}$
- $H_1: H_0$ 는 사실이 아니다. 즉, 요인B에 대한 차이 검정)
- $H_0: \mu_{AB1} = \mu_{AB2} = \dots = \mu_{ABpq}$
- $H_1: H_0$ 는 사실이 아니다. 즉, 요인A, B에 대한 차이 검정)

변동요인	제곱합	자유도	평균제곱합	F
요인A	SSA	p-1	MSA (=SSA/(p-1))	FA=MSA/ MSE FB=MSA/ MSE FAB=MSA B/MSE
요인B	SSB	q-1	MSB (=SSB/(q-1))	
요인AB	SSAB	(p-1)/(q-1)	MSAB (=SSAB/((p-1)(q-1)))	
오차	SSE	Pq(r-1)	MSE (=SSE/(pq(r-1)))	
총합	SST	pqr-1		

④ 반복이 있는 이원분류분산분석표

요인 A에 의해 p개의 집단으로 구분되고 요인 B에 의해 q개의 집단으로 구분되는 자료를 각각 r개씩 반복하여 추출하였을 때 이원분류 분산 분석표 ⑦

⑤ 가설검정에 따른 결과 해석

요인 A에 의해 p개의 기준이 정해지고 요인 B에 의해 q개의 기준이 정해질 때 각각의 경우 반복하여 r개의 자료를 추출하면 pqr개의 자료가 추출된다.

F검정은 군내변동(오차)에 비해 요인 A, B 각각에 의해 구분된 그룹간변동의 평균 제곱합을 비교하는 주효과 분석과 요인 A, B 가 동시에 영향을 미치는 교호효과 분석으로 나누어 시행

Discriminant Analysis

판별분석(Discriminant Analysis)

소개

- 범주형변수인 종속변수(2개, 또는 다수)를 구분할 수 있는 **독립변수(Feature)**를 통하여 **집단을 구분하는** 함수식(판별함수 discriminant function)을 도출하고, 새로운 개체에 대해 어느 집단에 속하는지를 판별하여 분류하는 다변량 기법
- 두 개 이상의 모집단(부도기업/정상기업)에서 추출된 표본들의 정보를 활용(**특성을 파악**)하여, 이 표본들이 어떤 집단에서 추출된 것인지를 결정할 수 있는 기준을 찾아 **새로운 대상을 어느 집단으로 분류할 지 판별분석방법**
- 1. 명백하게 집단을 구별한 후 (지도학습)
- 2. 그 집단들의 집단간(between the groups) 차이를 극대화 시키는 유의미한 **독립변수**들을 찾아
- 3. 선형결합으로써 **판별함수**를 추정하게 된다. 만일 특정 변수 기업들에 대해서 부실/정상의 집단간의 차이를 잘 설명하는 것이 가능하다면, 선형결합을 통해서 그 계수(coefficients)를 추정한 후 판별함수를 만들게 되는 것이다.

- 독립변수 : 등간척도(비율 척도), 범주형척도
- 종속변수 : 범주형 또는 서열척도 종속변수 (1:부실기업, 0 : 정상기업) , 종속변수 (다수 집단)
 - ⑦ 종속변수는 단순히 부실 또는 정상만을 구별 짓는 명목척도로서, 판별점수 자체를 도산확률과 연결짓는 절차는 분석자의 주관적인 판단에 의존해야 한다.

판별함수를 도출하기 위해 사용되는 독립변수 선정하는 방법

1. 직접법(direct method)
통계적인 고려 없이 이론에 입각하여 연구자가 선정하여 변수의 판별계수를 도출
2. 단계적 선택법(stepwise method)
통계적인 판별력을 기준으로 하여 고려하고자 하는 여러변수들 중에서, 가장 작은 AIC(Akaike Information Criterion)나 가장 높은 R^2 를 제시하는 변수들의 조합을 기준으로, 매 단계마다 한 변수씩 독립변수로 선정하거나 선정된 독립변수들 중에서 그 변수를 제거해 나가는 방법

Discriminant Analysis

종류

1. 종속변수 숫자에 따른 구분

- 1) 종속변수 범주가 두 집단 (Two way **discriminant analysis**) : 예시) 정상기업, 부도기업
- 2) 다중판별분석 (**MDA**: Multiple Discriminant Analysis) : 종속변수 범주가 3개 이상
: 정상기업, 부도기업, 판단보류 ⑦ Altman

2 범주별 분포도 동일 여부에 따른 분류

1) 선형판별분석 (LDA : Linear Discriminant Analysis)

: 정규분포의 분산-공분산이 범주에 관계없이 동일



⑦ Fisher Discriminant Analysis (FDA)

⑦ LDA 의 Decision Boundary는 분산대비 범주 간 평균의 차이를 극대화하는 경계(boundary) 임.

2) 이차판별분석 (QDA : Quadratic Discriminant Analysis)

: 정규분포의 분산-공분산이 범주별로 다름. QDA는 사실 LDA에서 공통 공분산구조에 대한 가정을 제외시킨 것

⑦ 공분산 구조가 다른 경우 사용하는 Discriminant Analysis



```
from sklearn.discriminant_analysis import LinearDiscriminantAnalysis
from sklearn.discriminant_analysis import QuadraticDiscriminantAnalysis
```

Discriminant Analysis

선형판별분석 (LDA: Linear Discriminant Analysis) , Fisher Discriminant Analysis (FDA)

(1) 의의

- 데이터들을 하나의 직선(1차원 공간)에 **투영(projection)** 시킨 후 그 projection된 data들이 잘 구분이 되는가를 판단하는 방법
- 데이터들이 모여 있고, **중심부 (범주별 평균 값)가 서로 멀리 떨어져 있을수록 (범주간 평균 차이를 최대화)** 데이터의 분류가 잘 된 경우임.

집단 내 분산이 작을 수록 : 두 개 이상의 집단을 구분하는데 있어서 오분류 확률을 최소화 하는 판별법

(2) LDA 가정

- 1) 독립변수들은 **다변량 정규분포** (Multivariate Gaussian normal distribution)를 따라야 한다.
- 2) 종속변수에 의해 그룹 범주화된 집단간에는 분산-공분산행렬이 동일해야 한다.
→ 등분산성(Homosdasticity → 불만족시 다중공선성 문제가 존재)
- 3) 독립성 (관측치 간 독립성)
각 관측치는 서로 독립적이어야 한다.
- 4) 선형성(Linearity) 가정
집단 간 구분을 위한 판별함수(discriminant function)는 각 예측 변수의 선형 결합을 이용

** 가정 불성립시 대처 방안

1. 공분산 동질성 위배 → QDA(Quadratic Discriminant Analysis)
 - 집단별로 공분산행렬이 다를 때, 판별함수가 이차식(quadratic) 형태로 바뀌며 더 유연한 경계를 그릴 수 있다.
2. 다변량 정규성 위배 → 비모수적 기법(예: k-NN, 의사결정나무, 랜덤 포레스트, SVM 등)
 - 정규성 가정이 크게 어긋나면 회귀트리나 서포트벡터머신처럼 분포 가정이 약한 모델을 고려한다.
3. 다중공선성 심할 때 → 변수 축소(PCA) 또는 변수 선택(Regularization)
 - PCA로 주요 성분만 추출하거나, LASSO, 릿지 정규화 등을 적용해 불필요한 변수를 제거/축소할 수 있다.

Discriminant Analysis

선형판별분석 (LDA: Linear Discriminant Analysis) , Fisher Discriminant Analysis (FDA)

(3) 장.단점

장점	단점
1. 차원 축소 기능 → 클래스 간 분별에 유용한 축으로 데이터를 투영하여 차원을 줄일 수 있음.	1. 정규성 가정 필요 → 각 클래스의 데이터가 정규분포를 따른다는 가정을 만족해야 결과가 안정적.
2. 계산 비용 절감 및 속도: → 특히 고차원 데이터에서 계산이 비교적 빠르며 메모리 비용이 낮음.	2. 등분산 가정(공분산 행렬의 동일성) → 클래스마다 동일한 공분산 행렬을 가진다고 가정하므로, 가정 위반 시 성능 저하.
3. 해석 용이성 → 투영된 축의 방향을 통해 각 피처가 판별에 기여하는 정도를 파악하기 쉬움.	3. 비선형 경계 부적합 → 클래스 사이의 경계가 비선형일 경우에는 성능이 크게 떨어짐.
4. 과적합 위험이 낮음 → 파라미터가 비교적 적어 작은 샘플에서도 안정적 분류 가능.	4. 다중공선성에 민감 → 피처들 간 강한 상관관계가 있으면 공분산 행렬 추정이 불안정해짐.
5. 소규모 샘플에 유리 → 데이터가 비교적 적어도 분류 성능을 낼 수 있음.	5. 이상치에 민감 → 평균과 공분산 추정에 이상치가 큰 영향을 미쳐 결과가 왜곡될 수 있음.
6. 클래스 간 분리 최적화 → 목적 함수가 클래스 간 분산 대비 클래스 내 분산을 최대화하여 분리도를 높임.	6. 다중 클래스 처리 시 한계 → 여러 클래스가 있을 때 이진 판별 기준이 각 클래스에서 최적이지 않을 수 있음.

Discriminant Analysis

선형판별함수 Linear Discriminant Function

$$Z = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_P X_P$$

Z : 판별 점수 Discriminant score

$X_1 X_2 \dots X_P$: 판별변수 Discriminant Variable

$\beta_1 \beta_2 \dots \beta_P$: 판별계수

- 판별함수 : 독립변수들의 선형 결합
- 판별점수 : 어떤 대상이 어떤 집단에 속하는지 판별하기 위하여 그 대상의 판별변수들의 값을 판별함수에 대입하여 구한 값 ⑦ 독립변수들의 선형 결합에 의한 점수(Z)
- 판별변수 : 표본이 어떤 집합에 속하는지 판별하기 위한 변수 데이터에 포함된 독립변수 중 판별력이 높은 변수
- 판별계수 : 가중치, 비표준화계수 / 표준화계수

판별분석은 독립변수의 선형결합에 의한 판별함수에서 만들어진 판별점수(Z)의 '집단 내 분산에 대한 집단간 분산의 비율값이 극대화 (Wilks' Lambda $\approx$ '0'에 가까워질수록) 가 되도록 변수들의 가중치(판별계수)를 결정하기 위한 것

Discriminant Analysis

이차판별분석 (QDA: Quadratic Discriminant Analysis)

- 선형판별분석은 공분산 구조가 많이 상이한 데이터를 잘 다루지 못하여 이를 보완하여 이차 판별 분석(QDA)을 이용
- 공분산구조가 다른 경우 사용
- ➔ 선형판별분석 (linear discriminant analysis, LDA)& 이차판별분석(quadratic discriminant analysis, QDA)는 확률론적 생성모형(generative model) ⑦ y 의 클래스 값에 따른 x 의 분포에 대한 정보를 먼저 알아낸 후 ⑦ Bayes' theorem를 사용 주어진 x 에 대한 y 의 확률분포를 알아내는 분석방법
- ➔ machine learning, 지도학습

Discriminant Analysis

판별분석 과정

1) 표본의 선정 및 후보 독립변수, 변수간 상관관계 및 기초통계량 등 계산

2) 판별함수 설정

(1) 종속변수 선택 : 판별식의 수 결정 ⑦

(2) 다양한 기법으로 독립변수 선정 ⑦

- 단계적 추출법(stepwise 법) : 전진선택법(변수추가법)을 이용하여 한 개 변수를 추가 후 후진제거법(변수제거법)에 의하여 제거될 변수가 있는지를 조사함
- 다른 모델에 의해 선택된 독립변수를 모두 입력

→ **윌크스 람다(Wilks' Lambda) 가 최소가 되는 독립변수 선택**

3) 가정 점검사항

- ⑦ 표본의 크기가 매우 클 경우 예외
- 독립변수들의 정규성 만족 여부
- 그룹내 독립변수들은 등분산성 만족 여부 검정 : Box-M 검정 이용
- 각 그룹에 소속될 사전확률 동일 여부?

4) 분류점(**C: Cut-off point, 임계값**) 산정

⑦ **분류점 (C) 과 판별점수 (Z) 비교하여 집단 분류 판단 (부실, 정상기업) 정상기업 > Z Score, 부실기업 < Z Score**

5) 판별함수 타당성 검 정 ⑦ 오분류

6) 검증된 판별함수 해 석 ⑦ 판별함수를 이용한 예측 활용

Discriminant Analysis

판별분석 과정

* 독립변수 선택 : Wilks' Lambda

종속변수의 변수 값을 기준으로 분류된 각 독립변수의 평균 값이 어느 정도 차이가 나는지에 대해서 분석하는 통계값
→ 불필요한 변수는 판별분석의 성능을 오히려 감소시키는 점

Wilks' Lambda = 집단내 제곱 합 / 전체의 제곱 합
→ (집단내 분산 / (총분산=집단내분산+집단간분산))

⑦ 분 모 값 집단간 분산이 클수록 Wilks' Lambda '0'에 가까워지며, 반대인 경우 '1'에 가까워진다. (값 범위 0~1)
결국 Wilks' Lambda가 작을수록 집단간 분산이 커진 경우이므로 판별력이 높은 독립변수로 이해할 수 있다.
Wilks' Lambda* ⑦ 람다가 최소가 되는 계수벡터 b를 구해야 함 (⑦ 집단 내 분산이 작고, 집단 간에는 멀리 떨어져 판
별식 계수를 구하는 것
⑦ 판별함수의 판별력의 통계적 유의성을 점검하는 사용되는 값,
⑦ 유의성(sig) < 0.05 판별계수는 사용 가능, 유의성(sig) > 0.05 판별계수는 삭제

Group Statistics(mean, Std.Dev)

-1이면 이것은 관측된 집단의 평균이 동일하다는 것을 의미하고,
이 값이 0에 가까우면 집단내의 ⑦ 분산이 총분산에 비해 적기 때문에 집단평균간에는 차이가 있다는 것을 나타낸다.
이를 보다 확실하게 알 수 있는 것은 자유도를 고려하여 구한 F값이다. F값이 크면 집단간의 분산이 커 차이가 크므로 구분이 잘되
는 계수가 된다. ⑦ 이 경우 유의성이 0.05보다 작아 집단간 차이가 크다.
→ 집단간에 차이가 있는 변수들이 판별분석에 판별계수로 사용.

Discriminant Analysis

판별분석 과정

선형 판별분석(Linear Discriminant Analysis, LDA)

분류점(Cutoff -point) , 임계값 (threshold)

- 주로 클래스를 구분하는 **결정 경계를 설정하는 데 사용**
- LDA는 기본적으로 두 클래스 간의 분리를 최대화하는 선형 결정 경계를 찾으며, 이 경계는 판별 함수의 값에 따라 결정
- 판별 함수의 값이 임계값보다 크면 한 클래스로, 작으면 다른 클래스로 분류

임계값의 기본 설정

- LDA에서는 종종 0을 기본 임계값으로 사용
- ⑦ 이는 LDA가 데이터를 변환하는 방식과 관련이 있다. LDA는 데이터를 새로운 축으로 투영하여 **클래스 간 분산은 최대화하고 클래스 내 분산은 최소화한다**. 이 때, 두 클래스의 **중심(평균)**을 기준으로 결정 경계가 설정되며, 이 경계는 판별 함수의 값이 0인 지점이다.

임계값의 조정방법

임계값을 조정하여 모델의 성능을 최적화

1. ROC 곡선 분석

: ROC 곡선을 분석하여 임계값을 결정할 수 있다.

ROC 곡선은 진짜 양성 비율(True Positive Rate, TPR) 대 가짜 양성 비율(False Positive Rate, FPR)을 다양한 임계값에서 그린 그래프 ⑦ ROC 곡선 아래의 면적(Area Under the Curve, **AUC**)을 **최대화하는 임계값을 선택**

2. 정밀도와 재현율의 균형

: 특정 문제에서는 정밀도(Precision)와 재현율(Recall) 사이의 균형을 고려하여 임계값을 조정할 필요가 있다.

3. 비용-민감 분석

: 오류의 종류에 따라 다른 비용이 발생하는 경우, 이를 고려하여 임계값을 조정할 수 있다. 예를 들어, 부정 거래 탐지에서 거짓 양성(False Positive)의 비용이 거짓 음성(False Negative)의 비용보다 낮을 수 있으므로, 이에 따라 임계값을 조정할 수 있다.

Discriminant Analysis

판별분석 과정

분류점(C : Cutoff -point)

판별함수(Z)의 집단별(정상기업별, 부도기업별) 값을 산정 후 ⑦ 집단(범주)별 각각 평균 계산

1) 만약, 집단별 정상기업 Z score 평균 0.5, 부도기업 Z score 평균 -0.5 경우 ⑦ 지도학습

2) 정상기업 표본수 500개, 부도기업 표본수 500개 -> 1:1

최적절사점(Cutoff -point*)

= [(부도기업 표본수 X 0.5) + (정상기업 표본수 X -0.5)] / (정상기업 표본수 + 부도기업 표본수)

= [(500X0.5) + (500X-0.5)]/(500+500) = 0 → cut-off point '0' 정상기업>0, 부도기업<0

- Z Score < 분류점(C) : 부도기업
- Z Score > 분류점(C) : 정상기업

도출할 수 있는 판별함수의 수

- 판별함수 : (종속변수 집단의 수 - 1) 과 (독립변수의 수)에서 작은 값만큼의 판별함수 생성
- ⑦ 집단의 수가 3 이고 독립변수의 수가 5 이면 2개의 판별함수 도출0
- **적정 표본크기 : 표본크기는 독립변수 수의 10~20배 이상 요구**
- ⑦ 카이제곱 , 유의수준 0.05 p-value <0.05 귀무가설 기각, 대립가설 채택

Discriminant Analysis

두 그룹의 판별

1. 다변량 정규분포 경우

선형판별분석(LDA : linear discriminant analysis) 과 이차판별함수(QDA : quadratic discriminant analysis)

1) 선형판별분석(LDA : Linear Discriminant Analysis)

- 선형판별분석 (LDA) : **두 그룹의 공분산행렬이 동일성 경우** 판별함수가 선형함수 ⑦ LDA는 오분류 확률을 최소화하는 판별법 **오분류 확률** : 잘못 분류할 확률 (집단 1을 집단 2로 또는 집단2를 집단 1로 잘못 분류하는 경우의 확률)
- 두 모집단의 경우에 다변량정규분포 가정하에서 우도함수의 비를 구하여 로그 값을 취한다.
- **선형 판별함수 식 $Y = b'X$**
- ⑦ LDA를 사용하기 위하여 **등분산 가정을** 먼저 검토해야 함.
- **공분산행렬의 동일성 검정 검정통계량 : Box's M test (Box's M-test for Homogeneity of Covariance Matrices)**
- p-value > 0.05 이면 유의수준 0.05에 귀무가설 채택 ⑦ 집단간 공분산행렬은 동일하다고 할 수 있다.
- ⑦ 선형판별분석(LDA)을 시행할 수 있다는 것을 의미
- **CV (Cross Validation) 교차타당성 검증**
 - ⑦ 훈련된 자료로 오분류를 측정하는 것은 평가가 다소 과장되어 있다.
 - ⑦ 훈련된 자료와 시험자료를 분류하여 평가를 진행해야 한다. - 훈련자료(training data), 평가자료(validation), 시험자료(test)
- (자료의 크기가 크지 않은 경우 2가지로 분류)
 - ⑦ 전체자료를 k등분하여 (k-1)개의 **훈련자료(training)**로 사용, 1개를 **시험자료(test)로 사용하는** 것을 k번 반복하여 성능 평가

https://github.com/freejyb/fin_stats

선형 판별분석(Linear Discriminant Analysis, LDA)

Discriminant Analysis

선형판별분석 (LDA) 단계

d차원 데이터셋을 표준화한다. (d = 특성개수)

1. 각 클래스 대해 d차원 평균 벡터를 계산한다.
2. 클래스 간의 산포 행렬(scatter matrix) $S(B)$ 와 클래스 내부의 산포행렬 $S(W)$ 를 구성한다.
3. $S(W)$ 의 역행렬과 $S(B)$ 의 곱행렬의 고유벡터와 고윳값을 계산한다.
4. 고윳값을 내림차순으로 정렬해 순서를 정한다.
5. 고윳값이 가장 큰 k 개의 고유벡터를 선택해 $d * k$ 차원의 변환행렬 W 를 구한다.
6. 변환 행렬 W 를 사용해 새로운 특성 부분 공간으로 투영한다.

LDA는 **행렬을 고윳값 (eigenvalue)과 고유벡터로 분해해서 새로운 저차원 특성 공간을 구성한다는 점에서 매우 PCA와 유사**

다만, LDA는 2단계에서 평균 벡터를 만들 때 클래스 레이블 정보를 사용하고, 레이블 별로 데이터를 나누어 평균을 구한다는 점에서 다르다.

* 쉬어가기

고유벡터(eigen vector)

: 행렬 A를 선형변환으로 봤을 때, **선형변환 A에 의한 변환 결과가 자기 자신의 상수배가 되는 0이 아닌 벡터**

- ⑦ 이 상수배 값을 고유 값(eigen value)라 한다.
- ⑦ 고유값, 고유벡터는 정방행렬에 대해서만 정의

고유값(eigen value)

: 판별함수가 어느 정도의 설명력이 있는지에 대한 내용을 분석하는데 사용하는 통계값

고유 값 = 집단간 제곱합 / 집단 내 제곱합

- ⑦ 고유값이 클수록 설명력이 높고, 작을수록 설명력이 약하다.
- ⑦ (일반적으로 4-5 이상이면 설명력이 높은 것으로 해석)
- ⑦ $Av = \lambda v$ 를 만족하는 0이 아닌 열벡터 v 를 고유벡터, 상수 λ 를 고유값이라 정의

에타
: 판별점수와 종속변수 사이의 상관관계를 나타내는 통계값
값의 범위 : 0~1

Discriminant Analysis

2. 다변량 정규분포가 아닌 경우

Fisher의 판별함수

- ⑦ Fisher의 판별함수는 변환된 y값들에 대해 두 집단의 표본평균간의 표준화된 거리의 제곱이 되는 t square 를 최대화 하는 선형 변환
- ⑦ 이 때의 최대값은 **Hotelling T square** 가 된다.

Fisher 판별분석

$d^T x_0 > d^T(\bar{x}_1 + \bar{x}_2)/2$ 이면 G_1 으로 분류

$d^T x_0 \leq d^T(\bar{x}_1 + \bar{x}_2)/2$ 이면 G_2 으로 분류

Fisher 판별분석 특징

- 표본의 두 집단을 가장 잘 분리시키는 정사영시키는 방법
- 정사영된 부분은 **집단간(between) 분산은 크고, 집단내(within) 분산은 작게**

Hotelling의 T- 제곱 분포

- 가설검정에서 [Harold Hotelling](#) 이 제안한 **Hotelling의 T- 제곱 분포**
- [F- 분포](#) 와 밀접하게 관련되어 있으며 분포로 발생하는 것으로 가장 주목할 만한 [다변량 확률 분포](#)
- [스튜던트 t- 분포](#) 의 기초가 되는 통계의 자연스러운 일반화 인 [샘플 통계](#) 세트의 집합

Hotelling T square

- 중다변인변량분석(MANOVA)에서 사용하는 가장 기초적인 다변량 통계치
- T검정이 1개의 종속변인에 대한 검정 ⑦ t 제곱은 여러 종속변인 간 집단간 차이 검정

Discriminant Analysis

판별분석 고려할 사항

- 판별분석을 위한 자료는 무작위 표본이어야 한다.
- 그룹을 나누는 명확한 기준이 있어야 한다.
- 가능한 많은 변수를 고려하는 것이 바람직하다. ❶ 이러한 변수들 중에서 적절한 변수를 선택하여 판별함수를 추정하는 것이 중요
- 자료를 탐색적으로 관찰하여 특이값을 제거, 결측값의 유무 확인하여야 한다.
- LDA의 경우 다변량 정규분포를 가정하고 있으므로 통계적 검정이 필요하다. ❷ 두 그룹에 대한 분산이 다를 경우 자료변환이나 비선형 형태인 2차 판별함수(QDA)의 형태를 고려해야 한다.
- 명목척도를 측정변수로 이용할 때 이에 대한 발생빈도가 낮을 경우 → 더미변수를 이용한 로지스틱 회귀분석이 더 적절하다.

Discriminant Analysis

판별분석 활용

◆ 은행

:은행 부도기업 예측

➔ 정상기업과 부도기업 특징(재무정보, 비재무정보 등 특징 추출)발견하여 새로운 기업에 대한 예측

◆ 투자

: 증권회사, 자산운용

➔ 우량종목, 불량종목 특징 파악하여 종목선정(제외)기준 마련하여 새로운 종목에 예측 활용

◆ 신용카드회사

우량고객, 불량고객의 특징(여러 정보 활용 추출)을 파악하여 신규 카드 발급시 고객에 대한 예측 활용

1. 신용카드회사에서 기존 고객의 특성(직업, 자산규모, 주거형태, 등)

을 변수로 하여 카드 발급 여부를 조사한 자료를 활용하여, 새로운 고객의 특성 자료에 대하여 카드를 발급 가능 여부 판단

2. 신용카드 고객의 카드 사용금액, 사용 업종, 사용 장소 등을 특성 변수로 하고, 카드 부정사용 예측

Discriminant Analysis

(유용성)

- (1) 단일변량분석과는 달리 여러 재무비율들을 동시에 이 용 ⑦ 각 재무비율의 상대적 기여도를 파악할 수 있고(판별계수), 부실예측시 각 재무비율에 부여해야 할 가중치에 대한 정보도 제공한다. ⑦ 단, 판별함수의 계수는 상대적인 비율이므로 개별변수가 도산 가능성의 예측에 어느 정도의 영향을 미치는지 측정하는 민감도 분석이 어려울 수 있다.
- (2) 재무비율과 같은 객관적 자료에 의거하고 있으므로 분석자의 주관적 판단에 의존하지 않고 보다 체계적 분석 가능
- (3) 판별모형이 일단 구축되면 모형을 이용하기도 쉽다.

(한계점)

- (1) 판별분석에 사용되는 변수들은 과거의 재무자료에 의해 계산되기 때문에 최근에 일어난 변화가 반영되지 않는다.
- (2) 부실예측에 유용할 수 있는 비재무적정보를 반영하지 못하고 있다.
- (3) 판별모형에 포함되어야 할 변수를 선정 기준 모호
- (4) 각 집단은 판별 변수들에 대해서 다변량 정규분포를 가진 모집단으로부터 추출되어야 한다.
 - ⑦ 대부분의 재무비율은 다변량 정규분포에 대한 가정을 충족하지 못하는 경우가 일반적이다.
- (5) 각 집단(부실/정상기업)의 공분산 행렬(covariance matrices)들은 동일하다.
- (6) 부실예측은 판별점수에 기초하는 판별점수에 대하여 적절한 경제적 해석을 하기 어렵다.
 - ⑦ 특정 판별점수를 기초로 하여 기업부실이 발생할 확률을 추정하기란 쉽지 않다.

D.A vs Linear vs Logistic

구분	Discriminant Analysis	Linear Regression	Logistic Regression
독립변수 (설명변수)	연속형 변수	연속형 변수	범주형 변수 (명 목형 변수, 순위 변수, 이항형)
종속변수	범주형(점수) (두 집단, 다수 집단)	연속형 변수	범주형 변수 (이항로직 7 이진분류)
계수추정(검정)	Wilks 람다 값 7 p-value < 0.05 (에타)	Least Square Method - t- test (R square)	Maximum Likelihood Estimation (에타 스퀘어)
모형추정 모수검정	판별함수 유의성 검정 chi-squared test	선형회귀선 유의성 검정 모수검정: t-검정, F 검정 (t 통계치) 이분산성 : Welch's t-test 비모 수검정 : wilcoxon rank sum test	로지스틱 회귀선 유의성 검정 카이제곱 검정 Wald 통계치
유의성 판단	p value < 0.05	p value < 0.05	p value < 0.05
비고	변수들이 <u>모수적일 경우</u> 선 형판별분석 방법이 <u>로지스틱</u> <u>회귀분석보다 우수</u>	2집단: t 검정 3집단: ANOVA	- 변수들이 비모수적 제한 없음 - 선형 분류

- 종속변수(y) = 절편 + (회귀계수) (설명변수X)
(독립변수)
- 레이블(label) (가중치w) (feature)


* Discriminant Analysis

군집분석과 판별분석 : 분류

군집분석	판별분석
비지도학습 : 설명변수	지도학습 : 설명변수, 종속변수
대상이 몇 개의 그룹으로 나뉘어 지는지 여부를 자료 보기 전까지는 알 수 없다	존재하는 그룹의 수를 알고 있고, 새로운 대상이 어느 그룹에 속하는지를 결정함.

PCA와 LDA

공통점 : 둘 다 투영(projection)이라는 기법 사용



PCA : Principal component analysis	LDA: Linear Discriminant Analysis
- 비지도학습 - 데이터들을 어떠한 벡터로 투영시켰을 때, 투영들의 분산이 큰 벡터들을 찾는다. -투영들의 분산이 적게 만드는 벡터들은 제거를 통해 데이터 차원 감소 -고차원의 데이터를 저차원으로 감소시켜 ⑦ 시각화가 가능하게 하거나 노이즈를 제거하는 것	- 지도학습 : PCA와 달리 데이터들이 어떤 범주에 속하는지 알아야 한다. - 투영 (projection) 후 두 집단(범주) 간 분산은 최대한 크게 가져가고, 집단 내부의 분산은 작게 가져가는 방식 - 집단 간 분산이 최대가 된다는 것은 각 집단(범주)의 중심(평균)이 서로 멀어지도록 분류한다는 것 ⑦ 집단 간 분산 이 값의 최대값화 하는 방식으로 차원을 축소 단 내 분산

Canonical discriminant analysis

1) 정준 판별분석

다수 (3개 이상) 의 집단으로 분류하는 경우 판별분석 ⑦ 판별식이 여러개가 된다

2) 정준판별함수란?

- 판별점수를 계산할 수 있는 판별함수
- 종속변수 집단의 수-1과 독립변수의 수 중에서 더 작은 값만큼 만들어진다.
- 정준판별함수는 카이제곱 검증을 통해 판별된 집단이 실질적으로 차이가 있는가를 검증하게 되고 정준상관계수의 제곱값으로 종속변수의 분산이 어느 정도 독립변수에 의해 설명되는가를 나타낸다.

3) 분류함수(판별함수)란?

- 정준판별함수로 각 집단의 중심값을 도출한 후 ⑦ 집단의 개수만큼 분류함수를 만들게 된다.
- 분류함수는 새로운 분류 대상의 분류집단을 결정하는데 사용하는 함수
- ⑦ 선택한 판별변수들을 이용하여, 분류의 기준이 되는 판별 점수 Discriminant Score를 도출하는 새로운 함수 ⑦ 판별함수에 새로운 데이터를 대입하여, 해당 데이터가 어떤 집단에 속하는지 판별
- 분류대상의 독립변수 값들을 분류함수에 삽입하여 계산한 결과가 더 큰 값을 갖는 집단으로 대상들을 분류하게 된다.

4) 분류함수의 도출 예시

- 기업을 정상기업과 부도기업 2집단으로 분류한다면 각 집단의 분류함수는 집단별로 도출이 된다.
- 분류함수를 통한 새로운 분류대상의 분류 값 계산
- 새로운 분류대상이 있을 때 각각의 독립변수 값들을 분류함수에 삽입하여 계산한 결과에 따라 점수가 높은 집단으로 분류한다.

5) Hit Ratio 계산

Hit Ratio는 분류함수에 의해 정확히 분류된 대상의 비율

- ⑦ 비율이 높을수록 분류함수의 판별력이 높다고 할 수 있다

Multivariate Statistical Analysis

모델	내용
다중회귀분석(Multi Regression)	- 하나의 계량적 종속변수와 하나 이상의 계량적 독립변수 간에 관련성이 있다고 가정되는 연구문제에 적합한 분석기법 - 다수의 독립변수의 변화에 따른 종속변수의 변화를 예측
다변량분산분석, 다변량공분산분석 (Multivariate ANOVA)	- 다변량분산분석: 두 개 이상의 범주형 종속변수와 다수의 계량적 독립변수 간 관련성을 동시에 알아볼 때 이용되는 통계적 방법으로 일변량분산분석의 확장된 형태 - 다변량공분산분석(Multivariate ANCOVA) : 실험에서 통제되지 않은 독립변수들의 종속변수들에 대한 효과를 제거하기 위해 다변량분산분석과 함께 이용되는 방법으로 그 절차는 이변량부분상관과 유사
정준상관분석(Canonical Analysis)	하나의 계량적 종속변수와 다수의 계량적 독립변수 간의 관련성을 조사하는 다중회귀분석을 논리적으로 확대시킨 것
다변량판별분석 (MDA:Multi Discriminant Analysis)	부도예측에 주로 사용 - 종속변수가 (정상기업/부도기업)과 같이 두 개의 범주로 나누어져 있거나, (상/중/하)와 같이 두 개 이상의 범주로 나누어져 있을 경우, 즉 종속변수가 비계량적 변수일 경우 MDA 이용
요인분석(Factor Analysis)	많은 수의 변수들 간 상호관련성을 분석하고, 이들 변수들을 어떤 공통 요인들로 설명하고자 할 때 이용되는 기법 ⑦ 많은 수의 원래 변수들을 이보다 적은 수의 요인으로 요약하기 위한 분석기법
군집분석(Cluster Analysis)	
다차원척도법 (MDS : Multi-Dimensional Scaling)	다차원 관측값 또는 개체들 간의 거리(distance) 또는 비유사성(dissimilarity)을 이용하여 개체들을 원래의 차원보다 낮은 차원(보통 2차원)의 공간상에 위치시켜(spatial configuration) 개체들 사이의 구조 또는 관계를 쉽게 파악하고자 하는데 목적

Cross-tabulation Analysis

1. 교차분석(Cross-tabulation analysis) / 카이제곱 검정이란?

- 독립변수와 종속변수 모두 범주형척도(명목척도나 서열척도)로 구성된 자료 일 때 연관관계를 확인하기 위해 교차표를 만들어 관계를 확인하는 분석 방법-
 - ⑦ 변수간 상호 독립 관계인지 또는 상호 연관성을 맺고 있는지를 검증하는 방법
- 1904년 Karl Pearson이 처음 사용
 - (Pearson 카이제곱 교차분석)
- 카이제곱 분포에 기초한 통계적 방법으로 실제로 나온 **관측빈도(observed frequency)**와 각 셀에서 통계적으로 **기대빈도(expected frequency)** 간에 얼마만큼의 차이가 있는지를 카이제곱 분포(chi-squared distribution)를 참조해 통계적으로 검증하는 통계 기법 , 적합도(goodness of fit)라고도 함
- 생산한 빈도 분포표를 **교차표(cross tabulation table)** 또는 **분할표(contingency table)**
 - ⑦ 2개의 조사 요인에 대한 자료값을 각각 행과 열로 배열하여 교차되는 항목에 대한 빈도를 나타낸 표

2. 카이제곱 검정 목적

- 변수가 1개 인 경우 : 변수 내 그룹간의 비율의 동일 여부
- 변수가 2개인 경우 : 변수 사이의 상호 **연관성 여부** (상관성이 아님을 주의 할 것)

Cross-tabulation Analysis

3. 교차분석(cross-tabulation analysis) 가정 : 카이제곱 검정시

1. 독립성

- 분석에 사용되는 두 변수가 서로 독립적이라는 것
- 한 변수의 결과가 다른 변수의 결과에 영향을 주지 않아야 한다.

2. 독립적인 관측치

- 각 관측치는 서로 독립적이어야 한다. 한 관측치가 다른 관측치에 영향을 주어서는 안된다.
- 예를 들어, 한 응답자가 여러 응답을 하는 경우, 이는 독립적인 관측치로 간주할 수 없다.

3. 무작위 표본 추출

데이터는 관심 있는 인구로부터 무작위로 추출되어야 한다. 이는 분석 결과가 해당 인구에 대한 일반화를 허용하기 위함이다.

4. 충분한 기대 빈도

- 각 칸(셀)의 기대 빈도가 너무 낮지 않아야 한다.
- 일반적으로, 모든 셀의 기대 빈도가 최소 5 이상이어야 한다는 규칙이 있다.
- 기대 빈도가 5 미만인 셀의 비율이 전체의 20%를 초과하지 않아야 한다.
- 기대 빈도가 너무 낮으면 카이제곱 검정의 정확도가 떨어질 수 있다.

5. 고정된 마진

- 분석에 사용되는 표의 행과 열의 합계(마진)는 고정되어야 한다.
- 이는 분석 중에 표의 구조가 변경되지 않음을 의미

- 이러한 가정들은 교차분석의 정확성과 신뢰성을 보장하는 데 중요
- 가정이 충족되지 않는 경우, 다른 통계적 방법이나 수정된 접근 방식을 고려해야 할 수 있다.
- 예를 들어, 기대 빈도가 낮은 경우 Fisher의 정확 검정 같은 대안적인 방법을 사용

Cross-tabulation Analysis

4. 교차분석(cross-tabulation analysis) 과정

1. 변수 선택

: 분석할 두 개 이상의 범주형 변수 선택

2. 데이터 표 형성

: 선택한 변수들을 축으로 하여 **교차표 (cross tabs)**를 만든다. ⑦ 이 표는 각 변수의 범주별로 데이터가 어떻게 분포하는지 보여준다.

3. 분석 수행

: 교차표를 기반으로 변수들 간의 관계를 분석 ⑦ 이 때, **카이제곱 검정(Chi-square test)** 같은 통계적 검정을 사용하여 변수들 간의 관계가 통계적으로 유의미한지 판단 가능

4. 결과 해석

: 분석 결과를 해석하여 변수들 간의 관계, 경향성, 가설 검증 여부 등을 결론

Cross-tabulation Analysis

5. 교차분석 '카이제곱 통계량'

교차분석에서의 관측빈도와 기대빈도 사이에 유의한 차이가 있는지를 확인하는 통계량으로 사용

$$\chi^2 \text{ 값} = \sum \frac{(\text{관측빈도} - \text{기대빈도})^2}{\text{기대빈도}}$$

(df = 범주의 개수 - 1)

▪ 관측빈도(observed frequency)

: 실제로 수집된 데이터의 빈도

• 기대빈도(expected frequency)

: 통상 평균적으로 기대되는 값

예를 들어 주사위를 60번 던졌을 때, 각각의 숫자는 10번씩 나온다고 기대

: 전체 빈도 n에 대하여 행과 열의 합을 기준으로 보았을 때, 각 교차되는 셀에 기대될 수 있는 기대 값

⑦ 귀무가설이 참 일 때 기대되는 빈도

$$\text{기대빈도} = \frac{\text{해당 칸이 속한 열의 총빈도} \times \text{해당 칸이 속한 행의 총빈도}}{\text{전체 빈도수}}$$

관측빈도와 기대빈도 분포의 차이 ($p < 0.05$) 인 경우 귀무가설 기각

Cross-tabulation Analysis

6. 교차표 분석

1. 어떤 자료일 경우?

- 범주형 독립변수와 범주형 종속변수가 있을 때 적용 가능
- 만약 등간변수인 경우는 명목/서열변수로 전환하여 사용

2. 독립변수 짝 여부?

- 독립변수가 서로 짝을 이루는 자료(쌍둥이 연구, 부부 연구) : McNemar 검정
- 독립변수가 짝이 아닌 경우 : 카이제곱 교차검정 또는 피셔의 정확도 검정(fisher's exact test)
- 연속형이라면 대응표본 t검정(paired t-test)
- 2*2 table이 나오는 이산형이라면 McNemar test 사용

3. 가정 만족여부에 따라?

- 카이제곱 교차검정 : 가정 만족시 (각 셀의 빈도 > 5 , 기대빈도가 5보다 작은 셀의 수가 전체 셀의 25%미만
- 피셔의 정확도 검정 (fisher's exact test) : 가정이 만족하지 않는 경우, 표본크기가 작은 경우

(사례)

- 연구자가 표본의 '거주지역'과 '성별'간의 관계가 있는지 알고 싶을 때
- 담배(X)를 많이 피우면 폐암(Y)에 걸리는가? 커피(X)를 많이 마시면 위암(Y)에 걸리는가?
- 성별에 따라 흡연 차이가 있는가?
- 성별에 따라 학력(Y) 차이가 있는가?

Cross-tabulation Analysis

교차분석 사례 보기

1991년 미국 일반 시민 1,504명을 대상 여론조사 중 인종별(독립변수)로 행복도(종속변수) 조사
(1,504명 : 백인 1,256명, 흑인 201명, 그 외 47명)

교차분석표 cross tabs

구분		인종 구분			전체
		백인	흑인	그 외	
행복도	매우 행복	409	46	12	467
	보통	730	116	26	872
	불행	117	39	9	165
전체		1,256	201	47	1,504

() 비중 %

구분		인종 구분			전체
		백인	흑인	그 외	
행복도	매우 행복	409 (32.6)	46 (22.9)	12 (25.5)	467 (31.0)
	보통	730 (58.1)	116 (57.7)	26 (55.3)	872 (58.0)
	불행	117 (9.3)	39 (19.4)	9 (19.2)	165 (11.0)
전체		1,256	201	47	1,504

Cross-tabulation Analysis

교차분석 활용

빈도 및 %의 분포가 독립변수의 범주에 따라 통계적으로 유의미한 차이가 있는가?

(1) 독립성 검정

- 두 집단간의 상관성이 있는지 없는지를 확인하기 위한 검정

• 귀무가설 : 두 범주형 집단 사이에는 차이가 없다.

• 대립가설 : 두 범주형 집단 사이에는 차이가 있다.

p-value < 0.05 귀무가설 기각하고 대립가설 채택한다.

⑦ 사후 사례 대조 : 사후의 결과를 토대로 연구하는 경우, 사례-대조 연구: Odds ratio

(2) 적합도 검정 (Goodness-of-Fit Test)

- 관측빈도와 범주의 기대빈도가 적합한지 여부를 확인하기 위한 검정

• 귀무가설 : 두 범주형 집단간 차이가 없다.

• 대립가설 : 두 범주형 집단간 차이가 있다.

p-value < 0.05, 귀무가설 기각하고 대립가설 채택한다.

(3) 동질성 검정 (Chi-squared Test for Homogeneity)

두 개 이상의 독립된 집단에서 관측된 범주형 데이터의 분포가 동일한지를 검정하는 데 사용

▪ 모집단에서 표본을 뽑았을 때, 모집단의 분포와 표본 집단의 분포가 동질성을 갖는지 확인하기 위한 검정

P-value < 0.05 연관 없다.

⑦ 사전실험 설계 : 사전에 그룹의 수를 결정해서 연구할 때 사용

▪ 코호트 연구(Cohort study): 특정 요인에 노출된 집단과 노출되지 않은 집단을 추적하고 연구 대상 질병의 발생률을 비교하여 요인과 질병 발생 관계를 조사하는 연구 방법, 요인 대조 연구(factor-control study)

https://github.com/freejyb/fin_stats

교차분석 검정(독립성, 적합도)

Cross-tabulation Analysis

일원 카이제곱 검정(One sample 카이제곱 검정)

주어진 데이터가 특정 기대되는 분포와 동일한 분포를 나타내는지에 대한 가설검정

(사례) 주사위를 총 60번 던지는 경우

주사위 눈	1	2	3	4	5	6
기대빈도	10	10	10	10	10	10
실제 1	9	10	8	11	10	12
실제 2	3	15	5	7	17	13

가설검정

- 귀무가설 (H_0) : 표본집단의 분포가 동일할 것이다 (각각의 범주(주사위 수)가 일어날 확률이 동일할 것이다)
- 대립가설 (H_1): 분포는 동일하지 않을 것이다.

실제 1 의 경우

pvalue=0.9625657732472964

pvalue가 약 0.9625로 충분히 큰 값 => 귀무가설 기각할 수 없다. 즉, 분포가 동일할 것이다.

Python 실습 : 통계분석- 교차분석 참조 할 것 !!!

실제2 경우

pvalue=0.005324337409375588

pvalue가 약 0.005324로 매우 작은 값 => 귀무가설 기각 즉, 분포가 동일하지 않을 것이다.

Cross-tabulation Analysis

일원 카이제곱 검정(One sample 카이제곱 검정)

두 명목변수들 사이에 연관성이 있는지 없는지 확인하기 위한 검정

(두 표본집단의 분포가 동일한지)

가장 단순한 형태는 2x2로, 각각의 변수가 두 개의 범주를 가지고 있는 경우

(사례) 바이러스 감염과 혈액형에 대한 분석

가설검정

- 귀무가설 (H_0) : 바이러스 감염과 혈액형 사이에는 연관성이 없다.(상호 독립이다)
- 대립가설 (H_1) : 바이러스 감염과 혈액형 사이에는 연관성이 있다.

이원 카이제곱 검정(Two sample 카이제곱 검정)

Python 실습 : 통계분석- 교차분석 참조 할 것 !!!

* Fisher's Exact Test

Fisher의 정확 검정(Fisher's Exact Test)

- 두 범주형 변수 사이의 독립성을 평가하기 위해 사용되는 통계적 검정 방법
- 주로 표본 크기가 작거나, 데이터가 희소할 때, 즉 기대 빈도가 낮은 2x2 분할표(교차표)에 대해 사용
- 카이제곱 검정(Chi-square test)이 적용되기 어려운 상황에서** (가정 불성립) Fisher의 정확 검정은 더 정확한 대안을 제공

작동 원리

- Fisher의 정확 검정은 특정 조건(표변의 합) 하에서 관측된 빈도가 발생할 조건부 확률을 계산
- 이 확률은 Hypergeometric distribution를 사용하여 계산 ⑦ 이는 무작위로 추출된 표본에서 특정 성공 횟수가 관측될 확률을 나타낸다.

- 표본 크기가 작을 때:** 데이터가 충분하지 않아 카이제곱 검정을 사용하기 어려울 때 유용
- 데이터가 희소할 때:** 한 칸이나 여러 칸의 기대 빈도가 5보다 작은 2x2 분할표에 적합

Fisher의 정확 검정은 다음과 같은 2x2 분할표를 기반

	그룹 A	그룹 B	합계
사례 1	a	b	a+b
사례 2	c	d	c+d
합계	a+c	b+d	N

a, b, c, d : 각 칸의 관측 빈도
N ; 전체 관측치의 수

➔ 검정의 목적은 두 변수(예: 그룹과 사례) 사이에 독립성이 있는지를 평가하는 것

해석

p-value : 두 범주형 변수 사이에 독립성에 대한 통계적 유의성

p-value < 유의 수준(예: 0.05) 경우

⑦ 두 그룹간 통계적으로 유의미한 차이관계에 있다.

Odds Ratio: 두 그룹 간의 효과 크기

1보다 크면 그룹A가 그룹B보다 효과적임을 의미
1보다 작으면 그 반대를 의미

https://github.com/freejyb/fin_stats

Fisher's Exact Test

* Structural Equation Model

Structural Equation Model

- 직접적인 측정이 어려운 **잠재변수(latent variable) 간의 영향관계를 분석**하기 위한 통계분석 기법
- 구조방정식은 회귀분석과 달리 잠재변수를 다룰 수 있고, 여러 변수 간의 영향관계를 동시에 분석할 수 있다는 장점
- **요인분석(factor analysis)**과 **회귀분석(regression analysis)**의 특성을 결합한 혼합 기법
- 구조방정식모델은 일반적으로 **경로도(path diagram)**로 표현
- ⑦ **정책효과에 대한 정량적 분석하고 체계적 전망치 제시에 유용한 모형 (계량경제학)**

잠재변수 = 외생잠재변수(exogenous latent variable) + 내생잠재변수(endogenous latent variable)

- **외생잠재변수** : 모델 내의 다른 잠재변수에 영향을 미치는 변수 --> 모델 내에서 **독립변수**로서의 역할 수행
- **내생잠재변수** : 모델 내의 외생잠재변수에 의해 직,간접적으로 영향을 받는 변수 ⑦ **독립변수, 종속변수로서의 역할을 수행**

구조방정식 구성 : 측정모델 + 구조모델

- **측정모델(measurement model)** :
: 잠재변수를 측정하는 모델 ⑦ 일반적으로 측정모델은 **확인적 요인분석(Confirmatory Factor Analysis, CFA)**를 사용
- **구조모델(structural model)**
측정된 잠재변수 간의 인과관계(causal relationship)를 분석하는 모델 ⑦ 구조모델은 **다중회귀분석(multiple regression analysis)**을 사용

* Structural Equation Model

구조방정식 절차

1. 변수 설정 & 측정 모델

2. 평가

측정모형을 대상으로 잠재변수 및 관측변수의 단일차원성, 신뢰도, 타당도를 평가

3. 검정

검증된 관측변수로 구성된 구조모형을 바탕으로 잠재변수 간 **경로분석**을 수행해 잠재변수 간의 영향관계 검정

1. 측정모델(확인적 요인분석 수행)

확인적 요인분석은 모든 잠재변수에 대해 수행되어야 하며, 개별적으로 평가할수도 있으나 일반적으로는 전체 잠재변수가 하나의 모델로 구성된 통합 측정모델(pooled measurement model)을 대상으로 한 번에 수행


⑦ 단일차원성(unidimensionality), 신뢰도(reliability), 타당도(validity)를 평가

2. 구조모델

- 구조모델에 대한 평가는 잠재변수와 잠재변수 간의 관계에 초점을 맞추어 진행
- 연구모델에 의해 설정된 이론적 관계가 데이터에 의해 지지되는지를 검토
- 모델의 적합도 평가, 유의성 검정, 결정계수 검토

* Path Analysis

- 변수들 사이에 **인과관계**에 대해 종합적(논리적)으로 분석할 수 있는 **회귀분석 방법**
- 인과관계에서 **원인**은 유일한 확정적 (deterministic)인 것이 아니라 인과관계를 결정하는 요인 중의 하나로서 **확률적 (probabilistic)**으로 해석
- 1920 Sewall Wright 창안
- 이미 알려진 이론적 배경 및 실증분석을 통해 입증된 가설에 입각 ⑦ 변수들 간의 인과관계를 나타내는 **경로모형을 설정한 후 ⑦ 회귀분석을 수번 수행 ⑦ 인과관계 분석하는 다중회귀분석의 확장 기법**
- **변수간**
 - 1) **직접효과(Direct Effects)**: 한 변수가 다른 변수에 직접적으로 미치는 영향
 - 2) **간접효과(Indirect Effects)**: 하나 이상의 중간 변수를 통해 한 변수가 다른 변수에 미치는 영향
 - 3) **총효과(Total Effects)**: 직접효과와 간접효과의 합으로, 한 변수가 다른 변수에 미치는 전체적인 영향
- 구조방정식모형을 따르며 경로 다이어그램(path diagrams : 연립방정식을 그림으로 표시한 것)을 도입하여 사용



$$X_4 = P_{41}X_1 + P_{42}X_2 + P_{43}X_3 + E_4$$

$$X_3 = P_{31}X_1 + P_{32}X_2 + E_3$$

$$X_2 = P_{21}X_1 + E_2$$

경로분석의 주요 구성 요소

- **외생변수(Exogenous Variables, 독립변수)** : **인과모형 밖의 변수들에** 의해서 그 변량이 결정되는 변수 ⑦ 경로 다이어그램에 있는 변수로부터 영향을 받지 않는 변수 (X_1) ⑦ 이 변수들은 모델의 시작점으로, 다른 변수들에 영향을 준다.
- **내생변수(Endogenous Variables, 종속변수)** : 하나 이상의 변수로부터 영향을 받는 변수 ⑦ 이 변수들은 모델 내에서 결과로 나타나며, 독립변수나 다른 종속변수의 영향을 받을 수 있다.
- **잔차변수** : 오차변수 + 교란변수
 : 오차변수(명시내생변수의 잔차 ⑦ 외생변수 E_2, E_3, E_4) 교란변수 (잠재내생변수와 관련된 잔차)
 : 명시변수(관측변수) :구체적인 수치로 측정되는 변수
- **경로계수(Path Coefficients)**:변수 간의 관계의 강도, 경로방정식을 통하여 계산된 회귀계수

* Path Analysis

효과분해


한 변수가 다른 변수에 작용하는 **총효과 크기를 직접효과와 간접효과로 분해하는 것**

- 1) **직접효과(direct effect)** : 한 변수가 다른 변수에 직접적으로 영향을 미치는 효과 (P_{41})
- 2) **간접효과** : 한 개 또는 그 이상의 중간변수를 통한 경로효과 (P_{31}, P_{43})
 - ⑦ 다른 변수에 의해 매개되어 두 변수들 간의 효과가 나타나는 것
- 2) **총효과** : 총 직접효과 + 총 간접효과

가정 회귀분석의 기본가정(정규성 등분산성, 독립성)을 포함

- 1) 독립변수와 종속변수 사이에 **공변량이 존재**해야 한다. ⑦ 변수간에 체계적 공통 변화 존재
 - 2) 독립변수의 변화가 종속변수의 변화 보다 선행적인 **시간순서(time order)**를 가져야 한다.
 - 3) 인과관계가 비의사적 관계 (nonspuriousness relationship, 인과적 폐쇄성)이어야 한다.
 - ⑦ 변수들간의 공변량이 외부의 영향력으로부터 폐쇄되어 있어야 한다는 점
- * 의사적 관계(spurious relationship) : 두 변수 간 공변량이 외부의 영향력에 의한 것

경로분석 과정



* Path Analysis

경로분석 장점

- 1) 여러개의 상호종속관계를 동시에 추정 가능
- 2) **효과분해 (effect decomposition)**를 쉽게 할 수 있다.
- 3) 모형이 데이터에 잘 부합하는지를 알 수 있는 모형적합도지수를 얻을 수 있다.
(활용 유용성) 사회적, 정책적& 생물학적 복잡성 (biocomplexity)에 대한 이해의 필요 한 영역에서 많이 활용

경로분석 제약점

- 1) 경로모형의 경로는 경로를 만들기 이전에 그 경로에 대한 상관관계와 인과관계가 있다라는, 즉 사전에 근거 (priori) 가 있어야 한다. 선행연구를 통한 조사가 사전 필수
- 2) 경로분석을 하기 위해서는 상당한 양의 분석과정이 요구된다.
- 3) 하나의 시스템 내에서도 다양한 경로모형이 만들어질 수 있다
- 4) 독립변수들간의 다중공선성 (multicollinearity)이 발생할 수 있다.

모델적합성 (Model's goodness of fit)

- 카이제곱 (Chi-Square Test of Model Fit)
- 근사치 오차평균 제곱근 (RMSEA: Root Mean Square Error of Approximation)
- 적합지수 (CFI: Comparative fit index)
- 터커 루이스지수 (TLI: Tucker Lewis Index)

* Path Analysis

경제분야에서 경로분석(Path Analysis) 사례

다양한 매크로경제 변수들 간의 복잡한 관계를 이해하고,
특정 경제정책이 경제 지표에 미치는 영향을 분석하는 데 널리 사용

중앙은행의 금리 결정이 경제에 미치는 영향 분석

(배경)

중앙은행이 금리를 조정함으로써 경제에 여러 가지 영향을 미칠 수 있다.

금리 인상은 인플레이션을 억제하고 화폐 가치를 강화할 수 있지만, 동시에 경제 성장을 둔화시키고 실업률을 증가시킬 수 있다.

반대로 금리 인하는 경제 성장을 촉진하고 실업률을 감소시킬 수 있으나, 인플레이션을 촉발할 위험이 있다.


(모델 설계)

경로분석을 사용하여 중앙은행의 금리 결정이 경제에 미치는 직접적 및 간접적 영향을 분석할 수 있다.

이를 위해 다음과 같은 변수를 고려할 수 있다:

- 독립변수: 중앙은행의 기준금리
- 매개변수: 대출 금리, 소비자 지출, 기업 투자
- 종속변수: GDP 성장률, 인플레이션, 실업률

경로 다이어그램



https://github.com/freejyb/fin_stats

경로분석

* Latent Growth Model : LGM

잠재성장 모델?

- 개인이나, 집단이 시간이 지남에 따른 어떤 변수의 변화를 측정한 종단적 데이터(longitudinal data)의 변화 패턴을 분석하고자 할 때 사용하는 방법
- 종단연구에서는 시간의 흐름에 따라 **동일한 대상자의 특징을 반복적으로 측정하고 그 측정치들의 변화 또는 그것들에 영향을 미치는 변인을 분석**
- 인구의 진화하는 특징이나 특성을 분석하기 위해 수행 ⑦ 개인차 모델(individual difference model)

주요 구성 요소

1. 기울기(Gradient) 또는 성장률: 시간에 따른 변화의 속도나 경향을 나타낸다.
예를 들어, 어떤 학습 프로그램이 학생들의 성적 향상에 얼마나 빠르게 영향을 미치는지를 측정할 수 있다.
2. 절편(Intercept) 또는 시작점: 모델의 시작점에서의 상태 ⑦ 이는 개인이나 집단이 연구 시작 시점에서 어떤 수준에 있었는지를 보여준다.
3. 시간(Time): 변화를 측정하는 데 사용되는 시간의 단위나 점들
⑦ 이는 연구 설계에 따라 다양할 수 있으며, 일, 주, 월, 년 등이 될 수 있다.

잠재성장모델의 사용

개인의 발달, 교육적 성취, 심리적 변화, 건강 상태의 변화 등 다양한 분야에서 변화를 이해하고 예측하는 데 사용

모델의 장점

- **개인 차이의 고려:** 개인별로 다른 성장 궤적을 모델링할 수 있어, 집단 내에서의 다양성을 포착할 수 있다.
- **시간에 따른 변화의 이해:** 시간이 지남에 따른 변화의 패턴을 명확하게 이해할 수 있으며, 이를 통해 개입의 효과나 발달의 자연스러운 과정을 분석할 수 있다.
- **예측 가능:** 초기 데이터를 바탕으로 미래의 상태나 변화를 예측할 수 있다.

* Latent Growth Model : LGM

잠재성장 모델 유용성

- 모델은 변화에 있어 개인차가 유의미한지?
- 개인차를 잘 설명할 수 있는 변수는 무엇인지?
- 변화 패턴을 간명하게 설명할 수 있는 함수는 무엇인지?
- 집단 간 변화 패턴에 유의미한 차이가 있는지 등을 연구하는데 관심
- 잠재성장모형은 구조방정식을 활용하여 한 사람을 대상으로 이루어진 반복 측정 자료를 통해 관찰되지 않는 잠재적 발달 궤적(underlying trajectory)을 추정하고 개인 내 변화를 모델링할 수 있다.

선형 잠재성장모델

개인 i 의 시간 t 에서의 관측값 Y_{it} 을 모델링하는 일반적인 형태

$$Y_{it} = \pi_{0i} + \pi_{1i}T_{it} + \epsilon_{it}$$

- Y_{it} : 개인 i 의 시간 t 에서의 관측값
- π_{0i} : 개인 i 의 절편(시작점)을 나타내는 잠재변수
- π_{1i} : 개인 i 의 기울기(시간에 따른 변화율)을 나타내는 잠재변수
- T_{it} : 시간, 연구시작 시점부터의 시간간격
- ϵ_{it} : 오차항, 시간 t 에서 개인 i 의 관측값과 모델 예측값의 차이

절편과 기울기의 모델링

$$\pi_{0i} = \gamma_{00} + u_{0i}$$

$$\pi_{1i} = \gamma_{10} + u_{1i}$$

- γ_{00} : 전체 샘플에 대한 평균 절편
- γ_{10} : 전체 샘플에 대한 평균 기울기
- u_{0i}, u_{1i} : 각각 개인 i 의 절편과 기울기에서 전체평균과의 차이

* Factor Analysis

요인분석의 분류기준

- 1) 상관관계 행렬(Correlation matrix)과 분석대상에 따른 분류
- 2) 회전(rotation)방법에 따른 분류
- 3) 요인의 추출모델에 따른 분류
- 4) 분석의 목적에 따른 분류

1) 상관관계 행렬(correlation matrix)과 분석대상에 따른 분류

요인분석을 실시하여 그 관계를 알려는 대상이 변수인가 혹은 표본인지에 따른 분류

(1) R-type 요인분석 : 변수들간의 상관관계를 이용하여 변수들을 요인(Factor)으로 분류

(2) Q-type 요인분석 ; 표본들을 일정한 기준에 따라 분류

2) 회전방법에 따른 분류

(1) 직각회전(orthogonal rotation)

: 변수들을 요인으로 묶어낼때 요인간의 독립성을 유지한 상태에서 해를 개선하는 방법

(2) 비직각회전(oblique rotation)

: 요인들간의 상관관계를 어느 정도 가정하거나 요인들이 독립적이라고 보기 힘든 경우에 사용하는 방법

* Factor Analysis

3) 요인의 추출 모델에 따른 분류

- (1) PCA(principal component analysis) : 고유분산(eigenvalues) 혹은 오차분산이 크거나 또는 이에 대한 지식이 없을 때
- (2) CFA(common factor analysis) : 공통분산의 비중이 크고 오차분산이나 고유분산이 적을 때
- (3) PFA(principal factor analysis)
- (4) ML(maximum likelihood)
- (5) GLS(generalized least square)

4) 분석의 목적에 따른 분류

(1) 탐색적 요인 분석 (EFA: Exploratory Factor Analysis)

•연구자는 요인 간의 이전 관계에 대해 어떤 가정이 없다.

•모든 변수를 모든 요인과 연관시킬 수 있다. 7변 수 간의 복잡한 관계를 식별하고 공통 요인에 따라 변수를 그룹화하는데 유용

(2) 확충적 요인분석

•변수가 특정 요인과 관련이 있다고 가정

•미리 설정된 이론을 사용하여 모형에 대한 기대치를 확인

* Factor Analysis

- 많은 변수들의 상호 관련성을 소수의 요인(factor, 인자)으로 추출하여 전체 변수들의 공통요인을 찾아내 각 변수가 받는 영향의 정도와 그 집단의 특성을 규명하는 통계분석방법
- 다수 변수 ⑦ 변수들간 관계분석(상관분석)을 통해 공통 차원을 축약(서로 연관성이 높은 변수들을 모아서 하나의 변수로 새롭게 만들어내는 과정) 하는 통계기법
- 추론 통계기법이 아닌 기술통계기법
(활용)
- 회귀분석, 판별분석등 변수 간 다중공선성과 같은 문제점 해결.
- ⑦ 여러 개의 변수를 소수의 새로운 요인으로 축소하고 각각의 요인이 독립적(orthogonal)이 되게 하기위해 요인분석을 이용

요인 분석 가정

변수의 선형 관계

- 다중공선성 부재
- 변수의 관련성
- 요인과 변수 사이의 진정한 상관관계의 존재

* Factor Analysis

요인분석 절차



* Meta-Analysis

메타분석

- 유사한 주제를 다루는 연구들의 결과를 결합하여 통합적인 결과를 얻는 분석 방법
- 여러 연구들의 결과를 종합적으로 분석하여 새로운 인사이트를 도출하는 방법통계학적 분석을 사용하여 효과 크기나 상호작용, 효과의 일반화, 이질성 및 출간 편향 등을 분석 가능
- 메타분석은 대규모 연구를 수행하는 것보다 효율적이며, 다양한 연구 결과를 종합하여 더욱 객관적이고 정확한 결론을 도출 가능

메타분석의 주요 단계

- 1.문제 정의: 메타분석을 위한 연구 질문을 명확하게 정의
- 2.문헌 검색: 관련된 모든 연구를 포괄적으로 검색합니다. 이 과정에서 연구의 포함 및 배제 기준을 설정
- 3.데이터 추출: 포함된 연구로부터 필요한 정보(예: 효과 크기, 표본 크기 등)를 추출
- 4.품질 평가: 연구의 품질이나 편향 위험 평가
- 5.통계적 분석: 효과 크기(effect size)를 종합하고, 연구 간의 이질성(heterogeneity)을 평가합니다. 필요한 경우, 서브그룹 분석이나 메타회귀(meta-regression)를 수행
- 6.결과 해석 및 보고: 메타분석의 결과를 해석하고, 연구의 한계와 미래 연구 방향에 대해 논의

* Meta-Analysis

메타분석의 중요 개념

•효과 크기 effect size

- 개별 연구 결과의 중요성을 표준화된 형태로 나타내는 지표
- 효과 크기를 사용하면 다양한 연구 결과를 직접 비교하고 종합
- ∴ 메타분석에서는 개별 연구의 결과를 효과크기라는 공통의 척도로 변환하여 사용
- 효과 크기는 연구 결과의 크기와 방향을 나타내며, Cohen's d, 상관관계수, 위험비(risk ratio), 오즈비(odds ratio) 등 다양한 형태로 표현

•이질성

: 메타분석에 포함된 연구들 사이에서 관찰된 효과 크기의 차이를 이질성

•fixed effect model과 random effects model

: 이질성의 존재 여부에 따라 메타분석에서 사용하는 모델이 달라진다.

1. 고정효과 모형 fixed effect model

- 각 연구에서 측정된 평균 효과 크기가 전체 연구에서 동일하다는 가정
- 각 연구의 가중치가 연구에서 사용된 샘플 크기에 비례
- 각 연구에서 측정된 효과 크기가 실제 효과 크기와 유사하다는 가정이 있어야 한다. 이 모형은 이질성이 적은 경우에 유용
- ⑦ 임의 효과 모형은 각 연구의 효과 크기가 서로 다른 진짜 효과 크기에서 무작위로 선택되었다고 가정

2. 랜덤효과 모형

- 각 연구에서 측정된 효과 크기가 서로 다르다는 가정을 기반
- 연구에서 효과크기는 표본오차를 포함한 값을 가지며, 랜덤효과 모형은 각 연구에서 측정된 효과크기의 가중평균을 계산
- 각 연구의 가중치가 연구에서 사용된 샘플 크기와 표본오차에 비례
- ⑦ 랜덤효과 모형은 이질성이 큰 경우에 유용

3. 메타-회귀분석

- 메타분석에서 사용되는 통계 분석 방법 중 하나
- 각 연구에서 사용된 독립변수들의 효과 크기를 함께 고려하여 종속변수의 효과 크기를 추정하는 방법

* Research design

연구설계(Research design)

- 횡단면 설계(cross-sectional design) vs 종단면 설계(longitudinal design)

횡단면 설계(cross-sectional design)

- 일정한 시점에서 연구대상을 통제하고 비교. 분석하는 연구방법
- 연구의 특정시점에서 서로 다른 특성을 가진 집단간의 차이를 연구하는 방법의 일환으로서 여러 조사대상에 대한 특성을 연구하는데 사용
- 종단연구와 비교하여 상대적으로 연구 자료의 수집과 활용이 수월하여 비용과 시간의 측면에서 경제적

(제약점)

- 상호 변인 사이의 인과관계를 파악하는 데는 제약사항이 존재한다.
- 각 조사의 개체에 대한 특성의 시간에 따른 변화를 충분히 반영하지 못한다는 한계

종단면 설계(longitudinal design)


- 연구 대상 동일집단에 대하여 장시간의 기간에 걸쳐서 반복적으로 연구 관찰함으로서 시간의 추이에 따라 각각의 연구 대상과 변인들이 어떻게 변화해 나가는가를 연구하는 동태적인 연구방법
- 변인에 대한 조작보다는 대상의 실제 상태를 관찰하는 데 중점이 두어지기 때문에 인과관계를 발견하고 분석하는 데 장점

(제약점)

- 시간과 비용
- 시간의 추이에 따른 연구 대상의 태도변화나 표본의 손실등의 문제점이 발생할 수 있는 제약이 존재할 수 있다.

추세연구(trend study, 경향연구), 코호트연구(cohort study)
패널연구(panel study)

* Statistical Analysis : DATA



- 모수적 방법 : student's t-test)
- 비모수적 방법 : Mann-Whitney test 시행

* Statistical Analysis : DATA

독립변수와 종속변수 데이터 유형별 분석기법 구분

		종속변수	
		연속형 data	범주형 data
독립변수	연속형 data	- 선형회귀분석 Artificial Neural Network, ANN - K-Nearest Neighbor(KNN)	- 로지스틱 회귀분석 - 판별분석 (LDA) - KNN
	범주형 data	- 회귀분석 - ANN regression trees	- ANN Decision Tree - 로지스틱 회귀분석

독립변수 데이터 유형별 분석기법 구분 (종속변수가 없는 경우)

독립변수	
연속형 data	범주형 data
- 주성분분석(PCA) - 군집분석	- 연관성분석 - 판별분석


* Statistical Analysis : DATA

독립변수	종속변수	모수적 통계방법	비모수적 통계방법
명목척도(범주2개)	비척도	student T-test paired T-test	Mann-Whitney test Wilcoxon rank sum test Wilcoxon signed rank test
범주형, 3개 이상	비척도	ANOVA	Kruskal-wallis test
범주형	범주형(1, 0)	카이제곱 검정 로지스틱 회귀분석	Fisher's exact test McNemar test
순위척도	범주형	경향분석(Test for trend)	
비 척도	비척도	회귀분석 (관계분석) 상관분석 (Pearson's correlation)	상관분석 Spearman correlation Kendall's tau
(범주형)	(범주형) + (비척도)	로지스틱 회귀분석	
(비 척도)(명목척도)	(비 척도)	공분산분석 (ANCOVA)	

- 1) 연령 (20세, 21세,) 비척도
- 2) 연령 (10세 미만, 10-19세, 20세 이상) 간격척도 혹은 순위척도
- 3) 연령 (19세 미만, 20세 이상) 순위척도 혹은 명목척도

변수들은 각기 고유의 척도를 가지지만 분석과정에서 **변수의 형태를 변환시키면** 그 척도가 달라진다.!!!

* Statistical Analysis



<https://pingouin-stats.org/build/html/index.html>

Pingouin is a Python 3 package and is currently tested for Python 3.7-3.10. It does not support Python 2.

1. ANOVAs: N-ways, repeated measures, mixed, ancova
2. Pairwise post-hocs tests (parametric and non-parametric) and pairwise correlations
3. Robust, partial, distance and repeated measures correlations
4. Linear/logistic regression and mediation analysis
5. Bayes Factors
6. Multivariate tests
7. Reliability and consistency
8. Effect sizes and power analysis
9. Parametric/bootstrapped confidence intervals around an effect size or a correlation coefficient
10. Circular statistics
11. Chi-squared tests
12. Plotting: Bland-Altman plot, Q-Q plot, paired plot, robust correlation...