

## 데이터 불균형 해결을 위한 Under-Sampling 기반 앙상블 SVMs

### EUS SVMs: Ensemble of Under-Sampled SVMs for Data Imbalance Problems

강필성, 조성준

서울대학교 산업공학과

{xfeel80, zoon}@snu.ac.kr

#### Abstract

패턴인식 문제에서 한 범주에 속한 데이터의 수가 다른 범주에 속한 데이터의 수보다 극히 많거나 적으면 데이터 불균형이 발생했다고 한다. Support Vector Machine(SVM)은 다른 기계 학습 알고리즘들과 마찬가지로 학습에 사용되는 데이터의 범주간 비율이 거의 비슷하다는 가정 하에서 학습을 하고 예측 결과를 도출하게 된다. 그러나 실제 문제에서는 데이터의 불균형이 발생하는 경우가 매우 빈번하며, 이러한 경우에는 모델의 성능이 매우 저하되는 문제점이 발생한다. 본 논문에서는 실제로 데이터 불균형이 SVM의 분류 결과에 어떠한 영향을 미치는지를 2차원 인공 데이터를 통하여 알아본다. 그리고 이러한 데이터 불균형을 해소하기 위하여 Under-Sampling 기반 앙상블 SVM을 제안하였다. 제안된 방법을 두 가지 인공 데이터에 적용하여 본 결과, 제안된 방법은 데이터 불균형을 해소하기 위해 사용되는 기존의 방법들에 비하여 소수 범주에 속하는 데이터의 수가 매우 적고 데이터의 불균형이 매우 심한 경우에도 높은 성능과 안정성을 갖는 효과적인 방법이라는 것이 입증되었다.

## 1. 서론

데이터 불균형(Data Imbalance)이란 분류 문제의 데이터에서 한 범주에 속하는 데이터의 수가 다른

범주들에 속하는 데이터의 수보다 현저히 적을 경우에 나타난다. 대부분의 패턴 인식 알고리즘들은 각 범주간의 비율이 거의 동일하다는 가정을 하고 학습을 하게 되는데, 실제 문제에서는 이러한 가정이 지켜지지 않는 경우가 빈번하게 발생한다. 예를 들어, Fraud Detection(Fawcett and Provost, 1997)은 다수의 휴대폰 사용자들 중에서 휴대폰 사용에 대한 사기 행위를 하는 사용자들을 찾아 내는 문제인데, 실제로 정상 사용자들에 비하면 사기 사용자들은 그 수가 매우 적기 때문에 데이터의 불균형이 발생한다. 이 외에도 Oil spill detection(Kubat et al., 1998), Response modeling(Shin and Cho, 2005), Remote sensing(Bruzzzone and Serpico, 1997), Scene classification(Yan et al., 2003)등에서 데이터 불균형 문제를 쉽게 확인할 수 있다.

데이터 불균형 문제는 Support Vector Machine(SVM)을 포함한 대부분의 기계학습 알고리즘의 성능을 저하시키는 요인들 중의 하나이다. 이는 두 가지의 중요한 요소에 기인한다. 첫 번째는 측정 지표의 부적절함이 야기하는 문제점이다. 예를 들어 소수 범주에 속한 데이터가 1%이고, 다수 범주에 속한 데이터가 99%인 2분류 문제를 생각해 보자. 이 경우 단순 정확도를 측정 지표로 사용하게 되면, 모든 데이터를 다수 범주로 분류함으로써 99%라는 높은 정확도를 얻을 수 있다. 그러나 정작 중요한 소수 범주에 속한 데이터를 전혀 판별하지

못하는 문제점을 표출하게 된다. 두 번째는 데이터의 분포가 야기하는 문제점이다. 소수 범주의 데이터에 비하여 다수 범주에 속하는 데이터의 수가 상대적으로 과도하게 분포함으로써 소수 범주의 영역을 침범하게 되고, 이는 정확한 분류 경계(Decision Boundary)를 설정하는데 장애가 된다.

측정 지표의 부적절함으로 나타나는 문제점을 해결하기 위해서, 단순 정확도가 아니라 다수 범주와 소수 범주의 정확도를 모두 고려하는 측정 지표들이 기존의 연구들에서 고려되었다(Kubat et al., 1997; Dumais et al., 1998; Chawla et al., 2002). 그리고 데이터의 분포에 의해 나타나는 문제점들을 해결하기 위해서 크게 세 가지 방법이 제안되었다. 첫째, Under-Sampling 기법은 정해진 규칙에 의해 소수 범주의 수만큼 다수 범주에서 데이터를 샘플링하여 사용한다. 이 방법은 계산 시간이 매우 짧다는 장점이 있으나 다수 범주에서 샘플링되는 데이터에 분류기의 성능이 크게 영향을 받을 수 있는 단점이 존재한다. 특히 이 문제는 소수 범주의 수가 매우 작은 경우 심각한 결과를 초래할 가능성이 매우 높다. 둘째, Over-Sampling 기법은 정해진 규칙에 의해 다수 범주의 수만큼 소수 범주에서 데이터를 샘플링한다. 이 방법은 모든 데이터의 정보를 사용할 수 있다는 장점이 있는 반면, 데이터의 수를 매우 증가시켜 계산에 소요되는 시간이 증가하는 단점이 있다. 셋째, Modifying Cost 방법은 오분류된 패턴에 서로 다른 페널티를 부과한다. 즉 소수 범주에 속하는 데이터가 오분류된 경우, 다수 범주에 속하는 데이터가 오분류되는 경우보다 큰 페널티를 부과하는 방식이다. 이 방법은 원래 데이터의 분포를 왜곡시키지 않는다는 장점이 있는 반면에, 데이터의 불균형이 매우 심할 경우, 그 효과가 Under-Sampling이나 Over-Sampling에 비하여 적다는 단점이 있다.

본 논문에서는 데이터 불균형이 나타나는 2범주 분류 문제에서 SVM을 사용하여 분류기를 구축할 때, Under-Sampling과 Over-Sampling, 그리고 Modifying Cost 기법들의 효과를 2차원 인공 데이터를 통하여 알아본다. 그리고 현존하는 방법들의 단

점을 극복하기 위하여 Under-Sampling 기반 앙상블 SVM(EUS SVMs: Ensemble of Under-Sampled SVMs)을 제안하였다. EUS SVMs는 앙상블 기법을 도입함으로써, 소수 범주 데이터의 수가 매우 적은 경우, Under-Sampling이 갖는 단점을 보완해 줄 수 있다. 그리고 Over-Sampling의 단점인 소수 범주를 다수 범주의 수만큼 샘플링 함으로써 발생하는 긴 학습 시간 또한 어느 정도 극복할 수 있다. 본 논문에서는 데이터 불균형이 나타나는 2차원 인공데이터에 EUS SVMs를 적용하여 실험을 수행하고 그 결과를 분석함으로써 EUS SVMs의 효과를 입증하고자 한다.

본 논문의 구성은 다음과 같다. 2장에서는 우선 단순 정확도로는 측정하기 어려운 불균형 데이터의 성능 척도에 대해서 언급하고 이를 해결할 수 있는 성능 척도를 선정한다. 이어서 2차원 인공 데이터를 통하여 데이터의 불균형과 적은 소수 범주 데이터의 수가 실제로 분류기의 성능에 어떠한 영향을 끼치는가를 알아본다. 3장에서는 EUS SVMs에 대한 설명을 하고 4장에서는 EUS SVMs의 성능 비교 실험을 위한 비교 방법론들과 실험 디자인에 대하여 설명한다. 또한 실험 결과를 토대로 EUS SVMs의 효과를 알아보도록 한다. 마지막으로 5장에서는 결론과 함께 추후 연구 방향을 알아보도록 하겠다.

## 2. 데이터 불균형의 영향

### 2.1 성능 척도

소수 범주에 속하는 데이터들을 Positive라고 하고, 다수 범주에 속하는 데이터들을 Negative라고 하자. 일반적으로 분류문제에서의 성능 척도로는 [표 1]에서  $(TP + TN) / (TP + FN + FP + TN)$ 으로 계산되는 정확도(Accuracy)를 사용하게 된다. 그러나 1장에서도 잠시 언급하였듯이, 데이터 불균형 문제에서는 TN이 정확도에 미치는 영향이 TP보다 훨씬 크기 때문에 대부분을 다수 범주로 분류하게 된다. 이러한 문제점을 해결하기 위하여 몇 가지 측정 지표들이 제안되었으며 본 논문에서는 Kubat et al.(1997)

[표 1] 성능 척도

|             |          | Predict                |                        |
|-------------|----------|------------------------|------------------------|
|             |          | Positive               | Negative               |
| Act-<br>ual | Positive | True Positive<br>(TP)  | False Negative<br>(FN) |
|             | Negative | False Positive<br>(FP) | True Negative<br>(TN)  |

에서 제안된 다수 범주의 정확도와 소수 범주의 정확도를 모두 고려한 Geometric Mean을 사용한다. 이는 소수 범주와 다수 범주의 정확도를 동등하게 고려하는 방법이다. A+는 소수 범주에 대한 정확도로써  $TP/(TP+FN)$ 으로 계산된다. A-는 다수 범주에 대한 정확도로써  $TN/(FP+TN)$ 으로 계산된다. 그리고 Geometric Mean은 A+와 A-의 기하평균으로써  $\sqrt{(A+) \cdot (A-)}$ 로 계산된다.


## 2.2 충분한 소수 범주 데이터

실제로 소수 범주의 데이터가 충분하면서 데이터가 불균형을 나타내는 경우 SVM의 성능이 어떠한 영향을 받는지 알아보기 위하여 인공 데이터를 생성하여 그 영향을 알아보았다. [표 2]과 같이 소수 범주 데이터의 수가 320개이며 불균형의 비율이 1:1, 1:3, 1:5, 1:10, 1:30, 1:50인 6개의 4×4 Checker Board 데이터를 생성하였다. 이 데이터 셋에 대하여 SVM을 기본 분류기로 하여 분류를 한 결과는 [그림 1]과 같다. 그림에서 실선으로 나타난 부분이 범주간의 경계선이다. 실제로 소수 범주와 다수 범주의 차이가 크게 나지 않는 경우([그림 1] (a), (b))에는 두 범주 사이의 경계가 원래 경계와 비슷함을 알 수 있다. 그러나 불균형이 심해질수록 다수 범주의 데이터가 소수 범주의 영역을 침범하게 되어 소수 범주의 영역이 점점 작아지는 것을 확인할 수 있다([그림 1] (c), (d)). 그리고 극단적인 불균형을 나타내는 상황에서는 분류기가 소수 범주에 대한 영역을 거의 설정하지 않는 것을 볼 수 있다([그림 1]


[표 2] 4×4 Checker Board Data Sets

| Set | 소수범주 | 다수범주   | Total  | 비율   |
|-----|------|--------|--------|------|
| A1  | 320  | 320    | 640    | 1:1  |
| A2  | 320  | 960    | 1,280  | 1:3  |
| A3  | 320  | 1,600  | 1,920  | 1:5  |
| A4  | 320  | 3,200  | 3,520  | 1:10 |
| A5  | 320  | 9,600  | 9,920  | 1:30 |
| A6  | 320  | 16,000 | 16,320 | 1:50 |

(e), (f)). 이 실험 결과에 대한 성능 척도는 [그림 2]과 같다. [그림 2]에서 나타난 것처럼 범주 간 불균형이 심해질수록 소수 범주에 대한 정확도(A+)가 크게 감소하고 이에 따라서 Geometric Mean도 감소하는 것을 확인할 수 있다. 그러나 단순 정확도(Accuracy)는 꾸준히 증가하는 경향을 나타내는데, 이는 2장에서 설명한 바와 같이 단순 정확도는 다수 범주의 정확도(A-)에 영향을 크게 받기 때문이며 따라서 데이터 불균형 문제에서는 적절한 지표가 될 수 없음을 다시 한번 확인할 수 있다. 이 인공 데이터에 대하여 기존의 해결 방안인 Under-Sampling, Over-Sampling, Modifying Cost방법을 사용한 결




[그림 1] SVM을 이용한 4×4 Checker Board Data 분류 결과 (소수 범주:다수 범주)




[그림 2] 소수범주와 다수범주의 비율에 따른 성능 척도

과는 [그림 3], [그림 4]와 같다. A1데이터는 범주 간 비율이 1:1이므로 모든 방법에서 값들이 동일하게 나타난다. [그림 3]에서 확인할 수 있듯이 Modifying Cost기법은 나머지 두 기법에 비하여 성능의 향상이 미미하다. 또한 불균형이 매우 심한 경우에는 원래의 SVM과 비교하여 성능의 향상을 보여주지 못할 뿐만 아니라, 최적의 파라미터 조건 하에서 수행시간이 매우 길게 나타나는 것을 확인할 수 있다. Geometric Mean의 측면으로 보면, Under-Sampling과 Over-Sampling 모두 데이터 불균형을 상당히 해소시킬 수 있으며, 그 중에서도 Over-Sampling이 높은 수치를 나타낸다. 그러나 수행 시간의 측면으로 보면 데이터의 불균형이 심해지더라도 Under-Sampling은 크게 영향을 받지 않는



[그림 3]기존 해결 방안들의 Geometric Mean



[그림 4]기존 해결 방안들의 수행시간(단위:초, 로그 간격)

반면에 Over-Sampling은 데이터의 수에 비례하여 기하급수적으로 증가한다[그림 4]. 따라서 두 가지 측면을 고려해 볼 때, Under-Sampling이 기존 방법들 중에서 가장 효과적인 방법이라고 할 수 있다.


## 2.3 불충분한 소수범주 데이터

비록 앞 절에서 Under-Sampling의 효과가 입증되었으나, 1장에서도 잠시 언급하였듯이 이 방법은 전체 데이터의 분포를 왜곡시킬 수 있는 문제점을 내재하고 있다. 앞 절의 경우처럼 소수 범주 데이터의 수가 충분한 경우에는 데이터 분포의 왜곡이 심하게 일어나지 않지만 소수 범주 데이터의 수가 매우 적은 경우에는 데이터 분포의 왜곡이 핵심적인 문제가 될 가능성이 매우 크다. 따라서 이 절에서는 소수 범주 데이터의 수가 매우 적은 인공 데이터를 생성하여 Under-Sampling 방법이 야기하는 데이터 분포 왜곡 현상이 어느 정도인지를 알아보기로 한다. 이를 위하여 [표 3]과 같이 소수 범주 데이터의 수가 80개이며 불균형의 비율이 1:5, 1:10, 1:30, 1:50, 1:100인 5개의 4×4 Checker Board 데이터(Set B)를 생성하였다. 이 데이터와 소수 범주의 수가 충분한 4×4 Checker Board 데이터(Set A)에 Under-Sampling을 적용한 결과의 비교는 [그림 5]와 같다. 두 경우 모두 Geometric Mean의 측면에서 보면 상당히 높은 수치를 보여주고 있다. 그러나 유의해야 할 점은 비록 두 데이터에서 비슷한 수준의

[표 3] 4×4 Checker Board Data Sets

| Set | 소수범주 | 다수범주  | Total | 비율    |
|-----|------|-------|-------|-------|
| B1  | 80   | 400   | 480   | 1:5   |
| B2  | 80   | 800   | 880   | 1:10  |
| B3  | 80   | 2,400 | 2,480 | 1:30  |
| B4  | 80   | 4,000 | 4,080 | 1:50  |
| B5  | 80   | 8,000 | 8,080 | 1:100 |

Geometric Mean을 보여주고 있지만, 소수 범주의 수가 불충분할 경우, 소수 범주의 정확도와 다수 범주의 정확도의 차이가 매우 크게 나타난다. 이는 Under-Sampling에서 소수범주의 영역을 실제 영역보다 더 크게 설정했기 때문에 나타나는 현상이다. 따라서 소수 범주의 수가 매우 적은 경우에 Under-Sampling은 소수 범주의 영역을 실제보다 크게 설정함으로써 다수 범주의 영역을 심각하게 침범하는 데이터 분포의 왜곡을 야기시키게 된다.



[그림 5] 소수범주의 수가 충분할 때(a)와 그렇지 않을 때(b)의 Under-Sampling의 성능

### 3. EUS SVMs: Ensemble of Under-Sampled SVMs

본 논문에서는 앞에서 언급된 데이터의 불균형이 심하고, 소수 범주에 속하는 데이터의 수가 매우 적은 경우 Under-Sampling이 가지는 단점을 극복하기 위하여 Ensemble of Under-Sampled SVMs (EUS SVMs)를 제안하였다. [그림 6]와 [그림 7]은 EUS SVMs의 Algorithm을 설명한 것이다. EUS SVMs의 첫 번째 단계에서는 전체 학습 데이터를 소수 범주 데이터와 다수 범주 데이터로 분류한다. 두 번째 단계에서는 다수 범주 데이터에서 소수 범주 데이터의 수만큼 비 복원 랜덤 추출을 하여 하나의 데이터 집합을 생성한다. 하나의 데이터 집합이 생성되면 다시 전체 다수 범주의 데이터를 사용하여 새로운 데이터 집합을 생성한다. 이 방법을 사용함

$$D = D_{Min} \cup D_{Maj}$$

%  $D$  : Total Dataset,  $D_{Min}$  : Minority Dataset,  $D_{Maj}$  : Majority Dataset

for  $i = 1$  to population

$$SD_i = \phi \quad \% SD_i : i^{th} \text{ Sampled Dataset}$$

for  $j = 1$  to  $|D_{Min}|$

%  $|D_{Min}|$  : The number of Data in Minority Class


$$SD_i = SD_i \cup \{x_j; x_j \in D_{Maj}, x_j \notin SD_i\}$$

end

$$ED_i = SD_i \cup D_{Min} \quad \% ED_i : i^{th} \text{ Ensemble Dataset}$$

end

[그림 6] EUS SVMs Algorithm



[그림 7] EUS SVMs의 학습 데이터 구축


으로써, 복원 추출시의 데이터의 중복을 방지 하는 효과와 비 복원 추출을 할 경우 소수 범주 데이터의 수에 앙상블의 크기가 영향을 받는 단점도 극복할 수 있다. 마지막으로 앙상블의 크기만큼 다수 범주에서의 데이터 집합 생성이 완료되면 각각의 데이터 집합과 소수 범주 데이터를 결합하여 범주 비율이 동일한 학습 데이터를 생성한다. 이러한 절차를 통하여 앙상블 학습 데이터를 구성함으로써, 소수 범주에 의해 데이터의 분포가 왜곡되지 않으면서 높은 성능을 나타내는 분류기를 구축할 수 있게 된다.

EUS SVMs가 다른 방법에 비하여 높은 안정성을 나타낼 수 있는 이유는 다음 두 가지로 설명될 수 있다. 첫째, 데이터 분포의 왜곡이 가져오는 문제점을 감소시킬 수 있다. 기존의 Under-Sampling 방법은 다수 범주에서 소수 범주의 데이터의 수만큼을 샘플링한 하나의 학습 데이터만을 사용한다. 이러한 경우, 어떠한 데이터들이 추출되는가에 따라서 다수 범주와 소수 범주의 영역이 큰 영향을 받을 수 있고, 이는 분류기의 불안정성의 원인이 될 수 있다. 그러나 제안된 방법에서는 앙상블의 인구 수와 같은 수의 학습 데이터 셋을 구성하기 때문에 다수 범주에 속한 데이터가 추출될 확률이 Under-Sampling 방법에 비하여 높아지고, 따라서 전체 데이터의 분포를 왜곡할 확률은 낮아지게 된다. 둘째, 제안된 방법은 앙상블을 사용함으로써, 개별 분류기의 성능 편차를 줄일 수 있다. 실제로 학습이 잘 되어 있는 분류기는 학습 데이터에 과적합할 확률이 높다. 그러나 이러한 개별 분류기들을 앙상블하여 결과를 취합함으로써, 일반화 성능을 향상시키고 높은 안정성을 보장할 수 있다.

## 4. 실험 설계 및 결과

### 4.1 Data

EUS SVMs의 효과를 알아보기 위하여 3장에서 언급된 4×4 Checker Board Data(Set B)와 2차원의 Spiral 데이터를 생성하여 실험을 수행하였다. 두 데이터에서 다수 범주와 소수 범주의 비율, 각 범주



[그림 8] 4×4 Checker Board Data(Set B, 왼쪽)와 2차원의 Spiral 데이터(오른쪽)(실선은 SVM을 통해 나타난 범주간 경계)

에 속하는 데이터의 수는 [표 3]와 같고 데이터의 분포는 [그림 8]과 같다.

### 4.2 앙상블 취합 방법


EUS SVMs는 앙상블 기법에 기반한 방법이므로 개별 분류기의 결과를 취합하여 앙상블의 전체 결과를 도출하는 방법에 따라 결과가 달라지게 된다. 본 실험에서는 세 가지의 앙상블 결합 방식을 사용하여 각 방식간의 성능을 비교하였다. 첫 번째는 앙상블을 취합하는데 가장 널리 사용되는 Majority Voting 방식이다. 이는 앙상블 내의 각 분류기가 데이터의 범주를 결정하면 가장 많이 도출된 범주가 전체 앙



상불의 범주가 되는 방식이다. 두 번째는 Weighted Voting 방식이다. 이는 앙상블 내의 각 분류기는 학습 예제가 다르게 나타날 수 있으므로 이를 고려하여 학습 예제가 적게 나타나는 분류기에 보다 높은 가중치를 주어 결과를 취합하는 방식이다. 본 실험에서의 측정 지표는 Geometric Mean이므로 학습 과정에서 Geometric Mean이 높은 분류기에 가중치를 높게 주어 결과를 취합하였다. 세 번째로 사용된 방법(Function Values Aggregation)은 SVM의 함수 값을 사용하는 것이다. 실제로 SVM의 결과값은 함수 값의 부호로 정해진다. 그러나 이 경우 절대값만이 중요할 뿐 실제 값은 결과값에 함수 값 자체가 내포하는 정보를 전달하지 못하게 된다. 이는 데이터의 함수 값의 절대값이 클수록 범주간 경계에서 멀리 위치한 데이터라는 해석을 할 수 있기 때문이다. 따라서 세 번째 방식은 함수 값 자체를 중요하게 생각하여 앙상블의 개별 분류기에서 도출된 결과값을 모두 더하고, 그 부호에 따라 데이터의 범주를 할당하는 방식이다.

### 4.3 실험 결과

4×4 Checker Board Data(Set B)와 Spiral Data에 대한 Under-Sampling과 EUS SVMs의 결과는 [그림 9]에 나타나 있다. 이를 통하여 다음과 같은 결과를 도출할 수 있다. 첫째, Under-Sampling과 EUS SVMs 모두 데이터의 불균형을 해소하는데 있어 No-Sampling보다 효과적인 방법이다. 특히 데이터의 불균형이 심해질수록 No-Sampling과의 성능 차이가 많이 나타나는 것으로 볼 때, 심한 데이터 불균형의 상황에서 두 방법은 모두 효과적인 대처방안이 될 수 있다. 둘째, Under-Sampling과 EUS SVMs를 비교해보면 10가지의 모든 상황에 대하여 EUS SVMs가 우월한 성능을 나타낸다. 또한 데이터의 불균형이 심해짐에 따른 성능의 차이에 편차가 없으므로, EUS SVMs는 데이터 불균형의 정도에 상관 없이 Under-Sampling 방법에 비하여 높은 성능을 보장할 수 있다. 마지막으로 앙상블의 결과 취합 방법에 따른 차이를 보면, 4×4 Checker Board



[그림 9] 4×4 Checker Board Data(Set B)와 Spiral Data에 대한 실험 결과 (Geometric Mean<sup>1</sup>, MV: Majority Voting, WV: Weighted Voting, FVA: Function Values Aggregation)

Data에 대해서는 Function Values Aggregation 방법이 가장 높은 성능을 나타내는 경우가 많고, Spiral Data의 경우에는 Majority Voting 방법이 가장 높은 성능을 나타내는 경우가 많다. 그러나 세 방법 간의 성능 차이는 통계적으로 유의한 수준이 아니며, 따라서 세 방법 사이에 큰 편차는 존재하지 않는다고 할 수 있다.

실험 결과에서 알 수 있듯이, EUS SVMs는 Under-Sampling SVM에 비하여 높은 성능을 나타낸다. 이는 EUS SVMs가 가지고 있는 두 가지의 특성에 기인한다. 첫째, EUS SVMs는 학습 데이터에

<sup>1</sup> (a) 4×4 Checker Board Data (Set B)에 대한 No-Sampling의 결과는 0.732, 0.663, 0.498, 0.335, 0.316 (1:5부터 1:100의 순서)이고, (b) Spiral Data에 대한 No-Sampling의 결과는 0.756, 0.724, 0.700, 0.568, 0.524 (순서는 위와 동일)이다.

속하는 소수 범주와 다수 범주의 데이터의 비율을 동일하게 유지하면서 앙상블의 인구수와 같은 학습 데이터 셋을 사용한다. 이는 EUS SVMs로 하여금 Under-Sampling 방법에 비하여 다수 범주의 분포를 왜곡시킬 확률을 줄임으로써, 분류기가 소수 범주에 비 정상적으로 집중하는 것을 방지한다. 둘째, EUS는 일반적으로 단일 분류기보다 일반화 성능이 높다고 알려진 앙상블을 사용함으로써, Under-Sampling에서 사용되는 개별 분류기들에 비하여 성능의 편차를 줄일 수 있고, 이는 높은 분류 성능을 가능하게 한다.

## 5. 결론

데이터 불균형 문제는 패턴 인식과 기계 학습 분야에서 지속적으로 연구되어온 중요한 이슈 중의 하나이다. 본 논문에는 소수 범주에 속하는 데이터가 매우 적은 경우, 데이터 불균형이 실제로 분류기의 성능에 미치는 영향을 2차원 인공 데이터를 통하여 알아보고 지금까지 제안된 방법들의 단점을 극복하기 위하여 랜덤 샘플링 기반 앙상블 SVM(RSBE SVM)을 제안하였다. 제안된 RSBE SVM을 두 가지의 인공 데이터에 적용하여 실험을 수행하고 기존의 기법들에 비하여 우수한 성능을 나타내는 것을 확인하였다. 본 연구의 후속으로 다음과 같은 연구들이 진행될 수 있다. 본 연구에서는 다수 범주의 데이터를 랜덤하게 샘플링하여 앙상블에 필요한 학습 데이터들을 구축하였다. 따라서 다수 범주의 데이터를 랜덤하게 샘플링하지 않고, K-Means 클러스터링이나 SOM(Self Organizing Map)등의 기법을 사용하여 비슷한 특징을 가지고 있는 군집을 이룬 후 이를 앙상블 학습 데이터로 구축할 수 있을 것이다. 또한 소수 범주의 데이터가 매우 적기 때문에 본 논문에서는 이를 처리하는 방법을 다루지 않았으나, 소수 범주가 가지고 있는 정보의 활용을 극대화하기 위하여 이 데이터들을 Noise Addition등의 기법을 통하여 효과적으로 샘플링하여 다수 범주의 데이터와 결합하는 연구가 진행될 수 있을 것이다.

## 6. 참고 문헌

- Bruzzone, L., Serpico, S.B. (1997), Classification of imbalanced remote-sensing data by neural networks, *Pattern Recognition Letters* **18**(11-13), pp. 1323-1328.
- Chawla, N.V., Hall, L. and Kegelmeyer, W. (2002), SMOTE : Synthetic Minority Oversampling Techniques, *Journal of Artificial Intelligence Research* **16**, pp. 321-357.
- Dumais, S., Platt, J., Heckerman, D., and Sahami, M. (1998), Inductive Learning Algorithms and Representations for Text Categorization. *Proceedings of the Seventh International Conference on Information and Knowledge Management*.
- Fawcett, T. and Provost, F. (1997), Adaptive Fraud Detection, *Data Mining and Knowledge Discovery* **1**(3), pp. 291-316.
- Kubat, M., Holte, R. and Matwin, S. (1997), Learning when Negative Examples Abound, *Proceedings of the 9th European Conference on Machine Learning*, ECML'97.
- Kubat, M., Holte, R. and Matwin, S. (1998), Machine Learning for the detection of oil spills in satellite radar images, *Machine Learning* **30**(2), pp. 195-215.
- Shin, H.J. and Cho, S.Z. (2006), Response Modeling with Support Vector Machines, *Expert Systems with Applications*, **30**(4), pp. 746-760.
- Yan, R., Liu, Y., Jin, R., Hauptman, A. (2003), On Predicting Rare Classes With SVM Ensembles in Scene Classification, *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP'03)*.