

AUROC기반의 부도예측 앙상블 모형*, **

윤 우 섭*** · 김 명 중****

논문초록

본 연구는 범주 불균형이 존재하는 기업부도 예측문제를 해결하기 위하여 AUROC 기반의 앙상블 학습기법인 AUCBoost 모형을 제안한다. AdaBoost 알고리즘은 오분류된 표본에 강화된 학습기회를 제공하는 장점이 있지만, 산술평균에 기초하여 기저 분류자의 결합 가중치를 결정한다는 점에서 범주 불균형 문제의 해결에 한계점이 있다. AUCBoost 알고리즘은 범주 불균형의 성과지표로 활용되는 AUROC를 활용하여 AdaBoost 앙상블 학습을 수정한 부스팅 기법이다. AUCBoost 알고리즘은 이차계획법을 활용하여 최종 분류자의 AUROC를 최대화하는 것을 학습목표로 한다. 실증분석을 위하여 정상기업 10,000개의 관측치와 500개 부도기업 관측치로 구성된 샘플을 수집하여 범주 불균형 비율에 따라 5개의 하위 샘플로 구성하였다. 7개 재무비율 군에서 가장 높은 AUROC를 가진 7개의 재무비율을 독립변수로 선정하였다. 각 하위 샘플별로 30회의 교차타당성 검증을 수행한 결과, 첫째, 범주 불균형 비율은 앙상블 학습 성과에 부정적인 영향을 미치는 것으로 분석되었다. 둘째, AUCBoost 알고리즘은 기존 AdaBoost 앙상블 학습의 유의한 성과개선 효과를 제공하는 것으로 분석되었다. 마지막으로 범주 불균형 정도가 심해질수록 AUCBoost의 성과개선 효과가 높아지는 것으로 분석되었다.

주제어

부도 예측, 범주 불균형, AdaBoost, AUCBoost

경제학 문헌분류

G17, M15, M41

한국연구재단 분류 연구분야 코드

B050200, B030200

접수일(2021년 8월 9일), 1차 수정일(2021년 9월 23일), 게재확정일(2021년 9월 30일)

* 본 연구는 과학기술정보통신부 및 정보통신기획평가원의 대학CT연구센터지원사업의 연구결과로 수행되었음 (IITP-2020-0-01797)

** 본 연구는 2021 경영정보관련 학회 춘계통합학술대회에서 발표한 내용을 수정 보완하였음

*** 주저자, 부산대학교 경영대학 경영학과 학사과정(tpdbs4032@pusan.ac.kr)

**** 교신저자, 부산대학교 경영대학 경영학과 교수(mjongkim@pusan.ac.kr)

AUROC-based Ensemble Model for Bankruptcy Prediction

Wooseob Yun* · Myoung Jong Kim**

Abstract

This paper proposes an AUCBoost model to address the class imbalance problem inherent in bankruptcy prediction. AdaBoost algorithm has the advantage of providing reinforced learning to misclassified samples. However, since the set of weights for combining the predictions of the base classifier is determined by the concept of prediction accuracy, it has a limitation in resolving class imbalance problem. AUCBoost algorithm is a boosting technique that replaces AdaBoost's predictive accuracy with AUROC. The goal of AUCBoost is to maximize the AUROC of the final classifier through iterative search for a set of weights to combine the base classifiers using quadratic programming. For empirical experiments, a sample consisting of 10,000 non-bankruptcy instances and 500 bankruptcy instances is collected and divided into 5 subsamples with different imbalance ratio values. As explanatory variables, the seven financial ratios with the highest AUROC are selected from the seven financial ratio groups. 30 cross-validations are performed for each subsample. The main findings are as follows. First, the class imbalance problem has a negative effect on the performance. Second, AUCBoost makes a significant contribution to performance improvements of AdaBoost ensembles. Finally, the effect of AUCBoost on the performance improvement is more magnified as the imbalance ratio value increases.

Keywords

Bankruptcy Prediction, Class Imbalance, AdaBoost, AUCBoost

JEL Classification

G17, M15, M41

* Main Author, Undergraduate Student, School of Business, Pusan National University (tpdbs4032@pusan.ac.kr)

** Corresponding Author, Professor, School of Business, Pusan National University (mjongkim@pusan.ac.kr)

I. 서론

제 4차 산업혁명 시대에서 핀테크(Fintech) 혹은 디지털 금융(Digital Finance)이란 개념이 금융 산업의 핵심 키워드로 부상하고 있다(Gartner, 2016). 전통적인 개념의 핀테크와 디지털 금융은 모바일을 기반으로 하는 편리성에 초점을 두었지만, 플랫폼을 기반으로 대출자와 투자자를 연결하는 P2P금융(김은미·박지영, 2019), 개인신용, 부동산담보부 대출 뿐 아니라 전자어음(신현규·안수현, 2020)을 발행하여 기업의 자금 조달업무를 보조하는 등 적용범위가 확대되고 있다. 특히, 최근에는 금융 프로세스에서 가장 보수적인 영역으로 꼽히는 신용평가 업무 역시 인공지능(AI)과 빅데이터의 영역으로 편입되고 있다. 빅데이터/AI 관련 기술을 신용평가 프로세스에 접목함으로써 기존의 신용평가시스템이 지니는 한계를 극복하고 빅데이터 및 머신러닝(Machine Learning) 기술을 플랫폼 기반 금융 네트워크와 연계한 신용평가시스템의 선진화는 치열한 글로벌 경쟁에서 생존하기 위한 금융기업의 성장전략으로 자리 잡고 있다. 제 4차 산업혁명 시대의 금융혁신 추이에 발맞추어 미국 등 금융 선진국에서는 방대한 신용 데이터베이스를 구축하고 빅데이터/AI를 접목하여 보다 정교한 신용평가시스템을 확보함으로써 금융 산업에서 글로벌 경쟁력을 제고하고 있지만, 아직 국내 금융기관들은 통계모형을 기반으로 하는 초기 단계의 신용평가 시스템만이 도입된 실정이다.

특히, 국내 금융기관들에서 활용되는 통계모형 기반의 기업부도 예측모형은 엄격한 통계적 가정에 의하여 다음과 같은 한계점을 가진다. 첫째, 통계모형 기반의 부도예측모형은 독립변수의 정규성과 두 집단(부도 기업군 및 건전 기업군)의 동분산성이라는 통계적 가정을 전제하기 때문에 이론적 타당성이나 실무에 대한 적용 가능성에 제약을 가진다. 둘째, 부도예측모형의 정확성 개선에 대한 대표적인 난제로서 부도 기업과 건전 기업의 표본 수가 동일하지 않은 범주 불균형 문제(Class Imbalance Problem)가 존재한다. 범주 불균형 문제는 다른 범주들에 속하는 표본에 비하여 하나의 범주에 속하는 표본이 현저하게 크게 나타나는 왜곡된 표본분포(Skewed Sample Distribution)로 정의된다. 기업의 부도는 발생 빈도가 드문 사건으로 무디스(Moody's) 등 전문신용평가기관은 국내 외부감사 법인의 10년 장기평균 부도율을 약 3%에서 5% 수준으로 예상한다. 범주 불균형 문제를 완화하기 위하여 산업 및 규모 기준의 층화추출법(Stratified Sampling)을 이용하여 1:1 균형 표본을 학습하여 기업부도 예측모형을 개발하고 있지만, 이러한 층화추출법은 필연적으로 데이터의 정보손실을 초래한다.

본 연구에서는 현재의 국내 금융 시스템의 현황을 고려하고 국제적 금융혁신의 추세에 따라 4차 산업혁명의 핵심 기술인 AI 기반의 선진화된 부도예측모형으로서 AUROC(Area Under Receiver

Operating Characteristic) 기반의 부스팅(Boosting) 모형인 AUCBoost 모형을 제안하고자 한다. 본 연구에서 제안한 AUCBoost 모형의 개발 및 성과측정을 위한 변수로써 30개 재무비율을 7개의 재무비율 군으로 분류하였으며, 각 재무비율 군별로 AUROC가 가장 우수한 7개의 재무비율을 최종 변수로 선정하였다. 모형의 성과를 측정하기 위한 표본수집 과정은 다음과 같이 두 단계로 진행되었다. 첫 번째 단계에서 2015년부터 2018년까지 4개년 동안 500개의 부도 기업과 10,000개의 기업-연도별 건전 기업 표본을 수집하였다. 두 번째 단계에서는 다양한 범주 불균형 환경 하에서 모형의 성과를 측정하기 위하여 K-Means Clustering(or Centroids) 기법을 이용한 Under-Sampling을 수행하여 건전 기업과 부도 기업의 비율이 다음과 같이 A(1:1), B(2:1), C(4:1) D(10:1) 및 E(20:1)인 5개 하위표본으로 재구성하였다. 본 연구의 연구모형으로 기업부도 예측모형의 성과개선을 위하여 선행 연구에서 학습 성과의 개선능력이 검증된 부스팅 기법을 활용하였다. 기저 분류자(Base Classifier)로서 20개의 3층 퍼셉트론 인공신경망(3-Layered Perceptron Neural Networks)을 구현하였다. 기저 분류자의 개별적인 학습 결과를 결합하여 최종결과를 도출하기 위하여 AdaBoost 기법과 본 연구에서 제안하고 있는 AUCBoost 모형을 대체적으로 활용하였다. 대체적 모형의 성과 비교를 위하여 10-fold 교차 타당성 (Cross Validation) 분석을 3회 수행하여 총 30회의 교차타당성 분석을 수행하였다. 대체적 모형의 성과를 비교한 결과, AUCBoost 모형은 AdaBoost 모형의 유의적인 성과개선에 긍정적인 효과를 제공하고 있음을 확인하였다.

II. 연구의 배경 및 선행연구고찰

1. 국내의 기업부실 현황

기업의 부실화는 기업의 직접적인 이해관계자뿐만 아니라 국민경제에 막대한 손실을 초래한다. 주주들에게는 주식 가치의 하락으로 인한 경제적 손실을 초래하며 채권자들에게는 채권 회수의 어려움을 가중시키며, 종업원들도 고용 상실의 위험에 직면하게 된다. 국민경제적 입장에서 기업도 산으로 부실채권이 양산되고 연쇄적 도산이 발생함으로써 금융기관의 부실화가 초래될 수 있다. 정부 입장에서도 조세수입이 감소하게 되고, 국민경제 측면에서도 실업의 증가, 경제성장 둔화, 금융기관 부실, 연쇄도산, 국가신인도 저하 등의 문제들이 초래될 수 있다.

2021년 6월 발간된 한국은행 금융 안전보고서에 따르면 COVID-19의 장기화에 따른 신용자금 수요 등에 따라 대출이 급증한 것으로 보고되고 있다. 기업 대출은 2021년 1/4 분기 말 1,402.2조 원으로 전년 동기 대비 14% 급증하였다. 그중 대기업 대출은 205.7조 원으로 전년 동기 대비 5.4% 상

승하여, 주가 상승을 배경으로 직접 금융시장을 통한 자금 조달이 용이하여 대출 증가율이 낮지만, 직접 금융시장을 통한 자금 조달이 어려운 중소기업은 운전자금 수요로 대출 규모가 1,103.4조 원으로 전년 동기 대비 17% 급증하여 재무 건전성 관리가 필요한 것으로 분석되었다. 특히, 2020년 말 기준 부채비율 200%를 초과하는 기업은 상반기보다 부채비율이 23.6%에서 28.8%로 상승하였고 이자보상배율 1 미만 기업 비중도 47%에서 50.9%로 상승하는 등 주요 재무지표가 악화되었다. 실질적으로 2019년까지의 한계 기업 수는 COVID-19 이전부터 지속해서 증가해왔고, 2020년 말 현재 법 인파산 접수 건수는 2013년 집계 이후 최고치에 이르고 있다. 한국은행은 2021년 하반기 금리상승을 예고하고 있으며, 미중 분쟁이 재점화되는 양상을 보이는 등, 차후 글로벌 경제상황이 한국기업에 우호적이지 않은 것으로 분석되고 있다. 이러한 상황에서 기업 부실이 사회경제에 주는 전반적인 영향이 이전보다 확대될 것이고 이를 사전에 예방하기 위한 노력이 더욱 필요한 것으로 언급되고 있다.

이러한 흐름 속에서 금융기관은 기업부도 예측의 중요성을 인식하고 부도예측모형을 개발하고자 하는 노력이 지속해서 이어져 왔다. 단변량 모델(Beaver, 1996)을 시초로 다변량 분석기법인 판별분석(Multivariate Discriminant Analysis)(Altman, 1968)과 Logistic 분석(Dimitras, 1996; Ohlson, 1980) 등 통계 모형이 적용되었다. 인공지능기법이 개발된 이후 기계학습 분야의 적용으로 귀납적 학습 방법(Messier et al., 1998), SVM(Support Vector Machine)(Shin et al., 2005), 의사결정나무(Decision Tree)(Buta, 1994), 인공신경망(Artificial Neural Network)(Tam et al., 1992) 등 다양한 기법들이 부도예측모형 개발에 활용되어 왔다. 최근의 연구들은 최적 변수의 선택 문제(홍승현·신경식, 2003), 입력 데이터 정규화 문제(Tai et al., 2010) 및 최적 분류자 문제(Kim, 2009) 등에서 유전자 알고리즘(Generic Algorithm)에 기반한 최적화 기법을 부도예측에 적용하고 있으며, 딥러닝(Deep Learning) 기법에 기반한 부도예측모형(김형준 외, 2019; 권혁건 외, 2017)의 개발도 활발하게 진행되고 있다.

2. 범주 불균형 문제

범주 불균형 문제란 특정 범주에 속하는 표본의 수가 타 범주들에 속하는 표본 수보다 현저하게 많을 경우 나타난다. 범주 불균형 문제는 카드 사기, 보험사기, 기름유출 탐지 등 여러 현실 문제에서 빈번하게 관찰되는 문제이다. 범주 불균형 문제가 부도예측모형의 성과를 저하하는 대표적인 원인으로, 다변량판별분석, 로지스틱 분석 및 인공신경망에 기반한 부도예측모형은 훈련 데이터에 대한 학습 결과로서 판별함수를 산출하게 되는데, 범주 불균형이 존재하는 경우, 판별함수는 다수 범주(Majority Class)에 편향(Biased)되어 구성되며, 결과적으로 소수 범주에 분류 정확성이 낮아진

다. 결과적으로 범주 불균형이 심화하는 경우 모든 사례를 다수 범주로 판단하게 된다. 인공신경망을 활용한 많은 연구에서 범주 불균형 문제로 인하여 인공신경망의 예측성능이 낮아짐을 보고되고 있다(Buda et al., 2018). 분류 경계영역(Decision Boundary)을 활용하는 의사결정트리(Decision Tree), 랜덤 포레스트(Random Forest), 베이지안 네트워크(Bayesian Network) 및 SVM 등과 같은 부도예측모형에서는 범주 불균형 비율이 증가할수록 다수 범주 표본의 분류 경계영역이 소수 범주 표본의 분류 경계영역을 침해하여 소수 범주의 영역이 점차로 축소하게 된다. 이러한 왜곡된 학습의 결과로서 소수 범주에 대한 분류 정확성이 급격하게 낮아지며, 범주 불균형이 심화될수록 소수 범주의 분류 정확성은 더욱 낮아지게 된다(Kim et al., 2015).

범주 불균형 문제에 대한 해결 기법은 크게 데이터 샘플링 기법(Data Sampling Techniques)과 알고리즘 기법으로 구분된다. 먼저, 데이터 샘플링 기법은 Under-Sampling과 Over-Sampling 기법으로 나누어지는데 Under-Sampling 기법은 다수 범주의 표본 수를 소수 범주 표본의 수만큼 축소하는 기법이다. 이러한 기법은 표본 데이터의 손실을 초래할 수 있는 문제가 있고, 또한 추출 표본이 모집단의 특성을 대표하지 못할 수도 있다는 단점이 존재한다. 반면 Over-Sampling 기법은 소수 범주의 표본 수를 다수 범주의 표본 수만큼 확대하는 기법으로 정보손실의 문제는 해결할 수 있으나 과적합(Over-Fit) 문제와 학습시간이 오래 걸리는 문제점이 존재하게 된다.

알고리즘 기법은 Cost Sensitive 기법과 앙상블 학습기법으로 나누어지는데, Cost Sensitive 기법은 오분류 관측치에 서로 다른 패널티를 부과하는 방식으로 소수 범주 표본이 오분류된 경우, 다수 범주 표본이 오분류되는 경우보다 높은 패널티를 부과하여 학습하는 방법이다. Cost Sensitive 기법은 데이터 분포는 왜곡시키지 않으나, 불균형 정도가 심화될수록 효과가 작다는 단점이 존재한다(Elkan, 2001; Provost et al., 2001).

최근의 범주 불균형 문제의 해결 대안으로 데이터 샘플링 기법과 앙상블 학습을 결합한 SMOTEBoost(Chawla et al., 2003) 및 RUSBoost(Seiffert et al., 2008) 등의 앙상블 학습기반의 부스팅 알고리즘이 제안되었으며, 범주 불균형 문제에 대하여 효과적인 결과를 보여주었다. 부스팅 알고리즘은 순차적 분류자 생성기법으로 이전 분류자에서 오분류된 관측치에 높은 가중치를 부여하여 다음 분류자에게 학습 비중을 전달하게 된다. 이러한 방식으로 오분류 표본에 대해 강건한 모형을 학습시킬 수 있다는 장점은 있지만, 부스팅 알고리즘은 기본적으로 산술평균 정확도를 성과측정치로 활용하고 있다는 성과측정치의 적합성 문제가 존재한다. 범주 균형 데이터를 대상으로 한 부도예측모형에서 산술평균 정확도는 두 범주의 성과를 균형적으로 보여주는 적합한 성과 측정치라 할 수 있지만, 범주 불균형의 부도예측모형의 경우 다수 범주인 건전 기업의 분류 정확성에 의존하여 모형의 산술평균 정확도(Arithmetic Accuracy)는 지속해서 높아지지만, 정작 경제적으로 중요한 의미

를 가지는 소수 범주(Minority Class)인 부도 기업에 대한 분류의 정확성이 심각하게 저하되기 때문에 성과측정치의 적합성에 대한 의문이 제기되고 있다. 현재, 범주 불균형 데이터에서 산술평균 정확도의 한계점을 보완하기 위한 대체적인 성과지표로서 다수 범주와 소수 범주의 정확도를 동시에 고려할 수 있는 ROC(Receiver Operating Characteristic) 곡선(Davis et al., 2006), AUROC(Weng et al., 2008) 및 기하평균 정확도(Geometric Accuracy)와 같은 대체적인 측정치가 이용되고 있다(Fawcett, 2006; Kim et al., 2015).¹⁾

부스팅 알고리즘의 학습알고리즘인 산술평균 정확도 문제를 해결하기 위하여 최근에는 GMBBoost와 같이 산술평균 정확도를 기하평균 정확도로 대체하고 기하평균 정확도를 최적화함으로써 범주 불균형 문제에서 보다 효과적인 학습 결과를 검증한 알고리즘이 제안되었다(Kim et al., 2015). SVM과 같은 개별 분류자를 활용한 연구에서는 AUROC를 최적화함으로써 분류학습의 성과를 개선한 연구도 다수 진행되고 있지만, 현재까지 AUROC 기반의 부스팅 알고리즘은 거의 제안되지 않고 있다.

본 연구에서는 산술평균 정확도의 대체 성과측정치로 제시된 AUROC를 부스팅 알고리즘과 결합하여 최적화된 학습성적을 제시하는 학습알고리즘으로서 AUCBoost를 제안하고자 한다.

III. 연구 설계

1. 표본 수집 및 변수 선정

표본 수집은 다음과 같이 두 단계 절차에 따라 진행하였다. 먼저 첫 번째 단계에서, 부도 기업은 2015~2018년 중 은행연합회 신용정보등록, 당좌부도 발생, 회사정리 절차 개시, 기업구조조정 절차 개시 등에 해당하는 500개 외부감사 제조 기업으로 구성하였으며, 부도 기업에 대응되는 건전 기업은 외부감사 제조기업 중 2018년 말 기준으로 부도 사유에 해당하지 않는 기업-년도별 10,000개 자료로 구성하였다.

두 번째 단계에서는 범주 불균형 정도에 따라 제안한 알고리즘의 성과 개선 효과를 평가하기 위

1) 아래의 오분류표에서 산술평균 정확도와 기하평균 정확도는 다음과 같이 측정된다.

$$\text{산술평균 정확도} = (TP + TN) / (TP + TN + FN + FP)$$

$$\text{기하평균 정확도} = (\text{민감도} \times \text{특이도}) = [(TP / (TP + FN)) \times (TN / (FP + TN))]$$

		예측 범주	
		Positive	Negative
실제 범주	Positive (소수)	True Positive(TP)	False Negative(FN)
	Negative (다수)	False Positive(FP)	True Negative(TN)

하여 건전 기업에 해당하는 10,000개 기업에 대하여 K-Means Clustering에 기초한 Under-Sampling을 적용하였다. 이를 통해 <표 1>과 같이 A(1:1), B(2:1), C(4:1), D(10:1), E(20:1)의 5개의 표본을 구성하였다.

<표 1> 범주 불균형 데이터 구성

데이터 불균형 비율	건전	부도	합계
1:1	500	500	1,000
2:1	1,000	500	1,500
4:1	2,000	500	2,500
10:1	5,000	500	5,500
20:1	10,000	500	10,500

부도예측을 위한 변수로 일차적으로 기존의 기업부도 예측연구에 사용된 비율 및 실무에서 부도예측 지표로 유용하게 활용되는 30개 재무비율을 수집하였다. 최종 변수를 선정하기 위하여 2단계의 실험을 수행하였다. 첫 번째 단계에서는 수집된 30개의 재무비율을 요인 분석을 통하여 수익성, 부채상환능력, 레버리지 등 7개의 재무비율 군으로 분류하였다. 두 번째 단계에서는 각 재무비율 군별로 AUROC를 측정하여 AUROC가 가장 높은 변수를 그룹별로 선정하여 <표 2>과같이 최종 입력변수로 7개의 재무비율을 선정하였다. 최종 선정된 7개의 재무비율의 다중공선성(Multicollinearity)을 분석하기 위하여 분산팽창요인(Variance Inflation Factor; VIF) 분석을 실시하였다. 검증 결과 7개 변수의 VIF 값은 3 이하로, 실질적인 다중공선성 문제는 없는 것으로 확인되었다.

<표 2> 재무비율의 AUROC

분류	재무비율	AUROC	분류	재무비율	AUROC
수익성	총자산경상이익률*	54.3	레버리지	자기자본비율*	51.7
	총자산순이익률	45.2		유동자산/총자산	49.3
	금융비용/매출액	47.8	자본구조	이익잉여금/총자산*	51.3
	금융비용/총부채	42.1		이익잉여금/총부채	50.5
	순금융비용/매출액	47.3		이익잉여금/유동자산	48.4
	매출액경상이익률	48.2	유동성	현금비율*	48.4
	매출액순이익률	51.1		당좌비율	47.0
	자기자본경상이익률	45.3		유동비율	43.5
	자기자본순이익률	47.9		재고자산회전율*	33.4
부채상환	EBITDA/이자비용*	53.1	활동성	유동부채회전율	29.4
	EBIT/이자비용	49.2		매출채권회전율	25.3
	영업현금흐름/이자비용	44.7	규모	총자산*	23.7
	잉여현금흐름/총부채	46.2		매출액	20.3
	잉여현금흐름/이자비용	51.0		고정자산	23.4
	잉여현금흐름/총부채	48.3			
	부채상환계수	47.2			

주: 1) * 최종 7개 재무비율

2. AdaBoost 알고리즘

AdaBoost 알고리즘은 다양한 부스팅 앙상블 알고리즘 중 가장 일반적으로 사용되는 학습 방법으로 기저 분류자는 이전 분류자의 성과를 기초로 하여, 이전 분류자에서 오분류된 표본의 훈련 비중을 높여 학습한다. 결과적으로 임의의 추측보다 다소 높은 정확성을 보유한 여러 개의 기저 분류자를 학습 생성하고 분류자들을 선형 결합하여 최종 분류자를 생성하는 알고리즘이다. 다수 범주($y=-1$)와 소수 범주($y=+1$)의 두 범주를 가진 전체 학습 표본 S 는 n 개의 표본으로 구성되어 있으며, K 개의 기저 분류자로 구성된 부스팅 모형 $C = \{C_1, C_2, \dots, C_K\}$ 에서 k 번째 분류자의 오류율(e_k)은 식 (1) 과 같이 산술평균 오류로 계산된다. 이와 같이 AdaBoost는 기본적으로 산술평균 오류를 측정하여 산술평균 정확도를 개선하는 알고리즘이다.

$$e_k = \frac{1}{n} \sum_{i=1}^n L(C_k(x_i), y_i), L(C_k(x_i), y_i) = \begin{cases} 1 & y_i C_k(x_i) > 0 \\ 0 & y_i C_k(x_i) \leq 0 \end{cases} \quad (1)$$

여기에서 $C_k(x_i)$ 는 i 번째 표본의 예측범주이며 y_i 는 i 번째 표본의 실제 범주이다. k 번째 분류자에서 i 번째 표본이 오분류되는 경우 $k+1$ 번째 기저 분류자에서 학습 시에 오분류된 i 번째 표본에는 식 (2) 와 같은 가중치가 부여된다.

$$w_{k+1}(i) = \frac{w_k(i) \exp(-\alpha_k y_k C_k(x_i))}{\sum_{i=1}^n \exp(-\alpha_k y_k C_k(x_i))}, \alpha_k = \ln \left(\frac{1-e_k}{e_k} \right) \quad (2)$$

이처럼 이전 분류자에서 오분류된 $k+1$ 표본은 번째 분류자에서 더 높은 가중치를 가지기 때문에, 부스팅 알고리즘은 오분류 관측치에 높은 비중을 두어 학습을 진행한다. 개별 기저 분류자의 학습 결과는 최종 분류자인 부스팅 분류자에 의하여 식 (3) 과 같이 계산된다.

$$C(x_i) = \begin{cases} 1, & \sum_{k=1}^K \alpha_k C_k(x_i) > T(=0) \\ 0, & \sum_{k=1}^K \alpha_k C_k(x_i) \leq T(=0) \end{cases} \quad (3)$$

그러나 식 (3)의 경우 범주 불균형 문제에서 2가지 문제점이 존재한다. 첫째, 기저 분류자의 결합 비중은 개별 기저 분류자의 성과지표 e_k 에 기초하여 측정된다. 범주 불균형이 존재할 경우, 산술 평균 정확도에 기초한 가중치 결합 비중은 다수 범주에 치우쳐져 있지만 소수 범주를 무시하기 때문에

적절한 성과 측정이 불가능하다. 둘째, 최종 분류자의 임계값(T)은 최종 추정치를 범주 예측으로 변환하는데 사용된다. 범주 불균형 문제에서 임계값은 특히 범주의 사전 확률에 영향을 받는 경향이 있기 때문에, 최종 분류자의 성능에 영향을 미칠 수 있고 이로 인해 발생하는 오분류 비용을 고려하여 임계값을 선정할 필요가 있다.

본 연구에서는 범주 불균형에서 임계값 문제를 해결하기 위하여 Thresholding Method 방법을 적용하였다. 식 (3)에 제시된 다수 범주와 소수 범주를 분류하는 임계점(T)은 AUROC를 극대화하는 임계점으로 민감도(Sensitivity)와 특이도(Specificity)가 가장 유사한 값을 탐색하여 선택하였다.

〈그림 1〉 AdaBoost 알고리즘

Algorithm	AdaBoost Algorithm
Input	Train Set $S = (x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)$, where $y_i \in \{-1, 1\}$
	Define a uniform distribution $w_1(i)$ over elements of S
for $k = 1$ to K do	
	Train model C_k using distribution w_k
	If $e_k \geq 0.5$ break
	Set $\alpha_k = \frac{1}{2} \ln \left(\frac{1 - e_k}{e_k} \right)$
	Update $w_{k+1}(i) = \frac{w_k(i) \exp(-\alpha_k y_k C_k(x_i))}{\sum_{i=1}^n \exp(-\alpha_k y_k C_k(x_i))}$
end for	
	For a new testing point (x', y') ,
	$C(x'_i) = \begin{cases} 1, & \sum_{k=1}^K \alpha_k C_k(x'_i) > T \\ 0, & \sum_{k=1}^K \alpha_k C_k(x'_i) \leq T \end{cases}$

3. AUCBoost 알고리즘

학습표본 S 가 n^- 개의 다수 범주 표본($y=-1$)과 n^+ 개의 소수 범주 표본($y=+1$)으로 구성되어 있을 때 K 개의 기저 분류자 $C = \{C_1, C_2, \dots, C_K\}$ 의 개별 학습 결과를 가중 결합하여 최종 결론을 도출하기 위한 최종 분류자 AUCBoost의 목적함수는 AUROC의 극대화이며 제약조건은 기저 분류자에 부여되는 개별 가중치(w_k)는 0과 1 사이의 값으로 결정되며 결합가중치의 총합은 1로 이러한 원시 문제(Primal Problem)를 쌍대문제(Dual Problem)로 정의할 때 식 (4)와 같은 이차계획법(Quadratic

Programming, QP) 함수로 정의할 수 있다.

$$\text{목적 함수 : } \text{Min } AAC^2 = (1 - AUROC)^2$$

$$\text{제약 조건 : } 0 \leq w_i \leq 1, \sum_i^n w_i = 1 \quad (4)$$

여기에서,
$$AUROC = \frac{\sum_{i=1}^{n^+} \sum_{j=1}^{n^-} 1(C(x_i^+) > C(x_j^-))}{n^+ n^-}$$

$$1[C(x^+) > C(x^-)] = \begin{cases} +1 & \text{if } C(x^+) > C(x^-) \\ 0 & \text{otherwise } C(x^+) \leq C(x^-) \end{cases}$$

$$C(x_i^+) = \sum_{k=1}^K \sum_{i=1}^{n^+} w_k C_k(x_i^+), \quad C(x_j^-) = \sum_{k=1}^K \sum_{j=1}^{n^-} w_k C_k(x_j^-)$$

식 (4) 의 QP 문제에서 AAC(Area Above the Curve)를 극소화하는 최적의 가중치(w^*)를 구하기 위하여 Taylor 급수(Taylor series approximation)에 따라 변환하게 되면 식 (5) 와 같은 미분 함수로 정의할 수 있다.

$$\text{목적 함수 : } \text{Min } AAC - \nabla AAC^T \cdot d - \frac{1}{2} \nabla^2 AAC \cdot L(w_k, y, \alpha_k, \beta_k, \gamma) \cdot d$$

$$\text{제약조건 : } 0 \leq \forall (w_k + \nabla w_k^T \cdot d) \leq 1, \sum_{k=1}^K w_k + \nabla \left(\sum_{k=1}^K w_k \right)^T \cdot d = 1 \quad (5)$$

여기에서, $\alpha_k, \beta_k, \gamma$ = 제약조건에 대한 라그랑주 계수

$$L(w_k, \alpha_k, \beta_k, \gamma) = AAC^2 - \sum_{k=1}^K w_k \alpha_k - \sum_{k=1}^K w_k \beta_k - \gamma \sum_{k=1}^K w_k$$

식 (5) 에서 목적함수(AAC)는 연속형 함수가 아닌 계단형 함수(Step Function) 형태를 가진 이산형 함수로서 직접적인 도함수를 정의할 수 없기 때문에, 본 연구에서는 w_k 의 미세 변화 값(ϵ)을 도입하였다. 결과적으로 1차 도함수(∇AAC)의 평균변화율과 2차 도함수($\nabla^2 AAC$)의 평균변화율은 식 (6) 과 같이 정의된다.

$$\text{1차 도함수}(\nabla AAC) \text{의 평균변화율} = \frac{f(w_k + e) - f(w_k)}{w_k + e - w_k}$$

$$\text{2차 도함수}(\nabla^2 AAC) \text{의 평균변화율} = \frac{f(w_k + e) - 2f(w_k) + f(w_k - e)}{(w_k + e - w_k)(w_k - (w_k - e))} \quad (6)$$

식 (5) 의 제약조건 $L(w_k, \alpha_k, \beta_k, \gamma)$ 을 라그랑지안 문제(Lagrangian Problem)로 변형하면 식 (7) 과 같이 정의된다.

$$\text{목적함수: } Min AAC - \nabla AAC^T \cdot d - \frac{1}{2} \nabla^2 AAC \cdot \left(AAC^2 - \sum_{k=1}^K w_k \alpha_k - \sum_{k=1}^K w_k \beta_k - \gamma \sum_{k=1}^K w_k \right) \cdot d \quad (7)$$

식 (7) 에서 벡터값으로 변화 가중치 값(d)을 구하여 기존의 결합 가중치(w_k^{old})에 d 를 가산하고 정규화하여 식 (8) 과 같이 새로운 결합 가중치(w_k^{new})가 산출된다.

$$\frac{w_k^{new} (= w_k^{old} + d)}{\sum_{k=1}^K w_k^{new}} \quad (8)$$

새로운 결합 가중치를 개별 기저 분류자에 순차적으로 적용하여 목적함수(AAC)의 변화가 0 미만일 경우(즉, AUROC가 증가하는 경우) 기존 결합 가중치는 새로운 결합 가중치로 대체되지만 목적함수(AAC)의 변화가 0 이상일 경우(즉, AUROC가 동일 또는 감소하는 경우) 기존 결합 가중치는 기존 값으로 유지된다. 이러한 과정을 종료 조건(Stop Condition)이 만족할 때까지 순차적으로 반복 수행함으로써 AUROC를 최대화하는 최적의 결합 가중치(w^*)가 탐색 된다.

〈그림 2〉 AUCBoost 알고리즘

Algorithm	AUCBoost
Input	Required ensemble size K , small change e , Max Epoch
	Define a uniform distribution w_1 over elements of K
for $t = 1$ to Max Epoch do	
	Define Dual Form with w_t
	Calculate $\nabla ACC, \nabla^2 ACC$ with w_t, e using average rate of change and define $L(w_k, \alpha_k, \beta_k, \gamma)$
	Change to Lagrangian problem and find problem's solution d
	Update $w_{t+1} = w^{new} = \frac{w^{old} + d}{\sum_{k=1}^K w_k^{new}}$
	If $ACC_t \geq ACC_{t+1}$ break
end for	
	For a new testing point (x', y') ,
	$C(x'_i) = \begin{cases} 1, & \sum_{k=1}^K \alpha_k C_k(x'_i) > T \\ 0, & \sum_{k=1}^K \alpha_k C_k(x'_i) \leq T \end{cases}$

AdaBoost와 AUCBoost의 가장 큰 차이점은 AdaBoost 알고리즘은 범주 불균형 문제에 대한 고려없이 전반적인 예측 오차를 최소화하여 산술평균 정확도를 극대화하는 것을 학습목적으로 한다. 이러한 특성으로 인하여 소수 범주의 성과를 개선하기 보다는 다수 범주의 정확도에 의존하여 다수 범주의 성과개선에 주목하여 학습을 진행하게 된다. 이러한 학습 결과로서 민감도(다수 범주의 정확도)는 증가하지만 특이도(소수 범주의 정확도)는 급속하게 감소하게 된다. 반면에 AUCBoost는 AUROC를 최적화를 목적으로 기저분류자의 최적 결합 가중치를 설정하게 된다. 최적화된 AUROC는 정확도를 개선하는 효과와 더불어 동시에 민감도와 특이도를 유사한 수준에서 유지하는 특성을 가진다. 이러한 특성으로 인하여 AUCBoost는 다수 범주와 소수 범주의 사례들에 대한 균형 학습을 진행하게 되며, 범주 불균형 문제에 대하여 더욱 강건한 분류모형이라는 장점을 가지게 된다.

4. 모형 설계

본 연구에서 기저 분류자는 3층 퍼셉트론 인공신경망으로 입력층은 7개의 노드, 은닉층은 5개의 노드, 출력층은 1개의 노드로 구성하였다. 입력층은 변수선정에서 선택한 7가지 재무비율 지표에 대응되며 은닉층과 출력층은 출력함수로 Sigmoid 함수를 활용하였다. 기저 분류자의 학습조건으로는 학습률(learning-rate) = 0.1을 설정하였으며 종료 조건으로 최대 epoch를 10,000으로 설정하였다.

AdaBoost 모형에서 기저 분류자의 추가적인 생성은 전통적인 앙상블 생성 조건과 동일하게 기저 분류자의 오분류율이 50% 이상($e_k \geq 0.5$)인 경우 기저 분류자의 생성을 중단하도록 설정하였다.

AUCBoost 모형에서 기저 분류자의 학습 결과를 결합하기 위한 결합 가중치는 $1/K$ 로 초기화하였으며 평균변화율에 계산에 활용되는 미세 변화값(e)은 0.001로 설정하였다. 앙상블 학습의 종료 조건으로 최대 epoch를 10,000 또는 목적함수인 AAC 의 변화 값이 0일 경우 자동 중단하도록 설정하였다.

IV. 연구결과

기존의 AdaBoost와 본 연구에서 제안한 AUCBoost 알고리즘의 성과를 비교하기 위해 10-fold 교차타당성 검증(10-fold cross validation)을 3회 반복하여 수행하였다. 10-fold 교차타당성 검증은 전체 표본에서 표본 수가 동일하도록 10개의 fold로 분할하고, 이 중 9개의 집합을 학습용 데이터, 1개의 집합을 검증용 데이터로 활용하여 성과를 검증하는 방식이다. 이러한 방식으로 10-fold 검증을 3회 수행하여 총 30회의 교차 타당성 검증을 수행하였다. <표 3>은 30회 교차 타당성 검증 결과로서 AdaBoost와 AUCBoost 알고리즘의 학습 성과의 평균과 t -test 차이검정의 결과를 범주 불균형 비율 및 성과지표에 따라 보여주고 있다.

<표 3> AdaBoost와 AUCBoost 알고리즘의 성과비교

데이터 불균형 비율	산술평균			기하평균			AUROC		
	AdaBoost	AUCBoost	t-value	AdaBoost	AUCBoost	t-value	AdaBoost	AUCBoost	t-value
1:1	0.867	0.892	1.598*	0.866	0.890	1.555*	0.924	0.952	2.12**
2:1	0.834	0.873	2.731***	0.833	0.872	2.696***	0.903	0.940	2.373**
4:1	0.805	0.843	2.811***	0.805	0.839	2.209**	0.877	0.919	2.564***
10:1	0.756	0.799	3.644***	0.755	0.796	2.999***	0.828	0.879	3.289***
20:1	0.694	0.775	5.789***	0.701	0.771	4.044***	0.760	0.853	4.674***

주: 1) *는 10% 수준에서 유의, **는 5% 수준에서 유의, ***는 1% 수준에서 유의


산술평균 정확도 측면에서 AdaBoost와 비교하여 AUCBoost 알고리즘은 균형 데이터 A(1:1)만 10% 수준에서 한계적으로 유의할 뿐 다른 모든 데이터 셋에 대하여 모두 1% 수준에서 기존 알고리즘 대비 유의한 정확도 개선 효과를 보여주었다. 또한, 불균형 데이터 B(2:1)에서 산술평균 정확도는 0.834에서 0.873로 약 4% 개선이 되었지만, 데이터 E(20:1)의 경우 산술평균 정확도는 0.694에서 0.775로 11% 개선되어 범주 불균형이 심해질수록 성능개선의 효과가 확대되는 것으로 나타났다.

동일하게 기하평균 정확도 측면에서도 범주 균형 데이터 A(1:1)를 제외한 모든 데이터 셋에 대하여 1% 수준에서 기존 알고리즘 대비 유의한 정확도 개선 효과를 보여주었다. 기하평균 정확도 또한 불균형 데이터 B(2:1)에서 4%(0.833에서 0.872) 서과개선이 이루어진 것에 비해, 불균형 데이터 E(20:1)의 경우 0.701에서 0.771로 10%의 성능개선이 이루어져 범주 불균형이 심화될수록 성과개선이 확대되었다.

AUROC의 경우, 균형 범주와 불균형 범주 모두에서 유의적인 성과개선을 확인하였다. 균형 데이터 A(1:1)의 경우 0.924에서 0.952로 3%가량 성능이 개선되었으나 불균형 데이터 E(20:1)의 경우 0.760에서 0.853으로 12%가량 개선되어 불균형이 심화될수록 AUCBoost 알고리즘이 성과개선 효과가 확대되는 것으로 확인되었다.

〈그림 3〉은 AdaBoost와 AUCBoost의 성과차이를 그래프로 표현하고 있다. 〈그림 3〉에 제시한 바와 같이 AUCBoost는 AdaBoost의 성과를 유의적으로 개선하는 효과를 제공하고 있다. 특히, 범주 불균형 비율이 심해질수록 AUCBoost의 성능개선 효과가 증폭되는 것으로 나타났다. 이러한 결과는 산술평균 기반으로 기저분류자의 결합 가중치를 결정하는 AdaBoost는 범주 불균형 문제 해결에 한계점이 있는 반면, 본 연구에서 제안한 AUCBoost는 AUROC 극대화를 통하여 기저 분류자의 결합 가중치를 최적화함으로써 범주 불균형 문제를 효과적으로 해결하고 있음을 의미한다. 특히, AUCBoost는 1:1의 균형 데이터와 모든 불균형 데이터에서 AUROC 뿐만 아니라 산술평균 정확도와 기하평균 정확도의 개선에도 기여하는 것으로 나타나 AUCBoost는 균형 및 불균형 데이터 모두에서 성과개선의 효과를 제공하는 강건한 분류 알고리즘으로 확인되었다.

〈그림 1〉 AdaBoost와 AUCBoost의 성과 비교



V. 결론

본 연구는 범주의 분포가 균일하지 않은 부도예측모형에서 AUROC 기반의 앙상블 알고리즘을 제안하였다. 실험 결과 본 연구에서 제안한 AUCBoost 알고리즘이 전통적인 방식의 AdaBoost 알고리즘보다 성과가 유의적으로 개선된 것을 보여 더욱 우수한 분류 알고리즘임을 확인하였다. 특히 범주 불균형 정도가 심해질수록 AdaBoost 알고리즘은 AdaBoost 알고리즘의 유의적인 성과개선에 공헌하고 있음을 확인하였다. 본 연구의 성과는 부도예측뿐만 아니라 보험사기, 신용카드사기 등 다양한 범주 불균형 상황에서 적용할 수 있을 것으로 예상되어 추가적인 연구가 진행될 것으로 기대한다.

본 연구의 공헌 점은 다음과 같다. 첫째, 기업의 부도에 따른 손실은 기업의 이해관계자뿐만 아니라 국민경제 전반에 미치는 영향이 계량화가 불가능할 정도로 막대한 손실을 야기하기 때문에 부도

기업예측에 대한 연구는 한정된 자원을 효율적으로 배분하기 위한 재무 및 회계 분야의 오랜 연구 주제로 인식되어 왔다. 부도 기업의 징후를 사전적으로 예측할 수 있는 선진화된 기법의 적용은 국민 경제적 손실을 축소하기 위한 사전적 조치를 모색하게 하며, 금융기관이나 이해관계자들은 합리적인 자원 배분의 의사결정을 가능하게 함으로써 기업부도에 따른 손실의 최소화에 기여할 수 있다. 둘째, 통계모형 기반의 부도예측모형은 독립변수의 정규성 및 두 집단자료의 등분성성을 가정하고 있으나, 본 연구에서 제안한 AI 기반의 부도 예측모형은 이러한 통계적 제약에서 자유롭다는 측면에서 예측 모형의 타당성과 일반화를 제고할 수 있다. 셋째, 범주 불균형 문제는 부도예측모형의 성과를 저하하는 문제로 선행 연구들에서는 새로운 성과 측정치로 AUROC의 적용을 제안하고 있다. 본 연구에서는 AUROC 기반한 AUCBoost 기법을 통하여 탁월한 성과개선 효과를 검증함으로써 정교한 AI 기반의 부도예측모형의 확산에 대한 이론적 토대를 제공하고 있다.

이러한 공헌점에도 본 연구는 다음과 같은 한계점이 존재한다. 첫째, 본 연구에서는 범주 불균형 문제에서의 성과측정치로 AUROC의 최적화에 주목하고 있다. 다른 범주 불균형 데이터의 성과지표로서 산술평균 정확도 및 기하평균 정확도 등의 성과측정치를 최적화하기 위한 예측 기법도 개발이 필요하다. 둘째, 본 연구에서는 군집별 평균값을 위주로 표본을 추출하는 k-Means Clustering 기법을 활용하여 Under-Sampling을 수행하였다. k-Means Clustering 기법을 활용하는 경우 표본의 평균은 이상치에 민감하게 반응하기 때문에 적절한 표본이 추출되지 못할 가능성이 있다. 이상치에 대한 민감도를 고려하여 이상치에 강건한 k-Medoids 등과 같은 여러 Under-Sampling 기법도 접목할 필요성이 있다.

본 연구의 향후 연구 주제로서 다음과 같은 연구가 진행되길 기대한다. 첫째, 본 연구에서 기저 분류자의 종류를 다층퍼셉트론(MLP)을 활용하였지만, 향후 연구에서는 SVM, 의사결정나무, 로지스틱회귀분석(Logistic-Regression Analysis) 등 다양한 분류자와의 결합방식을 검토할 필요가 있다. 둘째, 본 연구에서는 기저 분류자들의 개별 학습결과를 AUROC를 기준으로 한 앙상블 학습을 통하여 결합하여 최종 결과를 도출하였다. 향후 연구에서는 개별 분류자 자체에서도 학습기준을 AUROC로 설정하여 범주 불균형에서 학습 성과를 개선하기 위한 노력이 필요하다. 셋째, 본 연구에서는 전통적으로 부도예측모형에 활용되어 왔던 재무지표 비율을 예측변수로 활용하였다. 4차 산업혁명 시대에서 방대한 데이터를 효과적으로 활용하기 위해서는 데이터마이닝과 텍스트마이닝을 활용하여 유의미한 독립변수를 추출하고 부도예측에 활용하기 위한 개발이 시도되기를 기대한다.

참고문헌

- 권혁건 · 이동규 · 신민수(2017), “RNN(Recurrent Neural Network)을 이용한 기업부도예측모형에서 회계정보의 동적 변화 연구,” 「지능정보연구」, 제23권 제3호, pp. 139~153.
- 김명종(2009), “기업부실 예측 데이터의 불균형 문제 해결을 위한 앙상블 학습,” 「지능정보연구」, 제15권 제3호, pp. 1~15.
- 김은미 · 박지영(2019), “온라인 P2P 환경에서 딥러닝을 적용한 다분류 기반 개인신용등급 예측모형,” 「인터넷전자상거래연구」, 제19권 제4호, pp. 43~57.
- 김형준 · 류두진 · 조 훈(2019), “기업부도예측과 기계학습,” 「한국금융공학회」, 제18권 제3호, pp. 131~152.
- 맹수석 · 이형욱(2017), “핀테크(FinTech) 진전과 금융소비자보호 방안,” 「기업법연구」, 제31권 제4호, pp. 331~365.
- 민성환(2014), “개선된 배경 앙상블을 활용한 기업부도예측,” 「지능정보연구」, 제20권 제4호, pp. 121~139.
- 배재권(2018), “국내 인터넷전문은행 서비스의 이용요인 및 활성화요인에 관한 연구,” 「예술인문사회융합 멀티미디어 논문지」, 제8권 제6호, pp. 897~907.
- 신동인 · 박기영(2018), “코스닥 시장의 관리종목 지정 탐지 모형 개발,” 「지능정보연구」, 제24권 제3호, pp. 157~176.
- 신현규 · 안수현(2020), “핀테크에 따른 전자어음의 새로운 위상,” 「은행법학회」, 제13권 제1호, pp. 63~113.
- 조성빈(2020), “기업도산예측에 대한 의사결정나무 앙상블 모델 평가,” 「한국경영공학회지」, 제25권 제4호, pp. 63~71.
- 최하나 · 임동훈(2013), “앙상블 SVM 모형을 이용한 기업 부도 예측,” 「한국데이터정보과학회지」, 제24권 제6호, pp. 1113~1125.
- 홍승현 · 신경식(2003), “유전자 알고리즘을 활용한 인공신경망 모형 최적입력변수의 선정: 부도예측 모형을 중심으로,” 「지능정보연구」, 제9권 제1호, pp. 227~249.
- Altman, E. L.(1968), “Financial ratios, discriminant analysis and the prediction of corporate bankruptcy,” *The Journal of Finance*, 23(4), pp. 589~609.
- Beaver, W.(1996), “Financial ratios as predictors of failure, empirical research in accounting: Selected studied”, *Journal of Accounting Research*, 4(3), pp. 71~111.

- Buda, M., A. Maki, and M. A. Mazurowski.(2018), "A systematic study of the class imbalance problem in convolutional neural networks", *Neural Networks*, 106, pp. 249–259.
- Buta, P.(1994), "Mining for financial knowledge with CBR", *AI Expert*, 9(10), pp. 34~41.
- Chawla, N. V., A. Lazarevic, L. O. Hall, and K. W. Bowyer(2003), "SMOTEBoost : Improving prediction of the minority class in boosting", *In: Proceedings of 7th European conference on principles and practice of knowledge discovery in databases*, pp. 107~119.
- Davis, J., and M. Goadrich(2006), "The relationship between precision–recall and roc curves," *In: Proceedings of the 23rd international conference on machine learning, ICML '06. ACM*, New York, NY, USA, pp. 233~240.
- Dimitras, A. I., S. H. Zanakis, and C. Zopounidis(1996), "A survey of business failure with an emphasis on prediction methods and industrial applications," *European Journal of Operational Research*, 90(3), pp. 487~513.
- Elkan, C.(2001), "The foundations of cost–sensitive learning," *In: Proceedings of the 17th international joint conference on artificial intelligence*, San Francisco, CA, USA, 2, pp. 973~978.
- Fawcett, T.(2006), "An introduction to ROC anlysis," *Pattern Recognition Letter*, 27, pp. 861~874.
- Freund, Y., and R. E. Schapire(1997), "A decision–theoretic generalization of on–line learning and an application to boosting," *Journal of Computer and System Sciences*, 55, pp. 119~139.
- Kim, M. J.(2009), "A Performance Comparison of Ensemble in Bankruptcy Prediction," *Entrue Journal of Information Technology*, 8(2), pp. 41~49.
- Kim, M. J.(2015), "Geometric mean based boosting algorithm with over–sampling to resolve data imbalance data imbalance problem for bankruptcy prediction," *Expert Systems with Applications*, 42, pp. 1074~1082.
- Messier, W. F. Jr., and J. V. Hansen(1998), "Inducing rules for expert system development: an example using default and bankruptcy data," *Management Science*, 34(12), pp. 1403~1415.
- Ohlson, J.(1980), "Financial ratios and the probabilistic prediction of bankruptcy," *Journal of Accounting Research*, 18(1), pp. 109–131.
- Provost, F., and T. Fawcett(2001), "Robust classification for imprecise environments," *Machine Learning*, 42, pp. 203~231.
- Tai, Qiu–yue, and Kyung–shik Shin.(2010), "GA–optimized Nonlinear Fuzzy Normalization Approach in Back–Propagation Neural Network for Bankruptcy Prediction Modeling," 『한국지능 정보시스템학회 학술대회논문집』, pp. 294–302.

- Schapire R.E., Y. Freund, P. Bartlett, and W. S. Lee(1997), "Boosting the margin: a new explanation for the effectiveness of voting methods," *Proc. Of the 14th Int.Conference on Machine Learning*.
- Seiffert, C., T. M. Khoshgoftaar, J. V. Hulse, and A. Napolitano(2008), "RUSBoost : Improving classification performance when training data is skewed," *In : Proceedings of the 19th international conference on pattern recognition*, pp. 1~4.
- Shin, K., T. Lee, and H. Kim(2005), "An application of support vector machines in bankruptcy prediction," *Expert Systems with Applications*, 28, pp. 127~135.
- Tam, K. Y., and M. Y. Kiang(1992), "Managerial applications of neural networks: the case of bank failure predictions," *Management Science*, 38(7), pp. 926~947.
- Weng, C. G., and J. Poon(2008), "A new evaluation measure for imbalanced datasets," *In Proceedings of the 7th Australasian data mining conference—Vol. 87. AusDM '08. Australian Computer Society, Inc., Darlinghurst, Australia*, pp. 27~32.